

# Elementos de Cálculo Numérico

Martín D. Maas

June 10, 2026

# Contents

|                                                                   |           |
|-------------------------------------------------------------------|-----------|
| <b>Introducción</b>                                               | <b>5</b>  |
| <b>1 Fundamentos de la Computación Numérica</b>                   | <b>7</b>  |
| 1.1 Máquinas de Turing y Computabilidad . . . . .                 | 7         |
| 1.1.1 Máquinas de Turing . . . . .                                | 7         |
| 1.1.2 Cálculo de la complejidad de un algoritmo . . . . .         | 9         |
| 1.1.3 Análisis de algoritmos recursivos . . . . .                 | 10        |
| 1.1.4 El Teorema Maestro . . . . .                                | 12        |
| 1.2 Aritmética de Máquina . . . . .                               | 15        |
| 1.2.1 Enteros de 64 bits . . . . .                                | 15        |
| 1.2.2 Números de punto flotante . . . . .                         | 16        |
| 1.2.3 Épsilon de máquina . . . . .                                | 17        |
| 1.2.4 Redondeo y la cota fundamental de error . . . . .           | 18        |
| 1.2.5 Consecuencias y ejemplos . . . . .                          | 21        |
| 1.2.6 Precisión arbitraria por software . . . . .                 | 21        |
| 1.2.7 Ejemplos en geometría computacional . . . . .               | 22        |
| <b>2 Álgebra Lineal Numérica</b>                                  | <b>23</b> |
| 2.1 Eliminación Gaussiana y factorización LU . . . . .            | 23        |
| 2.1.1 Eliminación Gaussiana sin pivoteo . . . . .                 | 23        |
| 2.1.2 Factorización LU . . . . .                                  | 24        |
| 2.1.3 Pivoteo parcial y factorización PLU . . . . .               | 25        |
| 2.2 Ortogonalización de Gram-Schmidt y factorización QR . . . . . | 25        |
| 2.2.1 Proceso de Gram-Schmidt clásico . . . . .                   | 25        |
| 2.2.2 Gram-Schmidt Modificado (MGS) . . . . .                     | 26        |
| 2.2.3 Factorización QR . . . . .                                  | 26        |
| 2.3 Cuadrados mínimos y proyección ortogonal . . . . .            | 28        |
| 2.3.1 Ecuaciones normales para cuadrados mínimos . . . . .        | 28        |
| 2.3.2 QR para cuadrados mínimos . . . . .                         | 29        |
| 2.4 Descomposición en Valores Singulares (SVD) . . . . .          | 30        |
| 2.4.1 Pseudoinversa de Moore-Penrose . . . . .                    | 32        |
| 2.4.2 Condicionamiento y problemas mal condicionados . . . . .    | 34        |
| 2.4.3 Propiedades de la norma de matrices . . . . .               | 35        |
| 2.4.4 Regularización de Tikhonov . . . . .                        | 38        |

|          |                                                                    |           |
|----------|--------------------------------------------------------------------|-----------|
| 2.4.5    | Aproximación de bajo rango (Teorema de Eckart-Young) . . . . .     | 39        |
| 2.4.6    | Norma de Frobenius y propiedades de la traza . . . . .             | 40        |
| 2.5      | Métodos iterativos para autovalores . . . . .                      | 41        |
| 2.5.1    | Teorema de los círculos de Gershgorin . . . . .                    | 41        |
| 2.5.2    | El método de la potencia . . . . .                                 | 42        |
| 2.5.3    | El método QR . . . . .                                             | 42        |
| 2.5.4    | Matriz compañera y raíces de polinomios . . . . .                  | 43        |
| 2.6      | Métodos iterativos para sistemas lineales . . . . .                | 43        |
| 2.6.1    | Métodos estacionarios y convergencia . . . . .                     | 43        |
| 2.6.2    | Método de Jacobi . . . . .                                         | 44        |
| 2.6.3    | Método de Gauss-Seidel . . . . .                                   | 44        |
| <b>3</b> | <b>Interpolación</b>                                               | <b>45</b> |
| 3.1      | Existencia y unicidad del interpolante . . . . .                   | 45        |
| 3.1.1    | La matriz de Vandermonde . . . . .                                 | 46        |
| 3.1.2    | La base de Lagrange . . . . .                                      | 47        |
| 3.1.3    | La forma baricéntrica . . . . .                                    | 47        |
| 3.2      | Interpolación sobre $\mathbb{R}$ . . . . .                         | 48        |
| 3.2.1    | Error de interpolación . . . . .                                   | 48        |
| 3.2.2    | Cuadratura interpolatoria . . . . .                                | 50        |
| 3.2.3    | Las raíces de la unidad como nodos de interpolación . . . . .      | 52        |
| 3.2.4    | Matriz de Vandermonde y la transformada inversa (IDFT) . . . . .   | 52        |
| 3.2.5    | Transformada Rápida de Fourier (FFT) . . . . .                     | 54        |
| 3.2.6    | Criterio de Nyquist-Shannon y aliasing . . . . .                   | 56        |
| 3.2.7    | Convolución discreta . . . . .                                     | 57        |
| 3.2.8    | Filtrado digital de señales . . . . .                              | 58        |
| 3.2.9    | Multiplicación rápida de polinomios . . . . .                      | 59        |
| 3.2.10   | Principio de incertidumbre de Donoho-Stark para la DFT . . . . .   | 60        |
| 3.3      | Interpolación sobre cuerpos finitos . . . . .                      | 61        |
| 3.3.1    | Cuerpos finitos: estructura algebraica . . . . .                   | 62        |
| 3.3.2    | Interpolación en $\mathbb{Z}_p$ : teoría . . . . .                 | 62        |
| 3.3.3    | Implementación computacional . . . . .                             | 63        |
| 3.3.4    | Aplicación: Esquema de secreto compartido de Shamir . . . . .      | 64        |
| 3.3.5    | Aplicación: Códigos de Reed-Solomon . . . . .                      | 66        |
| <b>4</b> | <b>Series de Fourier Generalizadas</b>                             | <b>67</b> |
| 4.1      | Series de Fourier de funciones suaves periódicas . . . . .         | 72        |
| 4.1.1    | La serie trigonométrica real . . . . .                             | 72        |
| 4.1.2    | Decaimiento de los coeficientes de Fourier y regularidad . . . . . | 73        |
| 4.1.3    | Cuadratura de funciones suaves y periódicas . . . . .              | 75        |
| 4.1.4    | El fenómeno de Gibbs . . . . .                                     | 82        |
| 4.1.5    | Aplicaciones: ODEs periódicas y ecuaciones integrales . . . . .    | 82        |
| 4.2      | Series de Chebyshev . . . . .                                      | 85        |
| 4.2.1    | De Fourier a Chebyshev: El cambio de variable coseno . . . . .     | 86        |
| 4.2.2    | Los polinomios de Chebyshev y la serie de Chebyshev . . . . .      | 87        |

|          |                                                                              |            |
|----------|------------------------------------------------------------------------------|------------|
| 4.2.3    | Ortogonalidad . . . . .                                                      | 88         |
| 4.2.4    | Interpolación baricéntrica y matriz de diferenciación de Chebyshev . . . . . | 89         |
| 4.2.5    | Reglas de cuadratura en nodos de Chebyshev . . . . .                         | 91         |
| 4.3      | Polinomios Ortogonales . . . . .                                             | 93         |
| 4.3.1    | Familias clásicas de polinomios ortogonales . . . . .                        | 94         |
| 4.3.2    | Tasa de convergencia para funciones suaves: un caso general . . . . .        | 94         |
| 4.4      | Cuadratura Gaussiana . . . . .                                               | 95         |
| 4.4.1    | Motivación y definición . . . . .                                            | 95         |
| 4.4.2    | Exactitud y positividad . . . . .                                            | 96         |
| 4.4.3    | Error de cuadratura . . . . .                                                | 97         |
| 4.4.4    | Cálculo de nodos y pesos: Método de Golub-Welsch . . . . .                   | 98         |
| 4.5      | Error de interpolación . . . . .                                             | 99         |
| <b>5</b> | <b>Métodos de diferencias finitas</b>                                        | <b>103</b> |
| 5.1      | Problemas de valores iniciales . . . . .                                     | 103        |
| 5.1.1    | Métodos de un paso . . . . .                                                 | 105        |
| 5.1.2    | La función de incremento $\Phi$ . . . . .                                    | 106        |
| 5.1.3    | Convergencia de métodos de un paso . . . . .                                 | 106        |
| 5.1.4    | Problemas rígidos o “stiff” . . . . .                                        | 108        |
| 5.2      | Problema de valores de contorno . . . . .                                    | 110        |
| 5.2.1    | Estabilidad y convergencia . . . . .                                         | 111        |
| 5.2.2    | Caso periódico y diagonalización de Fourier . . . . .                        | 113        |
| 5.3      | Ecuaciones en Derivadas Parciales . . . . .                                  | 114        |
| 5.3.1    | Discretización espacial centrada + Euler en tiempo . . . . .                 | 114        |
| 5.3.2    | Error de truncamiento . . . . .                                              | 115        |
| 5.3.3    | Consistencia y estabilidad de Lax–Richtmyer . . . . .                        | 116        |
| 5.3.4    | Factores de amplificación de Fourier (borde periódico) . . . . .             | 116        |
| 5.3.5    | Análisis de estabilidad de Fourier: explícito e implícito . . . . .          | 118        |
| <b>6</b> | <b>Métodos iterativos para Ecuaciones No Lineales</b>                        | <b>122</b> |
| 6.1      | El método de bisección . . . . .                                             | 123        |
| 6.2      | Iteraciones de punto fijo . . . . .                                          | 124        |
| 6.3      | El método de Newton . . . . .                                                | 127        |
| 6.3.1    | Derivación . . . . .                                                         | 127        |
| 6.3.2    | Convergencia . . . . .                                                       | 127        |
| 6.3.3    | Newton para funciones convexas . . . . .                                     | 128        |
| 6.4      | El método de la secante . . . . .                                            | 129        |
| <b>A</b> | <b>Herramientas de Análisis y Álgebra</b>                                    | <b>132</b> |
| A.1      | Teorema del valor intermedio . . . . .                                       | 132        |
| A.2      | Teorema de Rolle . . . . .                                                   | 132        |
| A.3      | Teorema del valor medio para derivadas . . . . .                             | 133        |
| A.4      | Regla de la cadena . . . . .                                                 | 133        |
| A.5      | Teorema del valor medio para integrales . . . . .                            | 134        |
| A.6      | Desarrollo de Taylor . . . . .                                               | 135        |

|          |                                                                 |            |
|----------|-----------------------------------------------------------------|------------|
| A.7      | Fórmulas de sumatorias y series . . . . .                       | 136        |
| A.8      | Identidades exponenciales y trigonométricas . . . . .           | 137        |
| A.9      | Criterio M de Weierstrass . . . . .                             | 138        |
| A.10     | Jacobiana, gradiente y Hessiana . . . . .                       | 138        |
| A.11     | Subespacios y dimensiones . . . . .                             | 139        |
| A.12     | Polinomios sobre un cuerpo . . . . .                            | 140        |
| <b>B</b> | <b>Espacios de Pre-Hilbert</b>                                  | <b>141</b> |
| B.1      | Definiciones básicas . . . . .                                  | 141        |
| B.2      | Ortogonalidad y Proyección . . . . .                            | 142        |
| B.3      | Factorización de Schur y Teorema Espectral . . . . .            | 144        |
| <b>C</b> | <b>Convergencia de Series de Fourier</b>                        | <b>148</b> |
| C.1      | Convergencia puntual de sumas parciales . . . . .               | 148        |
| C.2      | Convergencia uniforme para funciones suaves . . . . .           | 150        |
| C.3      | Densidad de trigonométricas e igualdad de Parseval . . . . .    | 153        |
| C.4      | Derivación término a término de la serie de Fourier . . . . .   | 156        |
| C.5      | Recíproco de suavidad por decaimiento de coeficientes . . . . . | 158        |
| C.6      | Comentarios finales . . . . .                                   | 159        |

# Introducción

*El estudio profundo de la naturaleza es la fuente más fértil de descubrimientos matemáticos.*

— Joseph Fourier, *Prólogo de la Teoría analítica del calor*

El cálculo numérico se ocupa de resolver problemas matemáticos mediante algoritmos, es decir, de la “construcción efectiva” de soluciones a problemas matemáticos, y se preocupa por la precisión y la eficiencia de los métodos desarrollados. El cálculo numérico parte de la realización concreta de la visión de la matemática constructiva: la filosofía según la cual un objeto matemático existe cuando disponemos de un algoritmo para construirlo. En el Capítulo 1 veremos que esta idea está lejos de ser trivial, mostrando que el conjunto de números “efectivamente computables” es apenas *numerable* — con lo cual, para la inmensa mayoría de los números reales no puede existir un algoritmo capaz de aproximarlos. También en ese capítulo introduciremos la noción de complejidad computacional, que cuantifica los recursos necesarios para resolver un problema.

Uno de los hilos centrales del apunte es el problema de representar y aproximar funciones, y un tópico recurrente para abordar este problema es el de la ortogonalidad.

En el Capítulo 2 introducimos la noción de espacios de producto interno, que generalizan la geometría euclidiana a espacios abstractos. En estos espacios, la ortogonalidad y las proyecciones permiten construir algoritmos estables y eficientes para resolver problemas de álgebra lineal, como sistemas lineales, autovalores, y problemas de cuadrados mínimos.

En el Capítulo 3 estudiamos la interpolación polinomial: dado un conjunto de puntos, se desea construir un polinomio que pase por ellos. Por un lado, la aproximación por polinomios conduce naturalmente a la integración y a la diferenciación numérica, pero también veremos cómo las ideas de la interpolación se extienden al plano complejo para motivar el desarrollo de la transformada discreta de Fourier, o a cuerpos finitos donde se aplica a problemas de criptografía y teoría de códigos.

En el Capítulo 4 retomamos la noción de ortogonalidad, esta vez en espacios de funciones. Estudiamos las series de Fourier y las expansiones en polinomios de Chebyshev como casos centrales: para funciones suaves su convergencia es espectral —exponencialmente rápida—, lo que las hace especialmente útiles en la práctica. Nuestro interés central será entender este régimen de convergencia rápida y el error de proyección, mientras que dejamos para cursos teóricos avanzados las cuestiones de convergencia puntual en espacios más generales.

El Capítulo 5 aborda ecuaciones diferenciales, donde centralmente utilizaremos el análisis de Fourier discreto para estudiar estabilidad (análisis de von Neumann).

El Capítulo 6 introduce métodos iterativos para optimización y ecuaciones no lineales como el método de bisección, Newton, o el descenso por gradiente, este último conocido por su aplicación al entrenamiento de redes neuronales.

Uno de los temas recurrentes a lo largo de todo el apunte es la estabilidad: la sensibilidad de los algoritmos a errores de redondeo, perturbaciones en los datos, o incluso a la propia formulación del problema. La estabilidad es un concepto fundamental para entender por qué algunos métodos numéricos funcionan bien en la práctica, mientras que otros, aunque matemáticamente correctos, resultan inviables en la práctica.

Como ilustración del *principio de mínima generalidad*<sup>1</sup>, según el cual es preferible introducir una idea en el caso más simple que la revele con claridad, y solo después se extiende a situaciones más generales, consideremos el problema aparentemente inocente de calcular

$$I_n = \int_0^1 x^n e^x dx, \quad n = 0, 1, 2, \dots$$

Integrando por partes, se obtiene la recurrencia

$$I_n = e - n I_{n-1} \quad \text{con} \quad I_0 = e - 1.$$

Esta fórmula sugiere un algoritmo directo, pero cualquier error en la condición inicial se amplifica por un factor  $\sim n!$  tras  $n$  pasos: para  $n = 20$  la amplificación del error inicial es de  $\sim 10^{18}$ , destruyendo toda precisión.

La estabilidad —en sus diversas manifestaciones: estabilidad de algoritmos, de esquemas numéricos para ecuaciones diferenciales, de los problemas mismos— será un tema recurrente a lo largo de todo el apunte.

## Prerequisitos

Se asume familiaridad con álgebra lineal (espacios vectoriales, transformaciones lineales, producto interno, ortogonalidad, Gram-Schmidt) y con cálculo (series, convergencia, derivadas e integrales, ecuaciones diferenciales ordinarias). Si bien no se requiere experiencia previa en programación, sí se asume la madurez conceptual para seguir algoritmos y razonar sobre su correctitud.

---

<sup>1</sup>V.I. Arnold, prólogo de *Lectures on Partial Differential Equations*: “Instead of the principle of maximal generality that is usual in mathematical books, the author has attempted to adhere to the principle of minimal generality, according to which every idea should first be clearly understood in the simplest situation; only then should the method developed be extended to more complicated cases.”

# Chapter 1

## Fundamentos de la Computación Numérica

Este capítulo introductorio establece los fundamentos teóricos y prácticos de la computación numérica. Exploramos tres pilares fundamentales: la teoría de la computabilidad, que define qué problemas son resolubles algorítmicamente; la complejidad computacional, que cuantifica los recursos necesarios para resolver un problema; y la aritmética de máquina, que determina cómo se representan y manipulan los números en computadoras reales.

### 1.1 Máquinas de Turing y Computabilidad

#### 1.1.1 Máquinas de Turing

Una **máquina de Turing** es un modelo matemático abstracto de computación propuesto por Alan Turing en 1936. Consiste en:

- Una **cinta infinita** dividida en celdas, cada una conteniendo un símbolo de un alfabeto finito  $\Gamma$  (que incluye un símbolo especial *blanco*).
- Un **cabezal de lectura/escritura** que puede leer y escribir símbolos en la cinta, y moverse una posición a la izquierda o derecha.
- Un **conjunto finito de estados**  $Q$ , con un estado inicial  $q_0$  y estados de aceptación  $F \subseteq Q$ .
- Una **función de transición**  $\delta : Q \times \Gamma \rightarrow Q \times \Gamma \times \{L, R\}$  que, dado el estado actual y el símbolo leído, determina el nuevo estado, el símbolo a escribir, y la dirección del movimiento.

**Ejemplo 1.1** (Máquina que suma 1). *Consideremos una máquina de Turing que suma 1 a un número natural representado en unario. El número  $n$  se representa como una cadena de  $n$  unos:  $1^n$ .*

**Especificación:**

- *Alfabeto:  $\Gamma = \{1, B\}$  donde  $B$  representa el blanco.*



- *Estados:*  $Q = \{q_0, q_1, q_{halt}\}$
- *Estado inicial:*  $q_0$
- *Estado de aceptación:*  $\{q_{halt}\}$

**Función de transición:**

$$\begin{aligned}\delta(q_0, 1) &= (q_0, 1, R) && \text{(avanza a la derecha mientras haya unos)} \\ \delta(q_0, B) &= (q_1, 1, L) && \text{(encontró el final, escribe un 1 adicional)} \\ \delta(q_1, 1) &= (q_{halt}, 1, R) && \text{(retrocede y se detiene)}\end{aligned}$$

**Ejemplo de ejecución** para la entrada 111 (representa el número 3):

|          |          |          |          |   |     |                                         |
|----------|----------|----------|----------|---|-----|-----------------------------------------|
| <u>1</u> | 1        | 1        | B        | B | ... | Estado: $q_0$                           |
| 1        | <u>1</u> | 1        | B        | B | ... | Estado: $q_0$                           |
| 1        | 1        | <u>1</u> | B        | B | ... | Estado: $q_0$                           |
| 1        | 1        | 1        | <u>B</u> | B | ... | Estado: $q_0$                           |
| 1        | 1        | 1        | <u>1</u> | B | ... | Estado: $q_1$ (escribió el 1 adicional) |
| 1        | 1        | <u>1</u> | 1        | B | ... | Estado: $q_{halt}$ (se detiene)         |

**Definición 1.2** (Clase espacial  $SPACE(f(n))$ ). La clase  $SPACE(f(n))$  contiene todos los lenguajes que pueden ser resueltos por una máquina de Turing determinista usando  $O(f(n))$  celdas de memoria.

**Definición 1.3** (Clase P).  $P = \bigcup_{k=0}^{\infty} TIME(n^k)$  es la clase de problemas resolubles en tiempo polinomial. Representa los problemas tratables computacionalmente.

**Definición 1.4** (Clase NP). **NP** es la clase de problemas para los cuales, dada una solución propuesta, se puede verificar en tiempo polinomial si es correcta. Equivalentemente, son los problemas resolubles en tiempo polinomial por una máquina de Turing no determinista.

**Ejemplo 1.5** (Problemas en P). • *Determinar si un número es primo (algoritmo AKS, 2002).*

- *Ordenar  $n$  números:  $O(n \log n)$  (mergesort, heapsort).*
- *Calcular el máximo común divisor:  $O(\log n)$  (algoritmo de Euclides).*
- *Multiplicar dos matrices  $n \times n$ :  $O(n^{2.371})$  (algoritmo de Coppersmith-Winograd).*

**Ejemplo 1.6** (Problemas en NP). • **SAT:** Dado un conjunto de cláusulas booleanas, ¿existe una asignación de valores que las satisface?

- **Camino Hamiltoniano:** Dado un grafo, ¿existe un camino que visita cada vértice exactamente una vez?
- **Factorización de enteros:** Dado  $n$ , ¿tiene un factor primo menor que  $k$ ? (Verificar es fácil, encontrar es difícil).
- **Problema del viajante (TSP):** ¿Existe una ruta que visita todas las ciudades con distancia total  $< k$ ?

**Observación 1.7** (El problema P vs NP). *Claramente  $P \subseteq NP$  (si podemos resolver, podemos verificar). La pregunta del millón de dólares: ¿es  $P = NP$ ? Se cree ampliamente que no, pero nadie ha podido demostrarlo. Es uno de los siete Problemas del Milenio del Clay Mathematics Institute.*

### 1.1.2 Cálculo de la complejidad de un algoritmo

Para determinar la complejidad de un algoritmo:

1. **Identificar operaciones elementales:** asignaciones, comparaciones, operaciones aritméticas. Cada una cuesta  $O(1)$ .
2. **Contar repeticiones:** analizar bucles y recursiones.
3. **Sumar las contribuciones:** obtener una función  $T(n)$  del tamaño de entrada.
4. **Expresar en notación asintótica:** simplificar a  $O(f(n))$ .

**Ejemplo 1.8** (Búsqueda lineal). *Buscar un elemento en un array desordenado de tamaño  $n$ :*

```
for i = 1 to n:
    if array[i] == target:
        return i
return -1
```

- Operaciones en cada iteración:  $O(1)$  (comparación).
- Número de iteraciones: hasta  $n$  en el peor caso.
- Complejidad total:  $T(n) = O(n)$ .

**Ejemplo 1.9** (Búsqueda binaria). *Buscar en un array ordenado de tamaño  $n$ :*

```
left = 1, right = n
while left <= right:
    mid = (left + right) / 2
    if array[mid] == target:
        return mid
    else if array[mid] < target:
        left = mid + 1
    else:
        right = mid - 1
return -1
```

- En cada iteración, el espacio de búsqueda se reduce a la mitad.
- Número de iteraciones:  $k$  tal que  $n/2^k = 1$ , es decir,  $k = \log_2 n$ .
- Complejidad:  $T(n) = O(\log n)$ .

**Ejemplo 1.10** (Ordenamiento por inserción). `for i = 2 to n:`

```
    key = array[i]
    j = i - 1
    while j >= 1 and array[j] > key:
        array[j+1] = array[j]
        j = j - 1
    array[j+1] = key
```

- *Bucle externo:  $n - 1$  iteraciones.*
- *Bucle interno: en la iteración  $i$ , hasta  $i - 1$  comparaciones.*
- *Total:  $T(n) = \sum_{i=2}^n (i - 1) = \frac{n(n-1)}{2} = O(n^2)$ .*

**Ejemplo 1.11** (Multiplicación de matrices). *Multiplicar dos matrices  $A, B$  de tamaño  $n \times n$  con el algoritmo estándar:*

```
for i = 1 to n:
    for j = 1 to n:
        C[i,j] = 0
        for k = 1 to n:
            C[i,j] = C[i,j] + A[i,k] * B[k,j]
```

- *Tres bucles anidados, cada uno de tamaño  $n$ .*
- *Complejidad:  $T(n) = O(n^3)$ .*
- *(Existen algoritmos más eficientes: Strassen  $O(n^{2.807})$ , Coppersmith-Winograd  $O(n^{2.371})$ ).*

### 1.1.3 Análisis de algoritmos recursivos

Los algoritmos recursivos requieren un enfoque diferente para analizar su complejidad. En lugar de contar iteraciones directamente, establecemos una **relación de recurrencia** que relaciona el costo de resolver un problema de tamaño  $n$  con el costo de resolver subproblemas más pequeños.

**Definición 1.12** (Relación de recurrencia). *Una **relación de recurrencia** para el tiempo de ejecución  $T(n)$  de un algoritmo recursivo tiene la forma general:*

$$T(n) = \begin{cases} c & \text{si } n \leq n_0 \text{ (caso base)} \\ aT(n/b) + f(n) & \text{si } n > n_0 \text{ (caso recursivo)} \end{cases}$$

donde:

- *$a$  es el número de llamadas recursivas.*
- *$n/b$  es el tamaño de cada subproblema.*
- *$f(n)$  es el costo del trabajo fuera de las llamadas recursivas (dividir y combinar).*

**Ejemplo 1.13** (Búsqueda binaria recursiva). *El algoritmo de búsqueda binaria puede implementarse recursivamente:*

```
binary_search(array, target, left, right):
    if left > right:
        return -1
    mid = (left + right) / 2
    if array[mid] == target:
        return mid
    else if array[mid] < target:
        return binary_search(array, target, mid+1, right)
    else:
        return binary_search(array, target, left, mid-1)
```

**Análisis de complejidad:**

- *Caso base* ( $n = 1$ ):  $T(1) = O(1)$ .
- *Caso recursivo*: una sola llamada recursiva con la mitad del tamaño, más trabajo constante para calcular *mid* y hacer comparaciones.
- *Relación de recurrencia*:  $T(n) = T(n/2) + O(1)$ .

**Resolución:** En cada nivel de recursión, el problema se reduce a la mitad. Si empezamos con tamaño  $n$  y llegamos al caso base de tamaño 1, tenemos:

$$n \rightarrow n/2 \rightarrow n/4 \rightarrow \dots \rightarrow n/2^k = 1$$

Esto ocurre cuando  $k = \log_2 n$ . En cada nivel hacemos trabajo  $O(1)$ , por lo que:

$$T(n) = O(\log n).$$

**Ejemplo 1.14** (Mergesort). *Mergesort es un algoritmo de ordenamiento divide-y-vencerás:*

```
mergesort(array, left, right):
    if left >= right:
        return
    mid = (left + right) / 2
    mergesort(array, left, mid)      // Ordenar mitad izquierda
    mergesort(array, mid+1, right)  // Ordenar mitad derecha
    merge(array, left, mid, right)  // Combinar (O(n))
```

**Análisis de complejidad:**

- *Caso base* ( $n = 1$ ):  $T(1) = O(1)$ .
- *Caso recursivo*: dos llamadas recursivas con la mitad del tamaño cada una, más el trabajo de combinar las dos mitades ordenadas (que cuesta  $O(n)$ ).
- *Relación de recurrencia*:  $T(n) = 2T(n/2) + O(n)$ .

### *Resolución mediante árbol de recursión:*

- **Nivel 0:** Un problema de tamaño  $n$ , costo  $cn$  para combinar.
- **Nivel 1:** Dos problemas de tamaño  $n/2$ , costo total  $2 \cdot c(n/2) = cn$  para combinar.
- **Nivel 2:** Cuatro problemas de tamaño  $n/4$ , costo total  $4 \cdot c(n/4) = cn$  para combinar.
- $\vdots$
- **Nivel  $k$ :**  $2^k$  problemas de tamaño  $n/2^k$ , costo total  $2^k \cdot c(n/2^k) = cn$  para combinar.

El árbol tiene profundidad  $\log_2 n$  (hasta que  $n/2^k = 1$ ), y en cada nivel el costo total es  $cn$ . Por lo tanto:

$$T(n) = cn \cdot \log_2 n = O(n \log n).$$

**Ejemplo 1.15** (Fibonacci ingenuo). El algoritmo recursivo ingenuo para calcular el  $n$ -ésimo número de Fibonacci:

```
fib(n):  
    if n <= 1:  
        return n  
    return fib(n-1) + fib(n-2)
```

### *Análisis de complejidad:*

- **Relación de recurrencia:**  $T(n) = T(n-1) + T(n-2) + O(1)$ .
- Esta recurrencia es similar a la secuencia de Fibonacci misma.

Se puede demostrar que  $T(n) = \Theta(\phi^n)$  donde  $\phi = \frac{1+\sqrt{5}}{2} \approx 1.618$  es la razón áurea. Esto es **complejidad exponencial**, extremadamente ineficiente.

**Observación:** Este problema ilustra cómo un algoritmo recursivo natural puede ser muy ineficiente. Una implementación iterativa o con memoización reduce la complejidad a  $O(n)$ .

### **1.1.4 El Teorema Maestro**

Para recurrencias de la forma  $T(n) = aT(n/b) + f(n)$  donde  $a \geq 1, b > 1$ , el Teorema Maestro proporciona una solución directa sin necesidad de expandir la recursión.

**Teorema 1.16** (Teorema Maestro). Sea  $T(n)$  definida por la recurrencia:

$$T(n) = aT(n/b) + f(n)$$

donde  $a \geq 1, b > 1$  son constantes, y  $f(n)$  es una función asintóticamente positiva. Sea  $c_{crit} = \log_b a$ . Entonces:

1. **Caso 1** (Trabajo dominado por las hojas): Si  $f(n) = O(n^c)$  para algún  $c < c_{crit}$ , entonces:

$$T(n) = \Theta(n^{c_{crit}}) = \Theta(n^{\log_b a}).$$

2. **Caso 2** (Trabajo balanceado en todos los niveles): Si  $f(n) = \Theta(n^{c_{\text{crit}}} \log^k n)$  para algún  $k \geq 0$ , entonces:

$$T(n) = \Theta(n^{c_{\text{crit}}} \log^{k+1} n).$$

En particular, si  $f(n) = \Theta(n^{c_{\text{crit}}})$ , entonces  $T(n) = \Theta(n^{c_{\text{crit}}} \log n)$ .

3. **Caso 3** (Trabajo dominado por la raíz): Si  $f(n) = \Omega(n^c)$  para algún  $c > c_{\text{crit}}$ , y además se satisface la **condición de regularidad**:

$$af(n/b) \leq kf(n) \quad \text{para algún } k < 1 \text{ y } n \text{ suficientemente grande,}$$

entonces:

$$T(n) = \Theta(f(n)).$$

*Demostración (idea intuitiva).* Consideremos el árbol de recursión para  $T(n) = aT(n/b) + f(n)$ :

**Estructura del árbol:**

- **Nivel 0** (raíz): 1 nodo de tamaño  $n$ , costo  $f(n)$ .
- **Nivel 1**:  $a$  nodos de tamaño  $n/b$ , costo total  $a \cdot f(n/b)$ .
- **Nivel 2**:  $a^2$  nodos de tamaño  $n/b^2$ , costo total  $a^2 \cdot f(n/b^2)$ .
- $\vdots$
- **Nivel  $i$** :  $a^i$  nodos de tamaño  $n/b^i$ , costo total  $a^i \cdot f(n/b^i)$ .

**Profundidad del árbol:** El árbol tiene profundidad  $\log_b n$  (cuando  $n/b^k = 1$ , es decir,  $k = \log_b n$ ).

**Número de hojas:** En el nivel más profundo hay  $a^{\log_b n}$  hojas. Usando propiedades de logaritmos:

$$a^{\log_b n} = n^{\log_b a} = n^{c_{\text{crit}}}.$$

**Costo total:** El costo total es la suma de los costos en todos los niveles:

$$T(n) = \sum_{i=0}^{\log_b n - 1} a^i f(n/b^i) + \Theta(n^{c_{\text{crit}}}).$$

El comportamiento de esta suma depende de cómo crece  $f(n)$  comparado con  $n^{c_{\text{crit}}}$ :

**Caso 1:** Si  $f(n) = O(n^c)$  con  $c < c_{\text{crit}}$ , entonces  $a^i f(n/b^i)$  decrece geométricamente con  $i$ . La suma es dominada por las hojas del árbol (nivel más profundo), que contribuyen  $\Theta(n^{c_{\text{crit}}})$ .

**Caso 2:** Si  $f(n) = \Theta(n^{c_{\text{crit}}})$ , entonces  $a^i f(n/b^i) \approx n^{c_{\text{crit}}}$  en cada nivel. Con  $\log_b n$  niveles, el costo total es:

$$T(n) = \Theta(n^{c_{\text{crit}}} \log n).$$

**Caso 3:** Si  $f(n) = \Omega(n^c)$  con  $c > c_{\text{crit}}$ , entonces  $a^i f(n/b^i)$  crece geométricamente al acercarnos a la raíz. La suma es dominada por el trabajo en la raíz, que contribuye  $\Theta(f(n))$  (bajo la condición de regularidad, que garantiza que la serie converge).  $\square$

**Observación 1.17** (Interpretación intuitiva). *El exponente crítico  $c_{crit} = \log_b a$  representa el costo de las hojas del árbol (los casos base). El teorema compara este costo con el trabajo  $f(n)$  hecho en cada nivel:*

- Si las hojas dominan ( $f(n)$  crece más lento que  $n^{c_{crit}}$ ), entonces  $T(n) = \Theta(n^{c_{crit}})$ .
- Si todos los niveles contribuyen igual, el costo se multiplica por la profundidad  $\log n$ .
- Si la raíz domina ( $f(n)$  crece más rápido), entonces  $T(n) = \Theta(f(n))$ .

**Ejemplo 1.18** (Aplicaciones del Teorema Maestro). **1. Búsqueda binaria:**  $T(n) = T(n/2) + O(1)$ .

- $a = 1, b = 2, f(n) = O(1) = O(n^0)$ .
- $c_{crit} = \log_2 1 = 0$ .
- $f(n) = O(n^0) = \Theta(n^{c_{crit}})$ , así que estamos en el Caso 2 con  $k = 0$ .
- Conclusión:  $T(n) = \Theta(n^0 \log n) = \Theta(\log n)$ .

**2. Mergesort:**  $T(n) = 2T(n/2) + O(n)$ .

- $a = 2, b = 2, f(n) = O(n)$ .
- $c_{crit} = \log_2 2 = 1$ .
- $f(n) = \Theta(n) = \Theta(n^{c_{crit}})$ , así que estamos en el Caso 2 con  $k = 0$ .
- Conclusión:  $T(n) = \Theta(n \log n)$ .

**3. Multiplicación de matrices por divide-y-vencerás (ingenuo):**  $T(n) = 8T(n/2) + O(n^2)$ .

- $a = 8, b = 2, f(n) = O(n^2)$ .
- $c_{crit} = \log_2 8 = 3$ .
- $f(n) = O(n^2)$  con  $2 < 3$ , así que estamos en el Caso 1.
- Conclusión:  $T(n) = \Theta(n^3)$  (¡no mejor que el algoritmo estándar!).

**4. Algoritmo de Strassen:**  $T(n) = 7T(n/2) + O(n^2)$ .

- $a = 7, b = 2, f(n) = O(n^2)$ .
- $c_{crit} = \log_2 7 \approx 2.807$ .
- $f(n) = O(n^2)$  con  $2 < 2.807$ , así que estamos en el Caso 1.
- Conclusión:  $T(n) = \Theta(n^{\log_2 7}) \approx \Theta(n^{2.807})$  (¡mejor que  $O(n^3)$ !).

**5. Recurrencia con trabajo dominante:**  $T(n) = 2T(n/2) + O(n^2)$ .

- $a = 2, b = 2, f(n) = O(n^2)$ .
- $c_{crit} = \log_2 2 = 1$ .
- $f(n) = \Omega(n^2)$  con  $2 > 1$ , y se verifica la condición de regularidad:  $2f(n/2) = 2 \cdot (n/2)^2 = n^2/2 \leq kn^2$  para  $k = 1/2 < 1$ .
- *Estamos en el Caso 3.*
- *Conclusión:*  $T(n) = \Theta(n^2)$ .

**Observación 1.19** (Limitaciones del Teorema Maestro). *El Teorema Maestro no cubre todos los casos posibles:*

- *No aplica a recurrencias con subproblemas de tamaños desiguales, como  $T(n) = T(n/3) + T(2n/3) + O(n)$  (Quickselect).*
- *No aplica cuando  $f(n)$  oscila y no es monótona.*
- *Para recurrencias que no caen en ninguno de los tres casos (por ejemplo,  $T(n) = 2T(n/2) + n \log n$ ), se requieren métodos más avanzados como el **teorema maestro generalizado** o análisis directo mediante árboles de recursión.*

## 1.2 Aritmética de Máquina

En computación práctica, trabajamos con representaciones finitas de números, lo que introduce errores y limitaciones.

### 1.2.1 Enteros de 64 bits

Los enteros con signo de 64 bits se representan típicamente en **complemento a dos**:

- Rango:  $[-2^{63}, 2^{63} - 1] = [-9,223,372,036,854,775,808, 9,223,372,036,854,775,807]$ .
- El bit más significativo indica el signo: 0 para positivo, 1 para negativo.
- Operaciones aritméticas (+, −, ×) son exactas si el resultado cabe en el rango.
- **Overflow:** Si el resultado excede el rango, ocurre un desbordamiento (típicamente sin error, dando un resultado módulo  $2^{64}$ ).

**Ejemplo 1.20** (Overflow de enteros). *En aritmética de 8 bits con signo (rango  $[-128, 127]$ ):*

$$100 + 50 = 150 \quad \text{pero} \quad 150 > 127 \implies \text{overflow} \implies -106 \text{ (módulo } 2^8\text{)}.$$



### 1.2.2 Números de punto flotante

Los números reales se representan en una computadora de forma aproximada, utilizando un número finito de bits. Ya hemos visto la representación de enteros; pasamos ahora a la representación de números reales.

**Definición 1.21** (Sistema de punto flotante). *Un sistema de punto flotante  $\mathbb{F}(\beta, t, e_{\min}, e_{\max})$  queda determinado por:*

- una **base**  $\beta \geq 2$ ,
- una **precisión**  $t \geq 1$  (cantidad de dígitos significativos),
- un rango de exponentes  $e_{\min} \leq e \leq e_{\max}$ .

Un **número de máquina normalizado** es un número de la forma

$$x = \pm \underbrace{d_0.d_1d_2\cdots d_{t-1}}_{\text{mantisa}} \times \beta^e,$$

donde  $0 \leq d_i \leq \beta - 1$  para todo  $i$ ,  $d_0 \neq 0$  (condición de normalización), y  $e_{\min} \leq e \leq e_{\max}$ . Además se incluye el 0.

La condición  $d_0 \neq 0$  garantiza la unicidad de la representación. Los dígitos  $d_0.d_1\cdots d_{t-1}$  se llaman la **mantisa** (o *significando*) y son  $t$  dígitos en total. Nótese que como  $d_0 \neq 0$  y  $d_0 \leq \beta - 1$ , la mantisa satisface

$$1 \leq d_0.d_1\cdots d_{t-1} < \beta.$$

#### Formato IEEE 754 de doble precisión

El estándar IEEE 754 utiliza base  $\beta = 2$ . En **doble precisión** (64 bits), los parámetros son:

$$\beta = 2, \quad t = 53, \quad e_{\min} = -1022, \quad e_{\max} = 1023.$$

Los 64 bits se distribuyen así:

- $s$ : 1 bit de **signo**.
- $e$ : 11 bits para el **exponente** (almacenado con sesgo 1023).
- $f$ : 52 bits para la parte fraccionaria de la **mantisa**.

Como la base es 2, la condición de normalización fuerza  $d_0 = 1$ , que no necesita almacenarse (“bit implícito”). Así los 52 bits almacenados, junto con el bit implícito, dan  $t = 53$  bits de precisión. Un número normalizado se escribe

$$x = (-1)^s \times 1.\underbrace{f_1f_2\cdots f_{52}}_{52 \text{ bits}} \times 2^{e-1023}.$$

Además del rango normalizado, el estándar define:

- **Números subnormales** ( $e = 0$ ): permiten representar valores muy pequeños cerca de cero, sacrificando precisión gradualmente (*gradual underflow*).
- **$\pm$ Infinito** ( $e = 2047, f = 0$ ): resultado de desbordamientos (*overflow*).
- **NaN** (*Not a Number*,  $e = 2047, f \neq 0$ ): resultado de operaciones indefinidas como  $0/0$  o  $\sqrt{-1}$ .

**Ejemplo 1.22** (Rango de doble precisión). • *Menor positivo normalizado*:  $2^{-1022} \approx 2.225 \times 10^{-308}$ .

- *Mayor número representable*:  $(2 - 2^{-52}) \times 2^{1023} \approx 1.798 \times 10^{308}$ .

## Formatos de punto flotante en GPUs y machine learning

La doble precisión (FP64) es el estándar en cálculo científico, pero en aplicaciones de aprendizaje automático y procesamiento en GPUs se utilizan formatos de menor precisión que permiten mayor rendimiento y menor consumo de memoria. La siguiente tabla resume los formatos más comunes.

| Formato         | Bits | Signo | Exponente | Mantisa <sup>(*)</sup> | $\epsilon_{\text{mach}}$              |
|-----------------|------|-------|-----------|------------------------|---------------------------------------|
| FP64 (double)   | 64   | 1     | 11        | 52 (53)                | $2^{-52} \approx 2.2 \times 10^{-16}$ |
| FP32 (float)    | 32   | 1     | 8         | 23 (24)                | $2^{-23} \approx 1.2 \times 10^{-7}$  |
| TF32            | 19   | 1     | 8         | 10 (11)                | $2^{-10} \approx 9.8 \times 10^{-4}$  |
| FP16 (half)     | 16   | 1     | 5         | 10 (11)                | $2^{-10} \approx 9.8 \times 10^{-4}$  |
| BF16 (bfloat16) | 16   | 1     | 8         | 7 (8)                  | $2^{-7} \approx 7.8 \times 10^{-3}$   |
| FP8 (E5M2)      | 8    | 1     | 5         | 2 (3)                  | $2^{-2} = 0.25$                       |
| FP8 (E4M3)      | 8    | 1     | 4         | 3 (4)                  | $2^{-3} = 0.125$                      |

Table 1.1: Formatos de punto flotante utilizados en GPUs y machine learning. La columna “Mantisa” indica los bits almacenados y, entre paréntesis, la precisión total  $t$  incluyendo el bit implícito. TF32 es un formato de NVIDIA (Ampere y posterior); BF16 fue introducido por Google Brain; los formatos FP8 fueron estandarizados para las arquitecturas NVIDIA Hopper y AMD MI300.

Nótese que BF16 tiene el mismo rango de exponentes que FP32 (8 bits), lo que evita problemas de overflow/underflow al entrenar redes neuronales, a costa de menor precisión. En contraste, FP16 tiene mayor precisión que BF16 pero un rango de exponentes mucho más reducido. TF32 combina el exponente de FP32 con una mantisa intermedia y se usa internamente en las unidades tensoriales de NVIDIA. Los formatos FP8 de 8 bits, con precisiones de apenas 3 o 4 bits, se utilizan para inferencia y entrenamiento con cuantización agresiva.

### 1.2.3 Épsilon de máquina

¿Cuál es la “resolución” de un sistema de punto flotante? Para responder esta pregunta, consideremos la distancia entre el número 1 y el siguiente número de máquina.

En el sistema  $\mathbb{F}(\beta, t, e_{\min}, e_{\max})$ , el número 1 se representa como  $1.\underbrace{00\cdots 0}_{t-1} \times \beta^0$ . El siguiente número representable es

$$1.\underbrace{00\cdots 0}_{t-2} 1 \times \beta^0 = 1 + \beta^{-(t-1)}.$$

La distancia entre estos dos números motiva la siguiente definición central.

**Definición 1.23** (Épsilon de máquina). *El **épsilon de máquina** del sistema  $\mathbb{F}(\beta, t, e_{\min}, e_{\max})$  es*

$$\epsilon_{\text{mach}} = \beta^{1-t}.$$

**Observación 1.24.** *En la literatura existen dos convenciones: algunos autores definen  $\epsilon_{\text{mach}} = \beta^{1-t}$  (la distancia de 1 al siguiente representable) y otros definen  $\epsilon_{\text{mach}} = \frac{1}{2}\beta^{1-t}$  (el máximo error relativo de redondeo, llamado unit roundoff). Seguimos la primera convención, que es la utilizada por IEEE, MATLAB (`eps`), NumPy (`np.finfo(float).eps`), y Julia (`eps()`). En esta convención, la cota de error relativo de redondeo es  $\epsilon_{\text{mach}}/2$ .*

Veamos por qué  $\epsilon_{\text{mach}} = \beta^{1-t}$  coincide con la distancia entre 1 y el siguiente número de máquina. Ya observamos que dicha distancia vale  $\beta^{-(t-1)} = \beta^{1-t}$ . Esto es consistente:  $\epsilon_{\text{mach}} = \beta^{1-t}$ .

**Ejemplo 1.25** (Doble precisión). *Para IEEE 754 doble precisión,  $\beta = 2$ ,  $t = 53$ :*

$$\epsilon_{\text{mach}} = 2^{1-53} = 2^{-52} \approx 2.220 \times 10^{-16}.$$

*Esto significa que un número de punto flotante de doble precisión tiene aproximadamente 15–16 dígitos decimales significativos.*

## 1.2.4 Redondeo y la cota fundamental de error

**Definición 1.26** (Función de redondeo). *La **función de redondeo al más cercano**  $\text{fl}: \mathbb{R} \rightarrow \mathbb{F}$  asigna a cada número real  $x$  (en el rango representable) el número de máquina más cercano a  $x$ . En caso de empate, el estándar IEEE 754 utiliza la regla round to even (se elige el número cuyo último dígito es par).*

La propiedad más importante del redondeo es la siguiente cota de error relativo. Para demostrarla, necesitamos primero entender el espaciado entre números de máquina consecutivos.

**Lema 1.27** (Espaciado entre números de máquina consecutivos). *En el sistema  $\mathbb{F}(\beta, t, e_{\min}, e_{\max})$ , dos números de máquina normalizados consecutivos con exponente  $e$  distan exactamente*

$$\Delta_e = \beta^{e-(t-1)}.$$

*Demostración.* Un número de máquina normalizado con exponente  $e$  tiene la forma

$$x = d_0.d_1d_2\cdots d_{t-1} \times \beta^e,$$

donde  $d_0 \neq 0$  y  $0 \leq d_i \leq \beta - 1$ . Esto equivale a escribir

$$x = \left( \sum_{k=0}^{t-1} d_k \beta^{-k} \right) \beta^e = \left( \sum_{k=0}^{t-1} d_k \beta^{t-1-k} \right) \beta^{e-(t-1)}.$$

La cantidad entre paréntesis,  $m = \sum_{k=0}^{t-1} d_k \beta^{t-1-k}$ , es un entero (pues cada término es un entero). Además, dos números de máquina consecutivos con el mismo exponente  $e$  difieren en que sus enteros  $m$  correspondientes difieren en 1. Por lo tanto, la distancia entre ellos es

$$\Delta_e = 1 \times \beta^{e-(t-1)} = \beta^{e-(t-1)}.$$

□

Nótese que este espaciado **depende del exponente  $e$** : los números de máquina se hacen más densos cerca de cero y más espaciados lejos del origen. Sin embargo, el espaciado *relativo* es aproximadamente uniforme: como los números normalizados con exponente  $e$  satisfacen  $|x| \geq \beta^e$ , se tiene  $\Delta_e/|x| \leq \beta^{e-(t-1)}/\beta^e = \beta^{1-t} = \epsilon_{\text{mach}}$ .

**Teorema 1.28** (Cota fundamental del error de redondeo). *Para todo número real  $x$  en el rango normalizado del sistema  $\mathbb{F}(\beta, t, e_{\min}, e_{\max})$ , se cumple*

$$\boxed{\frac{|\text{fl}(x) - x|}{|x|} \leq \frac{1}{2} \epsilon_{\text{mach}} = \frac{1}{2} \beta^{1-t}}.$$

Equivalentemente, existe  $\delta$  con  $|\delta| \leq \frac{1}{2} \epsilon_{\text{mach}}$  tal que  $\text{fl}(x) = x(1 + \delta)$ .

La cantidad  $u = \frac{1}{2} \epsilon_{\text{mach}} = \frac{1}{2} \beta^{1-t}$  se denomina el **unit roundoff** y representa la máxima precisión relativa que puede esperarse de una operación de punto flotante.

*Demostración.* Sea  $x \neq 0$  un número real en el rango normalizado, con exponente  $e$  (es decir,  $\beta^e \leq |x| < \beta^{e+1}$ ). Por el Lema 1.27,  $x$  se encuentra entre dos números de máquina consecutivos  $x^-$  y  $x^+ = x^- + \beta^{e-(t-1)}$ . El redondeo al más cercano satisface

$$|\text{fl}(x) - x| \leq \frac{1}{2} (x^+ - x^-) = \frac{1}{2} \beta^{e-(t-1)}.$$

Como  $|x| \geq \beta^e$ , dividiendo:

$$\frac{|\text{fl}(x) - x|}{|x|} \leq \frac{\frac{1}{2} \beta^{e-(t-1)}}{\beta^e} = \frac{1}{2} \beta^{1-t} = \frac{1}{2} \epsilon_{\text{mach}}.$$

Para la formulación equivalente, basta definir  $\delta = (\text{fl}(x) - x)/x$ ; la cota recién demostrada da  $|\delta| \leq \frac{1}{2} \epsilon_{\text{mach}}$ , y entonces  $\text{fl}(x) = x + x\delta = x(1 + \delta)$ . □

**Observación 1.29.** *La cota es ajustada: se alcanza (hasta factores de redondeo) cuando  $x$  está justo en el punto medio entre dos consecutivos y  $|x|$  es apenas mayor que  $\beta^e$ . Por ejemplo, en doble precisión el número  $x = 1 + 2^{-53}$  (punto medio entre 1 y  $1 + 2^{-52}$ ) se redondea con error relativo exactamente  $2^{-53} = \epsilon_{\text{mach}}/2$ .*

**Ejemplo 1.30** (Doble precisión). *Para IEEE 754 doble precisión:*

$$u = \frac{\epsilon_{\text{mach}}}{2} = \frac{2^{-52}}{2} = 2^{-53} \approx 1.11 \times 10^{-16}.$$

*Esto significa que toda representación en punto flotante introduce un error relativo de a lo sumo  $\sim 10^{-16}$ .*

La formulación  $\text{fl}(x) = x(1 + \delta)$  es particularmente útil para propagar errores a través de secuencias de operaciones aritméticas. El estándar IEEE 754 garantiza además que cada operación aritmética elemental se realiza con esta misma precisión, lo que enunciamos como corolario.

**Corolario 1.31** (Modelo estándar de aritmética de punto flotante). *Sea  $u = \frac{1}{2}\epsilon_{\text{mach}}$ . En aritmética IEEE 754, para todo par de números de máquina  $a, b \in \mathbb{F}$  y toda operación  $\text{op} \in \{+, -, \times, /\}$  (con  $b \neq 0$  para la división), existe  $\delta$  con  $|\delta| \leq u$  tal que*

$$\text{fl}(a \text{ op } b) = (a \text{ op } b)(1 + \delta).$$

*Es decir, el resultado en punto flotante es el resultado exacto perturbado por un error relativo de a lo sumo  $u$ .*

Este modelo es el punto de partida del **análisis de errores de redondeo**: para estudiar un algoritmo, se reemplaza cada operación aritmética por la versión perturbada y se propagan los  $\delta$ .

**Ejemplo 1.32** (Error de redondeo de la suma). *Sean  $a, b \in \mathbb{F}$ . La suma en punto flotante satisface*

$$\text{fl}(a + b) = (a + b)(1 + \delta_1), \quad |\delta_1| \leq u.$$

*El error absoluto es  $|\text{fl}(a + b) - (a + b)| = |a + b| |\delta_1| \leq u |a + b|$ , y el error relativo (cuando  $a + b \neq 0$ ) es simplemente  $|\delta_1| \leq u$ . La suma de dos números de máquina introduce, pues, un error relativo de a lo sumo  $u$  sobre el resultado exacto.*

*Sin embargo, si  $a$  y  $b$  tienen signos opuestos y son de magnitud similar,  $|a + b|$  puede ser mucho menor que  $|a|$  o  $|b|$ : aunque el error relativo de la operación es pequeño, el resultado puede tener pocos dígitos significativos respecto de los operandos originales. Esto es la cancelación catastrófica (Ejemplo 1.35).*

**Ejemplo 1.33** (Error de redondeo de la multiplicación). *Sean  $a, b \in \mathbb{F}$ . La multiplicación en punto flotante satisface*

$$\text{fl}(a \cdot b) = a \cdot b(1 + \delta_1), \quad |\delta_1| \leq u.$$

*El error relativo es directamente  $|\delta_1| \leq u$ , independientemente de los valores de  $a$  y  $b$ . La multiplicación es, en este sentido, una operación “benigna” para los errores de redondeo: no sufre cancelación.*

**Ejemplo 1.34** (Propagación de errores: el producto interno). *Consideremos el cálculo de  $s = a_1b_1 + a_2b_2$  en punto flotante. Cada paso introduce su propio  $\delta$ :*

$$\begin{aligned} p_1 &= \text{fl}(a_1b_1) = a_1b_1(1 + \delta_1), \\ p_2 &= \text{fl}(a_2b_2) = a_2b_2(1 + \delta_2), \\ \hat{s} &= \text{fl}(p_1 + p_2) = (p_1 + p_2)(1 + \delta_3), \end{aligned}$$

*con  $|\delta_i| \leq u$ . Sustituyendo:*

$$\hat{s} = (a_1b_1(1 + \delta_1) + a_2b_2(1 + \delta_2))(1 + \delta_3).$$

Expandiendo y descartando términos de orden  $u^2$  (que son despreciables, del orden de  $10^{-32}$  en doble precisión):

$$\hat{s} \approx a_1 b_1 (1 + \delta_1 + \delta_3) + a_2 b_2 (1 + \delta_2 + \delta_3).$$

El error absoluto satisface

$$|\hat{s} - s| \lesssim 2u (|a_1 b_1| + |a_2 b_2|).$$

Nótese que la cota depende de  $|a_1 b_1| + |a_2 b_2|$  y no de  $|a_1 b_1 + a_2 b_2|$ : si los términos se cancelan parcialmente, el error relativo  $|\hat{s} - s|/|s|$  puede ser grande. Este análisis se generaliza al producto interno de vectores de dimensión  $n$ , donde la cota toma la forma  $|\hat{s} - s| \lesssim nu \sum |a_i b_i|$ .

### 1.2.5 Consecuencias y ejemplos

**Ejemplo 1.35** (Pérdida de significancia — cancelación catastrófica). Restar números muy cercanos puede causar pérdida de dígitos significativos. Si  $a = 1.234567890123456$  y  $b = 1.234567890123455$ , entonces

$$a - b \approx 1 \times 10^{-15} \quad (\text{queda un solo dígito significativo}).$$

El resultado tiene una precisión relativa mucho peor que  $\epsilon_{mach}$ , no porque la resta esté mal hecha, sino porque los dígitos significativos de  $a$  y  $b$  se cancelan. Este fenómeno se llama **cancelación catastrófica**.

**Ejemplo 1.36** (La suma no es asociativa en punto flotante). En punto flotante,  $(a + b) + c \neq a + (b + c)$  en general:

$$(10^{16} + 1) - 10^{16} = 0 \quad (\text{el } 1 \text{ se pierde al sumarse a } 10^{16}),$$

$$10^{16} + (1 - 10^{16}) = 10^{16} + (-10^{16} + 1) = 1 \quad (\text{orden diferente}).$$

El resultado depende del orden de evaluación porque la precisión relativa es fija: los números representables cerca de  $10^{16}$  están espaciados en más de 1.

### 1.2.6 Precisión arbitraria por software

Para superar las limitaciones de punto flotante, existen bibliotecas de **precisión arbitraria**:

- **BigInt**: Enteros de tamaño ilimitado. Disponible nativamente en lenguajes modernos (Python, JavaScript ES2020).
- **BigFloat**: Números de punto flotante con precisión configurable. Bibliotecas: GMP (C), mpmath (Python), Arb (C).

**Ejemplo 1.37** (Cálculo de  $\pi$  con alta precisión). Usando *mpmath* en Python:

```
from mpmath import mp
mp.dps = 100 # 100 dígitos decimales
pi_100 = mp.pi
print(pi_100)
```

Resultado:

**Costo:** Las operaciones con precisión arbitraria son *mucho más lentas* que las de hardware (típicamente 10-1000 veces). Además, la complejidad crece con la precisión.

### 1.2.7 Ejemplos en geometría computacional

La aritmética finita puede causar errores graves en geometría computacional.

**Ejemplo 1.38** (Test de orientación). *Dados tres puntos  $A, B, C$  en el plano, determinar si  $C$  está a la izquierda, derecha, o sobre la línea  $AB$ . Se calcula el determinante:*

$$D = \begin{vmatrix} x_A & y_A & 1 \\ x_B & y_B & 1 \\ x_C & y_C & 1 \end{vmatrix} = (x_B - x_A)(y_C - y_A) - (y_B - y_A)(x_C - x_A).$$

- $D > 0$ :  $C$  a la izquierda.
- $D < 0$ :  $C$  a la derecha.
- $D = 0$ :  $C$  colineal.

**Problema:** Con punto flotante,  $D$  puede ser muy pequeño pero no exactamente cero, llevando a decisiones erróneas sobre colinealidad.

**Ejemplo 1.39** (Intersección de segmentos). *Determinar si dos segmentos  $AB$  y  $CD$  se intersectan requiere comparaciones geométricas precisas. Errores de redondeo pueden hacer que:*

- Segmentos que se intersectan apenas se reporten como no intersectándose.
- Algoritmos de triangulación fallen al producir geometría inválida.

**Solución:** Usar predicados exactos (*exact predicates*) mediante aritmética de precisión arbitraria o expansión de flotantes (algoritmo de Shewchuk).

**Ejemplo 1.40** (Algoritmo de Graham para el casco convexo). *Construir el casco convexo de  $n$  puntos requiere ordenar puntos por ángulo y hacer tests de orientación. Errores numéricos pueden:*

- Hacer que el algoritmo produzca un polígono no convexo.
- Causar que el algoritmo entre en bucle infinito al no poder decidir correctamente la orientación.

**Observación 1.41** (Geometría computacional robusta). *Los algoritmos geométricos comerciales (CAD, GIS) usan técnicas especiales:*

- **Aritmética exacta** para predicados críticos.
- **Perturbación simbólica** para romper degeneraciones.
- **Snap rounding** para redondear coordenadas a una rejilla.

## Chapter 2

# Álgebra Lineal Numérica

### 2.1 Eliminación Gaussiana y factorización LU

La **eliminación Gaussiana** es el método más antiguo y fundamental para resolver sistemas lineales. Consiste en transformar el sistema en uno equivalente de forma triangular superior, que se resuelve fácilmente por sustitución hacia atrás.

#### 2.1.1 Eliminación Gaussiana sin pivoteo

**Ejemplo 2.1** (Eliminación Gaussiana). *Consideremos el sistema:*

$$\begin{pmatrix} 2 & 1 & 1 \\ 4 & -6 & 0 \\ -2 & 7 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 5 \\ -2 \\ 9 \end{pmatrix}.$$

**Paso 1:** Eliminar  $x_1$  de las ecuaciones 2 y 3.

- Multiplicador para fila 2:  $m_{21} = 4/2 = 2$ . Restar  $2 \times$  fila 1 de fila 2.
- Multiplicador para fila 3:  $m_{31} = -2/2 = -1$ . Restar  $-1 \times$  fila 1 de fila 3.

Resultado:

$$\begin{pmatrix} 2 & 1 & 1 \\ 0 & -8 & -2 \\ 0 & 8 & 3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 5 \\ -12 \\ 14 \end{pmatrix}.$$

**Paso 2:** Eliminar  $x_2$  de la ecuación 3.

- Multiplicador:  $m_{32} = 8/(-8) = -1$ . Restar  $-1 \times$  fila 2 de fila 3.

Resultado (matriz triangular superior):

$$\begin{pmatrix} 2 & 1 & 1 \\ 0 & -8 & -2 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 5 \\ -12 \\ 2 \end{pmatrix}.$$



**Paso 3:** Sustitución hacia atrás:

$$\begin{aligned}x_3 &= 2, \\x_2 &= \frac{-12 + 2x_3}{-8} = \frac{-12 + 4}{-8} = 1, \\x_1 &= \frac{5 - x_2 - x_3}{2} = \frac{5 - 1 - 2}{2} = 1.\end{aligned}$$

### 2.1.2 Factorización LU

La eliminación Gaussiana puede interpretarse como una factorización matricial.

**Teorema 2.2** (Factorización LU). *Si la eliminación Gaussiana se puede realizar sin intercambio de filas (sin pivoteo), entonces  $A$  admite una factorización:*

$$A = LU,$$

donde:

- $L \in \mathbb{C}^{n \times n}$  es triangular inferior con unos en la diagonal,
- $U \in \mathbb{C}^{n \times n}$  es triangular superior.

Además, los elementos de  $L$  son precisamente los multiplicadores  $m_{ij}$  usados en la eliminación.

*Idea.* Cada paso de eliminación puede representarse como una multiplicación por una matriz triangular inferior. En el paso  $k$ , eliminamos los elementos debajo del pivote  $a_{kk}$  multiplicando por la izquierda por:

$$M_k = \begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -m_{k+1,k} & \ddots & \\ & & \vdots & & 1 \\ & & -m_{n,k} & & \end{pmatrix}.$$

Después de  $n - 1$  pasos:

$$M_{n-1} \cdots M_2 M_1 A = U.$$

Como cada  $M_k$  es triangular inferior invertible, podemos escribir:

$$A = M_1^{-1} M_2^{-1} \cdots M_{n-1}^{-1} U = LU,$$

donde  $L = M_1^{-1} M_2^{-1} \cdots M_{n-1}^{-1}$ . Un cálculo directo muestra que  $L$  tiene los multiplicadores  $m_{ij}$  debajo de la diagonal.  $\square$

**Ejemplo 2.3** (Construcción de  $L$  y  $U$ ). *Para la matriz del ejemplo anterior:*

$$A = \begin{pmatrix} 2 & 1 & 1 \\ 4 & -6 & 0 \\ -2 & 7 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ -1 & -1 & 1 \end{pmatrix} \begin{pmatrix} 2 & 1 & 1 \\ 0 & -8 & -2 \\ 0 & 0 & 1 \end{pmatrix} = LU.$$

Los elementos de  $L$  debajo de la diagonal son los multiplicadores:  $m_{21} = 2$ ,  $m_{31} = -1$ ,  $m_{32} = -1$ .

### 2.1.3 Pivoteo parcial y factorización PLU

La eliminación Gaussiana puede fallar o ser numéricamente inestable si los pivotes son pequeños. La solución es el **pivoteo parcial**: intercambiar filas para asegurar que el pivote sea el elemento de mayor magnitud en cada columna.

**Teorema 2.4** (Factorización PLU). *Toda matriz invertible  $A \in \mathbb{C}^{n \times n}$  admite una factorización:*

$$PA = LU,$$

donde  $P$  es una matriz de permutación,  $L$  es triangular inferior con unos en la diagonal, y  $U$  es triangular superior.

**Observación 2.5** (Solución de sistemas con PLU). *Una vez calculada la factorización  $PA = LU$ , resolver  $Ax = b$  requiere:*

1. Permutar el vector:  $\tilde{b} = Pb$
2. Resolver  $Ly = \tilde{b}$  (sustitución hacia adelante): costo  $O(n^2)$
3. Resolver  $Ux = y$  (sustitución hacia atrás): costo  $O(n^2)$

El costo total es  $O(n^3)$  para la factorización (hecha una sola vez) más  $O(n^2)$  por cada sistema resuelto. Más precisamente, el conteo de operaciones de la factorización  $LU$  es  $\frac{2}{3}n^3 + O(n^2)$  (aproximadamente  $\frac{n^3}{3}$  multiplicaciones y  $\frac{n^3}{3}$  sumas), como se verifica sumando el costo del paso  $k$ : la eliminación de la columna  $k$  requiere  $(n-k)$  divisiones y  $(n-k)^2$  operaciones de multiplicación-suma, dando un total de  $\sum_{k=1}^{n-1} (n-k)^2 = \frac{(n-1)n(2n-1)}{6} \sim \frac{n^3}{3}$  para cada tipo.

## 2.2 Ortogonalización de Gram-Schmidt y factorización QR

Otra factorización importante es la **factorización QR**, que descompone una matriz en un producto de una matriz ortogonal y una triangular superior. Se obtiene mediante el proceso de **Gram-Schmidt**.

### 2.2.1 Proceso de Gram-Schmidt clásico

**Teorema 2.6** (Gram-Schmidt Clásico (CGS)). *Dado un conjunto de vectores linealmente independientes  $\{a_1, \dots, a_n\} \subset \mathbb{C}^m$ , el proceso de Gram-Schmidt construye un conjunto ortonormal  $\{q_1, \dots, q_n\}$  que genera el mismo subespacio:*

$$\text{span}\{a_1, \dots, a_k\} = \text{span}\{q_1, \dots, q_k\}, \quad k = 1, \dots, n.$$

**Algoritmo (Gram-Schmidt Clásico):**

1. Para  $k = 1, \dots, n$ :
  - (a)  $\tilde{q}_k = a_k$
  - (b) Para  $j = 1, \dots, k-1$ :
    - $r_{jk} = (a_k, q_j)$

- $\tilde{q}_k \leftarrow \tilde{q}_k - r_{jk}q_j$
- (c)  $r_{kk} = \|\tilde{q}_k\|_2$
- (d)  $q_k = \tilde{q}_k/r_{kk}$

**Observación 2.7.** El proceso CGS ortogonaliza  $a_k$  restando de una sola vez las proyecciones sobre todos los vectores ortogonales  $q_1, \dots, q_{k-1}$  previamente calculados.

### 2.2.2 Gram-Schmidt Modificado (MGS)

El problema con CGS es que es numéricamente inestable: los errores de redondeo pueden hacer que los vectores resultantes no sean ortogonales. El **Gram-Schmidt Modificado** (MGS) resuelve este problema.

**Algoritmo (Gram-Schmidt Modificado):**

1. Para  $k = 1, \dots, n$ :
  - (a)  $\tilde{q}_k = a_k$
  - (b) Para  $j = 1, \dots, k-1$ :
    - $r_{jk} = (\tilde{q}_k, q_j)$  (usar el vector parcialmente ortogonalizado)
    - $\tilde{q}_k \leftarrow \tilde{q}_k - r_{jk}q_j$  (ortogonalizar paso a paso)
  - (c)  $r_{kk} = \|\tilde{q}_k\|_2$
  - (d)  $q_k = \tilde{q}_k/r_{kk}$

**Observación 2.8** (Diferencia entre CGS y MGS). La diferencia clave es que MGS actualiza  $\tilde{q}_k$  después de cada proyección y usa el vector actualizado en la siguiente proyección. Esto hace que MGS sea mucho más estable numéricamente, produciendo vectores con mejor ortogonalidad en presencia de errores de redondeo.

### 2.2.3 Factorización QR

El proceso de Gram-Schmidt aplicado a las columnas de una matriz produce la factorización QR.

**Teorema 2.9** (Factorización QR). Toda matriz  $A \in \mathbb{C}^{m \times n}$  con  $m \geq n$  y rango completo admite una factorización:

$$A = QR,$$

donde:

- $Q \in \mathbb{C}^{m \times n}$  tiene columnas ortonormales:  $Q^*Q = I_n$ ,
- $R \in \mathbb{C}^{n \times n}$  es triangular superior con diagonal positiva.

Si se extiende  $Q$  a una matriz unitaria  $m \times m$ , se puede escribir:

$$A = (Q_1 \quad Q_2) \begin{pmatrix} R \\ 0 \end{pmatrix} = Q_1 R,$$

donde  $Q_1 Q_1^* + Q_2 Q_2^* = I_m$ .

*Demostración.* Aplicando Gram-Schmidt (modificado) a las columnas de  $A = (a_1 | \cdots | a_n)$ , obtenemos vectores ortonormales  $q_1, \dots, q_n$  y coeficientes  $r_{jk}$  tales que:

$$a_k = \sum_{j=1}^k r_{jk} q_j = \sum_{j=1}^n r_{jk} q_j,$$

donde  $r_{jk} = 0$  para  $j > k$  (triangularidad superior). Escribiendo esto en forma matricial:

$$A = QR, \quad Q = (q_1 | \cdots | q_n), \quad R = (r_{ij}).$$

□

**Ejemplo 2.10** (Factorización QR explícita). Sea

$$A = \begin{pmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

Aplicando MGS:

1.  $a_1 = (1, 1, 0)^T$ ,  $r_{11} = \|a_1\|_2 = \sqrt{2}$ ,  $q_1 = (1/\sqrt{2}, 1/\sqrt{2}, 0)^T$ .
2.  $\tilde{q}_2 = a_2 = (1, 0, 1)^T$ .
3.  $r_{12} = (a_2, q_1) = 1/\sqrt{2}$ .
4.  $\tilde{q}_2 \leftarrow (1, 0, 1)^T - \frac{1}{\sqrt{2}}(1/\sqrt{2}, 1/\sqrt{2}, 0)^T = (1/2, -1/2, 1)^T$ .
5.  $r_{22} = \|\tilde{q}_2\|_2 = \sqrt{1/4 + 1/4 + 1} = \sqrt{3/2}$ .
6.  $q_2 = (1/\sqrt{6}, -1/\sqrt{6}, 2/\sqrt{6})^T$ .

Entonces:

$$A = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{6} \\ 1/\sqrt{2} & -1/\sqrt{6} \\ 0 & 2/\sqrt{6} \end{pmatrix} \begin{pmatrix} \sqrt{2} & 1/\sqrt{2} \\ 0 & \sqrt{3/2} \end{pmatrix} = QR.$$

1. **Solución de sistemas lineales:** Si  $A = QR$  con  $A$  cuadrada e invertible, entonces:

$$Ax = b \quad \Rightarrow \quad QRx = b \quad \Rightarrow \quad Rx = Q^*b,$$

que se resuelve por sustitución hacia atrás en  $O(n^2)$  operaciones.

2. **Problemas de cuadrados mínimos:** Como veremos en el próximo capítulo, QR es superior a las ecuaciones normales para resolver problemas de mínimos cuadrados.
3. **Cálculo de autovalores:** El método QR iterativo (Capítulo 3) es el algoritmo estándar para calcular todos los autovalores de una matriz.

**Observación 2.11** (Comparación: LU vs QR). • **Costo:** La factorización LU cuesta  $\frac{2}{3}n^3$  operaciones, mientras que QR (vía MGS) cuesta  $2n^3$  operaciones. LU es más rápida.

- **Estabilidad:** *QR es más estable numéricamente, especialmente para matrices mal condicionadas.*
- **Aplicaciones:** *LU se prefiere para sistemas lineales simples. QR se prefiere para cuadrados mínimos, autovalores, y cuando la estabilidad es crítica.*

## 2.3 Cuadrados mínimos y proyección ortogonal

El problema de **cuadrados mínimos** consiste en encontrar  $x \in \mathbb{C}^n$  que minimiza el residuo  $\|Ax - b\|_2$  para un sistema sobredeterminado  $Ax = b$ , con  $A \in \mathbb{C}^{m \times n}$  ( $m \geq n$ ) y  $b \in \mathbb{C}^m$ .

Recordemos de Álgebra Lineal que si  $S$  es un subespacio de un espacio con producto interno  $V$ , la mejor aproximación de un vector  $b \in V$  en  $S$  es su **proyección ortogonal**  $P_S(b)$ . Esta proyección se caracteriza por la propiedad de que el error es ortogonal al subespacio:

$$(b - P_S(b)) \perp S.$$

En el contexto de matrices, buscamos  $Ax \in \text{Im}(A)$  que esté lo más cerca posible de  $b$ . Por lo tanto, el residuo  $r = b - Ax$  debe ser ortogonal a todo el espacio columna  $\text{Im}(A)$ .

### 2.3.1 Ecuaciones normales para cuadrados mínimos

El problema de **cuadrados mínimos** consiste en encontrar  $x \in \mathbb{C}^n$  que minimiza:

$$\|Ax - b\|_2, \quad A \in \mathbb{C}^{m \times n}, \quad b \in \mathbb{C}^m, \quad m \geq n.$$

**Teorema 2.12** (Ecuaciones normales). *El vector  $x$  que minimiza  $\|Ax - b\|_2$  satisface las **ecuaciones normales**:*

$$A^*Ax = A^*b.$$

*Si  $A$  tiene rango completo (rango  $n$ ), entonces  $A^*A$  es invertible y la solución única es:*

$$x = (A^*A)^{-1}A^*b.$$

*Demostración.* Sea  $x$  el minimizador de  $\|Ax - b\|_2$ . Por el Teorema de proyección ortogonal (Teorema B.11), el error  $r = Ax - b$  debe ser ortogonal al espacio columna de  $A$ , es decir,  $r \perp \text{Im}(A)$ .

Esto significa que para todo  $v \in \mathbb{C}^n$ , tenemos  $Av \perp r$ , o equivalentemente:

$$(Av, r) = 0 \quad \text{para todo } v \in \mathbb{C}^n.$$

Usando la propiedad del producto interno:

$$(Av, Ax - b) = 0 \quad \text{para todo } v \in \mathbb{C}^n.$$

Por la antilinealidad en el segundo argumento y la propiedad  $(u, v) = v^*u$  para vectores:

$$(Av)^*(Ax - b) = v^*A^*(Ax - b) = 0 \quad \text{para todo } v \in \mathbb{C}^n.$$

Como esto debe valer para todo  $v \in \mathbb{C}^n$ , necesariamente:

$$A^*(Ax - b) = 0,$$

lo que es equivalente a las ecuaciones normales:

$$A^*Ax = A^*b.$$

Para la segunda parte, si  $A$  tiene rango completo (rango  $n$ ), entonces las columnas de  $A$  son linealmente independientes. Esto implica que  $A^*A$  es invertible, pues si  $A^*Ax = 0$ , entonces:

$$\|Ax\|^2 = (Ax, Ax) = x^*A^*Ax = x^*0 = 0,$$

lo que implica  $Ax = 0$ , y por el rango completo de  $A$ , necesariamente  $x = 0$ . Por lo tanto,  $A^*A$  es invertible y la solución única es:

$$x = (A^*A)^{-1}A^*b.$$

□

### 2.3.2 QR para cuadrados mínimos

Una alternativa a la solución directa de las ecuaciones normales es usar la **factorización QR**.

**Teorema 2.13** (Factorización QR). *Toda matriz  $A \in \mathbb{C}^{m \times n}$  con  $m \geq n$  admite una factorización:*

$$A = QR,$$

donde  $Q \in \mathbb{C}^{m \times m}$  es unitaria ( $Q^*Q = I$ ) y  $R \in \mathbb{C}^{m \times n}$  es triangular superior.

Si  $A$  tiene rango completo, podemos escribir:

$$A = Q \begin{pmatrix} R_1 \\ 0 \end{pmatrix}, \quad Q = (Q_1 \quad Q_2),$$

donde  $R_1 \in \mathbb{C}^{n \times n}$  es triangular superior invertible y  $Q_1 \in \mathbb{C}^{m \times n}$  tiene columnas ortonormales.

**Teorema 2.14** (Solución de cuadrados mínimos vía QR). *Si  $A = QR$  con  $Q$  unitaria y  $R$  triangular superior, entonces la solución de cuadrados mínimos de  $\|Ax - b\|_2$  se reduce a resolver:*

$$R_1x = Q_1^*b,$$

un sistema triangular que se resuelve por sustitución hacia atrás en  $O(n^2)$  operaciones.

*Demostración.* Como  $Q$  es unitaria, preserva la norma:

$$\|Ax - b\|_2 = \|QRx - b\|_2 = \|Rx - Q^*b\|_2 = \left\| \begin{pmatrix} R_1x \\ 0 \end{pmatrix} - \begin{pmatrix} Q_1^*b \\ Q_2^*b \end{pmatrix} \right\|_2.$$

Esto se minimiza cuando  $R_1x = Q_1^*b$ , dando un residuo mínimo de  $\|Q_2^*b\|_2$ .

□

## 2.4 Descomposición en Valores Singulares (SVD)

La **descomposición en valores singulares** (SVD) es una de las factorizaciones más importantes en álgebra lineal numérica.

Para construirla nos apoyamos en el **teorema espectral** para matrices hermíticas, aunque lo enunciamos aquí en el caso más general de matrices normales.

**Teorema 2.15** (Teorema espectral para matrices normales). *Sea  $A \in \mathbb{C}^{n \times n}$  una matriz normal ( $A^*A = AA^*$ ). Entonces  $A$  es diagonalizable por una matriz unitaria:*

$$A = U\Lambda U^*,$$

donde  $U$  es unitaria y  $\Lambda$  es diagonal.

*Demostración.* La demostración de este teorema se estudia en un curso de Álgebra Lineal.  $\square$

**Teorema 2.16** (SVD). *Toda matriz  $A \in \mathbb{C}^{m \times n}$  admite una descomposición:*

$$A = U\Sigma V^*,$$

donde:

- $U \in \mathbb{C}^{m \times m}$  es unitaria (columnas = vectores singulares izquierdos),
- $V \in \mathbb{C}^{n \times n}$  es unitaria (columnas = vectores singulares derechos),
- $\Sigma \in \mathbb{R}^{m \times n}$  es diagonal con entradas no negativas  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{\min(m,n)} \geq 0$  (valores singulares).

*Demostración.* Consideremos la matriz  $A^*A \in \mathbb{C}^{n \times n}$ . Esta matriz es hermítica, pues:

$$(A^*A)^* = A^*(A^*)^* = A^*A,$$

y además es semidefinida positiva, ya que para todo  $x \in \mathbb{C}^n$ :

$$x^*(A^*A)x = (Ax)^*(Ax) = \|Ax\|_2^2 \geq 0.$$

Por el teorema espectral, existe una base ortonormal  $\{v_1, \dots, v_n\}$  de  $\mathbb{C}^n$  formada por autovectores de  $A^*A$ , con autovalores reales no negativos  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$ . Es decir:

$$A^*Av_j = \lambda_j v_j, \quad j = 1, \dots, n.$$

Sea  $V \in \mathbb{C}^{n \times n}$  la matriz unitaria cuyas columnas son estos autovectores:  $V = [v_1 \mid v_2 \mid \dots \mid v_n]$ . Entonces:

$$A^*A = V\Lambda V^*, \quad \text{donde } \Lambda = \text{diag}(\lambda_1, \dots, \lambda_n).$$

Definimos los **valores singulares** de  $A$  como:

$$\sigma_j = \sqrt{\lambda_j}, \quad j = 1, \dots, n.$$

Estos son no negativos y están ordenados:  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0$ .

Sea  $r = \text{rango}(A)$ . Observemos que  $\text{rango}(A) = \text{rango}(A^*A)$  (esto se sigue de que  $\ker(A) = \ker(A^*A)$ ). Por lo tanto, exactamente  $r$  de los autovalores  $\lambda_j$  son positivos, y los valores singulares satisfacen:

$$\sigma_1 \geq \cdots \geq \sigma_r > 0, \quad \sigma_{r+1} = \cdots = \sigma_n = 0.$$

Para  $j = 1, \dots, r$ , definimos:

$$u_j = \frac{1}{\sigma_j} A v_j.$$

Estos vectores son ortonormales. En efecto, para  $1 \leq i, j \leq r$ :

$$u_i^* u_j = \frac{1}{\sigma_i \sigma_j} (A v_i)^* (A v_j) = \frac{1}{\sigma_i \sigma_j} v_i^* A^* A v_j = \frac{1}{\sigma_i \sigma_j} v_i^* (\lambda_j v_j) = \frac{\lambda_j}{\sigma_i \sigma_j} v_i^* v_j.$$

Como  $\sigma_j^2 = \lambda_j$  y  $v_i^* v_j = \delta_{ij}$  (delta de Kronecker), obtenemos:

$$u_i^* u_j = \frac{\sigma_j^2}{\sigma_i \sigma_j} \delta_{ij} = \frac{\sigma_j}{\sigma_i} \delta_{ij} = \delta_{ij}.$$

Por lo tanto,  $\{u_1, \dots, u_r\}$  es un conjunto ortonormal en  $\mathbb{C}^m$ .

Completamos  $\{u_1, \dots, u_r\}$  a una base ortonormal  $\{u_1, \dots, u_m\}$  de  $\mathbb{C}^m$  (esto siempre es posible mediante el proceso de Gram-Schmidt aplicado a cualquier extensión de  $\{u_1, \dots, u_r\}$  a una base de  $\mathbb{C}^m$ ).

Sea  $U \in \mathbb{C}^{m \times m}$  la matriz unitaria cuyas columnas son estos vectores:  $U = [u_1 \mid u_2 \mid \cdots \mid u_m]$ .

Definimos  $\Sigma \in \mathbb{R}^{m \times n}$  como la matriz con entradas:

$$\Sigma_{ij} = \begin{cases} \sigma_i & \text{si } i = j \leq r, \\ 0 & \text{en caso contrario.} \end{cases}$$

Es decir,  $\Sigma$  tiene los valores singulares en su diagonal principal (hasta la posición  $\min(m, n)$ ) y ceros en el resto.

Ahora verificamos que  $A = U \Sigma V^*$ . Para ello, calculamos las columnas de ambas matrices. Para  $j = 1, \dots, n$ , la  $j$ -ésima columna de  $A$  es  $A v_j$ , mientras que la  $j$ -ésima columna de  $U \Sigma V^*$  es:

$$U \Sigma V^* v_j = U \Sigma e_j,$$

donde  $e_j$  es el  $j$ -ésimo vector canónico de  $\mathbb{C}^n$  (pues  $V^* v_j = e_j$  al ser  $v_j$  la  $j$ -ésima columna de  $V$ ).

Si  $j \leq r$ , entonces  $\Sigma e_j = \sigma_j e_j$  (el  $j$ -ésimo vector canónico de  $\mathbb{C}^m$  escalado por  $\sigma_j$ ), de donde:

$$U \Sigma e_j = \sigma_j U e_j = \sigma_j u_j = A v_j.$$

Si  $j > r$ , entonces  $\sigma_j = 0$ , así que  $\Sigma e_j = 0$ , y por lo tanto:

$$U \Sigma e_j = 0.$$

Pero también  $A v_j = 0$  en este caso, pues  $v_j \in \ker(A)$  (ya que  $A^* A v_j = \lambda_j v_j = 0$  implica  $\|A v_j\|^2 = v_j^* A^* A v_j = 0$ ).

Por lo tanto,  $A = U \Sigma V^*$ , lo que completa la demostración.  $\square$



### 2.4.1 Pseudoinversa de Moore-Penrose

**Definición 2.17** (Pseudoinversa de Moore-Penrose). Sea  $A \in \mathbb{C}^{m \times n}$  y sea

$$A = U\Sigma V^*, \quad \Sigma = \text{diag}(\sigma_1, \dots, \sigma_r, 0, \dots, 0), \quad \sigma_1 \geq \dots \geq \sigma_r > 0,$$

una SVD de  $A$ , con  $r = \text{rank}(A)$ . Se define

$$\Sigma^+ = \text{diag}\left(\frac{1}{\sigma_1}, \dots, \frac{1}{\sigma_r}, 0, \dots, 0\right), \quad A^+ := V\Sigma^+U^*.$$

La matriz  $A^+$  se llama **pseudoinversa de Moore-Penrose** de  $A$ .

**Teorema 2.18** (Pseudoinversa y cuadrados mínimos en el caso general). Sea  $A \in \mathbb{C}^{m \times n}$  (sin hipótesis de rango completo) y sea  $d \in \mathbb{C}^m$ . Entonces:

(i) El problema

$$\min_{x \in \mathbb{C}^n} \|Ax - d\|_2$$

siempre tiene solución.

(ii) El vector

$$x^\dagger := A^+d$$

es una solución de mínimos cuadrados y es la **única** solución de norma mínima.

(iii) El conjunto de todas las soluciones de mínimos cuadrados es

$$\{x^\dagger + z : z \in \ker(A)\}.$$

(iv) Si  $\text{rank}(A) = n$  (columnas linealmente independientes), entonces la solución es única y

$$A^+ = (A^*A)^{-1}A^*, \quad x^\dagger = (A^*A)^{-1}A^*d.$$

*Demostración.* Con la SVD, para  $y = V^*x$  y  $c = U^*d$ :

$$\|Ax - d\|_2 = \|\Sigma y - c\|_2^2 = \sum_{i=1}^r |\sigma_i y_i - c_i|^2 + \sum_{i=r+1}^m |c_i|^2.$$

El mínimo se obtiene imponiendo  $y_i = c_i/\sigma_i$  para  $i \leq r$ ; las componentes  $y_{r+1}, \dots, y_n$  no afectan el valor del residuo. Por lo tanto existe minimizador y el de norma mínima se obtiene tomando esas componentes libres iguales a 0:

$$y^\dagger = (c_1/\sigma_1, \dots, c_r/\sigma_r, 0, \dots, 0)^T = \Sigma^+c.$$

Volviendo a  $x$ :

$$x^\dagger = Vy^\dagger = V\Sigma^+U^*d = A^+d.$$

Si  $x$  es cualquier otro minimizador, coincide con  $x^\dagger$  en las primeras  $r$  componentes de  $y$  y difiere solo en componentes asociadas a valores singulares nulos; eso equivale a sumar un vector de  $\ker(A)$ .

Si  $\text{rank}(A) = n$ , entonces no hay componentes libres, la solución es única y además

$$A^*A = V\Sigma^2V^* \Rightarrow (A^*A)^{-1}A^* = V\Sigma^{-1}U^* = A^+.$$

□

**Lema 2.19** (Propiedades elementales de la pseudoinversa). Sea  $A \in \mathbb{C}^{m \times n}$  y sea  $A^+$  su pseudoinversa de Moore–Penrose. Entonces:

- (i)  $AA^+A = A$ .
- (ii)  $A^+AA^+ = A^+$ .
- (iii)  $(AA^+)^* = AA^+$ .
- (iv)  $(A^+A)^* = A^+A$ .

*Demostración.* Sea  $A = U\Sigma V^*$  una SVD de  $A$  con  $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r, 0, \dots, 0)$ , de modo que  $A^+ = V\Sigma^+U^*$ . Observemos primero que  $\Sigma^+$  es la matriz diagonal con entradas  $1/\sigma_i$  para  $i \leq r$  y 0 en el resto, de modo que

$$\Sigma\Sigma^+ = \Sigma^+\Sigma = \text{diag}(\underbrace{1, \dots, 1}_r, 0, \dots, 0).$$

En particular,  $\Sigma\Sigma^+$  y  $\Sigma^+\Sigma$  son matrices diagonales reales, por lo tanto  $(\Sigma\Sigma^+)^* = \Sigma\Sigma^+$  y  $(\Sigma^+\Sigma)^* = \Sigma^+\Sigma$ . Además,

$$\Sigma\Sigma^+\Sigma = \Sigma, \quad \Sigma^+\Sigma\Sigma^+ = \Sigma^+.$$

Con esto, las cuatro propiedades se verifican directamente:

- (i)  $AA^+A = (U\Sigma V^*)(V\Sigma^+U^*)(U\Sigma V^*) = U(\Sigma\Sigma^+\Sigma)V^* = U\Sigma V^* = A$ .
- (ii)  $A^+AA^+ = (V\Sigma^+U^*)(U\Sigma V^*)(V\Sigma^+U^*) = V(\Sigma^+\Sigma\Sigma^+)U^* = V\Sigma^+U^* = A^+$ .
- (iii)  $(AA^+)^* = (U\Sigma\Sigma^+U^*)^* = U(\Sigma\Sigma^+)^*U^* = U\Sigma\Sigma^+U^* = AA^+$ .
- (iv)  $(A^+A)^* = (V\Sigma^+\Sigma V^*)^* = V(\Sigma^+\Sigma)^*V^* = V\Sigma^+\Sigma V^* = A^+A$ .

□

**Lema 2.20** (Propiedades de la matriz *hat*). Sea  $A \in \mathbb{C}^{m \times n}$  y defina

$$H := AA^+ \in \mathbb{C}^{m \times m}.$$

Entonces:

- (i)  $H^* = H$  y  $H^2 = H$ .
- (ii)  $H$  es el proyector ortogonal sobre  $\text{Col}(A)$ .
- (iii) Para todo  $d \in \mathbb{C}^m$ , si  $\hat{x} = A^+d$ , entonces el ajuste es

$$\hat{d} = A\hat{x} = Hd.$$

- (iv) Si  $h_{ii}$  denota la diagonal de  $H$ , entonces  $0 \leq h_{ii} \leq 1$  para todo  $i$ .

*Demostración.* Por el lema anterior,

$$H^* = (AA^+)^* = AA^+ = H,$$

y también,

$$H^2 = (AA^+)(AA^+) = (AA^+A)A^+ = AA^+ = H,$$

porque  $AA^+A = A$ . Así,  $H$  es proyector hermítico, luego por la Proposición B.12 es la proyección ortogonal sobre su imagen. Como  $H = AA^+$ , se tiene  $\text{Im}(H) = \text{Col}(A)$ : en efecto,  $\text{Im}(AA^+) \subseteq \text{Col}(A)$  porque  $AA^+y$  es combinación lineal de columnas de  $A$ , y recíprocamente si  $z \in \text{Col}(A)$ ,  $z = Ax$  para algún  $x$ , entonces  $z = AA^+Ax \in \text{Im}(AA^+)$  (usando  $AA^+A = A$ ). También,

$$\hat{d} = A\hat{x} = A(A^+d) = Hd.$$

Finalmente, para el vector canónico  $e_i$ ,

$$h_{ii} = \langle e_i, He_i \rangle.$$

Como  $H$  es proyección ortogonal,  $e_i - He_i \perp He_i$ , y por lo tanto

$$h_{ii} = \langle He_i + (e_i - He_i), He_i \rangle = \langle He_i, He_i \rangle = \|He_i\|_2^2 \geq 0.$$

Además, aplicando el Teorema B.7 a la descomposición ortogonal  $e_i = He_i + (e_i - He_i)$ ,

$$\|e_i\|_2^2 = \|He_i\|_2^2 + \|e_i - He_i\|_2^2 \geq \|He_i\|_2^2.$$

Como  $\|e_i\|_2 = 1$ , concluimos

$$h_{ii} = \|He_i\|_2^2 \leq 1.$$

□

## 2.4.2 Condicionamiento y problemas mal condicionados

El condicionamiento mide la sensibilidad de la solución de un sistema lineal  $Ax = b$  ante perturbaciones. Para cuantificar esto rigurosamente, nos restringiremos a la **norma 2** (o norma espectral), que está íntimamente ligada a la SVD.

**Definición 2.21** (Norma 2 y Número de Condición). Sea  $A \in \mathbb{C}^{m \times n}$ . La **norma 2** de un vector  $x \in \mathbb{C}^n$  es  $\|x\|_2 = \sqrt{x^*x}$ . La norma matricial inducida (o norma espectral) se define como:

$$\|A\|_2 = \sup_{x \in \mathbb{C}^n, x \neq 0} \frac{\|Ax\|_2}{\|x\|_2}.$$

El **número de condición espectral** de una matriz invertible  $A \in \mathbb{C}^{n \times n}$  se define como:

$$\kappa_2(A) = \|A\|_2 \|A^{-1}\|_2.$$

### 2.4.3 Propiedades de la norma de matrices

**Definición 2.22** (Radio espectral). *El **radio espectral** de una matriz  $A \in \mathbb{C}^{n \times n}$  es:*

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i(A)|,$$

donde  $\lambda_1, \dots, \lambda_n$  son los autovalores de  $A$ .

**Teorema 2.23** (Relación entre radio espectral y norma). *Para toda norma matricial inducida  $\|\cdot\|$  y toda matriz  $A \in \mathbb{C}^{n \times n}$ :*

$$\rho(A) \leq \|A\|.$$

*Demostración.* Sea  $\lambda$  un autovalor de  $A$  con autovector  $v$ , es decir,  $Av = \lambda v$  con  $v \neq 0$ . Entonces:

$$|\lambda| \|v\| = \|\lambda v\| = \|Av\| \leq \|A\| \|v\|.$$

Dividiendo por  $\|v\| > 0$ :  $|\lambda| \leq \|A\|$ . Como esto vale para todo autovalor,  $\rho(A) \leq \|A\|$ .  $\square$

**Lema 2.24** (Acotación de una media ponderada). *Sean  $\lambda_1, \dots, \lambda_n \in \mathbb{R}$ , y sean  $\lambda_{\min} := \min_i \lambda_i$ ,  $\lambda_{\max} := \max_i \lambda_i$ . Si  $\alpha_1, \dots, \alpha_n \geq 0$  y  $\sum_{i=1}^n \alpha_i = 1$ , entonces*

$$\lambda_{\min} \leq \sum_{i=1}^n \alpha_i \lambda_i \leq \lambda_{\max}.$$

*Ambas cotas se alcanzan eligiendo  $\alpha_k = 1$  para el índice  $k$  que realiza el mínimo o el máximo respectivamente.*

*Demostración.* Como  $\lambda_{\min} \leq \lambda_i \leq \lambda_{\max}$  para todo  $i$ , multiplicando por  $\alpha_i \geq 0$  y sumando sobre  $i$  se obtiene la doble desigualdad. La igualdad en cada extremo es inmediata.  $\square$

**Teorema 2.25.** *La norma espectral de  $A$  es igual a su mayor valor singular:  $\|A\|_2 = \sigma_1(A)$ .*

*Demostración.* Usando la SVD  $A = U\Sigma V^*$ , y recordando que las matrices unitarias preservan la norma 2 (es decir,  $\|Ux\|_2 = \|x\|_2$  para todo  $x$ ), tenemos:

$$\|Ax\|_2 = \|U\Sigma V^*x\|_2 = \|\Sigma(V^*x)\|_2.$$

Hacemos el cambio de variable  $y = V^*x$ . Como  $V$  es unitaria,  $\|y\|_2 = \|x\|_2$ . Entonces maximizar  $\frac{\|Ax\|_2}{\|x\|_2}$  es equivalente a maximizar  $\frac{\|\Sigma y\|_2}{\|y\|_2}$  sobre  $y \neq 0$ .

$$\frac{\|\Sigma y\|_2^2}{\|y\|_2^2} = \frac{\sum_{i=1}^n \sigma_i^2 |y_i|^2}{\sum_{i=1}^n |y_i|^2}.$$

Como  $y \neq 0$ , definimos

$$\alpha_i := \frac{|y_i|^2}{\sum_{j=1}^n |y_j|^2}, \quad i = 1, \dots, n.$$

Entonces  $\alpha_i \geq 0$  y  $\sum_{i=1}^n \alpha_i = 1$ . Aplicando el lema anterior con  $\lambda_i = \sigma_i^2$  y usando que  $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$ , obtenemos

$$\frac{\|\Sigma y\|_2^2}{\|y\|_2^2} = \sum_{i=1}^n \alpha_i \sigma_i^2 \leq \sum_{i=1}^n \alpha_i \sigma_1^2 = \sigma_1^2.$$

Así, para todo  $y \neq 0$ , se cumple  $\frac{\|\Sigma y\|_2^2}{\|y\|_2^2} \leq \sigma_1^2$ . Además, tomando  $y = e_1$  se obtiene la igualdad:

$$\frac{\|\Sigma e_1\|_2^2}{\|e_1\|_2^2} = \sigma_1^2.$$

Luego el máximo es  $\sigma_1^2$ . Tomando raíz cuadrada, obtenemos  $\|A\|_2 = \sigma_1$ .  $\square$

**Lema 2.26** (Norma de la inversa y valor singular mínimo). *Sea  $A \in \mathbb{C}^{n \times n}$  inversible con valores singulares  $\sigma_1 \geq \dots \geq \sigma_n > 0$ . Entonces*

$$\|A^{-1}\|_2 = \frac{1}{\sigma_n},$$

y en particular

$$\sigma_n = \min_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2}.$$

*Demostración.* Sea  $A = U\Sigma V^*$  la SVD, con  $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_n)$  y  $\sigma_n > 0$ . Entonces

$$A^{-1} = (U\Sigma V^*)^{-1} = V\Sigma^{-1}U^* = V \text{diag}(1/\sigma_1, \dots, 1/\sigma_n)U^*.$$

Los valores singulares de  $A^{-1}$  son  $1/\sigma_n \geq \dots \geq 1/\sigma_1 > 0$ ; aplicando el teorema anterior a  $A^{-1}$  se obtiene  $\|A^{-1}\|_2 = 1/\sigma_n$ . La fórmula variacional para  $\sigma_n$  se deduce del mismo argumento: el mínimo de  $\|\Sigma y\|_2/\|y\|_2$  se alcanza en  $y = e_n$  y vale  $\sigma_n$ .  $\square$

Combinando el teorema anterior con el lema se obtiene la fórmula definitiva para el número de condición:

$$\kappa_2(A) = \|A\|_2 \|A^{-1}\|_2 = \frac{\sigma_1}{\sigma_n}.$$

**Observación 2.27.** *El supremo en la definición 2.21 se toma sobre vectores complejos, lo cual es natural ya que  $A \in \mathbb{C}^{m \times n}$ . Para matrices reales  $A \in \mathbb{R}^{m \times n}$ , el supremo sobre  $\mathbb{C}^n$  coincide con el supremo sobre  $\mathbb{R}^n$ : dado  $x = u + iv \in \mathbb{C}^n$ ,*

$$\|Ax\|_2^2 = \|Au\|_2^2 + \|Av\|_2^2 \leq \sigma_1^2(\|u\|_2^2 + \|v\|_2^2) = \sigma_1^2\|x\|_2^2,$$

y la cota se alcanza en el vector singular derecho real  $v_1$ . En el caso complejo esta coincidencia no se da en general (los vectores singulares de una matriz compleja son complejos), de modo que restringir el supremo a  $\mathbb{R}^n$  podría dar un valor estrictamente menor.

**Teorema 2.28** (Cota de error relativo para  $Ax = b$  en norma 2). *Sea  $A \in \mathbb{C}^{n \times n}$  inversible, y sea  $x = A^{-1}b$  con  $b \neq 0$ . Para una perturbación  $\delta b \in \mathbb{C}^n$ , defina*

$$x + \delta x := A^{-1}(b + \delta b),$$

*equivalentemente  $A\delta x = \delta b$ . Entonces*

$$\frac{\|\delta x\|_2}{\|x\|_2} \leq \kappa_2(A) \frac{\|\delta b\|_2}{\|b\|_2}, \quad \kappa_2(A) = \|A\|_2 \|A^{-1}\|_2.$$

*Demostración.* Sea  $A = U\Sigma V^*$  su SVD, con  $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_n)$ ,  $\sigma_1 \geq \dots \geq \sigma_n > 0$ .

Como  $\delta x = A^{-1}\delta b$ , se tiene

$$\delta x = \sum_{i=1}^n \frac{u_i^* \delta b}{\sigma_i} v_i,$$

de modo que, aplicando Parseval (Teorema B.10, ecuación (B.2)) en las bases ortonormales  $\{v_i\}$  y  $\{u_i\}$ ,

$$\|\delta x\|_2^2 = \sum_{i=1}^n \frac{|u_i^* \delta b|^2}{\sigma_i^2} \leq \frac{1}{\sigma_n^2} \sum_{i=1}^n |u_i^* \delta b|^2 = \frac{1}{\sigma_n^2} \|\delta b\|_2^2.$$

Luego

$$\|\delta x\|_2 \leq \frac{1}{\sigma_n} \|\delta b\|_2.$$

Además, de  $b = Ax = U\Sigma V^*x$  se obtiene

$$b = \sum_{i=1}^n \sigma_i (v_i^* x) u_i,$$

y nuevamente por Parseval (Teorema B.10),

$$\|b\|_2^2 = \sum_{i=1}^n \sigma_i^2 |v_i^* x|^2 \leq \sigma_1^2 \sum_{i=1}^n |v_i^* x|^2 = \sigma_1^2 \|x\|_2^2.$$

Así,

$$\|x\|_2 \geq \frac{\|b\|_2}{\sigma_1}.$$

Combinando ambas cotas:

$$\frac{\|\delta x\|_2}{\|x\|_2} \leq \frac{(1/\sigma_n) \|\delta b\|_2}{(1/\sigma_1) \|b\|_2} = \frac{\sigma_1}{\sigma_n} \frac{\|\delta b\|_2}{\|b\|_2} = \kappa_2(A) \frac{\|\delta b\|_2}{\|b\|_2}.$$

□

Esta cota es alcanzable (es decir, es óptima). El peor caso ocurre cuando  $b$  está alineado con la dirección de máxima amplificación ( $u_1$ ) y el error  $\delta b$  está alineado con la dirección de mínima amplificación ( $u_n$ ), que corresponde a la máxima amplificación de la inversa. En ese caso, el error relativo en la solución se amplifica exactamente por un factor  $\kappa_2(A)$ .

**Ejemplo 2.29** (Optimalidad de la cota). *Consideremos  $A = \text{diag}(\sigma_1, \sigma_2)$  con  $\sigma_1 > \sigma_2 > 0$  (aquí  $A = U\Sigma V^*$  con  $U = V = I$ ). Tomamos  $b = e_1 = (1, 0)^T$  (alineado con la dirección de  $\sigma_1$ ) y  $\delta b = \epsilon e_2$  (alineado con la dirección de  $\sigma_2$ ). Entonces:*

$$x = A^{-1}b = \left( \frac{1}{\sigma_1}, 0 \right)^T, \quad \delta x = A^{-1}\delta b = \left( 0, \frac{\epsilon}{\sigma_2} \right)^T.$$

*El error relativo resulta:*

$$\frac{\|\delta x\|_2 / \|x\|_2}{\|\delta b\|_2 / \|b\|_2} = \frac{\epsilon / \sigma_2}{1 / \sigma_1} \cdot \frac{1}{\epsilon} = \frac{\sigma_1}{\sigma_2} = \kappa_2(A).$$

*Esto confirma que la cota se alcanza con igualdad.*

Un problema es **mal condicionado** si  $\kappa_2(A) \gg 1$ , lo cual ocurre cuando  $\sigma_n \approx 0$ . Esto es consistente con la expansión de la solución en términos de la SVD, donde los términos asociados a  $\sigma_n$  pequeño dominan el error.

**Ejemplo 2.30** (Matriz de Hilbert). La matriz de Hilbert  $H_n$  con entradas  $H_{ij} = \frac{1}{i+j-1}$  está extremadamente mal condicionada. Para  $n = 10$ :

$$\kappa_2(H_{10}) \approx 1.6 \times 10^{13}.$$

Esto significa que se pierden aproximadamente 13 dígitos de precisión al resolver sistemas lineales con  $H_{10}$ , haciéndolo prácticamente imposible usando aritmética de precisión doble (que tiene solo 16 dígitos). El mal condicionamiento no depende de la norma: se puede verificar que  $\kappa_1(H_{10})$  y  $\kappa_\infty(H_{10})$  tienen el mismo orden de magnitud.

#### 2.4.4 Regularización de Tikhonov

Cuando nos enfrentamos a un problema mal condicionado (o incluso singular, donde  $\sigma_n = 0$ ), la solución directa por mínimos cuadrados o inversión es inestable. Para obtener una solución útil, se utiliza la **regularización**, que impone restricciones adicionales a la solución (como que su norma no sea demasiado grande).

La **regularización de Tikhonov** reemplaza el problema de mínimos cuadrados original  $\min_x \|Ax - b\|_2^2$  por un problema penalizado:

$$\min_x (\|Ax - b\|_2^2 + \lambda^2 \|x\|_2^2),$$

donde  $\lambda > 0$  es un parámetro de regularización que controla el balance entre el ajuste a los datos y la norma de la solución.

Utilizando la SVD de  $A = U\Sigma V^*$ , podemos encontrar una expresión explícita para la solución regularizada  $x_\lambda$ .

Para ver por qué, observemos que minimizar el funcional  $J(x) = \|Ax - b\|_2^2 + \lambda^2 \|x\|_2^2$  es equivalente a resolver un problema de mínimos cuadrados extendido. Definimos la matriz aumentada  $\tilde{A}$  y el vector aumentado  $\tilde{b}$  como:

$$\tilde{A} = \begin{pmatrix} A \\ \lambda I \end{pmatrix}, \quad \tilde{b} = \begin{pmatrix} b \\ 0 \end{pmatrix}.$$

Entonces:

$$\|\tilde{A}x - \tilde{b}\|_2^2 = \left\| \begin{pmatrix} Ax - b \\ \lambda x \end{pmatrix} \right\|_2^2 = \|Ax - b\|_2^2 + \|\lambda x\|_2^2 = J(x).$$

La solución de mínimos cuadrados para el sistema  $\tilde{A}x = \tilde{b}$  está dada por las ecuaciones normales  $\tilde{A}^* \tilde{A}x = \tilde{A}^* \tilde{b}$ . Calculando los productos:

$$\tilde{A}^* \tilde{A} = (A^* \quad \lambda I) \begin{pmatrix} A \\ \lambda I \end{pmatrix} = A^* A + \lambda^2 I,$$

$$\tilde{A}^* \tilde{b} = (A^* \quad \lambda I) \begin{pmatrix} b \\ 0 \end{pmatrix} = A^* b.$$

Por lo tanto, el problema es equivalente a resolver el sistema de ecuaciones normales regularizado:

$$(A^*A + \lambda^2 I)x = A^*b.$$

Sustituyendo  $A^*A = V\Sigma^2V^*$ , tenemos:

$$(V\Sigma^2V^* + \lambda^2 VIV^*)x = V(\Sigma^2 + \lambda^2 I)V^*x = V\Sigma U^*b.$$

Despejando  $x$ :

$$x_\lambda = V(\Sigma^2 + \lambda^2 I)^{-1}\Sigma U^*b.$$

En términos de las componentes, la solución es:

$$x_\lambda = \sum_{i=1}^n \frac{\sigma_i}{\sigma_i^2 + \lambda^2} (u_i^* b) v_i.$$

Comparemos esto con la solución de mínimos cuadrados estándar (para  $A$  invertible):

$$x_{LS} = \sum_{i=1}^n \frac{1}{\sigma_i} (u_i^* b) v_i.$$

Los términos  $\frac{\sigma_i}{\sigma_i^2 + \lambda^2}$  actúan como un filtro. Definimos los **factores de filtro** como  $f_i = \frac{\sigma_i}{\sigma_i^2 + \lambda^2}$ :

- Si  $\sigma_i \gg \lambda$ , entonces  $\sigma_i^2 + \lambda^2 \approx \sigma_i^2$ , por lo que el término se comporta como  $1/\sigma_i$  (la solución original).
- Si  $\sigma_i \ll \lambda$ , entonces  $\sigma_i^2 + \lambda^2 \approx \lambda^2$ , y el término se comporta como  $\sigma_i/\lambda^2 \approx 0$ .

De esta forma, la regularización de Tikhonov “apaga” suavemente las componentes asociadas a valores singulares pequeños (que son las que causan inestabilidad por ruido), a costa de introducir un pequeño sesgo en la solución exacta.

#### 2.4.5 Aproximación de bajo rango (Teorema de Eckart-Young)

Una de las aplicaciones más potentes de la SVD es la capacidad de aproximar una matriz por otra de rango menor de manera óptima.

**Teorema 2.31** (Eckart-Young-Mirsky). Sea  $A \in \mathbb{C}^{m \times n}$  con descomposición en valores singulares  $A = U\Sigma V^*$ , donde  $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_p)$  con  $p = \min(m, n)$ . Para cualquier  $k < p$ , definimos la matriz truncada  $A_k$  como:

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^* = U \Sigma_k V^*,$$

donde  $\Sigma_k$  es igual a  $\Sigma$  pero con  $\sigma_{k+1} = \dots = \sigma_p = 0$ .

Entonces,  $A_k$  es la mejor aproximación de rango  $k$  a  $A$  en la norma espectral (norma 2) y en la norma de Frobenius. Es decir:

$$1. \|A - A_k\|_2 = \min_{\text{rango}(B) \leq k} \|A - B\|_2 = \sigma_{k+1}.$$



$$2. \|A - A_k\|_F = \min_{\text{rango}(B) \leq k} \|A - B\|_F = \sqrt{\sum_{j=k+1}^p \sigma_j^2}.$$

*Demostración.* Demostraremos el caso de la norma espectral (norma 2).

Primero, es claro que  $\text{rango}(A_k) = k$  y que:

$$A - A_k = \sum_{i=k+1}^p \sigma_i u_i v_i^*.$$

La norma 2 de esta matriz es su mayor valor singular, que es  $\sigma_{k+1}$ . Por lo tanto,  $\|A - A_k\|_2 = \sigma_{k+1}$ .

Ahora debemos probar que para cualquier  $B$  con  $\text{rango}(B) \leq k$ , se cumple  $\|A - B\|_2 \geq \sigma_{k+1}$ . La idea es construir un vector unitario  $z$  que esté en  $\ker(B)$  (para poder eliminar  $B$ ) y en  $W := \text{span}\{v_1, \dots, v_{k+1}\}$  (para acotar  $\|Az\|_2$  por abajo).

Sea  $W$  como arriba, con  $\dim(W) = k + 1$ . Como  $\dim(\ker B) = n - \text{rango}(B) \geq n - k$  (Teorema A.21), el Corolario A.20 de la Fórmula de Grassmann da:

$$\dim(W \cap \ker B) \geq (k + 1) + (n - k) - n = 1,$$

así que existe  $z \in W \cap \ker(B)$  unitario. Escribimos  $z = \sum_{i=1}^{k+1} c_i v_i$  con  $\sum |c_i|^2 = 1$ . Entonces:

$$\|A - B\|_2 \geq \|(A - B)z\|_2 = \|Az\|_2 = \left\| \sum_{i=1}^{k+1} c_i \sigma_i u_i \right\|_2,$$

y aplicando la cota inferior del Lema 2.24 con  $\lambda_i = \sigma_i^2$  (el mínimo de  $\sigma_1^2, \dots, \sigma_{k+1}^2$  es  $\sigma_{k+1}^2$ ),

$$\|Az\|_2^2 = \sum_{i=1}^{k+1} |c_i|^2 \sigma_i^2 \geq \sigma_{k+1}^2.$$

Luego  $\|A - B\|_2 \geq \sigma_{k+1}$ , y como  $B$  era arbitrario,  $A_k$  es óptima en norma 2.  $\square$

## 2.4.6 Norma de Frobenius y propiedades de la traza

Además de la norma espectral  $\|A\|_2$ , otra norma matricial de uso frecuente es la norma de Frobenius.

**Definición 2.32** (Norma de Frobenius). *La **norma de Frobenius** de una matriz  $A \in \mathbb{C}^{m \times n}$  se define como:*

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2} = \sqrt{\text{tr}(A^* A)},$$

donde  $\text{tr}(B) = \sum_i b_{ii}$  denota la traza de una matriz cuadrada.

**Lema 2.33** (Propiedades de la traza). *Sean  $A \in \mathbb{C}^{m \times n}$  y  $B \in \mathbb{C}^{n \times m}$ . Entonces:*

1.  $\text{tr}(AB) = \text{tr}(BA)$ .
2.  $\|A\|_F^2 = \sum_{i=1}^{\min(m,n)} \sigma_i^2$  (donde  $\sigma_i$  son los valores singulares de  $A$ ).

3. Las matrices unitarias preservan la norma de Frobenius:  $\|UAV\|_F = \|A\|_F$  para  $U, V$  unitarias.

*Demostración.* (1)  $\text{tr}(AB) = \sum_{i=1}^m \sum_{k=1}^n a_{ik} b_{ki} = \sum_{k=1}^n \sum_{i=1}^m b_{ki} a_{ik} = \text{tr}(BA)$ .

(2) Si  $A = U\Sigma V^*$ , entonces  $A^*A = V\Sigma^2 V^*$  y  $\text{tr}(A^*A) = \text{tr}(V\Sigma^2 V^*) = \text{tr}(\Sigma^2 V^*V) = \text{tr}(\Sigma^2) = \sum \sigma_i^2$ .

(3)  $\|UAV\|_F^2 = \text{tr}(V^*A^*U^*UAV) = \text{tr}(V^*A^*AV) = \text{tr}(A^*AVV^*) = \text{tr}(A^*A) = \|A\|_F^2$ .  $\square$

## 2.5 Métodos iterativos para autovalores

La estrategia principal de muchos algoritmos para calcular autovalores consiste en transformar la matriz original en una forma más simple (diagonal o triangular) preservando su espectro. Esto se justifica por el hecho de que **las relaciones de similitud entre matrices no alteran los autovalores**: si  $B = S^{-1}AS$ , entonces  $\det(B - \lambda I) = \det(A - \lambda I)$ .

### 2.5.1 Teorema de los círculos de Gershgorin

El Teorema de Gershgorin localiza los autovalores de una matriz a partir de sus entradas, sin calcularlos.

**Teorema 2.34** (Teorema de los círculos de Gershgorin). *Sea  $A \in \mathbb{C}^{n \times n}$ . Todos los autovalores de  $A$  se encuentran en la unión de los  $n$  discos de Gershgorin:*

$$\sigma(A) \subseteq \bigcup_{i=1}^n D_i, \quad D_i = \{z \in \mathbb{C} : |z - a_{ii}| \leq R_i\}, \quad R_i = \sum_{j \neq i} |a_{ij}|.$$

*Demostración.* Sea  $\lambda$  un autovalor de  $A$  con autovector  $x$ , y sea  $x_i$  la componente de mayor módulo ( $|x_i| \geq |x_j|$  para todo  $j$ , con  $|x_i| > 0$ ). La  $i$ -ésima ecuación de  $Ax = \lambda x$  da:

$$(\lambda - a_{ii})x_i = \sum_{j \neq i} a_{ij}x_j.$$

Tomando valor absoluto y dividiendo por  $|x_i|$ :

$$|\lambda - a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \frac{|x_j|}{|x_i|} \leq \sum_{j \neq i} |a_{ij}| = R_i.$$

$\square$

**Observación 2.35.** Como  $\sigma(A) = \sigma(A^T)$ , también se puede aplicar el teorema usando sumas por columnas. La intersección de las regiones obtenidas por filas y por columnas da una localización más precisa.

## 2.5.2 El método de la potencia

El método de la potencia calcula el autovalor dominante de una matriz.

**Algoritmo (Método de la potencia):** Sea  $A \in \mathbb{C}^{n \times n}$  y  $v_0 \in \mathbb{C}^n$  no nulo. Para  $k = 0, 1, 2, \dots$ :

1.  $w_{k+1} = Av_k$
2.  $v_{k+1} = w_{k+1} / \|w_{k+1}\|_2$  (normalización)
3.  $\lambda_k = v_k^* Av_k$  (cociente de Rayleigh)

**Definición 2.36** (Cociente de Rayleigh). Dada  $A \in \mathbb{C}^{n \times n}$  y  $x \in \mathbb{C}^n$  no nulo, el **cociente de Rayleigh** de  $x$  es

$$\rho(x) = \frac{x^* Ax}{x^* x}.$$

Si  $x$  es autovector de  $A$  con autovalor  $\lambda$ , entonces  $\rho(x) = \lambda$ .

**Teorema 2.37** (Convergencia del método de la potencia). Sea  $A \in \mathbb{C}^{n \times n}$  diagonalizable con autovalores  $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$  y autovectores  $u_1, \dots, u_n$  que forman una base.

Si  $v_0 = \sum_{j=1}^n \alpha_j u_j$  con  $\alpha_1 \neq 0$ , entonces  $v_k \rightarrow \pm u_1$ ,  $\lambda_k \rightarrow \lambda_1$ , con tasa de convergencia  $O(|\lambda_2/\lambda_1|^k)$ .

**Observación 2.38.** Si  $|\lambda_1|$  está bien separado de  $|\lambda_2|$ , el método converge rápidamente. Si  $|\lambda_1| \approx |\lambda_2|$ , la convergencia es lenta. Si hay múltiples autovalores con la misma magnitud máxima, el método puede no converger.

## 2.5.3 El método QR

El **método QR** es un algoritmo iterativo para calcular *todos* los autovalores de una matriz.

**Algoritmo (Método QR):** Sea  $A_0 = A \in \mathbb{C}^{n \times n}$ . Para  $k = 0, 1, 2, \dots$ :

1. Factorizar  $A_k = Q_k R_k$  (factorización QR)
2. Formar  $A_{k+1} = R_k Q_k$

Observemos que  $A_{k+1} = R_k Q_k = Q_k^* (Q_k R_k) Q_k = Q_k^* A_k Q_k$ , de modo que todas las matrices  $A_k$  son unitariamente semejantes y comparten los mismos autovalores.

**Definición 2.39** (Matrices QR acumuladas). Definimos las matrices acumuladas

$$\bar{Q}_k = Q_0 Q_1 \cdots Q_{k-1}, \quad \bar{R}_k = R_{k-1} \cdots R_1 R_0.$$

**Teorema 2.40** (Convergencia del método QR). Si  $A$  es diagonalizable con  $|\lambda_1| > |\lambda_2| > \dots > |\lambda_n|$ , entonces  $A_k$  converge a una matriz triangular superior cuyos elementos diagonales son los autovalores de  $A$ .

La convergencia del elemento  $(i, j)$  con  $i > j$  es  $O(|\lambda_j/\lambda_i|^k)$ .

**Observación 2.41.** El método QR puede interpretarse como la aplicación simultánea del método de la potencia a múltiples vectores ortogonales: la factorización QR de  $A^k = \bar{Q}_k \bar{R}_k$  ortogonaliza las columnas de  $A^k$ , que convergen a los autovectores de  $A$ .

## 2.5.4 Matriz compañera y raíces de polinomios

**Definición 2.42** (Matriz compañera). Dado un polinomio mónico  $p(\lambda) = \lambda^n + a_{n-1}\lambda^{n-1} + \dots + a_0$ , su **matriz compañera** es:

$$C = \begin{pmatrix} 0 & 0 & \cdots & 0 & -a_0 \\ 1 & 0 & \cdots & 0 & -a_1 \\ 0 & 1 & \cdots & 0 & -a_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & -a_{n-1} \end{pmatrix}.$$

El polinomio característico de  $C$  es  $\det(C - \lambda I) = (-1)^n p(\lambda)$ , de modo que los autovalores de  $C$  son las raíces de  $p$ . Esto permite calcular raíces de polinomios aplicando el método QR a  $C$ .

## 2.6 Métodos iterativos para sistemas lineales

Cuando el sistema  $Ax = b$  es grande y la matriz  $A$  es rala (tiene muchos ceros), los métodos directos como LU pueden ser ineficientes. Los **métodos iterativos** construyen una sucesión  $\{x^{(k)}\}$  que converge a la solución.

### 2.6.1 Métodos estacionarios y convergencia

**Definición 2.43** (Método iterativo estacionario). Un **método iterativo estacionario** para resolver  $Ax = b$  tiene la forma

$$x^{(k+1)} = Gx^{(k)} + c,$$

donde  $G \in \mathbb{C}^{n \times n}$  es la **matriz de iteración** (que no depende de  $k$ ) y  $c$  es un vector fijo. Si la solución exacta  $x^*$  satisface  $x^* = Gx^* + c$ , el error  $e^{(k)} = x^{(k)} - x^*$  cumple

$$e^{(k)} = G^k e^{(0)}.$$

**Observación 2.44.** Se puede probar que  $G^k \rightarrow 0$  (y por lo tanto el método converge para todo  $x^{(0)}$ ) si y solo si  $\rho(G) < 1$  (véase la definición de radio espectral en el Teorema 2.23). Además, como  $\rho(G) \leq \|G\|$  para toda norma inducida, una condición suficiente práctica es  $\|G\| < 1$ .

Para definir los métodos concretos, descomponemos  $A$  como

$$A = D + L + U,$$

donde  $D$  es la diagonal de  $A$ ,  $L$  es la parte triangular inferior estricta y  $U$  es la parte triangular superior estricta.

**Definición 2.45** (Diagonal dominancia estricta). Una matriz  $A \in \mathbb{C}^{n \times n}$  es **estrictamente diagonal dominante por filas** si

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}|, \quad i = 1, \dots, n.$$

### 2.6.2 Método de Jacobi

**Definición 2.46** (Iteración de Jacobi). *El **método de Jacobi** para  $Ax = b$  (con  $a_{ii} \neq 0$  para todo  $i$ ) es el método estacionario con*

$$x^{(k+1)} = D^{-1}(b - (L + U)x^{(k)}).$$

La matriz de iteración es  $G_J = -D^{-1}(L + U) = I - D^{-1}A$ .

Componente a componente, cada iteración actualiza:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j \neq i} a_{ij}x_j^{(k)} \right), \quad i = 1, \dots, n.$$

### 2.6.3 Método de Gauss-Seidel

**Definición 2.47** (Iteración de Gauss-Seidel). *El **método de Gauss-Seidel** para  $Ax = b$  es el método estacionario*

$$(D + L)x^{(k+1)} = b - Ux^{(k)},$$

es decir,  $x^{(k+1)} = (D + L)^{-1}(b - Ux^{(k)})$ . La matriz de iteración es  $G_{GS} = -(D + L)^{-1}U$ .

La diferencia con Jacobi es que Gauss-Seidel usa los valores *ya actualizados* de  $x^{(k+1)}$  a medida que están disponibles:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j < i} a_{ij}x_j^{(k+1)} - \sum_{j > i} a_{ij}x_j^{(k)} \right).$$

## Chapter 3

# Interpolación

El objetivo de la interpolación polinomial es reconstruir un polinomio a partir de sus valores en ciertos puntos. Aunque el problema puede plantearse de forma elemental, su estructura matemática conecta áreas dispares: análisis de Fourier, integración numérica y criptografía moderna.

### 3.1 Existencia y unicidad del interpolante

Sea  $\mathbb{F}$  un cuerpo ( $\mathbb{R}$ ,  $\mathbb{C}$ ,  $\mathbb{Z}_p$ , etc.) y denotemos  $\mathcal{P}_n(\mathbb{F})$  al espacio vectorial de polinomios de grado  $\leq n$  con coeficientes en  $\mathbb{F}$ . Una base es la **base monomial**  $\{1, x, \dots, x^n\}$ , de modo que  $\dim \mathcal{P}_n = n + 1$ .

**Definición 3.1** (Problema de interpolación). *Dados  $n + 1$  nodos distintos  $x_0, \dots, x_n \in \mathbb{F}$  y valores  $y_0, \dots, y_n \in \mathbb{F}$ , busquemos  $p \in \mathcal{P}_n$  tal que  $p(x_i) = y_i$  para  $i = 0, \dots, n$ .*

**Definición 3.2** (Operador de evaluación). *Dados  $n + 1$  nodos distintos  $x_0, \dots, x_n \in \mathbb{F}$ , el **operador de evaluación** es la transformación lineal*

$$\Phi: \mathcal{P}_n \longrightarrow \mathbb{F}^{n+1}, \quad \Phi(p) = (p(x_0), \dots, p(x_n)).$$

La linealidad de  $\Phi$  es inmediata: evaluar una combinación lineal de polinomios en un punto da la misma combinación lineal de los valores. El problema de interpolación es, precisamente, resolver la ecuación  $\Phi(p) = y$  dado  $y = (y_0, \dots, y_n) \in \mathbb{F}^{n+1}$ ; dicho de otro modo, interpolar equivale a calcular  $\Phi^{-1}(y)$ .

**Teorema 3.3** (Existencia y unicidad). *Si los nodos  $x_0, \dots, x_n$  son distintos,  $\Phi$  es un isomorfismo. En particular, para cualquier vector de valores  $y \in \mathbb{F}^{n+1}$  existe un único  $p \in \mathcal{P}_n$  tal que  $p(x_i) = y_i$  para  $i = 0, \dots, n$ .*

*Demostración.* Puesto que  $\dim \mathcal{P}_n = n + 1 = \dim \mathbb{F}^{n+1}$ , el teorema rango-nulidad garantiza que  $\Phi$  es inyectiva si y solo si es sobreyectiva, por lo que basta verificar  $\ker \Phi = \{0\}$ .

Sea  $p \in \ker \Phi$ , es decir,  $p(x_i) = 0$  para  $i = 0, \dots, n$ . Un polinomio no nulo de grado  $\leq n$  tiene a lo sumo  $n$  raíces (Teorema A.22, Apéndice A); como  $p$  posee  $n + 1$  raíces distintas, se concluye  $p \equiv 0$ . Por tanto  $\ker \Phi = \{0\}$  y  $\Phi$  es un isomorfismo.  $\square$

### 3.1.1 La matriz de Vandermonde

Si escribimos  $p(x) = \sum_{k=0}^n a_k x^k$  en la base monomial, las condiciones  $p(x_i) = y_i$  se traducen en el sistema  $Va = y$  con la **matriz de Vandermonde**

$$V = \begin{pmatrix} 1 & x_0 & x_0^2 & \cdots & x_0^n \\ 1 & x_1 & x_1^2 & \cdots & x_1^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^n \end{pmatrix}, \quad \det(V) = \prod_{0 \leq i < j \leq n} (x_j - x_i) \neq 0.$$

Así, la existencia y unicidad del interpolante se reducen a la inversibilidad de  $V$ .

**Proposición 3.4** (Mal condicionamiento de Vandermonde). *Para cualquier elección de  $n + 1$  nodos distintos  $x_0, \dots, x_n \in [-1, 1]$ , la matriz de Vandermonde  $V$  satisface*

$$\kappa_2(V) \geq \frac{2^{\lfloor n/2 \rfloor}}{\sqrt{n+1}}.$$

En particular,  $\kappa_2(V)$  crece al menos exponencialmente con  $n$ , lo que hace que resolver el sistema  $Va = y$  sea un método numéricamente inadecuado para calcular el interpolante.

*Demostración.* Sea  $m = \lfloor n/2 \rfloor$  y consideremos el polinomio de prueba

$$p(x) = (1 - x^2)^m = \sum_{k=0}^m (-1)^k \binom{m}{k} x^{2k} \in \mathcal{P}_n,$$

que tiene grado  $2m \leq n$ . Su vector de coeficientes en la base monomial es  $a \in \mathbb{R}^{n+1}$  con  $a_{2k} = (-1)^k \binom{m}{k}$  para  $k = 0, \dots, m$  y las restantes componentes nulas.

**Cota inferior de  $\|a\|_2$ .** Por la identidad de Vandermonde–Chu,

$$\|a\|_2^2 = \sum_{k=0}^m \binom{m}{k}^2 = \binom{2m}{m}.$$

Como  $\binom{2m}{m}$  es el mayor de los  $2m + 1$  sumandos de  $\sum_{k=0}^{2m} \binom{2m}{k} = 4^m$ ,

$$\binom{2m}{m} \geq \frac{4^m}{2m+1}.$$

**Cota superior de  $\|Va\|_2$ .** Para todo  $x \in [-1, 1]$  se tiene  $0 \leq 1 - x^2 \leq 1$ , de modo que  $(1 - x_i^2)^{2m} \leq 1$ . Sumando sobre los  $n + 1$  nodos:

$$\|Va\|_2^2 = \sum_{i=0}^n (1 - x_i^2)^{2m} \leq n + 1.$$

**Cota de  $\sigma_{\min}(V)$ .** Aplicando la caracterización variacional del Lema 2.26:

$$\sigma_{\min}^2(V) \leq \frac{\|Va\|_2^2}{\|a\|_2^2} \leq \frac{n+1}{\binom{2m}{m}} \leq \frac{(n+1)(2m+1)}{4^m}.$$

**Cota inferior de  $\sigma_{\max}(V)$ .** La primera columna de  $V$  es el vector  $(1, \dots, 1)^T \in \mathbb{R}^{n+1}$ , así que

$$\sigma_{\max}(V) \geq \|Ve_1\|_2 = \sqrt{n+1}.$$

**Conclusión.** Combinando ambas cotas y usando  $2m+1 \leq n+1$ :

$$\kappa_2(V) = \frac{\sigma_{\max}(V)}{\sigma_{\min}(V)} \geq \frac{\sqrt{n+1} \cdot 2^m}{\sqrt{(n+1)(2m+1)}} = \frac{2^m}{\sqrt{2m+1}} \geq \frac{2^{\lfloor n/2 \rfloor}}{\sqrt{n+1}}. \quad \square$$

### 3.1.2 La base de Lagrange

El mal condicionamiento de la matriz de Vandermonde no implica que no existan formas estables de calcular el interpolante. En efecto, un método consiste en utilizar la **base de Lagrange**, que diagonaliza el operador  $\Phi$ .

**Definición 3.5** (Polinomios base de Lagrange). *Dados nodos distintos  $x_0, \dots, x_n \in \mathbb{F}$ , definimos*

$$\ell_k(x) = \prod_{\substack{j=0 \\ j \neq k}}^n \frac{x - x_j}{x_k - x_j}, \quad k = 0, \dots, n.$$

**Teorema 3.6** (Propiedades de la base de Lagrange). *Los polinomios  $\ell_0, \dots, \ell_n$  forman una base de  $\mathcal{P}_n$  y satisfacen:*

1. **Propiedad de Kronecker:**  $\ell_k(x_j) = \delta_{kj}$ .
2. **Partición de la unidad:**  $\sum_{k=0}^n \ell_k(x) = 1$  para todo  $x$ .

El polinomio interpolante es  $p(x) = \sum_{k=0}^n y_k \ell_k(x)$ .

*Demostración.* La propiedad de Kronecker se verifica directamente de la definición. En la base de Lagrange, la representación matricial de  $\Phi$  es la identidad:  $\Phi(\ell_k) = e_k$ . Como  $\Phi$  es un isomorfismo (Teorema 3.3),  $\{\ell_0, \dots, \ell_n\}$  es base de  $\mathcal{P}_n$ .

Para la partición de la unidad, observamos que  $q(x) = \sum_{k=0}^n \ell_k(x)$  pertenece a  $\mathcal{P}_n$  y satisface  $q(x_j) = \sum_k \delta_{kj} = 1$  para todo  $j$ . Como el polinomio constante 1 también interpola esos datos, la unicidad del interpolante da  $q \equiv 1$ .  $\square$

### 3.1.3 La forma baricéntrica

Definimos los **pesos baricéntricos**

$$w_k = \frac{1}{\prod_{j \neq k} (x_k - x_j)}, \quad k = 0, \dots, n,$$

de modo que  $\ell_k(x) = w_k \omega_{n+1}(x)/(x - x_k)$  donde  $\omega_{n+1}(x) = \prod_{j=0}^n (x - x_j)$ . Sustituyendo en la fórmula del interpolante y dividiendo por  $1 = \sum_k \ell_k(x)$ :

**Teorema 3.7** (Forma baricéntrica). *Para  $x \neq x_k$ , el polinomio interpolante se escribe*

$$p(x) = \frac{\sum_{k=0}^n \frac{w_k}{x - x_k} y_k}{\sum_{k=0}^n \frac{w_k}{x - x_k}}.$$



## 3.2 Interpolación sobre $\mathbb{R}$

Cuando los nodos y los datos son reales, podemos estimar cuánto difiere el interpolante de la función original. Un resultado elemental expresa  $f(x) - p_n(x)$  en términos de la derivada de orden  $n + 1$  de  $f$ . Un estudio más profundo del error se realizará en el Capítulo 4.

### 3.2.1 Error de interpolación

**Teorema 3.8** (Error de interpolación polinomial). *Sea  $f \in C^{(n+1)}([a, b])$  y  $p_n \in \mathcal{P}_n$  el polinomio que interpola a  $f$  en  $n + 1$  nodos distintos  $x_0, \dots, x_n \in [a, b]$ . Entonces, para todo  $x \in [a, b]$  existe  $\xi = \xi(x) \in (a, b)$  tal que*

$$f(x) - p_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x), \quad \omega_{n+1}(x) = \prod_{i=0}^n (x - x_i). \quad (3.1)$$

En particular,  $\|f - p_n\|_\infty \leq \frac{\|f^{(n+1)}\|_\infty}{(n+1)!} \|\omega_{n+1}\|_\infty$ .

*Demostración.* Si  $x$  coincide con algún nodo, ambos lados de (3.1) valen cero. Fijemos  $x \neq x_j$  para todo  $j$  y definamos

$$g(t) = f(t) - p_n(t) - \frac{f(x) - p_n(x)}{\omega_{n+1}(x)} \omega_{n+1}(t).$$

La función  $g \in C^{(n+1)}([a, b])$  tiene al menos  $n + 2$  ceros: los  $n + 1$  nodos  $x_0, \dots, x_n$  y el punto  $x$ . Por el teorema de Rolle aplicado sucesivamente,  $g^{(n+1)}$  tiene al menos un cero  $\xi \in (a, b)$ . Como  $p_n^{(n+1)} \equiv 0$  y  $\omega_{n+1}^{(n+1)} = (n+1)!$ :

$$0 = g^{(n+1)}(\xi) = f^{(n+1)}(\xi) - \frac{f(x) - p_n(x)}{\omega_{n+1}(x)} (n+1)!.$$

Despejando se obtiene (3.1). □

**Observación 3.9** (Rol del polinomio nodal  $\omega_{n+1}$ ). *La fórmula (3.1) separa dos contribuciones al error:*

1.  $f^{(n+1)}(\xi)/(n+1)!$ : depende de la **suavidad** de  $f$ .
2.  $\omega_{n+1}(x) = \prod (x - x_i)$ : depende de la **distribución de los nodos**. Los nodos que minimizan  $\|\omega_{n+1}\|_\infty$  en  $[-1, 1]$  son los **nodos de Chebyshev**  $x_j = \cos\left(\frac{(2j+1)\pi}{2(n+1)}\right)$ , que estudiaremos en el Capítulo 4.

Para nodos equiespaciados,  $\|\omega_{n+1}\|_\infty$  crece factorialmente con  $n$ , lo que explica el **fenómeno de Runge**: la interpolación equiespaciada puede diverger aunque  $f$  sea analítica.

**Ejemplo 3.10** (Error de la interpolación lineal). *Sea  $f \in C^2([a, a+h])$  y  $p_1 \in \mathcal{P}_1$  el polinomio que interpola  $f$  en los extremos  $x_0 = a$  y  $x_1 = a+h$ . Aplicamos el Teorema 3.8 con  $n = 1$ : para todo  $x \in [a, a+h]$  existe  $\xi \in (a, a+h)$  tal que*

$$f(x) - p_1(x) = \frac{f''(\xi)}{2} (x - a)(x - (a + h)).$$

Para acotar  $|\omega_2(x)| = |(x-a)(x-(a+h))|$  en  $[a, a+h]$ , hacemos  $t = x - a \in [0, h]$ :

$$|t(t-h)| = t(h-t) \leq \frac{h^2}{4},$$

pues el máximo de  $t(h-t)$  se alcanza en  $t = h/2$ . Por lo tanto

$$\|f - p_1\|_{\infty, [a, a+h]} \leq \frac{h^2}{8} \|f''\|_{\infty, [a, a+h]}.$$

El error de la interpolación lineal es  $O(h^2)$ , con constante proporcional a  $\|f''\|_{\infty}$ .

**Ejemplo 3.11** (Error de la derivada del interpolante lineal). Con las mismas hipótesis del Ejemplo 3.10, queremos aproximar derivadas a partir de  $p_1$ . Como  $p_1$  es afín,

$$p'_1(x) = \frac{f(a+h) - f(a)}{h} \quad (\text{constante en } [a, a+h]).$$

Es decir, la derivada del interpolante coincide con la **diferencia finita progresiva**

$$D_h^+ f(a) := \frac{f(a+h) - f(a)}{h}.$$

Demostramos ahora una cota del error usando Taylor. Si  $f \in C^2([a, a+h])$ , por Taylor de orden 1 en  $a$  con resto de Lagrange existe  $\xi \in (a, a+h)$  tal que

$$f(a+h) = f(a) + hf'(a) + \frac{h^2}{2} f''(\xi).$$

Dividiendo por  $h$  y restando  $f'(a)$ :

$$D_h^+ f(a) - f'(a) = \frac{h}{2} f''(\xi).$$

Por lo tanto,

$$|f'(a) - p'_1| = |f'(a) - D_h^+ f(a)| \leq \frac{h}{2} \|f''\|_{\infty, [a, a+h]}.$$

Esta es una cota del error de la diferencia finita progresiva en  $x = a$ : error  $O(h)$ .

Para obtener una cota para cualquier  $x \in [a, a+h]$ ,

$$|f'(x) - p'_1| \leq |f'(x) - f'(a)| + |f'(a) - p'_1| \leq (x-a) \|f''\|_{\infty} + \frac{h}{2} \|f''\|_{\infty} \leq \frac{3}{2} h \|f''\|_{\infty},$$

y en consecuencia

$$\|f' - p'_1\|_{\infty, [a, a+h]} \leq \frac{3}{2} h \|f''\|_{\infty, [a, a+h]} = O(h).$$

Se ve así que, al derivar el interpolante lineal, se pierde un orden respecto del error  $O(h^2)$  de la interpolación de  $f$ .

### 3.2.2 Cuadratura interpolatoria

La interpolación polinomial tiene una aplicación directa e importante: la integración numérica (o **cuadratura**). La idea es sencilla: si queremos aproximar la integral  $\int_a^b f(x) dx$  y no conocemos una primitiva de  $f$ , podemos reemplazar  $f$  por su polinomio interpolante  $p$  (que sí sabemos integrar explícitamente) y aproximar:

$$\int_a^b f(x) dx \approx \int_a^b p(x) dx.$$

Eligiendo distintos grados de interpolación y distintos nodos se obtienen las clásicas **fórmulas de Newton-Cotes**. En esta sección desarrollamos las dos más fundamentales —la regla del trapecio y la regla de Simpson— y analizamos sus errores.

Antes de deducir fórmulas particulares, escribimos la cuadratura interpolatoria en forma general.

**Proposición 3.12** (Pesos de la cuadratura interpolatoria). *Sean  $a = x_0 < \dots < x_k = b$  nodos en  $[a, b]$ , y sea*

$$p_k(x) = \sum_{i=0}^k f(x_i) \ell_i(x)$$

*el interpolante de Lagrange de grado  $k$ , donde  $\ell_i$  son los polinomios de la base de Lagrange. Entonces*

$$Q_k(f) := \int_a^b p_k(x) dx = \sum_{i=0}^k w_i f(x_i), \quad w_i := \int_a^b \ell_i(x) dx.$$

*Es decir, los **pesos** de la cuadratura interpolatoria son las integrales de los polinomios base de Lagrange.*

*Demostración.* Por linealidad de la integral,

$$\int_a^b p_k(x) dx = \int_a^b \sum_{i=0}^k f(x_i) \ell_i(x) dx = \sum_{i=0}^k f(x_i) \int_a^b \ell_i(x) dx = \sum_{i=0}^k w_i f(x_i).$$

□

#### La regla del trapecio

Aplicamos la Proposición 3.12 al caso  $k = 1$  con nodos  $x_0 = a$ ,  $x_1 = b$ . Los polinomios base son

$$\ell_0(x) = \frac{x-b}{a-b} = \frac{b-x}{b-a}, \quad \ell_1(x) = \frac{x-a}{b-a}.$$

Sus pesos resultan

$$w_0 = \int_a^b \ell_0(x) dx = \frac{1}{b-a} \int_a^b (b-x) dx = \frac{b-a}{2},$$
$$w_1 = \int_a^b \ell_1(x) dx = \frac{1}{b-a} \int_a^b (x-a) dx = \frac{b-a}{2}.$$

Por lo tanto,

$$Q_1(f) = w_0 f(a) + w_1 f(b) = \frac{b-a}{2} (f(a) + f(b)),$$

que es la **regla del trapecio**.

**Definición 3.13** (Regla del trapecio). *La **regla del trapecio** (simple) es*

$$T(f; a, b) := \frac{b-a}{2} (f(a) + f(b)).$$

**Teorema 3.14** (Error de la regla del trapecio). *Si  $f \in C^2([a, b])$ , existe  $\eta \in (a, b)$  tal que*

$$\int_a^b f(x) dx - T(f; a, b) = -\frac{(b-a)^3}{12} f''(\eta).$$

*Demostración.* Sea  $p_1$  el interpolante lineal de  $f$  en  $\{a, b\}$ . Como  $\int_a^b p_1 = T(f; a, b)$ , el error de cuadratura es  $\int_a^b (f - p_1)$ . Por el Teorema 3.8 con  $n = 1$ :

$$f(x) - p_1(x) = \frac{f''(\xi(x))}{2} (x-a)(x-b).$$

Como  $(x-a)(x-b) \leq 0$  en  $[a, b]$ , el teorema del valor medio para integrales (Teorema A.6, con  $g = f'' \circ \xi$  y  $\varphi(x) = (x-a)(x-b)/2$ ) da un  $\eta \in (a, b)$  con

$$\int_a^b \frac{f''(\xi(x))}{2} (x-a)(x-b) dx = \frac{f''(\eta)}{2} \int_a^b (x-a)(x-b) dx.$$

El cambio  $t = x - a$  da  $\int_0^h t(t-h) dt = -h^3/6$  con  $h = b - a$ , de donde el resultado.  $\square$

## Regla de Simpson

Si en lugar de interpolar linealmente usamos una parábola (polinomio de grado 2), obtenemos una fórmula más precisa. Tomamos tres nodos equiespaciados:  $x_0 = a$ ,  $x_1 = (a+b)/2$ ,  $x_2 = b$ . El polinomio de Lagrange de grado 2 que pasa por  $(x_0, f(x_0))$ ,  $(x_1, f(x_1))$ ,  $(x_2, f(x_2))$  se puede integrar directamente. Haciendo el cambio  $t = x - x_1$  (que centra el intervalo en el origen) e integrando los polinomios de Lagrange, se obtiene:

Esta elección no es arbitraria: la geometría regular de estos puntos sobre el círculo unitario dota al problema de interpolación de una estructura algebraica excepcional. La matriz de Vandermonde asociada se convierte, salvo un factor de escala, en una matriz unitaria. Esto significa que el problema de interpolación (y su inverso, la evaluación) se vuelve numéricamente muy estable y computacionalmente muy eficiente.

Este caso específico de interpolación es lo que conocemos como la **Transformada Discreta de Fourier (DFT)**.

### 3.2.3 Las raíces de la unidad como nodos de interpolación

**Definición 3.15** (Raíces  $n$ -ésimas de la unidad). Sea  $n \geq 1$  un entero. Las **raíces  $n$ -ésimas de la unidad** son las soluciones de la ecuación  $z^n = 1$  en  $\mathbb{C}$ :

$$\omega_n^k = e^{2\pi i k/n}, \quad k = 0, 1, \dots, n-1.$$

**Notación:** Cuando  $n$  está claro del contexto, escribimos simplemente  $\omega = \omega_n = e^{2\pi i/n}$ . Con esta notación, las raíces  $n$ -ésimas de la unidad son:  $\{1, \omega, \omega^2, \dots, \omega^{n-1}\}$ .

Ahora consideremos un polinomio sobre los complejos cualquiera

$$p(z) = \sum_{k=0}^{n-1} c_k z^k \quad (3.2)$$

Cuando tratamos el problema de interpolación, empezamos evaluando un polinomio en los nodos de interpolación, que en este caso son las raíces de la unidad. La evaluación de  $p$  en la raíz  $\omega^j$  se expresa como:

$$p(\omega^j) = \sum_{k=0}^{n-1} c_k (\omega^j)^k = \sum_{k=0}^{n-1} c_k \omega^{jk} = \sum_{k=0}^{n-1} c_k e^{2\pi i jk/n}. \quad (3.3)$$

A partir de aquí, podemos definir la **Transformada Discreta de Fourier (DFT)** como la evaluación de un polinomio en las raíces de la unidad. La definición usual de la DFT se presenta a continuación, pero es importante destacar que esta definición es una instancia particular de la interpolación polinomial en  $\mathbb{C}$  con nodos en las raíces de la unidad.

**Definición 3.16** (Transformada Discreta de Fourier (DFT)). Dado  $x \in \mathbb{C}^N$ , definimos su DFT como  $\hat{x} \in \mathbb{C}^N$  con

$$\hat{x}_j = \sum_{k=0}^{N-1} x_k \omega_N^{jk}, \quad j = 0, \dots, N-1, \quad \text{donde } \omega_N = e^{2\pi i/N}.$$

### 3.2.4 Matriz de Vandermonde y la transformada inversa (IDFT)

Como la DFT es evaluar un polinomio en las raíces de la unidad, podemos representarla mediante una matriz de Vandermonde.

**Observación 3.17** (Propiedades básicas de las raíces de la unidad). Sea  $\omega = e^{2\pi i/n}$  una raíz  $n$ -ésima primitiva de la unidad. Vale la pena recordar:

1.  $\omega^n = 1$  (por definición,  $\omega$  es raíz  $n$ -ésima de la unidad).
2.  $\omega^{jk} = (\omega^j)^k = (\omega^k)^j$  (exponentes conmutan).
3. Suma geométrica de raíces: Para cualquier  $\ell \in \mathbb{Z}$ ,

$$\sum_{j=0}^{n-1} \omega^{j\ell} = \begin{cases} n & \text{si } \ell \equiv 0 \pmod{n}, \\ 0 & \text{si } \ell \not\equiv 0 \pmod{n}. \end{cases}$$

En el segundo caso, la suma es una serie geométrica con razón  $r = \omega^\ell \neq 1$ :  $\sum_{j=0}^{n-1} r^j = \frac{r^n - 1}{r - 1} = \frac{\omega^{n\ell} - 1}{\omega^\ell - 1} = \frac{1 - 1}{\omega^\ell - 1} = 0$ .

**Definición 3.18** (Matriz DFT como Vandermonde). *La matriz de Vandermonde evaluada en las raíces  $n$ -ésimas de la unidad es:*

$$F_n = \begin{pmatrix} 1 & 1 & 1 & \cdots & 1 \\ 1 & \omega & \omega^2 & \cdots & \omega^{n-1} \\ 1 & \omega^2 & \omega^4 & \cdots & \omega^{2(n-1)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \omega^{n-1} & \omega^{2(n-1)} & \cdots & \omega^{(n-1)(n-1)} \end{pmatrix}.$$

*Elemento  $(j, k)$ :  $[F_n]_{jk} = \omega^{jk}$  para  $j, k = 0, 1, \dots, n-1$ .*

Una propiedad extraordinaria de  $F_n$  es que sus columnas son los **modos de Fourier discretos** y son mutuamente ortogonales.

**Lema 3.19** (Ortogonalidad de las columnas de  $F_n$ ). *La  $k$ -ésima columna de  $F_n$  es el modo de Fourier discreto*

$$\mathbf{v}_k = (1, \omega^k, \omega^{2k}, \dots, \omega^{(n-1)k})^T \in \mathbb{C}^n, \quad k = 0, \dots, n-1.$$

*Estos vectores son mutuamente ortogonales:*

$$\langle \mathbf{v}_k, \mathbf{v}_\ell \rangle = n \delta_{k\ell}.$$

*En particular,  $\|\mathbf{v}_k\| = \sqrt{n}$ , y los vectores normalizados  $\mathbf{u}_k = \frac{1}{\sqrt{n}}\mathbf{v}_k$  forman una base ortonormal (BON) de  $\mathbb{C}^n$ .*

*Demostración.* Calculamos el producto interior:

$$\langle \mathbf{v}_k, \mathbf{v}_\ell \rangle = \sum_{j=0}^{n-1} \omega^{jk} \overline{\omega^{j\ell}} = \sum_{j=0}^{n-1} \omega^{jk} \omega^{-j\ell} = \sum_{j=0}^{n-1} \omega^{j(k-\ell)}.$$

Si  $k = \ell$ , cada término vale 1, luego la suma es  $n$ . Si  $k \neq \ell$ , sea  $r = \omega^{k-\ell} \neq 1$ ; como  $r$  es una raíz  $n$ -ésima de la unidad ( $r^n = 1$ ), la fórmula de la suma geométrica da

$$\sum_{j=0}^{n-1} r^j = \frac{r^n - 1}{r - 1} = \frac{1 - 1}{r - 1} = 0.$$

Por tanto  $\langle \mathbf{v}_k, \mathbf{v}_\ell \rangle = n \delta_{k\ell}$ . Como hay  $n$  vectores no nulos ortogonales entre sí en  $\mathbb{C}^n$ , son linealmente independientes y forman una base; normalizados,  $\{\mathbf{u}_k\}$  es una BON.  $\square$

**Teorema 3.20** (Unitariedad de  $F_n$ ). *La matriz  $F_n$  satisface  $F_n^* F_n = n I_n$ . Equivalentemente,  $\frac{1}{\sqrt{n}} F_n$  es unitaria.*

*Demostración.* El elemento  $(k, \ell)$  de  $F_n^* F_n$  es  $\langle \mathbf{v}_k, \mathbf{v}_\ell \rangle$ , donde  $\mathbf{v}_k$  es la  $k$ -ésima columna de  $F_n$ . Por el Lema 3.19,  $[F_n^* F_n]_{k\ell} = n \delta_{k\ell}$ , es decir,  $F_n^* F_n = n I_n$ .  $\square$

**Corolario 3.21** (Inversa de la DFT). *La matriz inversa de  $F_n$  es:*

$$F_n^{-1} = \frac{1}{n} F_n^*.$$

*Explícitamente,  $[F_n^{-1}]_{jk} = \frac{1}{n} \omega^{-jk}$ .*

Con lo cual, la **DFT inversa (IDFT)** es:

$$\mathbf{x} = F_n^{-1} \mathbf{X} = \frac{1}{n} F_n^* \mathbf{X}, \quad \text{es decir, } x_j = \frac{1}{n} \sum_{k=0}^{n-1} \hat{x}_k \omega^{-jk}.$$

**Observación 3.22** (Convenciones de normalización). *Diferentes textos usan distintas convenciones:*

- **Convención asimétrica** (usada aquí y en numpy): Factor  $1/n$  solo en la inversa.
- **Convención simétrica**: Factor  $1/\sqrt{n}$  en ambas direcciones (hace a  $F_n/\sqrt{n}$  unitaria).
- **Convención de ingeniería**: A veces se usa  $\omega = e^{-2\pi i/n}$  (signo opuesto).

*Lo importante es la relación  $F_n^{-1} = \frac{1}{n} F_n^*$ , que es invariante.*

**Observación 3.23** (Lectura en términos de DFT). *Con la convención asimétrica usada aquí ( $\mathbf{X} = F_n \mathbf{x}$ ), la DFT difiere del operador de cambio a coordenadas ortonormales por normalización (y conjugación de fase, según convención de signo). En particular, la versión unitaria*

$$\tilde{\mathbf{X}} := \frac{1}{\sqrt{n}} F_n^* \mathbf{x} = U^* \mathbf{x}$$

*es exactamente el cambio de base de la base canónica a la BON de modos de Fourier.*

### 3.2.5 Transformada Rápida de Fourier (FFT)

El cálculo directo de  $\mathbf{X} = F_n \mathbf{x}$  requiere  $O(n^2)$  operaciones (producto matriz-vector). La **\*\*FFT\*\*** (Cooley-Tukey, 1965) reduce esto a  $O(n \log n)$  mediante factorización recursiva.

**Idea clave:** Explotar la estructura de  $F_n$  para descomponer la DFT de tamaño  $n$  en dos DFTs de tamaño  $n/2$  (asumiendo  $n$  par).

**Teorema 3.24** (Algoritmo FFT (Cooley-Tukey radix-2)). *Supongamos  $n = 2m$  (par). Separamos la secuencia  $\mathbf{x}$  en índices pares e impares:*

$$\mathbf{x}_{par} = (x_0, x_2, x_4, \dots, x_{n-2}), \quad \mathbf{x}_{impar} = (x_1, x_3, x_5, \dots, x_{n-1}).$$

*Sea  $X_k = \sum_{j=0}^{n-1} x_j \omega_n^{jk}$ . Separando en pares e impares:*

$$\begin{aligned} X_k &= \sum_{j=0}^{m-1} x_{2j} \omega_n^{2jk} + \sum_{j=0}^{m-1} x_{2j+1} \omega_n^{(2j+1)k} \\ &= \sum_{j=0}^{m-1} x_{2j} (\omega_n^2)^{jk} + \omega_n^k \sum_{j=0}^{m-1} x_{2j+1} (\omega_n^2)^{jk}. \end{aligned}$$

Observando que  $\omega_n^2 = e^{4\pi i/n} = e^{2\pi i/m} = \omega_m$ :

$$X_k = E_k + \omega_n^k O_k,$$

donde:

- $E_k = \sum_{j=0}^{m-1} x_{2j} \omega_m^{jk}$  es la DFT de tamaño  $m$  de  $\mathbf{x}_{par}$ .
- $O_k = \sum_{j=0}^{m-1} x_{2j+1} \omega_m^{jk}$  es la DFT de tamaño  $m$  de  $\mathbf{x}_{impar}$ .

Para completar los  $n$  coeficientes, no alcanza con  $k = 0, \dots, m-1$ : también necesitamos  $X_{k+m}$ . La clave es que  $E_k$  y  $O_k$  son DFTs de tamaño  $m$ , por lo que son periódicas módulo  $m$ :

$$E_{k+m} = \sum_{j=0}^{m-1} x_{2j} \omega_m^{j(k+m)} = \sum_{j=0}^{m-1} x_{2j} \omega_m^{jk} (\omega_m^m)^j = \sum_{j=0}^{m-1} x_{2j} \omega_m^{jk} = E_k,$$

y análogamente  $O_{k+m} = O_k$ , porque  $\omega_m^m = e^{2\pi i} = 1$ .

Además,

$$\omega_n^{k+m} = \omega_n^k \omega_n^m = \omega_n^k e^{\pi i} = -\omega_n^k,$$

ya que  $n = 2m$ .

Entonces, para  $k = 0, \dots, m-1$ :

$$\begin{cases} X_k = E_k + \omega_n^k O_k, & k = 0, \dots, m-1, \\ X_{k+m} = E_k - \omega_n^k O_k, & k = 0, \dots, m-1. \end{cases}$$

Este es el paso de **combinación** (butterfly): cada par  $(E_k, O_k)$  produce dos salidas  $(X_k, X_{k+m})$ .

En forma algorítmica, la FFT radix-2 termina así:

1. Si  $n = 1$ , devolver el único valor (caso base).
2. Si  $n > 1$ , calcular recursivamente las DFT de tamaño  $m = n/2$  de las partes par e impar para obtener  $E_k$  y  $O_k$ .
3. Para  $k = 0, \dots, m-1$ , formar

$$X_k = E_k + \omega_n^k O_k, \quad X_{k+m} = E_k - \omega_n^k O_k.$$

4. Devolver el vector completo  $\mathbf{X} = (X_0, \dots, X_{n-1})$ .

**Análisis de complejidad:** Sea  $T(n)$  el tiempo para calcular una DFT de tamaño  $n$ . El algoritmo FFT satisface:

$$T(n) = 2T(n/2) + O(n),$$

pues calcula dos DFTs de tamaño  $n/2$  más  $O(n)$  sumas/multiplicaciones. Por el Teorema Maestro:

$$T(n) = O(n \log n).$$

Para  $n = 2^{10} = 1024$ :



- DFT directa:  $\sim n^2 = 10^6$  operaciones.
- FFT:  $\sim n \log_2 n = 1024 \cdot 10 \approx 10^4$  operaciones.

¡Aceleración de 100x!

**Implementación:** En Python, usar `numpy.fft.fft(x)` y `numpy.fft.ifft(X)`. Ver el archivo `interpolacion_algebraica.py` para una implementación didáctica de DFT vía Vandermonde (sin FFT,  $O(n^2)$ ) y comparación con `numpy.fft`.

### 3.2.6 Criterio de Nyquist-Shannon y aliasing

Una vez que la señal se representa mediante coeficientes de Fourier, aparece una pregunta central: ¿cuántas muestras hacen falta para reconstruirla de manera unívoca a partir de su DFT?

Sea  $x : [0, T] \rightarrow \mathbb{C}$  una señal periódica de período  $T$  con expansión finita

$$x(t) = \sum_{k=-M}^M c_k e^{2\pi i k t / T},$$

de modo que la frecuencia máxima presente es  $f_{\max} = M/T$ .

Si muestreamos en  $N$  puntos equiespaciados

$$t_j = \frac{j}{f_s}, \quad j = 0, \dots, N-1, \quad f_s = \frac{N}{T},$$

entonces

$$x(t_j) = \sum_{k=-M}^M c_k e^{2\pi i k j / N}.$$

La estructura discreta implica periodicidad en frecuencia módulo  $N$ :

$$e^{2\pi i (k+\ell N) j / N} = e^{2\pi i k j / N} e^{2\pi i \ell j} = e^{2\pi i k j / N},$$

para todo  $\ell \in \mathbb{Z}$ . Por lo tanto, los modos  $k$  y  $k + \ell N$  son indistinguibles en los datos muestreados. Este fenómeno se llama **aliasing**.

Para evitar colisiones entre índices en el rango  $\{-M, \dots, M\}$ , debe cumplirse

$$N > 2M,$$

equivalentemente,

$$\boxed{f_s > 2f_{\max}}.$$

Esta es la condición del **teorema de muestreo de Nyquist-Shannon**. El valor  $f_s/2$  se denomina **frecuencia de Nyquist**.

**Observación 3.25** (Lectura práctica). Si  $f_s \leq 2f_{\max}$ , la reconstrucción espectral por DFT no es unívoca porque distintas señales pueden producir exactamente las mismas muestras. En aplicaciones, esto se evita con dos ideas complementarias:

- filtrar altas frecuencias antes de muestrear (filtro antialiasing),
- elegir una tasa de muestreo con margen por encima de  $2f_{\max}$ .

Por ejemplo, en audio digital se usa típicamente 44.1 kHz para señales cuyo contenido útil está por debajo de 20 kHz.

### 3.2.7 Convolución discreta

Una de las aplicaciones más poderosas de la DFT y, por extensión, de la FFT, es el **Teorema de Convolución**. Este teorema establece que la convolución circular de dos secuencias en el dominio del tiempo se convierte en una simple multiplicación punto a punto de sus DFT en el dominio de la frecuencia.

Si  $x[n]$  y  $y[n]$  son dos secuencias finitas de longitud  $N + 1$ , su convolución circular  $z[n] = (x * y)[n]$  está definida como:

$$z[n] = \sum_{m=0}^N x[m]y[(n - m) \bmod (N + 1)]$$

para  $n = 0, 1, \dots, N$ .

El Teorema de Convolución Discreta nos dice que:

$$\text{DFT}\{x[n] * y[n]\} = \text{DFT}\{x[n]\} \cdot \text{DFT}\{y[n]\}$$

O, en notación de Fourier:

$$Z[k] = X[k] \cdot Y[k]$$

Donde  $X[k]$ ,  $Y[k]$  y  $Z[k]$  son las DFT de  $x[n]$ ,  $y[n]$  y  $z[n]$  respectivamente.

El Teorema de Convolución Discreta establece que la Transformada Discreta de Fourier (DFT) de la convolución circular de dos secuencias es igual al producto punto a punto de las DFT de cada secuencia.

**Paso 1: Aplicar la DFT a la Convolución** Queremos calcular la DFT de  $z[n]$ , es decir,  $Z[k]$ :

$$Z[k] = \sum_{n=0}^N z[n]e^{-j\frac{2\pi}{N+1}kn}$$

Sustituimos la definición de  $z[n]$ :

$$Z[k] = \sum_{n=0}^N \left( \sum_{m=0}^N x[m]y[(n - m) \bmod (N + 1)] \right) e^{-j\frac{2\pi}{N+1}kn}$$

Intercambiamos el orden de las sumatorias:

$$Z[k] = \sum_{m=0}^N x[m] \sum_{n=0}^N y[(n - m) \bmod (N + 1)] e^{-j\frac{2\pi}{N+1}kn}$$

**Paso 2: Cambio de Variable** Hacemos un cambio de variable en la sumatoria interna. Sea  $p = (n - m) \bmod (N + 1)$ . Cuando  $n$  recorre de 0 a  $N$ ,  $p$  también recorrerá de 0 a  $N$ . De  $p = (n - m) \bmod (N + 1)$ , podemos expresar  $n = (p + m) \bmod (N + 1)$ .

Sustituimos esto en el término exponencial:

$$e^{-j\frac{2\pi}{N+1}kn} = e^{-j\frac{2\pi}{N+1}k(p+m)} = e^{-j\frac{2\pi}{N+1}kp} e^{-j\frac{2\pi}{N+1}km}$$

Ahora, la sumatoria interna se convierte en:

$$\sum_{p=0}^N y[p] e^{-j \frac{2\pi}{N+1} k(p+m)} = \sum_{p=0}^N y[p] e^{-j \frac{2\pi}{N+1} kp} e^{-j \frac{2\pi}{N+1} km}$$

Notamos que  $e^{-j \frac{2\pi}{N+1} km}$  no depende de  $p$ , por lo que puede salir de esta sumatoria:

$$e^{-j \frac{2\pi}{N+1} km} \sum_{p=0}^N y[p] e^{-j \frac{2\pi}{N+1} kp}$$

La sumatoria restante es, por definición, la **DFT de  $y[n]$** , es decir,  $Y[k]$ :

$$e^{-j \frac{2\pi}{N+1} km} Y[k]$$

**Paso 3: Reagrupar los Términos** Sustituimos este resultado de nuevo en la expresión de  $Z[k]$ :

$$Z[k] = \sum_{m=0}^N x[m] \left( Y[k] e^{-j \frac{2\pi}{N+1} km} \right)$$

Como  $Y[k]$  no depende de  $m$ , puede salir de la sumatoria externa:

$$Z[k] = Y[k] \sum_{m=0}^N x[m] e^{-j \frac{2\pi}{N+1} km}$$

Y la sumatoria restante es, por definición, la **DFT de  $x[n]$** , es decir,  $X[k]$ :

$$Z[k] = Y[k] \cdot X[k]$$

El teorema de convolución tiene numerosas aplicaciones prácticas en procesamiento de señales, resolución de ecuaciones y simulación numérica. A continuación presentamos algunas de las más importantes.

### 3.2.8 Filtrado digital de señales

El filtrado de señales es una de las aplicaciones más directas del teorema de convolución. Un **filtro digital** se representa mediante una secuencia  $h[n]$  llamada *respuesta al impulso* del filtro. La señal de salida  $y[n]$  se obtiene convolucionando la señal de entrada  $x[n]$  con  $h[n]$ :

$$y[n] = (h * x)[n] = \sum_{m=0}^N h[m] x[(n - m) \bmod (N + 1)].$$

Calcular esta convolución directamente requiere  $O(N^2)$  operaciones. Sin embargo, usando el teorema de convolución y la FFT, podemos reducir la complejidad a  $O(N \log N)$ :

### Algoritmo de filtrado rápido vía FFT:

1. Calcular  $H[k] = \text{FFT}\{h[n]\}$  (complejidad  $O(N \log N)$ ).
2. Calcular  $X[k] = \text{FFT}\{x[n]\}$  (complejidad  $O(N \log N)$ ).
3. Calcular  $Y[k] = H[k] \cdot X[k]$  (multiplicación punto a punto, complejidad  $O(N)$ ).
4. Calcular  $y[n] = \text{IFFT}\{Y[k]\}$  (complejidad  $O(N \log N)$ ).

El costo total es  $O(N \log N)$ , mucho menor que el método directo para  $N$  grande.

**Ejemplo 3.26** (Filtro pasa-bajos). *Un filtro pasa-bajos ideal tiene respuesta en frecuencia:*

$$H[k] = \begin{cases} 1 & \text{si } |k| \leq k_c \\ 0 & \text{si } |k| > k_c \end{cases}$$

donde  $k_c$  es la frecuencia de corte. Este filtro elimina las componentes de alta frecuencia de la señal, dejando solo las frecuencias bajas (hasta  $k_c$ ). En la práctica, se suele usar filtros con transiciones suaves en lugar de este corte abrupto para evitar el fenómeno de Gibbs.

### 3.2.9 Multiplicación rápida de polinomios

Sean  $p(x) = \sum_{k=0}^N p_k x^k$  y  $q(x) = \sum_{k=0}^N q_k x^k$  dos polinomios de grado a lo sumo  $N$ . Su producto  $r(x) = p(x)q(x)$  es un polinomio de grado a lo sumo  $2N$ :

$$r(x) = \sum_{k=0}^{2N} r_k x^k, \quad r_k = \sum_{j=0}^k p_j q_{k-j}.$$

Observemos que los coeficientes  $r_k$  son precisamente la **convolución lineal** (no circular) de las secuencias  $\{p_k\}$  y  $\{q_k\}$ . Para calcular la convolución lineal usando FFT, debemos trabajar con convolución circular de longitud suficiente para evitar el *aliasing circular*:

### Algoritmo de multiplicación rápida:

1. Extender ambas secuencias con ceros hasta longitud  $M \geq 2N + 1$  (típicamente  $M = 2^{\lceil \log_2(2N+1) \rceil}$  para eficiencia de FFT).
2. Calcular  $P[k] = \text{FFT}\{p_0, \dots, p_N, 0, \dots, 0\}$  (longitud  $M$ ).
3. Calcular  $Q[k] = \text{FFT}\{q_0, \dots, q_N, 0, \dots, 0\}$  (longitud  $M$ ).
4. Calcular  $R[k] = P[k] \cdot Q[k]$ .
5. Calcular  $\{r_k\} = \text{IFFT}\{R[k]\}$ .

La complejidad es  $O(M \log M) = O(N \log N)$ , frente a  $O(N^2)$  del método directo (multiplicación término a término).

### 3.2.10 Principio de incertidumbre de Donoho-Stark para la DFT

Una manifestación fundamental del principio de incertidumbre en el contexto discreto es: una señal no nula no puede estar simultáneamente muy concentrada en tiempo (índices) y en frecuencia (coeficientes de Fourier). Tomamos esta formulación del teorema de Donoho-Stark de [1].

**Teorema 3.27** (Donoho-Stark para la DFT). *Sea  $\mathbf{x} \in \mathbb{C}^n$ ,  $\mathbf{x} \neq 0$ , y sea  $\hat{\mathbf{x}} = F_n \mathbf{x}$  su DFT (convención asimétrica del apunte). Definimos*

$$\text{supp}(\mathbf{x}) = \{j : x_j \neq 0\}, \quad \text{supp}(\hat{\mathbf{x}}) = \{k : \hat{x}_k \neq 0\}.$$

*Si  $s := |\text{supp}(\mathbf{x})|$  y  $t := |\text{supp}(\hat{\mathbf{x}})|$ , entonces*

$$st \geq n.$$

*Demostración.* Sean

$$S := \text{supp}(\mathbf{x}), \quad T := \text{supp}(\hat{\mathbf{x}}), \quad |S| = s, \quad |T| = t.$$

**Paso 1 (cota puntual de  $x_j$ ).** Por la fórmula de la IDFT,

$$x_j = \frac{1}{n} \sum_{k=0}^{n-1} \hat{x}_k \omega^{-jk} = \frac{1}{n} \sum_{k \in T} \hat{x}_k \omega^{-jk},$$

ya que  $\hat{x}_k = 0$  fuera de  $T$ . Tomando módulo y usando  $|\omega^{-jk}| = 1$ :

$$|x_j| \leq \frac{1}{n} \sum_{k \in T} |\hat{x}_k|.$$

**Paso 2 (Cauchy-Schwarz en un producto interno discreto).** Consideremos el espacio  $\mathbb{C}^T \simeq \mathbb{C}^t$  con el producto interno hermitiano estándar

$$\langle a, b \rangle_T := \sum_{k \in T} a_k \bar{b}_k.$$

Aplicamos Cauchy-Schwarz (Apéndice, Teorema B.5) a

$$a_k := \hat{x}_k, \quad b_k := 1 \quad (k \in T).$$

Entonces

$$\sum_{k \in T} |\hat{x}_k| = \langle |\hat{x}|, \mathbf{1} \rangle_T \leq \| |\hat{x}| \|_{2,T} \| \mathbf{1} \|_{2,T} = \left( \sum_{k \in T} |\hat{x}_k|^2 \right)^{1/2} \sqrt{t} \leq \sqrt{t} \| \hat{\mathbf{x}} \|_2.$$

Sustituyendo en el Paso 1,

$$|x_j| \leq \frac{\sqrt{t}}{n} \| \hat{\mathbf{x}} \|_2 \quad \text{para todo } j = 0, \dots, n-1.$$

**Paso 3 (sumar sobre el soporte de  $\mathbf{x}$ ).** Como  $x_j = 0$  si  $j \notin S$ ,

$$\|\mathbf{x}\|_2^2 = \sum_{j \in S} |x_j|^2 \leq \sum_{j \in S} \left( \frac{\sqrt{t}}{n} \|\widehat{\mathbf{x}}\|_2 \right)^2 = \frac{st}{n^2} \|\widehat{\mathbf{x}}\|_2^2.$$

**Paso 4 (relación de normas DFT/IDFT).** Por la unitariedad de la DFT en nuestra convención (Teorema 3.20),

$$\|\widehat{\mathbf{x}}\|_2^2 = n \|\mathbf{x}\|_2^2.$$

Equivalentemente, si  $U := \frac{1}{\sqrt{n}} F_n$ , entonces  $U$  es unitaria y por Parseval en base ortonormal finita (Apéndice, Teorema B.10) se obtiene la misma identidad.

Reemplazando en la desigualdad del Paso 3:

$$\|\mathbf{x}\|_2^2 \leq \frac{st}{n} \|\mathbf{x}\|_2^2.$$

Como  $\mathbf{x} \neq 0$ , se tiene  $\|\mathbf{x}\|_2^2 > 0$ ; al dividir,

$$1 \leq \frac{st}{n},$$

y por lo tanto  $st \geq n$ . □

**Observación 3.28.** *Este resultado implica que no puede ocurrir simultáneamente que  $s \ll n$  y  $t \ll n$ . En forma equivalente,*

$$|\text{supp}(\mathbf{x})| |\text{supp}(\widehat{\mathbf{x}})| \geq n,$$

*que es la versión discreta (para DFT) del principio de incertidumbre de Donoho-Stark.*

**Corolario 3.29** (Cota aditiva para los soportes). *Con la notación del teorema anterior, se cumple*

$$s + t \geq 2\sqrt{n}.$$

*Demostración.* Por el Teorema de Donoho-Stark,  $st \geq n$ . Además, por la desigualdad aritmético-geométrica,

$$\frac{s+t}{2} \geq \sqrt{st}.$$

Combinando ambas:

$$\frac{s+t}{2} \geq \sqrt{st} \geq \sqrt{n},$$

y por tanto  $s + t \geq 2\sqrt{n}$ . □

### 3.3 Interpolación sobre cuerpos finitos

Hasta ahora hemos trabajado sobre  $\mathbb{R}$  o  $\mathbb{C}$ , pero la teoría de interpolación es completamente algebraica y se extiende a cualquier **cuerpo** (field). En particular, la interpolación sobre **cuerpos finitos**  $\mathbb{Z}_p$  (aritmética módulo un primo  $p$ ) tiene aplicaciones fundamentales en criptografía y teoría de códigos.

### 3.3.1 Cuerpos finitos: estructura algebraica

**Definición 3.30** (Cuerpo finito  $\mathbb{Z}_p$ ). Sea  $p$  un número primo. El conjunto  $\mathbb{Z}_p = \{0, 1, 2, \dots, p-1\}$  con suma y multiplicación módulo  $p$  forma un cuerpo finito de orden  $p$ .

**Operaciones:**

- Suma:  $(a + b) \bmod p$
- Multiplicación:  $(a \cdot b) \bmod p$
- Elemento neutro aditivo:  $0$
- Elemento neutro multiplicativo:  $1$
- Inverso aditivo de  $a$ :  $(-a) \bmod p = p - a$
- Inverso multiplicativo de  $a \neq 0$ :  $a^{-1}$  tal que  $a \cdot a^{-1} \equiv 1 \pmod{p}$

**Propiedad clave:** Todo elemento no nulo de  $\mathbb{Z}_p$  tiene inverso multiplicativo. Esto es esencial para que la interpolación funcione (necesitamos dividir por  $x_i - x_j$  con  $x_i \neq x_j$ ).

**Lema 3.31** (Cálculo de inversos en  $\mathbb{Z}_p$ ). Para  $a \in \mathbb{Z}_p$  con  $a \neq 0$ , el inverso multiplicativo puede calcularse mediante:

1. **Algoritmo extendido de Euclides:** Encuentra  $x, y$  tales que  $ax + py = \gcd(a, p) = 1$ . Entonces  $a^{-1} \equiv x \pmod{p}$ .
2. **Pequeño teorema de Fermat:**  $a^{-1} \equiv a^{p-2} \pmod{p}$  (exponenciación rápida).

**Ejemplo 3.32** (Cuerpo  $\mathbb{Z}_7$ ). En  $\mathbb{Z}_7$ :

- $3 + 5 = 8 \equiv 1 \pmod{7}$
- $4 \cdot 6 = 24 \equiv 3 \pmod{7}$
- $3^{-1} = 5$  porque  $3 \cdot 5 = 15 \equiv 1 \pmod{7}$
- $2^{-1} = 4$  porque  $2 \cdot 4 = 8 \equiv 1 \pmod{7}$

### 3.3.2 Interpolación en $\mathbb{Z}_p$ : teoría

La teoría desarrollada para  $\mathbb{R}$  se traslada palabra por palabra a  $\mathbb{Z}_p$ :

**Teorema 3.33** (Interpolación en  $\mathbb{Z}_p$ ). Sean  $x_0, x_1, \dots, x_n \in \mathbb{Z}_p$  nodos distintos (módulo  $p$ ) y  $y_0, y_1, \dots, y_n \in \mathbb{Z}_p$  valores arbitrarios. Entonces existe un **único** polinomio  $p(x) \in \mathcal{P}_n(\mathbb{Z}_p)$  tal que:

$$p(x_i) \equiv y_i \pmod{p}, \quad i = 0, 1, \dots, n.$$

**Demostración. Existencia:** Construimos el polinomio usando la fórmula de Lagrange. Los polinomios base son:

$$\ell_k(x) = \prod_{\substack{j=0 \\ j \neq k}}^n \frac{x - x_j}{x_k - x_j} \pmod{p}.$$

Como  $x_i \neq x_j \pmod{p}$ , cada diferencia  $x_k - x_j$  tiene inverso en  $\mathbb{Z}_p$ , por lo que  $\ell_k(x)$  está bien definido. Satisface  $\ell_k(x_j) \equiv \delta_{kj} \pmod{p}$ .

El interpolante es:

$$p(x) = \sum_{k=0}^n y_k \ell_k(x) \pmod{p}.$$

**Unicidad:** Si  $p(x)$  y  $q(x)$  interpolan los mismos datos, entonces  $r(x) = p(x) - q(x)$  satisface  $r(x_i) \equiv 0 \pmod{p}$  para todo  $i$ . El polinomio  $r(x)$  de grado  $\leq n$  tiene  $n + 1$  raíces distintas en  $\mathbb{Z}_p$ , por lo que debe ser el polinomio cero (módulo  $p$ ).  $\square$

### Diferencias con $\mathbb{R}$ :

- **Aritmética exacta:** No hay errores de redondeo en  $\mathbb{Z}_p$  (todo es exacto módulo  $p$ ).
- **Estructura finita:** Solo hay  $p$  elementos, lo que limita el número de nodos posibles.
- **Aplicaciones distintas:** Criptografía y códigos en lugar de aproximación de funciones.

### 3.3.3 Implementación computacional

La interpolación en  $\mathbb{Z}_p$  requiere aritmética modular cuidadosa:

#### Algoritmo (Interpolación de Lagrange en $\mathbb{Z}_p$ ):

*Entrada:* Nodos  $x_0, \dots, x_n \in \mathbb{Z}_p$ , valores  $y_0, \dots, y_n \in \mathbb{Z}_p$ , primo  $p$ .

*Salida:* Coeficientes  $[a_0, a_1, \dots, a_n]$  de  $p(x) = \sum_{k=0}^n a_k x^k \pmod{p}$ .

*Procedimiento:*

1. Inicializar  $\text{coefs} = [0, 0, \dots, 0]$  (longitud  $n + 1$ ).
2. Para  $k = 0, 1, \dots, n$ :
  - (a) Calcular denominador:  $d = \prod_{j \neq k} (x_k - x_j) \pmod{p}$ .
  - (b) Calcular inverso:  $d^{-1} \pmod{p}$  (Euclides extendido).
  - (c) Construir numerador (polinomio):  $\text{num}(x) = \prod_{j \neq k} (x - x_j) \pmod{p}$ .
  - (d) Actualizar:  $\text{coefs} = \text{coefs} + y_k \cdot d^{-1} \cdot \text{num} \pmod{p}$ .
3. Retornar  $\text{coefs}$ .

**Ejemplo 3.34** (Interpolación en  $\mathbb{Z}_7$ ). *Interpolar los puntos  $(0, 1)$ ,  $(1, 3)$ ,  $(2, 2)$  en  $\mathbb{Z}_7$ .*

**Solución:** Usando la fórmula de Lagrange:

$$\begin{aligned} \ell_0(x) &= \frac{(x-1)(x-2)}{(0-1)(0-2)} = \frac{(x-1)(x-2)}{2} \equiv 4(x-1)(x-2) \pmod{7} \\ &= 4(x^2 - 3x + 2) \equiv 4x^2 - 5x + 1 \pmod{7} \end{aligned}$$



Similarmente calculamos  $\ell_1(x)$  y  $\ell_2(x)$ . El interpolante es:

$$p(x) = 1 \cdot \ell_0(x) + 3 \cdot \ell_1(x) + 2 \cdot \ell_2(x) \equiv 5x^2 + 6x + 1 \pmod{7}.$$

Verificación:

$$p(0) = 1 \equiv 1 \pmod{7} \quad \checkmark$$

$$p(1) = 5 + 6 + 1 = 12 \equiv 5 \pmod{7} \quad (\text{jerror de cálculo! revisar})$$

$$p(2) = 20 + 12 + 1 = 33 \equiv 5 \pmod{7}$$

### 3.3.4 Aplicación: Esquema de secreto compartido de Shamir

Una aplicación elegante de la interpolación en  $\mathbb{Z}_p$  es el **esquema de Shamir** (1979) para compartir un secreto de manera segura.

**Definición 3.35** (Esquema de Shamir  $(n, k)$ -threshold). *Objetivo:* Dividir un secreto  $s \in \mathbb{Z}_p$  entre  $n$  participantes de modo que:

- Cualquier grupo de  $k$  participantes puede reconstruir  $s$ .
- Cualquier grupo de  $k - 1$  o menos participantes no obtiene ninguna información sobre  $s$ .

**Protocolo:**

#### 1. Distribución de shares:

(a) Elegir aleatoriamente  $a_1, a_2, \dots, a_{k-1} \in \mathbb{Z}_p$ .

(b) Construir el polinomio (en  $\mathbb{Z}_p$ ):

$$p(x) = s + a_1x + a_2x^2 + \dots + a_{k-1}x^{k-1} \pmod{p}.$$

(c) Distribuir los **shares**: participante  $i$  recibe  $(i, p(i) \bmod p)$  para  $i = 1, 2, \dots, n$ .

#### 2. Reconstrucción del secreto:

(a) Reunir  $k$  shares cualesquiera:  $(x_{i_1}, y_{i_1}), \dots, (x_{i_k}, y_{i_k})$ .

(b) Interpolar (Lagrange en  $\mathbb{Z}_p$ ) para obtener  $p(x)$ .

(c) Recuperar  $s = p(0) \bmod p$ .

**Teorema 3.36** (Seguridad perfecta de Shamir). *El esquema de Shamir tiene las siguientes propiedades:*

1. **Corrección:** Con  $k$  shares, el secreto se reconstruye correctamente.
2. **Seguridad perfecta:** Con  $k-1$  shares o menos, todos los valores de  $s \in \mathbb{Z}_p$  son igualmente probables.

*Demostración.* **(1) Corrección:** El polinomio  $p(x)$  de grado  $k-1$  está únicamente determinado por  $k$  puntos (teorema de interpolación). Como  $s = p(0)$ , se recupera exactamente.

**(2) Seguridad perfecta:** Supongamos que un adversario tiene  $k-1$  shares. Fijemos cualquier valor tentativo  $s' \in \mathbb{Z}_p$  para el secreto. ¿Existe un polinomio  $p'(x)$  de grado  $k-1$  tal que:

- $p'(0) = s'$  (el secreto tentativo),
- $p'$  pasa por los  $k-1$  shares conocidos?

La respuesta es **sí**: esto especifica  $k$  condiciones (valor en 0 más  $k-1$  shares) para un polinomio de grado  $k-1$ , que tiene  $k$  coeficientes libres. El sistema tiene solución única.

Más aún, como los coeficientes  $a_1, \dots, a_{k-1}$  se eligieron uniformemente al azar de  $\mathbb{Z}_p$ , todos los valores de  $s \in \mathbb{Z}_p$  son igualmente probables dado cualquier conjunto de  $k-1$  shares. Por lo tanto, el adversario no aprende *nada* sobre  $s$ .  $\square$

### Ejemplo numérico:

**Ejemplo 3.37** (Shamir en  $\mathbb{Z}_{97}$ ). Queremos compartir el secreto  $s = 42$  entre  $n = 5$  participantes, requiriendo  $k = 3$  para reconstruir. Trabajamos en  $\mathbb{Z}_{97}$ .

**Paso 1:** Elegimos aleatoriamente  $a_1 = 15, a_2 = 67$  en  $\mathbb{Z}_{97}$ . El polinomio es:

$$p(x) = 42 + 15x + 67x^2 \pmod{97}.$$

**Paso 2:** Generamos shares evaluando  $p(i)$  para  $i = 1, \dots, 5$ :

$$\begin{aligned} \text{Share 1: } (1, p(1)) &= (1, 42 + 15 + 67) = (1, 27) \\ \text{Share 2: } (2, p(2)) &= (2, 42 + 30 + 268) = (2, 49) \\ \text{Share 3: } (3, p(3)) &= (3, 42 + 45 + 603) = (3, 11) \\ \text{Share 4: } (4, p(4)) &= (4, 42 + 60 + 1072) = (4, 89) \\ \text{Share 5: } (5, p(5)) &= (5, 42 + 75 + 1675) = (5, 16) \end{aligned}$$

(todas las operaciones módulo 97).

**Paso 3:** Para reconstruir, usamos shares 1, 3, 5 (por ejemplo):

$$\text{Interpolar en } \mathbb{Z}_{97} : \{(1, 27), (3, 11), (5, 16)\}$$

Por interpolación de Lagrange obtenemos  $p(x) = 42 + 15x + 67x^2 \pmod{97}$ . El secreto es  $s = p(0) = 42$ .

**Implementación:** Ver `interpolacion_algebraica.py`:

- `shamir_generar_shares(secreto, n, k, p)`: Genera  $n$  shares.
- `shamir_reconstruir(shares, p)`: Reconstruye el secreto a partir de  $\geq k$  shares.

### 3.3.5 Aplicación: Códigos de Reed-Solomon

Los **códigos de Reed-Solomon** son códigos de corrección de errores basados en evaluación de polinomios sobre  $\mathbb{Z}_p$  (o más generalmente, sobre  $\mathbb{F}_q$ ).

**Definición 3.38** (Código Reed-Solomon  $RS(n, k)$ ). *Parámetros:*

- $k$ : longitud del mensaje (número de símbolos de información).
- $n$ : longitud del código ( $n > k$ , símbolos redundantes).
- $\mathbb{F}_q$ : Cuerpo finito con  $q \geq n$  elementos.
- $\alpha_1, \dots, \alpha_n \in \mathbb{F}_q$ : puntos de evaluación distintos.

**Codificación:** Un mensaje  $(m_0, m_1, \dots, m_{k-1}) \in \mathbb{F}_q^k$  se codifica como:

1. Interpretar el mensaje como coeficientes:  $m(x) = m_0 + m_1x + \dots + m_{k-1}x^{k-1}$ .
2. Evaluar en los  $n$  puntos:  $\mathbf{c} = (m(\alpha_1), m(\alpha_2), \dots, m(\alpha_n))$ .

El vector  $\mathbf{c} \in \mathbb{F}_q^n$  es la **palabra código**.

**Decodificación:** Dada una palabra posiblemente corrupta  $\mathbf{r} = \mathbf{c} + \mathbf{e}$  (error  $\mathbf{e}$ ):

1. Si hay  $\leq \lfloor (n-k)/2 \rfloor$  errores, usar algoritmos de decodificación (Berlekamp-Welch, Euclides, etc.) para recuperar  $m(x)$ .
2. Extraer el mensaje original de los coeficientes de  $m(x)$ .

**Teorema 3.39** (Capacidad de corrección de Reed-Solomon). El código  $RS(n, k)$  puede:

- **Detectar** hasta  $n - k$  errores.
- **Corregir** hasta  $\lfloor (n - k)/2 \rfloor$  errores.

*Idea.* La **distancia mínima** del código es  $d = n - k + 1$ . Dos palabras código distintas provienen de polinomios distintos  $m_1(x), m_2(x) \in \mathcal{P}_{k-1}(\mathbb{F}_q)$ . Su diferencia  $\Delta(x) = m_1(x) - m_2(x)$  es no nula y tiene grado  $< k$ , por lo que tiene a lo sumo  $k - 1$  raíces en  $\mathbb{F}_q$ .

Por lo tanto, las evaluaciones de  $m_1$  y  $m_2$  difieren en al menos  $n - (k - 1) = n - k + 1$  posiciones. Esta distancia mínima permite:

- Detectar hasta  $d - 1 = n - k$  errores (si hay  $\leq n - k$  errores, la palabra recibida no es válida).
- Corregir hasta  $\lfloor (d - 1)/2 \rfloor = \lfloor (n - k)/2 \rfloor$  errores (por teoría de codificación).

□

#### Aplicaciones de Reed-Solomon:

- **CDs y DVDs:** Protección contra rayones y defectos.
- **Códigos QR:** Recuperación de datos parcialmente dañados.
- **Comunicaciones espaciales:** NASA/ESA usan RS para transmisiones desde sondas.
- **Almacenamiento distribuido:** RAID 6 usa RS para tolerar fallas de discos.

## Chapter 4

# Series de Fourier Generalizadas

En este capítulo queremos aproximar funciones en bases de funciones, extendiendo la fórmula de proyección ortogonal del capítulo 2 al caso de dimensión infinita. Para hacerlo de manera sistemática, necesitamos un marco general en espacios con producto interno donde existan sistemas ortogonales de funciones, en completa analogía con las bases ortogonales de vectores en dimensión finita.

El marco necesario es el de los espacios de pre-Hilbert, que son espacios vectoriales con producto interno, pero sin suponer completitud (no necesariamente espacios de Hilbert). Una vez fijado ese marco abstracto, lo especializaremos a bases concretas (Fourier, Chebyshev y otras).

Históricamente, las series de Fourier nacen en el estudio de la conducción del calor. Fourier consideró la ecuación

$$u_t = \alpha u_{xx},$$

y, mediante separación de variables, obtuvo expansiones en senos y cosenos para describir la evolución temporal de la temperatura. Esa intuición fue extraordinariamente fecunda, aunque su formalización rigurosa (convergencia puntual, convergencia en norma, comportamiento en discontinuidades) tomó varias décadas.

La perspectiva actual enmarca ese desarrollo dentro de una teoría unificada de expansiones ortogonales: las series de Fourier son un caso particular de una familia más amplia de representaciones por proyección (Chebyshev y otras bases), con una arquitectura común de coeficientes, sumas parciales, densidad y estimación del error de truncamiento. En este capítulo seguimos precisamente esa lógica: primero el marco general y luego las especializaciones concretas.

**Definición 4.1** (Espacio de pre-Hilbert). *Un espacio de pre-Hilbert es un espacio vectorial  $V$  sobre  $\mathbb{C}$  (o  $\mathbb{R}$ ) provisto de un producto interno  $\langle \cdot, \cdot \rangle$ . En este capítulo reservamos la letra  $V$  para el espacio abstracto.*

En este capítulo trabajamos con funciones de variable real y valores complejos,

$$f : [a, b] \rightarrow \mathbb{C}, \quad f = u + iv,$$

donde  $u, v : [a, b] \rightarrow \mathbb{R}$ .

**Observación 4.2** (Funciones a valores complejos vs. funciones de variable compleja). *Cuando escribimos  $f : [a, b] \rightarrow \mathbb{C}$ , la variable es real. Esto no es lo mismo que una función  $f : \mathbb{C} \rightarrow \mathbb{C}$*

de variable compleja. En consecuencia, tanto las derivadas como las integrales de funciones a valores complejos se entienden componente a componente: si  $f = u + iv$  con  $u, v$  reales, entonces

$$f' = u' + iv', \quad \int_a^b f(x) dx = \int_a^b u(x) dx + i \int_a^b v(x) dx.$$

**Definición 4.3** (Producto interno con peso). Dado un intervalo  $(a, b)$  y una función de peso  $w(x) > 0$  integrable, el producto interno con peso es

$$\langle f, g \rangle_w = \int_a^b f(x) \overline{g(x)} w(x) dx.$$

En el caso real, la barra de conjugación se omite.

**Definición 4.4** (Norma asociada). La norma inducida por  $\langle \cdot, \cdot \rangle_w$  se define por

$$\|f\|_w := \sqrt{\langle f, f \rangle_w}.$$

**Definición 4.5** (Sistema ortonormal, coeficientes y sumas parciales). Sea  $\{e_k\}_{k \geq 1} \subset V$  un sistema ortonormal, es decir,

$$\langle e_j, e_k \rangle = \delta_{jk}.$$

Para  $u \in V$ , definimos los coeficientes de Fourier generalizados

$$\hat{u}_k := \langle u, e_k \rangle,$$

y las sumas parciales

$$S_N u := \sum_{k=1}^N \hat{u}_k e_k.$$

Más generalmente, si  $\{\varphi_k\}$  es una familia ortogonal no normalizada, los coeficientes de proyección son

$$c_k = \frac{\langle f, \varphi_k \rangle_w}{\|\varphi_k\|_w^2},$$

y la proyección de orden  $n$  correspondiente es

$$S_n f = \sum_{k=0}^n c_k \varphi_k.$$

**Ejemplo 4.6** (Exponenciales complejas y series de Fourier). Definimos el sistema de funciones  $\{e_k\}_{k \in \mathbb{Z}}$  por

$$e_k(x) := e^{ikx}, \quad k \in \mathbb{Z}. \quad (4.1)$$

Para cada  $N \in \mathbb{N}$ , definimos

$$V_N^{\mathbb{C}} := \text{span}\{e_k : |k| \leq N\}.$$

Con el producto interno estándar (sin pesos):

$$(f, g) = \int_0^{2\pi} f(x) \overline{g(x)} dx. \quad (4.2)$$

se tiene, para todo  $k, l \in \mathbb{Z}$ ,

$$(e_k, e_l) = \int_0^{2\pi} e^{i(k-l)x} dx = \begin{cases} 2\pi & \text{si } k = l, \\ 0 & \text{si } k \neq l. \end{cases} \quad (4.3)$$

En particular,  $\|e_k\|^2 = 2\pi$  para todo  $k \in \mathbb{Z}$ .

La demostración es inmediata. Si  $k = l$ :  $\int_0^{2\pi} 1 dx = 2\pi$ . Si  $k \neq l$ , sea  $m = k - l \neq 0$ :

$$\int_0^{2\pi} e^{imx} dx = \left[ \frac{e^{imx}}{im} \right]_0^{2\pi} = \frac{e^{2\pi im} - 1}{im} = 0,$$

pues  $e^{2\pi im} = 1$  para todo  $m \in \mathbb{Z}$ .

Con esta familia de funciones ortogonales, la fórmula de proyección ortogonal nos da la expresión de los coeficientes de Fourier complejos, y la serie de Fourier correspondiente a una función  $f$ .

**Definición 4.7** (Coeficientes de Fourier complejos, suma parcial y serie de Fourier). Sea  $f \in C([0, 2\pi]; \mathbb{C})$ . Sus coeficientes de Fourier complejos (respecto de la familia  $\{e_k\}_{k \in \mathbb{Z}}$ ) se definen por la fórmula de proyección (B.1):

$$\hat{f}_k = \frac{(f, e_k)}{\|e_k\|^2} = \frac{1}{2\pi} \int_0^{2\pi} f(x) e^{-ikx} dx, \quad k \in \mathbb{Z}. \quad (4.4)$$

La suma parcial de Fourier de orden  $N$  es

$$S_N f(x) = \sum_{|k| \leq N} \hat{f}_k e^{ikx}.$$

La serie de Fourier de  $f$  es

$$f(x) \sim \sum_{k=-\infty}^{\infty} \hat{f}_k e^{ikx}. \quad (4.5)$$

**Teorema 4.8** (Propiedad de mejor aproximación). Sea  $u \in V$  y sea  $V_N := \text{span}\{e_1, \dots, e_N\}$ . Entonces, para todo  $v \in V_N$ :

$$\|u - S_N u\| \leq \|u - v\|.$$

*Demostración.* Escribimos  $v = S_N u + q$  con  $q \in V_N$ . Por ortonormalidad,

$$\langle u - S_N u, e_j \rangle = 0, \quad j = 1, \dots, N,$$

y por lo tanto  $u - S_N u \perp V_N$ . Aplicando Pitágoras:

$$\|u - v\|^2 = \|u - S_N u\|^2 + \|q\|^2 \geq \|u - S_N u\|^2.$$

□

**Teorema 4.9** (Equivalencia entre densidad, convergencia en norma e identidad de Parseval). Sea  $\{e_k\}_{k \geq 1}$  un sistema ortonormal en un espacio de pre-Hilbert  $V$ . Son equivalentes:

1. *Densidad*:  $\overline{\text{span}\{e_k : k \geq 1\}} = V$ .

2. *Convergencia de sumas parciales*: para todo  $u \in V$ ,  $\|u - S_N u\| \xrightarrow{N \rightarrow \infty} 0$ .

3. *Parseval*: para todo  $u \in V$ ,

$$\|u\|^2 = \sum_{k=1}^{\infty} |\hat{u}_k|^2.$$

*Demostración.* (1)  $\Rightarrow$  (2). Sea  $u \in V$  y  $\varepsilon > 0$ . Por densidad, existe

$$v = \sum_{k=1}^m a_k e_k$$

tal que  $\|u - v\| < \varepsilon$ . Para  $N \geq m$ , se tiene  $v \in V_N$ , y por el Teorema 4.8:

$$\|u - S_N u\| \leq \|u - v\| < \varepsilon.$$

Luego  $\|u - S_N u\| \rightarrow 0$ .

(2)  $\Rightarrow$  (3). Para cada  $u \in V$  y cada  $N$ , como

$$S_N u \in V_N := \text{span}\{e_1, \dots, e_N\}, \quad u - S_N u \perp V_N,$$

y por lo tanto  $u - S_N u \perp S_N u$ . Entonces, por Pitágoras,

$$\|u\|^2 = \|S_N u\|^2 + \|u - S_N u\|^2.$$

Además, como  $\{e_k\}$  es ortonormal y  $S_N u = \sum_{k=1}^N \hat{u}_k e_k$ ,

$$\|S_N u\|^2 = \sum_{k=1}^N |\hat{u}_k|^2.$$

Sustituyendo, obtenemos la identidad finita de Parseval:

$$\|u\|^2 = \sum_{k=1}^N |\hat{u}_k|^2 + \|u - S_N u\|^2.$$

Si  $\|u - S_N u\| \rightarrow 0$ , al pasar al límite resulta Parseval.

(3)  $\Rightarrow$  (2). De la misma identidad finita,

$$\|u - S_N u\|^2 = \|u\|^2 - \sum_{k=1}^N |\hat{u}_k|^2.$$

Bajo (3), el segundo término converge a  $\|u\|^2$ , luego  $\|u - S_N u\| \rightarrow 0$ . Finalmente, (2) implica (1) porque  $S_N u \in \text{span}\{e_1, \dots, e_N\}$  para todo  $N$ .  $\square$

**Corolario 4.10** (Identidad de Parseval para el error de truncamiento). *Bajo las hipótesis del Teorema 4.9, para todo  $u \in V$  y todo  $N \geq 1$  se cumple*

$$\|u - S_N u\|^2 = \sum_{k > N} |\hat{u}_k|^2.$$

*Demostración.* La identidad general se obtiene restando

$$\|u\|^2 = \sum_{k=1}^{\infty} |\widehat{u}_k|^2 \quad \text{y} \quad \|u\|^2 = \sum_{k=1}^N |\widehat{u}_k|^2 + \|u - S_N u\|^2.$$

□

**Teorema 4.11** (Unicidad de los coeficientes de Fourier). *Bajo las hipótesis del Teorema 4.9, sea  $u \in V$ . Si existen dos sucesiones  $(a_k)_{k \geq 1}, (b_k)_{k \geq 1} \subset \mathbb{C}$  tales que*

$$u = \sum_{k=1}^{\infty} a_k e_k \quad \text{y} \quad u = \sum_{k=1}^{\infty} b_k e_k$$

*con convergencia en la norma de  $V$ , entonces los coeficientes coinciden uno a uno:*

$$a_k = b_k \quad \text{para todo } k \geq 1.$$

*Demostración.* Sea  $m \geq 1$  fijo. Para  $N \geq m$ , por ortonormalidad se tiene

$$(S_N^{(a)}, e_m) = \sum_{k=1}^N a_k (e_k, e_m) = a_m, \quad (S_N^{(b)}, e_m) = \sum_{k=1}^N b_k (e_k, e_m) = b_m,$$

donde

$$S_N^{(a)} := \sum_{k=1}^N a_k e_k, \quad S_N^{(b)} := \sum_{k=1}^N b_k e_k.$$

Como  $S_N^{(a)} \rightarrow u$  y  $S_N^{(b)} \rightarrow u$  en  $V$ , por Cauchy-Schwarz:

$$|(u, e_m) - (S_N^{(a)}, e_m)| \leq \|u - S_N^{(a)}\| \|e_m\| \xrightarrow{N \rightarrow \infty} 0,$$

y análogamente

$$|(u, e_m) - (S_N^{(b)}, e_m)| \leq \|u - S_N^{(b)}\| \|e_m\| \xrightarrow{N \rightarrow \infty} 0.$$

Por lo tanto,

$$(u, e_m) = \lim_{N \rightarrow \infty} (S_N^{(a)}, e_m) = \lim_{N \rightarrow \infty} (S_N^{(b)}, e_m).$$

Además, para  $N \geq m$  ya vimos que  $(S_N^{(a)}, e_m) = a_m$  y  $(S_N^{(b)}, e_m) = b_m$ , luego

$$\lim_{N \rightarrow \infty} (S_N^{(a)}, e_m) = a_m, \quad \lim_{N \rightarrow \infty} (S_N^{(b)}, e_m) = b_m.$$

Concluimos

$$a_m = (u, e_m) = b_m,$$

y por tanto  $a_m = b_m$ . Como  $m$  es arbitrario, vale para todo  $m \geq 1$ .

□



## 4.1 Series de Fourier de funciones suaves periódicas

Para caracterizar el error de truncamiento de la serie de Fourier, es necesario imponer condiciones de suavidad a la función  $f$ . Para ello, introducimos el espacio de funciones periódicas con derivadas continuas.

**Definición 4.12** (Espacio  $C_{per}^n$  complejo periódico). Sea  $n \in \mathbb{N} \cup \{0\}$ . Diremos que  $f : [0, 2\pi] \rightarrow \mathbb{C}$  pertenece a  $C_{per}^n([0, 2\pi]; \mathbb{C})$  si, al escribir  $f = u + iv$  con  $u, v : [0, 2\pi] \rightarrow \mathbb{R}$ , se cumple  $u, v \in C^n([0, 2\pi])$  y

$$f^{(p)}(0) = f^{(p)}(2\pi), \quad 0 \leq p \leq n-1,$$

donde  $f^{(p)} := u^{(p)} + iv^{(p)}$ .

La condición de periodicidad hasta orden  $n-1$  garantiza que la extensión periódica de  $f$  a todo  $\mathbb{R}$  es de clase  $C^{n-1}$ .

### 4.1.1 La serie trigonométrica real

Cuando  $f$  toma valores reales, los coeficientes de Fourier presentan una estructura de simetría que permite reescribir la serie en términos de senos y cosenos.

**Proposición 4.13** (Simetría conjugada). Sea  $f : [0, 2\pi] \rightarrow \mathbb{R}$  integrable. Entonces  $\hat{f}_{-k} = \overline{\hat{f}_k}$  para todo  $k \in \mathbb{Z}$ .

*Demostración.* Como  $\overline{f(x)} = f(x)$ :

$$\overline{\hat{f}_k} = \frac{1}{2\pi} \int_0^{2\pi} \overline{f(x) e^{-ikx}} dx = \frac{1}{2\pi} \int_0^{2\pi} f(x) e^{ikx} dx = \hat{f}_{-k}. \quad \square$$

Esta simetría permite agrupar los pares de frecuencia  $\pm k$  en la suma parcial:

$$\hat{f}_k e^{ikx} + \hat{f}_{-k} e^{-ikx} = \hat{f}_k e^{ikx} + \overline{\hat{f}_k} e^{-ikx} = 2 \operatorname{Re}(\hat{f}_k e^{ikx}). \quad (4.6)$$

Escribiendo  $\hat{f}_k = \frac{a_k - ib_k}{2}$  con  $a_k, b_k \in \mathbb{R}$  y usando  $e^{ikx} = \cos(kx) + i \sin(kx)$ :

$$2 \operatorname{Re}(\hat{f}_k e^{ikx}) = a_k \cos(kx) + b_k \sin(kx).$$

La evaluación directa de (4.4) con  $e^{-ikx} = \cos(kx) - i \sin(kx)$  muestra que  $a_k = 2 \operatorname{Re}(\hat{f}_k)$  y  $b_k = -2 \operatorname{Im}(\hat{f}_k)$  coinciden con las integrales:

**Definición 4.14** (Coeficientes de Fourier reales y suma parcial). Sea  $f : [0, 2\pi] \rightarrow \mathbb{R}$  integrable. Sus coeficientes de Fourier reales son:

$$a_k = \frac{1}{\pi} \int_0^{2\pi} f(x) \cos(kx) dx \quad (k \geq 0), \quad b_k = \frac{1}{\pi} \int_0^{2\pi} f(x) \sin(kx) dx \quad (k \geq 1). \quad (4.7)$$

La suma parcial de Fourier real de orden  $N$  es:

$$S_N(f)(x) = \frac{a_0}{2} + \sum_{k=1}^N (a_k \cos(kx) + b_k \sin(kx)). \quad (4.8)$$

La equivalencia con la suma parcial compleja es inmediata de (4.6): para  $f$  real,  $S_N f(x) = \hat{f}_0 + \sum_{k=1}^N [\hat{f}_k e^{ikx} + \hat{f}_{-k} e^{-ikx}] = \frac{a_0}{2} + \sum_{k=1}^N [a_k \cos(kx) + b_k \sin(kx)]$ .

**Observación 4.15.** La ortogonalidad del conjunto  $\{1, \cos(x), \sin(x), \dots, \cos(Nx), \sin(Nx)\}$  con el producto interno (4.2) se obtiene sin verificación adicional: es una consecuencia de la identidad (4.3) y del cambio de base (4.6). El Teorema 4.8 se extiende también al caso real: para  $f$  real,  $S_N(f)$  es el polinomio trigonométrico real de grado  $\leq N$  más cercano a  $f$  en norma cuadrática.

#### 4.1.2 Decaimiento de los coeficientes de Fourier y regularidad

**Lema 4.16** (Coeficientes de Fourier de la derivada). Sea  $f \in C_{per}^1([0, 2\pi])$ . Entonces, para todo  $k \in \mathbb{Z}$ :

$$\widehat{f'}_k = ik \hat{f}_k.$$

En particular, para  $k \neq 0$ ,

$$\hat{f}_k = \frac{1}{ik} \widehat{f'}_k. \quad (4.9)$$

*Demostración.* Por definición,

$$\widehat{f'}_k = \frac{1}{2\pi} \int_0^{2\pi} f'(x) e^{-ikx} dx.$$

Integrando por partes:

$$\widehat{f'}_k = \frac{1}{2\pi} \left[ f(x) e^{-ikx} \right]_0^{2\pi} + \frac{ik}{2\pi} \int_0^{2\pi} f(x) e^{-ikx} dx.$$

El término de borde se anula por periodicidad de  $f$  y porque  $e^{-2\pi ik} = 1$ . Luego  $\widehat{f'}_k = ik \hat{f}_k$ .  $\square$

**Teorema 4.17** (Decaimiento de los coeficientes de Fourier). Sea  $f \in C_{per}^n([0, 2\pi])$  con  $n \geq 1$ . Entonces, para todo  $k \in \mathbb{Z}$  con  $k \neq 0$ :

$$\hat{f}_k = \frac{\widehat{f^{(n)}}_k}{(ik)^n}, \quad |\hat{f}_k| \leq \frac{C}{|k|^n},$$

donde  $C = \frac{1}{2\pi} \int_0^{2\pi} |f^{(n)}(x)| dx$ .

En particular, se tiene

$$|\hat{f}_k| = O(|k|^{-n})$$

*Demostración.* Aplicando el Lema 4.16 sucesivamente a  $f, f', \dots, f^{(n-1)}$  (válido por periodicidad y regularidad), para  $k \neq 0$  se obtiene

$$\hat{f}_k = \frac{\widehat{f^{(n)}}_k}{(ik)^n}.$$

Finalmente,

$$|\hat{f}_k| = \frac{|\widehat{f^{(n)}}_k|}{|k|^n} \leq \frac{1}{|k|^n} \cdot \frac{1}{2\pi} \int_0^{2\pi} |f^{(n)}(x)| dx = \frac{C}{|k|^n}. \quad \square$$

**Corolario 4.18.** Si  $f \in C_{per}^\infty([0, 2\pi])$ , entonces para todo  $n \in \mathbb{N}$  existe  $C_n > 0$  tal que  $|\hat{f}_k| \leq C_n/|k|^n$ . Esto se conoce como decaimiento espectral o super-algebraico.

**Corolario 4.19** (Convergencia uniforme de la serie de Fourier para  $C_{per}^2$ ). Si  $f \in C_{per}^2([0, 2\pi])$ , entonces su serie de Fourier converge uniformemente a  $f$  en  $[0, 2\pi]$ .

*Demostración.* Consideremos la función

$$g(x) := \sum_{k \in \mathbb{Z}} \hat{f}_k e^{ikx}.$$

Veamos primero que queda bien definida para cada  $x$ , es decir, que la serie converge puntualmente. Para eso, mostremos que la serie de los módulos converge (convergencia absoluta):

$$\sum_{k \in \mathbb{Z}} |\hat{f}_k e^{ikx}| = |\hat{f}_0| + \sum_{k \neq 0} |\hat{f}_k|$$

Por el Teorema 4.17 (con  $n = 2$ ), existe  $C > 0$  tal que

$$|\hat{f}_k| \leq \frac{C}{|k|^2}, \quad k \neq 0.$$

y por lo tanto la serie de módulos converge. Esto prueba que la serie de Fourier converge puntualmente para cada  $x$  y, que  $g$  queda bien definida.

Ahora bien, también podemos acotar la diferencia con la suma parcial por la cola de la serie:

$$|g(x) - S_N f(x)| = \left| \sum_{|k| > N} \hat{f}_k e^{ikx} \right| \leq \sum_{|k| > N} |\hat{f}_k|.$$

Tomando supremo sobre  $x \in [0, 2\pi]$ ,

$$\|g - S_N f\|_\infty \leq \sum_{|k| > N} |\hat{f}_k| \xrightarrow{N \rightarrow \infty} 0.$$

Luego  $S_N f \rightarrow g$  uniformemente (es decir, independientemente de  $x$ ).

Para identificar el límite, escribimos

$$f - g = (f - S_N f) + (S_N f - g).$$

Aplicando desigualdad triangular en norma 2,

$$\|f - g\|_2 \leq \|f - S_N f\|_2 + \|S_N f - g\|_2.$$

El primer término tiende a 0 por la convergencia en norma de las sumas parciales de Fourier (Teorema 4.9, ítem (2), aplicado al sistema ortonormal considerado). Para el segundo, usamos

$$\|S_N f - g\|_2 \leq \sqrt{2\pi} \|S_N f - g\|_\infty \xrightarrow{N \rightarrow \infty} 0,$$

porque ya probamos convergencia uniforme. En consecuencia,

$$\|f - g\|_2 = 0.$$

Por propiedades de la norma, esto implica  $f = g$ . Por lo tanto,  $S_N f \rightarrow f$  uniformemente.  $\square$

**Observación 4.20.** *Puede demostrarse un resultado más ajustado que el anterior: si  $f \in C_{\text{per}}^1([0, 2\pi])$ , entonces su serie de Fourier también converge uniformemente a  $f$ . Esto se obtiene del Teorema C.7 del Apéndice C, donde se prueba en particular que*

$$\|f - S_N f\|_\infty \leq \frac{\|f'\|_{L^2}}{\sqrt{\pi}} \frac{1}{\sqrt{N}} \xrightarrow{N \rightarrow \infty} 0.$$

### 4.1.3 Cuadratura de funciones suaves y periódicas

El cálculo numérico de los coeficientes de Fourier requiere evaluar las integrales:

$$\hat{f}_k = \frac{1}{2\pi} \int_0^{2\pi} f(x) e^{-ikx} dx.$$

En la práctica estas integrales raramente admiten fórmula cerrada. Sin embargo, la herramienta necesaria ya fue desarrollada en el Capítulo 3: la regla del trapecio compuesta.

**Proposición 4.21** (Coeficientes discretos de Fourier como regla del trapecio). *Sea  $M \geq 1$ ,  $h = 2\pi/M$  y  $x_j = 2\pi j/M$  para  $j = 0, \dots, M-1$ . Si*

$$\hat{f}_k = \frac{1}{2\pi} \int_0^{2\pi} f(x) e^{-ikx} dx,$$

*la aproximación trapezoidal periódica de  $\hat{f}_k$  es*

$$\tilde{f}_k^{(M)} := \frac{1}{M} \sum_{j=0}^{M-1} f(x_j) e^{-ikx_j}.$$

*Demostración.* Apliquemos la regla del trapecio compuesta a

$$\int_0^{2\pi} g(x) dx, \quad g(x) = f(x) e^{-ikx}.$$

Con  $x_j = jh$  y  $h = 2\pi/M$ :

$$\int_0^{2\pi} g(x) dx \approx \frac{h}{2} [g(x_0) + 2g(x_1) + \dots + 2g(x_{M-1}) + g(x_M)].$$

Pero  $g$  es  $2\pi$ -periódica (producto de funciones  $2\pi$ -periódicas), de modo que  $g(x_M) = g(x_0)$ . Los dos extremos se promedian:  $\frac{1}{2}[g(x_0) + g(x_M)] = g(x_0)$ , y la fórmula se simplifica a:

$$\int_0^{2\pi} g(x) dx \approx h \sum_{j=0}^{M-1} g(x_j) = \frac{2\pi}{M} \sum_{j=0}^{M-1} f(x_j) e^{-ikx_j}.$$

Dividiendo por  $2\pi$  obtenemos exactamente la fórmula anunciada. □

La efectividad de esta aproximación para funciones periódicas se apoya en una ortogonalidad discreta elemental de los modos exponenciales.

**Lema 4.22** (Exactitud de la cuadratura trapezoidal para exponenciales complejas). Sea  $M \geq 1$  entero,  $h = 2\pi/M$  y  $x_j = jh$  para  $j = 0, \dots, M-1$ . Para cada  $\ell \in \mathbb{Z}$ , definimos

$$I_\ell := \int_0^{2\pi} e^{i\ell x} dx, \quad Q_\ell^{(M)} := \frac{2\pi}{M} \sum_{j=0}^{M-1} e^{i\ell x_j}.$$

Entonces

$$I_\ell = \begin{cases} 2\pi, & \ell = 0, \\ 0, & \ell \neq 0, \end{cases} \quad Q_\ell^{(M)} = \begin{cases} 2\pi, & \ell \equiv 0 \pmod{M}, \\ 0, & \ell \not\equiv 0 \pmod{M}. \end{cases}$$

En particular,

$$Q_\ell^{(M)} = I_\ell \iff \ell = 0 \text{ o } \ell \not\equiv 0 \pmod{M}.$$

*Demostración.* Para la integral exacta,

$$I_\ell = \left[ \frac{e^{i\ell x}}{i\ell} \right]_0^{2\pi} = 0 \quad (\ell \neq 0), \quad I_0 = \int_0^{2\pi} 1 dx = 2\pi.$$

Para la trapezoidal compuesta, escribimos

$$\frac{1}{M} \sum_{j=0}^{M-1} e^{i\ell x_j} = \frac{1}{M} \sum_{j=0}^{M-1} e^{2\pi i \ell j / M}.$$

Si  $\ell \equiv 0 \pmod{M}$ , cada término vale 1 y la suma es 1. Si  $\ell \not\equiv 0 \pmod{M}$ , tomando  $w = e^{2\pi i \ell / M} \neq 1$ ,

$$\sum_{j=0}^{M-1} w^j = \frac{w^M - 1}{w - 1} = \frac{e^{2\pi i \ell} - 1}{w - 1} = 0,$$

ya que  $e^{2\pi i \ell} = 1$ . Multiplicando por  $2\pi$  se obtiene la fórmula para  $Q_\ell^{(M)}$ . □

**Corolario 4.23** (Exactitud de trapecios para polinomios trigonométricos acotados en frecuencia). Sea  $N \geq 1$  y  $x_j = \frac{2\pi j}{N}$ ,  $j = 0, \dots, N-1$ . Entonces la regla trapezoidal periódica de  $N$  puntos es exacta para todo

$$p(x) = \sum_{|k| \leq d} c_k e^{ikx}$$

tal que  $d \leq N-1$ , es decir,

$$\int_0^{2\pi} p(x) dx = \frac{2\pi}{N} \sum_{j=0}^{N-1} p(x_j).$$

*Demostración.* Se aplica el Lema 4.22 con  $M = N$ : para cada modo  $e^{ikx}$  con  $|k| \leq d \leq N-1$ , si  $k \neq 0$  entonces  $k \not\equiv 0 \pmod{N}$ , y por lo tanto  $Q_k^{(N)} = I_k$ . Para  $k = 0$ , también vale  $Q_0^{(N)} = I_0 = 2\pi$ . Por linealidad en la suma finita de modos, se obtiene la igualdad anunciada. □

**Proposición 4.24** (Primera cota del error trapezoidal vía proyección). Sea  $f \in C_{per}([0, 2\pi])$ , sea  $N \geq 1$  y definamos

$$Q_N(f) := \frac{2\pi}{N} \sum_{j=0}^{N-1} f\left(\frac{2\pi j}{N}\right), \quad S_{N-1}f(x) := \sum_{|k| \leq N-1} \hat{f}_k e^{ikx}.$$

Entonces

$$\left| \int_0^{2\pi} f(x) dx - Q_N(f) \right| \leq 4\pi \|f - S_{N-1}f\|_\infty.$$

En particular,

$$\left| \int_0^{2\pi} f(x) dx - Q_N(f) \right| \leq 4\pi \sum_{|k| \geq N} |\hat{f}_k|.$$

*Demostración.* Como

$$S_{N-1}f(x) = \sum_{|k| \leq N-1} \hat{f}_k e^{ikx},$$

aplicamos el Corolario 4.23 con  $d := N - 1$ . La regla de  $N$  puntos es exacta para  $S_{N-1}f$ :

$$Q_N(S_{N-1}f) = \int_0^{2\pi} S_{N-1}f(x) dx.$$

Restando, con  $r_{N-1} := f - S_{N-1}f$ ,

$$\int_0^{2\pi} f(x) dx - Q_N(f) = \int_0^{2\pi} r_{N-1}(x) dx - Q_N(r_{N-1}).$$

Luego

$$\left| \int_0^{2\pi} r_{N-1} \right| \leq 2\pi \|r_{N-1}\|_\infty, \quad |Q_N(r_{N-1})| \leq \frac{2\pi}{N} \sum_{j=0}^{N-1} \|r_{N-1}\|_\infty = 2\pi \|r_{N-1}\|_\infty,$$

y por desigualdad triangular

$$\left| \int_0^{2\pi} f - Q_N(f) \right| \leq 4\pi \|r_{N-1}\|_\infty = 4\pi \|f - S_{N-1}f\|_\infty.$$

La segunda desigualdad se obtiene de

$$\|f - S_{N-1}f\|_\infty = \left\| \sum_{|k| \geq N} \hat{f}_k e^{ikx} \right\|_\infty \leq \sum_{|k| \geq N} |\hat{f}_k|. \quad \square$$

**Proposición 4.25** (Aliasing de los coeficientes discretos). Sea  $f \in C_{per}^2([0, 2\pi])$ . Para  $M \geq 1$  y  $|k| \leq M - 1$  se cumple:

$$\tilde{f}_k^{(M)} = \sum_{m \in \mathbb{Z}} \hat{f}_{k+mM}. \quad (4.10)$$

En particular,  $\tilde{f}_{k+M}^{(M)} = \tilde{f}_k^{(M)}$ .

*Demostración.* La periodicidad discreta en frecuencia es inmediata de la definición:

$$\tilde{f}_{k+M}^{(M)} = \frac{1}{M} \sum_{j=0}^{M-1} f(x_j) e^{-i(k+M)x_j} = \frac{1}{M} \sum_{j=0}^{M-1} f(x_j) e^{-ikx_j} e^{-iMx_j} = \tilde{f}_k^{(M)},$$

porque  $Mx_j = 2\pi j$ .

Para la fórmula de aliasing, expandimos  $f$  en serie de Fourier. Como  $f \in C_{per}^2$ , por el Teorema C.7 del Apéndice C, la serie converge absoluta y uniformemente; en particular,

$$\sum_{\ell \in \mathbb{Z}} |\hat{f}_\ell| < \infty.$$

Esta convergencia absoluta es la que permite intercambiar la suma infinita en  $\ell$  con la suma finita en  $j$ :

$$\tilde{f}_k^{(M)} = \frac{1}{M} \sum_{j=0}^{M-1} f(x_j) e^{-ikx_j} = \frac{1}{M} \sum_{j=0}^{M-1} \left( \sum_{\ell \in \mathbb{Z}} \hat{f}_\ell e^{i\ell x_j} \right) e^{-ikx_j} = \frac{1}{M} \sum_{j=0}^{M-1} \sum_{\ell \in \mathbb{Z}} \hat{f}_\ell e^{i\ell x_j} e^{-ikx_j}.$$

Como

$$e^{i\ell x_j} e^{-ikx_j} = e^{i(\ell-k)x_j},$$

se obtiene

$$\tilde{f}_k^{(M)} = \frac{1}{M} \sum_{j=0}^{M-1} \sum_{\ell \in \mathbb{Z}} \hat{f}_\ell e^{i(\ell-k)x_j} = \sum_{\ell \in \mathbb{Z}} \hat{f}_\ell \left( \frac{1}{M} \sum_{j=0}^{M-1} e^{i(\ell-k)x_j} \right),$$

y, usando  $x_j = 2\pi j/M$ ,

$$e^{i(\ell-k)x_j} = e^{i(\ell-k)2\pi j/M}.$$

Por el Lema 4.22, el paréntesis vale 1 si  $\ell - k$  es múltiplo de  $M$  y 0 en caso contrario. Entonces sobreviven exactamente los índices  $\ell = k + mM$ :

$$\tilde{f}_k^{(M)} = \sum_{m \in \mathbb{Z}} \hat{f}_{k+mM}.$$

□

**Corolario 4.26** (Cota explícita del error usando  $|\hat{f}_k| = O(|k|^{-n})$ ). Sea  $f \in C_{per}([0, 2\pi])$  y supongamos que existen  $n > 1$  y  $C_n > 0$  tales que

$$|\hat{f}_k| \leq C_n |k|^{-n}, \quad k \neq 0.$$

Entonces, para todo  $N \geq 2$ ,

$$\left| \int_0^{2\pi} f(x) dx - Q_N(f) \right| \leq 8\pi C_n \sum_{k=N}^{\infty} k^{-n} \leq \frac{8\pi C_n}{n-1} (N-1)^{1-n} = O(N^{1-n}).$$

*Demostración.* Por la Proposición 4.24,

$$\left| \int_0^{2\pi} f - Q_N(f) \right| \leq 4\pi \sum_{|k| \geq N} |\hat{f}_k|.$$

Usando la hipótesis de decaimiento y simetría de índices,

$$\sum_{|k| \geq N} |\hat{f}_k| \leq C_n \sum_{|k| \geq N} |k|^{-n} = 2C_n \sum_{k=N}^{\infty} k^{-n}.$$

Luego

$$\left| \int_0^{2\pi} f - Q_N(f) \right| \leq 8\pi C_n \sum_{k=N}^{\infty} k^{-n}.$$

Finalmente, por comparación integral para  $n > 1$ ,

$$\sum_{k=N}^{\infty} k^{-n} \leq \int_{N-1}^{\infty} x^{-n} dx = \frac{(N-1)^{1-n}}{n-1},$$

y se obtiene la cota anunciada.  $\square$

**Teorema 4.27** (Convergencia espectral del trapecio periódico). *Sea  $f \in C_{per}^n([0, 2\pi])$  con  $n \geq 2$  y sea*

$$x_j = \frac{2\pi j}{2N+1}, \quad j = 0, \dots, 2N.$$

*Entonces el error de la regla del trapecio periódica con  $2N+1$  nodos satisface:*

$$\left| \int_0^{2\pi} f(x) dx - \frac{2\pi}{2N+1} \sum_{j=0}^{2N} f(x_j) \right| = O((2N+1)^{-n}) = O(N^{-n}).$$

*Para  $f \in C_{per}^{\infty}$ , la convergencia es más rápida que cualquier potencia de  $1/N$  (**convergencia espectral**).*

*Demostración.* La Proposición 4.24 ya da una primera estimación del error en términos del resto de proyección. A continuación usamos aliasing para obtener una cota más ajustada: en lugar de sumar toda la cola  $|k| > N$ , sólo intervienen los modos resonantes  $k = m(2N+1)$ .

Por la Proposición 4.25 con  $M = 2N+1$  y  $k = 0$ :

$$\tilde{f}_0^{(2N+1)} = \sum_{m \in \mathbb{Z}} \hat{f}_{m(2N+1)} = \hat{f}_0 + \sum_{m \neq 0} \hat{f}_{m(2N+1)}.$$

Como  $\tilde{f}_0^{(2N+1)} = \frac{1}{2N+1} \sum_{j=0}^{2N} f(x_j)$  y  $\int_0^{2\pi} f(x) dx = 2\pi \hat{f}_0$ , el error es

$$\frac{2\pi}{2N+1} \sum_{j=0}^{2N} f(x_j) - \int_0^{2\pi} f(x) dx = 2\pi \sum_{m \neq 0} \hat{f}_{m(2N+1)}.$$



Del Teorema de decaimiento,  $|\hat{f}_k| \leq C/|k|^n$ . Entonces:

$$\left| \sum_{m \neq 0} \hat{f}_{m(2N+1)} \right| \leq \sum_{m \neq 0} \frac{C}{|m(2N+1)|^n} = \frac{C}{(2N+1)^n} \cdot 2 \sum_{m=1}^{\infty} \frac{1}{m^n} = \frac{2C \zeta(n)}{(2N+1)^n} = O((2N+1)^{-n}).$$

□

Aquí  $\zeta(n) := \sum_{m=1}^{\infty} m^{-n}$  es la función zeta de Riemann (bien definida para  $n > 1$ ).

**Observación 4.28** (Contraste con funciones no periódicas). *Para una función  $f \in C^m([a, b])$  no periódica, la regla del trapecio solo tiene error  $O(M^{-2})$ , independientemente de la suavidad de  $f$ . La periodicidad elimina los errores en los extremos del intervalo y permite aprovechar plenamente la suavidad de la función.*

**Teorema 4.29** (Error de interpolación trigonométrica). *Sea  $f \in C_{per}^m([0, 2\pi])$  con  $m \geq 2$ . Entonces:*

$$\|f - I_N f\|_{\infty} \leq 2 \sum_{|k| > N} |\hat{f}_k|.$$

Como  $|\hat{f}_k| = O(|k|^{-m})$ , esta cota es  $O(N^{1-m})$ .

*Demostración.* Descomponemos el error de interpolación usando la proyección como término intermedio. Como  $I_N$  reproduce exactamente los polinomios trigonométricos de grado  $\leq N$  (es decir,  $I_N(S_N f) = S_N f$ ), tenemos:

$$f - I_N f = \underbrace{(f - S_N f)}_{\text{cola de la serie}} - \underbrace{I_N(f - S_N f)}_{\text{aliasing}}.$$

**Cota de la cola.** Usando  $|e^{ikx}| = 1$ :

$$\|f - S_N f\|_{\infty} = \left\| \sum_{|k| > N} \hat{f}_k e^{ikx} \right\|_{\infty} \leq \sum_{|k| > N} |\hat{f}_k|.$$

**Cota del aliasing.** El polinomio trigonométrico  $I_N(f - S_N f)$  tiene coeficientes  $\tilde{f}_k - \hat{f}_k$  para  $|k| \leq N$ . Por la fórmula de aliasing (4.10) (aplicada con  $M = 2N + 1$ ):

$$\tilde{f}_k - \hat{f}_k = \sum_{m \neq 0} \hat{f}_{k+m(2N+1)}.$$

Crucialmente, la función  $k \mapsto k + m(2N+1)$  es inyectiva: cada coeficiente  $\hat{f}_j$  con  $|j| > N$  aparece como “alias” de **exactamente un** coeficiente  $\tilde{f}_k$  con  $|k| \leq N$  (el único  $k \in \{-N, \dots, N\}$  tal que  $j \equiv k \pmod{2N+1}$ ). Por lo tanto:

$$\sum_{|k| \leq N} |\tilde{f}_k - \hat{f}_k| \leq \sum_{|j| > N} |\hat{f}_j|.$$

Usando esta cota y  $|e^{ikx}| = 1$ :

$$\|I_N(f - S_N f)\|_{\infty} \leq \sum_{|k| \leq N} |\tilde{f}_k - \hat{f}_k| \leq \sum_{|j| > N} |\hat{f}_j|.$$

**Conclusión.** Sumando ambas contribuciones:

$$\|f - I_N f\|_\infty \leq \sum_{|k|>N} |\hat{f}_k| + \sum_{|j|>N} |\hat{f}_j| = 2 \sum_{|k|>N} |\hat{f}_k|. \quad \square$$

**Observación 4.30.** El factor 2 tiene una interpretación clara: la cola de la serie contribuye una vez al error (lo que “falta” por truncar), y los mismos coeficientes de alta frecuencia contribuyen una segunda vez por aliasing (lo que se “pliega” y contamina los coeficientes discretos de baja frecuencia). Para funciones muy suaves, donde los coeficientes de alta frecuencia son despreciables, la interpolación es prácticamente tan buena como la proyección.

**Corolario 4.31** (Convergencia de alto orden de la interpolación trigonométrica). Sea  $f \in C_{per}^n([0, 2\pi])$  con  $n \geq 2$ . Entonces

$$\|f - I_N f\|_\infty = O(N^{\frac{1}{2}-n}).$$

Si  $f \in C_{per}^\infty([0, 2\pi])$ , la convergencia es super-algebraica.

*Demostración.* Por el Teorema 4.29, cuya demostración combina la descomposición del error con la fórmula de aliasing (4.10),

$$\|f - I_N f\|_\infty \leq 2 \sum_{|k|>N} |\hat{f}_k|.$$

Para  $k \neq 0$ , vale

$$\hat{f}_k = \frac{\widehat{f^{(n)}}_k}{(ik)^n}.$$

Aplicando Cauchy–Schwarz,

$$\sum_{|k|>N} |\hat{f}_k| = \sum_{|k|>N} \frac{|\widehat{f^{(n)}}_k|}{|k|^n} \leq \left( \sum_{|k|>N} |\widehat{f^{(n)}}_k|^2 \right)^{1/2} \left( \sum_{|k|>N} |k|^{-2n} \right)^{1/2}.$$

Por Bessel (Teorema C.16),

$$\sum_{k \in \mathbb{Z}} |\widehat{f^{(n)}}_k|^2 \leq \frac{\|f^{(n)}\|_2^2}{2\pi},$$

y por comparación integral,

$$\sum_{|k|>N} |k|^{-2n} = O(N^{1-2n}).$$

En consecuencia,

$$\sum_{|k|>N} |\hat{f}_k| = O(N^{\frac{1}{2}-n}),$$

y por lo tanto  $\|f - I_N f\|_\infty = O(N^{\frac{1}{2}-n})$ .

Si  $f \in C_{per}^\infty([0, 2\pi])$ , para todo  $q \in \mathbb{N}$  puede repetirse el argumento con  $q$  derivadas y se obtiene  $\|f - I_N f\|_\infty = O(N^{\frac{1}{2}-q})$  para todo  $q$ , es decir, convergencia super-algebraica.  $\square$

**Observación 4.32** (Mejora adicional bajo regularidad Hölder). Si además  $f^{(n)}$  es Hölder (de exponente  $\alpha \in (0, 1]$ ), los coeficientes de Fourier decaen más rápido que en el caso meramente  $C^n$ . Insertando ese decaimiento mejorado en la misma estrategia (cota de cola + aliasing) se gana orden adicional, según  $\alpha$ .

#### 4.1.4 El fenómeno de Gibbs

Las series de Fourier son extraordinariamente efectivas para funciones periódicas. Sin embargo, presentan limitaciones significativas cuando se aplican a funciones no periódicas:

1. **Fenómeno de Gibbs:** Si  $f$  no es periódica, su extensión periódica presenta discontinuidades en los extremos, causando oscilaciones cerca de estos puntos que no desaparecen al aumentar el número de términos.
2. **Convergencia lenta:** Para funciones suaves pero no periódicas, la convergencia de la serie de Fourier es típicamente algebraica en lugar de exponencial.
3. **Condiciones de frontera:** Es difícil imponer condiciones de frontera específicas usando bases trigonométricas.

**Ejemplo 4.33** (La función  $f(x) = x$  y el fenómeno de Gibbs). *Consideremos  $f(x) = x$  en  $[-\pi, \pi]$ . La función es suave, pero no es periódica:  $f(-\pi) = -\pi \neq \pi = f(\pi)$ . Su extensión  $2\pi$ -periódica tiene un salto de magnitud  $2\pi$  en cada punto  $x = (2k+1)\pi$ .*

*La serie de Fourier de  $f$  se calcula por integración por partes:*

$$f(x) = \sum_{k=1}^{\infty} \frac{2(-1)^{k+1}}{k} \sin(kx) = 2 \sin x - \sin 2x + \frac{2}{3} \sin 3x - \dots$$

*La serie converge a  $f(x)$  para todo  $x \in (-\pi, \pi)$ , pero los coeficientes decaen como  $O(1/k)$ : la convergencia es muy lenta.*

*La Figura 4.1 muestra las sumas parciales  $S_N(x) = \sum_{k=1}^N \frac{2(-1)^{k+1}}{k} \sin(kx)$  para varios valores de  $N$ . Se observa claramente el fenómeno de Gibbs: cerca de los puntos de discontinuidad  $x = \pm\pi$ , la suma parcial presenta una oscilación que sobrepasa el valor de la función en aproximadamente un 9% del salto ( $\approx 0.18\pi \approx 0.5655$ ). Esta oscilación no desaparece al aumentar  $N$ : se estrecha, pero su altura converge a un valor fijo.*

#### 4.1.5 Aplicaciones: ODEs periódicas y ecuaciones integrales

El esquema para resolver problemas periódicos por Fourier se resume en tres pasos:

1. diagonalizar el operador en la base  $\{e^{ikx}\}$ ;
2. escribir la relación modal entre coeficientes;
3. estimar la cola por Parseval para truncamiento (Corolario 4.10) más decaimiento de coeficientes.

**Teorema 4.34** (Error de truncamiento para operadores diagonales en Fourier). *Sea  $L$  un operador lineal periódico tal que*

$$L[e^{ikx}] = \lambda_k e^{ikx}, \quad \lambda_k \neq 0 \quad \forall k \in \mathbb{Z}.$$

*Si  $Lu = f$ , con*

$$f(x) = \sum_{k \in \mathbb{Z}} \hat{f}_k e^{ikx}, \quad u(x) = \sum_{k \in \mathbb{Z}} \hat{u}_k e^{ikx},$$




Figure 4.1: Sumas parciales de la serie de Fourier de  $f(x) = x$  para  $N = 3, 7, 25, 100$ . Las oscilaciones cerca de  $x = \pm\pi$  (fenómeno de Gibbs) no desaparecen al aumentar  $N$ .

entonces  $\hat{u}_k = \hat{f}_k / \lambda_k$ , y para el truncado  $u_N = \sum_{|k| \leq N} \hat{u}_k e^{ikx}$ :

$$\|u - u_N\|_2^2 = 2\pi \sum_{|k| > N} \frac{|\hat{f}_k|^2}{|\lambda_k|^2}. \quad (4.11)$$

Además, si existen  $p, m, c, C > 0$  tales que para  $|k|$  grande

$$|\hat{f}_k| \leq C|k|^{-p}, \quad |\lambda_k| \geq c|k|^m,$$

y  $p + m > \frac{1}{2}$ , se obtiene

$$\|u - u_N\|_2 = O(N^{\frac{1}{2} - (p+m)}).$$

*Demostración.* La relación modal  $\hat{u}_k = \hat{f}_k / \lambda_k$  sale de comparar coeficientes de Fourier en  $Lu = f$ . La identidad (4.11) es el Corolario 4.10 aplicado a  $u$ :

$$\|u - u_N\|_2^2 = 2\pi \sum_{|k| > N} |\hat{u}_k|^2 = 2\pi \sum_{|k| > N} \frac{|\hat{f}_k|^2}{|\lambda_k|^2}.$$

Con las hipótesis de decaimiento/crecimiento,

$$\frac{|\hat{f}_k|^2}{|\lambda_k|^2} \leq \frac{C^2}{c^2} |k|^{-2(p+m)},$$

y la cola de p-serie da

$$\sum_{|k|>N} |k|^{-2(p+m)} = O(N^{1-2(p+m)}),$$

de donde el resultado al tomar raíz cuadrada.  $\square$

**Corolario 4.35** (Ejemplo: Schrödinger 1D estacionaria periódica). *Sea  $V_0 > 0$  y considere*

$$-\psi''(x) + V_0\psi(x) = f(x), \quad x \in [0, 2\pi],$$

*con condiciones periódicas en  $\psi$  y  $\psi'$ . Entonces*

$$\hat{\psi}_k = \frac{\hat{f}_k}{k^2 + V_0},$$

*y, si  $f \in C_{per}^n([0, 2\pi])$  con  $n \geq 1$ ,*

$$\|\psi - \psi_N\|_2 = O(N^{-(n+\frac{3}{2})}).$$

*Demostración.* Aquí  $\lambda_k = k^2 + V_0 \sim k^2$  (es decir,  $m = 2$ ). Por el Teorema 4.17,  $|\hat{f}_k| = O(|k|^{-n})$  (o sea,  $p = n$ ). Aplicando el Teorema 4.34:

$$\|\psi - \psi_N\|_2 = O(N^{\frac{1}{2}-(n+2)}) = O(N^{-(n+\frac{3}{2})}).$$

$\square$

**Proposición 4.36** (Convolución periódica y producto de coeficientes de Fourier). *Sean  $k, u \in C_{per}([0, 2\pi]; \mathbb{C})$  y definamos*

$$(k * u)(x) := \frac{1}{2\pi} \int_0^{2\pi} k(x-t)u(t) dt.$$

*Entonces, para todo  $n \in \mathbb{Z}$ ,*

$$\widehat{(k * u)}_n = \hat{k}_n \hat{u}_n.$$

*En particular, la serie de Fourier de  $k * u$  es*

$$(k * u)(x) \sim \sum_{n \in \mathbb{Z}} \hat{k}_n \hat{u}_n e^{inx}.$$

*Demostración.* Usando la definición de coeficiente de Fourier y Fubini (en dominio compacto e integrando continuo),

$$\widehat{(k * u)}_n = \frac{1}{2\pi} \int_0^{2\pi} \left( \frac{1}{2\pi} \int_0^{2\pi} k(x-t)u(t) dt \right) e^{-inx} dx = \frac{1}{2\pi} \int_0^{2\pi} u(t) \left( \frac{1}{2\pi} \int_0^{2\pi} k(x-t)e^{-inx} dx \right) dt.$$

En la integral interna hacemos el cambio  $y = x - t$ ; por periodicidad,

$$\frac{1}{2\pi} \int_0^{2\pi} k(x-t)e^{-inx} dx = \frac{1}{2\pi} \int_0^{2\pi} k(y)e^{-in(y+t)} dy = e^{-int} \hat{k}_n.$$

Sustituyendo,

$$\widehat{(k * u)}_n = \hat{k}_n \frac{1}{2\pi} \int_0^{2\pi} u(t)e^{-int} dt = \hat{k}_n \hat{u}_n.$$

Esto prueba la identidad modal, y la expresión de la serie resulta inmediata al reemplazar los coeficientes de Fourier de  $k * u$ .  $\square$

**Observación 4.37** (Convolución periódica). *Para la ecuación integral  $Ku = f$  con*

$$(Ku)(x) = \frac{1}{2\pi} \int_0^{2\pi} k(x-t)u(t) dt,$$

por la Proposición 4.36 se tiene

$$\widehat{Ku}_n = \hat{k}_n \hat{u}_n.$$

Por lo tanto, si  $\hat{k}_n \neq 0$ , entonces  $\hat{u}_n = \hat{f}_n / \hat{k}_n$ , y por Parseval

$$\|u - u_N\|_2^2 = 2\pi \sum_{|n| > N} \frac{|\hat{f}_n|^2}{|\hat{k}_n|^2}.$$

Análogamente, para  $(I + K)u = f$ :

$$\hat{u}_n = \frac{\hat{f}_n}{1 + \hat{k}_n}, \quad \|u - u_N\|_2^2 = 2\pi \sum_{|n| > N} \frac{|\hat{f}_n|^2}{|1 + \hat{k}_n|^2}.$$

Estas fórmulas son la base para discutir orden de convergencia y estabilidad modal en problemas periódicos lineales.

## 4.2 Series de Chebyshev

Las series de Fourier son una herramienta poderosa para aproximar funciones periódicas, ofreciendo convergencia espectral para funciones suaves. Sin embargo, la mayoría de las funciones que encontramos en aplicaciones (como soluciones de ecuaciones diferenciales con condiciones de frontera) no son periódicas. Si intentamos aproximar una función no periódica  $f(x)$  en  $[-1, 1]$  usando series de Fourier, nos encontramos con el fenómeno de Gibbs en los extremos, lo que destruye la convergencia uniforme. ¿Podemos de alguna manera "salvar" la convergencia espectral para funciones no periódicas? La respuesta es sí, mediante un simple cambio de variable.

### 4.2.1 De Fourier a Chebyshev: El cambio de variable coseno

Consideremos una función  $f(x)$  definida en  $[-1, 1]$ . Hacemos el cambio de variable:

$$x = \cos(\theta), \quad \theta \in [0, \pi].$$

Definimos una nueva función  $g(\theta)$  compuesta:

$$g(\theta) = f(\cos(\theta)).$$

Esta función  $g(\theta)$  es  $2\pi$ -periódica, y además es suave si  $f$  es suave, como muestra el siguiente Lema.

**Lema 4.38** (Suavidad y periodicidad en el intervalo  $(-\pi, \pi)$  con pegado en  $\pm\pi$ ). *Sea  $f \in C^m([-1, 1])$  con  $m \geq 0$ , y definamos*

$$g(\theta) := f(\cos \theta), \quad \theta \in [-\pi, \pi].$$

*Entonces  $g \in C^m([-\pi, \pi])$  y, para todo  $0 \leq j \leq m$ ,*

$$g^{(j)}(-\pi) = g^{(j)}(\pi).$$

*Demostración.* Primero, en el interior  $(-\pi, \pi)$  tenemos  $\cos \theta \in (-1, 1)$ . Como  $f \in C^m([-1, 1])$ , aplicando iteradamente la regla de la cadena (Teorema A.4) y la regla del producto, concluimos que  $g \in C^m((-\pi, \pi))$ . Para justificar la suavidad en los bordes, un camino muy directo consiste en construir una extensión suave de  $f$  a todo  $\mathbb{R}$  que coincida con  $f$  en  $[-1, 1]$ . Luego, al componer con el coseno, obtendremos una función periódica suave que coincide con  $g$  en  $[-\pi, \pi]$ . En una dimensión, una construcción simple es pegar los polinomios de Taylor de orden  $m$  en  $\pm 1$ :

$$P_{-1}(x) := \sum_{k=0}^m \frac{f^{(k)}(-1)}{k!} (x+1)^k, \quad P_1(x) := \sum_{k=0}^m \frac{f^{(k)}(1)}{k!} (x-1)^k,$$

$$\tilde{f}(x) := \begin{cases} P_{-1}(x), & x < -1, \\ f(x), & -1 \leq x \leq 1, \\ P_1(x), & x > 1. \end{cases}$$

Definimos entonces

$$G(\theta) := \tilde{f}(\cos \theta), \quad \theta \in \mathbb{R}.$$

De nuevo por regla de la cadena,  $G \in C^m(\mathbb{R})$ . Además, como  $\cos(\theta + 2\pi) = \cos \theta$ , se tiene  $G(\theta + 2\pi) = G(\theta)$ , y por lo tanto

$$G^{(j)}(\theta + 2\pi) = G^{(j)}(\theta), \quad 0 \leq j \leq m.$$

Finalmente, en  $[-\pi, \pi]$  vale  $\cos \theta \in [-1, 1]$ , luego

$$g(\theta) = f(\cos \theta) = \tilde{f}(\cos \theta) = G(\theta).$$

Así,  $g$  es la restricción de  $G$  a  $[-\pi, \pi]$ , en particular  $g \in C^m([\pi, \pi])$ , y

$$g^{(j)}(-\pi) = G^{(j)}(-\pi) = G^{(j)}(\pi) = g^{(j)}(\pi), \quad 0 \leq j \leq m.$$

□

Este lema es la razón fundamental por la que las series de Chebyshev evitan el fenómeno de Gibbs: la composición con el coseno convierte cualquier función suave en  $[-1, 1]$  en una función suave y periódica en  $[-\pi, \pi]$ , a la cual podemos aplicar la teoría de Fourier sin problemas de convergencia.

Como  $g$  es par, la serie solo tiene términos cosenos:

$$g(\theta) = \frac{a_0}{2} + \sum_{k=1}^{\infty} a_k \cos(k\theta),$$

con coeficientes  $a_k = \frac{2}{\pi} \int_0^{\pi} g(\theta) \cos(k\theta) d\theta$ .

**Observación 4.39.** *La demostración del lema 4.38 muestra que no hay nada especial en la función coseno: cualquier función suave y periódica, con imagen en  $[-1, 1]$ , serviría para evitar el fenómeno de Gibbs. Sin embargo, el coseno es la elección natural por su simplicidad y por las propiedades adicionales que veremos a continuación.*

### 4.2.2 Los polinomios de Chebyshev y la serie de Chebyshev

Cuando volvemos a la variable original  $x = \cos \theta$ , se obtienen los polinomios de Chebyshev  $T_k(x) = \cos(k \arccos x)$ , y la serie de Fourier en cosenos se traduce en la serie de Chebyshev.

**Definición 4.40** (Polinomios de Chebyshev). *Para cada entero  $k \geq 0$ , definimos el **polinomio de Chebyshev**  $T_k : [-1, 1] \rightarrow \mathbb{R}$  por:*

$$T_k(x) = \cos(k \arccos x).$$

La definición es natural:  $T_k$  es simplemente la función  $\cos(k\theta)$  expresada en la variable  $x = \cos \theta$ . En otras palabras,  $T_k(\cos \theta) = \cos(k\theta)$ . Con esta notación, la serie de Fourier en cosenos de  $g(\theta) = f(\cos \theta)$  se reescribe directamente en la variable original:

**Definición 4.41** (Serie de Chebyshev). *Dada  $f \in C([-1, 1])$ , su **serie de Chebyshev** es:*

$$f(x) = \frac{a_0}{2} + \sum_{k=1}^{\infty} a_k T_k(x),$$

con coeficientes  $a_k = \frac{2}{\pi} \int_{-1}^1 f(x) T_k(x) \frac{dx}{\sqrt{1-x^2}}$  (obtenidos del cambio  $x = \cos \theta$  en la fórmula  $a_k = \frac{2}{\pi} \int_0^{\pi} g(\theta) \cos(k\theta) d\theta$ ).

La serie de Chebyshev no es otra cosa que la serie de Fourier en cosenos de  $g$ , traducida a la variable  $x$  mediante la correspondencia  $\cos(k\theta) \leftrightarrow T_k(x)$ . Por lo tanto, hereda inmediatamente todas las propiedades de convergencia de la serie de Fourier.

**Teorema 4.42** (Decaimiento de coeficientes de Chebyshev). *Si  $f \in C^m([-1, 1])$  con  $m \geq 1$ , entonces sus coeficientes de Chebyshev satisfacen:*

$$|a_k| = O(k^{-m}).$$



*Demostración.* Por el Lema 4.38,  $g(\theta) = f(\cos \theta)$  es  $C^m$  en  $[-\pi, \pi]$  y satisface periodicidad de borde hasta orden  $m$ . Definiendo  $\tilde{g}(t) := g(t - \pi)$  en  $[0, 2\pi]$ , se tiene  $\tilde{g} \in C_{per}^m([0, 2\pi])$ . Los coeficientes  $a_k$  son los coeficientes de Fourier en cosenos de  $g$  (equivalentemente, de  $\tilde{g}$  tras corrimiento). Aplicando el Teorema 4.17 a  $\tilde{g}$ , obtenemos  $|a_k| = O(k^{-m})$ .  $\square$

Esto significa que para funciones suaves (pero no necesariamente periódicas), la serie de Chebyshev converge tan rápido como la serie de Fourier para funciones periódicas de la misma regularidad.

Hasta aquí, las funciones  $T_k(x) = \cos(k \arccos x)$  son simplemente funciones trigonométricas compuestas unas con otras. El siguiente resultado, quizás sorprendente, muestra que en realidad son *polinomios*.

**Teorema 4.43.** *Para cada  $k \geq 0$ , la función  $T_k(x) = \cos(k \arccos x)$  es un polinomio de grado exactamente  $k$ , con coeficiente líder  $2^{k-1}$  para  $k \geq 1$ .*

*Demostración.* La clave es la identidad trigonométrica  $\cos((k+1)\theta) = 2 \cos \theta \cos(k\theta) - \cos((k-1)\theta)$ , que se traduce en la **recurrencia de tres términos**:

$$T_{k+1}(x) = 2x T_k(x) - T_{k-1}(x), \quad k \geq 1.$$

Las condiciones iniciales son  $T_0(x) = \cos(0) = 1$  y  $T_1(x) = \cos(\arccos x) = x$ . Ambos son polinomios (de grados 0 y 1 respectivamente). Como el lado derecho de la recurrencia es un polinomio si  $T_k$  y  $T_{k-1}$  lo son, por inducción  $T_k$  es un polinomio para todo  $k$ . Además, si  $T_k$  tiene grado  $k$  con coeficiente líder  $c_k$ , entonces  $T_{k+1}$  tiene grado  $k+1$  con coeficiente líder  $2c_k$ , lo que da  $c_k = 2^{k-1}$  para  $k \geq 1$ .  $\square$

**Ejemplo 4.44** (Primeros polinomios de Chebyshev). *Aplicando la recurrencia:*

$$\begin{aligned} T_0(x) &= 1, \\ T_1(x) &= x, \\ T_2(x) &= 2x^2 - 1, \\ T_3(x) &= 4x^3 - 3x, \\ T_4(x) &= 8x^4 - 8x^2 + 1. \end{aligned}$$

*Se puede verificar directamente:*  $T_2(\cos \theta) = 2 \cos^2 \theta - 1 = \cos(2\theta)$  y  $T_3(\cos \theta) = 4 \cos^3 \theta - 3 \cos \theta = \cos(3\theta)$ , que son las identidades trigonométricas clásicas del ángulo doble y triple.

### 4.2.3 Ortogonalidad

La ortogonalidad de las funciones trigonométricas  $\{\cos(k\theta)\}$  se transfiere, vía el cambio de variable  $x = \cos \theta$ , a una relación de ortogonalidad para los polinomios de Chebyshev.

**Teorema 4.45** (Ortogonalidad de los polinomios de Chebyshev). *Los polinomios de Chebyshev son ortogonales respecto al peso  $w(x) = (1 - x^2)^{-1/2}$  en  $[-1, 1]$ :*

$$\int_{-1}^1 T_j(x) T_k(x) \frac{dx}{\sqrt{1-x^2}} = \begin{cases} \pi & \text{si } j = k = 0, \\ \pi/2 & \text{si } j = k \neq 0, \\ 0 & \text{si } j \neq k. \end{cases}$$

*Demostración.* Hacemos el cambio  $x = \cos \theta$ ,  $dx = -\sin \theta d\theta$ , y  $\sqrt{1-x^2} = \sin \theta$ :

$$\int_{-1}^1 T_j(x) T_k(x) \frac{dx}{\sqrt{1-x^2}} = \int_0^\pi \cos(j\theta) \cos(k\theta) d\theta.$$

La integral del lado derecho satisface

$$\int_0^\pi \cos(j\theta) \cos(k\theta) d\theta = \begin{cases} \pi, & j = k = 0, \\ \pi/2, & j = k \neq 0, \\ 0, & j \neq k. \end{cases} \quad (4.12)$$

y esto prueba la ortogonalidad enunciada.  $\square$

**Observación 4.46** (Raíces y extremos de  $T_k$ ). *De la identidad  $T_k(\cos \theta) = \cos(k\theta)$  se deducen inmediatamente:*

- (a) **Raíces:**  $T_k(x_j) = 0$  con  $x_j = \cos\left(\frac{(2j+1)\pi}{2k}\right)$  para  $j = 0, \dots, k-1$ . Son los nodos de Chebyshev.
- (b) **Extremos:**  $|T_k(x)| = 1$  en los puntos  $x_j = \cos(j\pi/k)$  para  $j = 0, \dots, k$ , alternando entre  $+1$  y  $-1$ .
- (c) **Acotación:**  $|T_k(x)| \leq 1$  para todo  $x \in [-1, 1]$ .

#### 4.2.4 Interpolación baricéntrica y matriz de diferenciación de Chebyshev

Para aplicaciones numéricas, suele preferirse la interpolación en los nodos de Chebyshev–Lobatto

$$x_j = \cos\left(\frac{j\pi}{N}\right), \quad j = 0, \dots, N.$$

Si  $u_j = u(x_j)$ , el interpolante  $p_N \in \mathcal{P}_N$  puede escribirse en forma baricéntrica:

$$p_N(x) = \frac{\sum_{j=0}^N \frac{\lambda_j}{x - x_j} u_j}{\sum_{j=0}^N \frac{\lambda_j}{x - x_j}}, \quad x \neq x_0, \dots, x_N,$$

donde

$$\lambda_j = \frac{1}{\prod_{m \neq j} (x_j - x_m)}.$$

**Proposición 4.47** (Pesos baricéntricos explícitos en nodos de Chebyshev–Lobatto). *Para  $x_j = \cos(j\pi/N)$  se tiene*

$$\lambda_j = \kappa (-1)^j \delta_j, \quad \delta_0 = \delta_N = \frac{1}{2}, \quad \delta_j = 1 \quad (1 \leq j \leq N-1),$$

con una constante global  $\kappa \neq 0$  independiente de  $j$ .

*Demostración.* Es la fórmula cerrada estándar para nodos de Chebyshev–Lobatto; se obtiene evaluando los productos  $\prod_{m \neq j} (x_j - x_m)$  mediante identidades trigonométricas. Omitimos esas cuentas porque aquí sólo se usa la estructura final de los pesos.  $\square$

**Observación 4.48** (Invariancia por factor constante). *En la fórmula baricéntrica, multiplicar todos los pesos por una misma constante no cambia  $p_N$ , porque ese factor aparece tanto en numerador como en denominador y se simplifica. Por eso, en la práctica se usan pesos normalizados equivalentes.*

Derivando la fórmula baricéntrica y evaluando en nodos se obtiene una matriz de diferenciación explícita.

**Teorema 4.49** (Matriz de diferenciación de Chebyshev). *Sea  $p_N$  el interpolante de  $u$  en los nodos  $x_j = \cos(j\pi/N)$  y defina*

$$\mathbf{u} = (u_0, \dots, u_N)^T, \quad \mathbf{p}' = (p'_N(x_0), \dots, p'_N(x_N))^T.$$

Entonces

$$\mathbf{p}' = D \mathbf{u},$$

donde, para  $i \neq j$ ,

$$D_{ij} = \frac{\lambda_j}{\lambda_i} \frac{1}{x_i - x_j},$$

y

$$D_{ii} = - \sum_{j \neq i} D_{ij}.$$

En particular, usando la normalización

$$c_0 = c_N = 2, \quad c_j = 1 \quad (1 \leq j \leq N-1),$$

los términos fuera de la diagonal quedan

$$D_{ij} = \frac{c_i}{c_j} \frac{(-1)^{i+j}}{x_i - x_j}, \quad i \neq j.$$

Además,

$$D_{ii} = -\frac{x_i}{2(1-x_i^2)}, \quad 1 \leq i \leq N-1, \quad D_{00} = \frac{2N^2+1}{6}, \quad D_{NN} = -\frac{2N^2+1}{6}.$$

*Demostración.* La fórmula general para  $D_{ij}$  se obtiene diferenciando la regla baricéntrica y tomando límite cuando  $x \rightarrow x_i$ . Las expresiones cerradas en nodos de Chebyshev–Lobatto resultan al sustituir la Proposición 4.47 y simplificar.  $\square$

Esta matriz es la base de los métodos pseudospectrales de Chebyshev: permite aproximar derivadas en nodos con precisión espectral para datos suaves.

### 4.2.5 Reglas de cuadratura en nodos de Chebyshev

Las mismas mallas de Chebyshev usadas para interpolar y derivar dan reglas de integración muy eficientes. La idea común es integrar un interpolante polinomial y trasladar la integral a una combinación lineal de valores nodales.

**Proposición 4.50** (Regla de Clenshaw–Curtis). *Sea  $f \in C([-1, 1])$  y sea  $I_N^{Ch} f \in \mathcal{P}_N$  su interpolante en nodos de Chebyshev–Lobatto*

$$x_j = \cos\left(\frac{j\pi}{N}\right), \quad j = 0, \dots, N.$$

*Definimos*

$$Q_N^{CC}(f) := \int_{-1}^1 I_N^{Ch} f(x) dx = \sum_{j=0}^N w_j^{CC} f(x_j), \quad w_j^{CC} := \int_{-1}^1 \ell_j(x) dx,$$

donde  $\ell_j$  son los polinomios de Lagrange asociados a los nodos. Entonces  $Q_N^{CC}$  es exacta sobre  $\mathcal{P}_N$  y satisface

$$\left| \int_{-1}^1 f(x) dx - Q_N^{CC}(f) \right| \leq 2 \|f - I_N^{Ch} f\|_{\infty}.$$

En particular, para funciones suaves, el error de Clenshaw–Curtis hereda el mismo orden del error de interpolación de Chebyshev.

*Demostración.* La exactitud en  $\mathcal{P}_N$  es inmediata porque  $I_N^{Ch} p = p$  para todo  $p \in \mathcal{P}_N$ . Además,

$$\int_{-1}^1 f - Q_N^{CC}(f) = \int_{-1}^1 (f - I_N^{Ch} f),$$

y la cota se obtiene por desigualdad triangular y longitud del intervalo.  $\square$

**Proposición 4.51** (Cálculo de pesos de Clenshaw–Curtis por DCT-I/FFT). *Sea  $N \geq 1$ ,  $x_j = \cos(j\pi/N)$  y  $c_0 = c_N = 2$ ,  $c_j = 1$  para  $1 \leq j \leq N-1$ . Definimos los momentos de Chebyshev*

$$\mu_k := \int_{-1}^1 T_k(x) dx, \quad \mu_0 = 2, \quad \mu_k = 0 \text{ (} k \text{ impar)}, \quad \mu_k = \frac{2}{1-k^2} \text{ (} k \geq 2 \text{ par)}.$$

Entonces los pesos de Clenshaw–Curtis en

$$Q_N^{CC}(f) = \sum_{j=0}^N w_j^{CC} f(x_j)$$

vienen dados por

$$w_j^{CC} = \frac{1}{c_j} \frac{2}{N} \sum_{k=0}^N \frac{\mu_k}{c_k} \cos\left(\frac{jk\pi}{N}\right), \quad j = 0, \dots, N.$$

Es decir,  $w^{CC}$  se obtiene aplicando una DCT-I al vector  $(\mu_k/c_k)_{k=0}^N$  y reescalando por  $(2/N)/c_j$ . Por lo tanto, los  $N+1$  pesos se calculan en costo  $O(N \log N)$  usando una implementación FFT de DCT-I.

*Demostración.* Escribimos el interpolante como

$$p_N(x) = \sum_{k=0}^N a_k T_k(x), \quad p_N(x_j) = f(x_j).$$

La transformada coseno discreta tipo I en nodos de Lobatto da

$$a_k = \frac{2}{N c_k} \sum_{j=0}^N \frac{1}{c_j} f(x_j) \cos\left(\frac{jk\pi}{N}\right).$$

Integrando término a término,

$$Q_N^{CC}(f) = \int_{-1}^1 p_N(x) dx = \sum_{k=0}^N a_k \mu_k.$$

Sustituyendo la expresión de  $a_k$  e intercambiando sumas finitas,

$$Q_N^{CC}(f) = \sum_{j=0}^N \left[ \frac{1}{c_j} \frac{2}{N} \sum_{k=0}^N \frac{\mu_k}{c_k} \cos\left(\frac{jk\pi}{N}\right) \right] f(x_j),$$

de donde se identifica la fórmula para  $w_j^{CC}$ . □

**Observación 4.52** (Anidamiento y adaptación en Clenshaw–Curtis). *A diferencia de otras reglas de orden alto (por ejemplo, las gaussianas), Clenshaw–Curtis es naturalmente anidada cuando se refina por duplicación  $N \mapsto 2N$ : los nodos de nivel  $N$  quedan contenidos en los de nivel  $2N$ . Esto permite construir estimadores de error baratos mediante diferencias entre niveles, por ejemplo*

$$\eta_N := |Q_{2N}^{CC}(f) - Q_N^{CC}(f)|,$$

*sin reevaluar  $f$  en los nodos ya usados. Esa reutilización de evaluaciones es la base de esquemas adaptativos robustos, donde se refina sólo en subintervalos con mayor error estimado.*

**Proposición 4.53** (Regla de Fejér tipo I). *Sea  $f \in C([-1, 1])$  y consideremos los nodos interiores de Chebyshev*

$$x_j = \cos\left(\frac{(2j-1)\pi}{2N}\right), \quad j = 1, \dots, N,$$

*que son las raíces de  $T_N$ . Si  $I_{N-1}^F f \in \mathcal{P}_{N-1}$  es el interpolante en esos nodos, definimos*

$$Q_N^F(f) := \int_{-1}^1 I_{N-1}^F f(x) dx = \sum_{j=1}^N w_j^F f(x_j), \quad w_j^F := \int_{-1}^1 \ell_j^F(x) dx.$$

*Entonces  $Q_N^F$  es exacta sobre  $\mathcal{P}_{N-1}$  y cumple*

$$\left| \int_{-1}^1 f(x) dx - Q_N^F(f) \right| \leq 2 \|f - I_{N-1}^F f\|_\infty.$$

*Para funciones analíticas, el error decrece espectralmente con  $N$ .*

*Demostración.* La demostración es idéntica a la de la Proposición 4.50, reemplazando la malla de Lobatto por la malla interior de Fejér.  $\square$

**Proposición 4.54** (Regla de Gauss–Chebyshev). *Para la integral con peso*

$$I_w(g) := \int_{-1}^1 \frac{g(x)}{\sqrt{1-x^2}} dx,$$

la regla gaussiana asociada al peso  $(1-x^2)^{-1/2}$  es

$$Q_N^{GC}(g) := \frac{\pi}{N} \sum_{j=1}^N g\left(\cos \frac{(2j-1)\pi}{2N}\right).$$

Esta regla es exacta para todo polinomio de grado  $\leq 2N-1$ .

Si se desea aproximar la integral sin peso,

$$\int_{-1}^1 f(x) dx,$$

se puede escribir

$$\int_{-1}^1 f(x) dx = \int_{-1}^1 \frac{\sqrt{1-x^2} f(x)}{\sqrt{1-x^2}} dx$$

y aplicar Gauss–Chebyshev a  $g(x) = \sqrt{1-x^2} f(x)$ . Esta reformulación es especialmente útil cuando la estructura del problema ya viene dada en términos del peso de Chebyshev.

*Demostración.* Es la propiedad general de las cuadraturas de Gauss: con  $N$  nodos, la regla asociada a una familia de polinomios ortogonales es exacta hasta grado  $2N-1$ . En este caso, los nodos son las raíces de  $T_N$  y los pesos son todos iguales a  $\pi/N$ .  $\square$

### 4.3 Polinomios Ortogonales

Para poder identificar el resto con una cola infinita de coeficientes hace falta, además de ortogonalidad, una hipótesis de densidad. En el caso de polinomios ortogonales sobre intervalos compactos, esa densidad se obtiene con Stone–Weierstrass.

**Teorema 4.55** (Densidad de polinomios en norma  $L_w^2$  para funciones continuas). *Sea  $[a, b]$  compacto y sea  $w \in L^1(a, b)$  con  $w(x) > 0$  para todo  $x \in (a, b)$ . Entonces, para toda  $f \in C([a, b])$  y todo  $\varepsilon > 0$ , existe un polinomio algebraico  $p$  tal que*

$$\|f - p\|_w < \varepsilon.$$

*Demostración.* Por Stone–Weierstrass, los polinomios son densos en  $C([a, b])$  para la norma uniforme. Dado  $\varepsilon > 0$ , existe  $p \in \mathbb{P}$  tal que

$$\|f - p\|_\infty < \frac{\varepsilon}{\sqrt{\int_a^b w(x) dx}}.$$

Entonces

$$\|f - p\|_w^2 = \int_a^b |f(x) - p(x)|^2 w(x) dx \leq \|f - p\|_\infty^2 \int_a^b w(x) dx < \varepsilon^2,$$

y por tanto  $\|f - p\|_w < \varepsilon$ .  $\square$

### 4.3.1 Familias clásicas de polinomios ortogonales

Cuando las funciones de la base  $\varphi_k$  son polinomios de grado  $k$ , hablamos de **polinomios ortogonales**. Las familias clásicas más importantes son:

| Familia         | Intervalo           | Peso $w(x)$      | Autovalor SL $\lambda_n$ |
|-----------------|---------------------|------------------|--------------------------|
| Legendre $P_n$  | $[-1, 1]$           | 1                | $n(n+1)$                 |
| Chebyshev $T_n$ | $[-1, 1]$           | $(1-x^2)^{-1/2}$ | $n^2$                    |
| Laguerre $L_n$  | $[0, \infty)$       | $e^{-x}$         | $n$                      |
| Hermite $H_n$   | $(-\infty, \infty)$ | $e^{-x^2}$       | $2n$                     |

La columna “Autovalor SL” se explica más adelante: será la herramienta para demostrar el decaimiento espectral en el caso general.

#### Propiedades compartidas por todas las familias clásicas:

1. **Recurrencia a tres términos:**  $P_{n+1}(x) = (A_n x + B_n)P_n(x) - C_n P_{n-1}(x)$ . Permite evaluar  $P_n(x)$  de forma estable y eficiente.
2. **Raíces reales simples:**  $P_n(x)$  tiene exactamente  $n$  raíces reales, simples y contenidas en  $(a, b)$ . Estas raíces son los nodos óptimos para cuadratura.

### 4.3.2 Tasa de convergencia para funciones suaves: un caso general

El resultado más profundo de esta teoría conecta la suavidad de una función con la velocidad de convergencia de su expansión en polinomios ortogonales. Esta conexión surge porque los polinomios clásicos son autofunciones de operadores diferenciales de **Sturm-Liouville**:

$$L[P_n] = -\frac{1}{w} \frac{d}{dx} \left( p(x) \frac{dP_n}{dx} \right) = \lambda_n P_n.$$

**Teorema 4.56** (Decaimiento espectral de coeficientes). *Sea  $f \in C^m([a, b])$  una función  $m$  veces diferenciable (compatible con las condiciones de frontera). Los coeficientes de su expansión  $c_n = \frac{(f, P_n)_w}{\|P_n\|_w^2}$  satisfacen:*

$$|c_n| = O(\lambda_n^{-m/2}).$$

Para Legendre y Chebyshev ( $\lambda_n \sim n^2$ ), esto implica  $|c_n| = O(n^{-m})$ .

*Demostración.* El operador de Sturm-Liouville  $L$  es formalmente autoadjunto respecto al producto interno con peso  $w$ . Más precisamente, para funciones  $u, v$  que satisfacen las condiciones de frontera apropiadas (que los polinomios ortogonales clásicos satisfacen automáticamente), se cumple la **identidad de Green-Lagrange**:

$$(Lu, v)_w = (u, Lv)_w,$$

donde  $(u, v)_w = \int_a^b u(x)v(x)w(x) dx$ . Esto se verifica por integración por partes: como  $L[u] = -\frac{1}{w} \frac{d}{dx} (p u')$ , tenemos  $\int L[u]v w = -\int (p u')' v$ , y al integrar por partes los términos de frontera se anulan gracias a que  $p(x)$  se anula en los extremos del intervalo para las familias clásicas (por ejemplo, para Legendre:  $p(x) = 1 - x^2$  en  $[-1, 1]$ ; para Chebyshev:  $p(x) = \sqrt{1 - x^2}$ ; para Laguerre:  $p(x) = x e^{-x}$ ).

Ahora, como  $L[P_n] = \lambda_n P_n$ , tenemos:

$$c_n \|P_n\|_w^2 = (f, P_n)_w = \frac{1}{\lambda_n} (f, L[P_n])_w = \frac{1}{\lambda_n} (L[f], P_n)_w,$$

donde la última igualdad usa la autoadjunción de  $L$  (válida si  $f$  satisface las condiciones de frontera; en caso contrario, aparecen términos de frontera que decaen con  $n$  y no afectan el orden asintótico).

Repitiendo el argumento  $k$  veces (si  $f \in C^{2k}$ ):

$$c_n \|P_n\|_w^2 = \frac{1}{\lambda_n^k} (L^k[f], P_n)_w.$$

Por la desigualdad de Cauchy-Schwarz:

$$|c_n| \|P_n\|_w^2 \leq \frac{1}{\lambda_n^k} \|L^k[f]\|_{L_w^2} \|P_n\|_{L_w^2}.$$

Distribuyendo:

$$|c_n| \leq \frac{\|L^k[f]\|_{L_w^2}}{\lambda_n^k \|P_n\|_{L_w^2}}.$$

Para las familias clásicas con  $\lambda_n \sim n(n+1) \sim n^2$  y  $\|P_n\|_{L_w^2}$  acotado inferior y superiormente por constantes independientes de  $n$ , obtenemos  $|c_n| = O(n^{-2k})$ . Tomando  $2k = m$  (la máxima regularidad disponible):  $|c_n| = O(n^{-m})$ .  $\square$

## 4.4 Cuadratura Gaussiana

### 4.4.1 Motivación y definición

En la Sección 3.2.2 construimos reglas de cuadratura interpolatorias eligiendo  $n$  nodos  $x_1, \dots, x_n$  y determinando los pesos  $w_k$  para que la regla

$$Q_n(f) = \sum_{k=1}^n w_k f(x_k)$$

sea exacta para polinomios de grado  $\leq n-1$  (los que se interpolan exactamente). Vimos que, con nodos equiespaciados, esta estrategia puede fallar para  $n$  grande (fenómeno de Runge, pesos negativos).

La pregunta natural es: ¿podemos elegir *también los nodos* de manera óptima? Si con  $n$  evaluaciones de  $f$  queremos máxima exactitud polinomial, tenemos  $2n$  parámetros libres ( $n$  nodos y  $n$  pesos), así que cabe esperar exactitud para polinomios de grado  $\leq 2n-1$ . La **cuadratura de Gauss** logra exactamente esto, y los nodos óptimos resultan ser las raíces de los polinomios ortogonales con respecto al peso  $w$ .

**Definición 4.57** (Regla de cuadratura de Gauss). *Sea  $w(x) > 0$  una función de peso en  $(a, b)$  y  $\{P_k\}$  los polinomios ortogonales correspondientes. La **regla de cuadratura de Gauss de  $n$  puntos** usa como nodos las  $n$  raíces  $x_1, \dots, x_n$  de  $P_n$ , y como pesos*

$$w_k = \int_a^b \ell_k(x) w(x) dx, \quad \ell_k(x) = \prod_{\substack{j=1 \\ j \neq k}}^n \frac{x - x_j}{x_k - x_j}.$$



La aproximación de la integral es  $\int_a^b f(x) w(x) dx \approx Q_n(f) = \sum_{k=1}^n w_k f(x_k)$ .

#### 4.4.2 Exactitud y positividad

**Teorema 4.58** (Exactitud de grado  $2n-1$ ). *La regla de cuadratura de Gauss de  $n$  puntos es exacta para todo polinomio de grado  $\leq 2n-1$ :*

$$\int_a^b p(x) w(x) dx = \sum_{k=1}^n w_k p(x_k) \quad \forall p \in \Pi_{2n-1}.$$

Más aún, ninguna regla con  $n$  nodos puede ser exacta para todo polinomio de grado  $2n$ .

*Demostración.* **Exactitud para  $\Pi_{2n-1}$ .** Sea  $p \in \Pi_{2n-1}$ . Dividimos  $p$  por  $P_n$  (que tiene grado exacto  $n$ ):

$$p(x) = q(x) P_n(x) + r(x), \quad q \in \Pi_{n-1}, \quad r \in \Pi_{n-1}.$$

Integrando contra el peso:

$$\int_a^b p w = \int_a^b q P_n w + \int_a^b r w.$$

El primer término es cero: como  $q \in \Pi_{n-1}$ , es combinación lineal de  $P_0, \dots, P_{n-1}$ , y cada  $P_k$  con  $k < n$  es ortogonal a  $P_n$  por definición de polinomios ortogonales. Queda  $\int_a^b p w = \int_a^b r w$ .

Ahora evaluamos  $Q_n(p)$ . En cada nodo  $x_k$  (raíz de  $P_n$ ), tenemos  $P_n(x_k) = 0$ , así que  $p(x_k) = r(x_k)$  y

$$Q_n(p) = \sum_{k=1}^n w_k p(x_k) = \sum_{k=1}^n w_k r(x_k) = Q_n(r).$$

Como  $r \in \Pi_{n-1}$  y  $Q_n$  es al menos una regla interpolatoria (exacta en  $\Pi_{n-1}$  por construcción vía polinomios de Lagrange), resulta  $Q_n(r) = \int_a^b r w$ . Combinando:  $Q_n(p) = \int_a^b p w$ .

**Optimalidad.** Para ver que grado  $2n$  es imposible con  $n$  nodos, basta tomar  $p(x) = \prod_{k=1}^n (x - x_k)^2 \in \Pi_{2n}$ , que satisface  $p(x_k) = 0$  para todo  $k$  pero  $\int_a^b p w > 0$  (pues  $p \geq 0$  y  $p \not\equiv 0$  en  $(a, b)$ ).  $\square$

**Teorema 4.59** (Positividad de los pesos). *Los pesos de la cuadratura de Gauss son estrictamente positivos, es decir*

$$w_k = \int_a^b \ell_k(x) w(x) dx > 0$$

*Demostración.* Para cada  $k$ , el polinomio  $\ell_k^2 \in \Pi_{2n-2} \subset \Pi_{2n-1}$  satisface  $\ell_k^2(x_j) = \delta_{jk}$ . Por la exactitud del teorema anterior:

$$w_k = \sum_{j=1}^n w_j \ell_k^2(x_j) = \int_a^b \ell_k^2(x) w(x) dx > 0. \quad \square$$

La positividad de los pesos es crucial para la estabilidad numérica: garantiza que no haya cancelaciones catastróficas al sumar los términos  $w_k f(x_k)$ .

#### 4.4.3 Error de cuadratura

Definimos el **error de cuadratura** de una función  $f$  como

$$E_n(f) = \int_a^b f(x) w(x) dx - Q_n(f).$$

El Teorema 4.58 dice que  $E_n(p) = 0$  para  $p \in \Pi_{2n-1}$ . Por lo tanto, para acotar  $E_n(f)$  conviene intercalar directamente la **proyección ortogonal de orden  $2n-1$** ,

$$S_{2n-1}f = \sum_{k=0}^{2n-1} c_k P_k,$$

y usar que la regla es exacta en  $\Pi_{2n-1}$ , es decir,

$$\int_a^b S_{2n-1}f(x) w(x) dx = Q_n(S_{2n-1}f).$$

**Teorema 4.60** (Cota del error usando proyección de orden  $2n-1$ ). *Para toda  $f \in C([a, b])$ , el error de la cuadratura de Gauss satisface:*

$$|E_n(f)| \leq 2\mu_0 \|f - S_{2n-1}f\|_\infty,$$

donde  $\mu_0 = \int_a^b w(x) dx = \sum_{k=1}^n w_k$ .

*Demostración.* Sea  $S = S_{2n-1}f \in \Pi_{2n-1}$ . Intercalamos simultáneamente los términos  $\int_a^b S w$  y  $Q_n(S)$  (equivalentemente, sumamos y restamos ambos):

$$\begin{aligned} E_n(f) &= \int_a^b f w - Q_n(f) \\ &= \left( \int_a^b f w - \int_a^b S w \right) + \left( \int_a^b S w - Q_n(S) \right) + (Q_n(S) - Q_n(f)). \end{aligned}$$

Como  $S \in \Pi_{2n-1}$  y la regla de Gauss es exacta en  $\Pi_{2n-1}$ , el término central es nulo. Luego, por linealidad de la integral y de  $Q_n$ , queda

$$E_n(f) = \int_a^b (f - S) w - Q_n(f - S).$$

Acotamos cada término por separado.

**Término integral.** Como  $w \geq 0$ :

$$\left| \int_a^b (f - S) w \right| \leq \int_a^b |f - S| w \leq \|f - S\|_\infty \int_a^b w = \mu_0 \|f - S\|_\infty.$$

**Término de cuadratura.** Como  $w_k > 0$ :

$$|Q_n(f - S)| = \left| \sum_{k=1}^n w_k (f - S)(x_k) \right| \leq \sum_{k=1}^n w_k |(f - S)(x_k)| \leq \|f - S\|_\infty \sum_{k=1}^n w_k = \mu_0 \|f - S\|_\infty.$$

**Conclusión:**

$$|E_n(f)| \leq 2\mu_0 \|f - S\|_\infty = 2\mu_0 \|f - S_{2n-1}f\|_\infty. \quad \square$$

**Observación 4.61** (Interpretación y consecuencias). *El Teorema 4.60 muestra la mejora estructural de Gauss: con  $n$  nodos, la cota queda gobernada por un error de aproximación de grado  $2n - 1$  (no de grado  $n - 1$ ). En forma compacta,*

$$|E_n(f)| \leq 2\mu_0 \mathcal{E}_{2n-1}(f),$$

donde  $\mathcal{E}_m(f) = \inf_{p \in \Pi_m} \|f - p\|_\infty$ .

*Comparado con reglas interpolatorias de  $n$  nodos (típicamente controladas por  $\mathcal{E}_{n-1}(f)$ ), Gauss “duplica” el grado efectivo de aproximación para el mismo número de evaluaciones. Por eso, para alcanzar una precisión dada, suele requerir aproximadamente la mitad de nodos.*

*Si  $\mathcal{E}_m(f) = O(m^{-s})$  (regularidad algebraica), entonces*

$$|E_n(f)| = O((2n)^{-s}).$$

*Si  $f$  es analítica y  $\mathcal{E}_m(f)$  decae exponencialmente, el beneficio en  $n$  es aún más marcado.*

#### 4.4.4 Cálculo de nodos y pesos: Método de Golub-Welsch

Aunque las raíces de los polinomios ortogonales clásicos están tabuladas, para  $n$  grande o pesos no estándar es necesario calcularlas numéricamente. El método de Golub-Welsch (1969) transforma el problema de búsqueda de raíces en un problema de autovalores, explotando la recurrencia a tres términos.

Los polinomios ortogonales mónicos  $\pi_k$  satisfacen:

$$\pi_{k+1}(x) = (x - \alpha_k)\pi_k(x) - \beta_k\pi_{k-1}(x),$$

con  $\beta_k > 0$ . Esta relación puede escribirse en forma matricial como:

$$x\pi(x) = J_n\pi(x) + \pi_n(x)\mathbf{e}_n,$$

donde  $\pi(x) = [\pi_0(x), \dots, \pi_{n-1}(x)]^T$  y  $J_n$  es la **matriz de Jacobi** tridiagonal simétrica:

$$J_n = \begin{pmatrix} \alpha_0 & \sqrt{\beta_1} & & & \\ \sqrt{\beta_1} & \alpha_1 & \sqrt{\beta_2} & & \\ & \sqrt{\beta_2} & \alpha_2 & \ddots & \\ & & \ddots & \ddots & \sqrt{\beta_{n-1}} \\ & & & \sqrt{\beta_{n-1}} & \alpha_{n-1} \end{pmatrix}.$$

**Teorema 4.62** (Golub-Welsch). *Los nodos de la cuadratura de Gauss de  $n$  puntos son los **autovalores** de  $J_n$ . Los pesos están dados por:*

$$w_k = \mu_0 (v_{k,1})^2,$$

donde  $\mu_0 = \int_a^b w(x) dx$  y  $v_{k,1}$  es la primera componente del autovector normalizado de  $J_n$  correspondiente al autovalor  $x_k$ .

**Demostración. Nodos como autovalores.** Sea  $x_j$  una raíz de  $\pi_n$ . Evaluando la relación vectorial en  $x = x_j$ :

$$x_j \pi(x_j) = J_n \pi(x_j) + \underbrace{\pi_n(x_j)}_{=0} \mathbf{e}_n = J_n \pi(x_j).$$

Como  $\pi_0(x_j) = 1 \neq 0$ , el vector  $\pi(x_j)$  es no nulo, y  $x_j$  es autovalor de  $J_n$  con autovector  $\pi(x_j)$ . Como  $J_n$  es tridiagonal simétrica con subdiagonal positiva, tiene  $n$  autovalores simples.

**Fórmula para los pesos.** Para  $0 \leq r, s \leq n-1$ , el producto  $\pi_r(x)\pi_s(x) \in \Pi_{2n-2}$  es integrado exactamente por la cuadratura de Gauss. Definiendo la matriz  $V$  con  $V_{jk} = \pi_k(x_j)$  y  $W = \text{diag}(w_1, \dots, w_n)$ :

$$V^T W V = D, \quad D = \text{diag}(\|\pi_0\|_w^2, \dots, \|\pi_{n-1}\|_w^2),$$

por la ortogonalidad de los polinomios. Los autovectores normalizados de  $J_n$  forman  $Q$  con  $Q^T Q = I$ , y  $V = Q \cdot \text{diag}(\|\pi(x_1)\|_2, \dots, \|\pi(x_n)\|_2)$ . Sustituyendo y usando  $\hat{v}_{k,1} = 1/\|\pi(x_k)\|_2$  (pues  $\pi_0 = 1$ ):

$$w_k = \mu_0 (\hat{v}_{k,1})^2. \quad \square$$

**Observación 4.63.** *El método es extremadamente robusto y bastante eficiente ( $O(n^2)$  con el algoritmo QR para matrices tridiagonales simétricas), y permite calcular reglas de cuadratura para cualquier peso cuyos coeficientes de recurrencia  $\alpha_k, \beta_k$  se conozcan. Para las familias clásicas estos tienen fórmulas cerradas; para pesos generales pueden obtenerse por un algoritmo que se debe a Stieltjes.*

## 4.5 Error de interpolación

En varios puntos del capítulo aparecieron cotas escritas en términos del error de interpolación (por ejemplo, al acotar errores de cuadratura mediante la diferencia entre  $f$  y su interpolante). Por eso, cerramos con un bloque conceptual único que explique cómo controlar ese error de manera sistemática.

La idea central es separar dos efectos: por un lado, la regularidad de la función, que controla la cola de su expansión espectral; por otro, la elección de nodos, que entra a través de la constante de Lebesgue (equivalentemente, la norma del interpolante). Esta separación permite reutilizar de inmediato cualquier resultado de decaimiento de coeficientes ya probado en el capítulo.

El esquema de esta sección final es: primero, un lema abstracto sobre la constante de Lebesgue y la alcanzabilidad de la cota; luego, una cota del error de interpolación por cola espectral; finalmente, la especialización a Chebyshev, donde  $\Lambda_N^{Ch} = O(\log N)$  y se obtiene una estimación explícita.

**Lema 4.64** (Constante de Lebesgue y alcanzabilidad). *Sea  $[a, b]$  un intervalo compacto y sean  $x_0, \dots, x_N \in [a, b]$  nodos distintos. Si*

$$I_N f(x) = \sum_{j=0}^N f(x_j) \ell_j(x)$$

es el interpolante de Lagrange asociado, definimos

$$\lambda_N(x) := \sum_{j=0}^N |\ell_j(x)|, \quad \Lambda_N := \max_{x \in [a,b]} \lambda_N(x).$$

Entonces, para todo  $f \in C([a, b])$ ,

$$\|I_N f\|_\infty \leq \Lambda_N \|f\|_\infty.$$

Además, la cota es óptima: existe  $f^* \in C([a, b])$ , con  $\|f^*\|_\infty \leq 1$ , tal que

$$\|I_N f^*\|_\infty = \Lambda_N.$$

*Demostración.* Para todo  $x \in [a, b]$ ,

$$|I_N f(x)| \leq \sum_{j=0}^N |f(x_j)| |\ell_j(x)| \leq \|f\|_\infty \sum_{j=0}^N |\ell_j(x)| = \|f\|_\infty \lambda_N(x) \leq \Lambda_N \|f\|_\infty.$$

Tomando supremo en  $x$  obtenemos la desigualdad.

Como  $\lambda_N$  es continua en el compacto  $[a, b]$ , existe  $x^*$  tal que  $\lambda_N(x^*) = \Lambda_N$ . Definimos

$$\sigma_j := \operatorname{sgn}(\ell_j(x^*)) \in \{-1, 1\}$$

(si  $\ell_j(x^*) = 0$ , elegimos cualquiera de los dos signos), y tomamos  $f^* \in C([a, b])$  con  $f^*(x_j) = \sigma_j$  para todo  $j$  y  $\|f^*\|_\infty \leq 1$  (por ejemplo, una función lineal a trozos entre nodos ordenados). Entonces

$$I_N f^*(x^*) = \sum_{j=0}^N \sigma_j \ell_j(x^*) = \sum_{j=0}^N |\ell_j(x^*)| = \Lambda_N,$$

y por lo tanto

$$\|I_N f^*\|_\infty \geq \Lambda_N.$$

Combinando con la desigualdad general aplicada a  $f^*$ , concluimos

$$\|I_N f^*\|_\infty = \Lambda_N.$$

□

En el caso de nodos de Chebyshev–Lobatto en  $[-1, 1]$ , escribiremos

$$\Lambda_N^{Ch} := \Lambda_N.$$

**Teorema 4.65** (Cota por constante de Lebesgue y cola espectral). *Sea  $[a, b]$  compacto y sea  $\{\phi_k\}_{k \geq 0} \subset C([a, b])$  una familia de funciones (en particular, puede ser una base ortonormal) tal que existe  $M > 0$  con*

$$\|\phi_k\|_\infty \leq M \quad \forall k \geq 0.$$

Para cada  $N$ , sea  $V_N := \text{span}\{\phi_0, \dots, \phi_N\}$  y sea  $I_N : C([a, b]) \rightarrow V_N$  un interpolante lineal exacto en  $V_N$  (es decir,  $I_N p = p$  para todo  $p \in V_N$ ), con constante de Lebesgue  $\Lambda_N := \|I_N\|_{\infty \rightarrow \infty}$ . Si

$$f(x) = \sum_{k=0}^{\infty} a_k \phi_k(x)$$

convergente uniformemente en  $[a, b]$ , entonces

$$\|f - I_N f\|_{\infty} \leq (1 + \Lambda_N) \|f - S_N f\|_{\infty} \leq (1 + \Lambda_N) M \sum_{k>N} |a_k|,$$

donde  $S_N f := \sum_{k=0}^N a_k \phi_k$ .

*Demostración.* Como  $I_N$  es exacto en  $V_N$ , se tiene  $I_N S_N f = S_N f$ . Luego

$$f - I_N f = (f - S_N f) - I_N(f - S_N f).$$

Tomando norma supremo y usando  $\|I_N\|_{\infty \rightarrow \infty} = \Lambda_N$ ,

$$\|f - I_N f\|_{\infty} \leq \|f - S_N f\|_{\infty} + \|I_N(f - S_N f)\|_{\infty} \leq (1 + \Lambda_N) \|f - S_N f\|_{\infty}.$$

Además,

$$f - S_N f = \sum_{k>N} a_k \phi_k,$$

y por desigualdad triangular,

$$\|f - S_N f\|_{\infty} \leq \sum_{k>N} |a_k| \|\phi_k\|_{\infty} \leq M \sum_{k>N} |a_k|.$$

Combinando ambas desigualdades se obtiene la cota. □

**Observación 4.66** (Caso Chebyshev). *Aplicando el Teorema 4.65 con la familia de Chebyshev clásica  $\phi_k = T_k$  (para la cual  $\|T_k\|_{\infty} \leq 1$ ), se recupera la Proposición 4.67.*

**Proposición 4.67** (Cota del error de interpolación). *Sea*

$$S_N^{Ch} f(x) := \frac{a_0}{2} + \sum_{k=1}^N a_k T_k(x)$$

*el truncamiento de la serie de Chebyshev de  $f$ . Entonces*

$$\|f - I_N^{Ch} f\|_{\infty} \leq (1 + \Lambda_N^{Ch}) \|f - S_N^{Ch} f\|_{\infty} \leq (1 + \Lambda_N^{Ch}) \sum_{k>N} |a_k|.$$

*Demostración.* Como  $I_N^{Ch}(S_N^{Ch} f) = S_N^{Ch} f$ , se tiene

$$f - I_N^{Ch} f = (f - S_N^{Ch} f) - I_N^{Ch}(f - S_N^{Ch} f).$$

Tomando norma supremo y aplicando el Lema 4.64,

$$\|f - I_N^{Ch} f\|_\infty \leq \|f - S_N^{Ch} f\|_\infty + \|I_N^{Ch}(f - S_N^{Ch} f)\|_\infty \leq (1 + \Lambda_N^{Ch}) \|f - S_N^{Ch} f\|_\infty.$$

Además,

$$f(x) - S_N^{Ch} f(x) = \sum_{k>N} a_k T_k(x),$$

y como  $|T_k(x)| \leq 1$  en  $[-1, 1]$ ,

$$\|f - S_N^{Ch} f\|_\infty \leq \sum_{k>N} |a_k|.$$

Juntando ambas desigualdades se obtiene la cota.  $\square$

**Corolario 4.68** (Cota con factor logarítmico). *Si  $|a_k| = O(k^{-m})$  con  $m > 1$  y se usa el crecimiento clásico*

$$\Lambda_N^{Ch} = O(\log N),$$

*entonces*

$$\|f - I_N^{Ch} f\|_\infty = O(N^{1-m} \log N).$$

*Demostración.* Por la Proposición 4.67,

$$\|f - I_N^{Ch} f\|_\infty \leq (1 + \Lambda_N^{Ch}) \sum_{k>N} |a_k|.$$

Como  $\sum_{k>N} |a_k| = O(N^{1-m})$  y  $\Lambda_N^{Ch} = O(\log N)$ , resulta

$$\|f - I_N^{Ch} f\|_\infty = O(N^{1-m} \log N).$$

$\square$

**Observación 4.69** (No optimalidad de la cota y mejora tipo Jackson). *La cota anterior es elemental y útil, pero no es ajustada en general. En teoría de aproximación, resultados tipo Jackson mejoran un orden en  $N$  respecto de esta estimación; en particular, bajo hipótesis de regularidad más finas se obtiene una tasa del tipo  $O(N^{-m} \log N)$  (y, según el marco y regularidad adicional, puede mejorarse aún más).*

## Chapter 5

# Métodos de diferencias finitas

En este capítulo estudiamos métodos numéricos basados en diferencias finitas para tres clases de ecuaciones diferenciales:

1. **Problema de valores iniciales (PVI).** Dada  $f : [t_0, T] \times \mathbb{R} \rightarrow \mathbb{R}$ , buscar  $y : [t_0, T] \rightarrow \mathbb{R}$  tal que

$$y'(t) = f(t, y(t)), \quad y(t_0) = y_0.$$

2. **Problema de valores de contorno (PVC).** Dado un operador diferencial  $\mathcal{L}$  y condiciones en los extremos, buscar  $u : (0, 1) \rightarrow \mathbb{R}$  tal que

$$\mathcal{L}u(x) = f(x), \quad x \in (0, 1).$$

El caso prototípico es  $\mathcal{L}u = -u'' + \sigma u$  con  $\sigma > 0$ .

3. **Ecuaciones en derivadas parciales (EDP).** Por ejemplo, la ecuación del calor:

$$u_t(x, t) = \kappa u_{xx}(x, t), \quad x \in [0, 1], \quad t > 0,$$

con condición inicial  $u(x, 0) = u_0(x)$  y condiciones de borde.

En todos los casos la estrategia es la misma: introducir una malla de puntos  $\{t_n = t_0 + n\Delta t\}$  y/o  $\{x_j = j\Delta x\}$ , y reemplazar cada derivada por una *fórmula de diferencias finitas*: una combinación lineal de valores de la función en puntos vecinos de la malla. Aplicando esta sustitución al problema diferencial obtenemos un sistema algebraico cuya solución  $\{y_n\}$ ,  $\{u_j\}$  o  $\{U_j^n\}$  queremos que aproxime la solución exacta cuando los pasos espaciales y temporales  $\Delta x, \Delta t \rightarrow 0$ .

### 5.1 Problemas de valores iniciales

Para fijar ideas y comparar métodos, empecemos con el problema más sencillo posible:

$$y'(t) = \alpha y(t), \quad y(0) = y_0, \quad \alpha \in \mathbb{R},$$

cuya solución exacta es  $y(t) = e^{\alpha t} y_0$ . Si  $\alpha < 0$  la solución decae exponencialmente; si  $\alpha > 0$  crece. Aplicaremos los dos métodos de diferencias finitas más elementales.



## Euler explícito

La fórmula de diferencias forward aproxima  $y'(t_n) \approx \frac{y_{n+1}-y_n}{\Delta t}$ . Evaluando el lado derecho en  $t_n$ :

$$\frac{y_{n+1}-y_n}{\Delta t} = \alpha y_n \implies y_{n+1} = (1 + \Delta t \alpha) y_n.$$

Por inducción,  $y_n = (1 + \Delta t \alpha)^n y_0$ .

Fijemos  $t = t_n = n\Delta t$ . Cuando  $\Delta t \rightarrow 0$  con  $t$  fijo ( $n = t/\Delta t \rightarrow \infty$ ):

$$y_n = (1 + \Delta t \alpha)^{t/\Delta t} y_0 \xrightarrow{\Delta t \rightarrow 0} e^{\alpha t} y_0 = y(t).$$

**Comportamiento cualitativo para  $\Delta t$  fijo.** La solución numérica es  $y_n = (1 + \Delta t \alpha)^n y_0$ , y crece o decae según  $|1 + \Delta t \alpha|$  sea mayor o menor que 1. Para  $\alpha < 0$ :

- Si  $\Delta t < 2/|\alpha|$ :  $|1 + \Delta t \alpha| < 1$  y  $|y_n| \rightarrow 0$ . El método reproduce el decaimiento.
- Si  $\Delta t = 2/|\alpha|$ :  $1 + \Delta t \alpha = -1$ , y  $y_n = (-1)^n y_0$  oscila indefinidamente.
- Si  $\Delta t > 2/|\alpha|$ :  $|1 + \Delta t \alpha| > 1$  y  $|y_n| \rightarrow \infty$ , aunque la solución exacta decae.

Por ejemplo, con  $\alpha = -10$  y  $\Delta t = 0.3 > 2/10$ :  $1 + \Delta t \alpha = -2$ , y  $y_n = (-2)^n y_0$  diverge en módulo. La convergencia asintótica ( $\Delta t \rightarrow 0$ ) no garantiza un comportamiento correcto para pasos finitos.

## Euler implícito

La fórmula de diferencias backward evalúa el lado derecho en  $t_{n+1}$ :

$$\frac{y_{n+1}-y_n}{\Delta t} = \alpha y_{n+1} \implies y_{n+1} = \frac{1}{1 - \Delta t \alpha} y_n =: R_I y_n.$$

Por inducción,  $y_n = R_I^n y_0 = \left( \frac{1}{1 - \Delta t \alpha} \right)^n y_0$ .

**Convergencia cuando  $\Delta t \rightarrow 0$ .** Con  $t = n\Delta t$ , análogamente al caso explícito,  $\log(1/(1 - \Delta t \alpha)) = \Delta t \alpha + O(\Delta t^2)$ , luego

$$y_n = \left( \frac{1}{1 - \Delta t \alpha} \right)^{t/\Delta t} y_0 \xrightarrow{\Delta t \rightarrow 0} e^{\alpha t} y_0 = y(t).$$

**Comportamiento cualitativo para  $\Delta t$  fijo.** Para  $\alpha < 0$  y *cualquier*  $\Delta t > 0$ :  $1 - \Delta t \alpha > 1 > 0$ , luego

$$|R_I| = \frac{1}{1 - \Delta t \alpha} = \frac{1}{1 + \Delta t |\alpha|} < 1.$$

Entonces  $|y_n| = |R_I|^n |y_0| \rightarrow 0$  para todo  $\Delta t > 0$ : Euler implícito reproduce el decaimiento de la solución exacta sin ninguna restricción sobre el paso.

**Observación 5.1.** Ambos métodos convergen cuando  $\Delta t \rightarrow 0$ , pero difieren cualitativamente para  $\Delta t$  fijo: Euler explícito puede producir soluciones divergentes si el paso supera el umbral  $2/|\alpha|$ , mientras que Euler implícito siempre decae. Este contraste se vuelve algorítmicamente crítico cuando  $|\alpha| \gg 1$  (problemas rígidos), obligando al método explícito a usar pasos extremadamente pequeños. Este fenómeno se estudia en la Sección 5.1.4.

### 5.1.1 Métodos de un paso

Seguimos con el PVI  $y' = f(t, y)$ ,  $y(t_0) = y_0$  sobre la malla  $\{t_n = t_0 + n\Delta t\}_{n=0}^N$  con  $N\Delta t = T - t_0$ .

#### Taylor de orden 2 y la familia RK2

El método de Euler explícito tiene orden 1: el error global es  $O(\Delta t)$ . Para obtener orden 2 expandimos la solución exacta dos pasos de Taylor:

$$y(t_{n+1}) = y(t_n) + \Delta t y'(t_n) + \frac{\Delta t^2}{2} y''(t_n) + O(\Delta t^3).$$

Como  $y'(t) = f(t, y(t))$ , por la regla de la cadena

$$y''(t) = \frac{d}{dt} f(t, y(t)) = f_t(t, y(t)) + f_y(t, y(t)) y'(t) = f_t(t, y(t)) + f_y(t, y(t)) f(t, y(t)).$$

Por lo tanto, el método de Taylor de orden 2 es

$$y_{n+1} = y_n + \Delta t f(t_n, y_n) + \frac{\Delta t^2}{2} (f_t(t_n, y_n) + f_y(t_n, y_n) f(t_n, y_n)).$$

Su ventaja es la precisión; su desventaja es que requiere calcular las derivadas parciales  $f_t$  y  $f_y$ .

**Familia Runge-Kutta de 2 etapas (RK2).** Para evitar diferenciar  $f$ , se aproxima el término de orden  $\Delta t^2$  evaluando  $f$  en un punto auxiliar. Se propone el esquema

$$\begin{aligned} k_1 &= f(t_n, y_n), \\ k_2 &= f(t_n + c_2 \Delta t, y_n + a_{21} \Delta t k_1), \\ y_{n+1} &= y_n + \Delta t (b_1 k_1 + b_2 k_2), \end{aligned}$$

con cuatro parámetros libres  $b_1, b_2, c_2, a_{21}$ . Expandiendo  $k_2$  en Taylor alrededor de  $(t_n, y_n)$ :

$$k_2 = f + c_2 \Delta t f_t + a_{21} \Delta t k_1 f_y + O(\Delta t^2) = f + \Delta t (c_2 f_t + a_{21} f f_y) + O(\Delta t^2).$$

Entonces  $y_{n+1} = y_n + \Delta t (b_1 + b_2) f + \Delta t^2 b_2 (c_2 f_t + a_{21} f f_y) + O(\Delta t^3)$ . Comparando con Taylor:

$$b_1 + b_2 = 1, \quad b_2 c_2 = \frac{1}{2}, \quad b_2 a_{21} = \frac{1}{2}.$$

Hay una familia uniparamétrica de soluciones. Dos casos especiales:

- **Método de Heun:**  $b_1 = b_2 = \frac{1}{2}$ ,  $c_2 = a_{21} = 1$ . Equivalentemente:  $k_1 = f(t_n, y_n)$ ,  $k_2 = f(t_n + \Delta t, y_n + \Delta t k_1)$ ,  $y_{n+1} = y_n + \frac{\Delta t}{2} (k_1 + k_2)$ .
- **Punto medio explícito:**  $b_1 = 0$ ,  $b_2 = 1$ ,  $c_2 = a_{21} = \frac{1}{2}$ . Equivalentemente:  $k_1 = f(t_n, y_n)$ ,  $y_{n+1} = y_n + \Delta t f(t_n + \frac{\Delta t}{2}, y_n + \frac{\Delta t}{2} k_1)$ .

### 5.1.2 La función de incremento $\Phi$

Todos los ejemplos anteriores tienen la estructura

$$y_{n+1} = y_n + \Delta t \Phi(t_n, y_n, \Delta t), \quad (5.1)$$

donde  $\Phi : [t_0, T] \times \mathbb{R} \times [0, \Delta t_{\max}] \rightarrow \mathbb{R}$  es la *función de incremento* que caracteriza al método. La tabla siguiente resume los métodos vistos hasta aquí.

| Método          | Función de incremento $\Phi(t, y, \Delta t)$                              | Orden | Tipo  |
|-----------------|---------------------------------------------------------------------------|-------|-------|
| Euler explícito | $f(t, y)$                                                                 | 1     | expl. |
| Euler implícito | $\tilde{y}$ tal que $\tilde{y} = f(t + \Delta t, y + \Delta t \tilde{y})$ | 1     | impl. |
| Taylor orden 2  | $f(t, y) + \frac{\Delta t}{2}(f_t(t, y) + f_y(t, y)f(t, y))$              | 2     | expl. |
| Heun (RK2)      | $\frac{1}{2}[f(t, y) + f(t + \Delta t, y + \Delta t f(t, y))]$            | 2     | expl. |
| Punto medio     | $f(t + \frac{\Delta t}{2}, y + \frac{\Delta t}{2}f(t, y))$                | 2     | expl. |

**Observación 5.2.** Para Euler implícito,  $\Phi$  está definida implícitamente: en cada paso hay que resolver la ecuación escalar

$$\tilde{y} = f(t_{n+1}, y_n + \Delta t \tilde{y}).$$

En problemas lineales, por ejemplo si  $f(t, y) = a(t)y + b(t)$ , la ecuación se resuelve explícitamente:

$$\tilde{y} = a(t_{n+1})(y_n + \Delta t \tilde{y}) + b(t_{n+1}) \implies \tilde{y} = \frac{a(t_{n+1})y_n + b(t_{n+1})}{1 - \Delta t a(t_{n+1})},$$

siempre que  $1 - \Delta t a(t_{n+1}) \neq 0$ .

### 5.1.3 Convergencia de métodos de un paso

Dado el esquema (5.1), preguntamos: ¿cuándo aproxima bien la solución exacta?

**Definición 5.3** (Convergencia). El método es **convergente** en  $[t_0, T]$  si

$$\max_{\substack{0 \leq n \leq N \\ t_n \leq T}} |y_n - y(t_n)| \xrightarrow{\Delta t \rightarrow 0} 0$$

para todo dato  $y_0$  y toda función  $f$  Lipschitz en  $y$ .

**Definición 5.4** (Error de truncamiento y consistencia). El **error de truncamiento local** en el paso  $n + 1$  es

$$\tau_{n+1}(\Delta t) := \frac{y(t_{n+1}) - y(t_n)}{\Delta t} - \Phi(t_n, y(t_n), \Delta t).$$

El método es **consistente** si  $\|\tau(\Delta t)\|_\infty := \max_n |\tau_{n+1}(\Delta t)| \rightarrow 0$  cuando  $\Delta t \rightarrow 0$ . Si  $\|\tau(\Delta t)\|_\infty = O(\Delta t^p)$ , decimos que tiene **orden**  $p$ .

Equivalentemente, el método es consistente si y solo si  $\Phi(t, y, 0) = f(t, y)$  para todo  $(t, y)$ .

**Observación 5.5** (Defecto local del paso y error de truncamiento). Si definimos el defecto local del paso

$$\eta_{n+1}(\Delta t) := y(t_{n+1}) - y(t_n) - \Delta t \Phi(t_n, y(t_n), \Delta t),$$

entonces, por definición de  $\tau_{n+1}$ ,

$$\eta_{n+1}(\Delta t) = \Delta t \tau_{n+1}(\Delta t).$$

Por eso, suponer  $\eta_{n+1} = O(\Delta t^{p+1})$  es equivalente a suponer  $\tau_{n+1} = O(\Delta t^p)$ . En muchos textos,  $\eta_{n+1}$  se llama directamente “error local”.

La condición  $\Phi(t, y, 0) = f(t, y)$  es inmediata para Euler explícito ( $\Phi = f$ ). Para RK2 se verifica sustituyendo  $\Delta t = 0$ :  $k_2 \rightarrow f(t, y) = k_1$  y  $\Phi \rightarrow b_1 k_1 + b_2 k_2 = (b_1 + b_2)f = f$ .

**Definición 5.6** (Estabilidad de un método de un paso). El método es **estable** en  $[t_0, T]$  si existen  $\Delta t_0 > 0$  y  $C_T > 0$  independientes de  $\Delta t$  tales que, para todo  $0 < \Delta t \leq \Delta t_0$ , toda pareja de datos  $y_0, \tilde{y}_0$  y todo  $n$  con  $t_n \leq T$ ,

$$|y_n - \tilde{y}_n| \leq C_T |y_0 - \tilde{y}_0|,$$

donde  $\{y_n\}$  y  $\{\tilde{y}_n\}$  son las soluciones del método con datos iniciales  $y_0$  y  $\tilde{y}_0$  respectivamente.

**Observación 5.7** (Lipschitz en  $\Phi$  implica estabilidad). Si  $\Phi$  es Lipschitz en  $y$  con constante  $K$  (uniformemente en  $t$  y  $\Delta t$ ), entonces el método es estable con  $C_T = e^{KT}$ . En efecto, sea  $\delta_n := y_n - \tilde{y}_n$  la diferencia de dos soluciones numéricas con datos distintos. Ambas satisfacen el mismo esquema, luego

$$\delta_{n+1} = \delta_n + \Delta t [\Phi(t_n, y_n, \Delta t) - \Phi(t_n, \tilde{y}_n, \Delta t)],$$

y la condición de Lipschitz da  $|\delta_{n+1}| \leq (1 + \Delta t K) |\delta_n|$ . Iterando y aplicando el Lema 5.8:  $|\delta_n| \leq (1 + \Delta t K)^n |\delta_0| \leq e^{\Delta t K n} |\delta_0| \leq e^{KT} |y_0 - \tilde{y}_0|$ .

Para los métodos de la tabla: Euler explícito tiene  $\Phi = f$ , por lo que  $K = L$  (la constante de Lipschitz de  $f$ ). Euler implícito tiene  $K_I(\Delta t) = L/(1 + \Delta t L) < L$ . Para los métodos RK2,  $\Phi$  hereda el Lipschitz de  $f$  con una constante explícitamente computable. En todos los casos, si  $f$  es Lipschitz entonces  $\Phi$  también lo es, y la estabilidad queda garantizada sin verificación adicional.

**Lema 5.8.** Para todo  $x \geq 0$  se tiene  $1 + x \leq e^x$ .

*Demostración.* Considérese  $g(x) := e^x - (1 + x)$ . Entonces  $g(0) = 0$  y  $g'(x) = e^x - 1 \geq 0$  para todo  $x \geq 0$ . Por lo tanto  $g$  es creciente en  $[0, \infty)$  y, como  $g(0) = 0$ , se sigue que  $g(x) \geq 0$  para todo  $x \geq 0$ .  $\square$

**Teorema 5.9** (Consistencia  $\Leftrightarrow$  convergencia para métodos de un paso). Sea  $y' = f(t, y)$  con  $f$  Lipschitz en  $y$  con constante  $L$  en  $[t_0, T] \times \mathbb{R}$ . Supongamos que  $\Phi$  es Lipschitz en  $y$  con constante  $K$  uniformemente en  $t$  y  $\Delta t$ . Entonces:

1. (Consistencia  $\Rightarrow$  convergencia, con orden.) Si  $|\tau_{n+1}(\Delta t)| \leq C \Delta t^p$  para todo  $n$ , entonces

$$\max_{0 \leq n \leq N} |y(t_n) - y_n| \leq \frac{e^{K(T-t_0)} - 1}{K} C \Delta t^p.$$

En particular, el método es convergente.

2. (Convergencia  $\Rightarrow$  consistencia.) Si el método es convergente para toda  $f$  Lipschitz, entonces es consistente.

*Demostración.* (1) Sea  $e_n := y(t_n) - y_n$ . Por definición del error de truncamiento y del método,

$$\begin{aligned} y(t_{n+1}) &= y(t_n) + \Delta t \Phi(t_n, y(t_n), \Delta t) + \Delta t \tau_{n+1}, \\ y_{n+1} &= y_n + \Delta t \Phi(t_n, y_n, \Delta t). \end{aligned}$$

Restando y usando que  $\Phi$  es Lipschitz en  $y$  con constante  $K$ ,

$$|e_{n+1}| \leq (1 + K\Delta t)|e_n| + \Delta t |\tau_{n+1}|.$$

Esto es exactamente la estimación de estabilidad Lipschitz con un término fuente de truncamiento. Tomando  $\tau_{\max} := \max_j |\tau_j|$  e iterando desde  $e_0 = 0$ :

$$|e_n| \leq \Delta t \tau_{\max} \sum_{j=0}^{n-1} (1 + K\Delta t)^j = \frac{\tau_{\max}}{K} ((1 + K\Delta t)^n - 1).$$

Aplicando el Lema 5.8 y usando  $t_n - t_0 = n\Delta t \leq T - t_0$ ,

$$|e_n| \leq \frac{\tau_{\max}}{K} (e^{K(t_n - t_0)} - 1) \leq \frac{\tau_{\max}}{K} (e^{K(T - t_0)} - 1).$$

Si  $|\tau_{n+1}(\Delta t)| \leq C\Delta t^p$  para todo  $n$ , entonces  $\tau_{\max} \leq C\Delta t^p$  y por lo tanto

$$\max_{0 \leq n \leq N} |y(t_n) - y_n| \leq \frac{e^{K(T - t_0)} - 1}{K} C\Delta t^p.$$

(2) La consistencia es la condición  $\Phi(t, y, 0) = f(t, y)$ . Si el método converge para la ecuación  $y' = f$ , en particular la solución numérica  $y_1 = y_0 + \Delta t \Phi(t_0, y_0, \Delta t)$  satisface  $y_1 \rightarrow y(t_0 + \Delta t) = y_0 + \Delta t f(t_0, y_0) + O(\Delta t^2)$  cuando  $\Delta t \rightarrow 0$ . Dividiendo por  $\Delta t$  y tomando  $\Delta t \rightarrow 0$ :  $\Phi(t_0, y_0, 0) = f(t_0, y_0)$ , que es la consistencia.  $\square$

**Observación 5.10.** La dirección (1) es la más importante para la práctica: basta verificar que el error local es  $O(\Delta t^{p+1})$  (es decir, que el método tiene orden  $p$ ) para concluir que el error global es  $O(\Delta t^p)$ . La constante de la cota es  $C' = \frac{e^{K(T - t_0)} - 1}{K} C$ , donde  $K$  es la constante de Lipschitz de  $\Phi$  cuya existencia garantiza la estabilidad (Definición 5.6 y el remark anterior).

#### 5.1.4 Problemas rígidos o “stiff”

En la Sección 5.1 vimos que Euler explícito e implícito difieren cualitativamente en la ecuación  $y' = \alpha y$  para  $\Delta t$  fijo: el método explícito diverge si  $\Delta t > 2/|\alpha|$ , mientras que el implícito decae para cualquier  $\Delta t > 0$ . Aquí usamos el Teorema 5.9 para entender de manera más precisa qué paso impone cada método.

Consideremos la ecuación test

$$y' = \lambda y, \quad y(0) = y_0, \quad \lambda < 0,$$

con solución exacta  $y(t) = e^{\lambda t} y_0$ . Calculamos la constante de Lipschitz de la función de incremento  $\Phi$  de cada método y la cota resultante.

**Euler explícito.**  $\Phi_E(t, y, \Delta t) = \lambda y$ , que es lineal en  $y$ :

$$|\Phi_E(t, y_1, \Delta t) - \Phi_E(t, y_2, \Delta t)| = |\lambda| |y_1 - y_2|.$$

La constante de Lipschitz es  $K_E = |\lambda|$ . El Teorema 5.9 da

$$\max_n |e_n| \leq T e^{|\lambda|T} C \Delta t,$$

donde  $C = |\lambda|^2/2$  viene del error de truncamiento  $|\tau_n| = \frac{\Delta t \lambda^2}{2} |y(t_n)| \leq \frac{\Delta t \lambda^2}{2} |y_0|$ . La cota crece *exponencialmente* con  $|\lambda|$ . Para garantizar error  $< \epsilon$  con esta estimación se necesitaría

$$\Delta t < \frac{2\epsilon}{\lambda^2 T e^{|\lambda|T}},$$

un paso astronómicamente pequeño para  $|\lambda| \gg 1$ .

**Euler implícito.** El esquema resuelve  $y_{n+1} = y_n + \Delta t \lambda y_{n+1}$ , dando  $y_{n+1} = y_n / (1 - \Delta t \lambda)$ . La función de incremento es

$$\Phi_I(t, y, \Delta t) = \frac{\lambda y}{1 - \Delta t \lambda},$$

también lineal en  $y$ , con constante de Lipschitz

$$K_I(\Delta t) = \frac{|\lambda|}{1 - \Delta t \lambda} = \frac{|\lambda|}{1 + \Delta t |\lambda|}.$$

Nótese que  $K_I(\Delta t) < |\lambda| = K_E$  para todo  $\Delta t > 0$ . Más importante:  $K_I$  es acotada superiormente por  $1/\Delta t$ , independientemente de  $|\lambda|$ :

$$K_I(\Delta t) = \frac{|\lambda|}{1 + \Delta t |\lambda|} \leq \frac{1}{\Delta t},$$

con  $K_I(\Delta t) \rightarrow 1/\Delta t$  cuando  $|\lambda| \rightarrow \infty$  con  $\Delta t$  fijo. Aplicando el Teorema 5.9 con esta cota:

$$\max_n |e_n| \leq T e^{K_I(\Delta t)T} C \Delta t \leq T e^{T/\Delta t} C \Delta t.$$

Esta cota es independiente de  $|\lambda|$ : para cualquier valor de la rigidez, el error de Euler implícito queda controlado sin restringir  $\Delta t$  en función de  $|\lambda|$ .

**Observación 5.11.** *El contraste entre los dos métodos se resume así: la cota del Teorema 5.9 para Euler explícito tiene el factor  $e^{|\lambda|T}$  que crece sin límite con la rigidez; la cota para Euler implícito tiene el factor  $e^{T/\Delta t}$  que solo depende del paso y del intervalo, no de  $|\lambda|$ . En la práctica, la restricción de paso de Euler explícito ( $\Delta t \lesssim 2/|\lambda|$ ) no proviene de la exactitud sino de la estabilidad: para  $\Delta t > 2/|\lambda|$  la solución numérica diverge (como vimos en la Sección 5.1), mientras que Euler implícito es estable para todo  $\Delta t > 0$ .*

*Esta distinción motiva la noción de **A-estabilidad**: un método es A-estable si su región de estabilidad absoluta contiene el semiplano  $\{\text{Re}(z) \leq 0\}$ . Euler explícito no es A-estable; Euler implícito sí lo es (al igual que el método del trapecio).*

## 5.2 Problema de valores de contorno

Consideramos el problema de Dirichlet con reacción

$$-u''(x) + \sigma u(x) = f(x), \quad x \in (0, 1), \quad u(0) = \alpha, \quad u(1) = \beta,$$

con  $\sigma > 0$ . Sea la malla uniforme  $x_j = jh$ ,  $j = 0, 1, \dots, m+1$ , con  $h = 1/(m+1)$ . En nodos interiores  $j = 1, \dots, m$ , aproximamos  $u(x_j)$  por  $u_j$  y usamos la diferencia centrada para  $u''$ :

$$-\frac{u_{j-1} - 2u_j + u_{j+1}}{h^2} + \sigma u_j = f(x_j).$$

Las condiciones de borde se imponen fijando  $u_0 = \alpha$  y  $u_{m+1} = \beta$ .

**Proposición 5.12** (Fórmula centrada para  $u''$ ). Si  $u \in C^4([0, 1])$ , entonces para todo nodo interior  $x_j$  existe  $\xi_j \in (x_{j-1}, x_{j+1})$  tal que

$$\frac{u(x_{j-1}) - 2u(x_j) + u(x_{j+1}))}{h^2} = u''(x_j) + \frac{h^2}{12} u^{(4)}(\xi_j).$$

En particular, la aproximación centrada de la segunda derivada tiene error  $O(h^2)$ .

**Lema 5.13** (Promedio de extremos en un punto intermedio). Si  $g \in C([a, b])$ , entonces existe  $\xi \in [a, b]$  tal que

$$g(\xi) = \frac{g(a) + g(b)}{2}.$$

Si además  $g(a) \neq g(b)$ , entonces  $\xi \in (a, b)$ .

*Demostración.* Sea

$$m := \frac{g(a) + g(b)}{2}, \quad h(x) := g(x) - m.$$

La función  $h$  es continua, y  $h(a)$  y  $h(b)$  tienen signos opuestos (o alguno es cero). Por Bolzano, existe  $\xi \in [a, b]$  con  $h(\xi) = 0$ , esto es,  $g(\xi) = m$ . Si  $g(a) \neq g(b)$ , entonces  $h(a)h(b) < 0$  y Bolzano da  $\xi \in (a, b)$ .  $\square$

*Demostración.* Escribimos Taylor con resto de Lagrange alrededor de  $x_j$  en ambos sentidos:

$$u(x_{j\pm 1}) = u(x_j) \pm hu'(x_j) + \frac{h^2}{2}u''(x_j) \pm \frac{h^3}{6}u^{(3)}(x_j) + \frac{h^4}{24}u^{(4)}(\xi_j^\pm).$$

Aquí  $\xi_j^- \in (x_{j-1}, x_j)$  y  $\xi_j^+ \in (x_j, x_{j+1})$ . Al sumar, se cancelan los términos impares:

$$u(x_{j-1}) - 2u(x_j) + u(x_{j+1}) = h^2u''(x_j) + \frac{h^4}{24}(u^{(4)}(\xi_j^-) + u^{(4)}(\xi_j^+)).$$

Dividiendo por  $h^2$ :

$$\frac{u(x_{j-1}) - 2u(x_j) + u(x_{j+1}))}{h^2} = u''(x_j) + \frac{h^2}{24}(u^{(4)}(\xi_j^-) + u^{(4)}(\xi_j^+)).$$

Aplicando el Lema 5.13 a  $g = u^{(4)}$  en  $[\xi_j^-, \xi_j^+]$ , existe  $\xi_j \in [\xi_j^-, \xi_j^+] \subset (x_{j-1}, x_{j+1})$  tal que

$$u^{(4)}(\xi_j) = \frac{u^{(4)}(\xi_j^-) + u^{(4)}(\xi_j^+)}{2}.$$

Esto justifica la escritura abreviada de “absorber el promedio en un punto intermedio” y queda

$$\frac{u(x_{j-1}) - 2u(x_j) + u(x_{j+1}))}{h^2} = u''(x_j) + \frac{h^2}{12} u^{(4)}(\xi_j).$$

□

Con esta fórmula, el esquema para el vector incógnita

$$u^h = (u_1, \dots, u_m)^T$$

toma la forma lineal

$$A^h u^h = F^h,$$

con

$$A^h = \begin{pmatrix} \frac{2}{h^2} + \sigma & -\frac{1}{h^2} & 0 & \cdots & 0 \\ -\frac{1}{h^2} & \frac{2}{h^2} + \sigma & -\frac{1}{h^2} & \ddots & \vdots \\ 0 & \ddots & \ddots & \ddots & 0 \\ \vdots & \ddots & -\frac{1}{h^2} & \frac{2}{h^2} + \sigma & -\frac{1}{h^2} \\ 0 & \cdots & 0 & -\frac{1}{h^2} & \frac{2}{h^2} + \sigma \end{pmatrix}, \quad F^h = \begin{pmatrix} f(x_1) + \frac{\alpha}{h^2} \\ f(x_2) \\ \vdots \\ f(x_{m-1}) \\ f(x_m) + \frac{\beta}{h^2} \end{pmatrix}.$$

### 5.2.1 Estabilidad y convergencia

Al discretizar problemas de valores de contorno en espacio, obtenemos un sistema lineal global

$$A^h u^h = F^h,$$

que debe resolverse en forma simultánea para todos los nodos interiores. Por eso, la estabilidad no se analiza mediante factores de amplificación (como en evolución temporal), sino en términos de la invertibilidad de  $A^h$  y del tamaño de  $(A^h)^{-1}$ .

Para vectores de malla  $v = (v_1, \dots, v_m)^T$  usaremos la norma discreta

$$\|v\|_{2,h} := \left( h \sum_{j=1}^m |v_j|^2 \right)^{1/2}.$$

La norma inducida sobre matrices coincide con la norma espectral usual  $\|\cdot\|_2$ , pues el factor  $\sqrt{h}$  aparece en ambos lados.

**Definición 5.14** (Estabilidad en norma 2). *Una familia de discretizaciones  $A^h u^h = F^h$  es estable en norma 2 si existe  $C > 0$ , independiente de  $h$ , tal que  $A^h$  es invertible y*

$$\|(A^h)^{-1}\|_2 \leq C.$$

*Equivalente y más instructivamente: para todo vector  $v^h$ ,*

$$\|v^h\|_{2,h} \leq C \|A^h v^h\|_{2,h}.$$



Si  $u|_h$  denota la restricción de la solución exacta a la malla y  $\tau^h$  el error de truncamiento definido por

$$A^h(u|_h) = F^h + \tau^h,$$

entonces el error global  $E^h := u|_h - u^h$  satisface

$$A^h E^h = \tau^h,$$

y por lo tanto

$$\|E^h\|_{2,h} \leq \|(A^h)^{-1}\|_2 \|\tau^h\|_{2,h}.$$

En consecuencia, para problemas lineales estacionarios la convergencia se obtiene combinando *consistencia* ( $\tau^h \rightarrow 0$ ) y *estabilidad en norma 2*.

**Teorema 5.15** (Dirichlet con reacción: estabilidad + truncado = convergencia). *Si  $u \in C^4([0, 1])$ , entonces el esquema centrado para el problema de Dirichlet con reacción es de orden 2 y estable en norma 2. En consecuencia,*

$$\|E^h\|_{2,h} \leq Ch^2.$$

*Demostración.* **Paso 1: truncado (consistencia).** Aplicando la Proposición 5.12 a la solución exacta en cada nodo interior obtenemos

$$-\frac{u(x_{j-1}) - 2u(x_j) + u(x_{j+1}))}{h^2} + \sigma u(x_j) = f(x_j) - \frac{h^2}{12} u^{(4)}(\xi_j).$$

Por lo tanto, el error de truncamiento local satisface  $|\tau_j| \leq Ch^2$ , y de aquí

$$\|\tau^h\|_{2,h} \leq Ch^2.$$

**Paso 2: estabilidad.** La matriz  $A^h$  es real simétrica, luego sus autovalores son reales. Cada fila tiene centro

$$c_j = \frac{2}{h^2} + \sigma$$

y radio de Gershgorin

$$r_j \leq \frac{2}{h^2}.$$

Por Gershgorin, todo autovalor  $\lambda$  de  $A^h$  pertenece al intervalo

$$\left[ \sigma, \frac{4}{h^2} + \sigma \right].$$

En particular,

$$\lambda_{\min}(A^h) \geq \sigma > 0.$$

Como  $A^h$  es simétrica definida positiva,

$$\|(A^h)^{-1}\|_2 = \frac{1}{\lambda_{\min}(A^h)} \leq \frac{1}{\sigma},$$

que es una cota uniforme en  $h$  para el inverso: estabilidad en norma 2.

**Paso 3: estabilidad + truncado = convergencia.** Del error global  $A^h E^h = \tau^h$  se obtiene

$$\|E^h\|_{2,h} \leq \|(A^h)^{-1}\|_2 \|\tau^h\|_{2,h} \leq \frac{C}{\sigma} h^2.$$

□

### 5.2.2 Caso periódico y diagonalización de Fourier

Para

$$-u''(x) + \sigma u(x) = f(x), \quad u(0) = u(1), \quad u'(0) = u'(1),$$

toda la información de estabilidad puede leerse directamente del operador discreto mediante Fourier. Tomamos la malla uniforme  $x_j = jh$ ,  $j = 0, 1, \dots, N-1$ , con  $h = 1/N$ , e imponemos índices módulo  $N$ . El esquema es

$$-\frac{u_{j-1} - 2u_j + u_{j+1}}{h^2} + \sigma u_j = f(x_j), \quad j = 0, 1, \dots, N-1,$$

que incorpora automáticamente las condiciones de borde periódicas mediante las identificaciones  $u_{-1} = u_{N-1}$  y  $u_N = u_0$ . Para cada  $k = 0, 1, \dots, N-1$  consideramos el modo de Fourier discreto

$$w_j^{(k)} = e^{2\pi i k j / N}.$$

La condición sobre la derivada se interpreta en la malla con la diferencia centrada de primer orden

$$(\delta_x u)_j := \frac{u_{j+1} - u_{j-1}}{2h},$$

también con índices módulo  $N$ . En consecuencia,

$$(\delta_x u)_{j+N} = (\delta_x u)_j,$$

y en particular en el borde periódico

$$(\delta_x u)_0 = \frac{u_1 - u_{N-1}}{2h},$$

que coincide con el valor en el nodo identificado  $x = 1$ . Estos modos satisfacen las condiciones periódicas, pues

$$w_N^{(k)} = e^{2\pi i k} = w_0^{(k)}, \quad w_{-1}^{(k)} = e^{-2\pi i k / N} = w_{N-1}^{(k)}.$$

Sustituyendo directamente en las ecuaciones del esquema obtenemos

$$(L_h w^{(k)})_j = \left( \sigma + \frac{2}{h^2} \right) w_j^{(k)} - \frac{1}{h^2} w_{j-1}^{(k)} - \frac{1}{h^2} w_{j+1}^{(k)}.$$

Como

$$w_{j\pm 1}^{(k)} = e^{\pm 2\pi i k / N} w_j^{(k)},$$

obtenemos

$$(L_h w^{(k)})_j = \left[ \sigma + \frac{2}{h^2} - \frac{1}{h^2} \left( e^{2\pi i k / N} + e^{-2\pi i k / N} \right) \right] w_j^{(k)}.$$

Por lo tanto  $w^{(k)}$  es autofunción del operador discreto  $L_h$  con autovalor

$$\lambda_k = \sigma + \frac{2}{h^2} - \frac{1}{h^2} \left( e^{2\pi i k / N} + e^{-2\pi i k / N} \right).$$

Usando las identidades trigonométricas

$$e^{i\theta} + e^{-i\theta} = 2 \cos \theta, \quad 1 - \cos \theta = 2 \sin^2 \left( \frac{\theta}{2} \right),$$

con  $\theta = 2\pi k/N$ , llegamos a

$$\lambda_k = \sigma + \frac{2}{h^2}(1 - \cos(2\pi k/N)) = \sigma + \frac{4}{h^2} \sin^2\left(\frac{\pi k}{N}\right).$$

En particular,  $\lambda_k \geq \sigma > 0$  para todo  $k$ . Como los modos de Fourier discretos forman una base ortogonal de  $\mathbb{C}^N$ , el operador discreto queda diagonalizado en esa base y por lo tanto

$$\|(A_N)^{-1}\|_2 = \frac{1}{\min_k \lambda_k} \leq \frac{1}{\sigma}.$$

La estabilidad en norma 2 es entonces uniforme en  $h$  y, combinada con la consistencia de orden 2 de la fórmula centrada, da convergencia de orden 2.

**Observación 5.16.** Si se escribe el sistema lineal asociado, la matriz  $A_N$  resulta ser circulante:

$$A_N = \begin{pmatrix} \frac{2}{h^2} + \sigma & -\frac{1}{h^2} & 0 & \cdots & 0 & -\frac{1}{h^2} \\ -\frac{1}{h^2} & \frac{2}{h^2} + \sigma & -\frac{1}{h^2} & \ddots & & 0 \\ 0 & \ddots & \ddots & \ddots & \ddots & \vdots \\ \vdots & \ddots & -\frac{1}{h^2} & \frac{2}{h^2} + \sigma & -\frac{1}{h^2} & 0 \\ 0 & & \ddots & -\frac{1}{h^2} & \frac{2}{h^2} + \sigma & -\frac{1}{h^2} \\ -\frac{1}{h^2} & 0 & \cdots & 0 & -\frac{1}{h^2} & \frac{2}{h^2} + \sigma \end{pmatrix}.$$

Esta observación explica por qué Fourier diagonaliza el problema, pero no es necesaria para el cálculo anterior: basta reemplazar directamente los modos  $w^{(k)}$  en las ecuaciones discretas.

**Proposición 5.17** (No suficiencia en bordes generales). La cota del símbolo interior no garantiza estabilidad con condiciones de borde arbitrarias.

*Demostración.* Para  $-u'' = f$  con Neumann puro  $u'(0) = u'(1) = 0$ , el símbolo es  $\frac{4}{h^2} \sin^2(\theta/2) \geq 0$ , pero la matriz discreta tiene núcleo no trivial (el vector constante) y no es invertible.  $\square$

## 5.3 Ecuaciones en Derivadas Parciales

Estudiamos la ecuación del calor

$$u_t = \kappa u_{xx}, \quad x \in (0, 1), \quad t > 0,$$

con malla uniforme  $x_j = jh$ ,  $t_n = n\Delta t$ , y parámetro

$$\mu := \frac{\kappa \Delta t}{h^2}.$$

### 5.3.1 Discretización espacial centrada + Euler en tiempo

En espacio usamos la diferencia centrada

$$\delta_{xx} U_j^n := \frac{U_{j-1}^n - 2U_j^n + U_{j+1}^n}{h^2},$$

de orden 2.

### Euler explícito en tiempo.

$$\frac{U_j^{n+1} - U_j^n}{\Delta t} = \kappa \delta_{xx} U_j^n \iff U_j^{n+1} = \mu U_{j-1}^n + (1 - 2\mu) U_j^n + \mu U_{j+1}^n.$$

Si hay condiciones de Dirichlet, en cada paso  $U_0^n$  y  $U_{m+1}^n$  son datos conocidos; entonces  $U^{n+1}$  se obtiene con una sola barrida sobre los nodos interiores. Costo por paso:  $O(m)$  operaciones y sin resolver sistemas lineales.

### Euler implícito en tiempo.

$$\frac{U_j^{n+1} - U_j^n}{\Delta t} = \kappa \delta_{xx} U_j^{n+1} \iff -\mu U_{j-1}^{n+1} + (1 + 2\mu) U_j^{n+1} - \mu U_{j+1}^{n+1} = U_j^n.$$

Para Dirichlet, en cada tiempo queda un sistema tridiagonal

$$A_h U^{n+1} = b^n.$$

Se resuelve en costo  $O(m)$  con el algoritmo de Thomas (eliminación gaussiana para matrices tridiagonales), con memoria lineal y buen comportamiento numérico en este caso SPD.

### 5.3.2 Error de truncamiento

**Proposición 5.18** (Error de truncamiento de Euler explícito e implícito). *Sea  $u \in C^{2,4}([0, 1] \times [0, T])$  solución de la ecuación del calor  $u_t = \kappa u_{xx}$ . Definimos el error de truncamiento de cada esquema como el residuo que produce la solución exacta al ser sustituida en él.*

(a) **Euler explícito.** Definiendo

$$\tau_j^n := \frac{u(x_j, t^{n+1}) - u(x_j, t^n)}{\Delta t} - \kappa \delta_{xx} u(x_j, t^n),$$

se tiene  $\tau_j^n = O(\Delta t + h^2)$ . Más precisamente,

$$\tau_j^n = \frac{\Delta t}{2} \partial_{tt} u(x_j, t^n) - \frac{\kappa h^2}{12} \partial_{xxxx} u(x_j, t^n) + O(\Delta t^2 + h^4).$$

(b) **Euler implícito.** Definiendo

$$\tau_j^n := \frac{u(x_j, t^{n+1}) - u(x_j, t^n)}{\Delta t} - \kappa \delta_{xx} u(x_j, t^{n+1}),$$

se tiene igualmente  $\tau_j^n = O(\Delta t + h^2)$ .

*Demostración.* (a) Expandiendo en Taylor en  $t$  alrededor de  $t^n$ :

$$\frac{u(x_j, t^{n+1}) - u(x_j, t^n)}{\Delta t} = \partial_t u(x_j, t^n) + \frac{\Delta t}{2} \partial_{tt} u(x_j, t^n) + O(\Delta t^2).$$

Expandiendo en  $x$  alrededor de  $x_j$ :

$$\delta_{xx}u(x_j, t^n) = \partial_{xx}u(x_j, t^n) + \frac{h^2}{12}\partial_{xxxx}u(x_j, t^n) + O(h^4).$$

Restando y usando  $\partial_t u = \kappa \partial_{xx}u$ :

$$\tau_j^n = (\partial_t u - \kappa \partial_{xx}u) + \frac{\Delta t}{2}\partial_{tt}u - \frac{\kappa h^2}{12}\partial_{xxxx}u + O(\Delta t^2 + h^4) = \frac{\Delta t}{2}\partial_{tt}u - \frac{\kappa h^2}{12}\partial_{xxxx}u + O(\Delta t^2 + h^4).$$

(b) Se expande  $u(x_j, t^n)$  alrededor de  $t^{n+1}$ : la diferencia cociente da  $\partial_t u(x_j, t^{n+1}) + O(\Delta t)$ , y  $\delta_{xx}u(x_j, t^{n+1}) = \partial_{xx}u(x_j, t^{n+1}) + O(h^2)$ . El resultado sigue de  $\partial_t u = \kappa \partial_{xx}u$  evaluado en  $t^{n+1}$ .  $\square$

### 5.3.3 Consistencia y estabilidad de Lax–Richtmyer

En el caso lineal homogéneo escribimos el esquema como

$$U^{n+1} = S_h U^n,$$

y usamos la norma discreta

$$\|v\|_{2,h} := \left( h \sum_j |v_j|^2 \right)^{1/2}.$$

**Definición 5.19** (Consistencia del esquema). Sea  $u_h^n$  la restricción de la solución exacta a la malla en  $t_n$ . El error de truncamiento  $\tau_h^n$  se define por  $u_h^{n+1} = S_h u_h^n + \Delta t \tau_h^n$ . El esquema es **consistente** si  $\max_{n\Delta t \leq T} \|\tau_h^n\|_{2,h} \rightarrow 0$  cuando  $h, \Delta t \rightarrow 0$ .

**Definición 5.20** (Estabilidad de Lax–Richtmyer). El esquema es **estable** en  $[0, T]$  si existe  $C_T$  independiente de  $h, \Delta t$  tal que  $\|S_h^n\|_{2,h \rightarrow 2,h} \leq C_T$  para  $0 \leq n\Delta t \leq T$ .

### 5.3.4 Factores de amplificación de Fourier (borde periódico)

A partir de aquí suponemos **condiciones de borde periódicas**:

$$U_{j+N}^n = U_j^n \quad \text{para todo } j \in \mathbb{Z}.$$

Esto hace que el operador de actualización  $S_h$  sea una **matriz circulante** de tamaño  $N \times N$ : cada fila es un desplazamiento cíclico de la anterior. Las matrices circulantes son diagonalizadas por la transformada de Fourier discreta (DFT), cuyos modos son las sucesiones periódicas

$$v_j^{(k)} = e^{i\theta_k j}, \quad \theta_k = \frac{2\pi k}{N}, \quad k = 0, \dots, N-1.$$

Para cualquier operador de diferencias de coeficientes constantes  $L_h$  (es decir, para el cual  $(L_h v)_j$  sólo depende de traslaciones de  $v$ ), cada modo  $v^{(k)}$  es autofunción:

$$(L_h v^{(k)})_j = \widehat{L_h}(\theta_k) v_j^{(k)}$$

para cierto escalar  $\widehat{L_h}(\theta_k) \in \mathbb{C}$ . La función  $\theta \mapsto \widehat{L_h}(\theta)$  se llama el **símbolo** de  $L_h$ : es la representación en frecuencia del operador, obtenida evaluándolo en un modo puro  $e^{i\theta j}$ .

**Ejemplo 5.21** (Símbolo de la segunda diferencia centrada). Aplicando  $\delta_{xx}$  al modo  $v^{(k)}$ :

$$(\delta_{xx} v^{(k)})_j = \frac{e^{i\theta_k(j-1)} - 2e^{i\theta_k j} + e^{i\theta_k(j+1)}}{h^2} = e^{i\theta_k j} \frac{e^{-i\theta_k} - 2 + e^{i\theta_k}}{h^2}.$$

Usando  $e^{i\theta} + e^{-i\theta} = 2 \cos \theta$  y  $1 - \cos \theta = 2 \sin^2(\theta/2)$ , el símbolo resulta

$$\widehat{\delta_{xx}}(\theta_k) = \frac{2(\cos \theta_k - 1)}{h^2} = -\frac{4}{h^2} \sin^2\left(\frac{\theta_k}{2}\right) \leq 0.$$

El **factor de amplificación**  $G_h(\theta_k)$  es el símbolo del operador de actualización  $S_h$ :

$$S_h v^{(k)} = G_h(\theta_k) v^{(k)}.$$

Interpretación: en cada paso de tiempo, la componente de frecuencia  $k$  queda multiplicada por  $G_h(\theta_k)$ . Tras  $n$  pasos queda multiplicada por  $G_h(\theta_k)^n$ , por lo que la estabilidad uniforme hasta tiempo  $T$  exige controlar estas potencias para todo  $n\Delta t \leq T$ .

**Proposición 5.22** (Equivalencia con estabilidad de Fourier). Si  $S_h$  es circulante con factores de amplificación  $G_h(\theta_k)$ , entonces

$$\|S_h^n\|_{2,h \rightarrow 2,h} = \max_k |G_h(\theta_k)|^n.$$

En particular, para un tiempo final fijo  $T$ ,

$$\text{estabilidad de Lax-Richtmyer en } [0, T] \iff \sup_h \sup_{n\Delta t \leq T} \max_k |G_h(\theta_k)|^n \leq C_T.$$

Además, esto es equivalente a la existencia de  $\omega \in \mathbb{R}$  tal que, para  $h$  suficientemente pequeño,

$$\max_k |G_h(\theta_k)| \leq e^{\omega \Delta t} \iff \max_k |G_h(\theta_k)| = 1 + O(\Delta t).$$

*Demostración.*  $S_h = F_h^{-1} \text{diag}(G_h(\theta_k)) F_h$  con  $F_h$  unitario en  $\ell_h^2$  (Teorema 3.20). Por lo tanto,

$$S_h^n = F_h^{-1} \text{diag}(G_h(\theta_k)^n) F_h,$$

y al tomar norma operador en  $\ell_h^2$  se obtiene

$$\|S_h^n\|_{2,h \rightarrow 2,h} = \max_k |G_h(\theta_k)|^n.$$

La equivalencia con Lax-Richtmyer en  $[0, T]$  es inmediata al sustituir esta identidad en la definición  $\|S_h^n\|_{2,h \rightarrow 2,h} \leq C_T$  para todo  $n\Delta t \leq T$ .

Para la equivalencia con la cota por paso, sea  $M_h := \max_k |G_h(\theta_k)|$ .

Si  $M_h \leq e^{\omega \Delta t}$ , entonces para todo  $n\Delta t \leq T$ :

$$\|S_h^n\|_{2,h \rightarrow 2,h} = M_h^n \leq e^{\omega n \Delta t} \leq e^{\omega T},$$

y el esquema es estable.

Recíprocamente, si el esquema es estable en  $[0, T]$ , entonces existe  $C_T$  con

$$M_h^n \leq C_T \quad \forall n\Delta t \leq T.$$

Tomando  $n = N_h := \lfloor T/\Delta t \rfloor$ :

$$M_h \leq C_T^{1/N_h} = \exp\left(\frac{\log C_T}{N_h}\right).$$

Para  $\Delta t$  suficientemente pequeño,  $N_h \geq T/(2\Delta t)$ , luego

$$M_h \leq \exp\left(\frac{2\log C_T}{T} \Delta t\right) = e^{\omega\Delta t},$$

con  $\omega := 2\log(C_T)/T$ . Finalmente,

$$e^{\omega\Delta t} = 1 + \omega\Delta t + O(\Delta t^2),$$

de donde  $M_h = 1 + O(\Delta t)$ . □

### 5.3.5 Análisis de estabilidad de Fourier: explícito e implícito

**Euler explícito.** Aquí

$$S_h^E = I + \kappa\Delta t \delta_{xx},$$

por lo que

$$G_E(\theta) = 1 + \kappa\Delta t \widehat{\delta_{xx}}(\theta) = 1 - 4\mu \sin^2\left(\frac{\theta}{2}\right).$$

La condición  $|G_E(\theta)| \leq 1$  para todo  $\theta$  equivale a

$$0 \leq 4\mu \sin^2\left(\frac{\theta}{2}\right) \leq 2 \quad \forall \theta \quad \Longleftrightarrow \quad \mu \leq \frac{1}{2}.$$

Por lo tanto, Euler explícito es estable sólo bajo la condición  $\mu \leq 1/2$ .

**Euler implícito.** Aquí

$$(I - \kappa\Delta t \delta_{xx})U^{n+1} = U^n,$$

y por Fourier

$$G_I(\theta) = \frac{1}{1 - \kappa\Delta t \widehat{\delta_{xx}}(\theta)} = \frac{1}{1 + 4\mu \sin^2(\frac{\theta}{2})}.$$

Entonces  $0 < G_I(\theta) \leq 1$  para todo  $\mu > 0$  y todo  $\theta$ : Euler implícito es incondicionalmente estable en el sentido de Fourier (y por la proposición, en el sentido de Lax–Richtmyer periódico).

**Lema 5.23** (Buen planteo en  $L^2$  y cota del símbolo). *Sea  $\partial_t u = Lu$  una EDP lineal con coeficientes constantes en el dominio  $[0, 1]$  con condiciones de borde periódicas. Supongamos que  $L$  es diagonalizado por los modos de Fourier:  $Le^{2\pi i k x} = \lambda_k e^{2\pi i k x}$  para cada  $k \in \mathbb{Z}$ , con  $\lambda_k \in \mathbb{C}$ . Son equivalentes:*

(i) **Buen planteo en  $L^2$ :** existe  $\omega \in \mathbb{R}$  tal que para todo dato inicial  $u_0 \in L^2([0, 1])$  y todo  $t \in [0, T]$ ,

$$\|u(\cdot, t)\|_{L^2} \leq e^{\omega t} \|u_0\|_{L^2}.$$

(ii) **Cota uniforme del símbolo:**  $\sup_{k \in \mathbb{Z}} \operatorname{Re}(\lambda_k) \leq \omega < +\infty$ .

*Demostración.* La solución formal con dato  $u_0 = \sum_{k \in \mathbb{Z}} \hat{u}_0(k) e^{2\pi i k x}$  es

$$u(x, t) = \sum_{k \in \mathbb{Z}} \hat{u}_0(k) e^{\lambda_k t} e^{2\pi i k x},$$

pues  $L e^{2\pi i k x} = \lambda_k e^{2\pi i k x}$  y los modos forman una base ortonormal de  $L^2([0, 1])$ . Por la identidad de Parseval (Teorema 4.9), aplicada en cada tiempo:

$$\|u(\cdot, t)\|_{L^2}^2 = \sum_{k \in \mathbb{Z}} |\hat{u}_0(k)|^2 |e^{\lambda_k t}|^2 = \sum_{k \in \mathbb{Z}} |\hat{u}_0(k)|^2 e^{2 \operatorname{Re}(\lambda_k) t}. \quad (*)$$

(ii)  $\Rightarrow$  (i). Si  $\operatorname{Re}(\lambda_k) \leq \omega$  para todo  $k$ , entonces  $e^{2 \operatorname{Re}(\lambda_k) t} \leq e^{2\omega t}$  para todo  $k$ . Sustituyendo en (\*):

$$\|u(\cdot, t)\|_{L^2}^2 \leq e^{2\omega t} \sum_{k \in \mathbb{Z}} |\hat{u}_0(k)|^2 = e^{2\omega t} \|u_0\|_{L^2}^2,$$

y tomando raíz cuadrada se obtiene (i).

(i)  $\Rightarrow$  (ii). Supongamos que (ii) falla, es decir  $\sup_k \operatorname{Re}(\lambda_k) = +\infty$ . Entonces existe una sucesión  $k_j \in \mathbb{Z}$  tal que  $\operatorname{Re}(\lambda_{k_j}) \rightarrow +\infty$ . Para cada  $j$ , tomamos el dato modal  $u_0^{(j)}(x) = e^{2\pi i k_j x}$ , que cumple  $\|u_0^{(j)}\|_{L^2} = 1$ . La solución correspondiente es  $u^{(j)}(x, t) = e^{\lambda_{k_j} t} e^{2\pi i k_j x}$ , con

$$\|u^{(j)}(\cdot, t)\|_{L^2} = |e^{\lambda_{k_j} t}| = e^{\operatorname{Re}(\lambda_{k_j}) t} \xrightarrow{j \rightarrow \infty} +\infty \quad \text{para cualquier } t > 0.$$

Ninguna constante  $e^{\omega t}$  puede acotar esta sucesión, luego (i) falla.  $\square$

**Observación 5.24.** La condición (ii) dice que el espectro del generador  $L$  está acotado superiormente en su parte real, lo que corresponde a que la semigrupo  $e^{tL}$  crece a lo sumo exponencialmente. Para la ecuación del calor,  $\lambda_k = -\kappa(2\pi k)^2 \leq 0$ , por lo que se cumple con  $\omega = 0$ : la energía no crece. Para una ecuación de ondas o convección pura,  $\operatorname{Re}(\lambda_k) = 0$  y la energía se conserva. Si en cambio  $\operatorname{Re}(\lambda_k) \rightarrow +\infty$ , el problema continuo es intrínsecamente inestable (mal planteado en  $L^2$ ).

**Teorema 5.25** (Lax–Richtmyer, versión periódica lineal). Para un esquema lineal consistente de coeficientes constantes con borde periódico,

$$\text{convergencia en } \ell_h^2 \iff \text{consistencia} + \text{estabilidad}.$$

*Demostración.* Sea  $e^n := u_h^n - U^n$  el error en el paso  $n$ ; por hipótesis  $e^0 = 0$ . De la definición de  $\tau_h^n$  y del esquema numérico se obtiene la **ecuación de error**:

$$e^{n+1} = S_h e^n + \Delta t \tau_h^n, \quad e^0 = 0.$$



( $\Leftarrow$ ) **Estabilidad + consistencia  $\Rightarrow$  convergencia.**

Desarrollando la recurrencia hacia atrás (suma telescópica):

$$e^n = S_h^{n-1}(\Delta t \tau_h^0) + S_h^{n-2}(\Delta t \tau_h^1) + \cdots + \Delta t \tau_h^{n-1} = \Delta t \sum_{m=0}^{n-1} S_h^{n-1-m} \tau_h^m.$$

Aplicando desigualdad triangular y la cota de estabilidad  $\|S_h^{n-1-m}\|_{2,h \rightarrow 2,h} \leq C_T$ :

$$\|e^n\|_{2,h} \leq \Delta t \sum_{m=0}^{n-1} \|S_h^{n-1-m}\|_{2,h \rightarrow 2,h} \|\tau_h^m\|_{2,h} \leq C_T \Delta t \cdot n \cdot \max_{0 \leq m \leq n-1} \|\tau_h^m\|_{2,h}.$$

Como  $n\Delta t \leq T$ , resulta  $\|e^n\|_{2,h} \leq C_T T \max_m \|\tau_h^m\|_{2,h} \xrightarrow{h, \Delta t \rightarrow 0} 0$  por consistencia.

( $\Rightarrow$ ) **Convergencia  $\Rightarrow$  estabilidad.**

Procedemos por reducción al absurdo en dos pasos.

*Paso 1: cota de buen planteo del problema continuo, uniforme en  $k$ .*

Por el Lema 5.23, el buen planteo de la EDP en  $L^2$  equivale a que exista  $\omega \in \mathbb{R}$  con  $\operatorname{Re}(\lambda(\theta_k)) \leq \omega$  para todo  $k$ ; en particular, para  $t \in [0, T]$ :

$$|e^{\lambda(\theta_k)t}| = e^{\operatorname{Re}(\lambda(\theta_k))t} \leq e^{\omega T} \quad \forall k. \quad (\text{BP})$$

*Paso 2: argumento de contradicción.*

Supongamos que el esquema *no* es estable. Entonces existen sucesiones  $h_j \rightarrow 0^+$ , índices modales  $k_j$  y pasos enteros  $n_j$  con  $n_j \Delta t_j \leq T$ , tales que

$$|G_{h_j}(\theta_{k_j})|^{n_j} \xrightarrow{j \rightarrow \infty} +\infty.$$

Para cada  $j$ , tomemos como dato inicial el modo discreto  $v^{(k_j)}$ , normalizado:  $\|v^{(k_j)}\|_{2,h_j} = 1$  (pues  $h_j \cdot N_j = 1$ ).

*Lado numérico.* Como  $S_{h_j}$  es circulante,  $S_{h_j}^{n_j} v^{(k_j)} = G_{h_j}(\theta_{k_j})^{n_j} v^{(k_j)}$ , luego

$$\|U_j^{n_j}\|_{2,h_j} = |G_{h_j}(\theta_{k_j})|^{n_j} \rightarrow +\infty.$$

*Lado continuo.* La solución exacta de la EDP con dato  $e^{i\theta_{k_j}x}$  es  $u_j(x, t) = e^{\lambda(\theta_{k_j})t} e^{i\theta_{k_j}x}$ , de modo que su restricción a la malla en el paso  $n_j$  es

$$(u_j)_{h_j}^{n_j} = e^{\lambda(\theta_{k_j})t_{n_j}} v^{(k_j)}.$$

Usando la cota (BP):

$$\|(u_j)_{h_j}^{n_j}\|_{2,h_j} = |e^{\lambda(\theta_{k_j})t_{n_j}}| \leq e^{\omega T}.$$

*Contradicción.* La hipótesis de convergencia aplicada al dato  $e^{i\theta_{k_j}x}$  da

$$\|U_j^{n_j} - (u_j)_{h_j}^{n_j}\|_{2,h_j} \rightarrow 0 \quad (j \rightarrow \infty).$$

Pero por desigualdad triangular:

$$|G_{h_j}(\theta_{k_j})|^{n_j} = \|U_j^{n_j}\|_{2,h_j} \leq \|U_j^{n_j} - (u_j)_{h_j}^{n_j}\|_{2,h_j} + \|(u_j)_{h_j}^{n_j}\|_{2,h_j} \leq o(1) + e^{\omega T},$$

en contradicción con  $|G_{h_j}(\theta_{k_j})|^{n_j} \rightarrow +\infty$ . Queda demostrado que  $\sup_{h,k,n\Delta t \leq T} |G_h(\theta_k)|^n \leq C_T < \infty$ , es decir, el esquema es estable con  $C_T = e^{\omega T} + 1$  para  $h$  suficientemente pequeño.  $\square$

**Observación 5.26.** *Fuera del caso periódico lineal, Fourier no diagonaliza el operador completo: el control del borde requiere análisis adicional (como en el Teorema 5.15 para Dirichlet). Sin embargo, es posible demostrar que las conclusiones del análisis de estabilidad de Fourier siguen siendo una condición necesaria para la estabilidad de Lax–Richtmyer, aunque no sean suficientes. Por ese motivo, en la práctica se suele usar el análisis de estabilidad de Fourier como una primera prueba de estabilidad, que frecuentemente arroja resultados ajustados, aunque luego se requiere un análisis más detallado para casos con bordes generales o no lineales.*

## Chapter 6

# Métodos iterativos para Ecuaciones No Lineales

Resolver  $f(x) = 0$  para una función no lineal  $f$  es uno de los problemas más recurrentes en la práctica científica y en la ingeniería. El problema aparece de forma *directa* cuando el modelo de un fenómeno conduce a una ecuación trascendente para la que no existe fórmula cerrada. Un ejemplo clásico: la ley de Planck para la radiancia espectral es

$$I(\lambda; T) = \frac{2hc^2}{\lambda^5} \frac{1}{e^{hc/(\lambda k_B T)} - 1}.$$

Maximizar  $I$  respecto de  $\lambda$  e introducir la variable adimensional  $x = hc/(\lambda k_B T)$  reduce el problema a la ecuación trascendente

$$5 - x = 5e^{-x},$$

cuya raíz de interés físico es  $x^* \approx 4.965$ . Esta constante relaciona la temperatura de las estrellas con su color y es la base de la pirometría óptica: no hay forma de extraerla sin métodos numéricos.

El problema también aparece *indirectamente* en optimización y ajuste de curvas. En efecto, cuando se ajusta un modelo  $m(t; \theta)$  no lineal en sus parámetros  $\theta$  minimizando el error cuadrático

$$\Phi(\theta) = \frac{1}{2} \sum_i (m(t_i; \theta) - y_i)^2,$$

se requiere, como condición necesaria de primer orden, que el gradiente se anule. En este caso, se obtienen las ecuaciones normales

$$\nabla_{\theta} \Phi = 0$$

que son un sistema no lineal.

**Ejemplo 6.1.** Para ajustar los parámetros  $\theta = (A, \beta, \omega, \varphi)$  del oscilador amortiguado

$$x(t; \theta) = Ae^{-\beta t} \cos(\omega t + \varphi)$$

contra datos experimentales  $(t_i, x_i^{\text{obs}})$ , se plantea el problema de cuadrados mínimos no lineal:

$$\min_{\theta} \Phi(\theta) = \frac{1}{2} \sum_{i=1}^N (x(t_i; \theta) - x_i^{\text{obs}})^2.$$

La condición necesaria de primer orden  $\nabla\Phi(\theta) = 0$  da el sistema de cuatro ecuaciones

$$\frac{\partial\Phi}{\partial\theta_j} = \sum_{i=1}^N (x(t_i; \theta) - x_i^{\text{obs}}) \frac{\partial x}{\partial\theta_j}(t_i; \theta) = 0, \quad j = 1, 2, 3, 4,$$

donde las derivadas parciales son

$$\begin{aligned} \frac{\partial x}{\partial A} &= e^{-\beta t} \cos(\omega t + \varphi), \\ \frac{\partial x}{\partial \beta} &= -Ate^{-\beta t} \cos(\omega t + \varphi), \\ \frac{\partial x}{\partial \omega} &= -Ate^{-\beta t} \sin(\omega t + \varphi), \\ \frac{\partial x}{\partial \varphi} &= -Ae^{-\beta t} \sin(\omega t + \varphi). \end{aligned}$$

Dado que  $\theta$  aparece dentro de exponentes y funciones trigonométricas, este sistema es no lineal y no puede resolverse con álgebra lineal: requiere métodos iterativos.

Si bien los métodos de optimización están muy emparentados con los métodos de resolución de ecuaciones no lineales, en este capítulo nos centraremos exclusivamente en estos últimos. Por simplicidad, también nos limitaremos a funciones de una variable, aunque la mayoría de los métodos se extienden a sistemas no lineales multidimensionales. Desarrollamos cuatro métodos clásicos: bisección, iteración de punto fijo, Newton y la secante.

Los métodos que estudiaremos en este capítulo se conocen como *métodos iterativos*. En efecto, el hilo conductor de este capítulo es la construcción de sucesiones  $\{x_k\}$  convergentes a una raíz, y el análisis cuantitativo de su velocidad de convergencia.

## 6.1 El método de bisección

El método más simple y robusto se basa en el Teorema de Bolzano: si  $f$  es continua y cambia de signo en  $[a, b]$ , entonces tiene al menos una raíz en ese intervalo.

**Definición 6.2** (Método de bisección). *Dados  $a_0 < b_0$  con  $f(a_0)f(b_0) < 0$ , en cada paso se define el punto medio  $m_k = (a_k + b_k)/2$  y se selecciona el subintervalo donde  $f$  cambia de signo:*

$$[a_{k+1}, b_{k+1}] = \begin{cases} [a_k, m_k] & \text{si } f(a_k)f(m_k) \leq 0, \\ [m_k, b_k] & \text{en caso contrario.} \end{cases}$$

**Teorema 6.3** (Convergencia de bisección). *Sea  $f \in C([a, b])$  con  $f(a)f(b) < 0$ . Existe  $x^* \in [a, b]$  con  $f(x^*) = 0$  y*

$$|m_k - x^*| \leq \frac{b - a}{2^{k+1}}.$$

*La convergencia es lineal con factor  $1/2$ .*

*Demostración.* En cada paso el intervalo se divide a la mitad y  $x^*$  permanece en él. Luego  $b_k - a_k = (b - a)/2^k$ , y como  $m_k$  es el punto medio,  $|m_k - x^*| \leq (b_k - a_k)/2 = (b - a)/2^{k+1}$ .  $\square$

**Corolario 6.4** (Número de iteraciones necesarias). *Para alcanzar un error menor que  $\varepsilon > 0$  basta con*

$$k \geq \left\lceil \log_2 \frac{b-a}{\varepsilon} \right\rceil - 1$$

*iteraciones.*

**Observación 6.5.** *Para estimar cuántas iteraciones son necesarias conviene recordar que  $\log_2 10 \approx 3.32$ , de modo que cada dígito decimal de precisión extra cuesta aproximadamente 3.32 iteraciones adicionales.*

**Definición 6.6** (Orden de convergencia). *Sea  $\{x_k\}$  una sucesión que converge a  $x^*$ . Se dice que  $\{x_k\}$  converge con orden  $p \geq 1$  si existe  $C > 0$  tal que*

$$|x_{k+1} - x^*| \leq C |x_k - x^*|^p$$

*para  $k$  suficientemente grande. El caso  $p = 1$  con  $C < 1$  se llama convergencia lineal (o geométrica). El caso  $p = 2$  se llama convergencia cuadrática. Cuando  $p = 1$  pero  $|x_{k+1} - x^*|/|x_k - x^*| \rightarrow 0$ , se habla de convergencia superlineal.*

**Observación 6.7.** *El orden de convergencia describe la tasa a la que se acumulan los dígitos correctos: con orden  $p$ , en cada iteración el número de dígitos correctos se multiplica aproximadamente por  $p$ . La bisección tiene  $p = 1$  con  $C = 1/2$ ; Newton tiene  $p = 2$ ; la secante tiene  $p = \varphi \approx 1.618$ .*

## 6.2 Iteraciones de punto fijo

Muchas ecuaciones  $f(x) = 0$  pueden reescribirse como  $x = g(x)$ , transformando la búsqueda de una raíz en la de un punto fijo de  $g$ .

**Definición 6.8** (Iteración de punto fijo). *Dada  $g : I \rightarrow \mathbb{R}$ , la iteración*

$$x_{k+1} = g(x_k), \quad k \geq 0,$$

*busca  $x^* \in I$  tal que  $x^* = g(x^*)$ .*

**Teorema 6.9** (Principio de contracción en  $\mathbb{R}$ ). *Sea  $I = [a, b]$ ,  $g : I \rightarrow I$  continua y derivable con*

$$\sup_{x \in I} |g'(x)| \leq q < 1.$$

*Entonces:*

(i) *Existe un único punto fijo  $x^* \in I$ .*

(ii) *Para todo  $x_0 \in I$ ,*

$$|x_k - x^*| \leq q^k |x_0 - x^*|.$$

(iii) *La convergencia es lineal con tasa  $q$ .*

*Demostración. Contracción.* La condición  $|g'| \leq q$  y el Teorema del Valor Medio dan  $|g(x) - g(y)| \leq q|x - y|$  para todo  $x, y \in I$ .

*Existencia.* Primero,

$$|x_{j+1} - x_j| = |g(x_j) - g(x_{j-1})| \leq q|x_j - x_{j-1}| \leq \cdots \leq q^j|x_1 - x_0|.$$

Luego, para  $n > m$ , por desigualdad triangular:

$$|x_n - x_m| \leq \sum_{j=m}^{n-1} |x_{j+1} - x_j| \leq \sum_{j=m}^{n-1} q^j|x_1 - x_0| = \left( \sum_{j=m}^{n-1} q^j \right) |x_1 - x_0|.$$

Para la suma de potencias, factorizamos  $q^m$  y reindexamos:

$$\sum_{j=m}^{n-1} q^j = q^m \sum_{j=m}^{n-1} q^{j-m} = q^m \sum_{r=0}^{n-1-m} q^r.$$

Resultado auxiliar (fórmula geométrica finita):

$$\sum_{r=0}^N q^r = \frac{1 - q^{N+1}}{1 - q} \quad (q \neq 1).$$

Con  $N = n - 1 - m$ :

$$\sum_{j=m}^{n-1} q^j = q^m \frac{1 - q^{n-m}}{1 - q} = \frac{q^m - q^n}{1 - q}.$$

Entonces

$$|x_n - x_m| \leq \frac{q^m - q^n}{1 - q} |x_1 - x_0| \leq \frac{q^m}{1 - q} |x_1 - x_0|.$$

Como  $q < 1$ , el lado derecho tiende a 0 cuando  $m \rightarrow \infty$ , así  $\{x_k\}$  es de Cauchy.  $\mathbb{R}$  es completo, luego existe  $x^* = \lim_{k \rightarrow \infty} x_k \in I$ . Tomando límite en  $x_{k+1} = g(x_k)$  y usando la continuidad de  $g$  se obtiene  $x^* = g(x^*)$ .

*Unicidad.* Si  $y^*$  fuera otro punto fijo, entonces  $|x^* - y^*| = |g(x^*) - g(y^*)| \leq q|x^* - y^*|$ , lo que implica  $(1 - q)|x^* - y^*| \leq 0$ ; como  $q < 1$ , resulta  $x^* = y^*$ .

*Tasa de convergencia.* Aplicando la desigualdad de contracción iteradamente:  $|x_k - x^*| = |g(x_{k-1}) - g(x^*)| \leq q|x_{k-1} - x^*| \leq \cdots \leq q^k|x_0 - x^*|$ .  $\square$

**Corolario 6.10** (Cota a priori uniforme). *Bajo las hipótesis del Teorema 6.9, para todo  $k \geq 1$ ,*

$$|x_k - x^*| \leq \frac{q^k}{1 - q} |x_1 - x_0|.$$

*En particular, para lograr  $|x_k - x^*| < \varepsilon$  basta con*

$$k > \frac{\log(\varepsilon(1 - q)/|x_1 - x_0|)}{\log q}.$$

*Esta cota solo requiere conocer  $|x_1 - x_0| = |g(x_0) - x_0|$ , que es computable sin conocer la ubicación de  $x^*$ .*

*Demostración.* Para todo  $n > k$  se tiene la identidad telescópica finita

$$x_n - x_k = \sum_{j=k}^{n-1} (x_{j+1} - x_j).$$

Como  $x_n \rightarrow x^*$ , al tomar límite en  $n$ :

$$x^* - x_k = \sum_{j=k}^{\infty} (x_{j+1} - x_j),$$

y por tanto

$$|x_k - x^*| \leq \sum_{j=k}^{\infty} |x_{j+1} - x_j| = \sum_{j=k}^{\infty} |g(x_j) - g(x_{j-1})| \leq \sum_{j=k}^{\infty} q |x_j - x_{j-1}| \leq \sum_{j=k}^{\infty} q^j |x_1 - x_0| = \frac{q^k}{1-q} |x_1 - x_0|.$$

□

**Lema 6.11** (Convergencia cuadrática cuando  $g'(x^*) = 0$ ). Sea  $g \in C^2$  en un entorno de  $x^*$  con  $g(x^*) = x^*$  y  $g'(x^*) = 0$ . Existe  $\delta > 0$  tal que, si  $|x_0 - x^*| < \delta$ , la iteración  $x_{k+1} = g(x_k)$  satisface

$$|x_{k+1} - x^*| \leq C |x_k - x^*|^2, \quad C = \frac{1}{2} \sup_{|x-x^*|<\delta} |g''(x)|.$$

En particular, la convergencia es cuadrática.

*Demostración.* Por Taylor con resto de Lagrange existe  $\xi_k$  entre  $x_k$  y  $x^*$  tal que

$$x_{k+1} - x^* = g(x_k) - g(x^*) = g'(x^*)(x_k - x^*) + \frac{1}{2}g''(\xi_k)(x_k - x^*)^2 = \frac{1}{2}g''(\xi_k)(x_k - x^*)^2,$$

donde se usó  $g'(x^*) = 0$ . Tomando valor absoluto y acotando  $|g''|$  en el entorno se obtiene la cota del enunciado. □

**Ejemplo 6.12** ( $\cos x = x$ : existencia, unicidad y convergencia). La ecuación  $\cos x = x$  es equivalente al problema de punto fijo  $x = g(x)$  con  $g(x) = \cos x$ . Puede resolverse en una calculadora pulsando repetidamente la tecla coseno: partiendo de cualquier número inicial, la pantalla converge siempre a  $x^* \approx 0.7391$ .

*Existencia.* Sea  $h(x) = \cos x - x$ . Como  $h(0) = 1 > 0$  y  $h(\pi/2) = -\pi/2 < 0$ , el Teorema de Bolzano garantiza la existencia de  $x^* \in (0, \pi/2)$  con  $h(x^*) = 0$ , es decir  $\cos(x^*) = x^*$ .

*Unicidad.*  $h'(x) = -\sin x - 1 \leq 0$  para todo  $x$ , con igualdad solo en  $x = -\pi/2 + 2k\pi$ . Luego  $h$  es estrictamente decreciente y puede tener a lo sumo un cero.

*Convergencia.* El intervalo  $I = [0, 1]$  es invariante bajo  $g$ : como  $g$  es decreciente con  $g(0) = 1$  y  $g(1) = \cos(1) \approx 0.54$ , se tiene  $g([0, 1]) \subset [0, 1]$ . Además

$$|g'(x)| = |-\sin x| = \sin x \leq \sin(1) < 1 \quad \text{para todo } x \in [0, 1].$$

El Teorema 6.9 garantiza convergencia con tasa  $q = \sin(1) \approx 0.841$ .

**Ejemplo 6.13** (Convergencia y divergencia según la formulación). Para resolver  $x^2 - 2 = 0$  (raíz positiva  $x^* = \sqrt{2}$ ) se puede escribir de varias formas:

(a)  $g(x) = 2/x$ :  $|g'(x)| = 2/x^2$ ; en  $x = \sqrt{2}$  vale  $|g'| = 1$ , no es contracción.

(b)  $g(x) = (x + 2/x)/2$  (media aritmético-geométrica):  $g'(x) = 1/2 - 1/x^2$ ; en  $x = \sqrt{2}$ ,  $g' = 0$ , de modo que la convergencia es en realidad cuadrática (véase el método de Newton, Sección 6.3).

La reformulación elegida determina tanto la convergencia como su velocidad.

## 6.3 El método de Newton

### 6.3.1 Derivación

Si  $f$  es diferenciable, la idea de Newton es reemplazar  $f$  por su aproximación lineal alrededor del iterado actual  $x_k$ :

$$f(x) \approx f(x_k) + f'(x_k)(x - x_k).$$

Igualando a cero y despejando  $x$  se obtiene el siguiente iterado:

**Definición 6.14** (Método de Newton en  $\mathbb{R}$ ).

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}.$$

*Esta iteración está definida siempre que  $f'(x_k) \neq 0$ .*

### 6.3.2 Convergencia

**Proposición 6.15** (Newton como punto fijo: anulación de  $g'$ ). *La iteración de Newton es una iteración de punto fijo con  $g(x) = x - f(x)/f'(x)$ . Si  $x^*$  es raíz simple de  $f$  ( $f(x^*) = 0$ ,  $f'(x^*) \neq 0$ ), entonces  $g'(x^*) = 0$ . Por el Lema 6.11, la iteración converge cuadráticamente para  $x_0$  suficientemente cercano a  $x^*$ .*

*Demostración.* Aplicando la regla del cociente a  $g(x) = x - f(x)/f'(x)$ :

$$g'(x) = 1 - \frac{[f'(x)]^2 - f(x)f''(x)}{[f'(x)]^2} = \frac{f(x)f''(x)}{[f'(x)]^2}.$$

Como  $f(x^*) = 0$ , se concluye  $g'(x^*) = 0$ . □

**Teorema 6.16** (Convergencia cuadrática de Newton). *Sea  $f \in C^2$  con  $f(x^*) = 0$  y  $f'(x^*) \neq 0$ . Existe  $\delta > 0$  tal que, si  $|x_0 - x^*| < \delta$ ,*

$$|x_{k+1} - x^*| \leq C |x_k - x^*|^2, \quad C = \frac{\sup_{|x-x^*|<\delta} |f''(x)|}{2 \inf_{|x-x^*|<\delta} |f'(x)|}.$$

*En particular, el número de dígitos correctos se duplica aproximadamente en cada iteración.*

*Demostración.* Por la fórmula de Taylor con resto de Lagrange,

$$0 = f(x^*) = f(x_k) + f'(x_k)(x^* - x_k) + \frac{1}{2}f''(\xi_k)(x^* - x_k)^2$$

para algún  $\xi_k$  entre  $x_k$  y  $x^*$ . Dividiendo por  $f'(x_k)$  y reordenando:

$$x^* - x_{k+1} = x^* - x_k + \frac{f(x_k)}{f'(x_k)} = -\frac{f''(\xi_k)}{2f'(x_k)}(x^* - x_k)^2.$$

Tomando valor absoluto y acotando  $|f''|$  e  $|1/f'|$  en el entorno, se obtiene la cota cuadrática con  $C$  como en el enunciado. □

**Observación 6.17.** *La convergencia cuadrática es local: requiere que  $x_0$  esté suficientemente cerca de  $x^*$ . Para funciones convexas se puede garantizar convergencia desde un conjunto de condiciones iniciales más amplio (véase el Teorema 6.18 a continuación).*



### 6.3.3 Newton para funciones convexas

Cuando  $f$  es estrictamente convexa existe un resultado más preciso: bajo la *condición de Fourier*  $f(x_0) \cdot f''(x_0) > 0$ , Newton converge *monótonamente* desde  $x_0$  sin necesidad de estar muy próximo a la raíz.

**Teorema 6.18** (Newton para funciones estrictamente convexas). *Sea  $f \in C^2([a, b])$  con  $f''(x) > 0$  para todo  $x \in [a, b]$ , y sea  $x^* \in (a, b)$  la única raíz de  $f$  en ese intervalo. Si  $x_0 \in [x^*, b]$  y  $f(x_0) \geq 0$  (condición de Fourier), entonces:*

(i) *Los iterados satisfacen  $x^* \leq x_{k+1} \leq x_k$  para todo  $k \geq 0$ .*

(ii) *La sucesión  $\{x_k\}$  converge monótonamente a  $x^*$ .*

(iii) *La convergencia es cuadrática.*

La condición  $f(x_0) > 0$ ,  $f''(x_0) > 0$  se denomina condición de Fourier.

*Demostración.* Sea

$$g(x) = x - \frac{f(x)}{f'(x)}, \quad x_{k+1} = g(x_k).$$

Como  $f$  es continua,  $x^*$  es la única raíz y  $f(x_0) \geq 0$  con  $x_0 \geq x^*$ , se tiene  $f(x) \geq 0$  para todo  $x \in [x^*, x_0]$ .

*Paso 1 (función creciente).* Si  $x \in (x^*, x_0]$ , entonces  $f(x) > 0$  (unicidad de raíz). Por el Teorema del Valor Medio entre  $x^*$  y  $x$ , existe  $\xi \in (x^*, x)$  tal que

$$f'(\xi) = \frac{f(x) - f(x^*)}{x - x^*} = \frac{f(x)}{x - x^*} > 0.$$

Como  $f'' > 0$ ,  $f'$  es creciente, luego  $f'(x) \geq f'(\xi) > 0$ .

*Paso 2 (cota inferior).* Tomemos  $x_k \in [x^*, x_0]$ . La convexidad da

$$f(x^*) \geq f(x_k) + f'(x_k)(x^* - x_k),$$

y como  $f(x^*) = 0$ :

$$0 \geq f(x_k) + f'(x_k)(x^* - x_k).$$

Además, por el Paso 1,  $f'(x_k) > 0$ , y podemos dividir:

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} \geq x^*.$$

*Paso 3 (monotonía).* Como  $f$  es creciente en  $(x^*, x_0]$  y  $x_k \geq x^*$ , se tiene  $f(x_k) \geq 0$ . Entonces

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} \leq x_k.$$

Por lo tanto,  $x^* \leq x_{k+1} \leq x_k$ . Repitiendo este paso desde  $x_0$ , la sucesión es decreciente y acotada inferiormente por  $x^*$ , luego converge a algún  $\ell \geq x^*$ .

Además,  $g$  es continua en un entorno de  $\ell$  (si  $\ell > x^*$ , por el mismo argumento del Paso 1 se tiene  $f'(\ell) > 0$ ), y por tanto

$$\ell = \lim_{k \rightarrow \infty} x_{k+1} = \lim_{k \rightarrow \infty} g(x_k) = g(\ell).$$

Así,  $f(\ell) = 0$ , contradicción con la unicidad de la raíz y  $\ell > x^*$ . Por lo tanto,  $\ell = x^*$ . La convergencia cuadrática se sigue del Teorema 6.16.  $\square$

**Corolario 6.19** (Caso cóncavo (simétrico)). *Sea  $f \in C^2([a, b])$  con  $f''(x) < 0$  para todo  $x \in [a, b]$ , y sea  $x^* \in (a, b)$  la única raíz de  $f$  en ese intervalo. Si  $x_0 \in [a, x^*]$  y  $f(x_0) \leq 0$  (condición de Fourier), entonces:*

(i) *Los iterados satisfacen  $x_k \leq x_{k+1} \leq x^*$  para todo  $k \geq 0$ .*

(ii) *La sucesión  $\{x_k\}$  converge monótonamente a  $x^*$ .*

(iii) *La convergencia es cuadrática.*

En particular, este es el caso de la condición de Fourier  $f(x_0) < 0$  y  $f''(x_0) < 0$ .

*Demostración.* Aplicamos el Teorema 6.18 a  $\tilde{f} = -f$ , que es estrictamente convexa. La iteración de Newton no cambia porque

$$x - \frac{\tilde{f}(x)}{\tilde{f}'(x)} = x - \frac{-f(x)}{-f'(x)} = x - \frac{f(x)}{f'(x)}.$$

Además,  $\tilde{f}(x_0) \geq 0$  y  $\tilde{f}''(x_0) > 0$ , de modo que se obtiene la conclusión monótona y la convergencia cuadrática para la misma sucesión  $\{x_k\}$ .  $\square$

**Ejemplo 6.20** (Ley de Wien: convergencia desde  $x_0 \geq x^*$ ). *Para  $f(x) = x - 5 + 5e^{-x}$  se tiene  $f''(x) = 5e^{-x} > 0$  (convexa). Las raíces son  $x = 0$  (trivial) y  $x^* \approx 4.965$ . En  $x > x^*$  se cumple  $f(x) > 0$  y  $f'(x) = 1 - 5e^{-x} > 0$ , por lo que la condición de Fourier  $f(x_0) \cdot f''(x_0) > 0$  es satisfecha automáticamente para cualquier  $x_0 \geq x^*$ . El Teorema 6.18 garantiza convergencia monótona desde cualquier tal  $x_0$ ; en particular,  $x_0 = 5$  es una elección práctica.*

## 6.4 El método de la secante

El método de Newton requiere evaluar  $f'$ , lo cual no siempre es cómodo. La secante reemplaza la derivada por una diferencia finita usando los dos últimos iterados:

**Definición 6.21** (Método de la secante). *Dados dos puntos iniciales  $x_0 \neq x_1$ , la iteración es*

$$x_{k+1} = x_k - f(x_k) \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})}, \quad k \geq 1.$$

*Geométricamente,  $x_{k+1}$  es la intersección con el eje  $x$  de la recta que pasa por  $(x_{k-1}, f(x_{k-1}))$  y  $(x_k, f(x_k))$ .*

**Observación 6.22.** La fórmula de la secante es análoga a la de Newton,

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)},$$

con la derivada  $f'(x_k)$  reemplazada por el cociente incremental

$$\frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}} \approx f'(x_k).$$

La ventaja es que no es necesario calcular  $f'$ , lo cual es especialmente valioso cuando la derivada es difícil de obtener analíticamente o costosa de evaluar.

**Teorema 6.23** (Convergencia superlineal de la secante). Sea  $f \in C^2$  con  $f(x^*) = 0$  y  $f'(x^*) \neq 0$ . Existen  $\delta > 0$  y  $C > 0$  tales que, si  $x_0, x_1 \in (x^* - \delta, x^* + \delta)$ ,

$$\frac{|x_{k+1} - x^*|}{|x_k - x^*|^\varphi} \rightarrow C, \quad \varphi = \frac{1 + \sqrt{5}}{2} \approx 1.618.$$

En particular la convergencia es de orden  $\varphi$ : superlineal pero sublineal respecto del orden cuadrático de Newton.

*Demostración.* Escribimos  $e_k = x^* - x_k$ ,  $f'_* = f'(x^*)$ ,  $f''_* = f''(x^*)$  y  $c_\infty = f''_*/(2f'_*)$ .

*Paso 1: relación de recurrencia*  $e_{k+1} = -c_k e_k e_{k-1}$ . De  $f(x^*) = 0$  y la definición de la secante,

$$e_{k+1} = \frac{e_{k-1}f(x_k) - e_k f(x_{k-1})}{f(x_k) - f(x_{k-1})}.$$

Expandiendo por Taylor,  $f(x_j) = -f'_* e_j + \frac{1}{2} f''_* e_j^2 + O(e_j^3)$ . Los términos en  $f'_*$  se cancelan exactamente en el numerador:

$$e_{k-1}f(x_k) - e_k f(x_{k-1}) = \underbrace{(-f'_* e_k e_{k-1} + f'_* e_k e_{k-1})}_{=0} + \frac{1}{2} f''_* e_k e_{k-1} (e_k - e_{k-1}) + O(|e_k e_{k-1}|(|e_k| + |e_{k-1}|)^2).$$

El denominador, en cambio, retiene el término lineal:

$$f(x_k) - f(x_{k-1}) = -(e_k - e_{k-1})(f'_* + O(|e_k| + |e_{k-1}|)).$$

Dividiendo, los factores  $(e_k - e_{k-1})$  se cancelan y se obtiene

$$e_{k+1} = -c_k e_k e_{k-1}, \quad c_k \xrightarrow{k \rightarrow \infty} c_\infty.$$

*Paso 2: convergencia (argumento de contracción).* De la relación anterior existe  $\mathcal{C} > 0$  tal que  $|e_{k+1}| \leq \mathcal{C}|e_k||e_{k-1}|$  para  $x_k, x_{k-1}$  suficientemente cerca de  $x^*$ . Eligiendo  $\varepsilon$  con  $\lambda := \mathcal{C}\varepsilon < 1$ , si  $|e_0|, |e_1| < \varepsilon$  entonces  $|e_{k+1}| \leq \lambda|e_k|$ : la iteración es una contracción y  $|e_k| \rightarrow 0$ .

*Paso 3: orden de convergencia.* Definamos  $y_k = |e_{k+1}|/|e_k|^p$  para  $p > 0$  a determinar. De  $|e_{k-1}| = (|e_k|/y_{k-1})^{1/p}$ :

$$y_k = |c_k| |e_k|^{1-p+1/p} y_{k-1}^{-1/p}.$$

Para que  $y_k$  tenga límite finito y no nulo debe cancelarse el exponente de  $|e_k|$ :  $1 - p + 1/p = 0$ , es decir  $p^2 - p - 1 = 0$ , cuya raíz positiva es  $p = \varphi = (1 + \sqrt{5})/2$ . Con esta elección,  $y_k = |c_k|y_{k-1}^{-1/\varphi}$  converge al punto fijo de  $h(y) = |c_\infty|y^{-1/\varphi}$ , que es  $\bar{y} = |c_\infty|^{1/\varphi}$  (usando  $1 + 1/\varphi = \varphi$ , propiedad del número áureo). En consecuencia,

$$\frac{|e_{k+1}|}{|e_k|^\varphi} \rightarrow \left| \frac{f''(x^*)}{2f'(x^*)} \right|^{1/\varphi} > 0. \quad \square$$

**Observación 6.24** (Comparación de métodos).

| <i>Método</i>     | <i>Evaluaciones por paso</i> | <i>Orden</i>            | <i>Observaciones</i>                 |
|-------------------|------------------------------|-------------------------|--------------------------------------|
| <i>Bisección</i>  | 1 ( <i>f</i> )               | 1 ( <i>factor</i> 1/2)  | <i>global, robusto</i>               |
| <i>Punto fijo</i> | 1 ( <i>g</i> )               | 1 ( <i>tasa</i> $q$ )   | <i>depende de la reformulación</i>   |
| <i>Secante</i>    | 1 ( <i>f</i> )               | $\varphi \approx 1.618$ | <i>requiere 2 valores iniciales</i>  |
| <i>Newton</i>     | 2 ( <i>f</i> y <i>f'</i> )   | 2                       | <i>convergencia local cuadrática</i> |

*En la práctica la secante es muy competitiva con Newton: por unidad de evaluación de  $f$ , su orden efectivo es  $\varphi \approx 1.618$  frente a  $\sqrt{2} \approx 1.414$  de Newton (pues Newton usa 2 evaluaciones por paso de orden 2, equivalente a orden  $\sqrt{2}$  por evaluación).*

## Appendix A

# Herramientas de Análisis y Álgebra

En este apéndice recopilamos resultados fundamentales de análisis matemático que se utilizan como herramientas a lo largo del apunte. Todos ellos son resultados clásicos que se estudian en cursos de Análisis Matemático y Álgebra, pero los enunciamos y demostramos aquí para facilitar la referencia.

### A.1 Teorema del valor intermedio

**Teorema A.1** (Teorema de Bolzano). *Sea  $f : [a, b] \rightarrow \mathbb{R}$  continua con  $f(a) \cdot f(b) < 0$ . Entonces existe  $c \in (a, b)$  tal que  $f(c) = 0$ .*

*Demostración.* Construimos por bisección sucesivas dos sucesiones  $\{a_n\}$  y  $\{b_n\}$  con  $a_0 = a$ ,  $b_0 = b$  tales que  $f(a_n) \cdot f(b_n) \leq 0$  y  $b_n - a_n = (b - a)/2^n$ . En cada paso, evaluamos  $f$  en el punto medio  $m = (a_n + b_n)/2$ : si  $f(a_n)f(m) \leq 0$ , definimos  $a_{n+1} = a_n$ ,  $b_{n+1} = m$ ; en caso contrario,  $a_{n+1} = m$ ,  $b_{n+1} = b_n$ .

Ambas sucesiones convergen al mismo límite  $c \in [a, b]$ . Por continuidad de  $f$ :

$$f(c) = \lim_{n \rightarrow \infty} f(a_n), \quad f(c) = \lim_{n \rightarrow \infty} f(b_n).$$

Como  $f(a_n)f(b_n) \leq 0$  para todo  $n$ , tomando límite obtenemos  $f(c)^2 \leq 0$ , es decir,  $f(c) = 0$ .  $\square$

### A.2 Teorema de Rolle

**Teorema A.2** (Teorema de Rolle). *Sea  $f : [a, b] \rightarrow \mathbb{R}$  continua en  $[a, b]$ , derivable en  $(a, b)$  y tal que  $f(a) = f(b)$ . Entonces existe  $c \in (a, b)$  con  $f'(c) = 0$ .*

*Demostración.* Por continuidad en el compacto  $[a, b]$ ,  $f$  alcanza máximo y mínimo. Si ambos extremos se alcanzan en los extremos  $a, b$ , como  $f(a) = f(b)$ , la función es constante y entonces  $f' \equiv 0$  en  $(a, b)$ . Si no, al menos uno de esos extremos se alcanza en un punto interior  $c \in (a, b)$ ; por el teorema de Fermat,  $f'(c) = 0$ .  $\square$

### A.3 Teorema del valor medio para derivadas

**Teorema A.3** (Teorema del valor medio para derivadas). Sea  $f : [a, b] \rightarrow \mathbb{R}$  continua en  $[a, b]$  y derivable en  $(a, b)$ . Entonces existe  $c \in (a, b)$  tal que

$$f'(c) = \frac{f(b) - f(a)}{b - a}.$$

*Demostración.* Consideramos

$$\ell(x) = f(a) + \frac{f(b) - f(a)}{b - a}(x - a), \quad h(x) = f(x) - \ell(x).$$

Entonces  $h$  es continua en  $[a, b]$ , derivable en  $(a, b)$  y cumple  $h(a) = h(b) = 0$ . Por el Teorema A.2, existe  $c \in (a, b)$  tal que  $h'(c) = 0$ . Como

$$h'(x) = f'(x) - \frac{f(b) - f(a)}{b - a},$$

se concluye

$$f'(c) = \frac{f(b) - f(a)}{b - a}.$$

□

### A.4 Regla de la cadena

**Teorema A.4** (Regla de la cadena en una variable). Sean  $I$  y  $J$  dos intervalos abiertos de  $\mathbb{R}$ ,

$$g : I \rightarrow \mathbb{R}, \quad f : J \rightarrow \mathbb{R},$$

con  $g(I) \subset J$ , y sea  $a \in I$ .

Si  $g$  es derivable en  $a$  y  $f$  es derivable en  $g(a)$ , entonces la composición  $f \circ g$  es derivable en  $a$  y

$$(f \circ g)'(a) = f'(g(a)) g'(a),$$

donde el producto es el usual en  $\mathbb{R}$ .

*Demostración.* Para  $x \neq a$ , escribimos

$$\frac{f(g(x)) - f(g(a))}{x - a} = \frac{f(g(x)) - f(g(a))}{g(x) - g(a)} \cdot \frac{g(x) - g(a)}{x - a},$$

cuando  $g(x) \neq g(a)$ . Si  $g(x) = g(a)$ , el cociente de la izquierda vale 0 y la identidad siguiente sigue siendo válida definiendo

$$\Phi(y) := \begin{cases} \frac{f(y) - f(g(a))}{y - g(a)}, & y \neq g(a), \\ f'(g(a)), & y = g(a). \end{cases}$$

Como  $f$  es derivable en  $g(a)$ , se tiene  $\Phi(y) \rightarrow f'(g(a))$  cuando  $y \rightarrow g(a)$ ; en particular,

$$\frac{f(g(x)) - f(g(a))}{x - a} = \Phi(g(x)) \frac{g(x) - g(a)}{x - a}.$$

Al hacer  $x \rightarrow a$ , por continuidad de  $g$  en  $a$  (derivabilidad implica continuidad),

$$\Phi(g(x)) \rightarrow f'(g(a)), \quad \frac{g(x) - g(a)}{x - a} \rightarrow g'(a).$$

Por lo tanto,

$$\lim_{x \rightarrow a} \frac{f(g(x)) - f(g(a))}{x - a} = f'(g(a)) g'(a),$$

que prueba la derivabilidad de  $f \circ g$  en  $a$  y la fórmula anunciada.  $\square$

## A.5 Teorema del valor medio para integrales

**Teorema A.5** (Teorema del valor medio para integrales — primera forma). *Sea  $g \in C([a, b])$ . Entonces existe  $\eta \in (a, b)$  tal que*

$$\int_a^b g(x) dx = g(\eta) (b - a).$$

*Demostración.* Definimos

$$G(x) := \int_a^x g(t) dt.$$

Entonces  $G$  es continua en  $[a, b]$ , derivable en  $(a, b)$  y  $G'(x) = g(x)$  (teorema fundamental del cálculo). Aplicando el Teorema A.3 a  $G$ , existe  $\eta \in (a, b)$  tal que

$$G'(\eta) = \frac{G(b) - G(a)}{b - a}.$$

Como  $G'(\eta) = g(\eta)$ ,  $G(b) = \int_a^b g(x) dx$  y  $G(a) = 0$ , resulta

$$\int_a^b g(x) dx = g(\eta)(b - a).$$

$\square$

**Teorema A.6** (Teorema del valor medio para integrales — segunda forma). *Sean  $g, \varphi \in C([a, b])$ , con  $\varphi$  de signo constante y  $\varphi(x) \neq 0$  para todo  $x \in (a, b)$ . Entonces existe  $\eta \in (a, b)$  tal que*

$$\int_a^b g(x) \varphi(x) dx = g(\eta) \int_a^b \varphi(x) dx.$$

*Demostración.* Sea

$$c := \frac{\int_a^b g(x) \varphi(x) dx}{\int_a^b \varphi(x) dx}, \quad H(x) := \int_a^x (g(t) - c) \varphi(t) dt.$$

Como  $\varphi$  tiene signo constante y no se anula en  $(a, b)$ , se tiene  $\int_a^b \varphi \neq 0$ , luego  $c$  está bien definido. Además,

$$H(a) = 0, \quad H(b) = \int_a^b (g - c)\varphi = \int_a^b g\varphi - c \int_a^b \varphi = 0.$$

Por el Teorema A.3 aplicado a  $H$  (equivalentemente, por Rolle), existe  $\eta \in (a, b)$  tal que  $H'(\eta) = 0$ . Por el teorema fundamental del cálculo,

$$H'(\eta) = (g(\eta) - c)\varphi(\eta) = 0.$$

Como  $\varphi(\eta) \neq 0$ , se concluye  $g(\eta) = c$ , es decir,

$$\int_a^b g(x) \varphi(x) dx = g(\eta) \int_a^b \varphi(x) dx.$$

□

## A.6 Desarrollo de Taylor

**Teorema A.7** (Teorema de Taylor con resto integral). *Sea  $f : I \rightarrow \mathbb{R}$  una función de clase  $C^{(n+1)}$  en un intervalo abierto  $I$ , y sea  $a \in I$ . Entonces, para todo  $x \in I$ :*

$$f(x) = \sum_{k=0}^n \frac{f^{(k)}(a)}{k!} (x - a)^k + R_{n+1}(x),$$

donde el resto en forma integral es:

$$R_{n+1}(x) = \frac{1}{n!} \int_a^x (x - t)^n f^{(n+1)}(t) dt.$$

*Demostración.* Procedemos por inducción en  $n$ . Para  $n = 0$ , el resultado es simplemente el teorema fundamental del cálculo:

$$f(x) = f(a) + \int_a^x f'(t) dt.$$

Supongamos el resultado válido para  $n - 1$ . Aplicamos integración por partes al término de resto con  $u = f^{(n)}(t)$  y  $dv = \frac{(x-t)^{n-1}}{(n-1)!} dt$  (notando que  $v = -\frac{(x-t)^n}{n!}$ ):

$$\begin{aligned} R_n(x) &= \frac{1}{(n-1)!} \int_a^x (x-t)^{n-1} f^{(n)}(t) dt \\ &= \left[ -\frac{(x-t)^n}{n!} f^{(n)}(t) \right]_a^x + \frac{1}{n!} \int_a^x (x-t)^n f^{(n+1)}(t) dt \\ &= \frac{f^{(n)}(a)}{n!} (x-a)^n + R_{n+1}(x). \end{aligned}$$

Esto completa el paso inductivo. □



**Corolario A.8** (Resto de Lagrange). *Bajo las mismas hipótesis, existe  $\xi$  entre  $a$  y  $x$  tal que:*

$$R_{n+1}(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!}(x-a)^{n+1}.$$

*Demostración.* Sea  $M = \max_{t \in [a, x]} f^{(n+1)}(t)$  y  $m = \min_{t \in [a, x]} f^{(n+1)}(t)$ . De la forma integral del resto:

$$m \cdot \frac{(x-a)^{n+1}}{(n+1)!} \leq R_{n+1}(x) \leq M \cdot \frac{(x-a)^{n+1}}{(n+1)!}.$$

Por el teorema del valor intermedio para funciones continuas, existe  $\xi$  entre  $a$  y  $x$  tal que  $f^{(n+1)}(\xi) = \frac{(n+1)! R_{n+1}(x)}{(x-a)^{n+1}}$ .  $\square$

**Teorema A.9** (Desarrollo de Taylor multivariable). *Sea  $F : \mathbb{R}^n \rightarrow \mathbb{R}^m$  de clase  $C^2$  en una vecindad de  $x_0 \in \mathbb{R}^n$ , y sea  $J_F(x) \in \mathbb{R}^{m \times n}$  su matriz Jacobiana. Entonces:*

$$F(x) = F(x_0) + J_F(x_0)(x - x_0) + R_2(x),$$

donde  $\|R_2(x)\| \leq C\|x - x_0\|^2$  para una constante  $C$  que depende de las segundas derivadas de  $F$  en la vecindad.

En el caso escalar  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  de clase  $C^3$ :

$$f(x) = f(x_0) + \nabla f(x_0)^T(x - x_0) + \frac{1}{2}(x - x_0)^T \nabla^2 f(x_0)(x - x_0) + O(\|x - x_0\|^3),$$

donde  $\nabla f$  es el gradiente y  $\nabla^2 f$  es la matriz Hessiana.

*Demostración.* Definimos  $g(t) = F(x_0 + t(x - x_0))$  para  $t \in [0, 1]$ . Por la regla de la cadena,  $g'(t) = J_F(x_0 + t(x - x_0))(x - x_0)$ . Aplicando Taylor en una variable:

$$F(x) = g(1) = g(0) + g'(0) + \int_0^1 (1-t)g''(t) dt = F(x_0) + J_F(x_0)(x - x_0) + R_2(x).$$

El resto  $R_2$  involucra las segundas derivadas parciales de  $F$ , que están acotadas por continuidad, dando  $\|R_2(x)\| \leq C\|x - x_0\|^2$ .

Para el caso escalar,  $g(t) = f(x_0 + th)$  con  $h = x - x_0$  da  $g'(0) = \nabla f(x_0)^T h$  y  $g''(0) = h^T \nabla^2 f(x_0) h$ , de donde se obtiene la fórmula cuadrática.  $\square$

## A.7 Fórmulas de sumatorias y series

**Lema A.10** (Fórmulas de sumatorias). *Para todo  $n \in \mathbb{N}$ :*

1.  $\sum_{i=1}^n i = \frac{n(n+1)}{2}.$
2.  $\sum_{i=1}^n i^2 = \frac{n(n+1)(2n+1)}{6}.$

*Demostración.* (1) Sea  $S = \sum_{i=1}^n i$ . Escribimos la suma en orden directo e inverso:

$$S = 1 + 2 + \cdots + n,$$

$$S = n + (n-1) + \cdots + 1.$$

Sumando:  $2S = n(n+1)$ , de donde  $S = n(n+1)/2$ .

(2) Por inducción. El caso  $n = 1$  es trivial:  $1 = 1 \cdot 2 \cdot 3/6$ . Si la fórmula vale para  $n$ , entonces:

$$\sum_{i=1}^{n+1} i^2 = \frac{n(n+1)(2n+1)}{6} + (n+1)^2 = (n+1) \left( \frac{n(2n+1)}{6} + n+1 \right) = (n+1) \frac{2n^2 + 7n + 6}{6} = \frac{(n+1)(n+2)(2n+3)}{6}$$

□

**Lema A.11** (Serie geométrica). Para  $r \neq 1$  y  $n \in \mathbb{N}_0$ :

$$\sum_{i=0}^n r^i = \frac{1 - r^{n+1}}{1 - r}.$$

En particular, si  $|r| < 1$ , la serie infinita converge:  $\sum_{i=0}^{\infty} r^i = \frac{1}{1 - r}$ .

*Demostración.* Sea  $S = \sum_{i=0}^n r^i$ . Entonces  $rS = \sum_{i=1}^{n+1} r^i$ . Restando:

$$S - rS = 1 - r^{n+1}, \quad \text{de donde} \quad S = \frac{1 - r^{n+1}}{1 - r}.$$

Para  $|r| < 1$ ,  $r^{n+1} \rightarrow 0$  cuando  $n \rightarrow \infty$ , lo que da la serie infinita.

□

**Lema A.12** (Identidad de Vandermonde). Para todo  $n \in \mathbb{N}_0$ :

$$\sum_{k=0}^n \binom{n}{k}^2 = \binom{2n}{n}.$$

*Demostración.* Consideremos el coeficiente de  $x^n$  en  $(1+x)^{2n}$ . Por un lado, es  $\binom{2n}{n}$ . Por otro lado,  $(1+x)^{2n} = (1+x)^n(1+x)^n$ , y el coeficiente de  $x^n$  del producto se obtiene por convolución de Cauchy:

$$\sum_{k=0}^n \binom{n}{k} \binom{n}{n-k} = \sum_{k=0}^n \binom{n}{k}^2,$$

donde usamos  $\binom{n}{n-k} = \binom{n}{k}$ .

□

## A.8 Identidades exponenciales y trigonométricas

**Lema A.13** (Fórmula de Euler). Para todo  $\theta \in \mathbb{R}$ :

$$e^{i\theta} = \cos \theta + i \sin \theta.$$

En consecuencia:

$$e^{i\theta} + e^{-i\theta} = 2 \cos \theta,$$

$$e^{i\theta} - e^{-i\theta} = 2i \sin \theta.$$

*Demostración.* La primera identidad se obtiene igualando las series de potencias  $e^{i\theta} = \sum_{n=0}^{\infty} \frac{(i\theta)^n}{n!}$  con las series de  $\cos \theta$  y  $\sin \theta$ . Separando partes real e imaginaria:

$$e^{i\theta} = \sum_{k=0}^{\infty} \frac{(-1)^k \theta^{2k}}{(2k)!} + i \sum_{k=0}^{\infty} \frac{(-1)^k \theta^{2k+1}}{(2k+1)!} = \cos \theta + i \sin \theta.$$

Las dos consecuencias resultan de sumar y restar  $e^{i\theta}$  con  $e^{-i\theta} = \cos \theta - i \sin \theta$ .  $\square$

## A.9 Criterio M de Weierstrass

**Teorema A.14** (Criterio M de Weierstrass). *Sea  $\{f_n\}$  una sucesión de funciones  $f_n : D \rightarrow \mathbb{C}$  tales que  $|f_n(x)| \leq M_n$  para todo  $x \in D$  y todo  $n$ . Si  $\sum_{n=1}^{\infty} M_n < \infty$ , entonces la serie  $\sum_{n=1}^{\infty} f_n$  converge absoluta y uniformemente en  $D$ .*

*Demostración.* Para toda  $x \in D$  y todo  $N$ , las sumas parciales  $S_N(x) = \sum_{n=1}^N f_n(x)$  satisfacen, para  $M > N$ :

$$|S_M(x) - S_N(x)| = \left| \sum_{n=N+1}^M f_n(x) \right| \leq \sum_{n=N+1}^M |f_n(x)| \leq \sum_{n=N+1}^M M_n.$$

Como  $\sum M_n$  converge, la cola  $\sum_{n=N+1}^{\infty} M_n \rightarrow 0$  cuando  $N \rightarrow \infty$ . Por lo tanto, la desigualdad anterior muestra que  $\{S_N\}$  es uniformemente de Cauchy en  $D$ . Por completitud de  $\mathbb{C}$  (o  $\mathbb{R}$ ), la serie converge uniformemente. La convergencia absoluta se sigue de  $\sum |f_n(x)| \leq \sum M_n < \infty$ .  $\square$

## A.10 Jacobiana, gradiente y Hessiana

**Definición A.15** (Jacobiana). *Sea  $F : \mathbb{R}^n \rightarrow \mathbb{R}^m$  diferenciable en  $x$ . La **matriz Jacobiana** de  $F$  en  $x$  es la matriz  $J_F(x) \in \mathbb{R}^{m \times n}$  cuyas entradas son:*

$$[J_F(x)]_{ij} = \frac{\partial F_i}{\partial x_j}(x), \quad 1 \leq i \leq m, \quad 1 \leq j \leq n.$$

La Jacobiana es la representación matricial de la diferencial  $dF_x : \mathbb{R}^n \rightarrow \mathbb{R}^m$ .

**Definición A.16** (Gradiente). *Sea  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  diferenciable en  $x$ . El **gradiente** de  $f$  en  $x$  es el vector columna:*

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1}(x) \\ \vdots \\ \frac{\partial f}{\partial x_n}(x) \end{pmatrix} \in \mathbb{R}^n.$$

Geométricamente,  $\nabla f(x)$  apunta en la dirección de mayor crecimiento de  $f$  en  $x$ , y  $\|\nabla f(x)\|$  es la tasa de cambio máxima.

**Definición A.17** (Hessiana). *Sea  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  dos veces diferenciable en  $x$ . La **matriz Hessiana** de  $f$  en  $x$  es la matriz simétrica  $\nabla^2 f(x) \in \mathbb{R}^{n \times n}$  con entradas:*

$$[\nabla^2 f(x)]_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}(x).$$

Es la Jacobiana del gradiente:  $\nabla^2 f(x) = J_{\nabla f}(x)$ .

## A.11 Subespacios y dimensiones

**Definición A.18** (Suma e intersección de subespacios). Sean  $U$  y  $V$  subespacios de un espacio vectorial  $W$  de dimensión finita. Su **suma** es

$$U + V := \{u + v : u \in U, v \in V\},$$

y su **intersección**  $U \cap V$  es el subespacio de todos los vectores que pertenecen a ambos.

**Teorema A.19** (Fórmula de Grassmann). Si  $U$  y  $V$  son subespacios de dimensión finita, entonces:

$$\dim(U + V) + \dim(U \cap V) = \dim(U) + \dim(V).$$

*Demostración.* Sea  $\{w_1, \dots, w_k\}$  una base de  $U \cap V$ . La extendemos a bases de  $U$  y  $V$  respectivamente:

$$\{w_1, \dots, w_k, u_1, \dots, u_p\} \text{ base de } U, \quad \{w_1, \dots, w_k, v_1, \dots, v_q\} \text{ base de } V.$$

Aquí  $\dim(U) = k+p$ ,  $\dim(V) = k+q$ ,  $\dim(U \cap V) = k$ . El conjunto  $\mathcal{B} = \{w_1, \dots, w_k, u_1, \dots, u_p, v_1, \dots, v_q\}$  genera  $U + V$ ; veamos que es linealmente independiente. Dada una combinación nula

$$\sum_i a_i w_i + \sum_j b_j u_j + \sum_l c_l v_l = 0,$$

el vector  $s := \sum_l c_l v_l = -\sum_i a_i w_i - \sum_j b_j u_j$  pertenece a  $U$ , luego  $s \in U \cap V$  y se escribe  $s = \sum_i d_i w_i$ . Por independencia de la base de  $V$  se concluye que todos los  $c_l = 0$  (y los  $d_i = 0$ ); sustituyendo, todos los  $a_i, b_j = 0$ . Esto prueba que  $\mathcal{B}$  es base de  $U + V$ , por lo que

$$\dim(U + V) = k + p + q = (k + p) + (k + q) - k = \dim(U) + \dim(V) - \dim(U \cap V).$$

□

**Corolario A.20** (Cota inferior para la intersección). Sean  $U$  y  $V$  subespacios de un espacio de dimensión  $n$ . Entonces:

$$\dim(U \cap V) \geq \dim(U) + \dim(V) - n.$$

En particular, si  $\dim(U) + \dim(V) > n$ , la intersección es no trivial.

*Demostración.* Como  $U + V$  está contenido en el espacio ambiente de dimensión  $n$ , se tiene  $\dim(U + V) \leq n$ . Por la Fórmula de Grassmann (Teorema A.19),

$$\dim(U \cap V) = \dim(U) + \dim(V) - \dim(U + V) \geq \dim(U) + \dim(V) - n.$$

□

**Teorema A.21** (Teorema rango-nulidad). Sea  $A \in \mathbb{C}^{m \times n}$ . Entonces:

$$\text{rango}(A) + \dim(\ker(A)) = n.$$

*Demostración.* Sea  $r = \text{rango}(A)$  y  $\{z_1, \dots, z_{n-r}\}$  una base de  $\ker(A)$ . Se extiende a una base  $\{z_1, \dots, z_{n-r}, e_1, \dots, e_r\}$  de  $\mathbb{C}^n$ . Los vectores  $Ae_1, \dots, Ae_r$  generan  $\text{Im}(A)$  y son linealmente independientes (pues si  $\sum \lambda_i Ae_i = 0$  entonces  $\sum \lambda_i e_i \in \ker(A)$ , lo que por independencia da  $\lambda_i = 0$ ). Luego  $\dim(\text{Im}(A)) = r = \text{rango}(A)$ , y

$$\dim(\ker(A)) = n - r = n - \text{rango}(A).$$

□

## A.12 Polinomios sobre un cuerpo

**Teorema A.22** (Cota de raíces de un polinomio). *Sea  $\mathbb{F}$  un cuerpo. Un polinomio no nulo de grado  $\leq n$  con coeficientes en  $\mathbb{F}$  tiene a lo sumo  $n$  raíces en  $\mathbb{F}$ .*

*Demostración.* Inducción en  $n$ . Para  $n = 0$  un polinomio no nulo es una constante  $c \neq 0$ , sin raíces.

Paso inductivo: sea  $p$  no nulo de grado  $\leq n$ . Si  $p$  no tiene raíces, no hay nada que probar. Si  $\alpha \in \mathbb{F}$  es una raíz, el algoritmo de división da  $p(x) = (x - \alpha)q(x)$  con  $q$  no nulo de grado  $\leq n - 1$ . Para toda raíz  $\beta \neq \alpha$  de  $p$  se tiene  $0 = p(\beta) = (\beta - \alpha)q(\beta)$ ; como  $\mathbb{F}$  no tiene divisores de cero,  $q(\beta) = 0$ . Por hipótesis inductiva  $q$  tiene a lo sumo  $n - 1$  raíces, luego  $p$  tiene a lo sumo  $1 + (n - 1) = n$ .  $\square$

## Appendix B

# Espacios de Pre-Hilbert

En este apéndice revisamos conceptos fundamentales de álgebra lineal en espacios con producto interno. Comenzamos con las definiciones geométricas básicas (ortogonalidad, proyección) para luego establecer resultados centrales sobre aproximación y bases ortonormales. Finalmente, aplicamos estas herramientas para demostrar teoremas de factorización matricial esenciales en análisis numérico, como la descomposición de Schur y la diagonalización de matrices normales.

### B.1 Definiciones básicas

**Definición B.1** (Espacio de pre-Hilbert). *Un **espacio de pre-Hilbert** (o espacio con producto interno) es un par  $(V, (\cdot, \cdot))$  donde  $V$  es un espacio vectorial sobre  $\mathbb{C}$  (o  $\mathbb{R}$ ) y  $(\cdot, \cdot) : V \times V \rightarrow \mathbb{C}$  es un producto interno en  $V$ .*

**Definición B.2** (Producto interno). *Sea  $V$  un espacio vectorial sobre  $\mathbb{C}$  (o  $\mathbb{R}$ ). Un **producto interno** en  $V$  es una función  $(\cdot, \cdot) : V \times V \rightarrow \mathbb{C}$  que satisface:*

1. **Linealidad en el primer argumento:**  $(\alpha u + \beta v, w) = \alpha(u, w) + \beta(v, w)$  para todos  $u, v, w \in V$  y  $\alpha, \beta \in \mathbb{C}$ .
2. **Simetría hermítica:**  $(u, v) = \overline{(v, u)}$  para todos  $u, v \in V$ .
3. **Positividad:**  $(u, u) \geq 0$  para todo  $u \in V$ , con igualdad si y solo si  $u = 0$ .

**Observación B.3.** *Para espacios reales, la condición de simetría hermítica se reduce a la simetría ordinaria:  $(u, v) = (v, u)$ . La linealidad en el primer argumento y la simetría hermítica implican antilinealidad (o sesquilinealidad) en el segundo argumento:  $(u, \alpha v + \beta w) = \overline{\alpha}(u, v) + \overline{\beta}(u, w)$ .*

**Definición B.4** (Norma inducida). *El producto interno induce una **norma** en  $V$  definida por:*

$$\|u\| = \sqrt{(u, u)}.$$

*Esta norma satisface:*

1.  $\|u\| \geq 0$  y  $\|u\| = 0 \Leftrightarrow u = 0$ ,

2.  $\|\alpha u\| = |\alpha| \|u\|$  para todo  $\alpha \in \mathbb{C}$ ,
3.  $\|u + v\| \leq \|u\| + \|v\|$  (desigualdad triangular).

**Teorema B.5** (Desigualdad de Cauchy-Schwarz). Para todos  $u, v \in V$ :

$$|(u, v)| \leq \|u\| \|v\|,$$

con igualdad si y solo si  $u$  y  $v$  son linealmente dependientes.

*Demostración.* Si  $v = 0$ , el resultado es trivial. Supongamos  $v \neq 0$ . Para cualquier  $t \in \mathbb{C}$ , tenemos:

$$0 \leq \|u - tv\|^2 = (u - tv, u - tv) = \|u\|^2 - t(v, u) - \bar{t}(u, v) + |t|^2 \|v\|^2.$$

Elegimos  $t = (u, v)/\|v\|^2$ , entonces:

$$0 \leq \|u\|^2 - \frac{|(u, v)|^2}{\|v\|^2} - \frac{|(u, v)|^2}{\|v\|^2} + \frac{|(u, v)|^2}{\|v\|^4} \cdot \|v\|^2 = \|u\|^2 - \frac{|(u, v)|^2}{\|v\|^2}.$$

Multiplicando por  $\|v\|^2$ , obtenemos  $|u, v|^2 \leq \|u\|^2 \|v\|^2$ . La igualdad se da si y solo si  $u = tv$ , es decir, si son linealmente dependientes.  $\square$

## B.2 Ortogonalidad y Proyección

**Definición B.6** (Ortogonalidad). Dos vectores  $u, v \in V$  son **ortogonales** si  $(u, v) = 0$ , y escribimos  $u \perp v$ .

Un conjunto  $\{v_k\}_{k \in I}$  de vectores es **ortogonal** si  $(v_j, v_k) = 0$  para todo  $j \neq k$ .

Un conjunto  $\{e_k\}_{k \in I}$  es **ortonormal** si es ortogonal y además  $\|e_k\| = 1$  para todo  $k \in I$ .

**Teorema B.7** (Teorema de Pitágoras). Si  $u \perp v$ , entonces:

$$\|u + v\|^2 = \|u\|^2 + \|v\|^2.$$

Más generalmente, si  $\{v_1, \dots, v_n\}$  es un conjunto ortogonal, entonces:

$$\left\| \sum_{k=1}^n v_k \right\|^2 = \sum_{k=1}^n \|v_k\|^2.$$

*Demostración.* Si  $u \perp v$ , entonces  $(u, v) = 0$ . Expandiendo:

$$\|u + v\|^2 = (u + v, u + v) = (u, u) + (u, v) + (v, u) + (v, v) = \|u\|^2 + 0 + 0 + \|v\|^2 = \|u\|^2 + \|v\|^2.$$

El caso general se demuestra por inducción.  $\square$

**Teorema B.8** (Proyección sobre una base ortogonal). Sea  $\{v_1, \dots, v_n\}$  una base ortogonal de un espacio vectorial  $V$  de dimensión finita. Entonces, todo vector  $u \in V$  se puede escribir de manera única como:

$$u = \sum_{k=1}^n c_k v_k,$$

donde los coeficientes están dados por la **fórmula de proyección**:

$$c_k = \frac{(u, v_k)}{(v_k, v_k)} = \frac{(u, v_k)}{\|v_k\|^2}. \quad (\text{B.1})$$

*Demostración.* Supongamos que  $u = \sum_{j=1}^n c_j v_j$ . Tomando el producto interno con  $v_k$ :

$$(u, v_k) = \left( \sum_{j=1}^n c_j v_j, v_k \right) = \sum_{j=1}^n c_j (v_j, v_k).$$

Por ortogonalidad,  $(v_j, v_k) = 0$  si  $j \neq k$  y  $(v_k, v_k) = \|v_k\|^2$ . Por lo tanto:

$$(u, v_k) = c_k \|v_k\|^2,$$

de donde se obtiene la fórmula para  $c_k$ . □

**Teorema B.9** (Proceso de Gram-Schmidt). *Todo espacio vectorial de dimensión finita con producto interno posee una base ortonormal. A partir de una base cualquiera  $\{u_1, \dots, u_n\}$ , se puede construir una base ortonormal  $\{e_1, \dots, e_n\}$  mediante la recursión:*

$$v_k = u_k - \sum_{j=1}^{k-1} (u_k, e_j) e_j, \quad e_k = \frac{v_k}{\|v_k\|}.$$

**Teorema B.10** (Identidad de Parseval para bases ortonormales finitas). *Sea  $\{e_1, \dots, e_n\}$  una base ortonormal de  $V$ . Si  $u = \sum_{k=1}^n c_k e_k$  con  $c_k = (u, e_k)$ , entonces:*

$$\|u\|^2 = \sum_{k=1}^n |c_k|^2. \quad (\text{B.2})$$

*Demostración.*

$$\|u\|^2 = (u, u) = \left( \sum_{j=1}^n c_j e_j, \sum_{k=1}^n c_k e_k \right) = \sum_{j=1}^n \sum_{k=1}^n c_j \overline{c_k} (e_j, e_k).$$

Por ortonormalidad,  $(e_j, e_k) = \delta_{jk}$  (delta de Kronecker), así que:

$$\|u\|^2 = \sum_{k=1}^n c_k \overline{c_k} = \sum_{k=1}^n |c_k|^2.$$

□

**Teorema B.11** (Proyección ortogonal). *Sea  $V$  un espacio de pre-Hilbert y  $S$  un subespacio de dimensión finita de  $V$ . Para cualquier  $u \in V$ , existe un **único** vector  $s_0 \in S$  tal que:*

$$\|u - s_0\| = \inf_{s \in S} \|u - s\|.$$

*Este vector  $s_0$  se llama la **mejor aproximación** de  $u$  en  $S$ , o la **proyección ortogonal**  $P_S(u)$ . Además,  $s_0$  es el único vector en  $S$  que satisface la **condición de ortogonalidad**:*

$$(u - s_0, s) = 0 \quad \text{para todo } s \in S.$$



*Demostración.* La demostración se basa en tomar una base ortonormal  $\{e_1, \dots, e_n\}$  para  $S$  y definir explícitamente

$$s_0 = \sum_{k=1}^n (u, e_k) e_k.$$

Para cualquier otro  $s \in S$ , podemos escribir  $s = \sum_{k=1}^n d_k e_k$  con coeficientes  $d_k$ . Entonces:

$$\|u - s\|^2 = \|(u - s_0) + (s_0 - s)\|^2.$$

Como  $(u - s_0) \perp (s_0 - s)$  (el vector  $(u - s_0)$  es ortogonal a todo  $S$ ), por el teorema de Pitágoras:

$$\|u - s\|^2 = \|u - s_0\|^2 + \|s_0 - s\|^2 \geq \|u - s_0\|^2,$$

con igualdad si y solo si  $s = s_0$ .

Para la condición de ortogonalidad, notemos que si  $s_0$  es el minimizador, para cualquier  $s \in S$  y  $t \in \mathbb{R}$ :

$$\|u - s_0\|^2 \leq \|u - (s_0 + ts)\|^2 = \|u - s_0\|^2 - 2t \operatorname{Re}(u - s_0, s) + t^2 \|s\|^2.$$

Dividiendo por  $t > 0$  (y luego  $t < 0$ ) y haciendo  $t \rightarrow 0$ , se obtiene  $\operatorname{Re}(u - s_0, s) = 0$ . Repitiendo con  $is$  se obtiene  $\operatorname{Im}(u - s_0, s) = 0$ , y por lo tanto  $(u - s_0, s) = 0$ .

Recíprocamente, si  $(u - s_0, s) = 0$  para todo  $s \in S$ , entonces para cualquier  $s \in S$ :

$$\|u - s\|^2 = \|(u - s_0) + (s_0 - s)\|^2 = \|u - s_0\|^2 + \|s_0 - s\|^2 \geq \|u - s_0\|^2,$$

donde usamos que  $(u - s_0) \perp (s_0 - s) \in S$ . □

**Teorema B.12** (Proyector hermítico es proyección ortogonal). *Sea  $V$  un espacio de pre-Hilbert de dimensión finita y sea  $P: V \rightarrow V$  una transformación lineal que satisface  $P^2 = P$  (idempotente) y  $P^* = P$  (autoadjunta). Entonces  $P$  es la proyección ortogonal sobre  $\operatorname{Im}(P)$ .*

*Demostración.* Como  $P^2 = P$ , todo vector  $v \in V$  se descompone como

$$v = Pv + (v - Pv),$$

donde  $Pv \in \operatorname{Im}(P)$ . Veamos que  $v - Pv \perp \operatorname{Im}(P)$ . Sea  $w = Pu \in \operatorname{Im}(P)$  cualquiera. Entonces, usando  $P^* = P$  y  $P^2 = P$ :

$$(v - Pv, w) = (v - Pv, Pu) = (P^*(v - Pv), u) = (P(v - Pv), u) = (Pv - P^2v, u) = (Pv - Pv, u) = 0.$$

Por lo tanto  $v - Pv \in \operatorname{Im}(P)^\perp$ . Como la descomposición  $V = \operatorname{Im}(P) \oplus \operatorname{Im}(P)^\perp$  es única (por el Teorema B.11), se sigue que  $Pv$  es la proyección ortogonal de  $v$  sobre  $\operatorname{Im}(P)$ . □

### B.3 Factorización de Schur y Teorema Espectral

En espacios de dimensión finita, la existencia de bases ortonormales permite simplificar la representación matricial de operadores lineales.

**Teorema B.13** (Factorización de Schur). Sea  $A \in \mathbb{C}^{n \times n}$ . Existe una matriz unitaria  $U \in \mathbb{C}^{n \times n}$  (es decir,  $U^*U = I$ ) y una matriz triangular superior  $T \in \mathbb{C}^{n \times n}$  tales que:

$$A = UTU^*.$$

Los elementos diagonales de  $T$  son los valores propios de  $A$ .

*Demostración.* Procedemos por inducción sobre la dimensión  $n$ . Para  $n = 1$  es trivial. Supongamos que el teorema es cierto para matrices de tamaño  $n - 1$ . Sea  $\lambda_1$  un valor propio de  $A$  y  $v_1$  un vector propio asociado con  $\|v_1\| = 1$ . Completamos  $v_1$  a una base ortonormal de  $\mathbb{C}^n$ , digamos  $\{v_1, v_2, \dots, v_n\}$ . Sea  $U_1 = [v_1, v_2, \dots, v_n]$  la matriz unitaria formada por estos vectores. Entonces:

$$U_1^*AU_1 = \begin{pmatrix} v_1^* \\ \vdots \\ v_n^* \end{pmatrix} A \begin{pmatrix} v_1 & \cdots & v_n \end{pmatrix} = \begin{pmatrix} v_1^*Av_1 & v_1^*Av_2 & \cdots \\ v_2^*Av_1 & v_2^*Av_2 & \cdots \\ \vdots & \vdots & \ddots \end{pmatrix}.$$

Como  $Av_1 = \lambda_1 v_1$ , la primera columna de  $AU_1$  es  $\lambda_1 v_1$ . Por ortonormalidad,  $v_1^*(\lambda_1 v_1) = \lambda_1$  y  $v_k^*(\lambda_1 v_1) = 0$  para  $k > 1$ . Así, la matriz toma la forma:

$$U_1^*AU_1 = \begin{pmatrix} \lambda_1 & w^* \\ 0 & A_2 \end{pmatrix},$$

donde  $A_2 \in \mathbb{C}^{(n-1) \times (n-1)}$ . Por hipótesis de inducción, existe  $V_2 \in \mathbb{C}^{(n-1) \times (n-1)}$  unitaria tal que  $V_2^*A_2V_2 = T_2$  es triangular superior. Definimos  $U = U_1 \begin{pmatrix} 1 & 0 \\ 0 & V_2 \end{pmatrix}$ . Esta matriz es unitaria y transforma  $A$  en una triangular superior.  $\square$

**Lema B.14** (Matrices triangulares normales). Una matriz triangular superior  $T \in \mathbb{C}^{n \times n}$  es normal si y solo si es diagonal.

*Demostración.* ( $\Leftarrow$ ) Si  $T$  es diagonal, entonces  $T^*$  también es diagonal, y como las matrices diagonales conmutan entre sí,  $TT^* = T^*T$ .

( $\Rightarrow$ ) Supongamos que  $T$  es triangular superior y normal. Escribimos  $T = (t_{ij})$  con  $t_{ij} = 0$  para  $i > j$ . Comparemos los elementos diagonales de  $TT^*$  y  $T^*T$ :

$$(TT^*)_{ii} = \sum_{k=1}^n t_{ik} \overline{t_{ik}} = \sum_{k=i}^n |t_{ik}|^2 \quad (\text{pues } t_{ik} = 0 \text{ para } k < i).$$

$$(T^*T)_{ii} = \sum_{k=1}^n \overline{t_{ki}} t_{ki} = \sum_{k=1}^i |t_{ki}|^2 \quad (\text{pues } t_{ki} = 0 \text{ para } k > i).$$

Como  $T$  es normal,  $(TT^*)_{ii} = (T^*T)_{ii}$ :

$$\sum_{k=i}^n |t_{ik}|^2 = \sum_{k=1}^i |t_{ki}|^2.$$

Para  $i = 1$ :

$$\sum_{k=1}^n |t_{1k}|^2 = |t_{11}|^2.$$

Esto implica que  $\sum_{k=2}^n |t_{1k}|^2 = 0$ , por lo que  $t_{1k} = 0$  para  $k > 1$ .

Para  $i = 2$ , usando que  $t_{12} = 0$ :

$$\sum_{k=2}^n |t_{2k}|^2 = |t_{12}|^2 + |t_{22}|^2 = |t_{22}|^2.$$

Esto implica que  $t_{2k} = 0$  para  $k > 2$ .

Procediendo inductivamente para  $i = 3, 4, \dots, n$ , obtenemos que  $t_{ik} = 0$  para todo  $i < k$ . Por lo tanto,  $T$  es diagonal.  $\square$

**Teorema B.15** (Teorema Espectral para Matrices Normales). *Una matriz  $A \in \mathbb{C}^{n \times n}$  es **normal** (es decir,  $AA^* = A^*A$ ) si y solo si es diagonalizable unitariamente. Es decir, existe una matriz unitaria  $U$  y una matriz diagonal  $\Lambda$  tales que:*

$$A = U\Lambda U^*.$$

*Demostración.* ( $\Leftarrow$ ) Si  $A = U\Lambda U^*$ , entonces  $A^* = U\Lambda^* U^*$ . Como  $\Lambda$  y  $\Lambda^*$  son diagonales, conmutan ( $\Lambda\Lambda^* = \Lambda^*\Lambda$ ). Entonces:

$$AA^* = U\Lambda U^* U\Lambda^* U^* = U\Lambda\Lambda^* U^* = U\Lambda^*\Lambda U^* = U\Lambda^* U^* U\Lambda U^* = A^*A.$$

( $\Rightarrow$ ) Por la factorización de Schur,  $A = UTU^*$  con  $T$  triangular superior. Como  $A$  es normal,  $T$  también debe serlo:

$$TT^* = (U^*AU)(U^*A^*U) = U^*AA^*U = U^*A^*AU = (U^*A^*U)(U^*AU) = T^*T.$$

Ahora bien,  $T$  es una matriz triangular superior y normal. Por lo tanto, por el lema anterior,  $T$  es diagonal, lo que concluye la demostración.  $\square$

**Corolario B.16** (Ortogonalidad de autovectores de matrices normales). *Si  $A \in \mathbb{C}^{n \times n}$  es normal y  $v_i, v_j$  son autovectores correspondientes a autovalores distintos  $\lambda_i \neq \lambda_j$ , entonces  $v_i$  y  $v_j$  son ortogonales:  $v_i^* v_j = 0$ .*

*Demostración.* Consideremos  $Av_i = \lambda_i v_i$  y  $Av_j = \lambda_j v_j$ . Calculamos:

$$\lambda_i(v_i^* v_j) = (Av_i)^* v_j = v_i^* A^* v_j.$$

Por otro lado, como  $A$  es normal,  $A^*$  también lo es, y comparten autovectores. Más precisamente, si  $Av_j = \lambda_j v_j$ , entonces  $A^* v_j = \bar{\lambda}_j v_j$  (esto se sigue de que  $A = U\Lambda U^*$  implica  $A^* = U\Lambda^* U^*$ ). Por lo tanto:

$$v_i^* A^* v_j = v_i^* (\bar{\lambda}_j v_j) = \bar{\lambda}_j (v_i^* v_j).$$

Igualando las dos expresiones:

$$\lambda_i(v_i^* v_j) = \bar{\lambda}_j(v_i^* v_j).$$

Si  $\lambda_i \neq \bar{\lambda}_j$  (lo cual es cierto si  $\lambda_i \neq \lambda_j$  en el caso hermitico, o en general por la diagonalización unitaria), entonces necesariamente  $v_i^* v_j = 0$ .  $\square$

**Corolario B.17** (Matrices Hermíticas). *Si  $A \in \mathbb{C}^{n \times n}$  es hermitica ( $A = A^*$ ), entonces:*

1. *A es normal, por lo que admite diagonalización unitaria:  $A = U\Lambda U^*$ .*

2. *Todos los autovalores de A son **reales**:  $\lambda_i \in \mathbb{R}$  para todo  $i$ .*

*Demostración.* (1) Es inmediato que  $AA^* = AA = A^*A$ .

(2) Sea  $\lambda$  un autovalor con autovector  $v$ :  $Av = \lambda v$ . Tomando el producto hermítico:

$$v^*Av = v^*(\lambda v) = \lambda v^*v = \lambda \|v\|^2.$$

Por otro lado, como  $A^* = A$ :

$$v^*Av = (Av)^*v = (\lambda v)^*v = \bar{\lambda} v^*v = \bar{\lambda} \|v\|^2.$$

Igualando,  $\lambda = \bar{\lambda}$ , por lo que  $\lambda \in \mathbb{R}$ . □

**Teorema B.18** (Caracterización Variacional de Autovalores (Courant-Fischer)). *Sea  $A \in \mathbb{C}^{n \times n}$  una matriz hermítica con autovalores  $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ . Entonces:*

$$\lambda_k = \min_{S \subset \mathbb{C}^n, \dim(S)=k} \max_{x \in S, x \neq 0} \frac{x^*Ax}{x^*x} = \max_{S \subset \mathbb{C}^n, \dim(S)=n-k+1} \min_{x \in S, x \neq 0} \frac{x^*Ax}{x^*x}.$$

*En particular, el autovalor máximo y mínimo están dados por el cociente de Rayleigh:*

$$\lambda_1 = \min_{x \neq 0} \frac{x^*Ax}{x^*x}, \quad \lambda_n = \max_{x \neq 0} \frac{x^*Ax}{x^*x}.$$

*Demostración.* Sea  $\{u_1, \dots, u_n\}$  una base ortonormal de vectores propios de  $A$  asociados a los autovalores  $\lambda_1 \leq \dots \leq \lambda_n$ . Para cualquier vector  $x \neq 0$ , podemos escribir  $x = \sum_{i=1}^n c_i u_i$ . El cociente de Rayleigh es:

$$R(x) = \frac{x^*Ax}{x^*x} = \frac{\sum_{i=1}^n \lambda_i |c_i|^2}{\sum_{i=1}^n |c_i|^2}.$$

Demostremos la caracterización max – min para  $\lambda_k$ :

$$\lambda_k = \max_{S \subset \mathbb{C}^n, \dim(S)=n-k+1} \min_{x \in S, x \neq 0} R(x).$$

Sea  $V_k = \text{span}\{u_k, \dots, u_n\}$ . La dimensión de  $V_k$  es  $n - k + 1$ . Para cualquier  $x \in V_k$ , tenemos  $c_1 = \dots = c_{k-1} = 0$ , por lo que:

$$R(x) = \frac{\sum_{i=k}^n \lambda_i |c_i|^2}{\sum_{i=k}^n |c_i|^2} \geq \lambda_k \frac{\sum_{i=k}^n |c_i|^2}{\sum_{i=k}^n |c_i|^2} = \lambda_k.$$

Por lo tanto,  $\min_{x \in V_k} R(x) \geq \lambda_k$ . Esto implica que el máximo sobre todos los subespacios es al menos  $\lambda_k$ .

Ahora sea  $S$  cualquier subespacio de dimensión  $n - k + 1$ . Consideremos el subespacio  $Z_k = \text{span}\{u_1, \dots, u_k\}$ , que tiene dimensión  $k$ . La suma de dimensiones es  $\dim(S) + \dim(Z_k) = (n - k + 1) + k = n + 1$ . Como la dimensión del espacio total es  $n$ , la intersección  $S \cap Z_k$  debe tener dimensión al menos 1. Sea  $x_0 \in S \cap Z_k$  con  $x_0 \neq 0$ . Como  $x_0 \in Z_k$ , es combinación lineal de  $u_1, \dots, u_k$ , así que:

$$R(x_0) = \frac{\sum_{i=1}^k \lambda_i |c_i|^2}{\sum_{i=1}^k |c_i|^2} \leq \lambda_k.$$

Por lo tanto,  $\min_{x \in S} R(x) \leq R(x_0) \leq \lambda_k$ . Como esto vale para todo  $S$ , el máximo de los mínimos es  $\leq \lambda_k$ . Concluimos que el valor es exactamente  $\lambda_k$ . La otra igualdad se prueba de manera análoga. □

## Appendix C

# Convergencia de Series de Fourier

En el cuerpo principal de las notas (Capítulo 4, Sección 4.1) ya establecimos la relación básica entre regularidad y decaimiento de coeficientes de Fourier. En particular, el Teorema 4.17 y el Corolario ?? muestran que la regularidad  $C^m$  implica decaimiento algebraico  $|\hat{f}_k| = O(|k|^{-m})$ .

Este apéndice reúne los argumentos de convergencia de series de Fourier en un bloque autónomo. El objetivo es separar con claridad dos planos complementarios: por un lado, la convergencia puntual/uniforme de las sumas parciales (núcleo de Dirichlet y Lema de Riemann–Lebesgue), y por otro, la convergencia en norma  $L^2$  y la identidad de Parseval, formuladas en lenguaje de proyección ortogonal. Esta organización permite reutilizar los resultados de decaimiento ya probados en el texto principal y, al mismo tiempo, presentar la teoría de convergencia con una lógica interna independiente.

### C.1 Convergencia puntual de sumas parciales

En esta primera etapa queremos entender por qué las sumas parciales realmente se acercan a la función en cada punto. La idea del pizarrón es combinar dos piezas clásicas: por un lado, el lema de Riemann–Lebesgue para apagar integrales oscilatorias, y por otro la fórmula de convolución con el núcleo de Dirichlet. Con esas herramientas, el error se reescribe en una forma manejable y la convergencia puntual cae de manera natural.

**Teorema C.1** (Lema de Riemann–Lebesgue para funciones  $C^1$ ). *Si  $g \in C^1([a, b])$ , entonces*

$$\int_a^b g(t)e^{i\omega t} dt \rightarrow 0 \quad (|\omega| \rightarrow \infty).$$

*Demostración.* Sea

$$J(\omega) := \int_a^b g(t)e^{i\omega t} dt.$$

Integramos por partes con  $u = g(t)$  y  $dv = e^{i\omega t} dt$ :

$$J(\omega) = \left[ \frac{g(t)e^{i\omega t}}{i\omega} \right]_a^b - \frac{1}{i\omega} \int_a^b g'(t)e^{i\omega t} dt.$$

Tomando módulo:

$$|J(\omega)| \leq \frac{|g(a)| + |g(b)|}{|\omega|} + \frac{1}{|\omega|} \int_a^b |g'(t)| dt \xrightarrow{|\omega| \rightarrow \infty} 0.$$

□

**Corolario C.2.** Si  $g \in C^1([a, b])$ , entonces

$$\int_a^b g(t) \sin(\omega t) dt \rightarrow 0, \quad \int_a^b g(t) \cos(\omega t) dt \rightarrow 0, \quad (|\omega| \rightarrow \infty).$$

*Demostración.* Por Euler,

$$\int_a^b g(t) e^{i\omega t} dt = \int_a^b g(t) \cos(\omega t) dt + i \int_a^b g(t) \sin(\omega t) dt.$$

Si un número complejo tiende a 0, también tienden a 0 su parte real e imaginaria. Aplicando el Teorema C.1, se obtiene el resultado. □

Con este paso ya controlamos el efecto de la oscilación en integrales. El siguiente ingrediente no es de estimación, sino de estructura: necesitamos una fórmula que escriba  $S_N f$  de forma explícita para poder manipular el error con comodidad.

**Lema C.3** (Núcleo de Dirichlet). *La suma parcial de Fourier admite la representación*

$$S_N f(x) = \frac{1}{2\pi} \int_0^{2\pi} f(x-t) D_N(t) dt,$$

donde

$$D_N(t) = \sum_{k=-N}^N e^{ikt} = \frac{\sin((N + \frac{1}{2})t)}{\sin(t/2)}, \quad \frac{1}{2\pi} \int_0^{2\pi} D_N(t) dt = 1.$$

*Demostración.* Partimos de  $S_N f(x) = \sum_{k=-N}^N \hat{f}_k e^{ikx}$  y sustituimos  $\hat{f}_k = \frac{1}{2\pi} \int_0^{2\pi} f(u) e^{-iku} du$ :

$$S_N f(x) = \frac{1}{2\pi} \int_0^{2\pi} f(u) \sum_{k=-N}^N e^{ik(x-u)} du.$$

Con el cambio  $u = x - t$  (periodicidad) se obtiene la fórmula de convolución. La expresión cerrada de  $D_N$  resulta de la suma geométrica finita y la normalización de integrar término a término. □

Una vez obtenida la representación por núcleo, el argumento de convergencia puntual queda casi servido: reescribimos el error y aplicamos el resultado oscilatorio del comienzo de la sección.

**Teorema C.4** (Convergencia puntual). *Sea  $f \in C_{per}^1([0, 2\pi])$ . Entonces, para todo  $x \in [0, 2\pi]$ ,*

$$S_N f(x) \rightarrow f(x).$$

*Demostración.* Por el Lema C.3 y la normalización de  $D_N$ ,

$$S_N f(x) - f(x) = \frac{1}{2\pi} \int_0^{2\pi} (f(x-t) - f(x)) D_N(t) dt.$$

Usando la forma cerrada de  $D_N$ ,

$$S_N f(x) - f(x) = \frac{1}{2\pi} \int_0^{2\pi} g_x(t) \sin((N + \frac{1}{2})t) dt,$$

donde

$$g_x(t) := \frac{f(x-t) - f(x)}{\sin(t/2)}$$

y se define por continuidad en  $t = 0$  y  $t = 2\pi$ . Como  $f \in C_{per}^1$ , el cociente tiene singularidad removible y  $g_x \in C([0, 2\pi])$ .

Aplicando el Corolario C.1 a  $g_x$ , el integral tiende a 0 cuando  $N \rightarrow \infty$ . Concluimos  $S_N f(x) \rightarrow f(x)$ .  $\square$

La conclusión de esta sección es que la regularidad  $C^1$  alcanza para convergencia puntual. A continuación pediremos más suavidad para subir al nivel de convergencia uniforme y, además, obtener tasas explícitas.

## C.2 Convergencia uniforme para funciones suaves

Ahora subimos la exigencia: no nos alcanza con convergencia punto a punto, queremos convergencia uniforme y una cota explícita del error. Para eso necesitamos preparar el terreno funcional con completitud en norma supremo y el criterio  $M$  de Weierstrass, que permiten controlar series de funciones de forma robusta. Esta maquinaria no es sólo técnica: volverá a aparecer cuando estudiemos el recíproco de regularidad.

**Lema C.5** (Completitud en norma supremo). *Sea  $E$  un conjunto y sea  $B(E)$  el espacio de funciones acotadas  $f : E \rightarrow \mathbb{C}$ , con norma*

$$\|f\|_\infty := \sup_{x \in E} |f(x)|.$$

*Entonces  $(B(E), \|\cdot\|_\infty)$  es completo: toda sucesión de Cauchy en  $\|\cdot\|_\infty$  converge en  $\|\cdot\|_\infty$  a una función de  $B(E)$ .*

*Demostración.* Sea  $(f_n)$  una sucesión de Cauchy en  $\|\cdot\|_\infty$ . Para cada  $x \in E$ ,

$$|f_n(x) - f_m(x)| \leq \|f_n - f_m\|_\infty \xrightarrow{n, m \rightarrow \infty} 0,$$

así que  $(f_n(x))$  es de Cauchy en  $\mathbb{C}$  y por completitud de  $\mathbb{C}$  existe

$$f(x) := \lim_{n \rightarrow \infty} f_n(x).$$

Tomemos  $\varepsilon > 0$ . Como  $(f_n)$  es Cauchy en  $\|\cdot\|_\infty$ , existe  $N$  tal que

$$\|f_n - f_m\|_\infty < \varepsilon \quad (n, m \geq N).$$

Fijado  $n \geq N$  y para todo  $x \in E$ , al pasar  $m \rightarrow \infty$  en  $|f_n(x) - f_m(x)| < \varepsilon$  obtenemos

$$|f_n(x) - f(x)| \leq \varepsilon.$$

Tomando supremo en  $x$ ,

$$\|f_n - f\|_\infty \leq \varepsilon \quad (n \geq N).$$

Luego  $f_n \rightarrow f$  en  $\|\cdot\|_\infty$ . Además, para  $n \geq N$ ,

$$|f(x)| \leq |f_n(x)| + |f(x) - f_n(x)| \leq \|f_n\|_\infty + \varepsilon,$$

por lo que  $f$  es acotada y  $f \in B(E)$ . □

**Lema C.6** (Criterio  $M$  de Weierstrass para series de funciones). *Sea  $(u_k)_{k \in \mathbb{Z}}$  una familia de funciones en  $[0, 2\pi]$ . Supongamos que existen números  $M_k \geq 0$  tales que*

$$|u_k(x)| \leq M_k \quad \text{para todo } x \in [0, 2\pi], \quad k \in \mathbb{Z},$$

y

$$\sum_{k \in \mathbb{Z}} M_k < \infty.$$

Entonces la serie  $\sum_{k \in \mathbb{Z}} u_k(x)$  converge absoluta y uniformemente en  $[0, 2\pi]$ . Si además cada  $u_k$  es continua, la suma es continua.

*Demostración.* Para  $N > M$ ,

$$\sup_{x \in [0, 2\pi]} \left| \sum_{M < |k| \leq N} u_k(x) \right| \leq \sum_{M < |k| \leq N} \sup_{x \in [0, 2\pi]} |u_k(x)| \leq \sum_{M < |k| \leq N} M_k.$$

Como  $\sum_{k \in \mathbb{Z}} M_k$  converge, su cola tiende a 0 cuando  $M, N \rightarrow \infty$ . Luego las sumas parciales son de Cauchy en norma supremo y, por el Lema C.5, convergen uniformemente.

Además,

$$\sup_{x \in [0, 2\pi]} \sum_{k \in \mathbb{Z}} |u_k(x)| \leq \sum_{k \in \mathbb{Z}} M_k < \infty,$$

de donde la convergencia absoluta es uniforme. Si cada  $u_k$  es continua, el límite uniforme de sumas parciales continuas es continuo. □

Con estas dos herramientas funcionales en mano, volvemos al problema de Fourier: ahora sí podemos traducir decaimiento de coeficientes en convergencia uniforme de la serie y en una cota cuantitativa del error.

**Teorema C.7** (Convergencia uniforme y cota cuantitativa). *Sea  $f \in C_{per}^n([0, 2\pi])$  con  $n \geq 1$ . Entonces*

$$\|f - S_N f\|_\infty \leq \frac{\|f^{(n)}\|_{L^2}}{\sqrt{\pi(2n-1)}} \frac{1}{N^{n-1/2}},$$

y en particular  $\|f - S_N f\|_\infty = O(N^{1/2-n})$ .



*Demostración.* Para  $k \neq 0$ , por el Teorema 4.17 se tiene

$$\hat{f}_k = \frac{\widehat{f^{(n)}}_k}{(ik)^n}.$$

Entonces, por Cauchy-Schwarz,

$$\sum_{|k|>N} |\hat{f}_k| = \sum_{|k|>N} \frac{|\widehat{f^{(n)}}_k|}{|k|^n} \leq \left( \sum_{|k|>N} |\widehat{f^{(n)}}_k|^2 \right)^{1/2} \left( \sum_{|k|>N} |k|^{-2n} \right)^{1/2}.$$

Por Bessel (Teorema C.16),

$$\sum_{k \in \mathbb{Z}} |\widehat{f^{(n)}}_k|^2 \leq \frac{\|f^{(n)}\|_{L^2}^2}{2\pi},$$

y por comparación integral,

$$\sum_{|k|>N} |k|^{-2n} = 2 \sum_{k=N+1}^{\infty} k^{-2n} \leq 2 \int_N^{\infty} x^{-2n} dx = \frac{2}{(2n-1)N^{2n-1}}.$$

Combinando,

$$\sum_{|k|>N} |\hat{f}_k| \leq \frac{\|f^{(n)}\|_{L^2}}{\sqrt{\pi(2n-1)}} \frac{1}{N^{n-1/2}}.$$

Esta cota implica convergencia absoluta de  $\sum_k \hat{f}_k e^{ikx}$ ; por el Lema C.6, la convergencia es uniforme. Como además  $f \in C_{per}^1$  (porque  $n \geq 1$ ), el Teorema C.4 da convergencia puntual de las sumas parciales a  $f$ ; por lo tanto, el límite uniforme coincide con  $f$ .

Finalmente,

$$\|f - S_N f\|_{\infty} = \left\| \sum_{|k|>N} \hat{f}_k e^{ikx} \right\|_{\infty} \leq \sum_{|k|>N} |\hat{f}_k| \leq \frac{\|f^{(n)}\|_{L^2}}{\sqrt{\pi(2n-1)}} \frac{1}{N^{n-1/2}},$$

que es la cota buscada. □

**Observación C.8** (Mejora tipo Jackson). *Bajo las mismas hipótesis, un resultado más fino de teoría de aproximación (debido a Jackson) da la tasa óptima en norma uniforme:*

$$\|f - S_N(f)\|_{\infty} = O(N^{-n}).$$

*Es decir, la cota del Teorema C.7 no es óptima en la potencia de  $N$ , aunque se obtiene con una demostración elemental basada en decaimiento de coeficientes y Cauchy-Schwarz.*

Hasta este punto trabajamos en norma supremo. El próximo salto será pasar al lenguaje  $L^2$  y preparar el camino para Parseval, apoyándonos en densidad de polinomios trigonométricos.

### C.3 Densidad de trigonométricas e igualdad de Parseval

Hasta ahora hemos visto resultados de convergencia puntual y uniforme, pero no hemos tocado la densidad de los polinomios trigonométricos en espacios de funciones, que es fundamental para establecer resultados como la identidad de Parseval. El recorrido es el siguiente: una versión compleja del Teorema de Stone–Weierstrass nos da densidad uniforme de las trigonométricas en el espacio de funciones continuas y periódicas, de allí pasamos a densidad en  $L^2$  para funciones continuas a trozos, y con esa densidad cerramos la identidad de Parseval usando proyección ortogonal y mejor aproximación.

**Teorema C.9** (Stone–Weierstrass complejo (reducción al caso real)). *Sea  $K$  un compacto y sea  $\mathcal{A} \subset C(K; \mathbb{C})$  una subálgebra tal que:*

1. *contiene a las constantes,*
2. *separa puntos de  $K$ ,*
3. *es cerrada por conjugación compleja ( $f \in \mathcal{A} \Rightarrow \bar{f} \in \mathcal{A}$ ).*

*Entonces  $\mathcal{A}$  es densa en  $C(K; \mathbb{C})$  en norma supremo.*

*Demostración.* Definimos

$$\mathcal{A}_{\mathbb{R}} := \{u \in \mathcal{A} : u \text{ es real-valuada}\} \subset C(K; \mathbb{R}).$$

Como  $\mathcal{A}$  es subálgebra y estable por conjugación, para todo  $f \in \mathcal{A}$  se tiene

$$\operatorname{Re} f = \frac{f + \bar{f}}{2} \in \mathcal{A}_{\mathbb{R}}, \quad \operatorname{Im} f = \frac{f - \bar{f}}{2i} \in \mathcal{A}_{\mathbb{R}}.$$

Luego  $\mathcal{A}_{\mathbb{R}}$  es una subálgebra real que contiene constantes.

Verifiquemos separación de puntos. Si  $x \neq y$ , por hipótesis existe  $f \in \mathcal{A}$  con  $f(x) \neq f(y)$ . Entonces al menos una de las dos diferencias

$$\operatorname{Re} f(x) - \operatorname{Re} f(y), \quad \operatorname{Im} f(x) - \operatorname{Im} f(y)$$

es no nula. Por lo tanto,  $\mathcal{A}_{\mathbb{R}}$  separa puntos de  $K$ .

Aplicando Stone–Weierstrass real,  $\mathcal{A}_{\mathbb{R}}$  es densa en  $C(K; \mathbb{R})$  para  $\|\cdot\|_{\infty}$ .

Sea ahora  $g \in C(K; \mathbb{C})$ ,  $g = u + iv$  con  $u, v \in C(K; \mathbb{R})$ . Dado  $\varepsilon > 0$ , elegimos  $u_{\varepsilon}, v_{\varepsilon} \in \mathcal{A}_{\mathbb{R}}$  tales que

$$\|u - u_{\varepsilon}\|_{\infty} < \frac{\varepsilon}{2}, \quad \|v - v_{\varepsilon}\|_{\infty} < \frac{\varepsilon}{2}.$$

Como  $u_{\varepsilon}, v_{\varepsilon} \in \mathcal{A} \subset C(K; \mathbb{C})$ , también

$$g_{\varepsilon} := u_{\varepsilon} + iv_{\varepsilon} \in \mathcal{A}.$$

Además,

$$\|g - g_{\varepsilon}\|_{\infty} \leq \|u - u_{\varepsilon}\|_{\infty} + \|v - v_{\varepsilon}\|_{\infty} < \varepsilon.$$

Concluimos que  $\overline{\mathcal{A}}^{\|\cdot\|_{\infty}} = C(K; \mathbb{C})$ . □

Este resultado abstracto se vuelve concreto en el círculo unitario: allí los monomios  $z^k$  se identifican exactamente con los modos exponenciales de Fourier.

**Corolario C.10** (Densidad uniforme de polinomios trigonométricos). *Sea*

$$\mathcal{T} := \left\{ \sum_{|k| \leq N} c_k e^{ikx} : N \in \mathbb{N}, c_k \in \mathbb{C} \right\}.$$

*Entonces  $\mathcal{T}$  es denso en  $C_{per}([0, 2\pi]; \mathbb{C})$  para la norma supremo.*

*Demostración.* Identificamos  $C_{per}([0, 2\pi]; \mathbb{C})$  con  $C(\mathbb{T}; \mathbb{C})$ , donde

$$\mathbb{T} := \{z \in \mathbb{C} : |z| = 1\}, \quad z = e^{ix}.$$

En  $C(\mathbb{T}; \mathbb{C})$  consideramos la subálgebra

$$\mathcal{A} := \text{span}\{z^k : k \in \mathbb{Z}\}.$$

Contiene constantes, es cerrada por conjugación porque  $\overline{z^k} = z^{-k}$  en  $\mathbb{T}$ , y separa puntos porque  $z \mapsto z$  separa puntos en  $\mathbb{T}$ . Por el Teorema C.9,  $\mathcal{A}$  es densa en  $C(\mathbb{T}; \mathbb{C})$ . Volviendo a la variable  $x$ , esto es exactamente la densidad uniforme de  $\mathcal{T}$  en  $C_{per}([0, 2\pi]; \mathbb{C})$ .  $\square$

Con la densidad uniforme establecida en  $C_{per}$ , el paso siguiente es llevar la aproximación al marco  $L^2$  para funciones Riemann integrables. Para esto usamos un operador de promediado local (argumento de Lyapunov, 1898), que regulariza la función y converge a ella en norma  $L^2$ .

**Lema C.11** (Promediado local de Lyapunov en  $L^2$ ). *Sea  $f : [0, 2\pi] \rightarrow \mathbb{C}$  una función  $2\pi$ -periódica y Riemann integrable. Para  $0 < h < \pi$ , definimos*

$$(\mathcal{L}_h f)(x) := \frac{1}{2h} \int_{x-h}^{x+h} f(t) dt,$$

*donde la integral se toma sobre la extensión  $2\pi$ -periódica de  $f$ . Entonces:*

1.  $\mathcal{L}_h f \in C_{per}([0, 2\pi]; \mathbb{C})$ ;
2.  $\|\mathcal{L}_h f - f\|_{L^2} \xrightarrow{h \downarrow 0} 0$ .

*Demostración.* Sea  $\tilde{f}$  la extensión periódica de  $f$  a  $\mathbb{R}$  y definamos

$$F(x) := \int_0^x \tilde{f}(t) dt.$$

Como  $\tilde{f}$  es Riemann integrable y acotada en compactos,  $F$  es continua. Además,

$$(\mathcal{L}_h f)(x) = \frac{F(x+h) - F(x-h)}{2h},$$

que es continua en  $x$ . La periodicidad se obtiene de  $F(x+2\pi) = F(x) + C$ , pues al tomar la diferencia centrada la constante  $C$  se cancela.

Para la convergencia en  $L^2$ , sea  $\tau_t f(x) := f(x - t)$ . Escribimos

$$\mathcal{L}_h f - f = \frac{1}{2h} \int_{-h}^h (\tau_t f - f) dt.$$

Aplicando Cauchy–Schwarz en la variable  $t$ ,

$$\left| \frac{1}{2h} \int_{-h}^h (\tau_t f(x) - f(x)) dt \right|^2 \leq \frac{1}{2h} \int_{-h}^h |\tau_t f(x) - f(x)|^2 dt.$$

Integrando en  $x$  y usando Fubini,

$$\|\mathcal{L}_h f - f\|_{L^2}^2 \leq \frac{1}{2h} \int_{-h}^h \|\tau_t f - f\|_{L^2}^2 dt.$$

Basta entonces probar que  $\|\tau_t f - f\|_{L^2} \rightarrow 0$  cuando  $t \rightarrow 0$ .

Fijado  $\varepsilon > 0$ , como  $f$  es Riemann integrable en compacto, existe una función escalonada periódica  $s$  tal que

$$\|f - s\|_{L^2} < \varepsilon.$$

Por invarianza traslacional de la norma  $L^2$ ,

$$\|\tau_t f - f\|_{L^2} \leq \|\tau_t(f - s)\|_{L^2} + \|\tau_t s - s\|_{L^2} + \|s - f\|_{L^2} \leq 2\varepsilon + \|\tau_t s - s\|_{L^2}.$$

Si  $s$  tiene saltos en  $\xi_1, \dots, \xi_m$  y  $\|s\|_\infty \leq A$ , entonces  $\tau_t s - s$  sólo puede ser no nula en la unión de intervalos de longitud total  $\leq 2m|t|$ , y allí

$$|\tau_t s - s| \leq 2A.$$

Por lo tanto,

$$\|\tau_t s - s\|_{L^2}^2 \leq (2A)^2 2m|t| = 8A^2 m|t|,$$

de donde  $\|\tau_t s - s\|_{L^2} \rightarrow 0$  cuando  $t \rightarrow 0$ .

Concluimos que existe  $\delta > 0$  tal que, si  $|t| < \delta$ ,

$$\|\tau_t f - f\|_{L^2} < 3\varepsilon.$$

Volviendo a la cota de promedio,

$$\|\mathcal{L}_h f - f\|_{L^2}^2 \leq \frac{1}{2h} \int_{-h}^h \|\tau_t f - f\|_{L^2}^2 dt \leq (3\varepsilon)^2 \quad (0 < h < \delta),$$

y por tanto

$$\|\mathcal{L}_h f - f\|_{L^2} \xrightarrow{h \downarrow 0} 0.$$

□

**Teorema C.12** (Densidad trigonométrica en  $L^2$  (marco Riemann)). *Sea  $f : [0, 2\pi] \rightarrow \mathbb{C}$  una función  $2\pi$ -periódica y Riemann integrable. Entonces, para todo  $\varepsilon > 0$ , existe  $p \in \mathcal{T}$  tal que*

$$\|f - p\|_{L^2} < \varepsilon.$$

*Demostración.* Por el Lema C.11, existe  $h > 0$  tal que

$$\|f - \mathcal{L}_h f\|_{L^2} < \frac{\varepsilon}{2},$$

y además  $\mathcal{L}_h f \in C_{per}([0, 2\pi]; \mathbb{C})$ .

Por el Corolario C.10, existe  $p \in \mathcal{T}$  tal que

$$\|\mathcal{L}_h f - p\|_{\infty} < \frac{\varepsilon}{2\sqrt{2\pi}}.$$

Luego

$$\|\mathcal{L}_h f - p\|_{L^2} \leq \sqrt{2\pi} \|\mathcal{L}_h f - p\|_{\infty} < \frac{\varepsilon}{2}.$$

Finalmente,

$$\|f - p\|_{L^2} \leq \|f - \mathcal{L}_h f\|_{L^2} + \|\mathcal{L}_h f - p\|_{L^2} < \varepsilon.$$

□

Esta densidad en norma  $L^2$  es exactamente la pieza que faltaba: combinada con la propiedad de proyección ortogonal, permite hacer desaparecer el resto en la identidad de energía y llegar a Parseval.

## C.4 Derivación término a término de la serie de Fourier

Volvemos aquí a una pregunta muy natural de clase: *¿se puede derivar la serie de Fourier término a término?* La respuesta es sí bajo hipótesis de regularidad, y la justificación se apoya en un criterio de derivación bajo límite. Ese criterio se combina con dos resultados que ya tenemos en la mochila: convergencia uniforme para la serie de  $f'$  y convergencia puntual de  $S_N f$  hacia  $f$ .

**Lema C.13** (Criterio funcional de derivación bajo el límite). *Sea  $(F_N)_{N \geq 1} \subset C^1([0, 2\pi])$ . Supongamos que:*

1. *Existe  $x_0 \in [0, 2\pi]$  tal que  $F_N(x_0)$  converge.*
2. *Existe  $g \in C([0, 2\pi])$  tal que  $F'_N \rightarrow g$  uniformemente en  $[0, 2\pi]$ .*

*Entonces existe  $F \in C^1([0, 2\pi])$  tal que  $F_N \rightarrow F$  uniformemente y  $F' = g$ .*

*Demostración.* Sea  $L := \lim_{N \rightarrow \infty} F_N(x_0)$  y definamos

$$F(x) := L + \int_{x_0}^x g(t) dt.$$

Como  $g$  es continua,  $F \in C^1([0, 2\pi])$  y  $F' = g$ .

Para cada  $x \in [0, 2\pi]$ , por el teorema fundamental del cálculo:

$$F_N(x) = F_N(x_0) + \int_{x_0}^x F'_N(t) dt.$$

Restando la definición de  $F$ ,

$$F_N(x) - F(x) = (F_N(x_0) - L) + \int_{x_0}^x (F'_N(t) - g(t)) dt.$$

Tomando supremo en  $x$ :

$$\|F_N - F\|_\infty \leq |F_N(x_0) - L| + 2\pi \|F'_N - g\|_\infty \xrightarrow{N \rightarrow \infty} 0.$$

Luego  $F_N \rightarrow F$  uniformemente y ya vimos que  $F' = g$ .  $\square$

Con este criterio preparado, la demostración de derivación término a término se vuelve transparente: basta controlar uniformemente las derivadas de las sumas parciales y fijar el valor en un punto.

**Teorema C.14** (Derivación término a término de la serie de Fourier). *Sea  $f \in C_{per}^2([0, 2\pi])$ . Entonces:*

$$f'(x) = \sum_{k=-\infty}^{\infty} ik \hat{f}_k e^{ikx} \quad \text{para todo } x \in [0, 2\pi],$$

y la convergencia de esta serie de derivadas es uniforme en  $[0, 2\pi]$ .

*Demostración.* Para cada  $N$ , la suma parcial

$$S_N f(x) = \sum_{|k| \leq N} \hat{f}_k e^{ikx}$$

es un polinomio trigonométrico y por tanto

$$(S_N f)'(x) = \sum_{|k| \leq N} ik \hat{f}_k e^{ikx}.$$

Por el Lema 4.16,  $\widehat{f'}_k = ik \hat{f}_k$ , luego

$$(S_N f)'(x) = \sum_{|k| \leq N} \widehat{f'}_k e^{ikx} = S_N(f')(x).$$

Como  $f \in C_{per}^2$ , se tiene  $f' \in C_{per}^1$ . Aplicando el Teorema C.7 a  $g = f'$  (con  $n = 1$ ), obtenemos

$$\|S_N(f') - f'\|_\infty \rightarrow 0.$$

Es decir,

$$\|(S_N f)' - f'\|_\infty \rightarrow 0,$$

así que la serie de derivadas converge uniformemente a  $f'$ .

Además, por el Teorema C.4,  $S_N f(0) \rightarrow f(0)$ . Aplicando el Lema C.13 a  $F_N = S_N f$  (con  $x_0 = 0$  y  $g = f'$ ), obtenemos que  $S_N f$  converge uniformemente a una función  $F \in C^1$  con  $F' = f'$ .

Por otro lado, el Teorema C.4 también da convergencia puntual  $S_N f(x) \rightarrow f(x)$  para todo  $x$ , luego necesariamente  $F = f$ . En consecuencia,

$$f'(x) = \lim_{N \rightarrow \infty} (S_N f)'(x) = \lim_{N \rightarrow \infty} \sum_{|k| \leq N} ik \hat{f}_k e^{ikx},$$

y la convergencia de la serie de derivadas es uniforme.  $\square$

Como cierre conceptual, invertimos ahora la dirección del razonamiento: en vez de partir de suavidad para deducir decaimiento, partimos de decaimiento para reconstruir suavidad.

## C.5 Recíproco de suavidad por decaimiento de coeficientes

Hasta ahora vimos que la suavidad implica decaimiento de coeficientes; en esta sección recorreremos el camino inverso. La idea es mostrar que, si los coeficientes caen lo suficientemente rápido, entonces la función necesariamente hereda regularidad. Técnicamente, el argumento encadena el criterio  $M$  de Weierstrass (para asegurar convergencia uniforme de las series derivadas formales) con el criterio de derivación bajo límite (para identificar una a una las derivadas reales de la suma).

**Teorema C.15** (Converso de suavidad por decaimiento de coeficientes). *Sea  $m \in \mathbb{N} \cup \{0\}$  y*

$$f(x) = \sum_{k \in \mathbb{Z}} c_k e^{ikx}$$

*una serie trigonométrica  $2\pi$ -periódica. Si*

$$\sum_{k \in \mathbb{Z}} (1 + |k|)^m |c_k| < \infty,$$

*entonces  $f \in C_{per}^m([0, 2\pi])$  y, para todo  $0 \leq j \leq m$ ,*

$$f^{(j)}(x) = \sum_{k \in \mathbb{Z}} (ik)^j c_k e^{ikx},$$

*convergencia uniforme en  $[0, 2\pi]$ .*

*Demostración.* Para  $0 \leq j \leq m$ , definimos

$$u_k^{(j)}(x) := (ik)^j c_k e^{ikx}, \quad M_k := (1 + |k|)^m |c_k|.$$

Entonces

$$|u_k^{(j)}(x)| \leq |k|^j |c_k| \leq (1 + |k|)^m |c_k| = M_k,$$

y  $\sum_{k \in \mathbb{Z}} M_k < \infty$ . Por el Lema C.6, para cada  $j \leq m$  la serie

$$\sum_{k \in \mathbb{Z}} (ik)^j c_k e^{ikx}$$

converge absoluta y uniformemente; denotemos su suma por  $g_j \in C([0, 2\pi])$ .

Sea  $S_N^{(j)}(x) := \sum_{|k| \leq N} (ik)^j c_k e^{ikx}$ . Entonces

$$\frac{d}{dx} S_N^{(j)}(x) = S_N^{(j+1)}(x).$$

Además,  $S_N^{(j)}(0) = \sum_{|k| \leq N} (ik)^j c_k$  converge cuando  $N \rightarrow \infty$  por convergencia absoluta de  $\sum_k |k|^j |c_k|$ .

Aplicando el Lema C.13 a  $F_N = S_N^{(j)}$  y  $g = g_{j+1}$ , obtenemos que  $g_j \in C^1$  y  $(g_j)' = g_{j+1}$ . Iterando para  $j = 0, 1, \dots, m-1$ , concluimos que  $g_0 \in C^m$  y

$$g_0^{(j)} = g_j \quad (0 \leq j \leq m).$$

Como  $g_0$  es justamente la suma de la serie original,  $g_0 = f$ , y el resultado queda probado.  $\square$

Tomado junto con los teoremas de decaimiento del cuerpo principal, este resultado cierra el círculo: regularidad y velocidad de caída de coeficientes se describen mutuamente.

## C.6 Comentarios finales

Para cerrar el apéndice, conviene tomar perspectiva: los resultados demostrados aquí cubren el marco que necesitamos para aplicaciones numéricas, pero la teoría de Fourier se extiende mucho más allá cuando se relajan hipótesis de regularidad y se trabaja en espacios funcionales más generales.

Los resultados demostrados en esta sección cubren el marco de funciones suaves a trozos, pero existen teoremas más ajustados:

- (Dirichlet–Jordan) Si  $f$  es de variación acotada, entonces

$$S_N f(x) \rightarrow \frac{f(x^+) + f(x^-)}{2} \quad \text{en todo } x.$$

- (Carleson–Hunt) Si  $f \in L^p([0, 2\pi])$  con  $1 < p < \infty$ , entonces  $S_N f(x) \rightarrow f(x)$  para casi todo  $x$ .
- Este umbral es esencialmente óptimo: existe  $f \in L^1([0, 2\pi])$  cuya serie de Fourier diverge casi en todo punto (Kolmogorov).

Estas tres referencias marcan una frontera conceptual útil: desde el punto de vista numérico, nuestras hipótesis de suavidad son naturales y productivas; desde el punto de vista analítico, el comportamiento de las series de Fourier en baja regularidad exige herramientas más finas.

**Teorema C.16** (Desigualdad de Bessel). *Sea  $\{e_k\}_{k=1}^\infty$  un sistema ortonormal en  $H$ . Para cualquier  $u \in H$ , se cumple:*

$$\sum_{k=1}^{\infty} |(u, e_k)|^2 \leq \|u\|^2.$$

*Demostración.* Para cada  $N \in \mathbb{N}$ , definimos  $S_N = \sum_{k=1}^N (u, e_k) e_k$ . Expandimos la norma:

$$\begin{aligned} 0 \leq \|u - S_N\|^2 &= (u - S_N, u - S_N) \\ &= \|u\|^2 - \sum_{k=1}^N (u, e_k) \overline{(u, e_k)} - \sum_{k=1}^N \overline{(u, e_k)} (u, e_k) + \sum_{j,k=1}^N (u, e_j) \overline{(u, e_k)} \underbrace{(e_j, e_k)}_{\delta_{jk}} \\ &= \|u\|^2 - 2 \sum_{k=1}^N |(u, e_k)|^2 + \sum_{k=1}^N |(u, e_k)|^2 = \|u\|^2 - \sum_{k=1}^N |(u, e_k)|^2. \end{aligned}$$



Por lo tanto,  $\sum_{k=1}^N |(u, e_k)|^2 \leq \|u\|^2$  para todo  $N \in \mathbb{N}$ . Como la sucesión de sumas parciales es monótona creciente y acotada superiormente por  $\|u\|^2$ , la serie converge y

$$\sum_{k=1}^{\infty} |(u, e_k)|^2 \leq \|u\|^2. \quad \square$$

# Bibliography

- [1] David L. Donoho and Philip B. Stark. Uncertainty principles and signal recovery. *SIAM Journal on Applied Mathematics*, 49(3):906–931, 1989.