

# Elementos de Cálculo Numérico

Martín D. Maas

May 6, 2026

# Contents

|                                                                   |           |
|-------------------------------------------------------------------|-----------|
| <b>Introducción</b>                                               | <b>5</b>  |
| <b>1 Fundamentos de la Computación Numérica</b>                   | <b>7</b>  |
| 1.1 Máquinas de Turing y Computabilidad . . . . .                 | 7         |
| 1.1.1 Máquinas de Turing . . . . .                                | 7         |
| 1.1.2 Cálculo de la complejidad de un algoritmo . . . . .         | 9         |
| 1.1.3 Análisis de algoritmos recursivos . . . . .                 | 10        |
| 1.1.4 El Teorema Maestro . . . . .                                | 12        |
| 1.2 Aritmética de Máquina . . . . .                               | 15        |
| 1.2.1 Enteros de 64 bits . . . . .                                | 15        |
| 1.2.2 Números de punto flotante . . . . .                         | 16        |
| 1.2.3 Épsilon de máquina . . . . .                                | 17        |
| 1.2.4 Redondeo y la cota fundamental de error . . . . .           | 18        |
| 1.2.5 Consecuencias y ejemplos . . . . .                          | 21        |
| 1.2.6 Precisión arbitraria por software . . . . .                 | 21        |
| 1.2.7 Ejemplos en geometría computacional . . . . .               | 22        |
| <b>2 Álgebra Lineal Numérica</b>                                  | <b>23</b> |
| 2.1 Eliminación Gaussiana y factorización LU . . . . .            | 23        |
| 2.1.1 Eliminación Gaussiana sin pivoteo . . . . .                 | 23        |
| 2.1.2 Factorización LU . . . . .                                  | 24        |
| 2.1.3 Pivoteo parcial y factorización PLU . . . . .               | 25        |
| 2.2 Ortogonalización de Gram-Schmidt y factorización QR . . . . . | 25        |
| 2.2.1 Proceso de Gram-Schmidt clásico . . . . .                   | 25        |
| 2.2.2 Gram-Schmidt Modificado (MGS) . . . . .                     | 26        |
| 2.2.3 Factorización QR . . . . .                                  | 26        |
| 2.3 Cuadrados mínimos y proyección ortogonal . . . . .            | 28        |
| 2.3.1 Ecuaciones normales para cuadrados mínimos . . . . .        | 28        |
| 2.3.2 QR para cuadrados mínimos . . . . .                         | 29        |
| 2.4 Descomposición en Valores Singulares (SVD) . . . . .          | 30        |
| 2.4.1 Pseudoinversa de Moore-Penrose . . . . .                    | 32        |
| 2.4.2 Condicionamiento y problemas mal condicionados . . . . .    | 34        |
| 2.4.3 Propiedades de la norma de matrices . . . . .               | 35        |
| 2.4.4 Regularización de Tikhonov . . . . .                        | 38        |

|          |                                                           |           |
|----------|-----------------------------------------------------------|-----------|
| 2.4.5    | Aproximación de bajo rango (Teorema de Eckart-Young)      | 39        |
| 2.4.6    | Norma de Frobenius y propiedades de la traza              | 40        |
| 2.5      | Métodos iterativos para autovalores                       | 41        |
| 2.5.1    | Teorema de los círculos de Gershgorin                     | 41        |
| 2.5.2    | El método de la potencia                                  | 42        |
| 2.5.3    | El método QR                                              | 42        |
| 2.5.4    | Matriz compañera y raíces de polinomios                   | 43        |
| 2.6      | Métodos iterativos para sistemas lineales                 | 43        |
| 2.6.1    | Métodos estacionarios y convergencia                      | 43        |
| 2.6.2    | Método de Jacobi                                          | 44        |
| 2.6.3    | Método de Gauss-Seidel                                    | 44        |
| <b>3</b> | <b>Interpolación</b>                                      | <b>45</b> |
| 3.1      | Existencia y unicidad del interpolante                    | 45        |
| 3.1.1    | La matriz de Vandermonde                                  | 46        |
| 3.1.2    | La base de Lagrange                                       | 47        |
| 3.1.3    | La forma baricéntrica                                     | 47        |
| 3.2      | Interpolación sobre $\mathbb{R}$                          | 48        |
| 3.2.1    | Error de interpolación                                    | 48        |
| 3.2.2    | Cuadratura interpolatoria                                 | 50        |
| 3.2.3    | Las raíces de la unidad como nodos de interpolación       | 52        |
| 3.2.4    | Matriz de Vandermonde y la transformada inversa (IDFT)    | 52        |
| 3.2.5    | Transformada Rápida de Fourier (FFT)                      | 54        |
| 3.2.6    | Criterio de Nyquist-Shannon y aliasing                    | 56        |
| 3.2.7    | Convolución discreta                                      | 57        |
| 3.2.8    | Filtrado digital de señales                               | 58        |
| 3.2.9    | Multiplicación rápida de polinomios                       | 59        |
| 3.2.10   | Principio de incertidumbre de Donoho-Stark para la DFT    | 60        |
| 3.3      | Interpolación sobre cuerpos finitos                       | 61        |
| 3.3.1    | Cuerpos finitos: estructura algebraica                    | 62        |
| 3.3.2    | Interpolación en $\mathbb{Z}_p$ : teoría                  | 62        |
| 3.3.3    | Implementación computacional                              | 63        |
| 3.3.4    | Aplicación: Esquema de secreto compartido de Shamir       | 64        |
| 3.3.5    | Aplicación: Códigos de Reed-Solomon                       | 66        |
| <b>4</b> | <b>Teoría de Aproximación</b>                             | <b>67</b> |
| 4.1      | Series de Fourier de funciones suaves periódicas          | 67        |
| 4.1.1    | La base exponencial compleja                              | 68        |
| 4.1.2    | La serie trigonométrica real                              | 69        |
| 4.1.3    | Decaimiento de los coeficientes de Fourier y regularidad  | 70        |
| 4.1.4    | Convergencia de la serie de Fourier para funciones suaves | 71        |
| 4.1.5    | Cuadratura de funciones suaves y periódicas               | 73        |
| 4.1.6    | El fenómeno de Gibbs                                      | 75        |
| 4.2      | Series de Chebyshev                                       | 77        |
| 4.2.1    | De Fourier a Chebyshev: El cambio de variable coseno      | 77        |

|          |                                                                       |            |
|----------|-----------------------------------------------------------------------|------------|
| 4.2.2    | Las funciones de Chebyshev y la serie de Chebyshev . . . . .          | 78         |
| 4.2.3    | Las funciones de Chebyshev son polinomios . . . . .                   | 79         |
| 4.2.4    | Ortogonalidad . . . . .                                               | 79         |
| 4.3      | Polinomios Ortogonales (Series de Fourier Generalizadas) . . . . .    | 80         |
| 4.3.1    | Marco general: espacios con producto interno . . . . .                | 81         |
| 4.3.2    | Familias clásicas de polinomios ortogonales . . . . .                 | 82         |
| 4.3.3    | Tasa de convergencia para funciones suaves: un caso general . . . . . | 82         |
| 4.4      | Cuadratura Gaussiana . . . . .                                        | 83         |
| 4.4.1    | Motivación y definición . . . . .                                     | 83         |
| 4.4.2    | Exactitud y positividad . . . . .                                     | 84         |
| 4.4.3    | Error de cuadratura . . . . .                                         | 85         |
| 4.4.4    | Cálculo de nodos y pesos: Método de Golub-Welsch . . . . .            | 86         |
| 4.5      | Del error de proyección al error de interpolación . . . . .           | 87         |
| 4.5.1    | Error de interpolación de Fourier . . . . .                           | 87         |
| 4.5.2    | Error de interpolación de Chebyshev . . . . .                         | 89         |
| 4.5.3    | Generalización a otros polinomios ortogonales . . . . .               | 91         |
| 4.6      | El operador de interpolación (*) . . . . .                            | 91         |
| 4.6.1    | Constante de Lebesgue . . . . .                                       | 91         |
| 4.6.2    | Nodos equiespaciados y el fenómeno de Runge . . . . .                 | 94         |
| 4.6.3    | Convergencia de la interpolación polinomial en $L^\infty$ . . . . .   | 95         |
| <b>5</b> | <b>Ecuaciones Diferenciales Ordinarias</b>                            | <b>100</b> |
| 5.1      | Discretización de derivadas mediante diferencias finitas . . . . .    | 100        |
| 5.1.1    | Aproximaciones de la primera derivada . . . . .                       | 100        |
| 5.1.2    | Aproximaciones de la segunda derivada . . . . .                       | 101        |
| 5.1.3    | Conexión con interpolación polinomial . . . . .                       | 101        |
| 5.2      | Problemas de valores iniciales . . . . .                              | 102        |
| 5.2.1    | Convergencia de métodos de un paso . . . . .                          | 103        |
| 5.2.2    | Convergencia y Estabilidad de métodos multipaso . . . . .             | 105        |
| 5.2.3    | A-estabilidad y estabilidad práctica . . . . .                        | 108        |
| 5.3      | Problemas de valores de contorno en 1D . . . . .                      | 112        |
| 5.3.1    | Condiciones de borde de Dirichlet . . . . .                           | 112        |
| 5.3.2    | Condiciones de borde de Neumann . . . . .                             | 114        |
| 5.3.3    | Condiciones de borde periódicas . . . . .                             | 115        |
| 5.3.4    | Caso general: término de reacción . . . . .                           | 116        |
| 5.3.5    | Métodos espectrales . . . . .                                         | 118        |
| <b>6</b> | <b>Sistemas No Lineales y Optimización Numérica</b>                   | <b>121</b> |
| 6.1      | El método de la bisección . . . . .                                   | 121        |
| 6.2      | El método de Newton en una variable . . . . .                         | 122        |
| 6.2.1    | Derivación como aproximación cuadrática . . . . .                     | 122        |
| 6.2.2    | Convergencia cuadrática local . . . . .                               | 122        |
| 6.3      | El método de Newton en dimensión $n$ . . . . .                        | 124        |
| 6.3.1    | Formulación para sistemas . . . . .                                   | 124        |
| 6.3.2    | Convergencia cuadrática local . . . . .                               | 125        |

|          |                                                                         |            |
|----------|-------------------------------------------------------------------------|------------|
| 6.3.3    | Aplicación a optimización . . . . .                                     | 125        |
| 6.4      | Descenso por gradiente . . . . .                                        | 126        |
| 6.4.1    | Motivación geométrica y definición . . . . .                            | 126        |
| 6.4.2    | Convergencia con paso constante para funciones fuertemente convexas . . | 126        |
| <b>A</b> | <b>Herramientas de Análisis y Álgebra</b>                               | <b>128</b> |
| A.1      | Teorema del valor intermedio . . . . .                                  | 128        |
| A.2      | Teorema de Rolle . . . . .                                              | 128        |
| A.3      | Teorema del valor medio para derivadas . . . . .                        | 129        |
| A.4      | Teorema del valor medio para integrales . . . . .                       | 129        |
| A.5      | Desarrollo de Taylor . . . . .                                          | 130        |
| A.6      | Fórmulas de sumatorias y series . . . . .                               | 132        |
| A.7      | Identidades exponenciales y trigonométricas . . . . .                   | 133        |
| A.8      | Criterio M de Weierstrass . . . . .                                     | 133        |
| A.9      | Jacobiana, gradiente y Hessiana . . . . .                               | 133        |
| A.10     | Subespacios y dimensiones . . . . .                                     | 134        |
| A.11     | Polinomios sobre un cuerpo . . . . .                                    | 135        |
| <b>B</b> | <b>Espacios de Pre-Hilbert</b>                                          | <b>136</b> |
| B.1      | Definiciones básicas . . . . .                                          | 136        |
| B.2      | Ortogonalidad y Proyección . . . . .                                    | 137        |
| B.3      | Factorización de Schur y Teorema Espectral . . . . .                    | 139        |
| <b>C</b> | <b>Espacios de Hilbert</b>                                              | <b>143</b> |
| C.1      | Definiciones y Ejemplos . . . . .                                       | 143        |
| C.2      | Bases Ortonormales . . . . .                                            | 143        |
| C.3      | Teoremas de Proyección y Representación de Riesz . . . . .              | 144        |

# Introducción

*El estudio profundo de la naturaleza es la fuente más fértil de descubrimientos matemáticos.*

— Joseph Fourier, *Prólogo de la Teoría analítica del calor*

El cálculo numérico se ocupa de resolver problemas matemáticos mediante algoritmos, es decir, de la “construcción efectiva” de soluciones a problemas matemáticos, y se preocupa por la precisión y la eficiencia de los métodos desarrollados.

El cálculo numérico parte de la realización concreta de la visión de la matemática constructiva: la filosofía según la cual un objeto matemático existe cuando disponemos de un algoritmo para construirlo. En el Capítulo 1 veremos que esta idea está lejos de ser trivial, mostrando que el conjunto de números “efectivamente computables” es apenas *numerable* — con lo cual, para la inmensa mayoría de los números reales no puede existir un algoritmo capaz de aproximarlos. También en ese capítulo introduciremos la noción de complejidad computacional, que cuantifica los recursos necesarios para resolver un problema.

Uno de los hilos centrales del apunte es el problema de representar y aproximar funciones, y un tópico recurrente para abordar este problema es el de la ortogonalidad.

En el Capítulo 2 introducimos la noción de espacios de producto interno, que generalizan la geometría euclidiana a espacios abstractos. En estos espacios, la ortogonalidad y las proyecciones permiten construir algoritmos estables y eficientes para resolver problemas de álgebra lineal, como sistemas lineales, autovalores, y problemas de cuadrados mínimos.

En el Capítulo 3 estudiamos la interpolación polinomial: dado un conjunto de puntos, se desea construir un polinomio que pase por ellos. Por un lado, la aproximación por polinomios conduce naturalmente a la integración y a la diferenciación numérica, pero también veremos cómo las ideas de la interpolación se extienden al plano complejo para motivar el desarrollo de la transformada discreta de Fourier, o a cuerpos finitos donde se aplica a problemas de criptografía y teoría de códigos.

En el Capítulo 4 retomamos la noción de ortogonalidad, esta vez en espacios de funciones. Estudiamos las series de Fourier y las expansiones en polinomios de Chebyshev como casos centrales: para funciones suaves su convergencia es espectral —exponencialmente rápida—, lo que las hace especialmente útiles en la práctica. Nuestro interés central será entender este régimen de convergencia rápida y el error de proyección, mientras que dejamos para cursos teóricos avanzados las cuestiones de convergencia puntual en espacios más generales.

El Capítulo 5 aborda ecuaciones diferenciales, donde centralmente utilizaremos el análisis de Fourier discreto para estudiar estabilidad (análisis de von Neumann).

El Capítulo 6 introduce métodos iterativos para optimización y ecuaciones no lineales como el método de bisección, Newton, o el descenso por gradiente, este último conocido por su aplicación al entrenamiento de redes neuronales.

Uno de los temas recurrentes a lo largo de todo el apunte es la estabilidad: la sensibilidad de los algoritmos a errores de redondeo, perturbaciones en los datos, o incluso a la propia formulación del problema. La estabilidad es un concepto fundamental para entender por qué algunos métodos numéricos funcionan bien en la práctica, mientras que otros, aunque matemáticamente correctos, resultan inviables en la práctica.

Como ilustración del *principio de mínima generalidad*<sup>1</sup>, según el cual es preferible introducir una idea en el caso más simple que la revele con claridad, y solo después se extiende a situaciones más generales, consideremos el problema aparentemente inocente de calcular

$$I_n = \int_0^1 x^n e^x dx, \quad n = 0, 1, 2, \dots$$

Integrando por partes, se obtiene la recurrencia

$$I_n = e - n I_{n-1} \quad \text{con} \quad I_0 = e - 1.$$

Esta fórmula sugiere un algoritmo directo, pero cualquier error en la condición inicial se amplifica por un factor  $\sim n!$  tras  $n$  pasos: para  $n = 20$  la amplificación del error inicial es de  $\sim 10^{18}$ , destruyendo toda precisión.

La estabilidad —en sus diversas manifestaciones: estabilidad de algoritmos, de esquemas numéricos para ecuaciones diferenciales, de los problemas mismos— será un tema recurrente a lo largo de todo el apunte.

## Prerequisitos

Se asume familiaridad con álgebra lineal (espacios vectoriales, transformaciones lineales, producto interno, ortogonalidad, Gram-Schmidt) y con cálculo (series, convergencia, derivadas e integrales, ecuaciones diferenciales ordinarias). Si bien no se requiere experiencia previa en programación, sí se asume la madurez conceptual para seguir algoritmos y razonar sobre su correctitud.

---

<sup>1</sup>V.I. Arnold, prólogo de *Lectures on Partial Differential Equations*: “Instead of the principle of maximal generality that is usual in mathematical books, the author has attempted to adhere to the principle of minimal generality, according to which every idea should first be clearly understood in the simplest situation; only then should the method developed be extended to more complicated cases.”

# Chapter 1

## Fundamentos de la Computación Numérica

Este capítulo introductorio establece los fundamentos teóricos y prácticos de la computación numérica. Exploramos tres pilares fundamentales: la teoría de la computabilidad, que define qué problemas son resolubles algorítmicamente; la complejidad computacional, que cuantifica los recursos necesarios para resolver un problema; y la aritmética de máquina, que determina cómo se representan y manipulan los números en computadoras reales.

### 1.1 Máquinas de Turing y Computabilidad

#### 1.1.1 Máquinas de Turing

Una **máquina de Turing** es un modelo matemático abstracto de computación propuesto por Alan Turing en 1936. Consiste en:

- Una **cinta infinita** dividida en celdas, cada una conteniendo un símbolo de un alfabeto finito  $\Gamma$  (que incluye un símbolo especial *blanco*).
- Un **cabezal de lectura/escritura** que puede leer y escribir símbolos en la cinta, y moverse una posición a la izquierda o derecha.
- Un **conjunto finito de estados**  $Q$ , con un estado inicial  $q_0$  y estados de aceptación  $F \subseteq Q$ .
- Una **función de transición**  $\delta : Q \times \Gamma \rightarrow Q \times \Gamma \times \{L, R\}$  que, dado el estado actual y el símbolo leído, determina el nuevo estado, el símbolo a escribir, y la dirección del movimiento.

**Ejemplo 1.1** (Máquina que suma 1). *Consideremos una máquina de Turing que suma 1 a un número natural representado en unario. El número  $n$  se representa como una cadena de  $n$  unos:  $1^n$ .*

**Especificación:**

- *Alfabeto:  $\Gamma = \{1, B\}$  donde  $B$  representa el blanco.*



- *Estados:*  $Q = \{q_0, q_1, q_{halt}\}$
- *Estado inicial:*  $q_0$
- *Estado de aceptación:*  $\{q_{halt}\}$

**Función de transición:**

$$\begin{aligned}\delta(q_0, 1) &= (q_0, 1, R) && \text{(avanza a la derecha mientras haya unos)} \\ \delta(q_0, B) &= (q_1, 1, L) && \text{(encontró el final, escribe un 1 adicional)} \\ \delta(q_1, 1) &= (q_{halt}, 1, R) && \text{(retrocede y se detiene)}\end{aligned}$$

**Ejemplo de ejecución** para la entrada 111 (representa el número 3):

|          |          |          |          |   |     |                                         |
|----------|----------|----------|----------|---|-----|-----------------------------------------|
| <u>1</u> | 1        | 1        | B        | B | ... | Estado: $q_0$                           |
| 1        | <u>1</u> | 1        | B        | B | ... | Estado: $q_0$                           |
| 1        | 1        | <u>1</u> | B        | B | ... | Estado: $q_0$                           |
| 1        | 1        | 1        | <u>B</u> | B | ... | Estado: $q_0$                           |
| 1        | 1        | 1        | <u>1</u> | B | ... | Estado: $q_1$ (escribió el 1 adicional) |
| 1        | 1        | <u>1</u> | 1        | B | ... | Estado: $q_{halt}$ (se detiene)         |

**Definición 1.2** (Clase espacial  $SPACE(f(n))$ ). La clase  $SPACE(f(n))$  contiene todos los lenguajes que pueden ser resueltos por una máquina de Turing determinista usando  $O(f(n))$  celdas de memoria.

**Definición 1.3** (Clase P).  $P = \bigcup_{k=0}^{\infty} TIME(n^k)$  es la clase de problemas resolubles en tiempo polinomial. Representa los problemas tratables computacionalmente.

**Definición 1.4** (Clase NP). **NP** es la clase de problemas para los cuales, dada una solución propuesta, se puede verificar en tiempo polinomial si es correcta. Equivalentemente, son los problemas resolubles en tiempo polinomial por una máquina de Turing no determinista.

**Ejemplo 1.5** (Problemas en P). • *Determinar si un número es primo (algoritmo AKS, 2002).*

- *Ordenar  $n$  números:  $O(n \log n)$  (mergesort, heapsort).*
- *Calcular el máximo común divisor:  $O(\log n)$  (algoritmo de Euclides).*
- *Multiplicar dos matrices  $n \times n$ :  $O(n^{2.371})$  (algoritmo de Coppersmith-Winograd).*

**Ejemplo 1.6** (Problemas en NP). • **SAT:** Dado un conjunto de cláusulas booleanas, ¿existe una asignación de valores que las satisface?

- **Camino Hamiltoniano:** Dado un grafo, ¿existe un camino que visita cada vértice exactamente una vez?
- **Factorización de enteros:** Dado  $n$ , ¿tiene un factor primo menor que  $k$ ? (Verificar es fácil, encontrar es difícil).
- **Problema del viajante (TSP):** ¿Existe una ruta que visita todas las ciudades con distancia total  $< k$ ?

**Observación 1.7** (El problema P vs NP). *Claramente  $P \subseteq NP$  (si podemos resolver, podemos verificar). La pregunta del millón de dólares: ¿es  $P = NP$ ? Se cree ampliamente que no, pero nadie ha podido demostrarlo. Es uno de los siete Problemas del Milenio del Clay Mathematics Institute.*

### 1.1.2 Cálculo de la complejidad de un algoritmo

Para determinar la complejidad de un algoritmo:

1. **Identificar operaciones elementales:** asignaciones, comparaciones, operaciones aritméticas. Cada una cuesta  $O(1)$ .
2. **Contar repeticiones:** analizar bucles y recursiones.
3. **Sumar las contribuciones:** obtener una función  $T(n)$  del tamaño de entrada.
4. **Expresar en notación asintótica:** simplificar a  $O(f(n))$ .

**Ejemplo 1.8** (Búsqueda lineal). *Buscar un elemento en un array desordenado de tamaño  $n$ :*

```
for i = 1 to n:
    if array[i] == target:
        return i
return -1
```

- Operaciones en cada iteración:  $O(1)$  (comparación).
- Número de iteraciones: hasta  $n$  en el peor caso.
- Complejidad total:  $T(n) = O(n)$ .

**Ejemplo 1.9** (Búsqueda binaria). *Buscar en un array ordenado de tamaño  $n$ :*

```
left = 1, right = n
while left <= right:
    mid = (left + right) / 2
    if array[mid] == target:
        return mid
    else if array[mid] < target:
        left = mid + 1
    else:
        right = mid - 1
return -1
```

- En cada iteración, el espacio de búsqueda se reduce a la mitad.
- Número de iteraciones:  $k$  tal que  $n/2^k = 1$ , es decir,  $k = \log_2 n$ .
- Complejidad:  $T(n) = O(\log n)$ .

**Ejemplo 1.10** (Ordenamiento por inserción). `for i = 2 to n:`

```
    key = array[i]
    j = i - 1
    while j >= 1 and array[j] > key:
        array[j+1] = array[j]
        j = j - 1
    array[j+1] = key
```

- *Bucle externo:  $n - 1$  iteraciones.*
- *Bucle interno: en la iteración  $i$ , hasta  $i - 1$  comparaciones.*
- *Total:  $T(n) = \sum_{i=2}^n (i - 1) = \frac{n(n-1)}{2} = O(n^2)$ .*

**Ejemplo 1.11** (Multiplicación de matrices). *Multiplicar dos matrices  $A, B$  de tamaño  $n \times n$  con el algoritmo estándar:*

```
for i = 1 to n:
    for j = 1 to n:
        C[i,j] = 0
        for k = 1 to n:
            C[i,j] = C[i,j] + A[i,k] * B[k,j]
```

- *Tres bucles anidados, cada uno de tamaño  $n$ .*
- *Complejidad:  $T(n) = O(n^3)$ .*
- *(Existen algoritmos más eficientes: Strassen  $O(n^{2.807})$ , Coppersmith-Winograd  $O(n^{2.371})$ ).*

### 1.1.3 Análisis de algoritmos recursivos

Los algoritmos recursivos requieren un enfoque diferente para analizar su complejidad. En lugar de contar iteraciones directamente, establecemos una **relación de recurrencia** que relaciona el costo de resolver un problema de tamaño  $n$  con el costo de resolver subproblemas más pequeños.

**Definición 1.12** (Relación de recurrencia). *Una **relación de recurrencia** para el tiempo de ejecución  $T(n)$  de un algoritmo recursivo tiene la forma general:*

$$T(n) = \begin{cases} c & \text{si } n \leq n_0 \text{ (caso base)} \\ aT(n/b) + f(n) & \text{si } n > n_0 \text{ (caso recursivo)} \end{cases}$$

donde:

- *$a$  es el número de llamadas recursivas.*
- *$n/b$  es el tamaño de cada subproblema.*
- *$f(n)$  es el costo del trabajo fuera de las llamadas recursivas (dividir y combinar).*

**Ejemplo 1.13** (Búsqueda binaria recursiva). *El algoritmo de búsqueda binaria puede implementarse recursivamente:*

```
binary_search(array, target, left, right):
    if left > right:
        return -1
    mid = (left + right) / 2
    if array[mid] == target:
        return mid
    else if array[mid] < target:
        return binary_search(array, target, mid+1, right)
    else:
        return binary_search(array, target, left, mid-1)
```

**Análisis de complejidad:**

- *Caso base* ( $n = 1$ ):  $T(1) = O(1)$ .
- *Caso recursivo*: una sola llamada recursiva con la mitad del tamaño, más trabajo constante para calcular *mid* y hacer comparaciones.
- *Relación de recurrencia*:  $T(n) = T(n/2) + O(1)$ .

**Resolución:** En cada nivel de recursión, el problema se reduce a la mitad. Si empezamos con tamaño  $n$  y llegamos al caso base de tamaño 1, tenemos:

$$n \rightarrow n/2 \rightarrow n/4 \rightarrow \dots \rightarrow n/2^k = 1$$

Esto ocurre cuando  $k = \log_2 n$ . En cada nivel hacemos trabajo  $O(1)$ , por lo que:

$$T(n) = O(\log n).$$

**Ejemplo 1.14** (Mergesort). *Mergesort es un algoritmo de ordenamiento divide-y-vencerás:*

```
mergesort(array, left, right):
    if left >= right:
        return
    mid = (left + right) / 2
    mergesort(array, left, mid)      // Ordenar mitad izquierda
    mergesort(array, mid+1, right)   // Ordenar mitad derecha
    merge(array, left, mid, right)   // Combinar (O(n))
```

**Análisis de complejidad:**

- *Caso base* ( $n = 1$ ):  $T(1) = O(1)$ .
- *Caso recursivo*: dos llamadas recursivas con la mitad del tamaño cada una, más el trabajo de combinar las dos mitades ordenadas (que cuesta  $O(n)$ ).
- *Relación de recurrencia*:  $T(n) = 2T(n/2) + O(n)$ .

### *Resolución mediante árbol de recursión:*

- **Nivel 0:** Un problema de tamaño  $n$ , costo  $cn$  para combinar.
- **Nivel 1:** Dos problemas de tamaño  $n/2$ , costo total  $2 \cdot c(n/2) = cn$  para combinar.
- **Nivel 2:** Cuatro problemas de tamaño  $n/4$ , costo total  $4 \cdot c(n/4) = cn$  para combinar.
- $\vdots$
- **Nivel  $k$ :**  $2^k$  problemas de tamaño  $n/2^k$ , costo total  $2^k \cdot c(n/2^k) = cn$  para combinar.

El árbol tiene profundidad  $\log_2 n$  (hasta que  $n/2^k = 1$ ), y en cada nivel el costo total es  $cn$ . Por lo tanto:

$$T(n) = cn \cdot \log_2 n = O(n \log n).$$

**Ejemplo 1.15** (Fibonacci ingenuo). El algoritmo recursivo ingenuo para calcular el  $n$ -ésimo número de Fibonacci:

```
fib(n):  
    if n <= 1:  
        return n  
    return fib(n-1) + fib(n-2)
```

### *Análisis de complejidad:*

- **Relación de recurrencia:**  $T(n) = T(n-1) + T(n-2) + O(1)$ .
- Esta recurrencia es similar a la secuencia de Fibonacci misma.

Se puede demostrar que  $T(n) = \Theta(\phi^n)$  donde  $\phi = \frac{1+\sqrt{5}}{2} \approx 1.618$  es la razón áurea. Esto es **complejidad exponencial**, extremadamente ineficiente.

**Observación:** Este problema ilustra cómo un algoritmo recursivo natural puede ser muy ineficiente. Una implementación iterativa o con memoización reduce la complejidad a  $O(n)$ .

### **1.1.4 El Teorema Maestro**

Para recurrencias de la forma  $T(n) = aT(n/b) + f(n)$  donde  $a \geq 1, b > 1$ , el Teorema Maestro proporciona una solución directa sin necesidad de expandir la recursión.

**Teorema 1.16** (Teorema Maestro). Sea  $T(n)$  definida por la recurrencia:

$$T(n) = aT(n/b) + f(n)$$

donde  $a \geq 1, b > 1$  son constantes, y  $f(n)$  es una función asintóticamente positiva. Sea  $c_{crit} = \log_b a$ . Entonces:

1. **Caso 1** (Trabajo dominado por las hojas): Si  $f(n) = O(n^c)$  para algún  $c < c_{crit}$ , entonces:

$$T(n) = \Theta(n^{c_{crit}}) = \Theta(n^{\log_b a}).$$

2. **Caso 2** (Trabajo balanceado en todos los niveles): Si  $f(n) = \Theta(n^{c_{\text{crit}}} \log^k n)$  para algún  $k \geq 0$ , entonces:

$$T(n) = \Theta(n^{c_{\text{crit}}} \log^{k+1} n).$$

En particular, si  $f(n) = \Theta(n^{c_{\text{crit}}})$ , entonces  $T(n) = \Theta(n^{c_{\text{crit}}} \log n)$ .

3. **Caso 3** (Trabajo dominado por la raíz): Si  $f(n) = \Omega(n^c)$  para algún  $c > c_{\text{crit}}$ , y además se satisface la **condición de regularidad**:

$$af(n/b) \leq kf(n) \quad \text{para algún } k < 1 \text{ y } n \text{ suficientemente grande,}$$

entonces:

$$T(n) = \Theta(f(n)).$$

*Demostración (idea intuitiva).* Consideremos el árbol de recursión para  $T(n) = aT(n/b) + f(n)$ :

**Estructura del árbol:**

- **Nivel 0** (raíz): 1 nodo de tamaño  $n$ , costo  $f(n)$ .
- **Nivel 1**:  $a$  nodos de tamaño  $n/b$ , costo total  $a \cdot f(n/b)$ .
- **Nivel 2**:  $a^2$  nodos de tamaño  $n/b^2$ , costo total  $a^2 \cdot f(n/b^2)$ .
- $\vdots$
- **Nivel  $i$** :  $a^i$  nodos de tamaño  $n/b^i$ , costo total  $a^i \cdot f(n/b^i)$ .

**Profundidad del árbol:** El árbol tiene profundidad  $\log_b n$  (cuando  $n/b^k = 1$ , es decir,  $k = \log_b n$ ).

**Número de hojas:** En el nivel más profundo hay  $a^{\log_b n}$  hojas. Usando propiedades de logaritmos:

$$a^{\log_b n} = n^{\log_b a} = n^{c_{\text{crit}}}.$$

**Costo total:** El costo total es la suma de los costos en todos los niveles:

$$T(n) = \sum_{i=0}^{\log_b n - 1} a^i f(n/b^i) + \Theta(n^{c_{\text{crit}}}).$$

El comportamiento de esta suma depende de cómo crece  $f(n)$  comparado con  $n^{c_{\text{crit}}}$ :

**Caso 1:** Si  $f(n) = O(n^c)$  con  $c < c_{\text{crit}}$ , entonces  $a^i f(n/b^i)$  decrece geométricamente con  $i$ . La suma es dominada por las hojas del árbol (nivel más profundo), que contribuyen  $\Theta(n^{c_{\text{crit}}})$ .

**Caso 2:** Si  $f(n) = \Theta(n^{c_{\text{crit}}})$ , entonces  $a^i f(n/b^i) \approx n^{c_{\text{crit}}}$  en cada nivel. Con  $\log_b n$  niveles, el costo total es:

$$T(n) = \Theta(n^{c_{\text{crit}}} \log n).$$

**Caso 3:** Si  $f(n) = \Omega(n^c)$  con  $c > c_{\text{crit}}$ , entonces  $a^i f(n/b^i)$  crece geométricamente al acercarnos a la raíz. La suma es dominada por el trabajo en la raíz, que contribuye  $\Theta(f(n))$  (bajo la condición de regularidad, que garantiza que la serie converge).  $\square$

**Observación 1.17** (Interpretación intuitiva). *El exponente crítico  $c_{crit} = \log_b a$  representa el costo de las hojas del árbol (los casos base). El teorema compara este costo con el trabajo  $f(n)$  hecho en cada nivel:*

- Si las hojas dominan ( $f(n)$  crece más lento que  $n^{c_{crit}}$ ), entonces  $T(n) = \Theta(n^{c_{crit}})$ .
- Si todos los niveles contribuyen igual, el costo se multiplica por la profundidad  $\log n$ .
- Si la raíz domina ( $f(n)$  crece más rápido), entonces  $T(n) = \Theta(f(n))$ .

**Ejemplo 1.18** (Aplicaciones del Teorema Maestro). **1. Búsqueda binaria:**  $T(n) = T(n/2) + O(1)$ .

- $a = 1, b = 2, f(n) = O(1) = O(n^0)$ .
- $c_{crit} = \log_2 1 = 0$ .
- $f(n) = O(n^0) = \Theta(n^{c_{crit}})$ , así que estamos en el Caso 2 con  $k = 0$ .
- Conclusión:  $T(n) = \Theta(n^0 \log n) = \Theta(\log n)$ .

**2. Mergesort:**  $T(n) = 2T(n/2) + O(n)$ .

- $a = 2, b = 2, f(n) = O(n)$ .
- $c_{crit} = \log_2 2 = 1$ .
- $f(n) = \Theta(n) = \Theta(n^{c_{crit}})$ , así que estamos en el Caso 2 con  $k = 0$ .
- Conclusión:  $T(n) = \Theta(n \log n)$ .

**3. Multiplicación de matrices por divide-y-vencerás (ingenuo):**  $T(n) = 8T(n/2) + O(n^2)$ .

- $a = 8, b = 2, f(n) = O(n^2)$ .
- $c_{crit} = \log_2 8 = 3$ .
- $f(n) = O(n^2)$  con  $2 < 3$ , así que estamos en el Caso 1.
- Conclusión:  $T(n) = \Theta(n^3)$  (¡no mejor que el algoritmo estándar!).

**4. Algoritmo de Strassen:**  $T(n) = 7T(n/2) + O(n^2)$ .

- $a = 7, b = 2, f(n) = O(n^2)$ .
- $c_{crit} = \log_2 7 \approx 2.807$ .
- $f(n) = O(n^2)$  con  $2 < 2.807$ , así que estamos en el Caso 1.
- Conclusión:  $T(n) = \Theta(n^{\log_2 7}) \approx \Theta(n^{2.807})$  (¡mejor que  $O(n^3)$ !).

**5. Recurrencia con trabajo dominante:**  $T(n) = 2T(n/2) + O(n^2)$ .

- $a = 2, b = 2, f(n) = O(n^2)$ .
- $c_{crit} = \log_2 2 = 1$ .
- $f(n) = \Omega(n^2)$  con  $2 > 1$ , y se verifica la condición de regularidad:  $2f(n/2) = 2 \cdot (n/2)^2 = n^2/2 \leq kn^2$  para  $k = 1/2 < 1$ .
- *Estamos en el Caso 3.*
- *Conclusión:*  $T(n) = \Theta(n^2)$ .

**Observación 1.19** (Limitaciones del Teorema Maestro). *El Teorema Maestro no cubre todos los casos posibles:*

- *No aplica a recurrencias con subproblemas de tamaños desiguales, como  $T(n) = T(n/3) + T(2n/3) + O(n)$  (Quickselect).*
- *No aplica cuando  $f(n)$  oscila y no es monótona.*
- *Para recurrencias que no caen en ninguno de los tres casos (por ejemplo,  $T(n) = 2T(n/2) + n \log n$ ), se requieren métodos más avanzados como el **teorema maestro generalizado** o análisis directo mediante árboles de recursión.*

## 1.2 Aritmética de Máquina

En computación práctica, trabajamos con representaciones finitas de números, lo que introduce errores y limitaciones.

### 1.2.1 Enteros de 64 bits

Los enteros con signo de 64 bits se representan típicamente en **complemento a dos**:

- Rango:  $[-2^{63}, 2^{63} - 1] = [-9,223,372,036,854,775,808, 9,223,372,036,854,775,807]$ .
- El bit más significativo indica el signo: 0 para positivo, 1 para negativo.
- Operaciones aritméticas (+, −, ×) son exactas si el resultado cabe en el rango.
- **Overflow:** Si el resultado excede el rango, ocurre un desbordamiento (típicamente sin error, dando un resultado módulo  $2^{64}$ ).

**Ejemplo 1.20** (Overflow de enteros). *En aritmética de 8 bits con signo (rango  $[-128, 127]$ ):*

$$100 + 50 = 150 \quad \text{pero} \quad 150 > 127 \implies \text{overflow} \implies -106 \text{ (módulo } 2^8\text{)}.$$



### 1.2.2 Números de punto flotante

Los números reales se representan en una computadora de forma aproximada, utilizando un número finito de bits. Ya hemos visto la representación de enteros; pasamos ahora a la representación de números reales.

**Definición 1.21** (Sistema de punto flotante). *Un sistema de punto flotante  $\mathbb{F}(\beta, t, e_{\min}, e_{\max})$  queda determinado por:*

- una **base**  $\beta \geq 2$ ,
- una **precisión**  $t \geq 1$  (cantidad de dígitos significativos),
- un rango de exponentes  $e_{\min} \leq e \leq e_{\max}$ .

Un **número de máquina normalizado** es un número de la forma

$$x = \pm \underbrace{d_0.d_1d_2\cdots d_{t-1}}_{\text{mantisa}} \times \beta^e,$$

donde  $0 \leq d_i \leq \beta - 1$  para todo  $i$ ,  $d_0 \neq 0$  (condición de normalización), y  $e_{\min} \leq e \leq e_{\max}$ . Además se incluye el 0.

La condición  $d_0 \neq 0$  garantiza la unicidad de la representación. Los dígitos  $d_0.d_1\cdots d_{t-1}$  se llaman la **mantisa** (o *significando*) y son  $t$  dígitos en total. Nótese que como  $d_0 \neq 0$  y  $d_0 \leq \beta - 1$ , la mantisa satisface

$$1 \leq d_0.d_1\cdots d_{t-1} < \beta.$$

#### Formato IEEE 754 de doble precisión

El estándar IEEE 754 utiliza base  $\beta = 2$ . En **doble precisión** (64 bits), los parámetros son:

$$\beta = 2, \quad t = 53, \quad e_{\min} = -1022, \quad e_{\max} = 1023.$$

Los 64 bits se distribuyen así:

- $s$ : 1 bit de **signo**.
- $e$ : 11 bits para el **exponente** (almacenado con sesgo 1023).
- $f$ : 52 bits para la parte fraccionaria de la **mantisa**.

Como la base es 2, la condición de normalización fuerza  $d_0 = 1$ , que no necesita almacenarse (“bit implícito”). Así los 52 bits almacenados, junto con el bit implícito, dan  $t = 53$  bits de precisión. Un número normalizado se escribe

$$x = (-1)^s \times 1.\underbrace{f_1f_2\cdots f_{52}}_{52 \text{ bits}} \times 2^{e-1023}.$$

Además del rango normalizado, el estándar define:

- **Números subnormales** ( $e = 0$ ): permiten representar valores muy pequeños cerca de cero, sacrificando precisión gradualmente (*gradual underflow*).
- **$\pm$ Infinito** ( $e = 2047, f = 0$ ): resultado de desbordamientos (*overflow*).
- **NaN** (*Not a Number*,  $e = 2047, f \neq 0$ ): resultado de operaciones indefinidas como  $0/0$  o  $\sqrt{-1}$ .

**Ejemplo 1.22** (Rango de doble precisión). • *Menor positivo normalizado*:  $2^{-1022} \approx 2.225 \times 10^{-308}$ .

- *Mayor número representable*:  $(2 - 2^{-52}) \times 2^{1023} \approx 1.798 \times 10^{308}$ .

## Formatos de punto flotante en GPUs y machine learning

La doble precisión (FP64) es el estándar en cálculo científico, pero en aplicaciones de aprendizaje automático y procesamiento en GPUs se utilizan formatos de menor precisión que permiten mayor rendimiento y menor consumo de memoria. La siguiente tabla resume los formatos más comunes.

| Formato         | Bits | Signo | Exponente | Mantisa <sup>(*)</sup> | $\epsilon_{\text{mach}}$              |
|-----------------|------|-------|-----------|------------------------|---------------------------------------|
| FP64 (double)   | 64   | 1     | 11        | 52 (53)                | $2^{-52} \approx 2.2 \times 10^{-16}$ |
| FP32 (float)    | 32   | 1     | 8         | 23 (24)                | $2^{-23} \approx 1.2 \times 10^{-7}$  |
| TF32            | 19   | 1     | 8         | 10 (11)                | $2^{-10} \approx 9.8 \times 10^{-4}$  |
| FP16 (half)     | 16   | 1     | 5         | 10 (11)                | $2^{-10} \approx 9.8 \times 10^{-4}$  |
| BF16 (bfloat16) | 16   | 1     | 8         | 7 (8)                  | $2^{-7} \approx 7.8 \times 10^{-3}$   |
| FP8 (E5M2)      | 8    | 1     | 5         | 2 (3)                  | $2^{-2} = 0.25$                       |
| FP8 (E4M3)      | 8    | 1     | 4         | 3 (4)                  | $2^{-3} = 0.125$                      |

Table 1.1: Formatos de punto flotante utilizados en GPUs y machine learning. La columna “Mantisa” indica los bits almacenados y, entre paréntesis, la precisión total  $t$  incluyendo el bit implícito. TF32 es un formato de NVIDIA (Ampere y posterior); BF16 fue introducido por Google Brain; los formatos FP8 fueron estandarizados para las arquitecturas NVIDIA Hopper y AMD MI300.

Nótese que BF16 tiene el mismo rango de exponentes que FP32 (8 bits), lo que evita problemas de overflow/underflow al entrenar redes neuronales, a costa de menor precisión. En contraste, FP16 tiene mayor precisión que BF16 pero un rango de exponentes mucho más reducido. TF32 combina el exponente de FP32 con una mantisa intermedia y se usa internamente en las unidades tensoriales de NVIDIA. Los formatos FP8 de 8 bits, con precisiones de apenas 3 o 4 bits, se utilizan para inferencia y entrenamiento con cuantización agresiva.

### 1.2.3 Épsilon de máquina

¿Cuál es la “resolución” de un sistema de punto flotante? Para responder esta pregunta, consideremos la distancia entre el número 1 y el siguiente número de máquina.

En el sistema  $\mathbb{F}(\beta, t, e_{\min}, e_{\max})$ , el número 1 se representa como  $1.\underbrace{00\cdots 0}_{t-1} \times \beta^0$ . El siguiente número representable es

$$1.\underbrace{00\cdots 0}_{t-2} 1 \times \beta^0 = 1 + \beta^{-(t-1)}.$$

La distancia entre estos dos números motiva la siguiente definición central.

**Definición 1.23** (Épsilon de máquina). *El **épsilon de máquina** del sistema  $\mathbb{F}(\beta, t, e_{\min}, e_{\max})$  es*

$$\epsilon_{\text{mach}} = \beta^{1-t}.$$

**Observación 1.24.** *En la literatura existen dos convenciones: algunos autores definen  $\epsilon_{\text{mach}} = \beta^{1-t}$  (la distancia de 1 al siguiente representable) y otros definen  $\epsilon_{\text{mach}} = \frac{1}{2}\beta^{1-t}$  (el máximo error relativo de redondeo, llamado unit roundoff). Seguimos la primera convención, que es la utilizada por IEEE, MATLAB (`eps`), NumPy (`np.finfo(float).eps`), y Julia (`eps()`). En esta convención, la cota de error relativo de redondeo es  $\epsilon_{\text{mach}}/2$ .*

Veamos por qué  $\epsilon_{\text{mach}} = \beta^{1-t}$  coincide con la distancia entre 1 y el siguiente número de máquina. Ya observamos que dicha distancia vale  $\beta^{-(t-1)} = \beta^{1-t}$ . Esto es consistente:  $\epsilon_{\text{mach}} = \beta^{1-t}$ .

**Ejemplo 1.25** (Doble precisión). *Para IEEE 754 doble precisión,  $\beta = 2$ ,  $t = 53$ :*

$$\epsilon_{\text{mach}} = 2^{1-53} = 2^{-52} \approx 2.220 \times 10^{-16}.$$

*Esto significa que un número de punto flotante de doble precisión tiene aproximadamente 15–16 dígitos decimales significativos.*

## 1.2.4 Redondeo y la cota fundamental de error

**Definición 1.26** (Función de redondeo). *La **función de redondeo al más cercano**  $\text{fl}: \mathbb{R} \rightarrow \mathbb{F}$  asigna a cada número real  $x$  (en el rango representable) el número de máquina más cercano a  $x$ . En caso de empate, el estándar IEEE 754 utiliza la regla round to even (se elige el número cuyo último dígito es par).*

La propiedad más importante del redondeo es la siguiente cota de error relativo. Para demostrarla, necesitamos primero entender el espaciado entre números de máquina consecutivos.

**Lema 1.27** (Espaciado entre números de máquina consecutivos). *En el sistema  $\mathbb{F}(\beta, t, e_{\min}, e_{\max})$ , dos números de máquina normalizados consecutivos con exponente  $e$  distan exactamente*

$$\Delta_e = \beta^{e-(t-1)}.$$

*Demostración.* Un número de máquina normalizado con exponente  $e$  tiene la forma

$$x = d_0.d_1d_2\cdots d_{t-1} \times \beta^e,$$

donde  $d_0 \neq 0$  y  $0 \leq d_i \leq \beta - 1$ . Esto equivale a escribir

$$x = \left( \sum_{k=0}^{t-1} d_k \beta^{-k} \right) \beta^e = \left( \sum_{k=0}^{t-1} d_k \beta^{t-1-k} \right) \beta^{e-(t-1)}.$$

La cantidad entre paréntesis,  $m = \sum_{k=0}^{t-1} d_k \beta^{t-1-k}$ , es un entero (pues cada término es un entero). Además, dos números de máquina consecutivos con el mismo exponente  $e$  difieren en que sus enteros  $m$  correspondientes difieren en 1. Por lo tanto, la distancia entre ellos es

$$\Delta_e = 1 \times \beta^{e-(t-1)} = \beta^{e-(t-1)}.$$

□

Nótese que este espaciado **depende del exponente  $e$** : los números de máquina se hacen más densos cerca de cero y más espaciados lejos del origen. Sin embargo, el espaciado *relativo* es aproximadamente uniforme: como los números normalizados con exponente  $e$  satisfacen  $|x| \geq \beta^e$ , se tiene  $\Delta_e/|x| \leq \beta^{e-(t-1)}/\beta^e = \beta^{1-t} = \epsilon_{\text{mach}}$ .

**Teorema 1.28** (Cota fundamental del error de redondeo). *Para todo número real  $x$  en el rango normalizado del sistema  $\mathbb{F}(\beta, t, e_{\min}, e_{\max})$ , se cumple*

$$\boxed{\frac{|\text{fl}(x) - x|}{|x|} \leq \frac{1}{2} \epsilon_{\text{mach}} = \frac{1}{2} \beta^{1-t}}.$$

Equivalentemente, existe  $\delta$  con  $|\delta| \leq \frac{1}{2} \epsilon_{\text{mach}}$  tal que  $\text{fl}(x) = x(1 + \delta)$ .

La cantidad  $u = \frac{1}{2} \epsilon_{\text{mach}} = \frac{1}{2} \beta^{1-t}$  se denomina el **unit roundoff** y representa la máxima precisión relativa que puede esperarse de una operación de punto flotante.

*Demostración.* Sea  $x \neq 0$  un número real en el rango normalizado, con exponente  $e$  (es decir,  $\beta^e \leq |x| < \beta^{e+1}$ ). Por el Lema 1.27,  $x$  se encuentra entre dos números de máquina consecutivos  $x^-$  y  $x^+ = x^- + \beta^{e-(t-1)}$ . El redondeo al más cercano satisface

$$|\text{fl}(x) - x| \leq \frac{1}{2} (x^+ - x^-) = \frac{1}{2} \beta^{e-(t-1)}.$$

Como  $|x| \geq \beta^e$ , dividiendo:

$$\frac{|\text{fl}(x) - x|}{|x|} \leq \frac{\frac{1}{2} \beta^{e-(t-1)}}{\beta^e} = \frac{1}{2} \beta^{1-t} = \frac{1}{2} \epsilon_{\text{mach}}.$$

Para la formulación equivalente, basta definir  $\delta = (\text{fl}(x) - x)/x$ ; la cota recién demostrada da  $|\delta| \leq \frac{1}{2} \epsilon_{\text{mach}}$ , y entonces  $\text{fl}(x) = x + x\delta = x(1 + \delta)$ . □

**Observación 1.29.** *La cota es ajustada: se alcanza (hasta factores de redondeo) cuando  $x$  está justo en el punto medio entre dos consecutivos y  $|x|$  es apenas mayor que  $\beta^e$ . Por ejemplo, en doble precisión el número  $x = 1 + 2^{-53}$  (punto medio entre 1 y  $1 + 2^{-52}$ ) se redondea con error relativo exactamente  $2^{-53} = \epsilon_{\text{mach}}/2$ .*

**Ejemplo 1.30** (Doble precisión). *Para IEEE 754 doble precisión:*

$$u = \frac{\epsilon_{\text{mach}}}{2} = \frac{2^{-52}}{2} = 2^{-53} \approx 1.11 \times 10^{-16}.$$

*Esto significa que toda representación en punto flotante introduce un error relativo de a lo sumo  $\sim 10^{-16}$ .*

La formulación  $\text{fl}(x) = x(1 + \delta)$  es particularmente útil para propagar errores a través de secuencias de operaciones aritméticas. El estándar IEEE 754 garantiza además que cada operación aritmética elemental se realiza con esta misma precisión, lo que enunciamos como corolario.

**Corolario 1.31** (Modelo estándar de aritmética de punto flotante). *Sea  $u = \frac{1}{2}\epsilon_{\text{mach}}$ . En aritmética IEEE 754, para todo par de números de máquina  $a, b \in \mathbb{F}$  y toda operación  $\text{op} \in \{+, -, \times, /\}$  (con  $b \neq 0$  para la división), existe  $\delta$  con  $|\delta| \leq u$  tal que*

$$\text{fl}(a \text{ op } b) = (a \text{ op } b)(1 + \delta).$$

*Es decir, el resultado en punto flotante es el resultado exacto perturbado por un error relativo de a lo sumo  $u$ .*

Este modelo es el punto de partida del **análisis de errores de redondeo**: para estudiar un algoritmo, se reemplaza cada operación aritmética por la versión perturbada y se propagan los  $\delta$ .

**Ejemplo 1.32** (Error de redondeo de la suma). *Sean  $a, b \in \mathbb{F}$ . La suma en punto flotante satisface*

$$\text{fl}(a + b) = (a + b)(1 + \delta_1), \quad |\delta_1| \leq u.$$

*El error absoluto es  $|\text{fl}(a + b) - (a + b)| = |a + b| |\delta_1| \leq u |a + b|$ , y el error relativo (cuando  $a + b \neq 0$ ) es simplemente  $|\delta_1| \leq u$ . La suma de dos números de máquina introduce, pues, un error relativo de a lo sumo  $u$  sobre el resultado exacto.*

*Sin embargo, si  $a$  y  $b$  tienen signos opuestos y son de magnitud similar,  $|a + b|$  puede ser mucho menor que  $|a|$  o  $|b|$ : aunque el error relativo de la operación es pequeño, el resultado puede tener pocos dígitos significativos respecto de los operandos originales. Esto es la cancelación catastrófica (Ejemplo 1.35).*

**Ejemplo 1.33** (Error de redondeo de la multiplicación). *Sean  $a, b \in \mathbb{F}$ . La multiplicación en punto flotante satisface*

$$\text{fl}(a \cdot b) = a \cdot b(1 + \delta_1), \quad |\delta_1| \leq u.$$

*El error relativo es directamente  $|\delta_1| \leq u$ , independientemente de los valores de  $a$  y  $b$ . La multiplicación es, en este sentido, una operación “benigna” para los errores de redondeo: no sufre cancelación.*

**Ejemplo 1.34** (Propagación de errores: el producto interno). *Consideremos el cálculo de  $s = a_1b_1 + a_2b_2$  en punto flotante. Cada paso introduce su propio  $\delta$ :*

$$\begin{aligned} p_1 &= \text{fl}(a_1b_1) = a_1b_1(1 + \delta_1), \\ p_2 &= \text{fl}(a_2b_2) = a_2b_2(1 + \delta_2), \\ \hat{s} &= \text{fl}(p_1 + p_2) = (p_1 + p_2)(1 + \delta_3), \end{aligned}$$

*con  $|\delta_i| \leq u$ . Sustituyendo:*

$$\hat{s} = (a_1b_1(1 + \delta_1) + a_2b_2(1 + \delta_2))(1 + \delta_3).$$

Expandiendo y descartando términos de orden  $u^2$  (que son despreciables, del orden de  $10^{-32}$  en doble precisión):

$$\hat{s} \approx a_1 b_1 (1 + \delta_1 + \delta_3) + a_2 b_2 (1 + \delta_2 + \delta_3).$$

El error absoluto satisface

$$|\hat{s} - s| \lesssim 2u (|a_1 b_1| + |a_2 b_2|).$$

Nótese que la cota depende de  $|a_1 b_1| + |a_2 b_2|$  y no de  $|a_1 b_1 + a_2 b_2|$ : si los términos se cancelan parcialmente, el error relativo  $|\hat{s} - s|/|s|$  puede ser grande. Este análisis se generaliza al producto interno de vectores de dimensión  $n$ , donde la cota toma la forma  $|\hat{s} - s| \lesssim nu \sum |a_i b_i|$ .

### 1.2.5 Consecuencias y ejemplos

**Ejemplo 1.35** (Pérdida de significancia — cancelación catastrófica). Restar números muy cercanos puede causar pérdida de dígitos significativos. Si  $a = 1.234567890123456$  y  $b = 1.234567890123455$ , entonces

$$a - b \approx 1 \times 10^{-15} \quad (\text{queda un solo dígito significativo}).$$

El resultado tiene una precisión relativa mucho peor que  $\epsilon_{mach}$ , no porque la resta esté mal hecha, sino porque los dígitos significativos de  $a$  y  $b$  se cancelan. Este fenómeno se llama **cancelación catastrófica**.

**Ejemplo 1.36** (La suma no es asociativa en punto flotante). En punto flotante,  $(a + b) + c \neq a + (b + c)$  en general:

$$(10^{16} + 1) - 10^{16} = 0 \quad (\text{el 1 se pierde al sumarse a } 10^{16}),$$

$$10^{16} + (1 - 10^{16}) = 10^{16} + (-10^{16} + 1) = 1 \quad (\text{orden diferente}).$$

El resultado depende del orden de evaluación porque la precisión relativa es fija: los números representables cerca de  $10^{16}$  están espaciados en más de 1.

### 1.2.6 Precisión arbitraria por software

Para superar las limitaciones de punto flotante, existen bibliotecas de **precisión arbitraria**:

- **BigInt**: Enteros de tamaño ilimitado. Disponible nativamente en lenguajes modernos (Python, JavaScript ES2020).
- **BigFloat**: Números de punto flotante con precisión configurable. Bibliotecas: GMP (C), mpmath (Python), Arb (C).

**Ejemplo 1.37** (Cálculo de  $\pi$  con alta precisión). Usando *mpmath* en Python:

```
from mpmath import mp
mp.dps = 100 # 100 dígitos decimales
pi_100 = mp.pi
print(pi_100)
```

Resultado:

**Costo:** Las operaciones con precisión arbitraria son *mucho más lentas* que las de hardware (típicamente 10-1000 veces). Además, la complejidad crece con la precisión.

### 1.2.7 Ejemplos en geometría computacional

La aritmética finita puede causar errores graves en geometría computacional.

**Ejemplo 1.38** (Test de orientación). *Dados tres puntos  $A, B, C$  en el plano, determinar si  $C$  está a la izquierda, derecha, o sobre la línea  $AB$ . Se calcula el determinante:*

$$D = \begin{vmatrix} x_A & y_A & 1 \\ x_B & y_B & 1 \\ x_C & y_C & 1 \end{vmatrix} = (x_B - x_A)(y_C - y_A) - (y_B - y_A)(x_C - x_A).$$

- $D > 0$ :  $C$  a la izquierda.
- $D < 0$ :  $C$  a la derecha.
- $D = 0$ :  $C$  colineal.

**Problema:** Con punto flotante,  $D$  puede ser muy pequeño pero no exactamente cero, llevando a decisiones erróneas sobre colinealidad.

**Ejemplo 1.39** (Intersección de segmentos). *Determinar si dos segmentos  $AB$  y  $CD$  se intersectan requiere comparaciones geométricas precisas. Errores de redondeo pueden hacer que:*

- Segmentos que se intersectan apenas se reporten como no intersectándose.
- Algoritmos de triangulación fallen al producir geometría inválida.

**Solución:** Usar predicados exactos (*exact predicates*) mediante aritmética de precisión arbitraria o expansión de flotantes (algoritmo de Shewchuk).

**Ejemplo 1.40** (Algoritmo de Graham para el casco convexo). *Construir el casco convexo de  $n$  puntos requiere ordenar puntos por ángulo y hacer tests de orientación. Errores numéricos pueden:*

- Hacer que el algoritmo produzca un polígono no convexo.
- Causar que el algoritmo entre en bucle infinito al no poder decidir correctamente la orientación.

**Observación 1.41** (Geometría computacional robusta). *Los algoritmos geométricos comerciales (CAD, GIS) usan técnicas especiales:*

- **Aritmética exacta** para predicados críticos.
- **Perturbación simbólica** para romper degeneraciones.
- **Snap rounding** para redondear coordenadas a una rejilla.

## Chapter 2

# Álgebra Lineal Numérica

### 2.1 Eliminación Gaussiana y factorización LU

La **eliminación Gaussiana** es el método más antiguo y fundamental para resolver sistemas lineales. Consiste en transformar el sistema en uno equivalente de forma triangular superior, que se resuelve fácilmente por sustitución hacia atrás.

#### 2.1.1 Eliminación Gaussiana sin pivoteo

**Ejemplo 2.1** (Eliminación Gaussiana). *Consideremos el sistema:*

$$\begin{pmatrix} 2 & 1 & 1 \\ 4 & -6 & 0 \\ -2 & 7 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 5 \\ -2 \\ 9 \end{pmatrix}.$$

**Paso 1:** Eliminar  $x_1$  de las ecuaciones 2 y 3.

- Multiplicador para fila 2:  $m_{21} = 4/2 = 2$ . Restar  $2 \times$  fila 1 de fila 2.
- Multiplicador para fila 3:  $m_{31} = -2/2 = -1$ . Restar  $-1 \times$  fila 1 de fila 3.

Resultado:

$$\begin{pmatrix} 2 & 1 & 1 \\ 0 & -8 & -2 \\ 0 & 8 & 3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 5 \\ -12 \\ 14 \end{pmatrix}.$$

**Paso 2:** Eliminar  $x_2$  de la ecuación 3.

- Multiplicador:  $m_{32} = 8/(-8) = -1$ . Restar  $-1 \times$  fila 2 de fila 3.

Resultado (matriz triangular superior):

$$\begin{pmatrix} 2 & 1 & 1 \\ 0 & -8 & -2 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 5 \\ -12 \\ 2 \end{pmatrix}.$$



**Paso 3:** Sustitución hacia atrás:

$$\begin{aligned}x_3 &= 2, \\x_2 &= \frac{-12 + 2x_3}{-8} = \frac{-12 + 4}{-8} = 1, \\x_1 &= \frac{5 - x_2 - x_3}{2} = \frac{5 - 1 - 2}{2} = 1.\end{aligned}$$

### 2.1.2 Factorización LU

La eliminación Gaussiana puede interpretarse como una factorización matricial.

**Teorema 2.2** (Factorización LU). *Si la eliminación Gaussiana se puede realizar sin intercambio de filas (sin pivoteo), entonces  $A$  admite una factorización:*

$$A = LU,$$

donde:

- $L \in \mathbb{C}^{n \times n}$  es triangular inferior con unos en la diagonal,
- $U \in \mathbb{C}^{n \times n}$  es triangular superior.

Además, los elementos de  $L$  son precisamente los multiplicadores  $m_{ij}$  usados en la eliminación.

*Idea.* Cada paso de eliminación puede representarse como una multiplicación por una matriz triangular inferior. En el paso  $k$ , eliminamos los elementos debajo del pivote  $a_{kk}$  multiplicando por la izquierda por:

$$M_k = \begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -m_{k+1,k} & \ddots & \\ & & \vdots & & 1 \\ & & -m_{n,k} & & \end{pmatrix}.$$

Después de  $n - 1$  pasos:

$$M_{n-1} \cdots M_2 M_1 A = U.$$

Como cada  $M_k$  es triangular inferior invertible, podemos escribir:

$$A = M_1^{-1} M_2^{-1} \cdots M_{n-1}^{-1} U = LU,$$

donde  $L = M_1^{-1} M_2^{-1} \cdots M_{n-1}^{-1}$ . Un cálculo directo muestra que  $L$  tiene los multiplicadores  $m_{ij}$  debajo de la diagonal.  $\square$

**Ejemplo 2.3** (Construcción de  $L$  y  $U$ ). *Para la matriz del ejemplo anterior:*

$$A = \begin{pmatrix} 2 & 1 & 1 \\ 4 & -6 & 0 \\ -2 & 7 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ -1 & -1 & 1 \end{pmatrix} \begin{pmatrix} 2 & 1 & 1 \\ 0 & -8 & -2 \\ 0 & 0 & 1 \end{pmatrix} = LU.$$

Los elementos de  $L$  debajo de la diagonal son los multiplicadores:  $m_{21} = 2$ ,  $m_{31} = -1$ ,  $m_{32} = -1$ .

### 2.1.3 Pivoteo parcial y factorización PLU

La eliminación Gaussiana puede fallar o ser numéricamente inestable si los pivotes son pequeños. La solución es el **pivoteo parcial**: intercambiar filas para asegurar que el pivote sea el elemento de mayor magnitud en cada columna.

**Teorema 2.4** (Factorización PLU). *Toda matriz invertible  $A \in \mathbb{C}^{n \times n}$  admite una factorización:*

$$PA = LU,$$

donde  $P$  es una matriz de permutación,  $L$  es triangular inferior con unos en la diagonal, y  $U$  es triangular superior.

**Observación 2.5** (Solución de sistemas con PLU). *Una vez calculada la factorización  $PA = LU$ , resolver  $Ax = b$  requiere:*

1. Permutar el vector:  $\tilde{b} = Pb$
2. Resolver  $Ly = \tilde{b}$  (sustitución hacia adelante): costo  $O(n^2)$
3. Resolver  $Ux = y$  (sustitución hacia atrás): costo  $O(n^2)$

El costo total es  $O(n^3)$  para la factorización (hecha una sola vez) más  $O(n^2)$  por cada sistema resuelto. Más precisamente, el conteo de operaciones de la factorización  $LU$  es  $\frac{2}{3}n^3 + O(n^2)$  (aproximadamente  $\frac{n^3}{3}$  multiplicaciones y  $\frac{n^3}{3}$  sumas), como se verifica sumando el costo del paso  $k$ : la eliminación de la columna  $k$  requiere  $(n-k)$  divisiones y  $(n-k)^2$  operaciones de multiplicación-suma, dando un total de  $\sum_{k=1}^{n-1} (n-k)^2 = \frac{(n-1)n(2n-1)}{6} \sim \frac{n^3}{3}$  para cada tipo.

## 2.2 Ortogonalización de Gram-Schmidt y factorización QR

Otra factorización importante es la **factorización QR**, que descompone una matriz en un producto de una matriz ortogonal y una triangular superior. Se obtiene mediante el proceso de **Gram-Schmidt**.

### 2.2.1 Proceso de Gram-Schmidt clásico

**Teorema 2.6** (Gram-Schmidt Clásico (CGS)). *Dado un conjunto de vectores linealmente independientes  $\{a_1, \dots, a_n\} \subset \mathbb{C}^m$ , el proceso de Gram-Schmidt construye un conjunto ortonormal  $\{q_1, \dots, q_n\}$  que genera el mismo subespacio:*

$$\text{span}\{a_1, \dots, a_k\} = \text{span}\{q_1, \dots, q_k\}, \quad k = 1, \dots, n.$$

**Algoritmo (Gram-Schmidt Clásico):**

1. Para  $k = 1, \dots, n$ :
  - (a)  $\tilde{q}_k = a_k$
  - (b) Para  $j = 1, \dots, k-1$ :
    - $r_{jk} = (a_k, q_j)$

- $\tilde{q}_k \leftarrow \tilde{q}_k - r_{jk}q_j$
- (c)  $r_{kk} = \|\tilde{q}_k\|_2$
- (d)  $q_k = \tilde{q}_k/r_{kk}$

**Observación 2.7.** El proceso CGS ortogonaliza  $a_k$  restando de una sola vez las proyecciones sobre todos los vectores ortogonales  $q_1, \dots, q_{k-1}$  previamente calculados.

### 2.2.2 Gram-Schmidt Modificado (MGS)

El problema con CGS es que es numéricamente inestable: los errores de redondeo pueden hacer que los vectores resultantes no sean ortogonales. El **Gram-Schmidt Modificado** (MGS) resuelve este problema.

**Algoritmo (Gram-Schmidt Modificado):**

1. Para  $k = 1, \dots, n$ :
  - (a)  $\tilde{q}_k = a_k$
  - (b) Para  $j = 1, \dots, k-1$ :
    - $r_{jk} = (\tilde{q}_k, q_j)$  (usar el vector parcialmente ortogonalizado)
    - $\tilde{q}_k \leftarrow \tilde{q}_k - r_{jk}q_j$  (ortogonalizar paso a paso)
  - (c)  $r_{kk} = \|\tilde{q}_k\|_2$
  - (d)  $q_k = \tilde{q}_k/r_{kk}$

**Observación 2.8** (Diferencia entre CGS y MGS). La diferencia clave es que MGS actualiza  $\tilde{q}_k$  después de cada proyección y usa el vector actualizado en la siguiente proyección. Esto hace que MGS sea mucho más estable numéricamente, produciendo vectores con mejor ortogonalidad en presencia de errores de redondeo.

### 2.2.3 Factorización QR

El proceso de Gram-Schmidt aplicado a las columnas de una matriz produce la factorización QR.

**Teorema 2.9** (Factorización QR). Toda matriz  $A \in \mathbb{C}^{m \times n}$  con  $m \geq n$  y rango completo admite una factorización:

$$A = QR,$$

donde:

- $Q \in \mathbb{C}^{m \times n}$  tiene columnas ortonormales:  $Q^*Q = I_n$ ,
- $R \in \mathbb{C}^{n \times n}$  es triangular superior con diagonal positiva.

Si se extiende  $Q$  a una matriz unitaria  $m \times m$ , se puede escribir:

$$A = (Q_1 \quad Q_2) \begin{pmatrix} R \\ 0 \end{pmatrix} = Q_1 R,$$

donde  $Q_1 Q_1^* + Q_2 Q_2^* = I_m$ .

*Demostración.* Aplicando Gram-Schmidt (modificado) a las columnas de  $A = (a_1 | \cdots | a_n)$ , obtenemos vectores ortonormales  $q_1, \dots, q_n$  y coeficientes  $r_{jk}$  tales que:

$$a_k = \sum_{j=1}^k r_{jk} q_j = \sum_{j=1}^n r_{jk} q_j,$$

donde  $r_{jk} = 0$  para  $j > k$  (triangularidad superior). Escribiendo esto en forma matricial:

$$A = QR, \quad Q = (q_1 | \cdots | q_n), \quad R = (r_{ij}).$$

□

**Ejemplo 2.10** (Factorización QR explícita). Sea

$$A = \begin{pmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

Aplicando MGS:

1.  $a_1 = (1, 1, 0)^T$ ,  $r_{11} = \|a_1\|_2 = \sqrt{2}$ ,  $q_1 = (1/\sqrt{2}, 1/\sqrt{2}, 0)^T$ .
2.  $\tilde{q}_2 = a_2 = (1, 0, 1)^T$ .
3.  $r_{12} = (a_2, q_1) = 1/\sqrt{2}$ .
4.  $\tilde{q}_2 \leftarrow (1, 0, 1)^T - \frac{1}{\sqrt{2}}(1/\sqrt{2}, 1/\sqrt{2}, 0)^T = (1/2, -1/2, 1)^T$ .
5.  $r_{22} = \|\tilde{q}_2\|_2 = \sqrt{1/4 + 1/4 + 1} = \sqrt{3/2}$ .
6.  $q_2 = (1/\sqrt{6}, -1/\sqrt{6}, 2/\sqrt{6})^T$ .

Entonces:

$$A = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{6} \\ 1/\sqrt{2} & -1/\sqrt{6} \\ 0 & 2/\sqrt{6} \end{pmatrix} \begin{pmatrix} \sqrt{2} & 1/\sqrt{2} \\ 0 & \sqrt{3/2} \end{pmatrix} = QR.$$

1. **Solución de sistemas lineales:** Si  $A = QR$  con  $A$  cuadrada e invertible, entonces:

$$Ax = b \quad \Rightarrow \quad QRx = b \quad \Rightarrow \quad Rx = Q^*b,$$

que se resuelve por sustitución hacia atrás en  $O(n^2)$  operaciones.

2. **Problemas de cuadrados mínimos:** Como veremos en el próximo capítulo, QR es superior a las ecuaciones normales para resolver problemas de mínimos cuadrados.
3. **Cálculo de autovalores:** El método QR iterativo (Capítulo 3) es el algoritmo estándar para calcular todos los autovalores de una matriz.

**Observación 2.11** (Comparación: LU vs QR). • **Costo:** La factorización LU cuesta  $\frac{2}{3}n^3$  operaciones, mientras que QR (vía MGS) cuesta  $2n^3$  operaciones. LU es más rápida.

- **Estabilidad:** *QR es más estable numéricamente, especialmente para matrices mal condicionadas.*
- **Aplicaciones:** *LU se prefiere para sistemas lineales simples. QR se prefiere para cuadrados mínimos, autovalores, y cuando la estabilidad es crítica.*

## 2.3 Cuadrados mínimos y proyección ortogonal

El problema de **cuadrados mínimos** consiste en encontrar  $x \in \mathbb{C}^n$  que minimiza el residuo  $\|Ax - b\|_2$  para un sistema sobredeterminado  $Ax = b$ , con  $A \in \mathbb{C}^{m \times n}$  ( $m \geq n$ ) y  $b \in \mathbb{C}^m$ .

Recordemos de Álgebra Lineal que si  $S$  es un subespacio de un espacio con producto interno  $V$ , la mejor aproximación de un vector  $b \in V$  en  $S$  es su **proyección ortogonal**  $P_S(b)$ . Esta proyección se caracteriza por la propiedad de que el error es ortogonal al subespacio:

$$(b - P_S(b)) \perp S.$$

En el contexto de matrices, buscamos  $Ax \in \text{Im}(A)$  que esté lo más cerca posible de  $b$ . Por lo tanto, el residuo  $r = b - Ax$  debe ser ortogonal a todo el espacio columna  $\text{Im}(A)$ .

### 2.3.1 Ecuaciones normales para cuadrados mínimos

El problema de **cuadrados mínimos** consiste en encontrar  $x \in \mathbb{C}^n$  que minimiza:

$$\|Ax - b\|_2, \quad A \in \mathbb{C}^{m \times n}, \quad b \in \mathbb{C}^m, \quad m \geq n.$$

**Teorema 2.12** (Ecuaciones normales). *El vector  $x$  que minimiza  $\|Ax - b\|_2$  satisface las **ecuaciones normales**:*

$$A^*Ax = A^*b.$$

*Si  $A$  tiene rango completo (rango  $n$ ), entonces  $A^*A$  es invertible y la solución única es:*

$$x = (A^*A)^{-1}A^*b.$$

*Demostración.* Sea  $x$  el minimizador de  $\|Ax - b\|_2$ . Por el Teorema de proyección ortogonal (Teorema B.11), el error  $r = Ax - b$  debe ser ortogonal al espacio columna de  $A$ , es decir,  $r \perp \text{Im}(A)$ .

Esto significa que para todo  $v \in \mathbb{C}^n$ , tenemos  $Av \perp r$ , o equivalentemente:

$$(Av, r) = 0 \quad \text{para todo } v \in \mathbb{C}^n.$$

Usando la propiedad del producto interno:

$$(Av, Ax - b) = 0 \quad \text{para todo } v \in \mathbb{C}^n.$$

Por la antilinealidad en el segundo argumento y la propiedad  $(u, v) = v^*u$  para vectores:

$$(Av)^*(Ax - b) = v^*A^*(Ax - b) = 0 \quad \text{para todo } v \in \mathbb{C}^n.$$

Como esto debe valer para todo  $v \in \mathbb{C}^n$ , necesariamente:

$$A^*(Ax - b) = 0,$$

lo que es equivalente a las ecuaciones normales:

$$A^*Ax = A^*b.$$

Para la segunda parte, si  $A$  tiene rango completo (rango  $n$ ), entonces las columnas de  $A$  son linealmente independientes. Esto implica que  $A^*A$  es invertible, pues si  $A^*Ax = 0$ , entonces:

$$\|Ax\|^2 = (Ax, Ax) = x^*A^*Ax = x^*0 = 0,$$

lo que implica  $Ax = 0$ , y por el rango completo de  $A$ , necesariamente  $x = 0$ . Por lo tanto,  $A^*A$  es invertible y la solución única es:

$$x = (A^*A)^{-1}A^*b.$$

□

### 2.3.2 QR para cuadrados mínimos

Una alternativa a la solución directa de las ecuaciones normales es usar la **factorización QR**.

**Teorema 2.13** (Factorización QR). *Toda matriz  $A \in \mathbb{C}^{m \times n}$  con  $m \geq n$  admite una factorización:*

$$A = QR,$$

donde  $Q \in \mathbb{C}^{m \times m}$  es unitaria ( $Q^*Q = I$ ) y  $R \in \mathbb{C}^{m \times n}$  es triangular superior.

Si  $A$  tiene rango completo, podemos escribir:

$$A = Q \begin{pmatrix} R_1 \\ 0 \end{pmatrix}, \quad Q = (Q_1 \quad Q_2),$$

donde  $R_1 \in \mathbb{C}^{n \times n}$  es triangular superior invertible y  $Q_1 \in \mathbb{C}^{m \times n}$  tiene columnas ortonormales.

**Teorema 2.14** (Solución de cuadrados mínimos vía QR). *Si  $A = QR$  con  $Q$  unitaria y  $R$  triangular superior, entonces la solución de cuadrados mínimos de  $\|Ax - b\|_2$  se reduce a resolver:*

$$R_1x = Q_1^*b,$$

un sistema triangular que se resuelve por sustitución hacia atrás en  $O(n^2)$  operaciones.

*Demostración.* Como  $Q$  es unitaria, preserva la norma:

$$\|Ax - b\|_2 = \|QRx - b\|_2 = \|Rx - Q^*b\|_2 = \left\| \begin{pmatrix} R_1x \\ 0 \end{pmatrix} - \begin{pmatrix} Q_1^*b \\ Q_2^*b \end{pmatrix} \right\|_2.$$

Esto se minimiza cuando  $R_1x = Q_1^*b$ , dando un residuo mínimo de  $\|Q_2^*b\|_2$ .

□

## 2.4 Descomposición en Valores Singulares (SVD)

La **descomposición en valores singulares** (SVD) es una de las factorizaciones más importantes en álgebra lineal numérica.

Para construirla nos apoyamos en el **teorema espectral** para matrices hermíticas, aunque lo enunciamos aquí en el caso más general de matrices normales.

**Teorema 2.15** (Teorema espectral para matrices normales). *Sea  $A \in \mathbb{C}^{n \times n}$  una matriz normal ( $A^*A = AA^*$ ). Entonces  $A$  es diagonalizable por una matriz unitaria:*

$$A = U\Lambda U^*,$$

donde  $U$  es unitaria y  $\Lambda$  es diagonal.

*Demostración.* La demostración de este teorema se estudia en un curso de Álgebra Lineal.  $\square$

**Teorema 2.16** (SVD). *Toda matriz  $A \in \mathbb{C}^{m \times n}$  admite una descomposición:*

$$A = U\Sigma V^*,$$

donde:

- $U \in \mathbb{C}^{m \times m}$  es unitaria (columnas = vectores singulares izquierdos),
- $V \in \mathbb{C}^{n \times n}$  es unitaria (columnas = vectores singulares derechos),
- $\Sigma \in \mathbb{R}^{m \times n}$  es diagonal con entradas no negativas  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{\min(m,n)} \geq 0$  (valores singulares).

*Demostración.* Consideremos la matriz  $A^*A \in \mathbb{C}^{n \times n}$ . Esta matriz es hermítica, pues:

$$(A^*A)^* = A^*(A^*)^* = A^*A,$$

y además es semidefinida positiva, ya que para todo  $x \in \mathbb{C}^n$ :

$$x^*(A^*A)x = (Ax)^*(Ax) = \|Ax\|_2^2 \geq 0.$$

Por el teorema espectral, existe una base ortonormal  $\{v_1, \dots, v_n\}$  de  $\mathbb{C}^n$  formada por autovectores de  $A^*A$ , con autovalores reales no negativos  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$ . Es decir:

$$A^*Av_j = \lambda_j v_j, \quad j = 1, \dots, n.$$

Sea  $V \in \mathbb{C}^{n \times n}$  la matriz unitaria cuyas columnas son estos autovectores:  $V = [v_1 \mid v_2 \mid \dots \mid v_n]$ . Entonces:

$$A^*A = V\Lambda V^*, \quad \text{donde } \Lambda = \text{diag}(\lambda_1, \dots, \lambda_n).$$

Definimos los **valores singulares** de  $A$  como:

$$\sigma_j = \sqrt{\lambda_j}, \quad j = 1, \dots, n.$$

Estos son no negativos y están ordenados:  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0$ .

Sea  $r = \text{rango}(A)$ . Observemos que  $\text{rango}(A) = \text{rango}(A^*A)$  (esto se sigue de que  $\ker(A) = \ker(A^*A)$ ). Por lo tanto, exactamente  $r$  de los autovalores  $\lambda_j$  son positivos, y los valores singulares satisfacen:

$$\sigma_1 \geq \cdots \geq \sigma_r > 0, \quad \sigma_{r+1} = \cdots = \sigma_n = 0.$$

Para  $j = 1, \dots, r$ , definimos:

$$u_j = \frac{1}{\sigma_j} A v_j.$$

Estos vectores son ortonormales. En efecto, para  $1 \leq i, j \leq r$ :

$$u_i^* u_j = \frac{1}{\sigma_i \sigma_j} (A v_i)^* (A v_j) = \frac{1}{\sigma_i \sigma_j} v_i^* A^* A v_j = \frac{1}{\sigma_i \sigma_j} v_i^* (\lambda_j v_j) = \frac{\lambda_j}{\sigma_i \sigma_j} v_i^* v_j.$$

Como  $\sigma_j^2 = \lambda_j$  y  $v_i^* v_j = \delta_{ij}$  (delta de Kronecker), obtenemos:

$$u_i^* u_j = \frac{\sigma_j^2}{\sigma_i \sigma_j} \delta_{ij} = \frac{\sigma_j}{\sigma_i} \delta_{ij} = \delta_{ij}.$$

Por lo tanto,  $\{u_1, \dots, u_r\}$  es un conjunto ortonormal en  $\mathbb{C}^m$ .

Completamos  $\{u_1, \dots, u_r\}$  a una base ortonormal  $\{u_1, \dots, u_m\}$  de  $\mathbb{C}^m$  (esto siempre es posible mediante el proceso de Gram-Schmidt aplicado a cualquier extensión de  $\{u_1, \dots, u_r\}$  a una base de  $\mathbb{C}^m$ ).

Sea  $U \in \mathbb{C}^{m \times m}$  la matriz unitaria cuyas columnas son estos vectores:  $U = [u_1 \mid u_2 \mid \cdots \mid u_m]$ .

Definimos  $\Sigma \in \mathbb{R}^{m \times n}$  como la matriz con entradas:

$$\Sigma_{ij} = \begin{cases} \sigma_i & \text{si } i = j \leq r, \\ 0 & \text{en caso contrario.} \end{cases}$$

Es decir,  $\Sigma$  tiene los valores singulares en su diagonal principal (hasta la posición  $\min(m, n)$ ) y ceros en el resto.

Ahora verificamos que  $A = U \Sigma V^*$ . Para ello, calculamos las columnas de ambas matrices. Para  $j = 1, \dots, n$ , la  $j$ -ésima columna de  $A$  es  $A v_j$ , mientras que la  $j$ -ésima columna de  $U \Sigma V^*$  es:

$$U \Sigma V^* v_j = U \Sigma e_j,$$

donde  $e_j$  es el  $j$ -ésimo vector canónico de  $\mathbb{C}^n$  (pues  $V^* v_j = e_j$  al ser  $v_j$  la  $j$ -ésima columna de  $V$ ).

Si  $j \leq r$ , entonces  $\Sigma e_j = \sigma_j e_j$  (el  $j$ -ésimo vector canónico de  $\mathbb{C}^m$  escalado por  $\sigma_j$ ), de donde:

$$U \Sigma e_j = \sigma_j U e_j = \sigma_j u_j = A v_j.$$

Si  $j > r$ , entonces  $\sigma_j = 0$ , así que  $\Sigma e_j = 0$ , y por lo tanto:

$$U \Sigma e_j = 0.$$

Pero también  $A v_j = 0$  en este caso, pues  $v_j \in \ker(A)$  (ya que  $A^* A v_j = \lambda_j v_j = 0$  implica  $\|A v_j\|^2 = v_j^* A^* A v_j = 0$ ).

Por lo tanto,  $A = U \Sigma V^*$ , lo que completa la demostración.  $\square$



### 2.4.1 Pseudoinversa de Moore-Penrose

**Definición 2.17** (Pseudoinversa de Moore-Penrose). Sea  $A \in \mathbb{C}^{m \times n}$  y sea

$$A = U\Sigma V^*, \quad \Sigma = \text{diag}(\sigma_1, \dots, \sigma_r, 0, \dots, 0), \quad \sigma_1 \geq \dots \geq \sigma_r > 0,$$

una SVD de  $A$ , con  $r = \text{rank}(A)$ . Se define

$$\Sigma^+ = \text{diag}\left(\frac{1}{\sigma_1}, \dots, \frac{1}{\sigma_r}, 0, \dots, 0\right), \quad A^+ := V\Sigma^+U^*.$$

La matriz  $A^+$  se llama **pseudoinversa de Moore-Penrose** de  $A$ .

**Teorema 2.18** (Pseudoinversa y cuadrados mínimos en el caso general). Sea  $A \in \mathbb{C}^{m \times n}$  (sin hipótesis de rango completo) y sea  $d \in \mathbb{C}^m$ . Entonces:

(i) El problema

$$\min_{x \in \mathbb{C}^n} \|Ax - d\|_2$$

siempre tiene solución.

(ii) El vector

$$x^\dagger := A^+d$$

es una solución de mínimos cuadrados y es la **única** solución de norma mínima.

(iii) El conjunto de todas las soluciones de mínimos cuadrados es

$$\{x^\dagger + z : z \in \ker(A)\}.$$

(iv) Si  $\text{rank}(A) = n$  (columnas linealmente independientes), entonces la solución es única y

$$A^+ = (A^*A)^{-1}A^*, \quad x^\dagger = (A^*A)^{-1}A^*d.$$

*Demostración.* Con la SVD, para  $y = V^*x$  y  $c = U^*d$ :

$$\|Ax - d\|_2 = \|\Sigma y - c\|_2^2 = \sum_{i=1}^r |\sigma_i y_i - c_i|^2 + \sum_{i=r+1}^m |c_i|^2.$$

El mínimo se obtiene imponiendo  $y_i = c_i/\sigma_i$  para  $i \leq r$ ; las componentes  $y_{r+1}, \dots, y_n$  no afectan el valor del residuo. Por lo tanto existe minimizador y el de norma mínima se obtiene tomando esas componentes libres iguales a 0:

$$y^\dagger = (c_1/\sigma_1, \dots, c_r/\sigma_r, 0, \dots, 0)^T = \Sigma^+c.$$

Volviendo a  $x$ :

$$x^\dagger = Vy^\dagger = V\Sigma^+U^*d = A^+d.$$

Si  $x$  es cualquier otro minimizador, coincide con  $x^\dagger$  en las primeras  $r$  componentes de  $y$  y difiere solo en componentes asociadas a valores singulares nulos; eso equivale a sumar un vector de  $\ker(A)$ .

Si  $\text{rank}(A) = n$ , entonces no hay componentes libres, la solución es única y además

$$A^*A = V\Sigma^2V^* \Rightarrow (A^*A)^{-1}A^* = V\Sigma^{-1}U^* = A^+.$$

□

**Lema 2.19** (Propiedades elementales de la pseudoinversa). Sea  $A \in \mathbb{C}^{m \times n}$  y sea  $A^+$  su pseudoinversa de Moore–Penrose. Entonces:

- (i)  $AA^+A = A$ .
- (ii)  $A^+AA^+ = A^+$ .
- (iii)  $(AA^+)^* = AA^+$ .
- (iv)  $(A^+A)^* = A^+A$ .

*Demostración.* Sea  $A = U\Sigma V^*$  una SVD de  $A$  con  $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r, 0, \dots, 0)$ , de modo que  $A^+ = V\Sigma^+U^*$ . Observemos primero que  $\Sigma^+$  es la matriz diagonal con entradas  $1/\sigma_i$  para  $i \leq r$  y 0 en el resto, de modo que

$$\Sigma\Sigma^+ = \Sigma^+\Sigma = \text{diag}(\underbrace{1, \dots, 1}_r, 0, \dots, 0).$$

En particular,  $\Sigma\Sigma^+$  y  $\Sigma^+\Sigma$  son matrices diagonales reales, por lo tanto  $(\Sigma\Sigma^+)^* = \Sigma\Sigma^+$  y  $(\Sigma^+\Sigma)^* = \Sigma^+\Sigma$ . Además,

$$\Sigma\Sigma^+\Sigma = \Sigma, \quad \Sigma^+\Sigma\Sigma^+ = \Sigma^+.$$

Con esto, las cuatro propiedades se verifican directamente:

- (i)  $AA^+A = (U\Sigma V^*)(V\Sigma^+U^*)(U\Sigma V^*) = U(\Sigma\Sigma^+\Sigma)V^* = U\Sigma V^* = A$ .
- (ii)  $A^+AA^+ = (V\Sigma^+U^*)(U\Sigma V^*)(V\Sigma^+U^*) = V(\Sigma^+\Sigma\Sigma^+)U^* = V\Sigma^+U^* = A^+$ .
- (iii)  $(AA^+)^* = (U\Sigma\Sigma^+U^*)^* = U(\Sigma\Sigma^+)^*U^* = U\Sigma\Sigma^+U^* = AA^+$ .
- (iv)  $(A^+A)^* = (V\Sigma^+\Sigma V^*)^* = V(\Sigma^+\Sigma)^*V^* = V\Sigma^+\Sigma V^* = A^+A$ .

□

**Lema 2.20** (Propiedades de la matriz *hat*). Sea  $A \in \mathbb{C}^{m \times n}$  y defina

$$H := AA^+ \in \mathbb{C}^{m \times m}.$$

Entonces:

- (i)  $H^* = H$  y  $H^2 = H$ .
- (ii)  $H$  es el proyector ortogonal sobre  $\text{Col}(A)$ .
- (iii) Para todo  $d \in \mathbb{C}^m$ , si  $\hat{x} = A^+d$ , entonces el ajuste es

$$\hat{d} = A\hat{x} = Hd.$$

- (iv) Si  $h_{ii}$  denota la diagonal de  $H$ , entonces  $0 \leq h_{ii} \leq 1$  para todo  $i$ .

*Demostración.* Por el lema anterior,

$$H^* = (AA^+)^* = AA^+ = H,$$

y también,

$$H^2 = (AA^+)(AA^+) = (AA^+A)A^+ = AA^+ = H,$$

porque  $AA^+A = A$ . Así,  $H$  es proyector hermítico, luego por la Proposición B.12 es la proyección ortogonal sobre su imagen. Como  $H = AA^+$ , se tiene  $\text{Im}(H) = \text{Col}(A)$ : en efecto,  $\text{Im}(AA^+) \subseteq \text{Col}(A)$  porque  $AA^+y$  es combinación lineal de columnas de  $A$ , y recíprocamente si  $z \in \text{Col}(A)$ ,  $z = Ax$  para algún  $x$ , entonces  $z = AA^+Ax \in \text{Im}(AA^+)$  (usando  $AA^+A = A$ ). También,

$$\hat{d} = A\hat{x} = A(A^+d) = Hd.$$

Finalmente, para el vector canónico  $e_i$ ,

$$h_{ii} = \langle e_i, He_i \rangle.$$

Como  $H$  es proyección ortogonal,  $e_i - He_i \perp He_i$ , y por lo tanto

$$h_{ii} = \langle He_i + (e_i - He_i), He_i \rangle = \langle He_i, He_i \rangle = \|He_i\|_2^2 \geq 0.$$

Además, aplicando el Teorema B.7 a la descomposición ortogonal  $e_i = He_i + (e_i - He_i)$ ,

$$\|e_i\|_2^2 = \|He_i\|_2^2 + \|e_i - He_i\|_2^2 \geq \|He_i\|_2^2.$$

Como  $\|e_i\|_2 = 1$ , concluimos

$$h_{ii} = \|He_i\|_2^2 \leq 1.$$

□

### 2.4.2 Condicionamiento y problemas mal condicionados

El condicionamiento mide la sensibilidad de la solución de un sistema lineal  $Ax = b$  ante perturbaciones. Para cuantificar esto rigurosamente, nos restringiremos a la **norma 2** (o norma espectral), que está íntimamente ligada a la SVD.

**Definición 2.21** (Norma 2 y Número de Condición). Sea  $A \in \mathbb{C}^{m \times n}$ . La **norma 2** de un vector  $x \in \mathbb{C}^n$  es  $\|x\|_2 = \sqrt{x^*x}$ . La norma matricial inducida (o norma espectral) se define como:

$$\|A\|_2 = \sup_{x \in \mathbb{C}^n, x \neq 0} \frac{\|Ax\|_2}{\|x\|_2}.$$

El **número de condición espectral** de una matriz invertible  $A \in \mathbb{C}^{n \times n}$  se define como:

$$\kappa_2(A) = \|A\|_2 \|A^{-1}\|_2.$$

### 2.4.3 Propiedades de la norma de matrices

**Definición 2.22** (Radio espectral). *El **radio espectral** de una matriz  $A \in \mathbb{C}^{n \times n}$  es:*

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i(A)|,$$

donde  $\lambda_1, \dots, \lambda_n$  son los autovalores de  $A$ .

**Teorema 2.23** (Relación entre radio espectral y norma). *Para toda norma matricial inducida  $\|\cdot\|$  y toda matriz  $A \in \mathbb{C}^{n \times n}$ :*

$$\rho(A) \leq \|A\|.$$

*Demostración.* Sea  $\lambda$  un autovalor de  $A$  con autovector  $v$ , es decir,  $Av = \lambda v$  con  $v \neq 0$ . Entonces:

$$|\lambda| \|v\| = \|\lambda v\| = \|Av\| \leq \|A\| \|v\|.$$

Dividiendo por  $\|v\| > 0$ :  $|\lambda| \leq \|A\|$ . Como esto vale para todo autovalor,  $\rho(A) \leq \|A\|$ .  $\square$

**Lema 2.24** (Acotación de una media ponderada). *Sean  $\lambda_1, \dots, \lambda_n \in \mathbb{R}$ , y sean  $\lambda_{\min} := \min_i \lambda_i$ ,  $\lambda_{\max} := \max_i \lambda_i$ . Si  $\alpha_1, \dots, \alpha_n \geq 0$  y  $\sum_{i=1}^n \alpha_i = 1$ , entonces*

$$\lambda_{\min} \leq \sum_{i=1}^n \alpha_i \lambda_i \leq \lambda_{\max}.$$

*Ambas cotas se alcanzan eligiendo  $\alpha_k = 1$  para el índice  $k$  que realiza el mínimo o el máximo respectivamente.*

*Demostración.* Como  $\lambda_{\min} \leq \lambda_i \leq \lambda_{\max}$  para todo  $i$ , multiplicando por  $\alpha_i \geq 0$  y sumando sobre  $i$  se obtiene la doble desigualdad. La igualdad en cada extremo es inmediata.  $\square$

**Teorema 2.25.** *La norma espectral de  $A$  es igual a su mayor valor singular:  $\|A\|_2 = \sigma_1(A)$ .*

*Demostración.* Usando la SVD  $A = U\Sigma V^*$ , y recordando que las matrices unitarias preservan la norma 2 (es decir,  $\|Ux\|_2 = \|x\|_2$  para todo  $x$ ), tenemos:

$$\|Ax\|_2 = \|U\Sigma V^*x\|_2 = \|\Sigma(V^*x)\|_2.$$

Hacemos el cambio de variable  $y = V^*x$ . Como  $V$  es unitaria,  $\|y\|_2 = \|x\|_2$ . Entonces maximizar  $\frac{\|Ax\|_2}{\|x\|_2}$  es equivalente a maximizar  $\frac{\|\Sigma y\|_2}{\|y\|_2}$  sobre  $y \neq 0$ .

$$\frac{\|\Sigma y\|_2^2}{\|y\|_2^2} = \frac{\sum_{i=1}^n \sigma_i^2 |y_i|^2}{\sum_{i=1}^n |y_i|^2}.$$

Como  $y \neq 0$ , definimos

$$\alpha_i := \frac{|y_i|^2}{\sum_{j=1}^n |y_j|^2}, \quad i = 1, \dots, n.$$

Entonces  $\alpha_i \geq 0$  y  $\sum_{i=1}^n \alpha_i = 1$ . Aplicando el lema anterior con  $\lambda_i = \sigma_i^2$  y usando que  $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$ , obtenemos

$$\frac{\|\Sigma y\|_2^2}{\|y\|_2^2} = \sum_{i=1}^n \alpha_i \sigma_i^2 \leq \sum_{i=1}^n \alpha_i \sigma_1^2 = \sigma_1^2.$$

Así, para todo  $y \neq 0$ , se cumple  $\frac{\|\Sigma y\|_2^2}{\|y\|_2^2} \leq \sigma_1^2$ . Además, tomando  $y = e_1$  se obtiene la igualdad:

$$\frac{\|\Sigma e_1\|_2^2}{\|e_1\|_2^2} = \sigma_1^2.$$

Luego el máximo es  $\sigma_1^2$ . Tomando raíz cuadrada, obtenemos  $\|A\|_2 = \sigma_1$ .  $\square$

**Lema 2.26** (Norma de la inversa y valor singular mínimo). *Sea  $A \in \mathbb{C}^{n \times n}$  inversible con valores singulares  $\sigma_1 \geq \dots \geq \sigma_n > 0$ . Entonces*

$$\|A^{-1}\|_2 = \frac{1}{\sigma_n},$$

y en particular

$$\sigma_n = \min_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2}.$$

*Demostración.* Sea  $A = U\Sigma V^*$  la SVD, con  $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_n)$  y  $\sigma_n > 0$ . Entonces

$$A^{-1} = (U\Sigma V^*)^{-1} = V\Sigma^{-1}U^* = V \text{diag}(1/\sigma_1, \dots, 1/\sigma_n)U^*.$$

Los valores singulares de  $A^{-1}$  son  $1/\sigma_n \geq \dots \geq 1/\sigma_1 > 0$ ; aplicando el teorema anterior a  $A^{-1}$  se obtiene  $\|A^{-1}\|_2 = 1/\sigma_n$ . La fórmula variacional para  $\sigma_n$  se deduce del mismo argumento: el mínimo de  $\|\Sigma y\|_2/\|y\|_2$  se alcanza en  $y = e_n$  y vale  $\sigma_n$ .  $\square$

Combinando el teorema anterior con el lema se obtiene la fórmula definitiva para el número de condición:

$$\kappa_2(A) = \|A\|_2 \|A^{-1}\|_2 = \frac{\sigma_1}{\sigma_n}.$$

**Observación 2.27.** *El supremo en la definición 2.21 se toma sobre vectores complejos, lo cual es natural ya que  $A \in \mathbb{C}^{m \times n}$ . Para matrices reales  $A \in \mathbb{R}^{m \times n}$ , el supremo sobre  $\mathbb{C}^n$  coincide con el supremo sobre  $\mathbb{R}^n$ : dado  $x = u + iv \in \mathbb{C}^n$ ,*

$$\|Ax\|_2^2 = \|Au\|_2^2 + \|Av\|_2^2 \leq \sigma_1^2(\|u\|_2^2 + \|v\|_2^2) = \sigma_1^2\|x\|_2^2,$$

y la cota se alcanza en el vector singular derecho real  $v_1$ . En el caso complejo esta coincidencia no se da en general (los vectores singulares de una matriz compleja son complejos), de modo que restringir el supremo a  $\mathbb{R}^n$  podría dar un valor estrictamente menor.

**Teorema 2.28** (Cota de error relativo para  $Ax = b$  en norma 2). *Sea  $A \in \mathbb{C}^{n \times n}$  inversible, y sea  $x = A^{-1}b$  con  $b \neq 0$ . Para una perturbación  $\delta b \in \mathbb{C}^n$ , defina*

$$x + \delta x := A^{-1}(b + \delta b),$$

*equivalentemente  $A\delta x = \delta b$ . Entonces*

$$\frac{\|\delta x\|_2}{\|x\|_2} \leq \kappa_2(A) \frac{\|\delta b\|_2}{\|b\|_2}, \quad \kappa_2(A) = \|A\|_2 \|A^{-1}\|_2.$$

*Demostración.* Sea  $A = U\Sigma V^*$  su SVD, con  $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_n)$ ,  $\sigma_1 \geq \dots \geq \sigma_n > 0$ .

Como  $\delta x = A^{-1}\delta b$ , se tiene

$$\delta x = \sum_{i=1}^n \frac{u_i^* \delta b}{\sigma_i} v_i,$$

de modo que, aplicando Parseval (Teorema B.10, ecuación (B.2)) en las bases ortonormales  $\{v_i\}$  y  $\{u_i\}$ ,

$$\|\delta x\|_2^2 = \sum_{i=1}^n \frac{|u_i^* \delta b|^2}{\sigma_i^2} \leq \frac{1}{\sigma_n^2} \sum_{i=1}^n |u_i^* \delta b|^2 = \frac{1}{\sigma_n^2} \|\delta b\|_2^2.$$

Luego

$$\|\delta x\|_2 \leq \frac{1}{\sigma_n} \|\delta b\|_2.$$

Además, de  $b = Ax = U\Sigma V^*x$  se obtiene

$$b = \sum_{i=1}^n \sigma_i (v_i^* x) u_i,$$

y nuevamente por Parseval (Teorema B.10),

$$\|b\|_2^2 = \sum_{i=1}^n \sigma_i^2 |v_i^* x|^2 \leq \sigma_1^2 \sum_{i=1}^n |v_i^* x|^2 = \sigma_1^2 \|x\|_2^2.$$

Así,

$$\|x\|_2 \geq \frac{\|b\|_2}{\sigma_1}.$$

Combinando ambas cotas:

$$\frac{\|\delta x\|_2}{\|x\|_2} \leq \frac{(1/\sigma_n) \|\delta b\|_2}{(1/\sigma_1) \|b\|_2} = \frac{\sigma_1}{\sigma_n} \frac{\|\delta b\|_2}{\|b\|_2} = \kappa_2(A) \frac{\|\delta b\|_2}{\|b\|_2}.$$

□

Esta cota es alcanzable (es decir, es óptima). El peor caso ocurre cuando  $b$  está alineado con la dirección de máxima amplificación ( $u_1$ ) y el error  $\delta b$  está alineado con la dirección de mínima amplificación ( $u_n$ ), que corresponde a la máxima amplificación de la inversa. En ese caso, el error relativo en la solución se amplifica exactamente por un factor  $\kappa_2(A)$ .

**Ejemplo 2.29** (Optimalidad de la cota). *Consideremos  $A = \text{diag}(\sigma_1, \sigma_2)$  con  $\sigma_1 > \sigma_2 > 0$  (aquí  $A = U\Sigma V^*$  con  $U = V = I$ ). Tomamos  $b = e_1 = (1, 0)^T$  (alineado con la dirección de  $\sigma_1$ ) y  $\delta b = \epsilon e_2$  (alineado con la dirección de  $\sigma_2$ ). Entonces:*

$$x = A^{-1}b = \left(\frac{1}{\sigma_1}, 0\right)^T, \quad \delta x = A^{-1}\delta b = \left(0, \frac{\epsilon}{\sigma_2}\right)^T.$$

*El error relativo resulta:*

$$\frac{\|\delta x\|_2/\|x\|_2}{\|\delta b\|_2/\|b\|_2} = \frac{\epsilon/\sigma_2}{1/\sigma_1} \cdot \frac{1}{\epsilon} = \frac{\sigma_1}{\sigma_2} = \kappa_2(A).$$

*Esto confirma que la cota se alcanza con igualdad.*

Un problema es **mal condicionado** si  $\kappa_2(A) \gg 1$ , lo cual ocurre cuando  $\sigma_n \approx 0$ . Esto es consistente con la expansión de la solución en términos de la SVD, donde los términos asociados a  $\sigma_n$  pequeño dominan el error.

**Ejemplo 2.30** (Matriz de Hilbert). La matriz de Hilbert  $H_n$  con entradas  $H_{ij} = \frac{1}{i+j-1}$  está extremadamente mal condicionada. Para  $n = 10$ :

$$\kappa_2(H_{10}) \approx 1.6 \times 10^{13}.$$

Esto significa que se pierden aproximadamente 13 dígitos de precisión al resolver sistemas lineales con  $H_{10}$ , haciéndolo prácticamente imposible usando aritmética de precisión doble (que tiene solo 16 dígitos). El mal condicionamiento no depende de la norma: se puede verificar que  $\kappa_1(H_{10})$  y  $\kappa_\infty(H_{10})$  tienen el mismo orden de magnitud.

#### 2.4.4 Regularización de Tikhonov

Cuando nos enfrentamos a un problema mal condicionado (o incluso singular, donde  $\sigma_n = 0$ ), la solución directa por mínimos cuadrados o inversión es inestable. Para obtener una solución útil, se utiliza la **regularización**, que impone restricciones adicionales a la solución (como que su norma no sea demasiado grande).

La **regularización de Tikhonov** reemplaza el problema de mínimos cuadrados original  $\min_x \|Ax - b\|_2^2$  por un problema penalizado:

$$\min_x (\|Ax - b\|_2^2 + \lambda^2 \|x\|_2^2),$$

donde  $\lambda > 0$  es un parámetro de regularización que controla el balance entre el ajuste a los datos y la norma de la solución.

Utilizando la SVD de  $A = U\Sigma V^*$ , podemos encontrar una expresión explícita para la solución regularizada  $x_\lambda$ .

Para ver por qué, observemos que minimizar el funcional  $J(x) = \|Ax - b\|_2^2 + \lambda^2 \|x\|_2^2$  es equivalente a resolver un problema de mínimos cuadrados extendido. Definimos la matriz aumentada  $\tilde{A}$  y el vector aumentado  $\tilde{b}$  como:

$$\tilde{A} = \begin{pmatrix} A \\ \lambda I \end{pmatrix}, \quad \tilde{b} = \begin{pmatrix} b \\ 0 \end{pmatrix}.$$

Entonces:

$$\|\tilde{A}x - \tilde{b}\|_2^2 = \left\| \begin{pmatrix} Ax - b \\ \lambda x \end{pmatrix} \right\|_2^2 = \|Ax - b\|_2^2 + \|\lambda x\|_2^2 = J(x).$$

La solución de mínimos cuadrados para el sistema  $\tilde{A}x = \tilde{b}$  está dada por las ecuaciones normales  $\tilde{A}^* \tilde{A}x = \tilde{A}^* \tilde{b}$ . Calculando los productos:

$$\tilde{A}^* \tilde{A} = (A^* \quad \lambda I) \begin{pmatrix} A \\ \lambda I \end{pmatrix} = A^* A + \lambda^2 I,$$

$$\tilde{A}^* \tilde{b} = (A^* \quad \lambda I) \begin{pmatrix} b \\ 0 \end{pmatrix} = A^* b.$$

Por lo tanto, el problema es equivalente a resolver el sistema de ecuaciones normales regularizado:

$$(A^*A + \lambda^2 I)x = A^*b.$$

Sustituyendo  $A^*A = V\Sigma^2V^*$ , tenemos:

$$(V\Sigma^2V^* + \lambda^2 VIV^*)x = V(\Sigma^2 + \lambda^2 I)V^*x = V\Sigma U^*b.$$

Despejando  $x$ :

$$x_\lambda = V(\Sigma^2 + \lambda^2 I)^{-1}\Sigma U^*b.$$

En términos de las componentes, la solución es:

$$x_\lambda = \sum_{i=1}^n \frac{\sigma_i}{\sigma_i^2 + \lambda^2} (u_i^* b) v_i.$$

Comparemos esto con la solución de mínimos cuadrados estándar (para  $A$  invertible):

$$x_{LS} = \sum_{i=1}^n \frac{1}{\sigma_i} (u_i^* b) v_i.$$

Los términos  $\frac{\sigma_i}{\sigma_i^2 + \lambda^2}$  actúan como un filtro. Definimos los **factores de filtro** como  $f_i = \frac{\sigma_i}{\sigma_i^2 + \lambda^2}$ :

- Si  $\sigma_i \gg \lambda$ , entonces  $\sigma_i^2 + \lambda^2 \approx \sigma_i^2$ , por lo que el término se comporta como  $1/\sigma_i$  (la solución original).
- Si  $\sigma_i \ll \lambda$ , entonces  $\sigma_i^2 + \lambda^2 \approx \lambda^2$ , y el término se comporta como  $\sigma_i/\lambda^2 \approx 0$ .

De esta forma, la regularización de Tikhonov “apaga” suavemente las componentes asociadas a valores singulares pequeños (que son las que causan inestabilidad por ruido), a costa de introducir un pequeño sesgo en la solución exacta.

#### 2.4.5 Aproximación de bajo rango (Teorema de Eckart-Young)

Una de las aplicaciones más potentes de la SVD es la capacidad de aproximar una matriz por otra de rango menor de manera óptima.

**Teorema 2.31** (Eckart-Young-Mirsky). *Sea  $A \in \mathbb{C}^{m \times n}$  con descomposición en valores singulares  $A = U\Sigma V^*$ , donde  $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_p)$  con  $p = \min(m, n)$ . Para cualquier  $k < p$ , definimos la matriz truncada  $A_k$  como:*

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^* = U \Sigma_k V^*,$$

donde  $\Sigma_k$  es igual a  $\Sigma$  pero con  $\sigma_{k+1} = \dots = \sigma_p = 0$ .

Entonces,  $A_k$  es la mejor aproximación de rango  $k$  a  $A$  en la norma espectral (norma 2) y en la norma de Frobenius. Es decir:

$$1. \|A - A_k\|_2 = \min_{\text{rango}(B) \leq k} \|A - B\|_2 = \sigma_{k+1}.$$



$$2. \|A - A_k\|_F = \min_{\text{rango}(B) \leq k} \|A - B\|_F = \sqrt{\sum_{j=k+1}^p \sigma_j^2}.$$

*Demostración.* Demostraremos el caso de la norma espectral (norma 2).

Primero, es claro que  $\text{rango}(A_k) = k$  y que:

$$A - A_k = \sum_{i=k+1}^p \sigma_i u_i v_i^*.$$

La norma 2 de esta matriz es su mayor valor singular, que es  $\sigma_{k+1}$ . Por lo tanto,  $\|A - A_k\|_2 = \sigma_{k+1}$ .

Ahora debemos probar que para cualquier  $B$  con  $\text{rango}(B) \leq k$ , se cumple  $\|A - B\|_2 \geq \sigma_{k+1}$ . La idea es construir un vector unitario  $z$  que esté en  $\ker(B)$  (para poder eliminar  $B$ ) y en  $W := \text{span}\{v_1, \dots, v_{k+1}\}$  (para acotar  $\|Az\|_2$  por abajo).

Sea  $W$  como arriba, con  $\dim(W) = k + 1$ . Como  $\dim(\ker B) = n - \text{rango}(B) \geq n - k$  (Teorema A.20), el Corolario A.19 de la Fórmula de Grassmann da:

$$\dim(W \cap \ker B) \geq (k + 1) + (n - k) - n = 1,$$

así que existe  $z \in W \cap \ker(B)$  unitario. Escribimos  $z = \sum_{i=1}^{k+1} c_i v_i$  con  $\sum |c_i|^2 = 1$ . Entonces:

$$\|A - B\|_2 \geq \|(A - B)z\|_2 = \|Az\|_2 = \left\| \sum_{i=1}^{k+1} c_i \sigma_i u_i \right\|_2,$$

y aplicando la cota inferior del Lema 2.24 con  $\lambda_i = \sigma_i^2$  (el mínimo de  $\sigma_1^2, \dots, \sigma_{k+1}^2$  es  $\sigma_{k+1}^2$ ),

$$\|Az\|_2^2 = \sum_{i=1}^{k+1} |c_i|^2 \sigma_i^2 \geq \sigma_{k+1}^2.$$

Luego  $\|A - B\|_2 \geq \sigma_{k+1}$ , y como  $B$  era arbitrario,  $A_k$  es óptima en norma 2.  $\square$

## 2.4.6 Norma de Frobenius y propiedades de la traza

Además de la norma espectral  $\|A\|_2$ , otra norma matricial de uso frecuente es la norma de Frobenius.

**Definición 2.32** (Norma de Frobenius). *La **norma de Frobenius** de una matriz  $A \in \mathbb{C}^{m \times n}$  se define como:*

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2} = \sqrt{\text{tr}(A^* A)},$$

donde  $\text{tr}(B) = \sum_i b_{ii}$  denota la traza de una matriz cuadrada.

**Lema 2.33** (Propiedades de la traza). *Sean  $A \in \mathbb{C}^{m \times n}$  y  $B \in \mathbb{C}^{n \times m}$ . Entonces:*

1.  $\text{tr}(AB) = \text{tr}(BA)$ .
2.  $\|A\|_F^2 = \sum_{i=1}^{\min(m,n)} \sigma_i^2$  (donde  $\sigma_i$  son los valores singulares de  $A$ ).

3. Las matrices unitarias preservan la norma de Frobenius:  $\|UAV\|_F = \|A\|_F$  para  $U, V$  unitarias.

*Demostración.* (1)  $\text{tr}(AB) = \sum_{i=1}^m \sum_{k=1}^n a_{ik} b_{ki} = \sum_{k=1}^n \sum_{i=1}^m b_{ki} a_{ik} = \text{tr}(BA)$ .

(2) Si  $A = U\Sigma V^*$ , entonces  $A^*A = V\Sigma^2 V^*$  y  $\text{tr}(A^*A) = \text{tr}(V\Sigma^2 V^*) = \text{tr}(\Sigma^2 V^*V) = \text{tr}(\Sigma^2) = \sum \sigma_i^2$ .

(3)  $\|UAV\|_F^2 = \text{tr}(V^*A^*U^*UAV) = \text{tr}(V^*A^*AV) = \text{tr}(A^*AVV^*) = \text{tr}(A^*A) = \|A\|_F^2$ .  $\square$

## 2.5 Métodos iterativos para autovalores

La estrategia principal de muchos algoritmos para calcular autovalores consiste en transformar la matriz original en una forma más simple (diagonal o triangular) preservando su espectro. Esto se justifica por el hecho de que **las relaciones de similitud entre matrices no alteran los autovalores**: si  $B = S^{-1}AS$ , entonces  $\det(B - \lambda I) = \det(A - \lambda I)$ .

### 2.5.1 Teorema de los círculos de Gershgorin

El Teorema de Gershgorin localiza los autovalores de una matriz a partir de sus entradas, sin calcularlos.

**Teorema 2.34** (Teorema de los círculos de Gershgorin). *Sea  $A \in \mathbb{C}^{n \times n}$ . Todos los autovalores de  $A$  se encuentran en la unión de los  $n$  discos de Gershgorin:*

$$\sigma(A) \subseteq \bigcup_{i=1}^n D_i, \quad D_i = \{z \in \mathbb{C} : |z - a_{ii}| \leq R_i\}, \quad R_i = \sum_{j \neq i} |a_{ij}|.$$

*Demostración.* Sea  $\lambda$  un autovalor de  $A$  con autovector  $x$ , y sea  $x_i$  la componente de mayor módulo ( $|x_i| \geq |x_j|$  para todo  $j$ , con  $|x_i| > 0$ ). La  $i$ -ésima ecuación de  $Ax = \lambda x$  da:

$$(\lambda - a_{ii})x_i = \sum_{j \neq i} a_{ij}x_j.$$

Tomando valor absoluto y dividiendo por  $|x_i|$ :

$$|\lambda - a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \frac{|x_j|}{|x_i|} \leq \sum_{j \neq i} |a_{ij}| = R_i.$$

$\square$

**Observación 2.35.** Como  $\sigma(A) = \sigma(A^T)$ , también se puede aplicar el teorema usando sumas por columnas. La intersección de las regiones obtenidas por filas y por columnas da una localización más precisa.

## 2.5.2 El método de la potencia

El método de la potencia calcula el autovalor dominante de una matriz.

**Algoritmo (Método de la potencia):** Sea  $A \in \mathbb{C}^{n \times n}$  y  $v_0 \in \mathbb{C}^n$  no nulo. Para  $k = 0, 1, 2, \dots$ :

1.  $w_{k+1} = Av_k$
2.  $v_{k+1} = w_{k+1} / \|w_{k+1}\|_2$  (normalización)
3.  $\lambda_k = v_k^* Av_k$  (cociente de Rayleigh)

**Definición 2.36** (Cociente de Rayleigh). Dada  $A \in \mathbb{C}^{n \times n}$  y  $x \in \mathbb{C}^n$  no nulo, el **cociente de Rayleigh** de  $x$  es

$$\rho(x) = \frac{x^* Ax}{x^* x}.$$

Si  $x$  es autovector de  $A$  con autovalor  $\lambda$ , entonces  $\rho(x) = \lambda$ .

**Teorema 2.37** (Convergencia del método de la potencia). Sea  $A \in \mathbb{C}^{n \times n}$  diagonalizable con autovalores  $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$  y autovectores  $u_1, \dots, u_n$  que forman una base.

Si  $v_0 = \sum_{j=1}^n \alpha_j u_j$  con  $\alpha_1 \neq 0$ , entonces  $v_k \rightarrow \pm u_1$ ,  $\lambda_k \rightarrow \lambda_1$ , con tasa de convergencia  $O(|\lambda_2/\lambda_1|^k)$ .

**Observación 2.38.** Si  $|\lambda_1|$  está bien separado de  $|\lambda_2|$ , el método converge rápidamente. Si  $|\lambda_1| \approx |\lambda_2|$ , la convergencia es lenta. Si hay múltiples autovalores con la misma magnitud máxima, el método puede no converger.

## 2.5.3 El método QR

El **método QR** es un algoritmo iterativo para calcular *todos* los autovalores de una matriz.

**Algoritmo (Método QR):** Sea  $A_0 = A \in \mathbb{C}^{n \times n}$ . Para  $k = 0, 1, 2, \dots$ :

1. Factorizar  $A_k = Q_k R_k$  (factorización QR)
2. Formar  $A_{k+1} = R_k Q_k$

Observemos que  $A_{k+1} = R_k Q_k = Q_k^* (Q_k R_k) Q_k = Q_k^* A_k Q_k$ , de modo que todas las matrices  $A_k$  son unitariamente semejantes y comparten los mismos autovalores.

**Definición 2.39** (Matrices QR acumuladas). Definimos las matrices acumuladas

$$\bar{Q}_k = Q_0 Q_1 \cdots Q_{k-1}, \quad \bar{R}_k = R_{k-1} \cdots R_1 R_0.$$

**Teorema 2.40** (Convergencia del método QR). Si  $A$  es diagonalizable con  $|\lambda_1| > |\lambda_2| > \dots > |\lambda_n|$ , entonces  $A_k$  converge a una matriz triangular superior cuyos elementos diagonales son los autovalores de  $A$ .

La convergencia del elemento  $(i, j)$  con  $i > j$  es  $O(|\lambda_j/\lambda_i|^k)$ .

**Observación 2.41.** El método QR puede interpretarse como la aplicación simultánea del método de la potencia a múltiples vectores ortogonales: la factorización QR de  $A^k = \bar{Q}_k \bar{R}_k$  ortogonaliza las columnas de  $A^k$ , que convergen a los autovectores de  $A$ .

## 2.5.4 Matriz compañera y raíces de polinomios

**Definición 2.42** (Matriz compañera). Dado un polinomio mónico  $p(\lambda) = \lambda^n + a_{n-1}\lambda^{n-1} + \dots + a_0$ , su **matriz compañera** es:

$$C = \begin{pmatrix} 0 & 0 & \cdots & 0 & -a_0 \\ 1 & 0 & \cdots & 0 & -a_1 \\ 0 & 1 & \cdots & 0 & -a_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & -a_{n-1} \end{pmatrix}.$$

El polinomio característico de  $C$  es  $\det(C - \lambda I) = (-1)^n p(\lambda)$ , de modo que los autovalores de  $C$  son las raíces de  $p$ . Esto permite calcular raíces de polinomios aplicando el método QR a  $C$ .

## 2.6 Métodos iterativos para sistemas lineales

Cuando el sistema  $Ax = b$  es grande y la matriz  $A$  es rala (tiene muchos ceros), los métodos directos como LU pueden ser ineficientes. Los **métodos iterativos** construyen una sucesión  $\{x^{(k)}\}$  que converge a la solución.

### 2.6.1 Métodos estacionarios y convergencia

**Definición 2.43** (Método iterativo estacionario). Un **método iterativo estacionario** para resolver  $Ax = b$  tiene la forma

$$x^{(k+1)} = Gx^{(k)} + c,$$

donde  $G \in \mathbb{C}^{n \times n}$  es la **matriz de iteración** (que no depende de  $k$ ) y  $c$  es un vector fijo. Si la solución exacta  $x^*$  satisface  $x^* = Gx^* + c$ , el error  $e^{(k)} = x^{(k)} - x^*$  cumple

$$e^{(k)} = G^k e^{(0)}.$$

**Observación 2.44.** Se puede probar que  $G^k \rightarrow 0$  (y por lo tanto el método converge para todo  $x^{(0)}$ ) si y solo si  $\rho(G) < 1$  (véase la definición de radio espectral en el Teorema 2.23). Además, como  $\rho(G) \leq \|G\|$  para toda norma inducida, una condición suficiente práctica es  $\|G\| < 1$ .

Para definir los métodos concretos, descomponemos  $A$  como

$$A = D + L + U,$$

donde  $D$  es la diagonal de  $A$ ,  $L$  es la parte triangular inferior estricta y  $U$  es la parte triangular superior estricta.

**Definición 2.45** (Diagonal dominancia estricta). Una matriz  $A \in \mathbb{C}^{n \times n}$  es **estrictamente diagonal dominante por filas** si

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}|, \quad i = 1, \dots, n.$$

### 2.6.2 Método de Jacobi

**Definición 2.46** (Iteración de Jacobi). *El **método de Jacobi** para  $Ax = b$  (con  $a_{ii} \neq 0$  para todo  $i$ ) es el método estacionario con*

$$x^{(k+1)} = D^{-1}(b - (L + U)x^{(k)}).$$

La matriz de iteración es  $G_J = -D^{-1}(L + U) = I - D^{-1}A$ .

Componente a componente, cada iteración actualiza:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j \neq i} a_{ij}x_j^{(k)} \right), \quad i = 1, \dots, n.$$

### 2.6.3 Método de Gauss-Seidel

**Definición 2.47** (Iteración de Gauss-Seidel). *El **método de Gauss-Seidel** para  $Ax = b$  es el método estacionario*

$$(D + L)x^{(k+1)} = b - Ux^{(k)},$$

es decir,  $x^{(k+1)} = (D + L)^{-1}(b - Ux^{(k)})$ . La matriz de iteración es  $G_{GS} = -(D + L)^{-1}U$ .

La diferencia con Jacobi es que Gauss-Seidel usa los valores *ya actualizados* de  $x^{(k+1)}$  a medida que están disponibles:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j < i} a_{ij}x_j^{(k+1)} - \sum_{j > i} a_{ij}x_j^{(k)} \right).$$

## Chapter 3

# Interpolación

El objetivo de la interpolación polinomial es reconstruir un polinomio a partir de sus valores en ciertos puntos. Aunque el problema puede plantearse de forma elemental, su estructura matemática conecta áreas dispares: análisis de Fourier, integración numérica y criptografía moderna.

### 3.1 Existencia y unicidad del interpolante

Sea  $\mathbb{F}$  un cuerpo ( $\mathbb{R}$ ,  $\mathbb{C}$ ,  $\mathbb{Z}_p$ , etc.) y denotemos  $\mathcal{P}_n(\mathbb{F})$  al espacio vectorial de polinomios de grado  $\leq n$  con coeficientes en  $\mathbb{F}$ . Una base es la **base monomial**  $\{1, x, \dots, x^n\}$ , de modo que  $\dim \mathcal{P}_n = n + 1$ .

**Definición 3.1** (Problema de interpolación). *Dados  $n + 1$  nodos distintos  $x_0, \dots, x_n \in \mathbb{F}$  y valores  $y_0, \dots, y_n \in \mathbb{F}$ , busquemos  $p \in \mathcal{P}_n$  tal que  $p(x_i) = y_i$  para  $i = 0, \dots, n$ .*

**Definición 3.2** (Operador de evaluación). *Dados  $n + 1$  nodos distintos  $x_0, \dots, x_n \in \mathbb{F}$ , el **operador de evaluación** es la transformación lineal*

$$\Phi: \mathcal{P}_n \longrightarrow \mathbb{F}^{n+1}, \quad \Phi(p) = (p(x_0), \dots, p(x_n)).$$

La linealidad de  $\Phi$  es inmediata: evaluar una combinación lineal de polinomios en un punto da la misma combinación lineal de los valores. El problema de interpolación es, precisamente, resolver la ecuación  $\Phi(p) = y$  dado  $y = (y_0, \dots, y_n) \in \mathbb{F}^{n+1}$ ; dicho de otro modo, interpolar equivale a calcular  $\Phi^{-1}(y)$ .

**Teorema 3.3** (Existencia y unicidad). *Si los nodos  $x_0, \dots, x_n$  son distintos,  $\Phi$  es un isomorfismo. En particular, para cualquier vector de valores  $y \in \mathbb{F}^{n+1}$  existe un único  $p \in \mathcal{P}_n$  tal que  $p(x_i) = y_i$  para  $i = 0, \dots, n$ .*

*Demostración.* Puesto que  $\dim \mathcal{P}_n = n + 1 = \dim \mathbb{F}^{n+1}$ , el teorema rango-nulidad garantiza que  $\Phi$  es inyectiva si y solo si es sobreyectiva, por lo que basta verificar  $\ker \Phi = \{0\}$ .

Sea  $p \in \ker \Phi$ , es decir,  $p(x_i) = 0$  para  $i = 0, \dots, n$ . Un polinomio no nulo de grado  $\leq n$  tiene a lo sumo  $n$  raíces (Teorema A.21, Apéndice A); como  $p$  posee  $n + 1$  raíces distintas, se concluye  $p \equiv 0$ . Por tanto  $\ker \Phi = \{0\}$  y  $\Phi$  es un isomorfismo.  $\square$

### 3.1.1 La matriz de Vandermonde

Si escribimos  $p(x) = \sum_{k=0}^n a_k x^k$  en la base monomial, las condiciones  $p(x_i) = y_i$  se traducen en el sistema  $Va = y$  con la **matriz de Vandermonde**

$$V = \begin{pmatrix} 1 & x_0 & x_0^2 & \cdots & x_0^n \\ 1 & x_1 & x_1^2 & \cdots & x_1^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^n \end{pmatrix}, \quad \det(V) = \prod_{0 \leq i < j \leq n} (x_j - x_i) \neq 0.$$

Así, la existencia y unicidad del interpolante se reducen a la inversibilidad de  $V$ .

**Proposición 3.4** (Mal condicionamiento de Vandermonde). *Para cualquier elección de  $n + 1$  nodos distintos  $x_0, \dots, x_n \in [-1, 1]$ , la matriz de Vandermonde  $V$  satisface*

$$\kappa_2(V) \geq \frac{2^{\lfloor n/2 \rfloor}}{\sqrt{n+1}}.$$

En particular,  $\kappa_2(V)$  crece al menos exponencialmente con  $n$ , lo que hace que resolver el sistema  $Va = y$  sea un método numéricamente inadecuado para calcular el interpolante.

*Demostración.* Sea  $m = \lfloor n/2 \rfloor$  y consideremos el polinomio de prueba

$$p(x) = (1 - x^2)^m = \sum_{k=0}^m (-1)^k \binom{m}{k} x^{2k} \in \mathcal{P}_n,$$

que tiene grado  $2m \leq n$ . Su vector de coeficientes en la base monomial es  $a \in \mathbb{R}^{n+1}$  con  $a_{2k} = (-1)^k \binom{m}{k}$  para  $k = 0, \dots, m$  y las restantes componentes nulas.

**Cota inferior de  $\|a\|_2$ .** Por la identidad de Vandermonde–Chu,

$$\|a\|_2^2 = \sum_{k=0}^m \binom{m}{k}^2 = \binom{2m}{m}.$$

Como  $\binom{2m}{m}$  es el mayor de los  $2m + 1$  sumandos de  $\sum_{k=0}^{2m} \binom{2m}{k} = 4^m$ ,

$$\binom{2m}{m} \geq \frac{4^m}{2m+1}.$$

**Cota superior de  $\|Va\|_2$ .** Para todo  $x \in [-1, 1]$  se tiene  $0 \leq 1 - x^2 \leq 1$ , de modo que  $(1 - x_i^2)^{2m} \leq 1$ . Sumando sobre los  $n + 1$  nodos:

$$\|Va\|_2^2 = \sum_{i=0}^n (1 - x_i^2)^{2m} \leq n + 1.$$

**Cota de  $\sigma_{\min}(V)$ .** Aplicando la caracterización variacional del Lema 2.26:

$$\sigma_{\min}^2(V) \leq \frac{\|Va\|_2^2}{\|a\|_2^2} \leq \frac{n+1}{\binom{2m}{m}} \leq \frac{(n+1)(2m+1)}{4^m}.$$

**Cota inferior de  $\sigma_{\max}(V)$ .** La primera columna de  $V$  es el vector  $(1, \dots, 1)^T \in \mathbb{R}^{n+1}$ , así que

$$\sigma_{\max}(V) \geq \|Ve_1\|_2 = \sqrt{n+1}.$$

**Conclusión.** Combinando ambas cotas y usando  $2m+1 \leq n+1$ :

$$\kappa_2(V) = \frac{\sigma_{\max}(V)}{\sigma_{\min}(V)} \geq \frac{\sqrt{n+1} \cdot 2^m}{\sqrt{(n+1)(2m+1)}} = \frac{2^m}{\sqrt{2m+1}} \geq \frac{2^{\lfloor n/2 \rfloor}}{\sqrt{n+1}}. \quad \square$$

### 3.1.2 La base de Lagrange

El mal condicionamiento de la matriz de Vandermonde no implica que no existan formas estables de calcular el interpolante. En efecto, un método consiste en utilizar la **base de Lagrange**, que diagonaliza el operador  $\Phi$ .

**Definición 3.5** (Polinomios base de Lagrange). *Dados nodos distintos  $x_0, \dots, x_n \in \mathbb{F}$ , definimos*

$$\ell_k(x) = \prod_{\substack{j=0 \\ j \neq k}}^n \frac{x - x_j}{x_k - x_j}, \quad k = 0, \dots, n.$$

**Teorema 3.6** (Propiedades de la base de Lagrange). *Los polinomios  $\ell_0, \dots, \ell_n$  forman una base de  $\mathcal{P}_n$  y satisfacen:*

1. **Propiedad de Kronecker:**  $\ell_k(x_j) = \delta_{kj}$ .
2. **Partición de la unidad:**  $\sum_{k=0}^n \ell_k(x) = 1$  para todo  $x$ .

El polinomio interpolante es  $p(x) = \sum_{k=0}^n y_k \ell_k(x)$ .

*Demostración.* La propiedad de Kronecker se verifica directamente de la definición. En la base de Lagrange, la representación matricial de  $\Phi$  es la identidad:  $\Phi(\ell_k) = e_k$ . Como  $\Phi$  es un isomorfismo (Teorema 3.3),  $\{\ell_0, \dots, \ell_n\}$  es base de  $\mathcal{P}_n$ .

Para la partición de la unidad, observamos que  $q(x) = \sum_{k=0}^n \ell_k(x)$  pertenece a  $\mathcal{P}_n$  y satisface  $q(x_j) = \sum_k \delta_{kj} = 1$  para todo  $j$ . Como el polinomio constante 1 también interpola esos datos, la unicidad del interpolante da  $q \equiv 1$ .  $\square$

### 3.1.3 La forma baricéntrica

Definimos los **pesos baricéntricos**

$$w_k = \frac{1}{\prod_{j \neq k} (x_k - x_j)}, \quad k = 0, \dots, n,$$

de modo que  $\ell_k(x) = w_k \omega_{n+1}(x)/(x - x_k)$  donde  $\omega_{n+1}(x) = \prod_{j=0}^n (x - x_j)$ . Sustituyendo en la fórmula del interpolante y dividiendo por  $1 = \sum_k \ell_k(x)$ :

**Teorema 3.7** (Forma baricéntrica). *Para  $x \neq x_k$ , el polinomio interpolante se escribe*

$$p(x) = \frac{\sum_{k=0}^n \frac{w_k}{x - x_k} y_k}{\sum_{k=0}^n \frac{w_k}{x - x_k}}.$$



## 3.2 Interpolación sobre $\mathbb{R}$

Cuando los nodos y los datos son reales, podemos estimar cuánto difiere el interpolante de la función original. El resultado fundamental es el **teorema del error de interpolación**, que expresa  $f(x) - p_n(x)$  en términos de la derivada de orden  $n + 1$  de  $f$ .

Un estudio más profundo del error —que requiere las herramientas de la teoría de aproximación— se realizará en el Capítulo 4.

### 3.2.1 Error de interpolación

**Teorema 3.8** (Error de interpolación polinomial). *Sea  $f \in C^{(n+1)}([a, b])$  y  $p_n \in \mathcal{P}_n$  el polinomio que interpola a  $f$  en  $n + 1$  nodos distintos  $x_0, \dots, x_n \in [a, b]$ . Entonces, para todo  $x \in [a, b]$  existe  $\xi = \xi(x) \in (a, b)$  tal que*

$$f(x) - p_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x), \quad \omega_{n+1}(x) = \prod_{i=0}^n (x - x_i). \quad (3.1)$$

En particular,  $\|f - p_n\|_\infty \leq \frac{\|f^{(n+1)}\|_\infty}{(n+1)!} \|\omega_{n+1}\|_\infty$ .

*Demostración.* Si  $x$  coincide con algún nodo, ambos lados de (3.1) valen cero. Fijemos  $x \neq x_j$  para todo  $j$  y definamos

$$g(t) = f(t) - p_n(t) - \frac{f(x) - p_n(x)}{\omega_{n+1}(x)} \omega_{n+1}(t).$$

La función  $g \in C^{(n+1)}([a, b])$  tiene al menos  $n + 2$  ceros: los  $n + 1$  nodos  $x_0, \dots, x_n$  y el punto  $x$ . Por el teorema de Rolle aplicado sucesivamente,  $g^{(n+1)}$  tiene al menos un cero  $\xi \in (a, b)$ . Como  $p_n^{(n+1)} \equiv 0$  y  $\omega_{n+1}^{(n+1)} = (n+1)!$ :

$$0 = g^{(n+1)}(\xi) = f^{(n+1)}(\xi) - \frac{f(x) - p_n(x)}{\omega_{n+1}(x)} (n+1)!.$$

Despejando se obtiene (3.1). □

**Observación 3.9** (Rol del polinomio nodal  $\omega_{n+1}$ ). *La fórmula (3.1) separa dos contribuciones al error:*

1.  $f^{(n+1)}(\xi)/(n+1)!$ : depende de la **suavidad** de  $f$ .
2.  $\omega_{n+1}(x) = \prod (x - x_i)$ : depende de la **distribución de los nodos**. Los nodos que minimizan  $\|\omega_{n+1}\|_\infty$  en  $[-1, 1]$  son los **nodos de Chebyshev**  $x_j = \cos\left(\frac{(2j+1)\pi}{2(n+1)}\right)$ , que estudiaremos en el Capítulo 4.

Para nodos equiespaciados,  $\|\omega_{n+1}\|_\infty$  crece factorialmente con  $n$ , lo que explica el **fenómeno de Runge**: la interpolación equiespaciada puede diverger aunque  $f$  sea analítica.

**Ejemplo 3.10** (Error de la interpolación lineal). Sea  $f \in C^2([a, a+h])$  y  $p_1 \in \mathcal{P}_1$  el polinomio que interpola  $f$  en los extremos  $x_0 = a$  y  $x_1 = a+h$ . Aplicamos el Teorema 3.8 con  $n = 1$ : para todo  $x \in [a, a+h]$  existe  $\xi \in (a, a+h)$  tal que

$$f(x) - p_1(x) = \frac{f''(\xi)}{2}(x-a)(x-(a+h)).$$

Para acotar  $|\omega_2(x)| = |(x-a)(x-(a+h))|$  en  $[a, a+h]$ , hacemos  $t = x - a \in [0, h]$ :

$$|t(t-h)| = t(h-t) \leq \frac{h^2}{4},$$

pues el máximo de  $t(h-t)$  se alcanza en  $t = h/2$ . Por lo tanto

$$\|f - p_1\|_{\infty, [a, a+h]} \leq \frac{h^2}{8} \|f''\|_{\infty, [a, a+h]}.$$

El error de la interpolación lineal es  $O(h^2)$ , con constante proporcional a  $\|f''\|_{\infty}$ .

**Ejemplo 3.11** (Error de la derivada del interpolante lineal). Con las mismas hipótesis del Ejemplo 3.10, queremos aproximar derivadas a partir de  $p_1$ . Como  $p_1$  es afín,

$$p_1'(x) = \frac{f(a+h) - f(a)}{h} \quad (\text{constante en } [a, a+h]).$$

Es decir, la derivada del interpolante coincide con la **diferencia finita progresiva**

$$D_h^+ f(a) := \frac{f(a+h) - f(a)}{h}.$$

Demostremos ahora una cota del error usando Taylor. Si  $f \in C^2([a, a+h])$ , por Taylor de orden 1 en  $a$  con resto de Lagrange existe  $\xi \in (a, a+h)$  tal que

$$f(a+h) = f(a) + hf'(a) + \frac{h^2}{2} f''(\xi).$$

Dividiendo por  $h$  y restando  $f'(a)$ :

$$D_h^+ f(a) - f'(a) = \frac{h}{2} f''(\xi).$$

Por lo tanto,

$$|f'(a) - p_1'| = |f'(a) - D_h^+ f(a)| \leq \frac{h}{2} \|f''\|_{\infty, [a, a+h]}.$$

Esta es una cota del error de la diferencia finita progresiva en  $x = a$ : error  $O(h)$ .

Para obtener una cota para cualquier  $x \in [a, a+h]$ ,

$$|f'(x) - p_1'| \leq |f'(x) - f'(a)| + |f'(a) - p_1'| \leq (x-a) \|f''\|_{\infty} + \frac{h}{2} \|f''\|_{\infty} \leq \frac{3}{2} h \|f''\|_{\infty},$$

y en consecuencia

$$\|f' - p_1'\|_{\infty, [a, a+h]} \leq \frac{3}{2} h \|f''\|_{\infty, [a, a+h]} = O(h).$$

Se ve así que, al derivar el interpolante lineal, se pierde un orden respecto del error  $O(h^2)$  de la interpolación de  $f$ .

### 3.2.2 Cuadratura interpolatoria

La interpolación polinomial tiene una aplicación directa e importante: la integración numérica (o **cuadratura**). La idea es sencilla: si queremos aproximar la integral  $\int_a^b f(x) dx$  y no conocemos una primitiva de  $f$ , podemos reemplazar  $f$  por su polinomio interpolante  $p$  (que sí sabemos integrar explícitamente) y aproximar:

$$\int_a^b f(x) dx \approx \int_a^b p(x) dx.$$

Eligiendo distintos grados de interpolación y distintos nodos se obtienen las clásicas **fórmulas de Newton-Cotes**. En esta sección desarrollamos las dos más fundamentales —la regla del trapecio y la regla de Simpson— y analizamos sus errores.

Antes de deducir fórmulas particulares, escribimos la cuadratura interpolatoria en forma general.

**Proposición 3.12** (Pesos de la cuadratura interpolatoria). *Sean  $a = x_0 < \dots < x_k = b$  nodos en  $[a, b]$ , y sea*

$$p_k(x) = \sum_{i=0}^k f(x_i) \ell_i(x)$$

*el interpolante de Lagrange de grado  $k$ , donde  $\ell_i$  son los polinomios de la base de Lagrange. Entonces*

$$Q_k(f) := \int_a^b p_k(x) dx = \sum_{i=0}^k w_i f(x_i), \quad w_i := \int_a^b \ell_i(x) dx.$$

*Es decir, los **pesos** de la cuadratura interpolatoria son las integrales de los polinomios base de Lagrange.*

*Demostración.* Por linealidad de la integral,

$$\int_a^b p_k(x) dx = \int_a^b \sum_{i=0}^k f(x_i) \ell_i(x) dx = \sum_{i=0}^k f(x_i) \int_a^b \ell_i(x) dx = \sum_{i=0}^k w_i f(x_i).$$

□

#### La regla del trapecio

Aplicamos la Proposición 3.12 al caso  $k = 1$  con nodos  $x_0 = a$ ,  $x_1 = b$ . Los polinomios base son

$$\ell_0(x) = \frac{x-b}{a-b} = \frac{b-x}{b-a}, \quad \ell_1(x) = \frac{x-a}{b-a}.$$

Sus pesos resultan

$$w_0 = \int_a^b \ell_0(x) dx = \frac{1}{b-a} \int_a^b (b-x) dx = \frac{b-a}{2},$$
$$w_1 = \int_a^b \ell_1(x) dx = \frac{1}{b-a} \int_a^b (x-a) dx = \frac{b-a}{2}.$$

Por lo tanto,

$$Q_1(f) = w_0 f(a) + w_1 f(b) = \frac{b-a}{2} (f(a) + f(b)),$$

que es la **regla del trapecio**.

**Definición 3.13** (Regla del trapecio). *La **regla del trapecio** (simple) es*

$$T(f; a, b) := \frac{b-a}{2} (f(a) + f(b)).$$

**Teorema 3.14** (Error de la regla del trapecio). *Si  $f \in C^2([a, b])$ , existe  $\eta \in (a, b)$  tal que*

$$\int_a^b f(x) dx - T(f; a, b) = -\frac{(b-a)^3}{12} f''(\eta).$$

*Demostración.* Sea  $p_1$  el interpolante lineal de  $f$  en  $\{a, b\}$ . Como  $\int_a^b p_1 = T(f; a, b)$ , el error de cuadratura es  $\int_a^b (f - p_1)$ . Por el Teorema 3.8 con  $n = 1$ :

$$f(x) - p_1(x) = \frac{f''(\xi(x))}{2} (x-a)(x-b).$$

Como  $(x-a)(x-b) \leq 0$  en  $[a, b]$ , el teorema del valor medio para integrales (Teorema A.5, con  $g = f'' \circ \xi$  y  $\varphi(x) = (x-a)(x-b)/2$ ) da un  $\eta \in (a, b)$  con

$$\int_a^b \frac{f''(\xi(x))}{2} (x-a)(x-b) dx = \frac{f''(\eta)}{2} \int_a^b (x-a)(x-b) dx.$$

El cambio  $t = x - a$  da  $\int_0^h t(t-h) dt = -h^3/6$  con  $h = b - a$ , de donde el resultado. □

## Regla de Simpson

Si en lugar de interpolar linealmente usamos una parábola (polinomio de grado 2), obtenemos una fórmula más precisa. Tomamos tres nodos equiespaciados:  $x_0 = a$ ,  $x_1 = (a+b)/2$ ,  $x_2 = b$ . El polinomio de Lagrange de grado 2 que pasa por  $(x_0, f(x_0))$ ,  $(x_1, f(x_1))$ ,  $(x_2, f(x_2))$  se puede integrar directamente. Haciendo el cambio  $t = x - x_1$  (que centra el intervalo en el origen) e integrando los polinomios de Lagrange, se obtiene:

Esta elección no es arbitraria: la geometría regular de estos puntos sobre el círculo unitario dota al problema de interpolación de una estructura algebraica excepcional. La matriz de Vandermonde asociada se convierte, salvo un factor de escala, en una matriz unitaria. Esto significa que el problema de interpolación (y su inverso, la evaluación) se vuelve numéricamente muy estable y computacionalmente muy eficiente.

Este caso específico de interpolación es lo que conocemos como la **Transformada Discreta de Fourier (DFT)**.

### 3.2.3 Las raíces de la unidad como nodos de interpolación

**Definición 3.15** (Raíces  $n$ -ésimas de la unidad). Sea  $n \geq 1$  un entero. Las **raíces  $n$ -ésimas de la unidad** son las soluciones de la ecuación  $z^n = 1$  en  $\mathbb{C}$ :

$$\omega_n^k = e^{2\pi i k/n}, \quad k = 0, 1, \dots, n-1.$$

**Notación:** Cuando  $n$  está claro del contexto, escribimos simplemente  $\omega = \omega_n = e^{2\pi i/n}$ . Con esta notación, las raíces  $n$ -ésimas de la unidad son:  $\{1, \omega, \omega^2, \dots, \omega^{n-1}\}$ .

Ahora consideremos un polinomio sobre los complejos cualquiera

$$p(z) = \sum_{k=0}^{n-1} c_k z^k \quad (3.2)$$

Cuando tratamos el problema de interpolación, empezamos evaluando un polinomio en los nodos de interpolación, que en este caso son las raíces de la unidad. La evaluación de  $p$  en la raíz  $\omega^j$  se expresa como:

$$p(\omega^j) = \sum_{k=0}^{n-1} c_k (\omega^j)^k = \sum_{k=0}^{n-1} c_k \omega^{jk} = \sum_{k=0}^{n-1} c_k e^{2\pi i jk/n}. \quad (3.3)$$

A partir de aquí, podemos definir la **Transformada Discreta de Fourier (DFT)** como la evaluación de un polinomio en las raíces de la unidad. La definición usual de la DFT se presenta a continuación, pero es importante destacar que esta definición es una instancia particular de la interpolación polinomial en  $\mathbb{C}$  con nodos en las raíces de la unidad.

**Definición 3.16** (Transformada Discreta de Fourier (DFT)). Dado  $x \in \mathbb{C}^N$ , definimos su DFT como  $\hat{x} \in \mathbb{C}^N$  con

$$\hat{x}_j = \sum_{k=0}^{N-1} x_k \omega_N^{jk}, \quad j = 0, \dots, N-1, \quad \text{donde } \omega_N = e^{2\pi i/N}.$$

### 3.2.4 Matriz de Vandermonde y la transformada inversa (IDFT)

Como la DFT es evaluar un polinomio en las raíces de la unidad, podemos representarla mediante una matriz de Vandermonde.

**Observación 3.17** (Propiedades básicas de las raíces de la unidad). Sea  $\omega = e^{2\pi i/n}$  una raíz  $n$ -ésima primitiva de la unidad. Vale la pena recordar:

1.  $\omega^n = 1$  (por definición,  $\omega$  es raíz  $n$ -ésima de la unidad).
2.  $\omega^{jk} = (\omega^j)^k = (\omega^k)^j$  (exponentes conmutan).
3. Suma geométrica de raíces: Para cualquier  $\ell \in \mathbb{Z}$ ,

$$\sum_{j=0}^{n-1} \omega^{j\ell} = \begin{cases} n & \text{si } \ell \equiv 0 \pmod{n}, \\ 0 & \text{si } \ell \not\equiv 0 \pmod{n}. \end{cases}$$

En el segundo caso, la suma es una serie geométrica con razón  $r = \omega^\ell \neq 1$ :  $\sum_{j=0}^{n-1} r^j = \frac{r^n - 1}{r - 1} = \frac{\omega^{n\ell} - 1}{\omega^\ell - 1} = \frac{1 - 1}{\omega^\ell - 1} = 0$ .

**Definición 3.18** (Matriz DFT como Vandermonde). *La matriz de Vandermonde evaluada en las raíces  $n$ -ésimas de la unidad es:*

$$F_n = \begin{pmatrix} 1 & 1 & 1 & \cdots & 1 \\ 1 & \omega & \omega^2 & \cdots & \omega^{n-1} \\ 1 & \omega^2 & \omega^4 & \cdots & \omega^{2(n-1)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \omega^{n-1} & \omega^{2(n-1)} & \cdots & \omega^{(n-1)(n-1)} \end{pmatrix}.$$

*Elemento  $(j, k)$ :  $[F_n]_{jk} = \omega^{jk}$  para  $j, k = 0, 1, \dots, n-1$ .*

Una propiedad extraordinaria de  $F_n$  es que sus columnas son los **modos de Fourier discretos** y son mutuamente ortogonales.

**Lema 3.19** (Ortogonalidad de las columnas de  $F_n$ ). *La  $k$ -ésima columna de  $F_n$  es el modo de Fourier discreto*

$$\mathbf{v}_k = (1, \omega^k, \omega^{2k}, \dots, \omega^{(n-1)k})^T \in \mathbb{C}^n, \quad k = 0, \dots, n-1.$$

*Estos vectores son mutuamente ortogonales:*

$$\langle \mathbf{v}_k, \mathbf{v}_\ell \rangle = n \delta_{k\ell}.$$

*En particular,  $\|\mathbf{v}_k\| = \sqrt{n}$ , y los vectores normalizados  $\mathbf{u}_k = \frac{1}{\sqrt{n}}\mathbf{v}_k$  forman una base ortonormal (BON) de  $\mathbb{C}^n$ .*

*Demostración.* Calculamos el producto interior:

$$\langle \mathbf{v}_k, \mathbf{v}_\ell \rangle = \sum_{j=0}^{n-1} \omega^{jk} \overline{\omega^{j\ell}} = \sum_{j=0}^{n-1} \omega^{jk} \omega^{-j\ell} = \sum_{j=0}^{n-1} \omega^{j(k-\ell)}.$$

Si  $k = \ell$ , cada término vale 1, luego la suma es  $n$ . Si  $k \neq \ell$ , sea  $r = \omega^{k-\ell} \neq 1$ ; como  $r$  es una raíz  $n$ -ésima de la unidad ( $r^n = 1$ ), la fórmula de la suma geométrica da

$$\sum_{j=0}^{n-1} r^j = \frac{r^n - 1}{r - 1} = \frac{1 - 1}{r - 1} = 0.$$

Por tanto  $\langle \mathbf{v}_k, \mathbf{v}_\ell \rangle = n \delta_{k\ell}$ . Como hay  $n$  vectores no nulos ortogonales entre sí en  $\mathbb{C}^n$ , son linealmente independientes y forman una base; normalizados,  $\{\mathbf{u}_k\}$  es una BON.  $\square$

**Teorema 3.20** (Unitariedad de  $F_n$ ). *La matriz  $F_n$  satisface  $F_n^* F_n = n I_n$ . Equivalentemente,  $\frac{1}{\sqrt{n}} F_n$  es unitaria.*

*Demostración.* El elemento  $(k, \ell)$  de  $F_n^* F_n$  es  $\langle \mathbf{v}_k, \mathbf{v}_\ell \rangle$ , donde  $\mathbf{v}_k$  es la  $k$ -ésima columna de  $F_n$ . Por el Lema 3.19,  $[F_n^* F_n]_{k\ell} = n \delta_{k\ell}$ , es decir,  $F_n^* F_n = n I_n$ .  $\square$

**Corolario 3.21** (Inversa de la DFT). *La matriz inversa de  $F_n$  es:*

$$F_n^{-1} = \frac{1}{n} F_n^*.$$

*Explícitamente,  $[F_n^{-1}]_{jk} = \frac{1}{n} \omega^{-jk}$ .*

Con lo cual, la **DFT inversa (IDFT)** es:

$$\mathbf{x} = F_n^{-1} \mathbf{X} = \frac{1}{n} F_n^* \mathbf{X}, \quad \text{es decir, } x_j = \frac{1}{n} \sum_{k=0}^{n-1} \hat{x}_k \omega^{-jk}.$$

**Observación 3.22** (Convenciones de normalización). *Diferentes textos usan distintas convenciones:*

- **Convención asimétrica** (usada aquí y en numpy): Factor  $1/n$  solo en la inversa.
- **Convención simétrica**: Factor  $1/\sqrt{n}$  en ambas direcciones (hace a  $F_n/\sqrt{n}$  unitaria).
- **Convención de ingeniería**: A veces se usa  $\omega = e^{-2\pi i/n}$  (signo opuesto).

*Lo importante es la relación  $F_n^{-1} = \frac{1}{n} F_n^*$ , que es invariante.*

**Observación 3.23** (Lectura en términos de DFT). *Con la convención asimétrica usada aquí ( $\mathbf{X} = F_n \mathbf{x}$ ), la DFT difiere del operador de cambio a coordenadas ortonormales por normalización (y conjugación de fase, según convención de signo). En particular, la versión unitaria*

$$\tilde{\mathbf{X}} := \frac{1}{\sqrt{n}} F_n^* \mathbf{x} = U^* \mathbf{x}$$

*es exactamente el cambio de base de la base canónica a la BON de modos de Fourier.*

### 3.2.5 Transformada Rápida de Fourier (FFT)

El cálculo directo de  $\mathbf{X} = F_n \mathbf{x}$  requiere  $O(n^2)$  operaciones (producto matriz-vector). La **\*\*FFT\*\*** (Cooley-Tukey, 1965) reduce esto a  $O(n \log n)$  mediante factorización recursiva.

**Idea clave:** Explotar la estructura de  $F_n$  para descomponer la DFT de tamaño  $n$  en dos DFTs de tamaño  $n/2$  (asumiendo  $n$  par).

**Teorema 3.24** (Algoritmo FFT (Cooley-Tukey radix-2)). *Supongamos  $n = 2m$  (par). Separamos la secuencia  $\mathbf{x}$  en índices pares e impares:*

$$\mathbf{x}_{par} = (x_0, x_2, x_4, \dots, x_{n-2}), \quad \mathbf{x}_{impar} = (x_1, x_3, x_5, \dots, x_{n-1}).$$

*Sea  $X_k = \sum_{j=0}^{n-1} x_j \omega_n^{jk}$ . Separando en pares e impares:*

$$\begin{aligned} X_k &= \sum_{j=0}^{m-1} x_{2j} \omega_n^{2jk} + \sum_{j=0}^{m-1} x_{2j+1} \omega_n^{(2j+1)k} \\ &= \sum_{j=0}^{m-1} x_{2j} (\omega_n^2)^{jk} + \omega_n^k \sum_{j=0}^{m-1} x_{2j+1} (\omega_n^2)^{jk}. \end{aligned}$$

Observando que  $\omega_n^2 = e^{4\pi i/n} = e^{2\pi i/m} = \omega_m$ :

$$X_k = E_k + \omega_n^k O_k,$$

donde:

- $E_k = \sum_{j=0}^{m-1} x_{2j} \omega_m^{jk}$  es la DFT de tamaño  $m$  de  $\mathbf{x}_{par}$ .
- $O_k = \sum_{j=0}^{m-1} x_{2j+1} \omega_m^{jk}$  es la DFT de tamaño  $m$  de  $\mathbf{x}_{impar}$ .

Para completar los  $n$  coeficientes, no alcanza con  $k = 0, \dots, m-1$ : también necesitamos  $X_{k+m}$ . La clave es que  $E_k$  y  $O_k$  son DFTs de tamaño  $m$ , por lo que son periódicas módulo  $m$ :

$$E_{k+m} = \sum_{j=0}^{m-1} x_{2j} \omega_m^{j(k+m)} = \sum_{j=0}^{m-1} x_{2j} \omega_m^{jk} (\omega_m^m)^j = \sum_{j=0}^{m-1} x_{2j} \omega_m^{jk} = E_k,$$

y análogamente  $O_{k+m} = O_k$ , porque  $\omega_m^m = e^{2\pi i} = 1$ .

Además,

$$\omega_n^{k+m} = \omega_n^k \omega_n^m = \omega_n^k e^{\pi i} = -\omega_n^k,$$

ya que  $n = 2m$ .

Entonces, para  $k = 0, \dots, m-1$ :

$$\begin{cases} X_k = E_k + \omega_n^k O_k, & k = 0, \dots, m-1, \\ X_{k+m} = E_k - \omega_n^k O_k, & k = 0, \dots, m-1. \end{cases}$$

Este es el paso de **combinación** (butterfly): cada par  $(E_k, O_k)$  produce dos salidas  $(X_k, X_{k+m})$ .

En forma algorítmica, la FFT radix-2 termina así:

1. Si  $n = 1$ , devolver el único valor (caso base).
2. Si  $n > 1$ , calcular recursivamente las DFT de tamaño  $m = n/2$  de las partes par e impar para obtener  $E_k$  y  $O_k$ .
3. Para  $k = 0, \dots, m-1$ , formar

$$X_k = E_k + \omega_n^k O_k, \quad X_{k+m} = E_k - \omega_n^k O_k.$$

4. Devolver el vector completo  $\mathbf{X} = (X_0, \dots, X_{n-1})$ .

**Análisis de complejidad:** Sea  $T(n)$  el tiempo para calcular una DFT de tamaño  $n$ . El algoritmo FFT satisface:

$$T(n) = 2T(n/2) + O(n),$$

pues calcula dos DFTs de tamaño  $n/2$  más  $O(n)$  sumas/multiplicaciones. Por el Teorema Maestro:

$$T(n) = O(n \log n).$$

Para  $n = 2^{10} = 1024$ :



- DFT directa:  $\sim n^2 = 10^6$  operaciones.
- FFT:  $\sim n \log_2 n = 1024 \cdot 10 \approx 10^4$  operaciones.

¡Aceleración de 100x!

**Implementación:** En Python, usar `numpy.fft.fft(x)` y `numpy.fft.ifft(X)`. Ver el archivo `interpolacion_algebraica.py` para una implementación didáctica de DFT vía Vandermonde (sin FFT,  $O(n^2)$ ) y comparación con `numpy.fft`.

### 3.2.6 Criterio de Nyquist-Shannon y aliasing

Una vez que la señal se representa mediante coeficientes de Fourier, aparece una pregunta central: ¿cuántas muestras hacen falta para reconstruirla de manera unívoca a partir de su DFT?

Sea  $x : [0, T] \rightarrow \mathbb{C}$  una señal periódica de período  $T$  con expansión finita

$$x(t) = \sum_{k=-M}^M c_k e^{2\pi i k t / T},$$

de modo que la frecuencia máxima presente es  $f_{\max} = M/T$ .

Si muestreamos en  $N$  puntos equiespaciados

$$t_j = \frac{j}{f_s}, \quad j = 0, \dots, N-1, \quad f_s = \frac{N}{T},$$

entonces

$$x(t_j) = \sum_{k=-M}^M c_k e^{2\pi i k j / N}.$$

La estructura discreta implica periodicidad en frecuencia módulo  $N$ :

$$e^{2\pi i (k+\ell N) j / N} = e^{2\pi i k j / N} e^{2\pi i \ell j} = e^{2\pi i k j / N},$$

para todo  $\ell \in \mathbb{Z}$ . Por lo tanto, los modos  $k$  y  $k + \ell N$  son indistinguibles en los datos muestreados. Este fenómeno se llama **aliasing**.

Para evitar colisiones entre índices en el rango  $\{-M, \dots, M\}$ , debe cumplirse

$$N > 2M,$$

equivalentemente,

$$\boxed{f_s > 2f_{\max}.$$

Esta es la condición del **teorema de muestreo de Nyquist-Shannon**. El valor  $f_s/2$  se denomina **frecuencia de Nyquist**.

**Observación 3.25** (Lectura práctica). Si  $f_s \leq 2f_{\max}$ , la reconstrucción espectral por DFT no es unívoca porque distintas señales pueden producir exactamente las mismas muestras. En aplicaciones, esto se evita con dos ideas complementarias:

- filtrar altas frecuencias antes de muestrear (filtro antialiasing),
- elegir una tasa de muestreo con margen por encima de  $2f_{\max}$ .

Por ejemplo, en audio digital se usa típicamente 44.1 kHz para señales cuyo contenido útil está por debajo de 20 kHz.

### 3.2.7 Convolución discreta

Una de las aplicaciones más poderosas de la DFT y, por extensión, de la FFT, es el **Teorema de Convolución**. Este teorema establece que la convolución circular de dos secuencias en el dominio del tiempo se convierte en una simple multiplicación punto a punto de sus DFT en el dominio de la frecuencia.

Si  $x[n]$  y  $y[n]$  son dos secuencias finitas de longitud  $N + 1$ , su convolución circular  $z[n] = (x * y)[n]$  está definida como:

$$z[n] = \sum_{m=0}^N x[m]y[(n - m) \bmod (N + 1)]$$

para  $n = 0, 1, \dots, N$ .

El Teorema de Convolución Discreta nos dice que:

$$\text{DFT}\{x[n] * y[n]\} = \text{DFT}\{x[n]\} \cdot \text{DFT}\{y[n]\}$$

O, en notación de Fourier:

$$Z[k] = X[k] \cdot Y[k]$$

Donde  $X[k]$ ,  $Y[k]$  y  $Z[k]$  son las DFT de  $x[n]$ ,  $y[n]$  y  $z[n]$  respectivamente.

El Teorema de Convolución Discreta establece que la Transformada Discreta de Fourier (DFT) de la convolución circular de dos secuencias es igual al producto punto a punto de las DFT de cada secuencia.

**Paso 1: Aplicar la DFT a la Convolución** Queremos calcular la DFT de  $z[n]$ , es decir,  $Z[k]$ :

$$Z[k] = \sum_{n=0}^N z[n]e^{-j\frac{2\pi}{N+1}kn}$$

Sustituimos la definición de  $z[n]$ :

$$Z[k] = \sum_{n=0}^N \left( \sum_{m=0}^N x[m]y[(n - m) \bmod (N + 1)] \right) e^{-j\frac{2\pi}{N+1}kn}$$

Intercambiamos el orden de las sumatorias:

$$Z[k] = \sum_{m=0}^N x[m] \sum_{n=0}^N y[(n - m) \bmod (N + 1)] e^{-j\frac{2\pi}{N+1}kn}$$

**Paso 2: Cambio de Variable** Hacemos un cambio de variable en la sumatoria interna. Sea  $p = (n - m) \bmod (N + 1)$ . Cuando  $n$  recorre de 0 a  $N$ ,  $p$  también recorrerá de 0 a  $N$ . De  $p = (n - m) \bmod (N + 1)$ , podemos expresar  $n = (p + m) \bmod (N + 1)$ .

Sustituimos esto en el término exponencial:

$$e^{-j\frac{2\pi}{N+1}kn} = e^{-j\frac{2\pi}{N+1}k(p+m)} = e^{-j\frac{2\pi}{N+1}kp} e^{-j\frac{2\pi}{N+1}km}$$

Ahora, la sumatoria interna se convierte en:

$$\sum_{p=0}^N y[p] e^{-j \frac{2\pi}{N+1} k(p+m)} = \sum_{p=0}^N y[p] e^{-j \frac{2\pi}{N+1} kp} e^{-j \frac{2\pi}{N+1} km}$$

Notamos que  $e^{-j \frac{2\pi}{N+1} km}$  no depende de  $p$ , por lo que puede salir de esta sumatoria:

$$e^{-j \frac{2\pi}{N+1} km} \sum_{p=0}^N y[p] e^{-j \frac{2\pi}{N+1} kp}$$

La sumatoria restante es, por definición, la **DFT de  $y[n]$** , es decir,  $Y[k]$ :

$$e^{-j \frac{2\pi}{N+1} km} Y[k]$$

**Paso 3: Reagrupar los Términos** Sustituimos este resultado de nuevo en la expresión de  $Z[k]$ :

$$Z[k] = \sum_{m=0}^N x[m] \left( Y[k] e^{-j \frac{2\pi}{N+1} km} \right)$$

Como  $Y[k]$  no depende de  $m$ , puede salir de la sumatoria externa:

$$Z[k] = Y[k] \sum_{m=0}^N x[m] e^{-j \frac{2\pi}{N+1} km}$$

Y la sumatoria restante es, por definición, la **DFT de  $x[n]$** , es decir,  $X[k]$ :

$$Z[k] = Y[k] \cdot X[k]$$

El teorema de convolución tiene numerosas aplicaciones prácticas en procesamiento de señales, resolución de ecuaciones y simulación numérica. A continuación presentamos algunas de las más importantes.

### 3.2.8 Filtrado digital de señales

El filtrado de señales es una de las aplicaciones más directas del teorema de convolución. Un **filtro digital** se representa mediante una secuencia  $h[n]$  llamada *respuesta al impulso* del filtro. La señal de salida  $y[n]$  se obtiene convolucionando la señal de entrada  $x[n]$  con  $h[n]$ :

$$y[n] = (h * x)[n] = \sum_{m=0}^N h[m] x[(n - m) \bmod (N + 1)].$$

Calcular esta convolución directamente requiere  $O(N^2)$  operaciones. Sin embargo, usando el teorema de convolución y la FFT, podemos reducir la complejidad a  $O(N \log N)$ :

### Algoritmo de filtrado rápido vía FFT:

1. Calcular  $H[k] = \text{FFT}\{h[n]\}$  (complejidad  $O(N \log N)$ ).
2. Calcular  $X[k] = \text{FFT}\{x[n]\}$  (complejidad  $O(N \log N)$ ).
3. Calcular  $Y[k] = H[k] \cdot X[k]$  (multiplicación punto a punto, complejidad  $O(N)$ ).
4. Calcular  $y[n] = \text{IFFT}\{Y[k]\}$  (complejidad  $O(N \log N)$ ).

El costo total es  $O(N \log N)$ , mucho menor que el método directo para  $N$  grande.

**Ejemplo 3.26** (Filtro pasa-bajos). *Un filtro pasa-bajos ideal tiene respuesta en frecuencia:*

$$H[k] = \begin{cases} 1 & \text{si } |k| \leq k_c \\ 0 & \text{si } |k| > k_c \end{cases}$$

donde  $k_c$  es la frecuencia de corte. Este filtro elimina las componentes de alta frecuencia de la señal, dejando solo las frecuencias bajas (hasta  $k_c$ ). En la práctica, se suele usar filtros con transiciones suaves en lugar de este corte abrupto para evitar el fenómeno de Gibbs.

### 3.2.9 Multiplicación rápida de polinomios

Sean  $p(x) = \sum_{k=0}^N p_k x^k$  y  $q(x) = \sum_{k=0}^N q_k x^k$  dos polinomios de grado a lo sumo  $N$ . Su producto  $r(x) = p(x)q(x)$  es un polinomio de grado a lo sumo  $2N$ :

$$r(x) = \sum_{k=0}^{2N} r_k x^k, \quad r_k = \sum_{j=0}^k p_j q_{k-j}.$$

Observemos que los coeficientes  $r_k$  son precisamente la **convolución lineal** (no circular) de las secuencias  $\{p_k\}$  y  $\{q_k\}$ . Para calcular la convolución lineal usando FFT, debemos trabajar con convolución circular de longitud suficiente para evitar el *aliasing circular*:

### Algoritmo de multiplicación rápida:

1. Extender ambas secuencias con ceros hasta longitud  $M \geq 2N + 1$  (típicamente  $M = 2^{\lceil \log_2(2N+1) \rceil}$  para eficiencia de FFT).
2. Calcular  $P[k] = \text{FFT}\{p_0, \dots, p_N, 0, \dots, 0\}$  (longitud  $M$ ).
3. Calcular  $Q[k] = \text{FFT}\{q_0, \dots, q_N, 0, \dots, 0\}$  (longitud  $M$ ).
4. Calcular  $R[k] = P[k] \cdot Q[k]$ .
5. Calcular  $\{r_k\} = \text{IFFT}\{R[k]\}$ .

La complejidad es  $O(M \log M) = O(N \log N)$ , frente a  $O(N^2)$  del método directo (multiplicación término a término).

### 3.2.10 Principio de incertidumbre de Donoho-Stark para la DFT

Una manifestación fundamental del principio de incertidumbre en el contexto discreto es: una señal no nula no puede estar simultáneamente muy concentrada en tiempo (índices) y en frecuencia (coeficientes de Fourier). Tomamos esta formulación del teorema de Donoho-Stark de [1].

**Teorema 3.27** (Donoho-Stark para la DFT). *Sea  $\mathbf{x} \in \mathbb{C}^n$ ,  $\mathbf{x} \neq 0$ , y sea  $\hat{\mathbf{x}} = F_n \mathbf{x}$  su DFT (convención asimétrica del apunte). Definimos*

$$\text{supp}(\mathbf{x}) = \{j : x_j \neq 0\}, \quad \text{supp}(\hat{\mathbf{x}}) = \{k : \hat{x}_k \neq 0\}.$$

*Si  $s := |\text{supp}(\mathbf{x})|$  y  $t := |\text{supp}(\hat{\mathbf{x}})|$ , entonces*

$$st \geq n.$$

*Demostración.* Sean

$$S := \text{supp}(\mathbf{x}), \quad T := \text{supp}(\hat{\mathbf{x}}), \quad |S| = s, \quad |T| = t.$$

**Paso 1 (cota puntual de  $x_j$ ).** Por la fórmula de la IDFT,

$$x_j = \frac{1}{n} \sum_{k=0}^{n-1} \hat{x}_k \omega^{-jk} = \frac{1}{n} \sum_{k \in T} \hat{x}_k \omega^{-jk},$$

ya que  $\hat{x}_k = 0$  fuera de  $T$ . Tomando módulo y usando  $|\omega^{-jk}| = 1$ :

$$|x_j| \leq \frac{1}{n} \sum_{k \in T} |\hat{x}_k|.$$

**Paso 2 (Cauchy-Schwarz en un producto interno discreto).** Consideremos el espacio  $\mathbb{C}^T \simeq \mathbb{C}^t$  con el producto interno hermitiano estándar

$$\langle a, b \rangle_T := \sum_{k \in T} a_k \bar{b}_k.$$

Aplicamos Cauchy-Schwarz (Apéndice, Teorema B.5) a

$$a_k := \hat{x}_k, \quad b_k := 1 \quad (k \in T).$$

Entonces

$$\sum_{k \in T} |\hat{x}_k| = \langle |\hat{\mathbf{x}}|, \mathbf{1} \rangle_T \leq \| |\hat{\mathbf{x}}| \|_{2,T} \| \mathbf{1} \|_{2,T} = \left( \sum_{k \in T} |\hat{x}_k|^2 \right)^{1/2} \sqrt{t} \leq \sqrt{t} \| \hat{\mathbf{x}} \|_2.$$

Sustituyendo en el Paso 1,

$$|x_j| \leq \frac{\sqrt{t}}{n} \| \hat{\mathbf{x}} \|_2 \quad \text{para todo } j = 0, \dots, n-1.$$

**Paso 3 (sumar sobre el soporte de  $\mathbf{x}$ ).** Como  $x_j = 0$  si  $j \notin S$ ,

$$\|\mathbf{x}\|_2^2 = \sum_{j \in S} |x_j|^2 \leq \sum_{j \in S} \left( \frac{\sqrt{t}}{n} \|\widehat{\mathbf{x}}\|_2 \right)^2 = \frac{st}{n^2} \|\widehat{\mathbf{x}}\|_2^2.$$

**Paso 4 (relación de normas DFT/IDFT).** Por la unitariedad de la DFT en nuestra convención (Teorema 3.20),

$$\|\widehat{\mathbf{x}}\|_2^2 = n \|\mathbf{x}\|_2^2.$$

Equivalentemente, si  $U := \frac{1}{\sqrt{n}} F_n$ , entonces  $U$  es unitaria y por Parseval en base ortonormal finita (Apéndice, Teorema B.10) se obtiene la misma identidad.

Reemplazando en la desigualdad del Paso 3:

$$\|\mathbf{x}\|_2^2 \leq \frac{st}{n} \|\mathbf{x}\|_2^2.$$

Como  $\mathbf{x} \neq 0$ , se tiene  $\|\mathbf{x}\|_2^2 > 0$ ; al dividir,

$$1 \leq \frac{st}{n},$$

y por lo tanto  $st \geq n$ . □

**Observación 3.28.** *Este resultado implica que no puede ocurrir simultáneamente que  $s \ll n$  y  $t \ll n$ . En forma equivalente,*

$$|\text{supp}(\mathbf{x})| |\text{supp}(\widehat{\mathbf{x}})| \geq n,$$

*que es la versión discreta (para DFT) del principio de incertidumbre de Donoho-Stark.*

**Corolario 3.29** (Cota aditiva para los soportes). *Con la notación del teorema anterior, se cumple*

$$s + t \geq 2\sqrt{n}.$$

*Demostración.* Por el Teorema de Donoho-Stark,  $st \geq n$ . Además, por la desigualdad aritmético-geométrica,

$$\frac{s+t}{2} \geq \sqrt{st}.$$

Combinando ambas:

$$\frac{s+t}{2} \geq \sqrt{st} \geq \sqrt{n},$$

y por tanto  $s + t \geq 2\sqrt{n}$ . □

### 3.3 Interpolación sobre cuerpos finitos

Hasta ahora hemos trabajado sobre  $\mathbb{R}$  o  $\mathbb{C}$ , pero la teoría de interpolación es completamente algebraica y se extiende a cualquier **cuerpo** (field). En particular, la interpolación sobre **cuerpos finitos**  $\mathbb{Z}_p$  (aritmética módulo un primo  $p$ ) tiene aplicaciones fundamentales en criptografía y teoría de códigos.

### 3.3.1 Cuerpos finitos: estructura algebraica

**Definición 3.30** (Cuerpo finito  $\mathbb{Z}_p$ ). Sea  $p$  un número primo. El conjunto  $\mathbb{Z}_p = \{0, 1, 2, \dots, p-1\}$  con suma y multiplicación módulo  $p$  forma un cuerpo finito de orden  $p$ .

**Operaciones:**

- Suma:  $(a + b) \bmod p$
- Multiplicación:  $(a \cdot b) \bmod p$
- Elemento neutro aditivo:  $0$
- Elemento neutro multiplicativo:  $1$
- Inverso aditivo de  $a$ :  $(-a) \bmod p = p - a$
- Inverso multiplicativo de  $a \neq 0$ :  $a^{-1}$  tal que  $a \cdot a^{-1} \equiv 1 \pmod{p}$

**Propiedad clave:** Todo elemento no nulo de  $\mathbb{Z}_p$  tiene inverso multiplicativo. Esto es esencial para que la interpolación funcione (necesitamos dividir por  $x_i - x_j$  con  $x_i \neq x_j$ ).

**Lema 3.31** (Cálculo de inversos en  $\mathbb{Z}_p$ ). Para  $a \in \mathbb{Z}_p$  con  $a \neq 0$ , el inverso multiplicativo puede calcularse mediante:

1. **Algoritmo extendido de Euclides:** Encuentra  $x, y$  tales que  $ax + py = \gcd(a, p) = 1$ . Entonces  $a^{-1} \equiv x \pmod{p}$ .
2. **Pequeño teorema de Fermat:**  $a^{-1} \equiv a^{p-2} \pmod{p}$  (exponenciación rápida).

**Ejemplo 3.32** (Cuerpo  $\mathbb{Z}_7$ ). En  $\mathbb{Z}_7$ :

- $3 + 5 = 8 \equiv 1 \pmod{7}$
- $4 \cdot 6 = 24 \equiv 3 \pmod{7}$
- $3^{-1} = 5$  porque  $3 \cdot 5 = 15 \equiv 1 \pmod{7}$
- $2^{-1} = 4$  porque  $2 \cdot 4 = 8 \equiv 1 \pmod{7}$

### 3.3.2 Interpolación en $\mathbb{Z}_p$ : teoría

La teoría desarrollada para  $\mathbb{R}$  se traslada palabra por palabra a  $\mathbb{Z}_p$ :

**Teorema 3.33** (Interpolación en  $\mathbb{Z}_p$ ). Sean  $x_0, x_1, \dots, x_n \in \mathbb{Z}_p$  nodos distintos (módulo  $p$ ) y  $y_0, y_1, \dots, y_n \in \mathbb{Z}_p$  valores arbitrarios. Entonces existe un **único** polinomio  $p(x) \in \mathcal{P}_n(\mathbb{Z}_p)$  tal que:

$$p(x_i) \equiv y_i \pmod{p}, \quad i = 0, 1, \dots, n.$$

**Demostración. Existencia:** Construimos el polinomio usando la fórmula de Lagrange. Los polinomios base son:

$$\ell_k(x) = \prod_{\substack{j=0 \\ j \neq k}}^n \frac{x - x_j}{x_k - x_j} \pmod{p}.$$

Como  $x_i \neq x_j \pmod{p}$ , cada diferencia  $x_k - x_j$  tiene inverso en  $\mathbb{Z}_p$ , por lo que  $\ell_k(x)$  está bien definido. Satisface  $\ell_k(x_j) \equiv \delta_{kj} \pmod{p}$ .

El interpolante es:

$$p(x) = \sum_{k=0}^n y_k \ell_k(x) \pmod{p}.$$

**Unicidad:** Si  $p(x)$  y  $q(x)$  interpolan los mismos datos, entonces  $r(x) = p(x) - q(x)$  satisface  $r(x_i) \equiv 0 \pmod{p}$  para todo  $i$ . El polinomio  $r(x)$  de grado  $\leq n$  tiene  $n + 1$  raíces distintas en  $\mathbb{Z}_p$ , por lo que debe ser el polinomio cero (módulo  $p$ ).  $\square$

### Diferencias con $\mathbb{R}$ :

- **Aritmética exacta:** No hay errores de redondeo en  $\mathbb{Z}_p$  (todo es exacto módulo  $p$ ).
- **Estructura finita:** Solo hay  $p$  elementos, lo que limita el número de nodos posibles.
- **Aplicaciones distintas:** Criptografía y códigos en lugar de aproximación de funciones.

### 3.3.3 Implementación computacional

La interpolación en  $\mathbb{Z}_p$  requiere aritmética modular cuidadosa:

#### Algoritmo (Interpolación de Lagrange en $\mathbb{Z}_p$ ):

*Entrada:* Nodos  $x_0, \dots, x_n \in \mathbb{Z}_p$ , valores  $y_0, \dots, y_n \in \mathbb{Z}_p$ , primo  $p$ .

*Salida:* Coeficientes  $[a_0, a_1, \dots, a_n]$  de  $p(x) = \sum_{k=0}^n a_k x^k \pmod{p}$ .

*Procedimiento:*

1. Inicializar  $\text{coefs} = [0, 0, \dots, 0]$  (longitud  $n + 1$ ).
2. Para  $k = 0, 1, \dots, n$ :
  - (a) Calcular denominador:  $d = \prod_{j \neq k} (x_k - x_j) \pmod{p}$ .
  - (b) Calcular inverso:  $d^{-1} \pmod{p}$  (Euclides extendido).
  - (c) Construir numerador (polinomio):  $\text{num}(x) = \prod_{j \neq k} (x - x_j) \pmod{p}$ .
  - (d) Actualizar:  $\text{coefs} = \text{coefs} + y_k \cdot d^{-1} \cdot \text{num} \pmod{p}$ .
3. Retornar  $\text{coefs}$ .

**Ejemplo 3.34** (Interpolación en  $\mathbb{Z}_7$ ). *Interpolar los puntos  $(0, 1)$ ,  $(1, 3)$ ,  $(2, 2)$  en  $\mathbb{Z}_7$ .*

**Solución:** Usando la fórmula de Lagrange:

$$\begin{aligned} \ell_0(x) &= \frac{(x-1)(x-2)}{(0-1)(0-2)} = \frac{(x-1)(x-2)}{2} \equiv 4(x-1)(x-2) \pmod{7} \\ &= 4(x^2 - 3x + 2) \equiv 4x^2 - 5x + 1 \pmod{7} \end{aligned}$$



Similarmente calculamos  $\ell_1(x)$  y  $\ell_2(x)$ . El interpolante es:

$$p(x) = 1 \cdot \ell_0(x) + 3 \cdot \ell_1(x) + 2 \cdot \ell_2(x) \equiv 5x^2 + 6x + 1 \pmod{7}.$$

Verificación:

$$p(0) = 1 \equiv 1 \pmod{7} \quad \checkmark$$

$$p(1) = 5 + 6 + 1 = 12 \equiv 5 \pmod{7} \quad (\text{jerror de cálculo! revisar})$$

$$p(2) = 20 + 12 + 1 = 33 \equiv 5 \pmod{7}$$

### 3.3.4 Aplicación: Esquema de secreto compartido de Shamir

Una aplicación elegante de la interpolación en  $\mathbb{Z}_p$  es el **esquema de Shamir** (1979) para compartir un secreto de manera segura.

**Definición 3.35** (Esquema de Shamir  $(n, k)$ -threshold). **Objetivo:** Dividir un secreto  $s \in \mathbb{Z}_p$  entre  $n$  participantes de modo que:

- Cualquier grupo de  $k$  participantes puede reconstruir  $s$ .
- Cualquier grupo de  $k - 1$  o menos participantes no obtiene ninguna información sobre  $s$ .

**Protocolo:**

#### 1. Distribución de shares:

(a) Elegir aleatoriamente  $a_1, a_2, \dots, a_{k-1} \in \mathbb{Z}_p$ .

(b) Construir el polinomio (en  $\mathbb{Z}_p$ ):

$$p(x) = s + a_1x + a_2x^2 + \dots + a_{k-1}x^{k-1} \pmod{p}.$$

(c) Distribuir los **shares**: participante  $i$  recibe  $(i, p(i) \bmod p)$  para  $i = 1, 2, \dots, n$ .

#### 2. Reconstrucción del secreto:

(a) Reunir  $k$  shares cualesquiera:  $(x_{i_1}, y_{i_1}), \dots, (x_{i_k}, y_{i_k})$ .

(b) Interpolar (Lagrange en  $\mathbb{Z}_p$ ) para obtener  $p(x)$ .

(c) Recuperar  $s = p(0) \bmod p$ .

**Teorema 3.36** (Seguridad perfecta de Shamir). El esquema de Shamir tiene las siguientes propiedades:

1. **Corrección:** Con  $k$  shares, el secreto se reconstruye correctamente.
2. **Seguridad perfecta:** Con  $k-1$  shares o menos, todos los valores de  $s \in \mathbb{Z}_p$  son igualmente probables.

*Demostración.* **(1) Corrección:** El polinomio  $p(x)$  de grado  $k-1$  está únicamente determinado por  $k$  puntos (teorema de interpolación). Como  $s = p(0)$ , se recupera exactamente.

**(2) Seguridad perfecta:** Supongamos que un adversario tiene  $k-1$  shares. Fijemos cualquier valor tentativo  $s' \in \mathbb{Z}_p$  para el secreto. ¿Existe un polinomio  $p'(x)$  de grado  $k-1$  tal que:

- $p'(0) = s'$  (el secreto tentativo),
- $p'$  pasa por los  $k-1$  shares conocidos?

La respuesta es **sí**: esto especifica  $k$  condiciones (valor en 0 más  $k-1$  shares) para un polinomio de grado  $k-1$ , que tiene  $k$  coeficientes libres. El sistema tiene solución única.

Más aún, como los coeficientes  $a_1, \dots, a_{k-1}$  se eligieron uniformemente al azar de  $\mathbb{Z}_p$ , todos los valores de  $s \in \mathbb{Z}_p$  son igualmente probables dado cualquier conjunto de  $k-1$  shares. Por lo tanto, el adversario no aprende *nada* sobre  $s$ .  $\square$

### Ejemplo numérico:

**Ejemplo 3.37** (Shamir en  $\mathbb{Z}_{97}$ ). Queremos compartir el secreto  $s = 42$  entre  $n = 5$  participantes, requiriendo  $k = 3$  para reconstruir. Trabajamos en  $\mathbb{Z}_{97}$ .

**Paso 1:** Elegimos aleatoriamente  $a_1 = 15, a_2 = 67$  en  $\mathbb{Z}_{97}$ . El polinomio es:

$$p(x) = 42 + 15x + 67x^2 \pmod{97}.$$

**Paso 2:** Generamos shares evaluando  $p(i)$  para  $i = 1, \dots, 5$ :

$$\text{Share 1: } (1, p(1)) = (1, 42 + 15 + 67) = (1, 27)$$

$$\text{Share 2: } (2, p(2)) = (2, 42 + 30 + 268) = (2, 49)$$

$$\text{Share 3: } (3, p(3)) = (3, 42 + 45 + 603) = (3, 11)$$

$$\text{Share 4: } (4, p(4)) = (4, 42 + 60 + 1072) = (4, 89)$$

$$\text{Share 5: } (5, p(5)) = (5, 42 + 75 + 1675) = (5, 16)$$

(todas las operaciones módulo 97).

**Paso 3:** Para reconstruir, usamos shares 1, 3, 5 (por ejemplo):

$$\text{Interpolar en } \mathbb{Z}_{97} : \{(1, 27), (3, 11), (5, 16)\}$$

Por interpolación de Lagrange obtenemos  $p(x) = 42 + 15x + 67x^2 \pmod{97}$ . El secreto es  $s = p(0) = 42$ .

**Implementación:** Ver `interpolacion_algebraica.py`:

- `shamir_generar_shares(secreto, n, k, p)`: Genera  $n$  shares.
- `shamir_reconstruir(shares, p)`: Reconstruye el secreto a partir de  $\geq k$  shares.

### 3.3.5 Aplicación: Códigos de Reed-Solomon

Los **códigos de Reed-Solomon** son códigos de corrección de errores basados en evaluación de polinomios sobre  $\mathbb{Z}_p$  (o más generalmente, sobre  $\mathbb{F}_q$ ).

**Definición 3.38** (Código Reed-Solomon  $RS(n, k)$ ). *Parámetros:*

- $k$ : longitud del mensaje (número de símbolos de información).
- $n$ : longitud del código ( $n > k$ , símbolos redundantes).
- $\mathbb{F}_q$ : Cuerpo finito con  $q \geq n$  elementos.
- $\alpha_1, \dots, \alpha_n \in \mathbb{F}_q$ : puntos de evaluación distintos.

**Codificación:** Un mensaje  $(m_0, m_1, \dots, m_{k-1}) \in \mathbb{F}_q^k$  se codifica como:

1. Interpretar el mensaje como coeficientes:  $m(x) = m_0 + m_1x + \dots + m_{k-1}x^{k-1}$ .
2. Evaluar en los  $n$  puntos:  $\mathbf{c} = (m(\alpha_1), m(\alpha_2), \dots, m(\alpha_n))$ .

El vector  $\mathbf{c} \in \mathbb{F}_q^n$  es la **palabra código**.

**Decodificación:** Dada una palabra posiblemente corrupta  $\mathbf{r} = \mathbf{c} + \mathbf{e}$  (error  $\mathbf{e}$ ):

1. Si hay  $\leq \lfloor (n-k)/2 \rfloor$  errores, usar algoritmos de decodificación (Berlekamp-Welch, Euclides, etc.) para recuperar  $m(x)$ .
2. Extraer el mensaje original de los coeficientes de  $m(x)$ .

**Teorema 3.39** (Capacidad de corrección de Reed-Solomon). El código  $RS(n, k)$  puede:

- **Detectar** hasta  $n - k$  errores.
- **Corregir** hasta  $\lfloor (n - k)/2 \rfloor$  errores.

*Idea.* La **distancia mínima** del código es  $d = n - k + 1$ . Dos palabras código distintas provienen de polinomios distintos  $m_1(x), m_2(x) \in \mathcal{P}_{k-1}(\mathbb{F}_q)$ . Su diferencia  $\Delta(x) = m_1(x) - m_2(x)$  es no nula y tiene grado  $< k$ , por lo que tiene a lo sumo  $k - 1$  raíces en  $\mathbb{F}_q$ .

Por lo tanto, las evaluaciones de  $m_1$  y  $m_2$  difieren en al menos  $n - (k - 1) = n - k + 1$  posiciones. Esta distancia mínima permite:

- Detectar hasta  $d - 1 = n - k$  errores (si hay  $\leq n - k$  errores, la palabra recibida no es válida).
- Corregir hasta  $\lfloor (d - 1)/2 \rfloor = \lfloor (n - k)/2 \rfloor$  errores (por teoría de codificación).

□

#### Aplicaciones de Reed-Solomon:

- **CDs y DVDs:** Protección contra rayones y defectos.
- **Códigos QR:** Recuperación de datos parcialmente dañados.
- **Comunicaciones espaciales:** NASA/ESA usan RS para transmisiones desde sondas.
- **Almacenamiento distribuido:** RAID 6 usa RS para tolerar fallas de discos.

## Chapter 4

# Teoría de Aproximación

En los capítulos anteriores desarrollamos dos grandes herramientas para construir aproximaciones. En el capítulo de Álgebra Lineal Numérica estudiamos la mejor aproximación de un vector por elementos de un subespacio, en el sentido de mínimos cuadrados. La fórmula de proyección ortogonal (B.1) nos permitió expresar esta aproximación de manera explícita en términos de una base ortogonal del subespacio. En el capítulo de Interpolación vimos cómo construir polinomios que pasan exactamente por un conjunto de puntos dados, utilizando para ello diferentes bases de polinomios, como la base monomial, la base de Lagrange, y en el caso complejo la base de los modos de Fourier discretos.

En este capítulo queremos dar un paso más: obtener representaciones de funciones en bases de funciones, extendiendo la fórmula de proyección (B.1) a espacios de dimensión infinita. La idea es la misma que en el caso finito-dimensional: si  $\{\phi_k\}_{k \in \mathcal{I}}$  es una familia ortogonal en un espacio de funciones dotado de un producto interno apropiado, los coeficientes  $\hat{f}_k = (f, \phi_k) / \|\phi_k\|^2$  definen una representación

$$f \sim \sum_{k \in \mathcal{I}} \hat{f}_k \phi_k,$$

que llamamos *serie* de  $f$  en la base  $\{\phi_k\}$ .

A diferencia del caso finito-dimensional, esta suma es en general infinita y surgen dos preguntas centrales. La primera es la convergencia: ¿en qué sentido tiende la serie completa a  $f$ ? Y si la serie converge, la segunda pregunta es ¿Con qué velocidad lo hace? Equivalentemente, si retenemos sólo los primeros  $N$  términos de la representación, ¿cuán grande es el error  $\|f - \sum_{|k| \leq N} \hat{f}_k \phi_k\|$ ? Las respuestas dependen de la regularidad de  $f$  y de la elección de la base, y su análisis es el hilo conductor de este capítulo.

### 4.1 Series de Fourier de funciones suaves periódicas

Para todo  $n \geq 1$ , el espacio de funciones  $n$  veces continuamente diferenciables y periódicas se define como:

$$C_{per}^n([0, 2\pi]) = \left\{ f \in C^n([0, 2\pi]) : f^{(p)}(0) = f^{(p)}(2\pi) \text{ para todo } 0 \leq p \leq n-1 \right\}.$$

La condición de periodicidad hasta el orden  $n-1$  garantiza que la extensión de  $f$  por periodicidad a todo  $\mathbb{R}$  es de clase  $C^{n-1}$ : en particular  $f$  es continua y periódica, y para  $n \geq 2$  también lo

es  $f'$ , y así sucesivamente.

### 4.1.1 La base exponencial compleja

Para funciones a valores complejos  $f, g : [0, 2\pi] \rightarrow \mathbb{C}$ , la integral se define componente a componente: si  $f = u + iv$  con  $u, v$  reales, entonces  $\int_0^{2\pi} f dx = \int_0^{2\pi} u dx + i \int_0^{2\pi} v dx$ . Con esta convención, el espacio  $C_{per}^n([0, 2\pi])$  queda dotado del producto interno:

$$(f, g) = \int_0^{2\pi} f(x) \overline{g(x)} dx, \quad (4.1)$$

donde  $\overline{g(x)}$  denota el conjugado complejo. Para cada  $N \in \mathbb{N}$ , la base de exponenciales complejas es:

$$B_N^{\mathbb{C}} = \{e^{ikx} : k \in \mathbb{Z}, |k| \leq N\} \subset C_{per}^{\infty}([0, 2\pi]). \quad (4.2)$$

**Teorema 4.1** (Ortogonalidad de la base exponencial). *Para  $k, l \in \mathbb{Z}$ :*

$$(e^{ikx}, e^{ilx}) = \int_0^{2\pi} e^{i(k-l)x} dx = \begin{cases} 2\pi & \text{si } k = l, \\ 0 & \text{si } k \neq l. \end{cases}$$

En particular,  $\|e^{ikx}\|^2 = 2\pi$  para todo  $k \in \mathbb{Z}$ .

*Demostración.* Si  $k = l$ :  $\int_0^{2\pi} 1 dx = 2\pi$ . Si  $k \neq l$ , sea  $m = k - l \neq 0$ :

$$\int_0^{2\pi} e^{imx} dx = \left[ \frac{e^{imx}}{im} \right]_0^{2\pi} = \frac{e^{2\pi im} - 1}{im} = 0,$$

pues  $e^{2\pi im} = 1$  para todo  $m \in \mathbb{Z}$ . □

Los **coeficientes de Fourier** de  $f$  son sus coordenadas en  $B_N^{\mathbb{C}}$  según la fórmula de proyección (B.1):

$$\hat{f}_k = \frac{(f, e^{ikx})}{\|e^{ikx}\|^2} = \frac{1}{2\pi} \int_0^{2\pi} f(x) e^{-ikx} dx, \quad k \in \mathbb{Z}. \quad (4.3)$$

La **suma parcial de Fourier** de orden  $N$  es  $S_N f(x) = \sum_{|k| \leq N} \hat{f}_k e^{ikx}$ , y la **serie de Fourier** de  $f$ :

$$f(x) \sim \sum_{k=-\infty}^{\infty} \hat{f}_k e^{ikx}. \quad (4.4)$$

Como  $S_N f$  es la proyección ortogonal de  $f$  sobre  $\langle B_N^{\mathbb{C}} \rangle$ , es el polinomio trigonométrico de grado  $\leq N$  más cercano a  $f$  en norma cuadrática.

**Teorema 4.2** (Propiedad de mejor aproximación). *Sea  $f \in L^2([0, 2\pi]; \mathbb{C})$  y  $N \geq 0$ . Para todo polinomio trigonométrico  $p = \sum_{|k| \leq N} c_k e^{ikx}$ :*

$$\|f - S_N f\|_2 \leq \|f - p\|_2,$$

donde  $\|h\|_2 = \left( \int_0^{2\pi} |h(x)|^2 dx \right)^{1/2}$ .

*Demostración.* Escribimos  $p = S_N f + q$  con  $q = p - S_N f \in \langle B_N^{\mathbb{C}} \rangle$ . Como  $f - S_N f \perp \langle B_N^{\mathbb{C}} \rangle$  por construcción de  $S_N f$  como proyección ortogonal, la identidad de Pitágoras da:

$$\|f - p\|_2^2 = \|f - S_N f\|_2^2 + \|q\|_2^2 \geq \|f - S_N f\|_2^2. \quad \square$$

**Observación 4.3** (Notación). *En este capítulo utilizamos  $i$  para la unidad imaginaria ( $i^2 = -1$ ), siguiendo la convención matemática estándar. En ingeniería eléctrica y procesamiento de señales se usa a veces la notación  $j$ ; ambas son equivalentes:  $i \equiv j$ .*

#### 4.1.2 La serie trigonométrica real

Cuando  $f$  toma valores reales, los coeficientes de Fourier presentan una estructura de simetría que permite reescribir la serie en términos de senos y cosenos.

**Proposición 4.4** (Simetría conjugada). *Sea  $f : [0, 2\pi] \rightarrow \mathbb{R}$  integrable. Entonces  $\hat{f}_{-k} = \overline{\hat{f}_k}$  para todo  $k \in \mathbb{Z}$ .*

*Demostración.* Como  $\overline{f(x)} = f(x)$ :

$$\overline{\hat{f}_k} = \frac{1}{2\pi} \int_0^{2\pi} \overline{f(x) e^{-ikx}} dx = \frac{1}{2\pi} \int_0^{2\pi} f(x) e^{ikx} dx = \hat{f}_{-k}. \quad \square$$

Esta simetría permite agrupar los pares de frecuencia  $\pm k$  en la suma parcial:

$$\hat{f}_k e^{ikx} + \hat{f}_{-k} e^{-ikx} = \hat{f}_k e^{ikx} + \overline{\hat{f}_k} e^{-ikx} = 2 \operatorname{Re}(\hat{f}_k e^{ikx}). \quad (4.5)$$

Escribiendo  $\hat{f}_k = \frac{a_k - ib_k}{2}$  con  $a_k, b_k \in \mathbb{R}$  y usando  $e^{ikx} = \cos(kx) + i \sin(kx)$ :

$$2 \operatorname{Re}(\hat{f}_k e^{ikx}) = a_k \cos(kx) + b_k \sin(kx).$$

La evaluación directa de (4.3) con  $e^{-ikx} = \cos(kx) - i \sin(kx)$  muestra que  $a_k = 2 \operatorname{Re}(\hat{f}_k)$  y  $b_k = -2 \operatorname{Im}(\hat{f}_k)$  coinciden con las integrales:

**Definición 4.5** (Coeficientes de Fourier reales y suma parcial). *Sea  $f : [0, 2\pi] \rightarrow \mathbb{R}$  integrable. Sus coeficientes de Fourier reales son:*

$$a_k = \frac{1}{\pi} \int_0^{2\pi} f(x) \cos(kx) dx \quad (k \geq 0), \quad b_k = \frac{1}{\pi} \int_0^{2\pi} f(x) \sin(kx) dx \quad (k \geq 1). \quad (4.6)$$

*La suma parcial de Fourier real de orden  $N$  es:*

$$S_N(f)(x) = \frac{a_0}{2} + \sum_{k=1}^N (a_k \cos(kx) + b_k \sin(kx)). \quad (4.7)$$

La equivalencia con la suma parcial compleja es inmediata de (4.5): para  $f$  real,  $S_N f(x) = \hat{f}_0 + \sum_{k=1}^N [\hat{f}_k e^{ikx} + \hat{f}_{-k} e^{-ikx}] = \frac{a_0}{2} + \sum_{k=1}^N [a_k \cos(kx) + b_k \sin(kx)]$ .

**Observación 4.6.** *La ortogonalidad del conjunto  $\{1, \cos(x), \sin(x), \dots, \cos(Nx), \sin(Nx)\}$  en  $L^2([0, 2\pi])$  se obtiene sin verificación adicional: es una consecuencia del Teorema 4.1 y del cambio de base (4.5). El Teorema 4.2 se extiende también al caso real: para  $f$  real,  $S_N(f)$  es el polinomio trigonométrico real de grado  $\leq N$  más cercano a  $f$  en  $L^2([0, 2\pi])$ .*

### 4.1.3 Decaimiento de los coeficientes de Fourier y regularidad

**Teorema 4.7** (Lema de Riemann-Lebesgue para funciones  $C^1$ ). Si  $g \in C^1([a, b])$ , entonces

$$\int_a^b g(t) e^{i\omega t} dt \rightarrow 0 \quad (|\omega| \rightarrow \infty).$$

*Demostración.* Sea

$$J(\omega) := \int_a^b g(t) e^{i\omega t} dt.$$

Integramos por partes con  $u = g(t)$  y  $dv = e^{i\omega t} dt$ :

$$J(\omega) = \left[ \frac{g(t) e^{i\omega t}}{i\omega} \right]_a^b - \frac{1}{i\omega} \int_a^b g'(t) e^{i\omega t} dt.$$

Tomando módulo:

$$|J(\omega)| \leq \frac{|g(a)| + |g(b)|}{|\omega|} + \frac{1}{|\omega|} \int_a^b |g'(t)| dt \xrightarrow{|\omega| \rightarrow \infty} 0.$$

□

**Corolario 4.8.** Si  $g \in C^1([a, b])$ , entonces

$$\int_a^b g(t) \sin(\omega t) dt \rightarrow 0, \quad \int_a^b g(t) \cos(\omega t) dt \rightarrow 0, \quad (|\omega| \rightarrow \infty).$$

*Demostración.* Por Euler,

$$\int_a^b g(t) e^{i\omega t} dt = \int_a^b g(t) \cos(\omega t) dt + i \int_a^b g(t) \sin(\omega t) dt.$$

Si un número complejo tiende a 0, también tienden a 0 su parte real e imaginaria. Aplicando el Teorema 4.7, se obtiene el resultado. □

En el contexto periódico de Fourier, la misma idea se itera y los términos de borde se anulan exactamente.

**Lema 4.9** (Coeficientes de Fourier de la derivada). Sea  $f \in C_{per}^1([0, 2\pi])$ . Entonces, para todo  $k \in \mathbb{Z}$ :

$$\widehat{f'}_k = ik \widehat{f}_k.$$

En particular, para  $k \neq 0$ ,

$$\widehat{f}_k = \frac{1}{ik} \widehat{f'}_k. \quad (4.8)$$

*Demostración.* Por definición,

$$\widehat{f'}_k = \frac{1}{2\pi} \int_0^{2\pi} f'(x) e^{-ikx} dx.$$

Integrando por partes:

$$\widehat{f'}_k = \frac{1}{2\pi} \left[ f(x) e^{-ikx} \right]_0^{2\pi} + \frac{ik}{2\pi} \int_0^{2\pi} f(x) e^{-ikx} dx.$$

El término de borde se anula por periodicidad de  $f$  y porque  $e^{-2\pi ik} = 1$ . Luego  $\widehat{f'}_k = ik \widehat{f}_k$ . □

**Teorema 4.10** (Decaimiento de los coeficientes de Fourier). Sea  $f \in C_{per}^n([0, 2\pi])$  con  $n \geq 1$ . Entonces, para todo  $k \in \mathbb{Z}$  con  $k \neq 0$ :

$$\hat{f}_k = \frac{\widehat{f^{(n)}}_k}{(ik)^n}, \quad |\hat{f}_k| \leq \frac{C}{|k|^n},$$

donde  $C = \frac{1}{2\pi} \int_0^{2\pi} |f^{(n)}(x)| dx$ .

*Demostración.* Aplicando el Lema 4.9 sucesivamente a  $f, f', \dots, f^{(n-1)}$  (válido por periodicidad y regularidad), para  $k \neq 0$  se obtiene

$$\hat{f}_k = \frac{\widehat{f^{(n)}}_k}{(ik)^n}.$$

Finalmente,

$$|\hat{f}_k| = \frac{|\widehat{f^{(n)}}_k|}{|k|^n} \leq \frac{1}{|k|^n} \cdot \frac{1}{2\pi} \int_0^{2\pi} |f^{(n)}(x)| dx = \frac{C}{|k|^n}. \quad \square$$

**Corolario 4.11** (Decaimiento algebraico por regularidad finita). Si  $f \in C_{per}^k([0, 2\pi])$  con  $k \geq 1$ , entonces

$$|\hat{f}_n| = O(|n|^{-k}) \quad (|n| \rightarrow \infty).$$

Más precisamente, existe  $C_k > 0$  tal que  $|\hat{f}_n| \leq C_k/|n|^k$  para todo  $n \neq 0$ .

*Demostración.* Es el Teorema 4.10 aplicado con  $n = k$ .  $\square$

**Corolario 4.12.** Si  $f \in C_{per}^\infty([0, 2\pi])$ , entonces para todo  $n \in \mathbb{N}$  existe  $C_n > 0$  tal que  $|\hat{f}_k| \leq C_n/|k|^n$ . Esto se conoce como decaimiento espectral o super-algebraico.

#### 4.1.4 Convergencia de la serie de Fourier para funciones suaves

Los resultados anteriores sobre decaimiento permiten organizar la convergencia en dos pasos: cota elemental del truncado y convergencia para  $C_{per}^1$  mediante núcleo de Dirichlet y Riemann-Lebesgue.

**Lema 4.13** (Cota elemental de truncamiento). Sea  $f \in C_{per}^n([0, 2\pi])$  con  $n \geq 1$ . Para todo  $N \geq 1$ :

$$\sum_{|k| > N} |\hat{f}_k| \leq \frac{\|f^{(n)}\|_{L^2}}{\sqrt{\pi(2n-1)}} \frac{1}{N^{n-1/2}}.$$

*Demostración.* Para  $k \neq 0$ , el Teorema 4.10 da  $\hat{f}_k = \widehat{f^{(n)}}_k / (ik)^n$ . Por Cauchy-Schwarz,

$$\sum_{|k| > N} |\hat{f}_k| = \sum_{|k| > N} \frac{|\widehat{f^{(n)}}_k|}{|k|^n} \leq \left( \sum_{|k| > N} |\widehat{f^{(n)}}_k|^2 \right)^{1/2} \left( \sum_{|k| > N} |k|^{-2n} \right)^{1/2}.$$

Por Bessel (Teorema C.6),

$$\sum_{k \in \mathbb{Z}} |\widehat{f^{(n)}}_k|^2 \leq \frac{\|f^{(n)}\|_{L^2}^2}{2\pi}.$$



Además,

$$\sum_{|k|>N} |k|^{-2n} = 2 \sum_{k=N+1}^{\infty} k^{-2n} \leq 2 \int_N^{\infty} x^{-2n} dx = \frac{2}{(2n-1)N^{2n-1}}.$$

Combinando,

$$\sum_{|k|>N} |\hat{f}_k| \leq \sqrt{\frac{\|f^{(n)}\|_{L^2}^2}{2\pi} \cdot \frac{2}{(2n-1)N^{2n-1}}} = \frac{\|f^{(n)}\|_{L^2}}{\sqrt{\pi(2n-1)}} \frac{1}{N^{n-1/2}}.$$

La segunda desigualdad sigue de  $\left| \sum_{|k|>N} \hat{f}_k e^{ikx} \right| \leq \sum_{|k|>N} |\hat{f}_k|$ .  $\square$

**Lema 4.14** (Núcleo de Dirichlet). *La suma parcial de Fourier admite la representación*

$$S_N f(x) = \frac{1}{2\pi} \int_0^{2\pi} f(x-t) D_N(t) dt,$$

donde

$$D_N(t) = \sum_{k=-N}^N e^{ikt} = \frac{\sin((N + \frac{1}{2})t)}{\sin(t/2)}, \quad \frac{1}{2\pi} \int_0^{2\pi} D_N(t) dt = 1.$$

*Demostración.* Partimos de  $S_N f(x) = \sum_{k=-N}^N \hat{f}_k e^{ikx}$  y sustituimos  $\hat{f}_k = \frac{1}{2\pi} \int_0^{2\pi} f(u) e^{-iku} du$ :

$$S_N f(x) = \frac{1}{2\pi} \int_0^{2\pi} f(u) \sum_{k=-N}^N e^{ik(x-u)} du.$$

Con el cambio  $u = x - t$  (periodicidad) se obtiene la fórmula de convolución. La expresión cerrada de  $D_N$  resulta de la suma geométrica finita y la normalización de integrar término a término.  $\square$

**Teorema 4.15** (Convergencia para funciones  $C^1$ ). *Sea  $f \in C_{per}^1([0, 2\pi])$ . Entonces, para todo  $x \in [0, 2\pi]$ ,*

$$S_N f(x) \rightarrow f(x).$$

*Demostración.* Por el Lema 4.14 y la normalización de  $D_N$ ,

$$S_N f(x) - f(x) = \frac{1}{2\pi} \int_0^{2\pi} (f(x-t) - f(x)) D_N(t) dt.$$

Usando la forma cerrada de  $D_N$ ,

$$S_N f(x) - f(x) = \frac{1}{2\pi} \int_0^{2\pi} g_x(t) \sin((N + \frac{1}{2})t) dt,$$

donde

$$g_x(t) := \frac{f(x-t) - f(x)}{\sin(t/2)}$$

y se define por continuidad en  $t = 0$  y  $t = 2\pi$ . Como  $f \in C_{per}^1$ , el cociente tiene singularidad removible y  $g_x \in C([0, 2\pi])$ .

Aplicando el Corolario 4.7 a  $g_x$ , el integral tiende a 0 cuando  $N \rightarrow \infty$ . Concluimos  $S_N f(x) \rightarrow f(x)$ .  $\square$

**Teorema 4.16** (Convergencia uniforme y cota cuantitativa). *Sea  $f \in C_{per}^n([0, 2\pi])$  con  $n \geq 1$ . Entonces*

$$\|f - S_N f\|_\infty \leq \frac{\|f^{(n)}\|_{L^2}}{\sqrt{\pi(2n-1)}} \frac{1}{N^{n-1/2}},$$

y en particular  $\|f - S_N f\|_\infty = O(N^{1/2-n})$ .

*Demostración.* Como  $n \geq 1$ , se tiene  $f \in C_{per}^1$  y por el Teorema 4.15 la serie de Fourier converge uniformemente a  $f$ . Luego

$$\|f - S_N f\|_\infty = \left\| \sum_{|k|>N} \hat{f}_k e^{ikx} \right\|_\infty \leq \sum_{|k|>N} |\hat{f}_k|,$$

y la cota final es la del Lema 4.13. □

**Observación 4.17** (Mejora tipo Jackson). *Bajo las mismas hipótesis, un resultado más fino de teoría de aproximación (debido a Jackson) da la tasa óptima en norma uniforme:*

$$\|f - S_N(f)\|_\infty = O(N^{-n}).$$

*Es decir, la cota del Teorema 4.16 no es óptima en la potencia de  $N$ , aunque se obtiene con una demostración elemental basada en decaimiento de coeficientes y Cauchy-Schwarz.*

#### 4.1.5 Cuadratura de funciones suaves y periódicas

El cálculo numérico de los coeficientes de Fourier requiere evaluar las integrales:

$$\hat{f}_k = \frac{1}{2\pi} \int_0^{2\pi} f(x) e^{-ikx} dx.$$

En la práctica estas integrales raramente admiten fórmula cerrada. Sin embargo, la herramienta necesaria ya fue desarrollada en el Capítulo 3: la regla del trapecio compuesta.

**Observación 4.18** (Los coeficientes discretos de Fourier son la regla del trapecio). *Apliquemos la regla del trapecio compuesta con  $M$  subintervalos iguales de ancho  $h = 2\pi/M$  a la integral  $\int_0^{2\pi} g(x) dx$  con  $g(x) = f(x)e^{-ikx}$ . Los nodos son  $x_j = jh = 2\pi j/M$  para  $j = 0, \dots, M$ . La regla del trapecio compuesta da:*

$$\int_0^{2\pi} g(x) dx \approx \frac{h}{2} [g(x_0) + 2g(x_1) + \dots + 2g(x_{M-1}) + g(x_M)].$$

*Pero  $g$  es  $2\pi$ -periódica (producto de funciones  $2\pi$ -periódicas), de modo que  $g(x_M) = g(x_0)$ . Los dos extremos se promedian:  $\frac{1}{2}[g(x_0) + g(x_M)] = g(x_0)$ , y la fórmula se simplifica a:*

$$\int_0^{2\pi} g(x) dx \approx h \sum_{j=0}^{M-1} g(x_j) = \frac{2\pi}{M} \sum_{j=0}^{M-1} f(x_j) e^{-ikx_j}.$$

Dividiendo por  $2\pi$ , obtenemos la aproximación de  $\hat{f}_k$ :

$$\hat{f}_k \approx \tilde{f}_k^{(M)} := \frac{1}{M} \sum_{j=0}^{M-1} f(x_j) e^{-ikx_j}.$$

Esta es exactamente la **Transformada Discreta de Fourier (DFT)** del vector de muestras  $(f(x_0), \dots, f(x_{M-1}))^T$  (con la convención de normalización  $1/M$ , consistente con la Definición ??). No se trata de una coincidencia: los “coeficientes de Fourier discretos” son la regla del trapecio aplicada a la integral de los coeficientes exactos.

La estructura de la DFT permite calcular los  $M$  coeficientes  $\tilde{f}_0^{(M)}, \dots, \tilde{f}_{M-1}^{(M)}$  simultáneamente en  $O(M \log M)$  operaciones mediante el algoritmo **FFT** (Fast Fourier Transform), en lugar de las  $O(M^2)$  que requeriría la evaluación directa.

**Observación 4.19** (Aliasing). Los coeficientes discretos son periódicos en la frecuencia:  $\tilde{f}_{k+M}^{(M)} = \tilde{f}_k^{(M)}$ , ya que  $e^{-i(k+M)x_j} = e^{-ikx_j} \cdot e^{-iMx_j} = e^{-ikx_j}$  (porque  $Mx_j = 2\pi j$ ). En consecuencia, el coeficiente discreto  $\tilde{f}_k^{(M)}$  no solo aproxima  $\hat{f}_k$  sino que captura la contribución de todas las frecuencias  $k + mM$  ( $m \in \mathbb{Z}$ ):

$$\tilde{f}_k^{(M)} = \sum_{m=-\infty}^{\infty} \hat{f}_{k+mM}.$$

Este fenómeno se denomina **aliasing**: las frecuencias altas  $|k + mM|$  con  $m \neq 0$  “se disfrazan” de la frecuencia baja  $k$  al muestrear en una malla finita. Para funciones suaves cuyos coeficientes decaen rápidamente, los términos con  $m \neq 0$  son despreciables y  $\tilde{f}_k^{(M)} \approx \hat{f}_k$ .

La efectividad de la regla del trapecio para funciones periódicas suaves es extraordinaria, y se explica con la siguiente observación.

**Lema 4.20** (Exactitud de la cuadratura trapezoidal para exponenciales complejas). Sea  $M \geq 1$  entero,  $h = 2\pi/M$  y  $x_j = jh$  para  $j = 0, \dots, M-1$ . Entonces:

$$\frac{1}{M} \sum_{j=0}^{M-1} e^{i\ell x_j} = \begin{cases} 1 & \text{si } \ell \text{ es múltiplo de } M, \\ 0 & \text{en caso contrario.} \end{cases}$$

Es decir, la regla del trapecio periódica integra **exactamente** a  $e^{i\ell x}$  siempre que  $\ell$  no sea múltiplo no nulo de  $M$ .

*Demostración.* Si  $\ell \equiv 0 \pmod{M}$ , cada sumando vale  $e^{i\ell \cdot 2\pi j/M} = e^{2\pi i j \cdot (\ell/M)} = 1$ , y la suma da  $M/M = 1$ .

Si  $\ell \not\equiv 0 \pmod{M}$ , definimos  $w = e^{2\pi i \ell/M} \neq 1$  y sumamos la serie geométrica:

$$\sum_{j=0}^{M-1} w^j = \frac{w^M - 1}{w - 1} = \frac{e^{2\pi i \ell} - 1}{w - 1} = 0,$$

ya que  $e^{2\pi i \ell} = 1$  para todo  $\ell \in \mathbb{Z}$ . □

**Teorema 4.21** (Convergencia espectral del trapecio periódico). Sea  $f \in C_{per}^n([0, 2\pi])$  con  $n \geq 2$ . Entonces el error de la regla del trapecio periódica con  $M$  nodos satisface:

$$\left| \int_0^{2\pi} f(x) dx - \frac{2\pi}{M} \sum_{j=0}^{M-1} f(x_j) \right| = O(M^{-n}).$$

Para  $f \in C_{per}^\infty$ , la convergencia es más rápida que cualquier potencia de  $1/M$  (**convergencia espectral**).

*Demostración.* Por el Lema 4.20, la cuadratura trapezoidal integra exactamente a  $e^{ikx}$  para  $|k| < M$ . Escribiendo  $f$  como su serie de Fourier (que converge uniformemente por el Teorema 4.16):

$$\frac{1}{M} \sum_{j=0}^{M-1} f(x_j) = \sum_{k=-\infty}^{\infty} \hat{f}_k \cdot \frac{1}{M} \sum_{j=0}^{M-1} e^{ikx_j} = \sum_{\substack{k \in \mathbb{Z} \\ M|k}} \hat{f}_k = \hat{f}_0 + \sum_{\substack{m \neq 0 \\ m \in \mathbb{Z}}} \hat{f}_{mM}.$$

Como  $\int_0^{2\pi} f(x) dx = 2\pi \hat{f}_0$ , el error de cuadratura es:

$$\frac{2\pi}{M} \sum_{j=0}^{M-1} f(x_j) - \int_0^{2\pi} f(x) dx = 2\pi \sum_{m \neq 0} \hat{f}_{mM}.$$

Del Teorema de decaimiento,  $|\hat{f}_k| \leq C/|k|^n$ . Entonces:

$$\left| \sum_{m \neq 0} \hat{f}_{mM} \right| \leq \sum_{m \neq 0} \frac{C}{|mM|^n} = \frac{C}{M^n} \cdot 2 \sum_{m=1}^{\infty} \frac{1}{m^n} = \frac{2C \zeta(n)}{M^n} = O(M^{-n}). \quad \square$$

**Observación 4.22** (Contraste con funciones no periódicas). Para una función  $f \in C^m([a, b])$  no periódica, la regla del trapecio solo tiene error  $O(M^{-2})$ , independientemente de la suavidad de  $f$ . La periodicidad elimina los errores en los extremos del intervalo y permite aprovechar plenamente la suavidad de la función.

#### 4.1.6 El fenómeno de Gibbs

Las series de Fourier son extraordinariamente efectivas para funciones periódicas. Sin embargo, presentan limitaciones significativas cuando se aplican a funciones no periódicas:

1. **Fenómeno de Gibbs:** Si  $f$  no es periódica, su extensión periódica presenta discontinuidades en los extremos, causando oscilaciones cerca de estos puntos que no desaparecen al aumentar el número de términos.
2. **Convergencia lenta:** Para funciones suaves pero no periódicas, la convergencia de la serie de Fourier es típicamente algebraica en lugar de exponencial.
3. **Condiciones de frontera:** Es difícil imponer condiciones de frontera específicas usando bases trigonométricas.

**Ejemplo 4.23** (La función  $f(x) = x$  y el fenómeno de Gibbs). Consideremos  $f(x) = x$  en  $[-\pi, \pi]$ . La función es suave, pero no es periódica:  $f(-\pi) = -\pi \neq \pi = f(\pi)$ . Su extensión  $2\pi$ -periódica tiene un salto de magnitud  $2\pi$  en cada punto  $x = (2k+1)\pi$ .

La serie de Fourier de  $f$  se calcula por integración por partes:

$$f(x) = \sum_{k=1}^{\infty} \frac{2(-1)^{k+1}}{k} \sin(kx) = 2 \sin x - \sin 2x + \frac{2}{3} \sin 3x - \dots$$

La serie converge a  $f(x)$  para todo  $x \in (-\pi, \pi)$ , pero los coeficientes decaen como  $O(1/k)$ : la convergencia es muy lenta.

La Figura 4.1 muestra las sumas parciales  $S_N(x) = \sum_{k=1}^N \frac{2(-1)^{k+1}}{k} \sin(kx)$  para varios valores de  $N$ . Se observa claramente el fenómeno de Gibbs: cerca de los puntos de discontinuidad  $x = \pm\pi$ , la suma parcial presenta una oscilación que sobrepasa el valor de la función en aproximadamente un 9% del salto ( $\approx 0.18\pi \approx 0.5655$ ). Esta oscilación no desaparece al aumentar  $N$ : se estrecha, pero su altura converge a un valor fijo.

Fenómeno de Gibbs: serie de Fourier de  $f(x) = x$  en  $[-\pi, \pi]$




Figure 4.1: Sumas parciales de la serie de Fourier de  $f(x) = x$  para  $N = 3, 7, 25, 100$ . Las oscilaciones cerca de  $x = \pm\pi$  (fenómeno de Gibbs) no desaparecen al aumentar  $N$ .

## 4.2 Series de Chebyshev

Las series de Fourier son una herramienta poderosa para aproximar funciones periódicas, ofreciendo convergencia espectral para funciones suaves. Sin embargo, la mayoría de las funciones que encontramos en aplicaciones (como soluciones de ecuaciones diferenciales con condiciones de frontera) no son periódicas. Si intentamos aproximar una función no periódica  $f(x)$  en  $[-1, 1]$  usando series de Fourier, nos encontramos con el **fenómeno de Gibbs** en los extremos, lo que destruye la convergencia uniforme.

¿Podemos "salvar" la convergencia espectral para funciones no periódicas? La respuesta es sí, mediante un simple cambio de variable.

### 4.2.1 De Fourier a Chebyshev: El cambio de variable coseno

Consideremos una función  $f(x)$  definida en  $[-1, 1]$ . Hacemos el cambio de variable:

$$x = \cos(\theta), \quad \theta \in [0, \pi].$$

Definimos una nueva función  $g(\theta)$  compuesta:

$$g(\theta) = f(\cos(\theta)).$$

Esta función  $g(\theta)$  tiene propiedades notables:

1. Está definida en  $[0, \pi]$ .
2. Podemos extenderla a  $[-\pi, \pi]$  como una función **par** ( $g(-\theta) = f(\cos(-\theta)) = f(\cos(\theta)) = g(\theta)$ ).
3. Podemos extenderla a todo  $\mathbb{R}$  como una función  $2\pi$ -periódica.

**Lema 4.24** (Suavidad de la extensión periódica). *Sea  $f \in C^m([-1, 1])$  con  $m \geq 0$ . Entonces la función  $g(\theta) = f(\cos \theta)$ , extendida a todo  $\mathbb{R}$  por paridad y  $2\pi$ -periodicidad, pertenece a  $C_{per}^m(\mathbb{R})$ . En particular,  $g$  es suave en los puntos de pegado  $\theta = k\pi$  ( $k \in \mathbb{Z}$ ) sin imponer ninguna condición de periodicidad sobre  $f$ .*

*Demostración.* La paridad de  $g$  es inmediata:  $g(-\theta) = f(\cos(-\theta)) = f(\cos \theta) = g(\theta)$ . En el interior  $(0, \pi)$ , la función  $\cos \theta$  es  $C^\infty$  con imagen en  $(-1, 1)$ , así que  $g = f \circ \cos$  es  $C^m$  por la regla de la cadena.

El punto clave es la regularidad en los extremos. Calculemos la primera derivada:

$$g'(\theta) = -f'(\cos \theta) \sin \theta.$$

Como  $\sin 0 = \sin \pi = 0$ , se tiene  $g'(0) = g'(\pi) = 0$ . Pero  $g$  es par, así que  $g'$  es impar:  $g'(-\theta) = -g'(\theta)$ . Entonces  $g'(0^+) = -g'(0^-) = g'(0^+)$ , lo que fuerza  $g'(0) = 0$  (la derivada se "pega" suavemente). El mismo argumento, usando  $g(\pi - \varphi) = f(-\cos \varphi)$ , da  $g'(\pi^-) = g'(\pi^+)$ .

Para las derivadas de orden superior, el mecanismo es el mismo: cada derivada  $g^{(j)}(\theta)$  es una combinación de términos  $f^{(r)}(\cos \theta)$  multiplicados por potencias de  $\sin \theta$  y  $\cos \theta$ . Por la paridad de  $g$ , las derivadas de orden impar son funciones impares y se anulan en  $\theta = 0$ ; las de orden par son funciones pares y tienen límites laterales iguales. Esto garantiza que  $g \in C^m$  en un entorno de  $\theta = 0$ . El caso  $\theta = \pi$  se reduce al anterior sustituyendo  $f$  por  $\tilde{f}(x) = f(-x)$ , y el pegado periódico ( $\theta = -\pi$  con  $\theta = \pi$ ) es consecuencia directa de la paridad.  $\square$

Este lema es la razón fundamental por la que las series de Chebyshev evitan el fenómeno de Gibbs: la composición con el coseno convierte cualquier función suave en  $[-1, 1]$  en una función periódica igualmente suave, sin introducir discontinuidades artificiales en los puntos de pegado.

Por el Lema 4.24,  $g \in C_{per}^m(\mathbb{R})$  y podemos desarrollarla en serie de Fourier. Como  $g$  es par, la serie solo tiene términos cosenos:

$$g(\theta) = \frac{a_0}{2} + \sum_{k=1}^{\infty} a_k \cos(k\theta),$$

con coeficientes  $a_k = \frac{2}{\pi} \int_0^\pi g(\theta) \cos(k\theta) d\theta$ . Para volver a la variable original  $x = \cos \theta$ , introducimos la siguiente notación.

#### 4.2.2 Las funciones de Chebyshev y la serie de Chebyshev

**Definición 4.25** (Funciones de Chebyshev). *Para cada entero  $k \geq 0$ , definimos la **función de Chebyshev**  $T_k : [-1, 1] \rightarrow \mathbb{R}$  por:*

$$T_k(x) = \cos(k \arccos x).$$

La definición es natural:  $T_k$  es simplemente la función  $\cos(k\theta)$  expresada en la variable  $x = \cos \theta$ . En otras palabras,  $T_k(\cos \theta) = \cos(k\theta)$ . Con esta notación, la serie de Fourier en cosenos de  $g(\theta) = f(\cos \theta)$  se reescribe directamente en la variable original:

**Definición 4.26** (Serie de Chebyshev). *Dada  $f \in C([-1, 1])$ , su **serie de Chebyshev** es:*

$$f(x) = \frac{a_0}{2} + \sum_{k=1}^{\infty} a_k T_k(x),$$

con coeficientes  $a_k = \frac{2}{\pi} \int_{-1}^1 f(x) T_k(x) \frac{dx}{\sqrt{1-x^2}}$  (obtenidos del cambio  $x = \cos \theta$  en la fórmula  $a_k = \frac{2}{\pi} \int_0^\pi g(\theta) \cos(k\theta) d\theta$ ).

La serie de Chebyshev no es otra cosa que la serie de Fourier en cosenos de  $g$ , traducida a la variable  $x$  mediante la correspondencia  $\cos(k\theta) \leftrightarrow T_k(x)$ . Por lo tanto, hereda inmediatamente todas las propiedades de convergencia de la serie de Fourier.

**Teorema 4.27** (Decaimiento de coeficientes de Chebyshev). *Si  $f \in C^m([-1, 1])$  con  $m \geq 1$ , entonces sus coeficientes de Chebyshev satisfacen:*

$$|a_k| = O(k^{-m}).$$

*Demostración.* Por el Lema 4.24,  $g(\theta) = f(\cos \theta) \in C_{per}^m(\mathbb{R})$ . Los coeficientes  $a_k$  son exactamente los coeficientes de Fourier en cosenos de  $g$ . El Teorema 4.10 aplicado a  $g$  da  $|a_k| = O(k^{-m})$ .  $\square$

Esto significa que para funciones suaves (pero no necesariamente periódicas), la serie de Chebyshev converge tan rápido como la serie de Fourier para funciones periódicas de la misma regularidad. Si además  $f$  es analítica en  $[-1, 1]$ , los coeficientes decaen *exponencialmente*.

### 4.2.3 Las funciones de Chebyshev son polinomios

Hasta aquí, las funciones  $T_k(x) = \cos(k \arccos x)$  son simplemente funciones trigonométricas disfrazadas. El siguiente resultado, quizás sorprendente, muestra que en realidad son *polinomios*.

**Teorema 4.28** (Las funciones de Chebyshev son polinomios). *Para cada  $k \geq 0$ , la función  $T_k(x) = \cos(k \arccos x)$  es un polinomio de grado exactamente  $k$ , con coeficiente líder  $2^{k-1}$  para  $k \geq 1$ .*

*Demostración.* La clave es la identidad trigonométrica  $\cos((k+1)\theta) = 2 \cos \theta \cos(k\theta) - \cos((k-1)\theta)$ , que se traduce en la **recurrencia de tres términos**:

$$T_{k+1}(x) = 2x T_k(x) - T_{k-1}(x), \quad k \geq 1.$$

Las condiciones iniciales son  $T_0(x) = \cos(0) = 1$  y  $T_1(x) = \cos(\arccos x) = x$ . Ambos son polinomios (de grados 0 y 1 respectivamente). Como el lado derecho de la recurrencia es un polinomio si  $T_k$  y  $T_{k-1}$  lo son, por inducción  $T_k$  es un polinomio para todo  $k$ . Además, si  $T_k$  tiene grado  $k$  con coeficiente líder  $c_k$ , entonces  $T_{k+1}$  tiene grado  $k+1$  con coeficiente líder  $2c_k$ , lo que da  $c_k = 2^{k-1}$  para  $k \geq 1$ .  $\square$

**Ejemplo 4.29** (Primeros polinomios de Chebyshev). *Aplicando la recurrencia:*

$$\begin{aligned} T_0(x) &= 1, \\ T_1(x) &= x, \\ T_2(x) &= 2x^2 - 1, \\ T_3(x) &= 4x^3 - 3x, \\ T_4(x) &= 8x^4 - 8x^2 + 1. \end{aligned}$$

*Se puede verificar directamente:  $T_2(\cos \theta) = 2 \cos^2 \theta - 1 = \cos(2\theta)$  y  $T_3(\cos \theta) = 4 \cos^3 \theta - 3 \cos \theta = \cos(3\theta)$ , que son las identidades trigonométricas clásicas del ángulo doble y triple.*

### 4.2.4 Ortogonalidad

La ortogonalidad de las funciones trigonométricas  $\{\cos(k\theta)\}$  se transfiere, vía el cambio de variable  $x = \cos \theta$ , a una relación de ortogonalidad para los polinomios de Chebyshev.

**Teorema 4.30** (Ortogonalidad de los polinomios de Chebyshev). *Los polinomios de Chebyshev son ortogonales respecto al peso  $w(x) = (1-x^2)^{-1/2}$  en  $[-1, 1]$ :*

$$\int_{-1}^1 T_j(x) T_k(x) \frac{dx}{\sqrt{1-x^2}} = \begin{cases} \pi & \text{si } j = k = 0, \\ \pi/2 & \text{si } j = k \neq 0, \\ 0 & \text{si } j \neq k. \end{cases}$$

*Demostración.* Hacemos el cambio  $x = \cos \theta$ ,  $dx = -\sin \theta d\theta$ , y  $\sqrt{1-x^2} = \sin \theta$ :

$$\int_{-1}^1 T_j(x) T_k(x) \frac{dx}{\sqrt{1-x^2}} = \int_0^\pi \cos(j\theta) \cos(k\theta) d\theta.$$



La integral del lado derecho satisface

$$\int_0^\pi \cos(j\theta) \cos(k\theta) d\theta = \begin{cases} \pi, & j = k = 0, \\ \pi/2, & j = k \neq 0, \\ 0, & j \neq k. \end{cases} \quad (4.9)$$

y esto prueba la ortogonalidad enunciada.  $\square$

**Observación 4.31** (Raíces y extremos de  $T_k$ ). *De la identidad  $T_k(\cos \theta) = \cos(k\theta)$  se deducen inmediatamente:*

- **Raíces:**  $T_k(x_j) = 0$  con  $x_j = \cos\left(\frac{(2j+1)\pi}{2k}\right)$  para  $j = 0, \dots, k-1$ . Son los **nodos de Chebyshev**, que minimizan el error de interpolación polinomial.
- **Extremos:**  $|T_k(x)| = 1$  en los puntos  $x_j = \cos(j\pi/k)$  para  $j = 0, \dots, k$ , alternando entre  $+1$  y  $-1$ .
- **Acotación:**  $|T_k(x)| \leq 1$  para todo  $x \in [-1, 1]$ .

### 4.3 Polinomios Ortogonales (Series de Fourier Generalizadas)

En las secciones anteriores obtuvimos dos resultados de aproximación notablemente similares:

- **Series de Fourier:** expansión en la base  $\{e^{ikx}\}$ , ortogonal respecto al producto interno

$$\langle f, g \rangle = \frac{1}{2\pi} \int_0^{2\pi} f(x) \overline{g(x)} dx,$$

con convergencia espectral: si  $f \in C_{\text{per}}^m$ , los coeficientes decaen como  $|\hat{f}_k| = O(|k|^{-m})$  (Teorema 4.10).

- **Series de Chebyshev:** expansión en la base  $\{T_k\}$ , ortogonal respecto al producto interno con peso

$$(f, g)_w = \int_{-1}^1 f(x) g(x) \frac{dx}{\sqrt{1-x^2}},$$

con la misma convergencia espectral: si  $f \in C^m([-1, 1])$ , los coeficientes decaen como  $|\tilde{f}_k| = O(k^{-m})$  (Teorema 4.27).

La similitud no es casual. En ambos casos, la estructura es idéntica: un *producto interno*, una *base ortogonal*, *coeficientes de proyección* y un *decaimiento controlado por la suavidad* de  $f$ . Esto sugiere un marco general que contenga a ambos como casos particulares: las **series de Fourier generalizadas**, es decir, expansiones en bases ortogonales asociadas a distintos productos internos con peso. Cada elección de peso produce una familia de polinomios ortogonales —Chebyshev, Legendre, Laguerre, Hermite, entre otras— con sus propias ventajas según el dominio y el tipo de función, pero que comparten la misma arquitectura teórica.

### 4.3.1 Marco general: espacios con producto interno

Recordemos las nociones de álgebra lineal que unifican los ejemplos anteriores.

**Definición 4.32** (Producto interno con peso). *Dado un intervalo  $(a, b)$  y una función de peso  $w(x) > 0$  integrable, el **producto interno con peso** es*

$$(f, g)_w = \int_a^b f(x) g(x) w(x) dx.$$

La norma asociada es  $\|f\|_w = \sqrt{(f, f)_w}$ . Denotamos  $L_w^2(a, b)$  al espacio de funciones con  $\|f\|_w < \infty$ .

**Definición 4.33** (Base ortogonal y coeficientes de proyección). *Una familia  $\{\varphi_k\}_{k=0}^\infty$  en  $L_w^2(a, b)$  es **ortogonal** si  $(\varphi_j, \varphi_k)_w = 0$  para  $j \neq k$ . Dada  $f \in L_w^2$ , sus **coeficientes de proyección** son*

$$c_k = \frac{(f, \varphi_k)_w}{\|\varphi_k\|_w^2},$$

y la **proyección de orden  $n$  (o suma parcial)** es

$$S_n f = \sum_{k=0}^n c_k \varphi_k.$$

Estas definiciones recuperan ambos casos conocidos: para Fourier,  $\varphi_k(x) = e^{ikx}$  con peso uniforme en  $[0, 2\pi]$ ; para Chebyshev,  $\varphi_k(x) = T_k(x)$  con peso  $(1 - x^2)^{-1/2}$  en  $[-1, 1]$ .

Las dos propiedades fundamentales de la proyección ortogonal son:

**Teorema 4.34** (Mejor aproximación e identidad de Parseval). *Sea  $\{\varphi_k\}$  una base ortogonal de  $L_w^2(a, b)$  y  $S_n f$  la proyección de orden  $n$ . Entonces:*

1. **Mejor aproximación:**  $S_n f$  minimiza el error  $\|f - g\|_w$  entre todas las combinaciones lineales  $g \in \text{span}\{\varphi_0, \dots, \varphi_n\}$ .
2. **Identidad de Parseval para el resto:**

$$\|f - S_n f\|_w^2 = \sum_{k=n+1}^{\infty} |c_k|^2 \|\varphi_k\|_w^2. \quad (4.10)$$

*Demostración.* Sea  $g = \sum_{k=0}^n a_k \varphi_k$  una combinación lineal arbitraria. Entonces:

$$\|f - g\|_w^2 = \left\| f - S_n f + \sum_{k=0}^n (c_k - a_k) \varphi_k \right\|_w^2 = \|f - S_n f\|_w^2 + \sum_{k=0}^n |c_k - a_k|^2 \|\varphi_k\|_w^2,$$

donde la igualdad usa que  $f - S_n f$  es ortogonal a cada  $\varphi_k$  con  $k \leq n$  (verificación:  $(f - S_n f, \varphi_j)_w = (f, \varphi_j)_w - c_j \|\varphi_j\|_w^2 = 0$ ). El mínimo se alcanza cuando  $a_k = c_k$  para todo  $k$ , probando (1).

Para (2), la ortogonalidad de  $\{\varphi_k\}$  da:

$$\|f - S_n f\|_w^2 = \left\| \sum_{k>n} c_k \varphi_k \right\|_w^2 = \sum_{k>n} |c_k|^2 \|\varphi_k\|_w^2. \quad \square$$

La consecuencia central es que **el error de proyección está completamente determinado por la velocidad de decaimiento de los coeficientes  $c_k$** . Si podemos demostrar que  $|c_k| = O(k^{-m})$  para una base ortogonal dada, la ecuación (4.10) traduce inmediatamente esta información en una cota del error.

### 4.3.2 Familias clásicas de polinomios ortogonales

Cuando las funciones de la base  $\varphi_k$  son polinomios de grado  $k$ , hablamos de **polinomios ortogonales**. Las familias clásicas más importantes son:

| Familia         | Intervalo           | Peso $w(x)$      | Autovalor SL $\lambda_n$ |
|-----------------|---------------------|------------------|--------------------------|
| Legendre $P_n$  | $[-1, 1]$           | 1                | $n(n+1)$                 |
| Chebyshev $T_n$ | $[-1, 1]$           | $(1-x^2)^{-1/2}$ | $n^2$                    |
| Laguerre $L_n$  | $[0, \infty)$       | $e^{-x}$         | $n$                      |
| Hermite $H_n$   | $(-\infty, \infty)$ | $e^{-x^2}$       | $2n$                     |

La columna “Autovalor SL” se explica más adelante: será la herramienta para demostrar el decaimiento espectral en el caso general.

**Propiedades compartidas por todas las familias clásicas:**

1. **Recurrencia a tres términos:**  $P_{n+1}(x) = (A_n x + B_n)P_n(x) - C_n P_{n-1}(x)$ . Permite evaluar  $P_n(x)$  de forma estable y eficiente.
2. **Raíces reales simples:**  $P_n(x)$  tiene exactamente  $n$  raíces reales, simples y contenidas en  $(a, b)$ . Estas raíces son los nodos óptimos para cuadratura.

### 4.3.3 Tasa de convergencia para funciones suaves: un caso general

El resultado más profundo de esta teoría conecta la suavidad de una función con la velocidad de convergencia de su expansión en polinomios ortogonales. Esta conexión surge porque los polinomios clásicos son autofunciones de operadores diferenciales de **Sturm-Liouville**:

$$L[P_n] = -\frac{1}{w} \frac{d}{dx} \left( p(x) \frac{dP_n}{dx} \right) = \lambda_n P_n.$$

**Teorema 4.35** (Decaimiento espectral de coeficientes). *Sea  $f \in C^m([a, b])$  una función  $m$  veces diferenciable (compatible con las condiciones de frontera). Los coeficientes de su expansión  $c_n = \frac{(f, P_n)_w}{\|P_n\|_w^2}$  satisfacen:*

$$|c_n| = O(\lambda_n^{-m/2}).$$

Para Legendre y Chebyshev ( $\lambda_n \sim n^2$ ), esto implica  $|c_n| = O(n^{-m})$ .

*Demostración.* El operador de Sturm-Liouville  $L$  es formalmente autoadjunto respecto al producto interno con peso  $w$ . Más precisamente, para funciones  $u, v$  que satisfacen las condiciones de frontera apropiadas (que los polinomios ortogonales clásicos satisfacen automáticamente), se cumple la **identidad de Green-Lagrange**:

$$(Lu, v)_w = (u, Lv)_w,$$

donde  $(u, v)_w = \int_a^b u(x)v(x)w(x) dx$ . Esto se verifica por integración por partes: como  $L[u] = -\frac{1}{w} \frac{d}{dx}(p u')$ , tenemos  $\int L[u]vw = -\int (pu')'v$ , y al integrar por partes los términos de frontera se anulan gracias a que  $p(x)$  se anula en los extremos del intervalo para las familias clásicas (por ejemplo, para Legendre:  $p(x) = 1 - x^2$  en  $[-1, 1]$ ; para Chebyshev:  $p(x) = \sqrt{1 - x^2}$ ; para Laguerre:  $p(x) = xe^{-x}$ ).

Ahora, como  $L[P_n] = \lambda_n P_n$ , tenemos:

$$c_n \|P_n\|_w^2 = (f, P_n)_w = \frac{1}{\lambda_n} (f, L[P_n])_w = \frac{1}{\lambda_n} (L[f], P_n)_w,$$

donde la última igualdad usa la autoadjunción de  $L$  (válida si  $f$  satisface las condiciones de frontera; en caso contrario, aparecen términos de frontera que decaen con  $n$  y no afectan el orden asintótico).

Repitiendo el argumento  $k$  veces (si  $f \in C^{2k}$ ):

$$c_n \|P_n\|_w^2 = \frac{1}{\lambda_n^k} (L^k[f], P_n)_w.$$

Por la desigualdad de Cauchy-Schwarz:

$$|c_n| \|P_n\|_w^2 \leq \frac{1}{\lambda_n^k} \|L^k[f]\|_{L_w^2} \|P_n\|_{L_w^2}.$$

Distribuyendo:

$$|c_n| \leq \frac{\|L^k[f]\|_{L_w^2}}{\lambda_n^k \|P_n\|_{L_w^2}}.$$

Para las familias clásicas con  $\lambda_n \sim n(n+1) \sim n^2$  y  $\|P_n\|_{L_w^2}$  acotado inferior y superiormente por constantes independientes de  $n$ , obtenemos  $|c_n| = O(n^{-2k})$ . Tomando  $2k = m$  (la máxima regularidad disponible):  $|c_n| = O(n^{-m})$ .  $\square$

## 4.4 Cuadratura Gaussiana

### 4.4.1 Motivación y definición

En la Sección 3.2.2 construimos reglas de cuadratura interpolatorias eligiendo  $n$  nodos  $x_1, \dots, x_n$  y determinando los pesos  $w_k$  para que la regla

$$Q_n(f) = \sum_{k=1}^n w_k f(x_k)$$

sea exacta para polinomios de grado  $\leq n-1$  (los que se interpolan exactamente). Vimos que, con nodos equiespaciados, esta estrategia puede fallar para  $n$  grande (fenómeno de Runge, pesos negativos).

La pregunta natural es: ¿podemos elegir *también los nodos* de manera óptima? Si con  $n$  evaluaciones de  $f$  queremos máxima exactitud polinomial, tenemos  $2n$  parámetros libres ( $n$  nodos y  $n$  pesos), así que cabe esperar exactitud para polinomios de grado  $\leq 2n-1$ . La **cuadratura de Gauss** logra exactamente esto, y los nodos óptimos resultan ser las raíces de los polinomios ortogonales con respecto al peso  $w$ .

**Definición 4.36** (Regla de cuadratura de Gauss). Sea  $w(x) > 0$  una función de peso en  $(a, b)$  y  $\{P_k\}$  los polinomios ortogonales correspondientes. La **regla de cuadratura de Gauss de  $n$  puntos** usa como nodos las  $n$  raíces  $x_1, \dots, x_n$  de  $P_n$ , y como pesos

$$w_k = \int_a^b \ell_k(x) w(x) dx, \quad \ell_k(x) = \prod_{\substack{j=1 \\ j \neq k}}^n \frac{x - x_j}{x_k - x_j}.$$

La aproximación de la integral es  $\int_a^b f(x) w(x) dx \approx Q_n(f) = \sum_{k=1}^n w_k f(x_k)$ .

#### 4.4.2 Exactitud y positividad

**Teorema 4.37** (Exactitud de grado  $2n-1$ ). La regla de cuadratura de Gauss de  $n$  puntos es exacta para todo polinomio de grado  $\leq 2n-1$ :

$$\int_a^b p(x) w(x) dx = \sum_{k=1}^n w_k p(x_k) \quad \forall p \in \Pi_{2n-1}.$$

Más aún, ninguna regla con  $n$  nodos puede ser exacta para todo polinomio de grado  $2n$ .

*Demostración.* **Exactitud para  $\Pi_{2n-1}$ .** Sea  $p \in \Pi_{2n-1}$ . Dividimos  $p$  por  $P_n$  (que tiene grado exacto  $n$ ):

$$p(x) = q(x) P_n(x) + r(x), \quad q \in \Pi_{n-1}, \quad r \in \Pi_{n-1}.$$

Integrando contra el peso:

$$\int_a^b p w = \int_a^b q P_n w + \int_a^b r w.$$

El primer término es cero: como  $q \in \Pi_{n-1}$ , es combinación lineal de  $P_0, \dots, P_{n-1}$ , y cada  $P_k$  con  $k < n$  es ortogonal a  $P_n$  por definición de polinomios ortogonales. Queda  $\int_a^b p w = \int_a^b r w$ .

Ahora evaluamos  $Q_n(p)$ . En cada nodo  $x_k$  (raíz de  $P_n$ ), tenemos  $P_n(x_k) = 0$ , así que  $p(x_k) = r(x_k)$  y

$$Q_n(p) = \sum_{k=1}^n w_k p(x_k) = \sum_{k=1}^n w_k r(x_k) = Q_n(r).$$

Como  $r \in \Pi_{n-1}$  y  $Q_n$  es al menos una regla interpolatoria (exacta en  $\Pi_{n-1}$  por construcción vía polinomios de Lagrange), resulta  $Q_n(r) = \int_a^b r w$ . Combinando:  $Q_n(p) = \int_a^b p w$ .

**Optimalidad.** Para ver que grado  $2n$  es imposible con  $n$  nodos, basta tomar  $p(x) = \prod_{k=1}^n (x - x_k)^2 \in \Pi_{2n}$ , que satisface  $p(x_k) = 0$  para todo  $k$  pero  $\int_a^b p w > 0$  (pues  $p \geq 0$  y  $p \not\equiv 0$  en  $(a, b)$ ).  $\square$

**Teorema 4.38** (Positividad de los pesos). Los pesos de la cuadratura de Gauss son estrictamente positivos:

$$w_k = \int_a^b \ell_k^2(x) w(x) dx > 0.$$

*Demostración.* Para cada  $k$ , el polinomio  $\ell_k^2 \in \Pi_{2n-2} \subset \Pi_{2n-1}$  satisface  $\ell_k^2(x_j) = \delta_{jk}$ . Por la exactitud del teorema anterior:

$$w_k = \sum_{j=1}^n w_j \ell_k^2(x_j) = \int_a^b \ell_k^2(x) w(x) dx > 0. \quad \square$$

La positividad de los pesos es crucial para la estabilidad numérica: garantiza que no haya cancelaciones catastróficas al sumar los términos  $w_k f(x_k)$ .

#### 4.4.3 Error de cuadratura

Definimos el **error de cuadratura** de una función  $f$  como

$$E_n(f) = \int_a^b f(x) w(x) dx - Q_n(f).$$

El Teorema 4.37 dice que  $E_n(p) = 0$  para  $p \in \Pi_{2n-1}$ . En particular,  $E_n(p) = 0$  para todo  $p \in \Pi_{n-1}$ . Esto permite conectar el error de cuadratura con el error de la **proyección ortogonal**  $S_{n-1}f = \sum_{k=0}^{n-1} c_k P_k$ .

**Teorema 4.39** (Cota del error en términos de la proyección). *Para toda  $f \in L_w^2(a, b)$  continua, el error de la cuadratura de Gauss satisface:*

$$|E_n(f)| \leq C_n \|f - S_{n-1}f\|_w,$$

donde  $C_n = \sqrt{\sum_{k=1}^n w_k} = \sqrt{\mu_0}$ , con  $\mu_0 = \int_a^b w(x) dx$ .

*Demostración.* Como  $E_n(p) = 0$  para todo  $p \in \Pi_{n-1}$ , y  $S_{n-1}f \in \Pi_{n-1}$ , tenemos

$$E_n(f) = E_n(f - S_{n-1}f).$$

Sea  $g = f - S_{n-1}f$ . Entonces:

$$E_n(g) = \int_a^b g(x) w(x) dx - \sum_{k=1}^n w_k g(x_k).$$

Acotamos cada término por separado.

**Término integral.** Por Cauchy-Schwarz:

$$\left| \int_a^b g w \right| = |(g, 1)_w| \leq \|g\|_w \|1\|_w = \sqrt{\mu_0} \|g\|_w.$$

**Término de cuadratura.** Por Cauchy-Schwarz discreto, usando  $w_k > 0$ :

$$\left| \sum_{k=1}^n w_k g(x_k) \right| \leq \left( \sum_{k=1}^n w_k \right)^{1/2} \left( \sum_{k=1}^n w_k g(x_k)^2 \right)^{1/2} = \sqrt{\mu_0} \left( \sum_{k=1}^n w_k g(x_k)^2 \right)^{1/2}.$$

La suma  $\sum_{k=1}^n w_k g(x_k)^2 = Q_n(g^2)$  es la cuadratura de Gauss aplicada a  $g^2$ . Como los pesos son positivos:

$$Q_n(g^2) \leq \int_a^b g(x)^2 w(x) dx = \|g\|_w^2,$$

donde la desigualdad se obtiene notando que  $Q_n(g^2)$  es una evaluación numérica con pesos positivos y  $g^2 \geq 0$ ; para funciones  $g$  con desarrollo en  $\{P_k\}$ , la cuadratura subestima  $\|g\|_w^2$  porque las frecuencias altas ( $k \geq n$ ) sufren aliasing. Así:

$$\left| \sum_{k=1}^n w_k g(x_k) \right| \leq \sqrt{\mu_0} \|g\|_w.$$

**Conclusión:**

$$|E_n(f)| = |E_n(g)| \leq 2\sqrt{\mu_0} \|g\|_w = 2\sqrt{\mu_0} \|f - S_{n-1}f\|_w. \quad \square$$

**Observación 4.40** (Interpretación y consecuencias). *El Teorema 4.39 dice que el error de cuadratura gaussiana hereda directamente la velocidad de convergencia de la proyección ortogonal. Combinando con la identidad de Parseval (4.10) y el decaimiento  $|c_k| = O(k^{-m})$ , si  $f \in C^m([a, b])$ :*

$$|E_n(f)| \leq C \|f - S_{n-1}f\|_w = O(n^{(1-2m)/2}),$$

*que tiende a cero más rápido que cualquier potencia de  $n$  si  $f$  es  $C^\infty$ . Esto es la **convergencia espectral de la cuadratura de Gauss**: para funciones muy suaves, agregar un solo nodo puede ganar varios órdenes de precisión.*

#### 4.4.4 Cálculo de nodos y pesos: Método de Golub-Welsch

Aunque las raíces de los polinomios ortogonales clásicos están tabuladas, para  $n$  grande o pesos no estándar es necesario calcularlas numéricamente. El método de Golub-Welsch (1969) transforma el problema de búsqueda de raíces en un problema de autovalores, explotando la recurrencia a tres términos.

Los polinomios ortogonales mónicos  $\pi_k$  satisfacen:

$$\pi_{k+1}(x) = (x - \alpha_k)\pi_k(x) - \beta_k\pi_{k-1}(x),$$

con  $\beta_k > 0$ . Esta relación puede escribirse en forma matricial como:

$$x\pi(x) = J_n\pi(x) + \pi_n(x)\mathbf{e}_n,$$

donde  $\pi(x) = [\pi_0(x), \dots, \pi_{n-1}(x)]^T$  y  $J_n$  es la **matriz de Jacobi** tridiagonal simétrica:

$$J_n = \begin{pmatrix} \alpha_0 & \sqrt{\beta_1} & & & \\ \sqrt{\beta_1} & \alpha_1 & \sqrt{\beta_2} & & \\ & \sqrt{\beta_2} & \alpha_2 & \ddots & \\ & & \ddots & \ddots & \sqrt{\beta_{n-1}} \\ & & & \sqrt{\beta_{n-1}} & \alpha_{n-1} \end{pmatrix}.$$

**Teorema 4.41** (Golub-Welsch). *Los nodos de la cuadratura de Gauss de  $n$  puntos son los autovalores de  $J_n$ . Los pesos están dados por:*

$$w_k = \mu_0 (v_{k,1})^2,$$

donde  $\mu_0 = \int_a^b w(x) dx$  y  $v_{k,1}$  es la primera componente del autovector normalizado de  $J_n$  correspondiente al autovalor  $x_k$ .

*Demostración. Nodos como autovalores.* Sea  $x_j$  una raíz de  $\pi_n$ . Evaluando la relación vectorial en  $x = x_j$ :

$$x_j \pi(x_j) = J_n \pi(x_j) + \underbrace{\pi_n(x_j)}_{=0} \mathbf{e}_n = J_n \pi(x_j).$$

Como  $\pi_0(x_j) = 1 \neq 0$ , el vector  $\pi(x_j)$  es no nulo, y  $x_j$  es autovalor de  $J_n$  con autovector  $\pi(x_j)$ . Como  $J_n$  es tridiagonal simétrica con subdiagonal positiva, tiene  $n$  autovalores simples.

**Fórmula para los pesos.** Para  $0 \leq r, s \leq n-1$ , el producto  $\pi_r(x)\pi_s(x) \in \Pi_{2n-2}$  es integrado exactamente por la cuadratura de Gauss. Definiendo la matriz  $V$  con  $V_{jk} = \pi_k(x_j)$  y  $W = \text{diag}(w_1, \dots, w_n)$ :

$$V^T W V = D, \quad D = \text{diag}(\|\pi_0\|_w^2, \dots, \|\pi_{n-1}\|_w^2),$$

por la ortogonalidad de los polinomios. Los autovectores normalizados de  $J_n$  forman  $Q$  con  $Q^T Q = I$ , y  $V = Q \cdot \text{diag}(\|\pi(x_1)\|_2, \dots, \|\pi(x_n)\|_2)$ . Sustituyendo y usando  $\hat{v}_{k,1} = 1/\|\pi(x_k)\|_2$  (pues  $\pi_0 = 1$ ):

$$w_k = \mu_0 (\hat{v}_{k,1})^2. \quad \square$$

**Observación 4.42.** *El método es extremadamente robusto y eficiente ( $O(n^2)$  con el algoritmo QR para matrices tridiagonales simétricas), y permite calcular reglas de cuadratura para cualquier peso cuyos coeficientes de recurrencia  $\alpha_k, \beta_k$  se conozcan. Para las familias clásicas estos tienen fórmulas cerradas; para pesos generales pueden obtenerse por el algoritmo de Stieltjes.*

## 4.5 Del error de proyección al error de interpolación

Las secciones anteriores establecieron que los coeficientes de la expansión de una función  $f$  en una base ortogonal (Fourier, Chebyshev, o polinomios ortogonales generales) decaen a una tasa determinada por la regularidad de  $f$ . Este decaimiento tiene una consecuencia inmediata para la calidad de la **proyección ortogonal** (el truncamiento de la serie).

En esta sección, nos interesa estudiar cómo este decaimiento afecta también la calidad de la **interpolación**. La clave es que, aunque la interpolación y la proyección son operaciones distintas, están estrechamente relacionadas. En esta sección formalizamos esta conexión, que es uno de los resultados centrales y más útiles de la teoría de aproximación en el curso.

### 4.5.1 Error de interpolación de Fourier

Consideremos una función  $f \in C_{per}^m([0, 2\pi])$  con  $m \geq 2$  y su serie de Fourier  $f(x) = \sum_{k \in \mathbb{Z}} \hat{f}_k e^{ikx}$ . La **proyección de Fourier** de orden  $N$  es:

$$S_N f(x) = \sum_{|k| \leq N} \hat{f}_k e^{ikx},$$



y el **interpolante trigonométrico**  $I_N f$  se obtiene a partir de los  $2N + 1$  valores  $f(x_j)$  en los nodos equiespaciados  $x_j = 2\pi j/(2N + 1)$ ,  $j = 0, \dots, 2N$ :

$$I_N f(x) = \sum_{|k| \leq N} \tilde{f}_k e^{ikx}, \quad \tilde{f}_k = \frac{1}{2N + 1} \sum_{j=0}^{2N} f(x_j) e^{-ikx_j}.$$

Los coeficientes discretos  $\tilde{f}_k$  difieren de los coeficientes exactos  $\hat{f}_k$  por el fenómeno de **aliasing**: la ortogonalidad discreta de las exponenciales en los  $2N + 1$  nodos equiespaciados da:

$$\frac{1}{2N + 1} \sum_{j=0}^{2N} e^{i(k-l)x_j} = \begin{cases} 1 & \text{si } k - l \equiv 0 \pmod{2N + 1}, \\ 0 & \text{en caso contrario.} \end{cases}$$

Sustituyendo la serie de Fourier de  $f$  en la fórmula de  $\tilde{f}_k$ , obtenemos la **fórmula de aliasing**:

$$\tilde{f}_k = \sum_{m \in \mathbb{Z}} \hat{f}_{k+m(2N+1)}, \quad |k| \leq N. \quad (4.11)$$

Es decir, el coeficiente discreto  $\tilde{f}_k$  “ve” no solo la frecuencia  $k$ , sino también todas las frecuencias  $k + m(2N + 1)$  para  $m \neq 0$ .

**Teorema 4.43** (Error de interpolación trigonométrica). *Sea  $f \in C_{per}^m([0, 2\pi])$  con  $m \geq 2$ . Entonces:*

$$\|f - I_N f\|_\infty \leq 2 \sum_{|k| > N} |\hat{f}_k|.$$

Como  $|\hat{f}_k| = O(|k|^{-m})$ , esta cota es  $O(N^{1-m})$ .

*Demostración.* Descomponemos el error de interpolación usando la proyección como término intermedio. Como  $I_N$  reproduce exactamente los polinomios trigonométricos de grado  $\leq N$  (es decir,  $I_N(S_N f) = S_N f$ ), tenemos:

$$f - I_N f = \underbrace{(f - S_N f)}_{\text{cola de la serie}} - \underbrace{I_N(f - S_N f)}_{\text{aliasing}}.$$

**Cota de la cola.** Usando  $|e^{ikx}| = 1$ :

$$\|f - S_N f\|_\infty = \left\| \sum_{|k| > N} \hat{f}_k e^{ikx} \right\|_\infty \leq \sum_{|k| > N} |\hat{f}_k|.$$

**Cota del aliasing.** El polinomio trigonométrico  $I_N(f - S_N f)$  tiene coeficientes  $\tilde{f}_k - \hat{f}_k$  para  $|k| \leq N$ . Por la fórmula de aliasing (4.11):

$$\tilde{f}_k - \hat{f}_k = \sum_{m \neq 0} \hat{f}_{k+m(2N+1)}.$$

Crucialmente, la función  $k \mapsto k + m(2N + 1)$  es inyectiva: cada coeficiente  $\hat{f}_j$  con  $|j| > N$  aparece como “alias” de **exactamente un** coeficiente  $\tilde{f}_k$  con  $|k| \leq N$  (el único  $k \in \{-N, \dots, N\}$  tal que  $j \equiv k \pmod{2N + 1}$ ). Por lo tanto:

$$\sum_{|k| \leq N} |\tilde{f}_k - \hat{f}_k| \leq \sum_{|j| > N} |\hat{f}_j|.$$

Usando esta cota y  $|e^{ikx}| = 1$ :

$$\|I_N(f - S_N f)\|_\infty \leq \sum_{|k| \leq N} |\tilde{f}_k - \hat{f}_k| \leq \sum_{|j| > N} |\hat{f}_j|.$$

**Conclusión.** Sumando ambas contribuciones:

$$\|f - I_N f\|_\infty \leq \sum_{|k| > N} |\hat{f}_k| + \sum_{|j| > N} |\hat{f}_j| = 2 \sum_{|k| > N} |\hat{f}_k|. \quad \square$$

**Observación 4.44.** El factor 2 tiene una interpretación clara: la cola de la serie contribuye una vez al error (lo que “falta” por truncar), y los mismos coeficientes de alta frecuencia contribuyen una segunda vez por aliasing (lo que se “pliega” y contamina los coeficientes discretos de baja frecuencia). Para funciones muy suaves, donde los coeficientes de alta frecuencia son despreciables, la interpolación es prácticamente tan buena como la proyección.

#### 4.5.2 Error de interpolación de Chebyshev

Sea  $f \in C^m([-1, 1])$  con expansión de Chebyshev  $f(x) = \frac{a_0}{2} + \sum_{k=1}^{\infty} a_k T_k(x)$ . La **proyección de Chebyshev** de orden  $n$  es:

$$S_n f(x) = \frac{a_0}{2} + \sum_{k=1}^n a_k T_k(x),$$

y el **interpolante de Chebyshev**  $I_n f$  se construye a partir de los  $n + 1$  ceros de  $T_{n+1}$ :

$$x_j = \cos\left(\frac{(2j+1)\pi}{2(n+1)}\right), \quad j = 0, 1, \dots, n.$$

Bajo la sustitución  $x = \cos \theta$ , los nodos  $x_j$  corresponden a los ángulos  $\theta_j = \frac{(2j+1)\pi}{2(n+1)}$  equiespaciados en  $(0, \pi)$ , y los polinomios de Chebyshev se reducen a cosenos:  $T_k(\cos \theta) = \cos(k\theta)$ . Por lo tanto, el interpolante de Chebyshev es equivalente a un interpolante trigonométrico en la variable  $\theta$ .

El interpolante se escribe como  $I_n f(x) = \frac{\tilde{a}_0}{2} + \sum_{k=1}^n \tilde{a}_k T_k(x)$ , donde los **coeficientes discretos**  $\tilde{a}_k$  se obtienen por la ortogonalidad discreta de los cosenos en los nodos  $\theta_j$ :

$$\tilde{a}_k = \frac{2}{n+1} \sum_{j=0}^n f(x_j) T_k(x_j), \quad k = 0, 1, \dots, n.$$

La **fórmula de aliasing** para estos coeficientes es:

$$\tilde{a}_k - a_k = \sum_{q=1}^{\infty} (-1)^q [a_{2q(n+1)-k} + a_{2q(n+1)+k}], \quad k = 1, \dots, n, \quad (4.12)$$

con una fórmula análoga para  $k = 0$  (donde los términos  $2q(n+1) \pm 0$  coinciden, dando un coeficiente  $2(-1)^q a_{2q(n+1)}$ , que al dividirse por 2 en la expansión  $a_0/2$  produce la misma contribución que para  $k \geq 1$ ).

**Teorema 4.45** (Error de interpolación de Chebyshev). *Sea  $f \in C^m([-1, 1])$  con  $m \geq 2$ . Entonces el interpolante  $I_n f$  en los ceros de  $T_{n+1}$  satisface:*

$$\|f - I_n f\|_{\infty} \leq 2 \sum_{k=n+1}^{\infty} |a_k|.$$

Como  $|a_k| = O(k^{-m})$ , esta cota es  $O(n^{1-m})$ .

*Demostración.* La estrategia es idéntica al caso de Fourier. Descomponemos:  $f - I_n f = (f - S_n f) - I_n(f - S_n f)$ , usando que  $I_n(S_n f) = S_n f$  (el interpolante reproduce exactamente los polinomios de grado  $\leq n$ ).

**Cota de la cola.** Por  $|T_k(x)| \leq 1$  para todo  $x \in [-1, 1]$ :

$$\|f - S_n f\|_{\infty} = \left\| \sum_{k=n+1}^{\infty} a_k T_k(x) \right\|_{\infty} \leq \sum_{k=n+1}^{\infty} |a_k|.$$

**Cota del aliasing.** El polinomio  $I_n(f - S_n f) = \frac{b_0}{2} + \sum_{k=1}^n b_k T_k(x)$ , donde  $b_k = \tilde{a}_k - a_k$  es el error de aliasing del coeficiente  $k$ -ésimo. Debemos acotar:

$$\|I_n(f - S_n f)\|_{\infty} \leq \frac{|b_0|}{2} + \sum_{k=1}^n |b_k|.$$

Usando la fórmula de aliasing (4.12), cada  $|a_m|$  con  $m > n$  contribuye a esta suma. La clave es que **cada  $|a_m|$  aparece a lo sumo una vez**. En efecto, dado  $m > n$ , escribimos  $m = 2q(n+1) + r$  con  $0 \leq r < 2(n+1)$ :

- Si  $0 \leq r \leq n$ :  $a_m$  aparece en  $b_r$  (vía el término  $a_{2q(n+1)+r}$ ).
- Si  $n+2 \leq r \leq 2n+1$ :  $a_m$  aparece en  $b_{2(n+1)-r}$  (vía  $a_{2(q+1)(n+1)-(2(n+1)-r)}$ ).
- Si  $r = n+1$ :  $m$  es un múltiplo impar de  $n+1$ , y  $T_m$  se anula en todos los nodos (pues  $T_m(x_j) = \cos(m\theta_j)$  y  $m\theta_j$  recorre ángulos de la forma  $\frac{m(2j+1)\pi}{2(n+1)}$  que se cancelan). **En este caso,  $a_m$  no aparece en ningún  $b_k$ .**

Incluyendo la contribución del término  $\frac{b_0}{2}$  (que absorbe el factor 2 de la fórmula para  $k = 0$ ), tenemos:

$$\frac{|b_0|}{2} + \sum_{k=1}^n |b_k| \leq \sum_{\substack{m > n \\ m \neq \text{múlt. impar de } n+1}} |a_m| \leq \sum_{m=n+1}^{\infty} |a_m|.$$

**Conclusión.** Sumando ambas contribuciones:

$$\|f - I_n f\|_\infty \leq \sum_{k>n} |a_k| + \sum_{k>n} |a_k| = 2 \sum_{k=n+1}^{\infty} |a_k|. \quad \square$$

**Observación 4.46** (Conexión con FFT). *Los nodos de Chebyshev  $x_j = \cos(\theta_j)$  corresponden a puntos equiespaciados en la variable  $\theta$ . Por lo tanto, los coeficientes discretos  $\tilde{a}_k$  pueden calcularse eficientemente mediante la FFT en  $O(n \log n)$  operaciones, lo que hace que los métodos espectrales de Chebyshev sean extremadamente eficientes en la práctica.*

### 4.5.3 Generalización a otros polinomios ortogonales

Los resultados anteriores para Fourier y Chebyshev se extienden cualitativamente a otras familias de polinomios ortogonales. Sin embargo, la cota uniforme  $|P_k(x)| \leq C$  (que fue esencial en las demostraciones) no vale para familias generales: por ejemplo, los polinomios de Legendre satisfacen  $|P_k(x)| \leq 1$  en  $[-1, 1]$  pero  $|P_k(\pm 1)| = 1$ , y su crecimiento en norma  $L^\infty$  es  $\|P_k\|_\infty = 1$  (favorable), mientras que para Hermite o Laguerre la situación es diferente.

La herramienta general que permite pasar del error de proyección al error de interpolación es la **constante de Lebesgue**  $\Lambda_n$ , introducida en la siguiente sección.

**Teorema 4.47** (Del error de proyección al error de interpolación: caso general). *Sea  $I_n f$  el polinomio interpolante de  $f$  en  $n+1$  nodos arbitrarios  $\{x_j\}_{j=0}^n \subset [a, b]$ , y sea  $E_n(f) = \inf_{p \in \Pi_n} \|f - p\|_\infty$  el error de la mejor aproximación uniforme. Entonces:*

$$\|f - I_n f\|_\infty \leq (1 + \Lambda_n) E_n(f),$$

donde  $\Lambda_n = \max_{x \in [a, b]} \sum_{k=0}^n |\ell_k(x)|$  es la constante de Lebesgue de los nodos.

Para las familias clásicas de nodos (ceros de polinomios ortogonales), la constante de Lebesgue satisface:

| Nodos                           | $\Lambda_n$                      |
|---------------------------------|----------------------------------|
| Chebyshev (ceros de $T_{n+1}$ ) | $\frac{2}{\pi} \log(n+1) + O(1)$ |
| Legendre (ceros de $P_{n+1}$ )  | $O(\sqrt{n})$                    |
| Jacobi general                  | $O(\sqrt{n})$                    |
| Equiespaciados                  | $O(2^n / (n \log n))$            |

La demostración de este teorema se da en la Sección 4.6, a continuación.

## 4.6 El operador de interpolación (\*)

### 4.6.1 Constante de Lebesgue

Como vimos, el error de interpolación depende de dos factores fundamentales:

1. **Suavidad de la función:**  $\frac{f^{(n+1)}(\xi)}{(n+1)!}$
2. **Distribución de los nodos:**  $\prod_{k=0}^n (x - x_k)$

**Definición 4.48** (Función de Lebesgue). Para un conjunto de nodos  $\{x_k\}$ , la **función de Lebesgue** se define como:

$$\Lambda(x) = \sum_{k=0}^n |\ell_k(x)|.$$

La **constante de Lebesgue** es  $\Lambda_n = \max_{x \in [a,b]} \Lambda(x)$ .

**Definición 4.49** (Mejor aproximación en  $L^\infty$ ). Dada una función continua  $f$  en  $[a, b]$ , la **mejor aproximación uniforme** de grado  $n$  es el polinomio  $p^* \in \Pi_n$  que minimiza:

$$\|f - p^*\|_\infty = \max_{x \in [a,b]} |f(x) - p^*(x)|.$$

**Teorema 4.50** (Existencia de la mejor aproximación uniforme). Para toda función continua  $f : [a, b] \rightarrow \mathbb{R}$  y todo  $n \geq 0$ , existe al menos un polinomio  $p^* \in \Pi_n$  que minimiza  $\|f - p\|_\infty$  sobre todos los  $p \in \Pi_n$ .

*Demostración.* Definimos  $E_n(f) = \inf_{p \in \Pi_n} \|f - p\|_\infty$ . Sea  $\{p_k\}$  una sucesión minimizante, es decir,  $\|f - p_k\|_\infty \rightarrow E_n(f)$ .

Primero mostramos que los coeficientes de  $p_k$  están acotados. Como  $\|p_k\|_\infty \leq \|f - p_k\|_\infty + \|f\|_\infty \leq E_n(f) + 1 + \|f\|_\infty$  para  $k$  suficientemente grande, y en el espacio de dimensión finita  $\Pi_n$  todas las normas son equivalentes, los coeficientes de  $p_k$  en cualquier base están acotados.

Por el teorema de Bolzano-Weierstrass, existe una subsucesión  $\{p_{k_j}\}$  que converge a algún polinomio  $p^* \in \Pi_n$  (la convergencia coeficiente a coeficiente implica convergencia uniforme en  $[a, b]$ ). Entonces:

$$\|f - p^*\|_\infty = \lim_{j \rightarrow \infty} \|f - p_{k_j}\|_\infty = E_n(f).$$

□

**Teorema 4.51** (Cota del error en términos de la constante de Lebesgue). Si  $p^*$  es la mejor aproximación uniforme de  $f$  en el espacio de polinomios de grado  $\leq n$ , entonces:

$$\|f - p\|_\infty \leq (1 + \Lambda_n) \|f - p^*\|_\infty.$$

*Demostración.* La demostración se basa en descomponer el error de interpolación usando la mejor aproximación como término intermedio.

Para cualquier  $x \in [a, b]$ , podemos escribir:

$$f(x) - p(x) = [f(x) - p^*(x)] + [p^*(x) - p(x)],$$

donde  $p$  es el polinomio interpolante y  $p^*$  es la mejor aproximación uniforme. El primer término ya está acotado por  $\|f - p^*\|_\infty$  por definición de la norma infinito. Debemos analizar el segundo término.

Como  $p^*$  es un polinomio de grado  $\leq n$ , podemos escribirlo en la base de Lagrange asociada a los nodos  $\{x_k\}_{k=0}^n$ :

$$p^*(x) = \sum_{k=0}^n p^*(x_k) \ell_k(x),$$

donde  $\ell_k(x)$  son los polinomios base de Lagrange. Por otro lado, el polinomio interpolante  $p$  satisface  $p(x_k) = f(x_k)$  para todo  $k$ , por lo que:

$$p(x) = \sum_{k=0}^n f(x_k) \ell_k(x).$$

Restando estas expresiones obtenemos:

$$p^*(x) - p(x) = \sum_{k=0}^n [p^*(x_k) - f(x_k)] \ell_k(x).$$

Tomando valores absolutos y usando la desigualdad triangular:

$$\begin{aligned} |p^*(x) - p(x)| &= \left| \sum_{k=0}^n [p^*(x_k) - f(x_k)] \ell_k(x) \right| \\ &\leq \sum_{k=0}^n |p^*(x_k) - f(x_k)| \cdot |\ell_k(x)| \\ &\leq \max_{k=0, \dots, n} |p^*(x_k) - f(x_k)| \cdot \sum_{k=0}^n |\ell_k(x)| \\ &\leq \|f - p^*\|_{\infty} \cdot \Lambda(x), \end{aligned}$$

donde en la última desigualdad usamos que el máximo puntual de  $|p^*(x_k) - f(x_k)|$  está acotado por el supremo global  $\|f - p^*\|_{\infty}$ .

Juntando ambos términos de la descomposición inicial, obtenemos:

$$\begin{aligned} |f(x) - p(x)| &\leq |f(x) - p^*(x)| + |p^*(x) - p(x)| \\ &\leq \|f - p^*\|_{\infty} + \Lambda(x) \|f - p^*\|_{\infty} \\ &= (1 + \Lambda(x)) \|f - p^*\|_{\infty}. \end{aligned}$$

Finalmente, tomando supremo sobre  $x \in [a, b]$ :

$$\|f - p\|_{\infty} = \sup_{x \in [a, b]} |f(x) - p(x)| \leq (1 + \Lambda_n) \|f - p^*\|_{\infty},$$

donde  $\Lambda_n = \max_{x \in [a, b]} \Lambda(x)$  es la constante de Lebesgue. □

**Teorema 4.52** (La cota es ajustada). *La cota  $(1 + \Lambda_n)$  del teorema anterior no puede mejorarse: para cualquier conjunto de nodos  $\{x_k\}_{k=0}^n$ , existen funciones continuas  $f$  para las cuales el error de interpolación alcanza (esencialmente) este valor. Más precisamente, para cualquier  $\varepsilon > 0$ , existe una función continua  $f$  tal que:*

$$\|f - p\|_{\infty} \geq (\Lambda_n - \varepsilon) \|f - p^*\|_{\infty},$$

donde  $p$  es el interpolante de  $f$  y  $p^*$  es la mejor aproximación uniforme de  $f$  de grado  $n$ .

*Idea de la demostración.* Una construcción explícita de la función  $f$  que alcanza la cota puede realizarse considerando:

$$f(x) = \sum_{k=0}^n \operatorname{sgn}(\ell_k(\bar{x})) \cdot \ell_k(x) + h(x),$$

donde  $\bar{x}$  es un punto donde  $\Lambda(\bar{x}) = \Lambda_n$  y  $h$  es una función continua no polinomial apropiadamente elegida. La demostración es técnica y se basa en analizar el comportamiento del interpolante y la mejor aproximación para esta función específica.  $\square$

**Observación 4.53** (Interpretación y consecuencias). *Los resultados anteriores tienen varias implicaciones importantes para la interpolación polinomial:*

1. **Cuasi-optimalidad:** *La interpolación es cuasi-óptima: su error está controlado por  $(1 + \Lambda_n)$  veces el error de la mejor aproximación posible. Esto significa que si existe un polinomio que aproxima bien a  $f$ , entonces el interpolante también lo hará razonablemente bien.*
2. **La cota es ajustada:** *El Teorema 4.52 muestra que no podemos mejorar el factor  $(1 + \Lambda_n)$  en general: existen funciones para las cuales el error de interpolación es esencialmente  $(1 + \Lambda_n)$  veces el error de la mejor aproximación.*
3. **Importancia de  $\Lambda_n$ :** *La constante de Lebesgue determina completamente la calidad de la interpolación en el peor caso:*
  - Si  $\Lambda_n$  es pequeña (como para nodos de Chebyshev, donde  $\Lambda_n \approx \frac{2}{\pi} \log(n+1)$ ), la interpolación es casi óptima.
  - Si  $\Lambda_n$  es grande (como para nodos equiespaciados, donde  $\Lambda_n \approx \frac{2^n}{en \log n}$ ), la interpolación puede ser mucho peor que la mejor aproximación.
4. **Factor de amplificación inevitable:** *La constante de Lebesgue representa un factor de amplificación inevitable del error de aproximación. Es una propiedad intrínseca del conjunto de nodos elegido, independiente de la función particular que interpolamos.*
5. **Criterio de selección de nodos:** *Para obtener buenas interpolaciones, debemos elegir nodos que minimicen  $\Lambda_n$ . Esto justifica matemáticamente la preferencia por nodos de Chebyshev sobre nodos equiespaciados.*

#### 4.6.2 Nodos equiespaciados y el fenómeno de Runge

**Definición 4.54** (Nodos equiespaciados). *En el intervalo  $[a, b]$ , los **nodos equiespaciados** se definen como:*

$$x_k = a + k \frac{b-a}{n}, \quad k = 0, 1, \dots, n.$$

Los nodos equiespaciados son la elección más natural y se usan frecuentemente en aplicaciones prácticas. Sin embargo, como veremos, pueden llevar a problemas de convergencia serios.

**Teorema 4.55** (Fenómeno de Runge). *Existen funciones  $C^\infty$  para las cuales la interpolación polinomial en nodos equiespaciados diverge cuando  $n \rightarrow \infty$ .*

**Ejemplo 4.56** (Función de Runge). Consideremos la función  $f(x) = \frac{1}{1+25x^2}$  en el intervalo  $[-1, 1]$ . Esta función es  $C^\infty(\mathbb{R})$  y perfectamente suave.

Para nodos equiespaciados  $x_k = -1 + \frac{2k}{n}$ ,  $k = 0, \dots, n$ , los polinomios interpolantes  $p_n(x)$  satisfacen:

- $p_n(x) \rightarrow f(x)$  uniformemente en  $[-1/2, 1/2]$  cuando  $n \rightarrow \infty$ .
- $p_n(x)$  diverge cerca de los extremos  $x = \pm 1$ , con oscilaciones de amplitud creciente.

*Explicación del fenómeno.* El polinomio interpolante puede escribirse usando la fórmula de error:

$$p_n(x) = f(x) - \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{k=0}^n (x - x_k).$$

Para nodos equiespaciados en  $[-1, 1]$ , se puede demostrar que:

$$\max_{x \in [-1, 1]} \left| \prod_{k=0}^n (x - x_k) \right| \geq \frac{2^n}{4^n} = \left( \frac{1}{2} \right)^n.$$

Sin embargo, este crecimiento no es uniforme: cerca de los extremos,  $|\prod (x - x_k)|$  crece mucho más rápido que cerca del centro. Las derivadas  $f^{(n+1)}$  crecen factorialmente con  $n$ , y la competencia entre el decaimiento del factor  $1/(n+1)!$  y el crecimiento del producto nodal  $\prod (x - x_k)$  determina si hay convergencia o divergencia en cada punto.  $\square$

**Teorema 4.57** (Constante de Lebesgue para nodos equiespaciados). Para nodos equiespaciados en  $[-1, 1]$ , la constante de Lebesgue satisface:

$$\Lambda_n \geq \frac{2^n}{en \log n}.$$

Es decir, la constante de Lebesgue crece exponencialmente con  $n$ .

Esta cota inferior explica por qué los nodos equiespaciados pueden ser problemáticos: incluso si la función tiene una excelente aproximación polinomial, la interpolación puede amplificar enormemente el error debido a la constante de Lebesgue grande.

### 4.6.3 Convergencia de la interpolación polinomial en $L^\infty$

Una pregunta fundamental es: ¿bajo qué condiciones los polinomios interpolantes  $p_n$  convergen a la función  $f$  cuando  $n \rightarrow \infty$ ? La respuesta depende tanto de las propiedades de  $f$  como de la elección de los nodos de interpolación.

**Teorema 4.58** (Teorema de Faber, 1914). Para cualquier conjunto de nodos triangular  $\{x_k^{(n)}\}_{k=0}^n$  con  $n = 0, 1, 2, \dots$  en  $[-1, 1]$  (es decir, un esquema donde para cada  $n$  se tienen  $n+1$  nodos), existe una función continua  $f \in C[-1, 1]$  tal que la sucesión de polinomios interpolantes  $\{p_n\}$  diverge en al menos un punto de  $[-1, 1]$ .

**Observación 4.59.** Este resultado negativo muestra que **no existe un conjunto universal de nodos** que garantice convergencia uniforme para todas las funciones continuas. Incluso para funciones suaves, la interpolación puede diverger si los nodos no están bien elegidos.

A pesar de este resultado negativo, existen resultados positivos importantes bajo hipótesis adicionales:



## Teoremas fundamentales de aproximación polinomial

Antes de estudiar la convergencia de interpolación, recordemos dos resultados fundamentales sobre la mejor aproximación uniforme por polinomios:

**Definición 4.60** (Módulo de continuidad). *Para una función  $f \in C[a, b]$ , el **módulo de continuidad** se define como:*

$$\omega(f, \delta) = \sup_{\substack{x, y \in [a, b] \\ |x - y| \leq \delta}} |f(x) - f(y)|.$$

*Esta función mide cuánto puede variar  $f$  en un intervalo de longitud  $\delta$ .*

**Observación 4.61.** *El módulo de continuidad satisface:*

1.  $\omega(f, \delta) \rightarrow 0$  cuando  $\delta \rightarrow 0$  (por continuidad uniforme en  $[a, b]$ ).
2.  $\omega(f, \delta)$  es creciente en  $\delta$ .
3.  $\omega(f, \lambda\delta) \leq (1 + \lambda)\omega(f, \delta)$  para  $\lambda \geq 0$ .
4. Si  $f \in C^1[a, b]$ , entonces  $\omega(f, \delta) \leq \|f'\|_\infty \cdot \delta$ .

**Teorema 4.62** (Teorema de Jackson, 1911). *Sea  $f \in C[-1, 1]$ . Para todo  $n \geq 1$ , existe un polinomio  $p_n \in \Pi_n$  tal que:*

$$\|f - p_n\|_\infty \leq C \cdot \omega\left(f, \frac{1}{n}\right),$$

*donde  $C$  es una constante absoluta (independiente de  $f$  y  $n$ ).*

*En particular, si  $f \in C^k[-1, 1]$  para algún  $k \geq 1$ , entonces existe  $p_n \in \Pi_n$  tal que:*

$$\|f - p_n\|_\infty \leq \frac{C_k \|f^{(k)}\|_\infty}{n^k}.$$

**Idea de la demostración.** La demostración original de Jackson usa un núcleo de suavización específico (el **núcleo de Jackson**). La construcción moderna más simple usa los **polinomios de Bernstein**:

$$B_n(f)(x) = \sum_{k=0}^n f\left(\frac{k}{n}\right) \binom{n}{k} x^k (1-x)^{n-k}.$$

Estos polinomios tienen las siguientes propiedades:

1.  $B_n(f)$  es un polinomio de grado  $\leq n$ .
2.  $B_n(f)(x) \rightarrow f(x)$  uniformemente cuando  $n \rightarrow \infty$  (teorema de aproximación de Weierstrass).
3. El error satisface:

$$|f(x) - B_n(f)(x)| \leq \frac{3}{2} \omega\left(f, \frac{1}{\sqrt{n}}\right).$$

Para obtener la tasa óptima  $\omega(f, 1/n)$ , Jackson utilizó un proceso de suavización iterado. La idea es:

1. Convolucionar  $f$  con un núcleo suave  $K_n$  de soporte  $\sim 1/n$ .
2. El resultado es una función suavizada  $f_n = f * K_n$  que es aproximadamente polinomial.
3. El error es  $|f - f_n| \leq C\omega(f, 1/n)$  por la construcción del núcleo.
4. Aproximar  $f_n$  por un polinomio da el resultado.

La versión para  $f \in C^k$  se obtiene integrando por partes  $k$  veces en la representación integral del error.  $\square$

**Teorema 4.63** (Teorema de Bernstein, 1912). Sea  $f \in C[-1, 1]$  y sea  $E_n(f) = \inf_{p \in \Pi_n} \|f - p\|_\infty$  el error de la mejor aproximación uniforme por polinomios de grado  $\leq n$ . Si  $E_n(f) = O(n^{-\alpha})$  para algún  $\alpha > 0$ , entonces  $f \in C^{[\alpha]}[-1, 1]$ .

Más precisamente:

1. Si  $E_n(f) = O(n^{-\alpha})$  con  $0 < \alpha < 1$ , entonces  $\omega(f, \delta) = O(\delta^\alpha)$  (es decir,  $f$  es Hölder continua de exponente  $\alpha$ ).
2. Si  $E_n(f) = O(n^{-k})$  para  $k \in \mathbb{N}$ , entonces  $f \in C^{k-1}[-1, 1]$  y  $\omega(f^{(k-1)}, \delta) = O(\delta)$ .

*Idea de la demostración.* La demostración se basa en las siguientes observaciones:

**Caso 1: Regularidad Hölder.**

Sea  $p_n$  la mejor aproximación de  $f$  de grado  $n$ . Para  $h > 0$  pequeño, consideremos la diferencia:

$$\Delta_h f(x) = f(x+h) - f(x).$$

Queremos acotar  $|\Delta_h f(x)|$ . Como  $p_n$  aproxima bien a  $f$ :

$$|\Delta_h f(x)| \leq |\Delta_h [f - p_n](x)| + |\Delta_h p_n(x)|.$$

El primer término satisface:

$$|\Delta_h [f - p_n](x)| \leq 2\|f - p_n\|_\infty \leq 2E_n(f).$$

El segundo término, usando que  $|p'_n(x)| \leq Cn^2\|p_n\|_\infty$  (desigualdad de Markov para polinomios):

$$|\Delta_h p_n(x)| \leq h\|p'_n\|_\infty \leq Chn^2\|p_n\|_\infty \leq Chn^2(\|f\|_\infty + E_n(f)).$$

Eligiendo  $n \sim 1/h$  y usando  $E_n(f) = O(n^{-\alpha})$ , obtenemos:

$$|\Delta_h f(x)| \leq Ch^\alpha,$$

lo que implica  $\omega(f, h) = O(h^\alpha)$ .

**Caso 2: Diferenciabilidad.**

Si  $E_n(f) = O(n^{-k})$  con  $k \geq 1$ , se puede demostrar inductivamente que  $f$  tiene  $k-1$  derivadas continuas. La idea es usar que:

$$E_n(f') \leq Cn \cdot E_{n-1}(f) = O(n^{1-k}).$$

Por el caso Hölder, esto implica que  $f^{(k-1)}$  existe y es Hölder continua.  $\square$

**Observación 4.64** (Jackson vs. Bernstein). *Los teoremas de Jackson y Bernstein son **conver-**sos el uno del otro:*

- **Jackson:** regularidad de  $f \Rightarrow$  velocidad de aproximación.
- **Bernstein:** velocidad de aproximación  $\Rightarrow$  regularidad de  $f$ .

*Juntos, caracterizan completamente la relación entre la suavidad de una función y qué tan bien puede ser aproximada por polinomios.*

## Convergencia de interpolación polinomial

Ahora podemos estudiar la convergencia de interpolación usando estos resultados:

**Teorema 4.65** (Convergencia para funciones  $C^m$  con nodos de Chebyshev). *Sea  $f \in C^m[-1, 1]$  con  $m \geq 1$ . Sea  $p_n$  el polinomio que interpola a  $f$  en los  $n + 1$  nodos de Chebyshev. Entonces  $p_n \rightarrow f$  uniformemente en  $[-1, 1]$  cuando  $n \rightarrow \infty$ , con tasa:*

$$\|f - p_n\|_\infty = O\left(\frac{\log n}{n^m}\right).$$

*Demostración.* Por el teorema de Jackson,  $E_n(f) = O(n^{-m})$ . Como la constante de Lebesgue para nodos de Chebyshev satisface  $\Lambda_n = O(\log n)$ :

$$\|f - p_n\|_\infty \leq (1 + \Lambda_n)E_n(f) = O(\log(n) \cdot n^{-m}) \rightarrow 0.$$

□

**Teorema 4.66** (No convergencia con nodos equiespaciados). *Existen funciones  $f \in C^\infty(\mathbb{R})$  tales que los polinomios interpolantes en nodos equiespaciados en  $[-1, 1]$  divergen cuando  $n \rightarrow \infty$ .*

*Idea.* La función de Runge  $f(x) = \frac{1}{1+25x^2}$  es un ejemplo explícito. El crecimiento exponencial  $\Lambda_n \approx \frac{2^n}{en \log n}$  para nodos equiespaciados domina cualquier decaimiento del error de aproximación, causando divergencia cerca de los extremos del intervalo. □

**Teorema 4.67** (Convergencia uniforme para funciones Lipschitz). *Sea  $f \in C^1[-1, 1]$  una función con derivada acotada. Sea  $\{x_k^{(n)}\}$  un conjunto de nodos tal que  $\Lambda_n = O(n^\alpha)$  para algún  $\alpha > 0$  (por ejemplo, nodos de Chebyshev con  $\alpha = 0$ , o incluso algunos nodos menos óptimos con  $\alpha$  finito). Entonces el error de interpolación satisface:*

$$\|f - p_n\|_\infty = O\left(\frac{\Lambda_n}{n}\right) = O(n^{\alpha-1}).$$

*En particular, si  $\alpha < 1$ , entonces  $p_n \rightarrow f$  uniformemente.*

*Idea.* Por el teorema de Jackson, existe un polinomio  $q_n$  de grado  $n$  tal que:

$$\|f - q_n\|_\infty \leq \frac{C\omega(f, 1/n)}{n} \leq \frac{C\|f'\|_\infty}{n},$$

donde  $\omega(f, \delta)$  es el módulo de continuidad de  $f$ . Aplicando la cota de la constante de Lebesgue:

$$\|f - p_n\|_\infty \leq (1 + \Lambda_n)\|f - q_n\|_\infty \leq \frac{C(1 + \Lambda_n)\|f'\|_\infty}{n}.$$

□

**Teorema 4.68** (Teorema de Erdős-Turán). *Para nodos equiespaciados en  $[-1, 1]$ , existe una constante  $c > 0$  tal que para toda función  $f \in C[-1, 1]$ :*

$$\limsup_{n \rightarrow \infty} \|f - p_n\|_{\infty} \geq c \cdot E_n(f),$$

donde  $E_n(f) = \inf_{q \in \Pi_n} \|f - q\|_{\infty}$  es el error de la mejor aproximación uniforme.

En particular, si  $E_n(f) \not\rightarrow 0$  rápidamente (como  $O(\rho^{-n})$ ), entonces  $\|f - p_n\|_{\infty}$  puede no converger a cero.

**Observación 4.69** (Criterios prácticos de convergencia). *En la práctica, la convergencia de interpolación depende de:*

1. **Regularidad de  $f$ :** A mayor regularidad ( $C^m$  con  $m$  grande, o  $C^{\infty}$ ), más rápida es la convergencia con nodos adecuados. Funciones apenas continuas pueden divergir con cualquier esquema de nodos (Teorema de Faber).
2. **Elección de nodos:** Nodos de Chebyshev garantizan  $\Lambda_n = O(\log n)$ , lo cual es casi óptimo. Nodos equiespaciados tienen  $\Lambda_n = O(2^n/n)$ , lo cual es catastrófico.
3. **Comportamiento asintótico:** Para funciones  $C^k$ , la convergencia con nodos de Chebyshev es algebraica:  $\|f - p_n\|_{\infty} = O(\log(n)/n^k)$ .
4. **Criterio de selección:** Para funciones generales en aplicaciones prácticas, se recomienda usar nodos de Chebyshev o Gauss-Lobatto en lugar de nodos equiespaciados.

## Chapter 5

# Ecuaciones Diferenciales Ordinarias

### 5.1 Discretización de derivadas mediante diferencias finitas

La base de los métodos numéricos para ecuaciones diferenciales consiste en aproximar derivadas usando valores de la función en puntos discretos de una malla. Consideremos una función  $u(x)$  suficientemente suave y una malla equiespaciada con paso  $h > 0$ .

#### 5.1.1 Aproximaciones de la primera derivada

Las aproximaciones más comunes de  $u'(x)$  son:

(a) **Diferencias forward:**

$$u'(x) \approx \frac{u(x+h) - u(x)}{h}$$

(b) **Diferencias backward:**

$$u'(x) \approx \frac{u(x) - u(x-h)}{h}$$

(c) **Diferencias centradas:**

$$u'(x) \approx \frac{u(x+h) - u(x-h)}{2h}$$

**Análisis del error.** Para analizar la precisión de estas fórmulas, utilizamos el desarrollo de Taylor. Si  $u \in C^2$ , tenemos:

$$u(x \pm h) = u(x) \pm u'(x)h + \frac{u''(\xi_{\pm})}{2}h^2, \quad \xi_{\pm} \in (x, x \pm h).$$

Sustituyendo en las fórmulas de diferencias forward y backward:

$$\frac{u(x+h) - u(x)}{h} = u'(x) + \frac{u''(\xi)}{2}h,$$

es decir, ambas son aproximaciones de **orden 1**: el error es  $O(h)$ .

Para diferencias centradas, necesitamos  $u \in C^3$  y una expansión de orden superior:

$$u(x \pm h) = u(x) \pm u'(x)h + \frac{u''(x)}{2}h^2 \pm \frac{u'''(\xi_{\pm})}{6}h^3.$$

Al restar las expansiones, los términos pares se cancelan:

$$\frac{u(x+h) - u(x-h)}{2h} = u'(x) + \frac{u'''(\xi)}{6}h^2,$$

resultando en una aproximación de **orden 2**: el error es  $O(h^2)$ .

### 5.1.2 Aproximaciones de la segunda derivada

La discretización más usual para  $u''(x)$  es:

$$u''(x) \approx \frac{u(x+h) - 2u(x) + u(x-h)}{h^2}.$$

Si  $u \in C^4$ , expandimos hasta cuarto orden:

$$u(x \pm h) = u(x) \pm u'(x)h + \frac{u''(x)}{2}h^2 \pm \frac{u'''(x)}{6}h^3 + \frac{u^{(4)}(\xi_{\pm})}{24}h^4.$$

Sumando ambas expansiones, los términos impares se cancelan:

$$u(x+h) + u(x-h) = 2u(x) + u''(x)h^2 + \frac{u^{(4)}(\xi)}{12}h^4.$$

Por lo tanto:

$$\frac{u(x+h) - 2u(x) + u(x-h)}{h^2} = u''(x) + \frac{u^{(4)}(\xi)}{12}h^2.$$

Esta aproximación es también de **orden 2**.

### 5.1.3 Conexión con interpolación polinomial

Las fórmulas de diferencias finitas pueden interpretarse como derivadas de polinomios interpoladores. Si  $p(x)$  es el polinomio que interpola  $u$  en ciertos nodos, entonces  $p'(x) \approx u'(x)$  y  $p''(x) \approx u''(x)$ .

- **Diferencias forward/backward**: Interpolación lineal en  $\{x, x+h\}$  o  $\{x-h, x\}$ , respectivamente. El polinomio de grado 1 es  $p(t) = u(x) + \frac{u(x+h)-u(x)}{h}(t-x)$ , cuya derivada es constante e igual a la diferencia dividida.
- **Diferencias centradas (primera derivada)**: Interpolación lineal en  $\{x-h, x+h\}$ . La derivada en  $x$  del polinomio  $p(t) = u(x-h) + \frac{u(x+h)-u(x-h)}{2h}(t-(x-h))$  evaluada en  $x$  da la fórmula centrada.
- **Diferencias centradas (segunda derivada)**: Interpolación cuadrática en  $\{x-h, x, x+h\}$ . Usando la fórmula de Lagrange o Newton, la segunda derivada del polinomio interpolador resulta constante e igual a  $\frac{u(x+h)-2u(x)+u(x-h)}{h^2}$ .

Esta observación es fundamental: las fórmulas de diferencias finitas son casos particulares de diferenciación numérica mediante interpolación polinomial. Los órdenes de precisión pueden entenderse en términos del error de interpolación y la suavidad de la función.

## 5.2 Problemas de valores iniciales

Consideremos el problema de valores iniciales (PVI):

$$\frac{du}{dt} = f(t, u), \quad u(t_0) = u_0,$$

donde buscamos  $u(t)$  para  $t \in [t_0, T]$ .

Para garantizar que el PVI tiene solución única, necesitamos una condición sobre  $f$ :

**Definición 5.1** (Condición de Lipschitz). *Una función  $f : [t_0, T] \times \mathbb{R} \rightarrow \mathbb{R}$  satisface la **condición de Lipschitz** en la segunda variable con constante  $L > 0$  si:*

$$|f(t, u) - f(t, v)| \leq L|u - v|, \quad \text{para todo } t \in [t_0, T], \quad u, v \in \mathbb{R}.$$

Si  $f$  es Lipschitz en la segunda variable, el teorema de Picard-Lindelöf garantiza existencia y unicidad de la solución del PVI. La constante  $L$  juega un papel central en las cotas de error de los métodos numéricos.

Los métodos numéricos construyen una aproximación discreta  $u_n \approx u(t_n)$  en puntos  $t_n = t_0 + nh$  con paso  $h > 0$ .

**Método de Euler explícito.** El más simple es aproximar  $u'(t_n) \approx (u_{n+1} - u_n)/h$  (diferencias forward):

$$u_{n+1} = u_n + hf(t_n, u_n).$$

Este método tiene error local  $O(h^2)$  (por desarrollo de Taylor) y error global  $O(h)$  tras  $N = T/h$  pasos. Es fácil de implementar pero requiere  $h$  pequeño para estabilidad.

**Métodos de Runge-Kutta.** Para mejorar la precisión sin usar derivadas de  $f$ , evaluamos  $f$  en puntos intermedios. El **método RK4** (Runge-Kutta de orden 4) es:

$$\begin{aligned} k_1 &= f(t_n, u_n), \\ k_2 &= f(t_n + h/2, u_n + hk_1/2), \\ k_3 &= f(t_n + h/2, u_n + hk_2/2), \\ k_4 &= f(t_n + h, u_n + hk_3), \\ u_{n+1} &= u_n + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4). \end{aligned}$$

Este método tiene error global  $O(h^4)$ , muy superior a Euler con solo 4 evaluaciones de  $f$  por paso.

**Estabilidad.** Para el problema lineal de prueba  $u' = \lambda u$  con  $\lambda < 0$  (decaimiento), un método es **A-estable** si captura el comportamiento asintótico correcto para todo  $h > 0$ . Euler explícito solo es estable si  $|1 + h\lambda| \leq 1$ , i.e.,  $h \leq 2/|\lambda|$  (restricción severa para problemas rígidos). Los **métodos implícitos** como el trapecio implícito:

$$u_{n+1} = u_n + \frac{h}{2}[f(t_n, u_n) + f(t_{n+1}, u_{n+1})]$$

son A-estables pero requieren resolver una ecuación (posiblemente no lineal) en cada paso.

**Métodos adaptativos.** En la práctica, usamos esquemas que ajustan  $h$  automáticamente. El par **Dormand-Prince 5(4)** (usado en `scipy.integrate.solve_ivp` y MATLAB's `ode45`) combina dos métodos RK de órdenes 4 y 5 para estimar el error local:

$$\text{error estimado} \approx \|u_{n+1}^{(5)} - u_{n+1}^{(4)}\|.$$

Si el error excede la tolerancia, se reduce  $h$ ; si es muy pequeño, se aumenta  $h$ .

### 5.2.1 Convergencia de métodos de un paso

Los resultados previos sobre Euler y Runge-Kutta son casos particulares de una teoría general de convergencia. El siguiente teorema establece que, para métodos de un paso, el error global está controlado por el error de truncamiento local.

**Teorema 5.2.** Para  $n \in \mathbb{N}$  y  $h = (T - t_0)/n$  consideremos el método de un paso dado por

$$u_{i+1} = u_i + h\Phi(t_i, u_i, h),$$

con  $\Phi$  una función Lipschitz en la segunda variable, es decir, existe una constante  $K$  independiente de  $t$  y  $h$  tal que

$$|\Phi(t, x, h) - \Phi(t, y, h)| \leq K|x - y|$$

para todo  $x, y \in \mathbb{R}$  y  $t \in [t_0, T]$ . Entonces, se tiene

$$|u(T) - u_n| \leq \frac{\tau_{\max}}{K} \left( e^{K(T-t_0)} - 1 \right),$$

donde  $\tau_{\max} = \max_{1 \leq i \leq n} \{|\tau_i|\}$  con  $\tau_i$  el error de truncamiento local del método en el paso  $i$ .

*Demostración.* Sea  $e_i = u(t_i) - u_i$  el error global cometido hasta el paso  $i$ . Consideramos la ecuación del método y la definición de  $\tau_i$  (el error de truncamiento local satisface  $u(t_{i+1}) = u(t_i) + h\Phi(t_i, u(t_i), h) + h\tau_i$ ):

$$\begin{aligned} u_{i+1} &= u_i + h\Phi(t_i, u_i, h), \\ u(t_{i+1}) &= u(t_i) + h\Phi(t_i, u(t_i), h) + h\tau_i. \end{aligned}$$

Luego,

$$e_{i+1} = u(t_{i+1}) - u_{i+1} = e_i + h(\Phi(t_i, u(t_i), h) - \Phi(t_i, u_i, h)) + h\tau_i.$$

Usando que  $\Phi$  es Lipschitz se obtiene

$$\begin{aligned} |e_{i+1}| &\leq |e_i| + h|\Phi(t_i, u(t_i), h) - \Phi(t_i, u_i, h)| + h|\tau_i| \\ &\leq |e_i| + hK|u(t_i) - u_i| + h|\tau_i| \\ &\leq (1 + Kh)|e_i| + h|\tau_i|. \end{aligned}$$

Como  $|\tau_i| \leq \tau_{\max}$ , llamando  $A = 1 + Kh$ , tenemos

$$|e_{i+1}| \leq A|e_i| + h\tau_{\max}.$$



Usando esta acotación para  $i = 0$  y teniendo en cuenta que  $e_0 = 0$  (la condición inicial es exacta) se tiene

$$\begin{aligned} |e_1| &\leq h\tau_{\max}, \\ |e_2| &\leq A|e_1| + h\tau_{\max} \leq Ah\tau_{\max} + h\tau_{\max} = (1 + A)h\tau_{\max}, \\ |e_3| &\leq A|e_2| + h\tau_{\max} \leq A(1 + A)h\tau_{\max} + h\tau_{\max} = (1 + A + A^2)h\tau_{\max}. \end{aligned}$$

Iterando el procedimiento, podemos ver que

$$|e_n| \leq (1 + A + A^2 + \cdots + A^{n-1})h\tau_{\max} = h\tau_{\max} \sum_{j=0}^{n-1} A^j.$$

Ahora, usando la fórmula para suma de potencias tenemos

$$|e_n| \leq h\tau_{\max} \frac{A^n - 1}{A - 1} = h\tau_{\max} \frac{(1 + Kh)^n - 1}{Kh} = \frac{\tau_{\max}}{K} ((1 + Kh)^n - 1).$$

Como para  $\alpha > 0$  se tiene  $(1 + \alpha)^n \leq e^{n\alpha}$ , entonces

$$|e_n| \leq \frac{\tau_{\max}}{K} (e^{nKh} - 1) = \frac{\tau_{\max}}{K} (e^{K(T-t_0)} - 1),$$

lo que concluye la demostración.  $\square$

**Observación 5.3.** *Bajo las hipótesis del teorema anterior se deduce que un método de un paso es **convergente** (es decir,  $|u(T) - u_n| \rightarrow 0$  cuando  $h \rightarrow 0$ ) si y solo si  $\lim_{h \rightarrow 0} \tau_{\max} = 0$ . Esta condición se denomina **consistencia** del método. Puede demostrarse que, para un método de un paso con función de incremento  $\Phi$  continua en sus tres variables, se tiene  $\lim_{h \rightarrow 0} \tau_{\max} = 0$  si y solo si  $\Phi(t, u, 0) = f(t, u)$ . Los métodos de Euler, Taylor y Runge-Kutta satisfacen esta condición y, por lo tanto, son convergentes.*

**Corolario 5.4** (Cota de error para el método de Euler explícito). *Sea  $u' = f(t, u)$  con  $f$  Lipschitz en la segunda variable con constante  $L$ , y supongamos  $u \in C^2([t_0, T])$ . Si  $M = \max_{t \in [t_0, T]} |u''(t)|$ , entonces el error del método de Euler explícito satisface:*

$$|u(t_n) - u_n| \leq \frac{Mh}{2L} (e^{L(t_n-t_0)} - 1).$$

*Demostración.* Para el método de Euler,  $\Phi(t, u, h) = f(t, u)$ , que es Lipschitz con constante  $K = L$ . El error de truncamiento local del paso  $i$  es:

$$\tau_i = \frac{u(t_{i+1}) - u(t_i)}{h} - f(t_i, u(t_i)) = \frac{u(t_{i+1}) - u(t_i)}{h} - u'(t_i).$$

Por el desarrollo de Taylor,  $u(t_{i+1}) = u(t_i) + hu'(t_i) + \frac{h^2}{2}u''(\xi_i)$  para algún  $\xi_i \in (t_i, t_{i+1})$ . Por lo tanto,  $\tau_i = \frac{h}{2}u''(\xi_i)$ , lo que da  $\tau_{\max} \leq \frac{Mh}{2}$ . Sustituyendo en el teorema general con  $K = L$ :

$$|e_n| \leq \frac{\tau_{\max}}{L} (e^{L(t_n-t_0)} - 1) \leq \frac{Mh}{2L} (e^{L(t_n-t_0)} - 1).$$

$\square$

### 5.2.2 Convergencia y Estabilidad de métodos multipaso

Para los métodos multipaso lineales (LMM), la relación entre consistencia y convergencia es más sutil que para los métodos de un paso. Mientras que para métodos de un paso (como Euler o Runge-Kutta) la consistencia implica convergencia (bajo condiciones de suavidad de  $f$ ), para los LMM necesitamos una condición adicional de estabilidad.

Consideremos el método multipaso lineal general de  $k$  pasos:

$$\sum_{j=0}^k \alpha_j u_{n+j} = h \sum_{j=0}^k \beta_j f_{n+j},$$

donde normalizamos asumiendo  $\alpha_k = 1$ . Asociamos a este método los polinomios característicos:

$$\rho(z) = \sum_{j=0}^k \alpha_j z^j, \quad \sigma(z) = \sum_{j=0}^k \beta_j z^j.$$

**Definición 5.5** (Consistencia). *Un LMM se dice **consistente** si tiene orden de consistencia al menos 1, es decir, si el error de truncamiento local satisface  $\tau_n(h) \rightarrow 0$  cuando  $h \rightarrow 0$ . En términos de los polinomios característicos, esto equivale a las condiciones:*

$$\rho(1) = 0 \quad \text{y} \quad \rho'(1) = \sigma(1).$$

La consistencia por sí sola no es suficiente. Si las raíces del polinomio  $\rho(z)$  no se comportan adecuadamente, los errores pueden amplificarse exponencialmente al avanzar los pasos, incluso si el error local es pequeño.

**Ejemplo 5.6** (Consistencia no implica convergencia). *Consideremos el método multipaso dado por:*

$$u^{n+2} - 3u^{n+1} + 2u^n = -hf(t_n, u^n).$$

*El error de truncamiento local resulta:*

$$\tau^n = \frac{1}{h} [u(t_{n+2}) - 3u(t_{n+1}) + 2u(t_n)] + u'(t_n) = \frac{5}{2}hu''(t_n) + O(h^2),$$

*por lo que **el método es consistente** (de orden 1).*

*Sin embargo, el método **no converge**. Para verlo, consideremos el problema test  $u'(t) = 0$ ,  $u(0) = 0$ . El método toma la forma:*

$$u^{n+2} - 3u^{n+1} + 2u^n = 0.$$

*El polinomio característico es  $\rho(z) = z^2 - 3z + 2 = (z-1)(z-2)$ , con raíces  $z_1 = 1$  y  $z_2 = 2$ . La solución general de la recurrencia es:*

$$u^n = C_1 \cdot 1^n + C_2 \cdot 2^n = C_1 + C_2 \cdot 2^n.$$

*Para implementar el método necesitamos **dos valores iniciales**,  $u^0$  y  $u^1$ . Si tomamos  $u^0 = u^1 = 0$ , entonces  $C_1 = C_2 = 0$  y el método converge a la solución exacta. Pero en la práctica,  $u^1$  se obtiene con otro método (por ejemplo, Euler) y tendrá un error pequeño.*

Consideremos  $u^0 = 0$  y  $u^1 = h$  (un error del orden del paso). Las constantes satisfacen:

$$\begin{cases} C_1 + C_2 = 0 \\ C_1 + 2C_2 = h \end{cases} \Rightarrow C_1 = -h, C_2 = h.$$

Por lo tanto:

$$u^n = -h + h \cdot 2^n = h(2^n - 1).$$

En el tiempo final  $T$ , con  $n = T/h$ :

$$u^n = h(2^{T/h} - 1) \rightarrow \infty \quad \text{cuando } h \rightarrow 0.$$

A pesar de ser consistente, **el método diverge exponencialmente** debido a la raíz  $|z_2| = 2 > 1$ .

Este ejemplo motiva la siguiente definición crucial:

**Definición 5.7** (0-Estabilidad). Un LMM se dice **0-estable** (o que satisface la **condición de la raíz**) si todas las raíces  $z$  del primer polinomio característico  $\rho(z)$  satisfacen:

1.  $|z| \leq 1$ .
2. Si  $|z| = 1$ , entonces  $z$  es una raíz simple.

El siguiente teorema, debido a Germund Dahlquist, es el pilar fundamental de la teoría de métodos multipaso.

**Teorema 5.8** (Teorema de Equivalencia de Dahlquist). Un método multipaso lineal consistente es convergente si y solo si es 0-estable.

*Demostración. Necesidad ( $\Rightarrow$ ):* Supongamos que el método es convergente. Consideremos la ecuación diferencial trivial  $u' = 0, u(0) = 0$ , cuya solución exacta es  $u(t) = 0$ . Al aplicar el método numérico a esta ecuación (donde  $f(t, u) = 0$ ), obtenemos la relación de recurrencia lineal homogénea con coeficientes constantes:

$$\sum_{j=0}^k \alpha_j u_{n+j} = 0.$$

La solución general de esta recurrencia se puede expresar en términos de las raíces  $z_1, \dots, z_m$  de  $\rho(z)$ . Si  $z_i$  es una raíz de multiplicidad  $\mu_i$ , los términos asociados son  $z_i^n, n z_i^n, \dots, n^{\mu_i-1} z_i^n$ .

- Si existiera una raíz con  $|z_i| > 1$ , el término  $z_i^n$  crecería exponencialmente en magnitud con  $n$ . Dado que  $n = T/h$ , cuando  $h \rightarrow 0$ ,  $n \rightarrow \infty$ , y  $|u_n| \rightarrow \infty$  para casi cualquier condición inicial (errores de redondeo infinitesimales excitarían este modo). Esto contradice la convergencia a 0.
- Si existiera una raíz con  $|z_i| = 1$  y multiplicidad  $\mu_i > 1$ , la solución contendría un término de la forma  $n^{\mu_i-1} z_i^n$ . Su magnitud crece polinomialmente con  $n$ . Nuevamente, como  $n \rightarrow \infty$  cuando  $h \rightarrow 0$ , el error no acotado impide la convergencia.

Por lo tanto, para que el método sea convergente, es necesario que todas las raíces satisfagan  $|z| \leq 1$  y las de módulo 1 sean simples.

**Suficiencia ( $\Leftarrow$ ):** Supongamos que el método es consistente y 0-estable. Sea  $e_n = u(t_n) - u_n$  el error global. La solución exacta satisface el esquema numérico salvo por el error de truncamiento local  $\tau_n$ :

$$\sum_{j=0}^k \alpha_j u(t_{n+j}) = h \sum_{j=0}^k \beta_j f(t_{n+j}, u(t_{n+j})) + h\tau_{n+k}.$$

Restando la ecuación del método numérico  $\sum_{j=0}^k \alpha_j u_{n+j} = h \sum_{j=0}^k \beta_j f(t_{n+j}, u_{n+j})$ , obtenemos la ecuación para el error:

$$\sum_{j=0}^k \alpha_j e_{n+j} = h \sum_{j=0}^k \beta_j [f(t_{n+j}, u(t_{n+j})) - f(t_{n+j}, u_{n+j})] + h\tau_{n+k}.$$

Usando la condición de Lipschitz para  $f$  con constante  $L$ , tenemos  $|f(t, u) - f(t, v)| \leq L|u - v|$ . Sea  $g_n$  tal que la diferencia de las  $f$  es  $g_n e_{n+j}$  con  $|g_n| \leq L$ . Podemos reescribir la ecuación como:

$$\sum_{j=0}^k \alpha_j e_{n+j} = \gamma_n, \quad \text{donde } \gamma_n = h \sum_{j=0}^k \beta_j g_{n+j} e_{n+j} + h\tau_{n+k}.$$

Esta es una ecuación en diferencias lineal inhomogénea para  $e_n$ . Debido a la 0-estabilidad, las raíces de  $\rho(z)$  se comportan bien, lo que implica que el operador inverso es estable. Existe una constante  $K$  (que depende solo de los coeficientes  $\alpha_j$ ) tal que la solución de  $\sum \alpha_j e_{n+j} = \gamma_n$  está acotada por:

$$|e_n| \leq K \left( \sum_{i=0}^{k-1} |e_i| + \sum_{m=0}^{n-k} |\gamma_m| \right).$$

Sustituyendo  $\gamma_m$ :

$$|e_n| \leq K \left( \sum_{i=0}^{k-1} |e_i| + \sum_{m=0}^{n-k} \left( hL \sum_{j=0}^k |\beta_j| |e_{m+j}| + h|\tau_{m+k}| \right) \right).$$

Sea  $B = \sum |\beta_j|$  y supongamos que el método es consistente de orden  $p$ , tal que  $|\tau_m| \leq Ch^p$ . Asumimos también que los errores iniciales son del orden adecuado  $\sum_{i=0}^{k-1} |e_i| \leq C_0 h^p$ .

$$|e_n| \leq KC_0 h^p + Kh \sum_{m=0}^{n-k} Ch^p + KhLB \sum_{m=0}^{n-k} \sum_{j=0}^k |e_{m+j}|.$$

El término de la suma de  $\tau$  es  $\approx n \cdot h \cdot h^p \approx Th^p$ . Reorganizando los términos de la suma doble, podemos acotar por una suma simple sobre los errores pasados (ajustando la constante  $K'$ ):

$$|e_n| \leq C'h^p + K'h \sum_{m=0}^{n-1} |e_m|.$$

Esta es la forma discreta de la desigualdad de Grönwall. Su resolución implica:

$$|e_n| \leq C' h^p \exp(K' n h) = C' h^p \exp(K' T).$$

Como  $T$  es fijo, esto demuestra que  $|e_n| \rightarrow 0$  cuando  $h \rightarrow 0$ , y además que el orden de convergencia es  $p$ .  $\square$

**Ejemplo 5.9** (Análisis de estabilidad). • **Método de Adams-Bashforth (2 pasos):**  $u_{n+2} - u_{n+1} = \dots$ .  $\rho(z) = z^2 - z = z(z-1)$ . Raíces: 0, 1. Ambas  $\leq 1$ , 1 es simple. **Es 0-estable.**

• **Método inestable:**  $u_{n+2} + 4u_{n+1} - 5u_n = \dots$ .  $\rho(z) = z^2 + 4z - 5 = (z+5)(z-1)$ . Raíces: 1, -5. Como  $|-5| > 1$ , **no es 0-estable** y no convergerá.

• **Diferencias centradas para  $u' = f$ :** El método  $\frac{u^{n+1} - u^{n-1}}{2h} = f(t_n, u^n)$  tiene  $\rho(z) = z^2 - 1 = (z-1)(z+1)$ . Raíces:  $\pm 1$ . Ambas sobre el círculo unitario, pero la raíz  $-1$  genera oscilaciones espurias. Aunque es 0-estable, su comportamiento numérico es pobre.

**Corolario 5.10.** Los métodos de un paso son automáticamente 0-estables si son consistentes.

*Demostración.* Para  $k = 1$ , el polinomio  $\rho(z) = \alpha_0 + \alpha_1 z$  tiene una única raíz  $z = -\alpha_0/\alpha_1$ . La condición de consistencia  $\rho(1) = 0$  implica  $\alpha_0 + \alpha_1 = 0$ , es decir,  $\alpha_0 = -\alpha_1$ . Por lo tanto,  $z = 1$ , que satisface la condición de la raíz.  $\square$

**Observación 5.11.** Este corolario explica por qué en métodos de un paso (Euler, Runge-Kutta) solo necesitamos verificar consistencia para garantizar convergencia, mientras que en métodos multipaso debemos verificar además la 0-estabilidad.

### 5.2.3 A-estabilidad y estabilidad práctica

Mientras que la 0-estabilidad es una propiedad intrínseca del método, la A-estabilidad caracteriza el comportamiento del método aplicado a la ecuación de prueba de Dahlquist  $u' = \lambda u$  con  $\operatorname{Re}(\lambda) < 0$ .

**Definición 5.12** (Ecuación de prueba de Dahlquist). La **ecuación de prueba** es:

$$u'(t) = \lambda u(t), \quad u(0) = u_0,$$

donde  $\lambda \in \mathbb{C}$  con  $\operatorname{Re}(\lambda) \leq 0$ . La solución exacta es  $u(t) = u_0 e^{\lambda t}$ .

Esta ecuación es fundamental porque captura el comportamiento de sistemas lineales y de la linealización local de sistemas no lineales. Para  $\operatorname{Re}(\lambda) < 0$ , la solución exacta decae exponencialmente a cero.

**Definición 5.13** (Función de estabilidad para métodos multipaso). Aplicando un método multipaso a la ecuación de prueba  $u' = \lambda u$ , obtenemos:

$$\sum_{j=0}^k \alpha_j u_{n+j} = h\lambda \sum_{j=0}^k \beta_j u_{n+j}.$$

Buscando soluciones de la forma  $u_n = r^n$ , donde  $r$  es un número complejo, llegamos a:

$$\sum_{j=0}^k \alpha_j r^j = h\lambda \sum_{j=0}^k \beta_j r^j,$$

o equivalentemente:

$$\rho(r) = h\lambda\sigma(r),$$

donde  $\rho(z) = \sum_{j=0}^k \alpha_j z^j$  y  $\sigma(z) = \sum_{j=0}^k \beta_j z^j$  son los polinomios característicos del método.

**Definición 5.14** (Región de estabilidad absoluta). La **región de estabilidad absoluta**  $S$  de un método multipaso es el conjunto:

$$S = \{z \in \mathbb{C} : \text{todas las raíces } r \text{ de } \rho(r) - z\sigma(r) = 0 \text{ satisfacen } |r| \leq 1\}.$$

Alternativamente,  $S$  es el conjunto de valores  $z = h\lambda$  para los cuales el método produce soluciones acotadas.

**Definición 5.15** (A-estabilidad). Un método numérico es **A-estable** si su región de estabilidad absoluta contiene todo el semiplano izquierdo complejo:

$$S \supseteq \{z \in \mathbb{C} : \operatorname{Re}(z) < 0\}.$$

**Observación 5.16** (Interpretación física). Un método A-estable preserva la propiedad cualitativa de la solución exacta (decaimiento para  $\operatorname{Re}(\lambda) < 0$ ) para cualquier tamaño de paso  $h > 0$ . Esto es especialmente importante para **problemas rígidos** (stiff), donde diferentes componentes de la solución decaen a tasas muy diferentes.

**Teorema 5.17** (Primer teorema de barrera de Dahlquist). No existe ningún método multipaso lineal explícito que sea A-estable.

*Idea de la demostración.* Para un método explícito, tenemos  $\beta_k = 0$  (el lado derecho no involucra  $f_{n+k}$ ). Por lo tanto,  $\sigma(z)$  tiene grado menor que  $k$ , mientras que  $\rho(z)$  tiene grado exactamente  $k$ .

Para valores grandes de  $|z|$ , la ecuación  $\rho(r) = z\sigma(r)$  se comporta asintóticamente como  $\alpha_k r^k = z \cdot O(r^{k-1})$ , lo que da  $r \sim \frac{z\beta_{k-1}}{\alpha_k}$  (más otras raíces).

Para  $z \rightarrow -\infty$  (que está en el semiplano izquierdo), al menos una de estas raíces satisface  $|r| > 1$ , por lo que  $z \notin S$ . Por tanto,  $S$  no puede contener todo el semiplano izquierdo, y el método no es A-estable.  $\square$

**Teorema 5.18** (Segundo teorema de barrera de Dahlquist). El orden máximo de un método multipaso lineal A-estable es 2. Además, el método de orden 2 con menor error asintótico es la **regla del trapecio**:

$$u_{n+1} - u_n = \frac{h}{2}(f_{n+1} + f_n).$$

*Esquema de la demostración.* La demostración completa utiliza técnicas de análisis complejo y teoría de polinomios. Las ideas principales son:

**Paso 1:** Para que un método sea A-estable, la función racional  $R(z) = \frac{\rho(e^z)}{\sigma(e^z)}$  debe satisfacer ciertas propiedades en el semiplano izquierdo.

**Paso 2:** Usando la consistencia (que relaciona  $\rho$  y  $\sigma$  en  $z = 1$ ) y condiciones de orden, se demuestra que el grado del numerador y denominador están restringidos.

**Paso 3:** Un análisis detallado muestra que solo métodos de orden  $\leq 2$  pueden satisfacer simultáneamente todas las condiciones requeridas para A-estabilidad.

**Paso 4:** La regla del trapecio, con  $\rho(z) = z - 1$  y  $\sigma(z) = \frac{1}{2}(z + 1)$ , satisface todas las condiciones y alcanza orden 2.  $\square$

**Ejemplo 5.19** (Análisis de estabilidad: Euler explícito vs. Euler implícito). *Comparemos el comportamiento de los métodos de Euler en la ecuación de prueba  $u' = \lambda u$  con  $\operatorname{Re}(\lambda) < 0$ .*

**Euler explícito:**  $u_{n+1} = u_n + h\lambda u_n = (1 + h\lambda)u_n = R(h\lambda)u_n$ .

*La función de estabilidad es  $R(z) = 1 + z$ . Para estabilidad, requerimos  $|1 + z| \leq 1$ . Escribiendo  $z = h\lambda = h(\alpha + i\beta)$  con  $\alpha < 0$ :*

$$|1 + h\alpha + ih\beta|^2 = (1 + h\alpha)^2 + h^2\beta^2 \leq 1.$$

*Expandiendo:  $1 + 2h\alpha + h^2(\alpha^2 + \beta^2) \leq 1$ , es decir:*

$$h \leq \frac{-2\alpha}{\alpha^2 + \beta^2} = \frac{2|\operatorname{Re}(\lambda)|}{|\lambda|^2}.$$

*Si  $\lambda$  es real negativo ( $\lambda = \alpha < 0$ ), esto se reduce a:*

$$h < \frac{2}{|\lambda|}.$$

**Conclusión:** *El método de Euler explícito requiere una restricción sobre el paso temporal para ser estable. No es A-estable.*

**Euler implícito:**  $u_{n+1} = u_n + h\lambda u_{n+1}$ , de donde:

$$u_{n+1}(1 - h\lambda) = u_n \quad \Rightarrow \quad u_{n+1} = \frac{1}{1 - h\lambda}u_n = R(h\lambda)u_n.$$

*La función de estabilidad es  $R(z) = \frac{1}{1-z}$ . Para  $\operatorname{Re}(z) < 0$ , escribimos  $z = x + iy$  con  $x < 0$ :*

$$|R(z)|^2 = \frac{1}{|1 - z|^2} = \frac{1}{(1 - x)^2 + y^2}.$$

*Como  $x < 0$ , tenemos  $1 - x > 1$ , por lo que  $(1 - x)^2 > 1$ , y así:*

$$|R(z)|^2 < 1 \quad \text{para todo } \operatorname{Re}(z) < 0.$$

**Conclusión:** *El método de Euler implícito es A-estable. No hay restricción sobre  $h$  para estabilidad (aunque la precisión puede degradarse con  $h$  grande).*

**Observación 5.20** (Implicaciones para problemas rígidos). *La diferencia entre Euler explícito e implícito es dramática para **problemas rígidos** (stiff), donde el sistema tiene autovalores  $\lambda$  con  $|\operatorname{Re}(\lambda)| \gg 1$ . Por ejemplo, si  $\lambda = -1000$ :*

- Euler explícito requiere  $h < 0.002$  para estabilidad, forzando pasos muy pequeños.
- Euler implícito permite pasos grandes arbitrarios sin inestabilidad numérica.

Aunque el costo por paso del método implícito es mayor (resolver sistema lineal), puede compensarse con pasos mucho mayores.

**Ejemplo 5.21** (Verificación de A-estabilidad de la regla del trapecio). Para la regla del trapecio:

$$u_{n+1} - u_n = \frac{h}{2}(f_{n+1} + f_n).$$

Aplicando a  $u' = \lambda u$ :

$$u_{n+1} - u_n = \frac{h\lambda}{2}(u_{n+1} + u_n).$$

Reorganizando:

$$u_{n+1} \left(1 - \frac{h\lambda}{2}\right) = u_n \left(1 + \frac{h\lambda}{2}\right),$$

de donde:

$$u_{n+1} = \frac{1 + \frac{h\lambda}{2}}{1 - \frac{h\lambda}{2}} u_n = R(h\lambda)u_n,$$

donde  $R(z) = \frac{1+z/2}{1-z/2}$  es la función de estabilidad.

Para estabilidad, necesitamos  $|R(z)| \leq 1$ . Si  $z = h\lambda$  con  $\text{Re}(z) < 0$ , escribamos  $z = x + iy$  con  $x < 0$ :

$$|R(z)|^2 = \left| \frac{1 + z/2}{1 - z/2} \right|^2 = \frac{|1 + x/2 + iy/2|^2}{|1 - x/2 - iy/2|^2} = \frac{(1 + x/2)^2 + y^2/4}{(1 - x/2)^2 + y^2/4}.$$

Como  $x < 0$ , tenemos  $1 + x/2 < 1 < 1 - x/2$ , por lo que  $(1 + x/2)^2 < (1 - x/2)^2$ . Así:

$$|R(z)|^2 < 1 \quad \text{para todo } \text{Re}(z) < 0.$$

Por lo tanto, la regla del trapecio es A-estable.

**Observación 5.22** (Consecuencias prácticas). Los teoremas de barrera de Dahlquist tienen consecuencias importantes:

1. Los métodos explícitos multipaso no pueden ser A-estables, lo que limita su uso para problemas rígidos.
2. Los métodos implícitos de orden alto ( $p \geq 3$ ) tampoco pueden ser A-estables.
3. Para problemas rígidos, se debe elegir entre: (a) usar métodos de orden bajo A-estables como el trapecio, o (b) usar métodos de orden alto con regiones de estabilidad grandes pero no A-estables.
4. Esto ha motivado el desarrollo de los **métodos BDF** (Backward Differentiation Formulas), que sacrifican A-estabilidad por  $A(\alpha)$ -estabilidad (una versión relajada) y pueden alcanzar orden hasta 6.



## 5.3 Problemas de valores de contorno en 1D

A diferencia de los problemas de valores iniciales (PVI), en los problemas de valores de contorno (PVC) las condiciones se especifican en los extremos del intervalo. Esta aparente diferencia sutil tiene consecuencias profundas: mientras los PVI se resuelven marchando en el tiempo, los PVC requieren resolver un sistema de ecuaciones algebraicas.

### 5.3.1 Condiciones de borde de Dirichlet

Consideremos la ecuación de Poisson unidimensional con condiciones de Dirichlet:

$$\begin{cases} -u_{xx}(x) = f(x), & \text{para } x \in (0, 1) \\ u(0) = \alpha \\ u(1) = \beta. \end{cases} \quad (5.1)$$

**Discretización por diferencias finitas.** Consideramos la malla uniforme  $\{x_j = jh, j = 0, 1, 2, \dots, m+1\}$  con  $h = 1/(m+1)$ . Para los puntos interiores  $x_j \in (0, 1)$ , el esquema de diferencias centradas para la derivada segunda conduce al sistema:

$$\frac{1}{h^2} (u_{j-1} - 2u_j + u_{j+1}) = f(x_j), \quad j = 1, 2, \dots, m.$$

Utilizando las condiciones de borde  $u_0 = \alpha$ ,  $u_{m+1} = \beta$ , obtenemos el sistema lineal:

$$A^h u^h = F^h, \quad (5.2)$$

donde  $u^h = [u_1, u_2, \dots, u_m]^T$  es el vector de incógnitas, y:

$$A^h = \frac{1}{h^2} \begin{bmatrix} -2 & 1 & & & \\ 1 & -2 & 1 & & \\ & 1 & -2 & 1 & \\ & & \ddots & \ddots & \ddots \\ & & & 1 & -2 & 1 \\ & & & & 1 & -2 \end{bmatrix}, \quad F^h = \begin{bmatrix} f(x_1) - \alpha/h^2 \\ f(x_2) \\ f(x_3) \\ \vdots \\ f(x_{m-1}) \\ f(x_m) - \beta/h^2 \end{bmatrix}. \quad (5.3)$$

**Definición 5.23** (Error de discretización y de truncamiento). *Para  $h$  fijo, definimos:*

- **Error de discretización:**  $e_j^h = u(x_j) - u_j^h$ , donde  $u$  es la solución exacta y  $u^h$  la aproximada.
- **Error de truncamiento local:**  $\tau_j^h = (A^h U)_j - f(x_j)$ , donde  $U$  denota la solución exacta evaluada en la malla:  $U_j = u(x_j)$ .

**Teorema 5.24** (Error de truncamiento). *Si  $u \in C^4[0, 1]$ , existe una constante  $C$  independiente de  $h$  tal que:*

$$\max_{1 \leq j \leq m} |\tau_j^h| \leq Ch^2.$$

*Demostración.* Como  $u \in C^4$ , podemos usar la fórmula del error de diferencias centradas:  $\tau_j^h = -\frac{h^2}{12}u^{(4)}(\xi_j)$  para algún  $\xi_j \in (x_{j-1}, x_{j+1})$ . Como  $u^{(4)}$  es continua en  $[0, 1]$ , está acotada:  $|u^{(4)}(x)| \leq M$  para todo  $x \in [0, 1]$ . Por tanto:

$$|\tau_j^h| \leq \frac{h^2}{12}M = Ch^2.$$

□

**Relación entre errores.** Aplicando  $A^h$  al error de discretización:

$$A^h e^h = A^h U - A^h u^h = A^h U - F^h = \tau^h.$$

Por tanto:  $e^h = (A^h)^{-1}\tau^h$ , y:

$$\|e^h\| \leq \|(A^h)^{-1}\| \cdot \|\tau^h\|.$$

Para garantizar convergencia, necesitamos que  $(A^h)^{-1}$  esté acotada uniformemente en  $h$ :

**Definición 5.25** (Estabilidad). *Una discretización es **estable** en norma  $\|\cdot\|$  si existe una constante  $C$  independiente de  $h$  tal que:*

$$\|(A^h)^{-1}\| \leq C \quad \text{para todo } h.$$

**Teorema 5.26** (Autovalores y autovectores de la matriz tridiagonal). *Dados  $a, b, c \in \mathbb{R}$ , consideremos la matriz tridiagonal  $A \in \mathbb{R}^{n \times n}$ :*

$$A = \begin{bmatrix} a & b & & & & \\ c & a & b & & & \\ & c & a & b & & \\ & & \ddots & \ddots & \ddots & \\ & & & c & a & b \\ & & & & c & a \end{bmatrix}.$$

Llamando  $h = 1/(n+1)$  y  $w^2 = c/b$ , el  $q$ -ésimo autovector  $r^q$  de  $A$  está dado por:

$$r_j^q = w^j \sin(q\pi jh), \quad j = 1, \dots, n,$$

y el correspondiente autovalor es:

$$\lambda^q = a + 2\sqrt{bc} \cos(q\pi h).$$

*Demostración.* Verificamos que  $Ar^q = \lambda^q r^q$ . Para  $1 < j < n$ :

$$\begin{aligned} (Ar^q)_j &= cr_{j-1}^q + ar_j^q + br_{j+1}^q \\ &= cw^{j-1} \sin(q\pi(j-1)h) + aw^j \sin(q\pi jh) + bw^{j+1} \sin(q\pi(j+1)h) \\ &= w^j \left[ cw^{-1} \sin(q\pi(j-1)h) + a \sin(q\pi jh) + bw \sin(q\pi(j+1)h) \right]. \end{aligned}$$

Usando la identidad  $\sin(q\pi(j \pm 1)h) = \sin(q\pi jh) \cos(q\pi h) \pm \cos(q\pi jh) \sin(q\pi h)$ , y observando que el segundo término se cancela (por simetría), obtenemos:

$$(Ar^q)_j = w^j \sin(q\pi jh) \cdot (cw^{-1} \cos(q\pi h) + a + bw \cos(q\pi h)).$$

Como  $w^2 = c/b$ , tenemos  $w = \sqrt{c/b}$ , por lo que  $cw^{-1} = \sqrt{bc}$  y  $bw = \sqrt{bc}$ . Así:

$$\lambda^q = a + 2\sqrt{bc} \cos(q\pi h).$$

Los casos  $j = 1$  y  $j = n$  se verifican análogamente usando que  $r_0^q = r_{n+1}^q = 0$ .  $\square$

**Corolario 5.27** (Estabilidad de la discretización de Dirichlet). *Para la matriz  $A^h$  en (5.3) (con  $a = -2/h^2$ ,  $b = c = 1/h^2$ ), los autovalores son:*

$$\lambda^q = \frac{2}{h^2} (\cos(q\pi h) - 1), \quad q = 1, \dots, m.$$

*El autovalor de mínimo módulo es:*

$$\lambda_1 = \frac{2}{h^2} (\cos(\pi h) - 1) = \frac{2}{h^2} \left( -\frac{\pi^2 h^2}{2} + O(h^4) \right) = -\pi^2 + O(h^2).$$

*Por tanto, como  $A^h$  es simétrica:*

$$\|(A^h)^{-1}\|_2 = \frac{1}{|\lambda_1|} \leq \frac{1}{\pi^2} + O(h^2) = O(1).$$

*La discretización es estable en norma 2, y el error global es:*

$$\|e^h\|_2 \leq Ch^2.$$

### 5.3.2 Condiciones de borde de Neumann

Consideremos ahora un problema con condición de Neumann en un extremo:

$$\begin{cases} -u_{xx}(x) = f(x), & \text{para } x \in (0, 1) \\ u_x(0) = \sigma \\ u(1) = \beta. \end{cases} \quad (5.4)$$

**Método 1: Nodo ficticio.** Usamos diferencias centradas para  $u_x(0)$ :

$$\frac{u_1 - u_{-1}}{2h} = \sigma.$$

Evaluando la ecuación en  $j = 0$ :

$$\frac{1}{h^2} (u_{-1} - 2u_0 + u_1) = f(x_0).$$

Despejando  $u_{-1} = u_1 - 2h\sigma$  y sustituyendo:

$$\frac{u_1 - u_0}{h} = \sigma + \frac{h}{2} f(x_0).$$

Esta fórmula es una corrección de orden  $O(h^2)$  a la diferencia forward. En efecto, considerando  $u'(x_0 + h/2)$ :

$$u' \left( x_0 + \frac{h}{2} \right) = u'(x_0) + \frac{h}{2} u''(x_0) + O(h^2) = \sigma - \frac{h}{2} f(x_0) + O(h^2).$$

Usando diferencias centradas en  $x_0 + h/2$ :

$$u' \left( x_0 + \frac{h}{2} \right) \approx \frac{u_1 - u_0}{h}.$$

Igualando, obtenemos la fórmula deseada con error  $O(h^2)$ .

**Método 2: Diferencia forward de orden 2.** Usando la fórmula de tres puntos:

$$u'(x_0) = \frac{-3u_0 + 4u_1 - u_2}{2h} + O(h^2) = \sigma.$$

Esta aproximación también tiene error  $O(h^2)$  y no requiere nodo ficticio.

### 5.3.3 Condiciones de borde periódicas

Consideremos la ecuación con periodicidad:

$$\begin{cases} -u_{xx}(x) = f(x), & \text{para } x \in (0, 2\pi) \\ u(0) = u(2\pi) \end{cases} \quad (5.5)$$

Discretizando con  $x_j = jh$ ,  $h = 2\pi/(m+1)$ :

$$\frac{1}{h^2} (u_{j-1} - 2u_j + u_{j+1}) = f(x_j), \quad j = 0, 1, \dots, m,$$

con  $u_{-1} = u_m$  y  $u_{m+1} = u_0$  (periodicidad).

**Lema 5.28** (Modos de Fourier discretos como autofunciones). *Considerando  $W_j(\xi) = e^{i\xi x_j} = e^{i\xi jh}$ , tenemos:*

$$\delta_{xx}(W(\xi))_j = \frac{1}{h^2} (W_{j+1} - 2W_j + W_{j-1}) = -\frac{4}{h^2} \sin^2 \left( \frac{h\xi}{2} \right) W_j.$$

*Demostración.*

$$\begin{aligned} \delta_{xx}(W)_j &= \frac{1}{h^2} (e^{i(j+1)h\xi} - 2e^{ijh\xi} + e^{i(j-1)h\xi}) \\ &= \frac{1}{h^2} (e^{ih\xi} - 2 + e^{-ih\xi}) e^{ijh\xi} \\ &= \frac{2}{h^2} (\cos(h\xi) - 1) e^{ijh\xi} \\ &= -\frac{4}{h^2} \sin^2 \left( \frac{h\xi}{2} \right) W_j, \end{aligned}$$

usando  $\cos(2x) = 1 - 2\sin^2(x)$ . □

**Observación 5.29.** El autovalor discreto  $\lambda(\xi) = -\frac{4}{h^2} \sin^2\left(\frac{h\xi}{2}\right)$  aproxima el autovalor continuo  $-\xi^2$  con error  $O(h^2)$ :

$$-\frac{4}{h^2} \sin^2\left(\frac{h\xi}{2}\right) = -\frac{4}{h^2} \cdot \frac{h^2 \xi^2}{4} + O(h^4) = -\xi^2 + O(h^2).$$

**Lema 5.30** (Ortonormalidad de modos de Fourier discretos). Los modos  $W(k) = \left\{ \frac{e^{kijh}}{\sqrt{2\pi}} \right\}_{j=0}^m$  con  $h = 2\pi/(m+1)$ ,  $k \in \mathbb{Z}$ , son ortonormales respecto al producto interno discreto:

$$(v, w) = h \sum_{j=0}^m v_j \bar{w}_j.$$

*Demostración.* Basta probar que para  $k \neq 0$ :

$$h \sum_{j=0}^m e^{kijh} = 0.$$

Usando la suma geométrica:

$$h \sum_{j=0}^m \left( e^{ikh} \right)^j = h \frac{1 - e^{ikh(m+1)}}{1 - e^{ikh}} = h \frac{1 - e^{2\pi ik}}{1 - e^{ikh}} = 0,$$

ya que  $e^{2\pi ik} = 1$  para  $k \in \mathbb{Z}$  y  $e^{ikh} \neq 1$  para  $|k| \leq m$ . □

**Corolario 5.31.** La matriz del sistema periódico se diagonaliza en una base ortonormal (los modos de Fourier discretos). Por tanto,  $\|(A^h)^{-1}\|_2 = 1/|\lambda_{\min}|$ , donde:

$$\lambda_{\min} = -\frac{4}{h^2} \sin^2\left(\frac{\pi h}{2}\right) \sim -\pi^2 + O(h^2).$$

La discretización es estable con  $\|(A^h)^{-1}\|_2 \leq 1/\pi^2 + O(h^2)$ .

### 5.3.4 Caso general: término de reacción

Consideremos el problema más general:

$$\begin{cases} -u_{xx}(x) + q(x)u(x) = f(x), & \text{para } x \in (a, b) \\ u(a) = \alpha \\ u(b) = \beta, \end{cases} \quad (5.6)$$

con  $q(x) \geq 0$ .

La discretización conduce al sistema:

$$A^h u^h = F^h,$$

donde:

$$A^h = \frac{1}{h^2} \begin{pmatrix} 2 + h^2 q_1 & -1 & 0 & \cdots & 0 \\ -1 & 2 + h^2 q_2 & -1 & \cdots & 0 \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 0 & \cdots & -1 & 2 + h^2 q_{m-1} & -1 \\ 0 & \cdots & 0 & -1 & 2 + h^2 q_m \end{pmatrix}.$$

**Teorema 5.32** (Dominancia diagonal estricta). Si  $q(x) \geq q_0 > 0$  para todo  $x \in (a, b)$ , entonces  $A^h$  es estrictamente diagonalmente dominante por filas:

$$|a_{jj}| = \frac{2 + h^2 q_j}{h^2} > \frac{2}{h^2} = \sum_{k \neq j} |a_{jk}|.$$

Por el teorema de Gershgorin,  $A^h$  es no singular. Más aún, existe  $C$  independiente de  $h$  tal que  $\|(A^h)^{-1}\|_\infty \leq C$ .

**Observación 5.33** (Principio de máximo discreto). Cuando  $q(x) \geq 0$ , la matriz  $A^h$  satisface un **principio de máximo discreto**: si  $A^h w \geq 0$  y  $w_0, w_{m+1} \geq 0$ , entonces  $w_j \geq 0$  para todo  $j = 1, \dots, m$ . Esto generaliza el principio de máximo para la ecuación diferencial y permite demostrar estabilidad en norma infinito:

$$\|(A^h)^{-1}\|_\infty \leq C(b-a)^2,$$

donde  $C$  depende solo de  $\|q\|_\infty$ .

**Problemas en dimensiones superiores.** Para la ecuación de Poisson 2D:

$$-\Delta u = f \quad \text{en } \Omega, \quad u = g \quad \text{en } \partial\Omega,$$

discretizamos en una malla  $(x_i, y_j)$  con  $x_i = ih$ ,  $y_j = jh$ . La aproximación del Laplaciano es:

$$\Delta u_{ij} \approx \frac{u_{i+1,j} + u_{i-1,j} + u_{i,j+1} + u_{i,j-1} - 4u_{ij}}{h^2}.$$

Esto da un sistema lineal de tamaño  $N^2 \times N^2$  (para malla  $N \times N$ ). La matriz es grande pero **esparsa** (cada fila tiene solo 5 elementos no nulos). Métodos iterativos como Gauss-Seidel, gradiente conjugado, o multigrad son esenciales para resolver sistemas grandes eficientemente.

**Ejemplo 5.34** (Problema de Sturm-Liouville discreto). Considerar el problema de autovalores:

$$-u''(x) = \lambda u(x), \quad x \in (0, 1), \quad u(0) = u(1) = 0.$$

Discretizando con diferencias finitas, obtenemos:

$$\frac{1}{h^2} \begin{pmatrix} 2 & -1 & 0 & \cdots & 0 \\ -1 & 2 & -1 & \cdots & 0 \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 0 & \cdots & -1 & 2 & -1 \\ 0 & \cdots & 0 & -1 & 2 \end{pmatrix} \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_{N-1} \\ u_N \end{pmatrix} = \lambda \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_{N-1} \\ u_N \end{pmatrix}.$$

Los autovalores de esta matriz aproximan  $\lambda_k = (k\pi)^2$  con error  $O(h^2)$ . Los autovectores aproximan las autofunciones  $\sin(k\pi x)$ . Este es el fundamento de métodos espectrales discretos.

### 5.3.5 Métodos espectrales

El primer paso en la implementación de métodos espectrales es calcular derivadas de funciones representadas por sus coeficientes de Fourier. Si  $f(x) = \sum_{k=-N/2}^{N/2} \hat{f}_k e^{ikx}$ , entonces su derivada es:

$$f'(x) = \sum_{k=-N/2}^{N/2} ik \hat{f}_k e^{ikx}.$$

En el contexto discreto, dados valores  $f_j = f(x_j)$  en puntos de malla equiespaciados:

1. Calcular  $\hat{F}[k] = \text{FFT}\{f_j\}$ .
2. Multiplicar por  $ik$  (análogo a la Ecuación (4.8)):  $\hat{F}'[k] = ik \cdot \hat{F}[k]$  (con  $k$  apropiadamente definido para la DFT).
3. Calcular  $f'_j = \text{IFFT}\{\hat{F}'[k]\}$ .

Este método proporciona **precisión espectral**: si  $f$  es suave, el error decrece más rápido que cualquier potencia de  $1/N$  (decaimiento exponencial). Es la base de los *métodos espectrales* para resolver numéricamente ecuaciones diferenciales.

Para problemas no periódicos en un intervalo  $[a, b]$ , los polinomios de Chebyshev son la base natural. Tras cambio de variable, trabajamos en  $[-1, 1]$ .

**Derivadas espectrales de Chebyshev.** Si  $u(x) = \sum_{k=0}^N a_k T_k(x)$ , su derivada es  $u'(x) = \sum_{k=0}^N b_k T_k(x)$  donde los coeficientes  $\{b_k\}$  se relacionan con  $\{a_k\}$  mediante:

$$b_k = \sum_{j=k+1, j+k \text{ impar}}^N \frac{2ja_j}{c_k},$$

donde  $c_0 = 2$ ,  $c_k = 1$  para  $k \geq 1$ . Esta fórmula se deriva de la relación de recurrencia para derivadas de Chebyshev. En la práctica, dados valores  $u_j = u(x_j)$  en los nodos de Chebyshev  $x_j = \cos(j\pi/N)$ :

1. Calcular coeficientes:  $a_k = \text{DCT}\{u_j\}$  (transformada coseno discreta,  $O(N \log N)$  vía FFT).
2. Aplicar matriz de derivación en espacio de coeficientes:  $b_k = \sum_j D_{kj} a_j$ .
3. Transformar de vuelta:  $u'_j = \text{IDCT}\{b_k\}$ .

Alternativamente, se puede usar la **matriz de derivación** directamente en espacio físico:  $u'_j = \sum_{\ell=0}^N D_{j\ell} u_\ell$ , donde  $D$  es densa pero tiene estructura conocida.

**Método de colocación espectral.** Para resolver un PVC:

$$Lu = f \quad \text{en } (-1, 1), \quad u(-1) = u_a, \quad u(1) = u_b,$$

donde  $L$  es un operador diferencial, aproximamos  $u \approx u_N = \sum_{k=0}^N \hat{u}_k T_k$  e imponemos que la ecuación se satisfaga exactamente en los nodos interiores de Chebyshev  $\{x_j\}_{j=1}^{N-1}$ :

$$(Lu_N)(x_j) = f(x_j), \quad j = 1, \dots, N-1,$$

más las condiciones de frontera:

$$u_N(-1) = u_a, \quad u_N(1) = u_b.$$

Esto da un sistema algebraico (generalmente denso) de  $N + 1$  ecuaciones para los  $N + 1$  coeficientes.

**Ejemplo 5.35** (Ecuación de Helmholtz 1D). Resolver  $-u''(x) - k^2 u(x) = f(x)$  en  $(-1, 1)$  con  $u(\pm 1) = 0$ . Discretizando con Chebyshev:

$$-(D^2 u)_j - k^2 u_j = f_j, \quad j = 1, \dots, N-1,$$

donde  $D^2$  es la segunda derivada espectral (obtenida aplicando  $D$  dos veces o usando fórmula directa). Con las condiciones de frontera, obtenemos un sistema lineal de tamaño  $(N-1) \times (N-1)$ . La matriz es densa pero el sistema se resuelve en  $O(N^2)$  (directo) o  $O(N)$  iteraciones con preconditionador.

**Convergencia espectral.** Para funciones analíticas en una región que contiene  $[-1, 1]$ , el error decrece exponencialmente:  $\|u - u_N\| = O(\rho^{-N})$  con  $\rho > 1$ . Para funciones  $C^m$  pero no analíticas, el error es  $O(N^{-m})$ , similar a diferencias finitas de orden alto pero con constantes más favorables.

**Ventajas vs diferencias finitas:**

- **Precisión superior:** Para funciones suaves, métodos espectrales alcanzan precisión de máquina con  $N$  moderado ( $N \sim 10-100$ ), mientras que diferencias finitas requieren  $N \sim 10^3-10^6$ .
- **Derivadas de alto orden:** Calcular  $u^{(k)}$  es directo en métodos espectrales; en diferencias finitas, stencils de alto orden son complejos e inestables.

**Desventajas:**

- **Matrices densas:** Los sistemas lineales no tienen la estructura de banda de diferencias finitas, aunque hay métodos rápidos (FFT, preconditionadores).
- **Geometrías complejas:** Métodos espectrales son naturales en dominios rectangulares; para geometrías irregulares, se necesitan extensiones (métodos de elementos espectrales).
- **Funciones no suaves:** Si  $u$  tiene singularidades o discontinuidades, la convergencia espectral se pierde (fenómeno de Gibbs). En estos casos, diferencias finitas o elementos finitos pueden ser preferibles.

**Ejemplo 5.36** (Comparación numérica:  $-u'' = \pi^2 \sin(\pi x)$ ,  $u(\pm 1) = 0$ ). Solución exacta:  $u(x) = \sin(\pi x)$ . Errores  $\|u - u_N\|_\infty$ :

| $N$ | Diferencias finitas ( $O(h^2)$ ) | Chebyshev espectral        |
|-----|----------------------------------|----------------------------|
| 10  | $8.2 \times 10^{-3}$             | $1.3 \times 10^{-12}$      |
| 20  | $2.1 \times 10^{-3}$             | $4.4 \times 10^{-15}$      |
| 40  | $5.1 \times 10^{-4}$             | $\sim 10^{-16}$ (redondeo) |



*El método espectral alcanza precisión de máquina con  $N = 20$ , mientras que diferencias finitas requiere  $N \gg 100$  para similar precisión.*

**Extensión a múltiples dimensiones.** En 2D, usamos productos tensoriales de polinomios de Chebyshev:  $u(x, y) \approx \sum_{j,k} \hat{u}_{jk} T_j(x) T_k(y)$ . Las derivadas se calculan aplicando  $D$  en cada dirección. Para la ecuación de Poisson  $-\Delta u = f$  en el cuadrado  $[-1, 1]^2$ , el sistema discreto es de tamaño  $N^2 \times N^2$  y se resuelve con métodos iterativos, usando FFT multidimensional para aplicar operadores rápidamente.

En resumen, los métodos espectrales son la herramienta de elección cuando la solución es suave y la geometría es simple. Su precisión superior (convergencia exponencial vs algebraica) los hace indispensables en simulaciones de fluidos, ondas, y otros problemas donde la resolución fina de estructuras suaves es crítica.

## Chapter 6

# Sistemas No Lineales y Optimización Numérica

Este capítulo aborda dos problemas íntimamente relacionados:

1. **Ecuaciones no lineales:** hallar  $x$  tal que  $f(x) = 0$  (una variable) o  $F(x) = 0$  (varias variables).
2. **Optimización:** hallar  $x$  que minimice un funcional  $\varphi(x)$ .

A diferencia de los sistemas lineales, donde existe una solución alcanzable en un número finito de operaciones, aquí solo podemos *aproximarnos* al resultado mediante iteración. Desarrollamos los métodos fundamentales en orden de sofisticación creciente: bisección (simple y robusto), Newton en una variable (convergencia cuadrática), Newton en dimensión  $n$ , y descenso por gradiente para optimización.

### 6.1 El método de la bisección

El método más elemental para resolver  $f(x) = 0$  explota únicamente el **teorema del valor intermedio** (Teorema A.1): si  $f$  es continua en  $[a, b]$  y  $f(a)f(b) < 0$ , entonces  $f$  tiene al menos una raíz en  $(a, b)$ .

**Definición 6.1** (Método de la bisección). *Dados  $a_0 < b_0$  con  $f(a_0)f(b_0) < 0$ , el método genera intervalos  $[a_k, b_k]$  encajados con  $f(a_k)f(b_k) \leq 0$ :*

1. Calcular el punto medio  $m_k = \frac{a_k + b_k}{2}$ .
2. Si  $f(m_k) = 0$ , terminamos.
3. Si  $f(a_k)f(m_k) < 0$ , definimos  $a_{k+1} = a_k$ ,  $b_{k+1} = m_k$ .
4. Si  $f(m_k)f(b_k) < 0$ , definimos  $a_{k+1} = m_k$ ,  $b_{k+1} = b_k$ .

**Teorema 6.2** (Convergencia de la bisección). Sea  $f \in C([a, b])$  con  $f(a)f(b) < 0$ . El método de la bisección genera una sucesión de intervalos  $[a_k, b_k]$  que contienen al menos una raíz  $x^*$  de  $f$ , y satisface:

$$|m_k - x^*| \leq \frac{b-a}{2^{k+1}}.$$

En particular, para obtener un error menor que  $\varepsilon$  se necesitan  $k = \lceil \log_2(\frac{b-a}{\varepsilon}) \rceil$  iteraciones.

*Demostración.* Por inducción,  $b_k - a_k = (b-a)/2^k$  y  $f(a_k)f(b_k) \leq 0$  en cada paso. Por el teorema del valor intermedio, existe  $x^* \in [a_k, b_k]$ , y por lo tanto  $|m_k - x^*| \leq (b_k - a_k)/2 = (b-a)/2^{k+1}$ .  $\square$

**Observación 6.3** (Ventajas y limitaciones). La bisección:

- **Siempre converge** (no requiere diferenciabilidad, solo continuidad y cambio de signo).
- Agrega un bit de precisión por iteración: convergencia **lineal** con tasa  $1/2$ .
- No generaliza directamente a dimensión  $n > 1$ .

La convergencia lineal es lenta: para obtener 16 dígitos se necesitan  $\sim 53$  iteraciones. Esto motiva buscar métodos con convergencia más rápida, a costa de hipótesis más fuertes.

## 6.2 El método de Newton en una variable

### 6.2.1 Derivación como aproximación cuadrática

Sea  $f : \mathbb{R} \rightarrow \mathbb{R}$  una función dos veces diferenciable. Queremos resolver  $f(x) = 0$ . Si tenemos una aproximación  $x_k$ , desarrollamos  $f$  en Taylor alrededor de  $x_k$ :

$$f(x) = f(x_k) + f'(x_k)(x - x_k) + \frac{f''(\xi)}{2}(x - x_k)^2$$

para algún  $\xi$  entre  $x$  y  $x_k$ . Si  $x_k$  está cerca de una raíz  $x^*$  y  $f'(x_k) \neq 0$ , el término dominante del error es el lineal. Descartando el término cuadrático y resolviendo la ecuación lineal  $f(x_k) + f'(x_k)(x - x_k) = 0$ , obtenemos la nueva aproximación:

**Definición 6.4** (Método de Newton en una variable). Dado  $x_0 \in \mathbb{R}$ , la **iteración de Newton** es:

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}, \quad k = 0, 1, 2, \dots$$

**Interpretación geométrica:** en cada paso, reemplazamos la gráfica de  $f$  por su recta tangente en  $(x_k, f(x_k))$  y tomamos la raíz de esa tangente como nueva aproximación.

### 6.2.2 Convergencia cuadrática local

**Teorema 6.5** (Convergencia cuadrática de Newton en 1D). Sea  $f \in C^2([a, b])$  con una raíz  $x^* \in (a, b)$  tal que  $f'(x^*) \neq 0$ . Entonces existe  $\delta > 0$  tal que, si  $|x_0 - x^*| < \delta$ , la sucesión de Newton converge a  $x^*$  y satisface:

$$|x_{k+1} - x^*| \leq C |x_k - x^*|^2, \quad C = \frac{|f''(x^*)|}{2|f'(x^*)|}.$$

*Demostración.* Como  $f(x^*) = 0$  y  $f \in C^2$ , el desarrollo de Taylor de  $f$  alrededor de  $x_k$  evaluado en  $x^*$  da:

$$0 = f(x^*) = f(x_k) + f'(x_k)(x^* - x_k) + \frac{f''(\xi_k)}{2}(x^* - x_k)^2,$$

para algún  $\xi_k$  entre  $x_k$  y  $x^*$ . Dividiendo por  $f'(x_k) \neq 0$  (que vale en una vecindad de  $x^*$  por continuidad):

$$0 = \frac{f(x_k)}{f'(x_k)} + (x^* - x_k) + \frac{f''(\xi_k)}{2f'(x_k)}(x^* - x_k)^2.$$

Recordando que  $x_{k+1} = x_k - f(x_k)/f'(x_k)$  y por lo tanto  $f(x_k)/f'(x_k) = x_k - x_{k+1}$ :

$$0 = (x_k - x_{k+1}) + (x^* - x_k) + \frac{f''(\xi_k)}{2f'(x_k)}(x^* - x_k)^2 = -(x_{k+1} - x^*) + \frac{f''(\xi_k)}{2f'(x_k)}(x_k - x^*)^2.$$

Despejando:

$$x_{k+1} - x^* = \frac{f''(\xi_k)}{2f'(x_k)}(x_k - x^*)^2.$$

Tomando valor absoluto y usando la continuidad de  $f''$  y  $f'$ :

$$|x_{k+1} - x^*| = \frac{|f''(\xi_k)|}{2|f'(x_k)|}|x_k - x^*|^2 \leq C|x_k - x^*|^2,$$

con  $C = \sup_{|t-x^*|<\delta} \frac{|f''(t)|}{2|f'(t)|}$ , que es finito para  $\delta$  suficientemente pequeño.

Para garantizar la convergencia, elegimos  $\delta$  tal que  $C\delta < 1$ . Entonces  $|x_1 - x^*| \leq C|x_0 - x^*|^2 < C\delta \cdot |x_0 - x^*| < |x_0 - x^*|$ , y por inducción la sucesión converge a  $x^*$ .  $\square$

**Observación 6.6** (Raíces múltiples). *La hipótesis  $f'(x^*) \neq 0$  (raíz simple) es esencial. Si  $x^*$  es una raíz de multiplicidad  $m \geq 2$ , es decir  $f(x) = (x - x^*)^m g(x)$  con  $g(x^*) \neq 0$ , entonces  $f'(x^*) = 0$  y el teorema no aplica. En este caso, Newton sigue convergiendo, pero solo **linealmente** con tasa  $1 - 1/m$ . Se puede recuperar la convergencia cuadrática usando la iteración modificada:*

$$x_{k+1} = x_k - m \frac{f(x_k)}{f'(x_k)},$$

*siempre que se conozca la multiplicidad  $m$ .*

**Observación 6.7** (Convergencia cuadrática: duplicación de dígitos). *La convergencia cuadrática  $|e_{k+1}| \leq C|e_k|^2$  significa que el número de dígitos correctos se **duplica** en cada iteración. Partiendo de 1 dígito correcto:*

| $k$               | 0 | 1 | 2 | 3 | 4  |
|-------------------|---|---|---|---|----|
| dígitos correctos | 1 | 2 | 4 | 8 | 16 |

*Cuatro iteraciones de Newton equivalen a  $\sim 53$  iteraciones de bisección. Este es el precio de la diferenciableidad: a cambio de pedir  $f \in C^2$  y  $f'(x^*) \neq 0$ , la convergencia es enormemente más rápida.*

**Ejemplo 6.8** (Cálculo de  $\sqrt{2}$ ). Para calcular  $\sqrt{2}$ , aplicamos Newton a  $f(x) = x^2 - 2$  con  $f'(x) = 2x$ :

$$x_{k+1} = x_k - \frac{x_k^2 - 2}{2x_k} = \frac{x_k}{2} + \frac{1}{x_k}.$$

Partiendo de  $x_0 = 1$ :

| $k$ | $x_k$            | $ x_k - \sqrt{2} $    |
|-----|------------------|-----------------------|
| 0   | 1                | $4.1 \times 10^{-1}$  |
| 1   | 1.5              | $8.6 \times 10^{-2}$  |
| 2   | 1.41 $\bar{6}$   | $2.5 \times 10^{-3}$  |
| 3   | 1.41421568...    | $1.0 \times 10^{-6}$  |
| 4   | 1.41421356237... | $1.6 \times 10^{-12}$ |

Los dígitos correctos se duplican en cada paso, como predice el teorema.

**Observación 6.9** (Método de la secante). El método de Newton requiere evaluar  $f'(x_k)$  en cada paso. Cuando la derivada es costosa o no está disponible en forma cerrada, se la puede aproximar por una diferencia dividida, obteniendo el **método de la secante**:

$$x_{k+1} = x_k - f(x_k) \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})}.$$

Geométricamente, en lugar de trazar la tangente a  $f$  en  $x_k$ , se traza la secante que pasa por  $(x_{k-1}, f(x_{k-1}))$  y  $(x_k, f(x_k))$ . El método necesita dos puntos iniciales  $x_0, x_1$ , y cada iteración requiere solo una evaluación de  $f$  (sin derivada). Puede demostrarse que el orden de convergencia es  $p = \frac{1+\sqrt{5}}{2} \approx 1.618$  (el número áureo): intermedio entre lineal y cuadrático.

## 6.3 El método de Newton en dimensión $n$

### 6.3.1 Formulación para sistemas

El método de Newton se generaliza naturalmente a sistemas de ecuaciones no lineales. Dado  $F: \mathbb{R}^n \rightarrow \mathbb{R}^n$  diferenciable, queremos resolver  $F(x) = 0$ . Linealizando  $F$  alrededor de  $x^{(k)}$ :

$$F(x) \approx F(x^{(k)}) + J_F(x^{(k)})(x - x^{(k)}),$$

donde  $J_F(x) \in \mathbb{R}^{n \times n}$  es la **matriz Jacobiana** con  $(J_F)_{ij} = \frac{\partial F_i}{\partial x_j}$ . Igualando a cero la aproximación lineal:

**Definición 6.10** (Método de Newton para sistemas). Dado  $x^{(0)} \in \mathbb{R}^n$ , la iteración de Newton es:

$$x^{(k+1)} = x^{(k)} - [J_F(x^{(k)})]^{-1} F(x^{(k)}).$$

En la práctica, nunca se invierte  $J_F$  explícitamente: se resuelve el **sistema lineal**

$$J_F(x^{(k)}) \delta^{(k)} = -F(x^{(k)}), \quad x^{(k+1)} = x^{(k)} + \delta^{(k)}. \quad (6.1)$$

Cada iteración requiere: evaluar  $F$  y  $J_F$ , y resolver un sistema lineal  $n \times n$  (coste  $O(n^3)$  con factorización LU, o menos con estructura esparsa).

### 6.3.2 Convergencia cuadrática local

**Teorema 6.11** (Convergencia cuadrática de Newton en  $\mathbb{R}^n$ ). Sea  $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$  continuamente diferenciable en un entorno de  $x^*$  con  $F(x^*) = 0$ . Supongamos:

1.  $J_F(x^*)$  es invertible.

2.  $J_F$  es Lipschitz en un entorno de  $x^*$ :  $\|J_F(x) - J_F(y)\| \leq L \|x - y\|$ .

Entonces existe  $\delta > 0$  tal que, si  $\|x^{(0)} - x^*\| < \delta$ , la sucesión de Newton converge a  $x^*$  con

$$\|x^{(k+1)} - x^*\| \leq C \|x^{(k)} - x^*\|^2, \quad C = \frac{L}{2} \| [J_F(x^*)]^{-1} \|.$$

*Demostración.* El desarrollo de Taylor vectorial de  $F$  alrededor de  $x^{(k)}$ , evaluado en  $x^*$ , es:

$$0 = F(x^*) = F(x^{(k)}) + J_F(x^{(k)})(x^* - x^{(k)}) + R_k,$$

donde el resto es  $R_k = \int_0^1 [J_F(x^{(k)} + t(x^* - x^{(k)})) - J_F(x^{(k)})](x^* - x^{(k)}) dt$ .

Multiplicando por  $[J_F(x^{(k)})]^{-1}$  y usando la definición (6.1):

$$x^{(k+1)} - x^* = -[J_F(x^{(k)})]^{-1} R_k.$$

La condición Lipschitz da  $\|R_k\| \leq \frac{L}{2} \|x^{(k)} - x^*\|^2$ , y en un entorno de  $x^*$  la inversa  $[J_F(x^{(k)})]^{-1}$  está uniformemente acotada, con lo cual:

$$\|x^{(k+1)} - x^*\| \leq \| [J_F(x^{(k)})]^{-1} \| \cdot \frac{L}{2} \|x^{(k)} - x^*\|^2 \leq C \|x^{(k)} - x^*\|^2. \quad \square$$

### 6.3.3 Aplicación a optimización

Para el problema  $\min_x \varphi(x)$  con  $\varphi : \mathbb{R}^n \rightarrow \mathbb{R}$  dos veces diferenciable, un minimizador local  $x^*$  satisface  $\nabla \varphi(x^*) = 0$ . Aplicando Newton a  $F(x) = \nabla \varphi(x)$ :

$$x^{(k+1)} = x^{(k)} - [\nabla^2 \varphi(x^{(k)})]^{-1} \nabla \varphi(x^{(k)}),$$

donde  $\nabla^2 \varphi$  es la **matriz Hessiana**. Si  $\nabla^2 \varphi(x^*) \succ 0$  (minimizador local estricto), el Teorema 6.11 aplica directamente y la convergencia es cuadrática.

**Observación 6.12** (Newton vs. descenso por gradiente). • **Convergencia:** Newton es cuadrática (localmente), gradiente es lineal.

- **Costo por iteración:** Newton:  $O(n^3)$  (resolver con Hessiana). Gradiente:  $O(n)$ .
- **Convergencia global:** Gradiente con paso adecuado converge globalmente; Newton requiere estar cerca del óptimo.
- **En la práctica:** los métodos **cuasi-Newton** (como BFGS) aproximan la Hessiana a partir de información de gradiente, combinando ventajas de ambos.

## 6.4 Descenso por gradiente

Para problemas de optimización donde la dimensión  $n$  es grande o la Hessiana es costosa de calcular, el **descenso por gradiente** es el método de referencia. Su idea es simple: moverse en la dirección de mayor decrecimiento de la función.

### 6.4.1 Motivación geométrica y definición

Sea  $\varphi : \mathbb{R}^n \rightarrow \mathbb{R}$  diferenciable. En un punto  $x$ , el gradiente  $\nabla\varphi(x)$  apunta en la dirección de mayor crecimiento de  $\varphi$ . Por lo tanto,  $-\nabla\varphi(x)$  es la dirección de **mayor decrecimiento**.

**Definición 6.13** (Método de descenso por gradiente). *Dado un punto inicial  $x^{(0)} \in \mathbb{R}^n$  y tamaños de paso  $\{\alpha_k\}$ :*

$$x^{(k+1)} = x^{(k)} - \alpha_k \nabla\varphi(x^{(k)}), \quad k = 0, 1, 2, \dots$$

*El parámetro  $\alpha_k > 0$  se llama **tamaño de paso** (o **tasa de aprendizaje** en aprendizaje automático).*

### 6.4.2 Convergencia con paso constante para funciones fuertemente convexas

Para obtener un resultado preciso de convergencia, necesitamos hipótesis cuantitativas sobre la función. Introducimos las nociones de convexidad fuerte y suavidad, y a partir de ellas derivamos una desigualdad de descenso fundamental.

**Definición 6.14** (Función fuertemente convexa). *Una función  $\varphi : \mathbb{R}^n \rightarrow \mathbb{R}$  es  $\mu$ -fuertemente convexa ( $\mu > 0$ ) si para todo  $x, y$ :*

$$\varphi(y) \geq \varphi(x) + \nabla\varphi(x)^T(y - x) + \frac{\mu}{2}\|y - x\|^2.$$

*Si  $\varphi$  es  $C^2$ , esto equivale a  $\nabla^2\varphi(x) \succeq \mu I$  para todo  $x$ .*

**Definición 6.15** (Suavidad de Lipschitz).  *$\varphi$  es  $L$ -suave si  $\nabla\varphi$  es  $L$ -Lipschitz:*

$$\|\nabla\varphi(x) - \nabla\varphi(y)\| \leq L\|x - y\| \quad \forall x, y.$$

*Si  $\varphi$  es  $C^2$ , esto equivale a  $\nabla^2\varphi(x) \preceq LI$  para todo  $x$ .*

Una función  $\mu$ -fuertemente convexa y  $L$ -suave satisface  $\mu I \preceq \nabla^2\varphi \preceq LI$ : los autovalores del Hessiano están entre  $\mu$  y  $L$ . El **número de condición**  $\kappa = L/\mu \geq 1$  mide cuánto difiere  $\varphi$  de una función cuadrática isótropa.

**Lema 6.16** (Desigualdad de descenso). *Si  $\varphi$  es  $L$ -suave, entonces para todo  $x, y$ :*

$$\varphi(y) \leq \varphi(x) + \nabla\varphi(x)^T(y - x) + \frac{L}{2}\|y - x\|^2. \quad (6.2)$$

*Recíprocamente, si  $\varphi$  es  $\mu$ -fuertemente convexa:*

$$\varphi(y) \geq \varphi(x) + \nabla\varphi(x)^T(y - x) + \frac{\mu}{2}\|y - x\|^2. \quad (6.3)$$

*La primera desigualdad dice que  $\varphi$  está acotada superiormente por una parábola de curvatura  $L$  en cada punto; la segunda, que está acotada inferiormente por una parábola de curvatura  $\mu$ .*

*Demostración.* Para (6.2): por el teorema fundamental del cálculo,

$$\varphi(y) - \varphi(x) = \int_0^1 \nabla \varphi(x + t(y - x))^T (y - x) dt.$$

Sumando y restando  $\nabla \varphi(x)^T (y - x)$ :

$$\varphi(y) - \varphi(x) - \nabla \varphi(x)^T (y - x) = \int_0^1 [\nabla \varphi(x + t(y - x)) - \nabla \varphi(x)]^T (y - x) dt.$$

Por Cauchy-Schwarz y la condición Lipschitz  $\|\nabla \varphi(u) - \nabla \varphi(v)\| \leq L\|u - v\|$ :

$$\leq \int_0^1 L t \|y - x\|^2 dt = \frac{L}{2} \|y - x\|^2.$$

La desigualdad (6.3) es exactamente la definición de  $\mu$ -convexidad fuerte.  $\square$

**Teorema 6.17** (Convergencia de descenso por gradiente). *Sea  $\varphi : \mathbb{R}^n \rightarrow \mathbb{R}$   $\mu$ -fuertemente convexa y  $L$ -suave, con minimizador  $x^*$ . Con paso constante  $\alpha = 1/L$ :*

$$\|x^{(k)} - x^*\|^2 \leq \left(1 - \frac{1}{\kappa}\right)^k \|x^{(0)} - x^*\|^2, \quad \kappa = \frac{L}{\mu}.$$

*Demostración. Paso 1: Desigualdad de descenso.* Aplicando el Lema 6.16 (6.2) con  $y = x^{(k+1)} = x^{(k)} - \frac{1}{L} \nabla \varphi(x^{(k)})$  y  $x = x^{(k)}$ :

$$\varphi(x^{(k+1)}) \leq \varphi(x^{(k)}) - \frac{1}{2L} \|\nabla \varphi(x^{(k)})\|^2.$$

**Paso 2: Cota del gradiente.** Por (6.3) con  $y = x^*$  y  $x = x^{(k)}$ , y usando  $\nabla \varphi(x^*) = 0$ :

$$\varphi(x^{(k)}) - \varphi(x^*) \leq \nabla \varphi(x^{(k)})^T (x^{(k)} - x^*) - \frac{\mu}{2} \|x^{(k)} - x^*\|^2 \leq \frac{1}{2\mu} \|\nabla \varphi(x^{(k)})\|^2,$$

donde la última desigualdad se obtiene aplicando Young con parámetro  $\mu$ . Combinando:

$$\varphi(x^{(k+1)}) - \varphi(x^*) \leq \left(1 - \frac{\mu}{L}\right) (\varphi(x^{(k)}) - \varphi(x^*)).$$

**Paso 3: De energía a distancia.** Por inducción,  $\varphi(x^{(k)}) - \varphi(x^*) \leq (1 - 1/\kappa)^k (\varphi(x^{(0)}) - \varphi(x^*))$ . Usando  $\varphi(x) - \varphi(x^*) \geq \frac{\mu}{2} \|x - x^*\|^2$  y  $\varphi(x^{(0)}) - \varphi(x^*) \leq \frac{L}{2} \|x^{(0)} - x^*\|^2$  se obtiene el resultado.  $\square$

**Observación 6.18** (Convergencia lineal y número de condición). *La convergencia es **lineal** con tasa  $1 - 1/\kappa$ . Para reducir el error por un factor  $\varepsilon$  se necesitan*

$$k \approx \kappa \log(1/\varepsilon)$$

*iteraciones. Si  $\kappa \gg 1$  (problema mal condicionado), la convergencia es lenta. Esto es el análogo en optimización del mal condicionamiento de sistemas lineales, y motiva los métodos de segundo orden (Newton) y los métodos cuasi-Newton (BFGS) que aproximan la curvatura sin calcular la Hessiana completa.*



## Appendix A

# Herramientas de Análisis y Álgebra

En este apéndice recopilamos resultados fundamentales de análisis matemático que se utilizan como herramientas a lo largo del apunte. Todos ellos son resultados clásicos que se estudian en cursos de Análisis Matemático y Álgebra, pero los enunciamos y demostramos aquí para facilitar la referencia.

### A.1 Teorema del valor intermedio

**Teorema A.1** (Teorema de Bolzano). *Sea  $f : [a, b] \rightarrow \mathbb{R}$  continua con  $f(a) \cdot f(b) < 0$ . Entonces existe  $c \in (a, b)$  tal que  $f(c) = 0$ .*

*Demostración.* Construimos por bisección sucesivas dos sucesiones  $\{a_n\}$  y  $\{b_n\}$  con  $a_0 = a$ ,  $b_0 = b$  tales que  $f(a_n) \cdot f(b_n) \leq 0$  y  $b_n - a_n = (b - a)/2^n$ . En cada paso, evaluamos  $f$  en el punto medio  $m = (a_n + b_n)/2$ : si  $f(a_n)f(m) \leq 0$ , definimos  $a_{n+1} = a_n$ ,  $b_{n+1} = m$ ; en caso contrario,  $a_{n+1} = m$ ,  $b_{n+1} = b_n$ .

Ambas sucesiones convergen al mismo límite  $c \in [a, b]$ . Por continuidad de  $f$ :

$$f(c) = \lim_{n \rightarrow \infty} f(a_n), \quad f(c) = \lim_{n \rightarrow \infty} f(b_n).$$

Como  $f(a_n)f(b_n) \leq 0$  para todo  $n$ , tomando límite obtenemos  $f(c)^2 \leq 0$ , es decir,  $f(c) = 0$ .  $\square$

### A.2 Teorema de Rolle

**Teorema A.2** (Teorema de Rolle). *Sea  $f : [a, b] \rightarrow \mathbb{R}$  continua en  $[a, b]$ , derivable en  $(a, b)$  y tal que  $f(a) = f(b)$ . Entonces existe  $c \in (a, b)$  con  $f'(c) = 0$ .*

*Demostración.* Por continuidad en el compacto  $[a, b]$ ,  $f$  alcanza máximo y mínimo. Si ambos extremos se alcanzan en los extremos  $a, b$ , como  $f(a) = f(b)$ , la función es constante y entonces  $f' \equiv 0$  en  $(a, b)$ . Si no, al menos uno de esos extremos se alcanza en un punto interior  $c \in (a, b)$ ; por el teorema de Fermat,  $f'(c) = 0$ .  $\square$

### A.3 Teorema del valor medio para derivadas

**Teorema A.3** (Teorema del valor medio para derivadas). Sea  $f : [a, b] \rightarrow \mathbb{R}$  continua en  $[a, b]$  y derivable en  $(a, b)$ . Entonces existe  $c \in (a, b)$  tal que

$$f'(c) = \frac{f(b) - f(a)}{b - a}.$$

*Demostración.* Consideramos

$$\ell(x) = f(a) + \frac{f(b) - f(a)}{b - a}(x - a), \quad h(x) = f(x) - \ell(x).$$

Entonces  $h$  es continua en  $[a, b]$ , derivable en  $(a, b)$  y cumple  $h(a) = h(b) = 0$ . Por el Teorema A.2, existe  $c \in (a, b)$  tal que  $h'(c) = 0$ . Como

$$h'(x) = f'(x) - \frac{f(b) - f(a)}{b - a},$$

se concluye

$$f'(c) = \frac{f(b) - f(a)}{b - a}.$$

□

### A.4 Teorema del valor medio para integrales

**Teorema A.4** (Teorema del valor medio para integrales — primera forma). Sea  $g \in C([a, b])$ . Entonces existe  $\eta \in (a, b)$  tal que

$$\int_a^b g(x) dx = g(\eta)(b - a).$$

*Demostración.* Definimos

$$G(x) := \int_a^x g(t) dt.$$

Entonces  $G$  es continua en  $[a, b]$ , derivable en  $(a, b)$  y  $G'(x) = g(x)$  (teorema fundamental del cálculo). Aplicando el Teorema A.3 a  $G$ , existe  $\eta \in (a, b)$  tal que

$$G'(\eta) = \frac{G(b) - G(a)}{b - a}.$$

Como  $G'(\eta) = g(\eta)$ ,  $G(b) = \int_a^b g(x) dx$  y  $G(a) = 0$ , resulta

$$\int_a^b g(x) dx = g(\eta)(b - a).$$

□

**Teorema A.5** (Teorema del valor medio para integrales — segunda forma). Sean  $g, \varphi \in C([a, b])$ , con  $\varphi$  de signo constante y  $\varphi(x) \neq 0$  para todo  $x \in (a, b)$ . Entonces existe  $\eta \in (a, b)$  tal que

$$\int_a^b g(x) \varphi(x) dx = g(\eta) \int_a^b \varphi(x) dx.$$

*Demostración.* Sea

$$c := \frac{\int_a^b g(x) \varphi(x) dx}{\int_a^b \varphi(x) dx}, \quad H(x) := \int_a^x (g(t) - c) \varphi(t) dt.$$

Como  $\varphi$  tiene signo constante y no se anula en  $(a, b)$ , se tiene  $\int_a^b \varphi \neq 0$ , luego  $c$  está bien definido. Además,

$$H(a) = 0, \quad H(b) = \int_a^b (g - c)\varphi = \int_a^b g\varphi - c \int_a^b \varphi = 0.$$

Por el Teorema A.3 aplicado a  $H$  (equivalentemente, por Rolle), existe  $\eta \in (a, b)$  tal que  $H'(\eta) = 0$ . Por el teorema fundamental del cálculo,

$$H'(\eta) = (g(\eta) - c)\varphi(\eta) = 0.$$

Como  $\varphi(\eta) \neq 0$ , se concluye  $g(\eta) = c$ , es decir,

$$\int_a^b g(x) \varphi(x) dx = g(\eta) \int_a^b \varphi(x) dx.$$

□

## A.5 Desarrollo de Taylor

**Teorema A.6** (Teorema de Taylor con resto integral). Sea  $f : I \rightarrow \mathbb{R}$  una función de clase  $C^{(n+1)}$  en un intervalo abierto  $I$ , y sea  $a \in I$ . Entonces, para todo  $x \in I$ :

$$f(x) = \sum_{k=0}^n \frac{f^{(k)}(a)}{k!} (x - a)^k + R_{n+1}(x),$$

donde el resto en forma integral es:

$$R_{n+1}(x) = \frac{1}{n!} \int_a^x (x - t)^n f^{(n+1)}(t) dt.$$

*Demostración.* Procedemos por inducción en  $n$ . Para  $n = 0$ , el resultado es simplemente el teorema fundamental del cálculo:

$$f(x) = f(a) + \int_a^x f'(t) dt.$$

Supongamos el resultado válido para  $n-1$ . Aplicamos integración por partes al término de resto con  $u = f^{(n)}(t)$  y  $dv = \frac{(x-t)^{n-1}}{(n-1)!} dt$  (notando que  $v = -\frac{(x-t)^n}{n!}$ ):

$$\begin{aligned} R_n(x) &= \frac{1}{(n-1)!} \int_a^x (x-t)^{n-1} f^{(n)}(t) dt \\ &= \left[ -\frac{(x-t)^n}{n!} f^{(n)}(t) \right]_a^x + \frac{1}{n!} \int_a^x (x-t)^n f^{(n+1)}(t) dt \\ &= \frac{f^{(n)}(a)}{n!} (x-a)^n + R_{n+1}(x). \end{aligned}$$

Esto completa el paso inductivo.  $\square$

**Corolario A.7** (Resto de Lagrange). *Bajo las mismas hipótesis, existe  $\xi$  entre  $a$  y  $x$  tal que:*

$$R_{n+1}(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} (x-a)^{n+1}.$$

*Demostración.* Sea  $M = \max_{t \in [a,x]} f^{(n+1)}(t)$  y  $m = \min_{t \in [a,x]} f^{(n+1)}(t)$ . De la forma integral del resto:

$$m \cdot \frac{(x-a)^{n+1}}{(n+1)!} \leq R_{n+1}(x) \leq M \cdot \frac{(x-a)^{n+1}}{(n+1)!}.$$

Por el teorema del valor intermedio para funciones continuas, existe  $\xi$  entre  $a$  y  $x$  tal que  $f^{(n+1)}(\xi) = \frac{(n+1)! R_{n+1}(x)}{(x-a)^{n+1}}$ .  $\square$

**Teorema A.8** (Desarrollo de Taylor multivariable). *Sea  $F : \mathbb{R}^n \rightarrow \mathbb{R}^m$  de clase  $C^2$  en una vecindad de  $x_0 \in \mathbb{R}^n$ , y sea  $J_F(x) \in \mathbb{R}^{m \times n}$  su matriz Jacobiana. Entonces:*

$$F(x) = F(x_0) + J_F(x_0)(x - x_0) + R_2(x),$$

donde  $\|R_2(x)\| \leq C\|x - x_0\|^2$  para una constante  $C$  que depende de las segundas derivadas de  $F$  en la vecindad.

En el caso escalar  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  de clase  $C^3$ :

$$f(x) = f(x_0) + \nabla f(x_0)^T (x - x_0) + \frac{1}{2} (x - x_0)^T \nabla^2 f(x_0) (x - x_0) + O(\|x - x_0\|^3),$$

donde  $\nabla f$  es el gradiente y  $\nabla^2 f$  es la matriz Hessiana.

*Demostración.* Definimos  $g(t) = F(x_0 + t(x - x_0))$  para  $t \in [0, 1]$ . Por la regla de la cadena,  $g'(t) = J_F(x_0 + t(x - x_0))(x - x_0)$ . Aplicando Taylor en una variable:

$$F(x) = g(1) = g(0) + g'(0) + \int_0^1 (1-t)g''(t) dt = F(x_0) + J_F(x_0)(x - x_0) + R_2(x).$$

El resto  $R_2$  involucra las segundas derivadas parciales de  $F$ , que están acotadas por continuidad, dando  $\|R_2(x)\| \leq C\|x - x_0\|^2$ .

Para el caso escalar,  $g(t) = f(x_0 + th)$  con  $h = x - x_0$  da  $g'(0) = \nabla f(x_0)^T h$  y  $g''(0) = h^T \nabla^2 f(x_0) h$ , de donde se obtiene la fórmula cuadrática.  $\square$

## A.6 Fórmulas de sumatorias y series

**Lema A.9** (Fórmulas de sumatorias). *Para todo  $n \in \mathbb{N}$ :*

$$1. \sum_{i=1}^n i = \frac{n(n+1)}{2}.$$

$$2. \sum_{i=1}^n i^2 = \frac{n(n+1)(2n+1)}{6}.$$

*Demostración.* (1) Sea  $S = \sum_{i=1}^n i$ . Escribimos la suma en orden directo e inverso:

$$S = 1 + 2 + \cdots + n,$$

$$S = n + (n-1) + \cdots + 1.$$

Sumando:  $2S = n(n+1)$ , de donde  $S = n(n+1)/2$ .

(2) Por inducción. El caso  $n = 1$  es trivial:  $1 = 1 \cdot 2 \cdot 3/6$ . Si la fórmula vale para  $n$ , entonces:

$$\sum_{i=1}^{n+1} i^2 = \frac{n(n+1)(2n+1)}{6} + (n+1)^2 = (n+1) \left( \frac{n(2n+1)}{6} + n+1 \right) = (n+1) \frac{2n^2 + 7n + 6}{6} = \frac{(n+1)(n+2)(2n+3)}{6}$$

□

**Lema A.10** (Serie geométrica). *Para  $r \neq 1$  y  $n \in \mathbb{N}_0$ :*

$$\sum_{i=0}^n r^i = \frac{1 - r^{n+1}}{1 - r}.$$

*En particular, si  $|r| < 1$ , la serie infinita converge:  $\sum_{i=0}^{\infty} r^i = \frac{1}{1-r}$ .*

*Demostración.* Sea  $S = \sum_{i=0}^n r^i$ . Entonces  $rS = \sum_{i=1}^{n+1} r^i$ . Restando:

$$S - rS = 1 - r^{n+1}, \quad \text{de donde} \quad S = \frac{1 - r^{n+1}}{1 - r}.$$

Para  $|r| < 1$ ,  $r^{n+1} \rightarrow 0$  cuando  $n \rightarrow \infty$ , lo que da la serie infinita.

□

**Lema A.11** (Identidad de Vandermonde). *Para todo  $n \in \mathbb{N}_0$ :*

$$\sum_{k=0}^n \binom{n}{k}^2 = \binom{2n}{n}.$$

*Demostración.* Consideremos el coeficiente de  $x^n$  en  $(1+x)^{2n}$ . Por un lado, es  $\binom{2n}{n}$ . Por otro lado,  $(1+x)^{2n} = (1+x)^n(1+x)^n$ , y el coeficiente de  $x^n$  del producto se obtiene por convolución de Cauchy:

$$\sum_{k=0}^n \binom{n}{k} \binom{n}{n-k} = \sum_{k=0}^n \binom{n}{k}^2,$$

donde usamos  $\binom{n}{n-k} = \binom{n}{k}$ .

□

## A.7 Identidades exponenciales y trigonométricas

**Lema A.12** (Fórmula de Euler). *Para todo  $\theta \in \mathbb{R}$ :*

$$e^{i\theta} = \cos \theta + i \sin \theta.$$

*En consecuencia:*

$$e^{i\theta} + e^{-i\theta} = 2 \cos \theta,$$

$$e^{i\theta} - e^{-i\theta} = 2i \sin \theta.$$

*Demostración.* La primera identidad se obtiene igualando las series de potencias  $e^{i\theta} = \sum_{n=0}^{\infty} \frac{(i\theta)^n}{n!}$  con las series de  $\cos \theta$  y  $\sin \theta$ . Separando partes real e imaginaria:

$$e^{i\theta} = \sum_{k=0}^{\infty} \frac{(-1)^k \theta^{2k}}{(2k)!} + i \sum_{k=0}^{\infty} \frac{(-1)^k \theta^{2k+1}}{(2k+1)!} = \cos \theta + i \sin \theta.$$

Las dos consecuencias resultan de sumar y restar  $e^{i\theta}$  con  $e^{-i\theta} = \cos \theta - i \sin \theta$ .  $\square$

## A.8 Criterio M de Weierstrass

**Teorema A.13** (Criterio M de Weierstrass). *Sea  $\{f_n\}$  una sucesión de funciones  $f_n : D \rightarrow \mathbb{C}$  tales que  $|f_n(x)| \leq M_n$  para todo  $x \in D$  y todo  $n$ . Si  $\sum_{n=1}^{\infty} M_n < \infty$ , entonces la serie  $\sum_{n=1}^{\infty} f_n$  converge absoluta y uniformemente en  $D$ .*

*Demostración.* Para toda  $x \in D$  y todo  $N$ , las sumas parciales  $S_N(x) = \sum_{n=1}^N f_n(x)$  satisfacen, para  $M > N$ :

$$|S_M(x) - S_N(x)| = \left| \sum_{n=N+1}^M f_n(x) \right| \leq \sum_{n=N+1}^M |f_n(x)| \leq \sum_{n=N+1}^M M_n.$$

Como  $\sum M_n$  converge, la cola  $\sum_{n=N+1}^{\infty} M_n \rightarrow 0$  cuando  $N \rightarrow \infty$ . Por lo tanto, la desigualdad anterior muestra que  $\{S_N\}$  es uniformemente de Cauchy en  $D$ . Por completitud de  $\mathbb{C}$  (o  $\mathbb{R}$ ), la serie converge uniformemente. La convergencia absoluta se sigue de  $\sum |f_n(x)| \leq \sum M_n < \infty$ .  $\square$

## A.9 Jacobiana, gradiente y Hessiana

**Definición A.14** (Jacobiana). *Sea  $F : \mathbb{R}^n \rightarrow \mathbb{R}^m$  diferenciable en  $x$ . La **matriz Jacobiana** de  $F$  en  $x$  es la matriz  $J_F(x) \in \mathbb{R}^{m \times n}$  cuyas entradas son:*

$$[J_F(x)]_{ij} = \frac{\partial F_i}{\partial x_j}(x), \quad 1 \leq i \leq m, \quad 1 \leq j \leq n.$$

*La Jacobiana es la representación matricial de la diferencial  $dF_x : \mathbb{R}^n \rightarrow \mathbb{R}^m$ .*

**Definición A.15** (Gradiente). Sea  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  diferenciable en  $x$ . El **gradiente** de  $f$  en  $x$  es el vector columna:

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1}(x) \\ \vdots \\ \frac{\partial f}{\partial x_n}(x) \end{pmatrix} \in \mathbb{R}^n.$$

Geoméricamente,  $\nabla f(x)$  apunta en la dirección de mayor crecimiento de  $f$  en  $x$ , y  $\|\nabla f(x)\|$  es la tasa de cambio máxima.

**Definición A.16** (Hessiana). Sea  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  dos veces diferenciable en  $x$ . La **matriz Hessiana** de  $f$  en  $x$  es la matriz simétrica  $\nabla^2 f(x) \in \mathbb{R}^{n \times n}$  con entradas:

$$[\nabla^2 f(x)]_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}(x).$$

Es la Jacobiana del gradiente:  $\nabla^2 f(x) = J_{\nabla f}(x)$ .

## A.10 Subespacios y dimensiones

**Definición A.17** (Suma e intersección de subespacios). Sean  $U$  y  $V$  subespacios de un espacio vectorial  $W$  de dimensión finita. Su **suma** es

$$U + V := \{u + v : u \in U, v \in V\},$$

y su **intersección**  $U \cap V$  es el subespacio de todos los vectores que pertenecen a ambos.

**Teorema A.18** (Fórmula de Grassmann). Si  $U$  y  $V$  son subespacios de dimensión finita, entonces:

$$\dim(U + V) + \dim(U \cap V) = \dim(U) + \dim(V).$$

*Demostración.* Sea  $\{w_1, \dots, w_k\}$  una base de  $U \cap V$ . La extendemos a bases de  $U$  y  $V$  respectivamente:

$$\{w_1, \dots, w_k, u_1, \dots, u_p\} \text{ base de } U, \quad \{w_1, \dots, w_k, v_1, \dots, v_q\} \text{ base de } V.$$

Aquí  $\dim(U) = k+p$ ,  $\dim(V) = k+q$ ,  $\dim(U \cap V) = k$ . El conjunto  $\mathcal{B} = \{w_1, \dots, w_k, u_1, \dots, u_p, v_1, \dots, v_q\}$  genera  $U + V$ ; veamos que es linealmente independiente. Dada una combinación nula

$$\sum_i a_i w_i + \sum_j b_j u_j + \sum_l c_l v_l = 0,$$

el vector  $s := \sum_l c_l v_l = -\sum_i a_i w_i - \sum_j b_j u_j$  pertenece a  $U$ , luego  $s \in U \cap V$  y se escribe  $s = \sum_i d_i w_i$ . Por independencia de la base de  $V$  se concluye que todos los  $c_l = 0$  (y los  $d_i = 0$ ); sustituyendo, todos los  $a_i, b_j = 0$ . Esto prueba que  $\mathcal{B}$  es base de  $U + V$ , por lo que

$$\dim(U + V) = k + p + q = (k + p) + (k + q) - k = \dim(U) + \dim(V) - \dim(U \cap V).$$

□

**Corolario A.19** (Cota inferior para la intersección). Sean  $U$  y  $V$  subespacios de un espacio de dimensión  $n$ . Entonces:

$$\dim(U \cap V) \geq \dim(U) + \dim(V) - n.$$

En particular, si  $\dim(U) + \dim(V) > n$ , la intersección es no trivial.

*Demostración.* Como  $U + V$  está contenido en el espacio ambiente de dimensión  $n$ , se tiene  $\dim(U + V) \leq n$ . Por la Fórmula de Grassmann (Teorema A.18),

$$\dim(U \cap V) = \dim(U) + \dim(V) - \dim(U + V) \geq \dim(U) + \dim(V) - n.$$

□

**Teorema A.20** (Teorema rango-nulidad). Sea  $A \in \mathbb{C}^{m \times n}$ . Entonces:

$$\text{rango}(A) + \dim(\ker(A)) = n.$$

*Demostración.* Sea  $r = \text{rango}(A)$  y  $\{z_1, \dots, z_{n-r}\}$  una base de  $\ker(A)$ . Se extiende a una base  $\{z_1, \dots, z_{n-r}, e_1, \dots, e_r\}$  de  $\mathbb{C}^n$ . Los vectores  $Ae_1, \dots, Ae_r$  generan  $\text{Im}(A)$  y son linealmente independientes (pues si  $\sum \lambda_i Ae_i = 0$  entonces  $\sum \lambda_i e_i \in \ker(A)$ , lo que por independencia da  $\lambda_i = 0$ ). Luego  $\dim(\text{Im}(A)) = r = \text{rango}(A)$ , y

$$\dim(\ker(A)) = n - r = n - \text{rango}(A).$$

□

## A.11 Polinomios sobre un cuerpo

**Teorema A.21** (Cota de raíces de un polinomio). Sea  $\mathbb{F}$  un cuerpo. Un polinomio no nulo de grado  $\leq n$  con coeficientes en  $\mathbb{F}$  tiene a lo sumo  $n$  raíces en  $\mathbb{F}$ .

*Demostración.* Inducción en  $n$ . Para  $n = 0$  un polinomio no nulo es una constante  $c \neq 0$ , sin raíces.

Paso inductivo: sea  $p$  no nulo de grado  $\leq n$ . Si  $p$  no tiene raíces, no hay nada que probar. Si  $\alpha \in \mathbb{F}$  es una raíz, el algoritmo de división da  $p(x) = (x - \alpha)q(x)$  con  $q$  no nulo de grado  $\leq n - 1$ . Para toda raíz  $\beta \neq \alpha$  de  $p$  se tiene  $0 = p(\beta) = (\beta - \alpha)q(\beta)$ ; como  $\mathbb{F}$  no tiene divisores de cero,  $q(\beta) = 0$ . Por hipótesis inductiva  $q$  tiene a lo sumo  $n - 1$  raíces, luego  $p$  tiene a lo sumo  $1 + (n - 1) = n$ . □



## Appendix B

# Espacios de Pre-Hilbert

En este apéndice revisamos conceptos fundamentales de álgebra lineal en espacios con producto interno. Comenzamos con las definiciones geométricas básicas (ortogonalidad, proyección) para luego establecer resultados centrales sobre aproximación y bases ortonormales. Finalmente, aplicamos estas herramientas para demostrar teoremas de factorización matricial esenciales en análisis numérico, como la descomposición de Schur y la diagonalización de matrices normales.

### B.1 Definiciones básicas

**Definición B.1** (Espacio de pre-Hilbert). *Un **espacio de pre-Hilbert** (o espacio con producto interno) es un par  $(V, (\cdot, \cdot))$  donde  $V$  es un espacio vectorial sobre  $\mathbb{C}$  (o  $\mathbb{R}$ ) y  $(\cdot, \cdot) : V \times V \rightarrow \mathbb{C}$  es un producto interno en  $V$ .*

**Definición B.2** (Producto interno). *Sea  $V$  un espacio vectorial sobre  $\mathbb{C}$  (o  $\mathbb{R}$ ). Un **producto interno** en  $V$  es una función  $(\cdot, \cdot) : V \times V \rightarrow \mathbb{C}$  que satisface:*

1. **Linealidad en el primer argumento:**  $(\alpha u + \beta v, w) = \alpha(u, w) + \beta(v, w)$  para todos  $u, v, w \in V$  y  $\alpha, \beta \in \mathbb{C}$ .
2. **Simetría hermítica:**  $(u, v) = \overline{(v, u)}$  para todos  $u, v \in V$ .
3. **Positividad:**  $(u, u) \geq 0$  para todo  $u \in V$ , con igualdad si y solo si  $u = 0$ .

**Observación B.3.** *Para espacios reales, la condición de simetría hermítica se reduce a la simetría ordinaria:  $(u, v) = (v, u)$ . La linealidad en el primer argumento y la simetría hermítica implican antilinealidad (o sesquilinealidad) en el segundo argumento:  $(u, \alpha v + \beta w) = \overline{\alpha}(u, v) + \overline{\beta}(u, w)$ .*

**Definición B.4** (Norma inducida). *El producto interno induce una **norma** en  $V$  definida por:*

$$\|u\| = \sqrt{(u, u)}.$$

*Esta norma satisface:*

1.  $\|u\| \geq 0$  y  $\|u\| = 0 \Leftrightarrow u = 0$ ,

2.  $\|\alpha u\| = |\alpha| \|u\|$  para todo  $\alpha \in \mathbb{C}$ ,
3.  $\|u + v\| \leq \|u\| + \|v\|$  (desigualdad triangular).

**Teorema B.5** (Desigualdad de Cauchy-Schwarz). Para todos  $u, v \in V$ :

$$|(u, v)| \leq \|u\| \|v\|,$$

con igualdad si y solo si  $u$  y  $v$  son linealmente dependientes.

*Demostración.* Si  $v = 0$ , el resultado es trivial. Supongamos  $v \neq 0$ . Para cualquier  $t \in \mathbb{C}$ , tenemos:

$$0 \leq \|u - tv\|^2 = (u - tv, u - tv) = \|u\|^2 - t(v, u) - \bar{t}(u, v) + |t|^2 \|v\|^2.$$

Elegimos  $t = (u, v)/\|v\|^2$ , entonces:

$$0 \leq \|u\|^2 - \frac{|(u, v)|^2}{\|v\|^2} - \frac{|(u, v)|^2}{\|v\|^2} + \frac{|(u, v)|^2}{\|v\|^4} \cdot \|v\|^2 = \|u\|^2 - \frac{|(u, v)|^2}{\|v\|^2}.$$

Multiplicando por  $\|v\|^2$ , obtenemos  $|u, v|^2 \leq \|u\|^2 \|v\|^2$ . La igualdad se da si y solo si  $u = tv$ , es decir, si son linealmente dependientes.  $\square$

## B.2 Ortogonalidad y Proyección

**Definición B.6** (Ortogonalidad). Dos vectores  $u, v \in V$  son **ortogonales** si  $(u, v) = 0$ , y escribimos  $u \perp v$ .

Un conjunto  $\{v_k\}_{k \in I}$  de vectores es **ortogonal** si  $(v_j, v_k) = 0$  para todo  $j \neq k$ .

Un conjunto  $\{e_k\}_{k \in I}$  es **ortonormal** si es ortogonal y además  $\|e_k\| = 1$  para todo  $k \in I$ .

**Teorema B.7** (Teorema de Pitágoras). Si  $u \perp v$ , entonces:

$$\|u + v\|^2 = \|u\|^2 + \|v\|^2.$$

Más generalmente, si  $\{v_1, \dots, v_n\}$  es un conjunto ortogonal, entonces:

$$\left\| \sum_{k=1}^n v_k \right\|^2 = \sum_{k=1}^n \|v_k\|^2.$$

*Demostración.* Si  $u \perp v$ , entonces  $(u, v) = 0$ . Expandiendo:

$$\|u + v\|^2 = (u + v, u + v) = (u, u) + (u, v) + (v, u) + (v, v) = \|u\|^2 + 0 + 0 + \|v\|^2 = \|u\|^2 + \|v\|^2.$$

El caso general se demuestra por inducción.  $\square$

**Teorema B.8** (Proyección sobre una base ortogonal). Sea  $\{v_1, \dots, v_n\}$  una base ortogonal de un espacio vectorial  $V$  de dimensión finita. Entonces, todo vector  $u \in V$  se puede escribir de manera única como:

$$u = \sum_{k=1}^n c_k v_k,$$

donde los coeficientes están dados por la **fórmula de proyección**:

$$c_k = \frac{(u, v_k)}{(v_k, v_k)} = \frac{(u, v_k)}{\|v_k\|^2}. \quad (\text{B.1})$$

*Demostración.* Supongamos que  $u = \sum_{j=1}^n c_j v_j$ . Tomando el producto interno con  $v_k$ :

$$(u, v_k) = \left( \sum_{j=1}^n c_j v_j, v_k \right) = \sum_{j=1}^n c_j (v_j, v_k).$$

Por ortogonalidad,  $(v_j, v_k) = 0$  si  $j \neq k$  y  $(v_k, v_k) = \|v_k\|^2$ . Por lo tanto:

$$(u, v_k) = c_k \|v_k\|^2,$$

de donde se obtiene la fórmula para  $c_k$ . □

**Teorema B.9** (Proceso de Gram-Schmidt). *Todo espacio vectorial de dimensión finita con producto interno posee una base ortonormal. A partir de una base cualquiera  $\{u_1, \dots, u_n\}$ , se puede construir una base ortonormal  $\{e_1, \dots, e_n\}$  mediante la recursión:*

$$v_k = u_k - \sum_{j=1}^{k-1} (u_k, e_j) e_j, \quad e_k = \frac{v_k}{\|v_k\|}.$$

**Teorema B.10** (Identidad de Parseval para bases ortonormales finitas). *Sea  $\{e_1, \dots, e_n\}$  una base ortonormal de  $V$ . Si  $u = \sum_{k=1}^n c_k e_k$  con  $c_k = (u, e_k)$ , entonces:*

$$\|u\|^2 = \sum_{k=1}^n |c_k|^2. \quad (\text{B.2})$$

*Demostración.*

$$\|u\|^2 = (u, u) = \left( \sum_{j=1}^n c_j e_j, \sum_{k=1}^n c_k e_k \right) = \sum_{j=1}^n \sum_{k=1}^n c_j \overline{c_k} (e_j, e_k).$$

Por ortonormalidad,  $(e_j, e_k) = \delta_{jk}$  (delta de Kronecker), así que:

$$\|u\|^2 = \sum_{k=1}^n c_k \overline{c_k} = \sum_{k=1}^n |c_k|^2.$$

□

**Teorema B.11** (Proyección ortogonal). *Sea  $V$  un espacio de pre-Hilbert y  $S$  un subespacio de dimensión finita de  $V$ . Para cualquier  $u \in V$ , existe un **único** vector  $s_0 \in S$  tal que:*

$$\|u - s_0\| = \inf_{s \in S} \|u - s\|.$$

*Este vector  $s_0$  se llama la **mejor aproximación** de  $u$  en  $S$ , o la **proyección ortogonal**  $P_S(u)$ . Además,  $s_0$  es el único vector en  $S$  que satisface la **condición de ortogonalidad**:*

$$(u - s_0, s) = 0 \quad \text{para todo } s \in S.$$

*Demostración.* La demostración se basa en tomar una base ortonormal  $\{e_1, \dots, e_n\}$  para  $S$  y definir explícitamente

$$s_0 = \sum_{k=1}^n (u, e_k) e_k.$$

Para cualquier otro  $s \in S$ , podemos escribir  $s = \sum_{k=1}^n d_k e_k$  con coeficientes  $d_k$ . Entonces:

$$\|u - s\|^2 = \|(u - s_0) + (s_0 - s)\|^2.$$

Como  $(u - s_0) \perp (s_0 - s)$  (el vector  $(u - s_0)$  es ortogonal a todo  $S$ ), por el teorema de Pitágoras:

$$\|u - s\|^2 = \|u - s_0\|^2 + \|s_0 - s\|^2 \geq \|u - s_0\|^2,$$

con igualdad si y solo si  $s = s_0$ .

Para la condición de ortogonalidad, notemos que si  $s_0$  es el minimizador, para cualquier  $s \in S$  y  $t \in \mathbb{R}$ :

$$\|u - s_0\|^2 \leq \|u - (s_0 + ts)\|^2 = \|u - s_0\|^2 - 2t \operatorname{Re}(u - s_0, s) + t^2 \|s\|^2.$$

Dividiendo por  $t > 0$  (y luego  $t < 0$ ) y haciendo  $t \rightarrow 0$ , se obtiene  $\operatorname{Re}(u - s_0, s) = 0$ . Repitiendo con  $is$  se obtiene  $\operatorname{Im}(u - s_0, s) = 0$ , y por lo tanto  $(u - s_0, s) = 0$ .

Recíprocamente, si  $(u - s_0, s) = 0$  para todo  $s \in S$ , entonces para cualquier  $s \in S$ :

$$\|u - s\|^2 = \|(u - s_0) + (s_0 - s)\|^2 = \|u - s_0\|^2 + \|s_0 - s\|^2 \geq \|u - s_0\|^2,$$

donde usamos que  $(u - s_0) \perp (s_0 - s) \in S$ . □

**Teorema B.12** (Proyector hermítico es proyección ortogonal). *Sea  $V$  un espacio de pre-Hilbert de dimensión finita y sea  $P: V \rightarrow V$  una transformación lineal que satisface  $P^2 = P$  (idempotente) y  $P^* = P$  (autoadjunta). Entonces  $P$  es la proyección ortogonal sobre  $\operatorname{Im}(P)$ .*

*Demostración.* Como  $P^2 = P$ , todo vector  $v \in V$  se descompone como

$$v = Pv + (v - Pv),$$

donde  $Pv \in \operatorname{Im}(P)$ . Veamos que  $v - Pv \perp \operatorname{Im}(P)$ . Sea  $w = Pu \in \operatorname{Im}(P)$  cualquiera. Entonces, usando  $P^* = P$  y  $P^2 = P$ :

$$(v - Pv, w) = (v - Pv, Pu) = (P^*(v - Pv), u) = (P(v - Pv), u) = (Pv - P^2v, u) = (Pv - Pv, u) = 0.$$

Por lo tanto  $v - Pv \in \operatorname{Im}(P)^\perp$ . Como la descomposición  $V = \operatorname{Im}(P) \oplus \operatorname{Im}(P)^\perp$  es única (por el Teorema B.11), se sigue que  $Pv$  es la proyección ortogonal de  $v$  sobre  $\operatorname{Im}(P)$ . □

### B.3 Factorización de Schur y Teorema Espectral

En espacios de dimensión finita, la existencia de bases ortonormales permite simplificar la representación matricial de operadores lineales.

**Teorema B.13** (Factorización de Schur). Sea  $A \in \mathbb{C}^{n \times n}$ . Existe una matriz unitaria  $U \in \mathbb{C}^{n \times n}$  (es decir,  $U^*U = I$ ) y una matriz triangular superior  $T \in \mathbb{C}^{n \times n}$  tales que:

$$A = UTU^*.$$

Los elementos diagonales de  $T$  son los valores propios de  $A$ .

*Demostración.* Procedemos por inducción sobre la dimensión  $n$ . Para  $n = 1$  es trivial. Supongamos que el teorema es cierto para matrices de tamaño  $n - 1$ . Sea  $\lambda_1$  un valor propio de  $A$  y  $v_1$  un vector propio asociado con  $\|v_1\| = 1$ . Completamos  $v_1$  a una base ortonormal de  $\mathbb{C}^n$ , digamos  $\{v_1, v_2, \dots, v_n\}$ . Sea  $U_1 = [v_1, v_2, \dots, v_n]$  la matriz unitaria formada por estos vectores. Entonces:

$$U_1^*AU_1 = \begin{pmatrix} v_1^* \\ \vdots \\ v_n^* \end{pmatrix} A \begin{pmatrix} v_1 & \cdots & v_n \end{pmatrix} = \begin{pmatrix} v_1^*Av_1 & v_1^*Av_2 & \cdots \\ v_2^*Av_1 & v_2^*Av_2 & \cdots \\ \vdots & \vdots & \ddots \end{pmatrix}.$$

Como  $Av_1 = \lambda_1 v_1$ , la primera columna de  $AU_1$  es  $\lambda_1 v_1$ . Por ortonormalidad,  $v_1^*(\lambda_1 v_1) = \lambda_1$  y  $v_k^*(\lambda_1 v_1) = 0$  para  $k > 1$ . Así, la matriz toma la forma:

$$U_1^*AU_1 = \begin{pmatrix} \lambda_1 & w^* \\ 0 & A_2 \end{pmatrix},$$

donde  $A_2 \in \mathbb{C}^{(n-1) \times (n-1)}$ . Por hipótesis de inducción, existe  $V_2 \in \mathbb{C}^{(n-1) \times (n-1)}$  unitaria tal que  $V_2^*A_2V_2 = T_2$  es triangular superior. Definimos  $U = U_1 \begin{pmatrix} 1 & 0 \\ 0 & V_2 \end{pmatrix}$ . Esta matriz es unitaria y transforma  $A$  en una triangular superior.  $\square$

**Lema B.14** (Matrices triangulares normales). Una matriz triangular superior  $T \in \mathbb{C}^{n \times n}$  es normal si y solo si es diagonal.

*Demostración.* ( $\Leftarrow$ ) Si  $T$  es diagonal, entonces  $T^*$  también es diagonal, y como las matrices diagonales conmutan entre sí,  $TT^* = T^*T$ .

( $\Rightarrow$ ) Supongamos que  $T$  es triangular superior y normal. Escribimos  $T = (t_{ij})$  con  $t_{ij} = 0$  para  $i > j$ . Comparemos los elementos diagonales de  $TT^*$  y  $T^*T$ :

$$(TT^*)_{ii} = \sum_{k=1}^n t_{ik} \overline{t_{ik}} = \sum_{k=i}^n |t_{ik}|^2 \quad (\text{pues } t_{ik} = 0 \text{ para } k < i).$$

$$(T^*T)_{ii} = \sum_{k=1}^n \overline{t_{ki}} t_{ki} = \sum_{k=1}^i |t_{ki}|^2 \quad (\text{pues } t_{ki} = 0 \text{ para } k > i).$$

Como  $T$  es normal,  $(TT^*)_{ii} = (T^*T)_{ii}$ :

$$\sum_{k=i}^n |t_{ik}|^2 = \sum_{k=1}^i |t_{ki}|^2.$$

Para  $i = 1$ :

$$\sum_{k=1}^n |t_{1k}|^2 = |t_{11}|^2.$$

Esto implica que  $\sum_{k=2}^n |t_{1k}|^2 = 0$ , por lo que  $t_{1k} = 0$  para  $k > 1$ .

Para  $i = 2$ , usando que  $t_{12} = 0$ :

$$\sum_{k=2}^n |t_{2k}|^2 = |t_{12}|^2 + |t_{22}|^2 = |t_{22}|^2.$$

Esto implica que  $t_{2k} = 0$  para  $k > 2$ .

Procediendo inductivamente para  $i = 3, 4, \dots, n$ , obtenemos que  $t_{ik} = 0$  para todo  $i < k$ . Por lo tanto,  $T$  es diagonal.  $\square$

**Teorema B.15** (Teorema Espectral para Matrices Normales). *Una matriz  $A \in \mathbb{C}^{n \times n}$  es **normal** (es decir,  $AA^* = A^*A$ ) si y solo si es diagonalizable unitariamente. Es decir, existe una matriz unitaria  $U$  y una matriz diagonal  $\Lambda$  tales que:*

$$A = U\Lambda U^*.$$

*Demostración.* ( $\Leftarrow$ ) Si  $A = U\Lambda U^*$ , entonces  $A^* = U\Lambda^* U^*$ . Como  $\Lambda$  y  $\Lambda^*$  son diagonales, conmutan ( $\Lambda\Lambda^* = \Lambda^*\Lambda$ ). Entonces:

$$AA^* = U\Lambda U^* U\Lambda^* U^* = U\Lambda\Lambda^* U^* = U\Lambda^*\Lambda U^* = U\Lambda^* U^* U\Lambda U^* = A^*A.$$

( $\Rightarrow$ ) Por la factorización de Schur,  $A = UTU^*$  con  $T$  triangular superior. Como  $A$  es normal,  $T$  también debe serlo:

$$TT^* = (U^*AU)(U^*A^*U) = U^*AA^*U = U^*A^*AU = (U^*A^*U)(U^*AU) = T^*T.$$

Ahora bien,  $T$  es una matriz triangular superior y normal. Por lo tanto, por el lema anterior,  $T$  es diagonal, lo que concluye la demostración.  $\square$

**Corolario B.16** (Ortogonalidad de autovectores de matrices normales). *Si  $A \in \mathbb{C}^{n \times n}$  es normal y  $v_i, v_j$  son autovectores correspondientes a autovalores distintos  $\lambda_i \neq \lambda_j$ , entonces  $v_i$  y  $v_j$  son ortogonales:  $v_i^* v_j = 0$ .*

*Demostración.* Consideremos  $Av_i = \lambda_i v_i$  y  $Av_j = \lambda_j v_j$ . Calculamos:

$$\lambda_i(v_i^* v_j) = (Av_i)^* v_j = v_i^* A^* v_j.$$

Por otro lado, como  $A$  es normal,  $A^*$  también lo es, y comparten autovectores. Más precisamente, si  $Av_j = \lambda_j v_j$ , entonces  $A^* v_j = \bar{\lambda}_j v_j$  (esto se sigue de que  $A = U\Lambda U^*$  implica  $A^* = U\Lambda^* U^*$ ). Por lo tanto:

$$v_i^* A^* v_j = v_i^* (\bar{\lambda}_j v_j) = \bar{\lambda}_j (v_i^* v_j).$$

Igualando las dos expresiones:

$$\lambda_i(v_i^* v_j) = \bar{\lambda}_j(v_i^* v_j).$$

Si  $\lambda_i \neq \bar{\lambda}_j$  (lo cual es cierto si  $\lambda_i \neq \lambda_j$  en el caso hermitico, o en general por la diagonalización unitaria), entonces necesariamente  $v_i^* v_j = 0$ .  $\square$

**Corolario B.17** (Matrices Hermíticas). *Si  $A \in \mathbb{C}^{n \times n}$  es hermitica ( $A = A^*$ ), entonces:*

1. *A es normal, por lo que admite diagonalización unitaria:  $A = U\Lambda U^*$ .*

2. *Todos los autovalores de A son **reales**:  $\lambda_i \in \mathbb{R}$  para todo  $i$ .*

*Demostración.* (1) Es inmediato que  $AA^* = AA = A^*A$ .

(2) Sea  $\lambda$  un autovalor con autovector  $v$ :  $Av = \lambda v$ . Tomando el producto hermítico:

$$v^*Av = v^*(\lambda v) = \lambda v^*v = \lambda \|v\|^2.$$

Por otro lado, como  $A^* = A$ :

$$v^*Av = (Av)^*v = (\lambda v)^*v = \bar{\lambda} v^*v = \bar{\lambda} \|v\|^2.$$

Igualando,  $\lambda = \bar{\lambda}$ , por lo que  $\lambda \in \mathbb{R}$ . □

**Teorema B.18** (Caracterización Variacional de Autovalores (Courant-Fischer)). *Sea  $A \in \mathbb{C}^{n \times n}$  una matriz hermítica con autovalores  $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ . Entonces:*

$$\lambda_k = \min_{S \subset \mathbb{C}^n, \dim(S)=k} \max_{x \in S, x \neq 0} \frac{x^*Ax}{x^*x} = \max_{S \subset \mathbb{C}^n, \dim(S)=n-k+1} \min_{x \in S, x \neq 0} \frac{x^*Ax}{x^*x}.$$

*En particular, el autovalor máximo y mínimo están dados por el cociente de Rayleigh:*

$$\lambda_1 = \min_{x \neq 0} \frac{x^*Ax}{x^*x}, \quad \lambda_n = \max_{x \neq 0} \frac{x^*Ax}{x^*x}.$$

*Demostración.* Sea  $\{u_1, \dots, u_n\}$  una base ortonormal de vectores propios de  $A$  asociados a los autovalores  $\lambda_1 \leq \dots \leq \lambda_n$ . Para cualquier vector  $x \neq 0$ , podemos escribir  $x = \sum_{i=1}^n c_i u_i$ . El cociente de Rayleigh es:

$$R(x) = \frac{x^*Ax}{x^*x} = \frac{\sum_{i=1}^n \lambda_i |c_i|^2}{\sum_{i=1}^n |c_i|^2}.$$

Demostremos la caracterización max – min para  $\lambda_k$ :

$$\lambda_k = \max_{S \subset \mathbb{C}^n, \dim(S)=n-k+1} \min_{x \in S, x \neq 0} R(x).$$

Sea  $V_k = \text{span}\{u_k, \dots, u_n\}$ . La dimensión de  $V_k$  es  $n - k + 1$ . Para cualquier  $x \in V_k$ , tenemos  $c_1 = \dots = c_{k-1} = 0$ , por lo que:

$$R(x) = \frac{\sum_{i=k}^n \lambda_i |c_i|^2}{\sum_{i=k}^n |c_i|^2} \geq \lambda_k \frac{\sum_{i=k}^n |c_i|^2}{\sum_{i=k}^n |c_i|^2} = \lambda_k.$$

Por lo tanto,  $\min_{x \in V_k} R(x) \geq \lambda_k$ . Esto implica que el máximo sobre todos los subespacios es al menos  $\lambda_k$ .

Ahora sea  $S$  cualquier subespacio de dimensión  $n - k + 1$ . Consideremos el subespacio  $Z_k = \text{span}\{u_1, \dots, u_k\}$ , que tiene dimensión  $k$ . La suma de dimensiones es  $\dim(S) + \dim(Z_k) = (n - k + 1) + k = n + 1$ . Como la dimensión del espacio total es  $n$ , la intersección  $S \cap Z_k$  debe tener dimensión al menos 1. Sea  $x_0 \in S \cap Z_k$  con  $x_0 \neq 0$ . Como  $x_0 \in Z_k$ , es combinación lineal de  $u_1, \dots, u_k$ , así que:

$$R(x_0) = \frac{\sum_{i=1}^k \lambda_i |c_i|^2}{\sum_{i=1}^k |c_i|^2} \leq \lambda_k.$$

Por lo tanto,  $\min_{x \in S} R(x) \leq R(x_0) \leq \lambda_k$ . Como esto vale para todo  $S$ , el máximo de los mínimos es  $\leq \lambda_k$ . Concluimos que el valor es exactamente  $\lambda_k$ . La otra igualdad se prueba de manera análoga. □

## Appendix C

# Espacios de Hilbert

### C.1 Definiciones y Ejemplos

**Definición C.1** (Espacio de Hilbert). *Un espacio de pre-Hilbert  $(H, (\cdot, \cdot))$  se dice **espacio de Hilbert** si es completo respecto a la norma inducida  $\|u\| = \sqrt{(u, u)}$ . Es decir, toda sucesión de Cauchy en  $H$  converge a un elemento de  $H$ .*

**Definición C.2** (Separabilidad). *Un espacio de Hilbert  $H$  se dice **separable** si posee un subconjunto denso que es numerable. Es decir, existe un conjunto  $D = \{d_n\}_{n=1}^{\infty} \subset H$  tal que  $\overline{D} = H$ .*

La separabilidad es una propiedad técnica crucial que garantiza la existencia de bases ortonormales numerables.

**Ejemplo C.3** (El espacio  $\ell^2$ ). *El espacio de sucesiones de cuadrado sumable  $\ell^2$  es el prototipo de espacio de Hilbert separable. La base canónica  $e_n = (0, \dots, 1, \dots)$  es una base ortonormal.*

**Ejemplo C.4** (El espacio  $L^2$ ). *El espacio  $L^2([0, 2\pi])$  es separable. El sistema trigonométrico  $\{\frac{1}{\sqrt{2\pi}}e^{ikx}\}_{k \in \mathbb{Z}}$  es una base ortonormal.*

### C.2 Bases Ortonormales

En dimensión infinita, la noción de base algebraica (base de Hamel) es menos útil que la de base topológica u ortonormal.

**Definición C.5** (Sistema Ortonormal). *Un subconjunto  $S = \{e_k\}_{k \in I} \subset H$  es un **sistema ortonormal** si  $(e_j, e_k) = \delta_{jk}$  para todos  $j, k \in I$ .*

**Teorema C.6** (Desigualdad de Bessel). *Sea  $\{e_k\}_{k=1}^{\infty}$  un sistema ortonormal en  $H$ . Para cualquier  $u \in H$ , se cumple:*

$$\sum_{k=1}^{\infty} |(u, e_k)|^2 \leq \|u\|^2.$$



*Demostración.* Para cada  $N \in \mathbb{N}$ , definimos  $S_N = \sum_{k=1}^N (u, e_k) e_k$ . Expandimos la norma:

$$\begin{aligned} 0 \leq \|u - S_N\|^2 &= (u - S_N, u - S_N) \\ &= \|u\|^2 - \sum_{k=1}^N (u, e_k) \overline{(u, e_k)} - \sum_{k=1}^N \overline{(u, e_k)} (u, e_k) + \sum_{j,k=1}^N (u, e_j) \overline{(u, e_k)} \underbrace{(e_j, e_k)}_{\delta_{jk}} \\ &= \|u\|^2 - 2 \sum_{k=1}^N |(u, e_k)|^2 + \sum_{k=1}^N |(u, e_k)|^2 = \|u\|^2 - \sum_{k=1}^N |(u, e_k)|^2. \end{aligned}$$

Por lo tanto,  $\sum_{k=1}^N |(u, e_k)|^2 \leq \|u\|^2$  para todo  $N \in \mathbb{N}$ . Como la sucesión de sumas parciales es monótona creciente y acotada superiormente por  $\|u\|^2$ , la serie converge y

$$\sum_{k=1}^{\infty} |(u, e_k)|^2 \leq \|u\|^2. \quad \square$$

**Definición C.7** (Base Ortonormal). *Un sistema ortonormal  $\{e_k\}_{k=1}^{\infty}$  en un espacio de Hilbert  $H$  se llama **base ortonormal** (o base de Hilbert) si el subespacio generado por  $\{e_k\}$  es denso en  $H$ .*

El siguiente teorema conecta la separabilidad con la existencia de bases.

**Teorema C.8** (Existencia de Bases Ortonormales). *Sea  $H$  un espacio de Hilbert de dimensión infinita. Entonces  $H$  es separable si y solo si posee una base ortonormal numerable.*

*Demostración.* ( $\Leftarrow$ ) Si  $\{e_n\}$  es una base ortonormal numerable, el conjunto de combinaciones lineales finitas con coeficientes racionales (en  $\mathbb{Q} + i\mathbb{Q}$ ) es denso en  $H$  y es numerable. ( $\Rightarrow$ ) Sea  $D = \{d_n\}_{n=1}^{\infty}$  un conjunto denso numerable. Aplicando el proceso de Gram-Schmidt a la sucesión  $\{d_n\}$  (descartando los linealmente dependientes), obtenemos un sistema ortonormal  $\{e_n\}$ . El espacio generado por  $\{e_n\}$  coincide con el generado por  $\{d_n\}$ , que es denso en  $H$ . Por tanto,  $\{e_n\}$  es una base ortonormal.  $\square$

**Teorema C.9** (Caracterizaciones de Bases Ortonormales). *Sea  $\{e_k\}_{k=1}^{\infty}$  un sistema ortonormal en  $H$ . Las siguientes afirmaciones son equivalentes:*

1.  $\{e_k\}$  es una base ortonormal (es completo).
2. (Identidad de Parseval) Para todo  $u \in H$ ,  $\|u\|^2 = \sum_{k=1}^{\infty} |(u, e_k)|^2$ .
3. Para todo  $u \in H$ ,  $u = \sum_{k=1}^{\infty} (u, e_k) e_k$  (convergencia en norma).
4. Si  $(u, e_k) = 0$  para todo  $k$ , entonces  $u = 0$ .

### C.3 Teoremas de Proyección y Representación de Riesz

Una de las propiedades geométricas más importantes de los espacios de Hilbert es la posibilidad de proyectar ortogonalmente sobre subespacios cerrados.

**Teorema C.10** (Teorema de la Proyección). *Sea  $H$  un espacio de Hilbert y  $M$  un subespacio cerrado de  $H$ . Entonces, para todo  $x \in H$ , existen únicos vectores  $m \in M$  y  $z \in M^\perp$  tales que*

$$x = m + z.$$

*Además,  $\|x - m\| = \inf_{y \in M} \|x - y\|$ , es decir,  $m$  es la mejor aproximación de  $x$  en  $M$ .*

*Demostración.* Sea  $d = \inf_{y \in M} \|x - y\|$ . Existe una sucesión  $\{y_n\} \subset M$  tal que  $\|x - y_n\| \rightarrow d$ . Usando la identidad del paralelogramo:

$$\|a + b\|^2 + \|a - b\|^2 = 2\|a\|^2 + 2\|b\|^2,$$

aplicada a  $a = x - y_n$  y  $b = x - y_m$ , se puede demostrar que  $\{y_n\}$  es una sucesión de Cauchy. Como  $M$  es cerrado y  $H$  es completo,  $\{y_n\}$  converge a un  $m \in M$ . Para ver que  $x - m \in M^\perp$ , sea  $y \in M$  arbitrario. La función  $f(t) = \|x - (m + ty)\|^2$  tiene un mínimo en  $t = 0$ , lo que implica que la derivada en 0 es nula, resultando en  $\operatorname{Re}(x - m, y) = 0$ . Considerando  $iy$ , se obtiene la parte imaginaria. La unicidad se sigue de que  $M \cap M^\perp = \{0\}$ .  $\square$

Este teorema permite identificar el espacio dual de un espacio de Hilbert con el espacio mismo.

**Teorema C.11** (Teorema de Representación de Riesz). *Sea  $H$  un espacio de Hilbert y sea  $L : H \rightarrow \mathbb{C}$  un funcional lineal continuo (o acotado). Entonces existe un único vector  $u \in H$  tal que*

$$L(v) = (v, u) \quad \text{para todo } v \in H.$$

*Además, la norma del funcional coincide con la norma del vector:  $\|L\|_{H^*} = \|u\|_H$ .*

*Demostración.* Si  $L = 0$ , tomamos  $u = 0$ . Si  $L \neq 0$ , sea  $M = \ker(L)$ . Como  $L$  es continuo,  $M$  es cerrado. Por el Teorema de la Proyección,  $H = M \oplus M^\perp$ . Como  $L \neq 0$ ,  $M^\perp \neq \{0\}$ . Existe  $z \in M^\perp$  con  $\|z\| = 1$ . Para cualquier  $v \in H$ , el vector  $w = L(v)z - L(z)v$  está en  $\ker(L) = M$ , pues  $L(w) = L(v)L(z) - L(z)L(v) = 0$ . Como  $z \perp M$ , tenemos  $(w, z) = 0$ .

$$0 = (L(v)z - L(z)v, z) = L(v)(z, z) - L(z)(v, z) = L(v) - (v, \overline{L(z)}z).$$

Despejando  $L(v)$ , obtenemos  $L(v) = (v, u)$  con  $u = \overline{L(z)}z$ .  $\square$

# Bibliography

- [1] David L. Donoho and Philip B. Stark. Uncertainty principles and signal recovery. *SIAM Journal on Applied Mathematics*, 49(3):906–931, 1989.