Elementos de Cálculo Numérico

Primer Cuatrimestre 2026

Práctica N° 2: Álgebra Lineal Numérica

Descomposiciones matriciales

Ejercicio 1 (Propiedades de matrices triangulares superiores) *Sea $\mathcal{T}_n$ el conjunto de matrices triangulares superiores de tamaño $n \times n$.*

(a) Demuestre que si $A, B \in \mathcal{T}_n$, entonces $AB \in \mathcal{T}_n$.

(b) Demuestre que si $A \in \mathcal{T}_n$ tiene todos sus elementos diagonales no nulos, entonces A es inversible.

(c) Demuestre que si $A \in \mathcal{T}_n$ es inversible, entonces $A^{-1} \in \mathcal{T}_n$.

***Sugerencia para (c)**: Considere la ecuación $AA^{-1} = I$ y determine las entradas de A^{-1} por sustitución hacia atrás.*

Ejercicio 2 (Descomposición LDL^T para matrices simétricas) *Sea $A \in \mathbb{R}^{n\times n}$ una matriz simétrica que admite una descomposición LU sin pivoteo, donde L es triangular inferior con diagonal unitaria y U es triangular superior.*

(a) Demuestre que $U = DL^T$, donde D es una matriz diagonal.

(b) Concluya que A admite la descomposición $A = LDL^T$.

(c) Compare el costo de almacenamiento de LDL^T vs LU para matrices simétricas.

Ejercicio 3 (Eficiencia de LU para matrices tridiagonales) *Una matriz tridiagonal $A \in \mathbb{R}^{n\times n}$ tiene la forma:*

$$A = \begin{pmatrix} b_1 & c_1 & 0 & \cdots & 0 \\ a_2 & b_2 & c_2 & \cdots & 0 \\ 0 & a_3 & b_3 & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & c_{n-1} \\ 0 & \cdots & 0 & a_n & b_n \end{pmatrix}.$$

(a) Demuestre que si A admite descomposición LU sin pivoteo, entonces L y U son bidiagonales:

$$L = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ \ell_2 & 1 & \ddots & \vdots \\ 0 & \ddots & \ddots & 0 \\ \vdots & & \ell_n & 1 \end{pmatrix}, \quad U = \begin{pmatrix} u_1 & c_1 & 0 & \cdots \\ 0 & u_2 & c_2 & \ddots \\ \vdots & \ddots & \ddots & \ddots \\ 0 & \cdots & 0 & u_n \end{pmatrix}.$$

(b) *Derive fórmulas explícitas para ℓ_i y u_i en términos de a_i, b_i, c_i.*

(c) *Demuestre que el costo de factorizar A es $O(n)$ operaciones (en lugar de $O(n^3)$ para matrices densas).*

(d) *Demuestre que el costo de resolver $Ax = b$ dado $A = LU$ es $O(n)$ operaciones. ¿Cuántas eran para matrices densas?*

Ejercicio 4 (Proyección ortogonal mediante factorización QR) *Sea $A \in \mathbb{R}^{m\times n}$ con $m \geq n$ y rango columna completo, y sea $A = QR$ su descomposición QR.*

(a) *Demuestre que $P = QQ^T$ es una matriz de proyección, es decir, que $P^2 = P$ y $P^T = P$.*

(b) *Demuestre que P proyecta sobre el espacio columna de A: para todo $y \in \mathbb{R}^m$, se tiene $Py \in Col(A)$.*

(c) *Demuestre que P es la proyección ortogonal: $(I - P)y \perp Col(A)$ para todo $y \in \mathbb{R}^m$.*

(d) *Calcule explícitamente la matriz de proyección P para:*

$$A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{pmatrix}.$$

Ejercicio 5 (Espacios fundamentales y factorización QR) *Sea $A \in \mathbb{R}^{m\times n}$ con $m \geq n$ y sea $A = QR$ su descomposición QR, donde $Q \in \mathbb{R}^{m\times n}$ tiene columnas ortonormales y $R \in \mathbb{R}^{n\times n}$ es triangular superior.*

(a) ***Espacio columna**: Demuestre que $Col(A) = Col(Q)$.*

(b) ***Espacio nulo**: Demuestre que $Nul(A) = Nul(R)$.*

(c) *Use (a) y (b) para explicar por qué A y Q tienen el mismo rango.*

(d) *Si $r = rank(A) < n$, explique cómo la estructura de R revela esta deficiencia de rango.*

Ejercicio 6 (Factorización de Cholesky para matrices definidas positivas) *Sea $B \in \mathbb{R}^{n\times n}$ una matriz simétrica definida positiva.*

(a) ***Existencia**: Demuestre que B admite una descomposición $B = LL^T$, donde L es triangular inferior.*

***Sugerencia**: Escriba $B = B^{1/2}B^{1/2}$ usando la raíz cuadrada matricial y aplique la descomposición QR a $B^{1/2}$.*

(b) ***Algoritmo**: Suponiendo que la descomposición $B = LL^T$ existe, derive fórmulas explícitas para las entradas de L y estime el costo del algoritmo.*

***Sugerencia**: Iguale entradas en $B = LL^T$ columna por columna. La entrada (i, j) da $b_{ij} = \sum_{k=1}^{\min(i,j)} \ell_{ik}\ell_{jk}$. Para determinar la columna j de L (es decir, $\ell_{jj}, \ell_{j+1,j}, \ldots, \ell_{nj}$), suponiendo conocidas las columnas $1, \ldots, j-1$: primero despeje ℓ_{jj} de la entrada diagonal (j, j), y luego ℓ_{ij} para $i > j$.*

Ejercicio 7 (Ajuste polinomial por cuadrados mínimos) *Se mide la deformación y (en mm) de una viga en función de la carga aplicada t (en kN), obteniendo los datos:*

t_k	1	2	3	4	5
y_k	0.5	2.5	5.8	11.2	18.1

Se propone ajustar un polinomio de grado 2: $p(t) = c_0 + c_1 t + c_2 t^2$.

(a) *Escriba el sistema sobredeterminado $Ac = y$.*

(b) *Plantee las ecuaciones normales $A^T Ac = A^T y$ y calcule $A^T A$ y $A^T y$.*

(c) *¿Qué cambiaría en la matriz A si en lugar de la base $\{1, t, t^2\}$ se usara la base $\{1, t, \frac{1}{2}(3t^2 - 1)\}$?*

Ejercicio 8 (Linealización de modelos no lineales) *En muchas aplicaciones, los datos siguen un modelo que no es lineal en los parámetros, pero puede* ***linealizarse*** *mediante un cambio de variable.*

(a) ***Modelo exponencial****: La concentración de un fármaco en sangre sigue $y = \alpha\, e^{\beta t}$, donde $\alpha > 0$ y $\beta < 0$ son desconocidos. Se tienen los datos:*

t_k (horas)	0	1	2	3	4
y_k (mg/L)	10.2	6.9	4.3	3.2	1.9

Aplique logaritmo natural a ambos lados del modelo y plantee el problema de cuadrados mínimos resultante. Identifique la matriz A y el vector b.

(b) ***Modelo potencial****: La velocidad del viento y a altura t sigue una ley de potencia $y = \alpha\, t^{\beta}$. Se tienen las mediciones:*

t_k (metros)	10	20	40	80	100
y_k (m/s)	5.1	5.9	6.8	7.8	8.2

Linealice el modelo y plantee el problema de cuadrados mínimos correspondiente.

(c) ***Discusión****: La linealización transforma el problema de minimizar $\sum_k (y_k - \alpha e^{\beta t_k})^2$ en minimizar $\sum_k (\ln y_k - \ln \alpha - \beta t_k)^2$. ¿Son equivalentes estos dos problemas de optimización? ¿En qué sentido la linealización altera el peso relativo de las observaciones?*

Ejercicio 9 (Cuadrados mínimos en el caso complejo: ajuste de sinusoides) *Un sismógrafo registra una señal $y(t)$ que se modela como superposición de ondas sinusoidales de frecuencias conocidas $\omega_1, \omega_2, \ldots, \omega_n$:*

$$y(t) = \sum_{j=1}^{n} c_j\, e^{i\omega_j t}, \quad c_j \in \mathbb{C}.$$

Las amplitudes complejas c_j (que codifican amplitud y fase de cada onda) son desconocidas. Se dispone de $m > n$ mediciones $y_k = y(t_k)$ en tiempos $t_1, \ldots, t_m$, contaminadas por ruido, por lo que el sistema es incompatible y se busca la solución de cuadrados mínimos:

$$\min_{c \in \mathbb{C}^n} \|Ac - y\|_2, \quad \text{donde } A_{kj} = e^{i\omega_j t_k}, \quad y = (y_1, \ldots, y_m)^T.$$

(a) *Escriba las ecuaciones normales para este problema. Verifique que la matriz A^*A es hermítica y definida positiva.*

(b) *Suponga $n = 2$ frecuencias $\omega_1 = 1$, $\omega_2 = 3$, con $m = 4$ mediciones equiespaciadas $t_k = \frac{\pi}{4}(k-1)$, $k = 1, \ldots, 4$. Escriba explícitamente la matriz $A \in \mathbb{C}^{4\times 2}$.*

Ejercicio 10 (Análisis del timbre de un instrumento musical) *Cuando un instrumento musical produce una nota con frecuencia fundamental ω_0, la señal resultante es una superposición de la fundamental y sus* ***armónicos superiores*** *$2\omega_0, 3\omega_0, \ldots$:*

$$y(t) = \sum_{j=1}^{n} c_j \, e^{ij\omega_0 t}, \quad c_j \in \mathbb{C}.$$

La frecuencia fundamental ω_0 determina la nota (por ejemplo, un La central corresponde a 440 Hz). El ***timbre****, que es lo que permite distinguir la misma nota tocada por un piano, un violín o una flauta, está determinado por las amplitudes relativas $|c_1|, |c_2|, \ldots, |c_n|$ de cada armónico. Por ejemplo, una flauta tiene casi toda la energía en la fundamental ($|c_1| \gg |c_j|$ para $j \geq 2$), mientras que un oboe tiene armónicos superiores muy pronunciados.*

El objetivo es, dada una grabación de una nota conocida, estimar los coeficientes c_j para caracterizar el timbre del instrumento. Se toman $m > n$ muestras $y_k = y(t_k)$ (contaminadas por ruido) y se plantea el problema de cuadrados mínimos:

$$\min_{c\in\mathbb{C}^n} \|Ac - y\|_2, \quad \text{donde } A_{kj} = e^{ij\omega_0 t_k}, \quad y = (y_1, \ldots, y_m)^T.$$

Considere un La central ($\omega_0 = 440 \cdot 2\pi$ rad/s) con $n = 3$ armónicos y $m = 6$ muestras equiespaciadas en $t_k = \frac{k-1}{6\cdot 440}$ para $k = 1, \ldots, 6$.

(a) *Escriba la matriz $A \in \mathbb{C}^{6\times 3}$ y verifique que las columnas de A son ortogonales, es decir, que $A^*A = 6I_3$.*

(b) *Use el teorema de la proyección ortogonal para escribir directamente la solución de cuadrados mínimos. ¿Cuál es la complejidad del algoritmo obtenido, en comparación con resolver las ecuaciones normales o realizar la descomposición QR?*

Ejercicio 11 *Sea $A \in \mathbb{C}^{n\times n}$ una matriz no singular. Demuestre que la distancia de A al conjunto de matrices singulares (en norma 2) es exactamente su menor valor singular σ_n. Es decir:*

$$\min_{B \text{ singular}} \|A - B\|_2 = \sigma_n.$$

Ejercicio 12 (Descomposición polar desde SVD) *Toda matriz $A \in \mathbb{R}^{m\times n}$ admite una* ***descomposición polar*** *$A = Q_{polar}S$, donde:*

- *$Q_{polar} \in \mathbb{R}^{m\times n}$ tiene columnas ortonormales ($Q_{polar}^T Q_{polar} = I_n$).*
- *$S \in \mathbb{R}^{n\times n}$ es simétrica semidefinida positiva.*

Sea $A = U\Sigma V^T$ la descomposición SVD de A. Demuestre que:

$$Q_{polar} = UV^T, \quad S = V\Sigma V^T.$$

Ejercicio 13 (Problema de Procrustes ortogonal) *Dadas dos matrices $A, B \in \mathbb{R}^{m\times n}$ representando conjuntos de datos (nubes de puntos), queremos encontrar la matriz ortogonal $Q \in \mathbb{R}^{n\times n}$ óptima (geométricamente, la rotación óptima) que transforma A en B minimizando:*

$$\min_{Q^TQ=I} \|AQ - B\|_F,$$

donde $\|\cdot\|_F$ es la norma de Frobenius.

(a) Demuestre que minimizar $\|AQ - B\|_F^2$ es equivalente a maximizar $tr(Q^TA^TB)$.

(b) Sea $A^TB = U\Sigma V^T$ la descomposición SVD de A^TB. Demuestre que la solución óptima es:

$$Q = UV^T.$$

Ejercicio 14 (Pseudoinversa y solución de norma mínima) *Sea $A \in \mathbb{R}^{m\times n}$ con $m \geq n$ y $r = rank(A) \leq n$. Sea $A = U\Sigma V^T$ su SVD, donde $U = (u_1 \mid \cdots \mid u_m) \in \mathbb{R}^{m\times m}$ y $V = (v_1 \mid \cdots \mid v_n) \in \mathbb{R}^{n\times n}$ son ortogonales, y $\Sigma \in \mathbb{R}^{m\times n}$ tiene entradas diagonales $\sigma_1 \geq \cdots \geq \sigma_r > 0 = \sigma_{r+1} = \cdots = \sigma_n$. Se define la **pseudoinversa de Moore-Penrose** como:*

$$A^+ = V\Sigma^+U^T = \sum_{i=1}^{r} \frac{1}{\sigma_i} v_i u_i^T \in \mathbb{R}^{n\times m},$$

donde $\Sigma^+ \in \mathbb{R}^{n\times m}$ tiene entradas diagonales $1/\sigma_1, \ldots, 1/\sigma_r, 0, \ldots, 0$.

Consideramos el problema de cuadrados mínimos $\min_x \|Ax - b\|_2$

*(a) Demuestre que si $r < n$, el problema de cuadrados mínimos admite infinitas soluciones. **Sugerencia**: Si $\hat{x}$ es una solución, considere $\hat{x} + z$ con $z \in Ker(A)$.*

(b) Demuestre que $x = A^+b$ es una solución del problema de cuadrados mínimos.

(c) Demuestre que entre todas las soluciones de cuadrados mínimos, $x = A^+b$ tiene norma mínima. Es decir, si definimos el conjunto de soluciones de cuadrados mínimos como

$$\mathcal{S} = \operatorname{argmin}_{x\in\mathbb{R}^n} \|Ax - b\|_2,$$

entonces $\|A^+b\|_2 = \min_{x\in\mathcal{S}} \|x\|_2$.

Ejercicio 15 (Condicionamiento de mínimos cuadrados vía SVD) *Sea $A \in \mathbb{R}^{m\times n}$ con $m \geq n$ y rango columna completo, con descomposición QR $A = QR$ y SVD $A = U\Sigma V^T$. Usando la SVD de A, demuestre que:*

$$\kappa(A^TA) = \kappa(A)^2 = \kappa(R)^2,$$

donde $\kappa(\cdot)$ denota el número de condición en norma 2. Concluya que resolver el problema de mínimos cuadrados vía QR es numéricamente más estable que vía las ecuaciones normales cuando A está mal condicionada.

Métodos iterativo para autovalores y sistemas lineales

Ejercicio 16 (Método de la potencia: análisis de convergencia) *Sea $A \in \mathbb{R}^{n\times n}$ una matriz diagonalizable con autovalores $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$ y autovectores linealmente independientes $\{v_1, \ldots, v_n\}$. El método de la potencia construye la sucesión $x^{(k+1)} = \frac{Ax^{(k)}}{\|Ax^{(k)}\|}$.*

(a) Si escribimos el vector inicial como $x^{(0)} = c_1 v_1 + \cdots + c_n v_n$ con $c_1 \neq 0$, demuestre que:

$$A^k x^{(0)} = \lambda_1^k \left(c_1 v_1 + \sum_{j=2}^{n} c_j \left(\frac{\lambda_j}{\lambda_1}\right)^k v_j \right).$$

(b) Deduzca que la dirección de $x^{(k)}$ converge a la dirección de v_1 (autovector dominante) cuando $k \to \infty$.

(c) Identifique el término que controla la velocidad de convergencia y exprese la tasa de convergencia en función de los autovalores.

(d) Demuestre que el cociente de Rayleigh $\rho(x^{(k)}) = \frac{(x^{(k)})^T A x^{(k)}}{\|x^{(k)}\|_2^2}$ converge a λ_1 (asuma convergencia de $x^{(k)}$ a v_1 normalizado).

Ejercicio 17 (Método QR e Iteración Ortogonal) *El **método QR** utiliza la descomposición QR para calcular autovalores. Consiste en, dada una matriz $A_1 = A \in \mathbb{R}^{n\times n}$, generar una sucesión de matrices A_k definida por:*

$$A_k = Q_k R_k \quad (QR), \qquad A_{k+1} = R_k Q_k.$$

*(a) Probar que todas las matrices A_k tienen los mismos autovalores. **Sugerencia**: Demuestre que A_{k+1} es semejante a A_k.*

*(b) Considere las matrices acumuladas $\bar{Q}_k = Q_1 Q_2 \cdots Q_k$ y $\bar{R}_k = R_k R_{k-1} \cdots R_1$. Demuestre por inducción que $A^k = \bar{Q}_k \bar{R}_k$. Es decir, $\bar{Q}_k$ proviene de la factorización QR de la potencia A^k. **Sugerencia**: Observe que $A_{k+1} = Q_k^T A_k Q_k$ y use la hipótesis inductiva.*

*(c) Demuestre que $A^k e_1$ es proporcional a la primera columna de $\bar{Q}_k$ (use que $\bar{R}_k$ es triangular superior). Concluya que la primera columna de la matriz ortogonal acumulada converge al autovector dominante de A (simulando el **método de la potencia** sobre e_1).*

Ejercicio 18 (Algoritmo QR para raíces de polinomios) *Dado un polinomio mónico $p(\lambda) = \lambda^n + a_{n-1}\lambda^{n-1} + \cdots + a_1\lambda + a_0$, su **matriz compañera** es:*

$$C = \begin{pmatrix} 0 & 0 & \cdots & 0 & -a_0 \\ 1 & 0 & \cdots & 0 & -a_1 \\ 0 & 1 & \cdots & 0 & -a_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & -a_{n-1} \end{pmatrix}.$$

(a) *Demuestre que el polinomio característico de C es:*

$$\det(C - \lambda I) = (-1)^n p(\lambda).$$

Por lo tanto, los autovalores de C son precisamente las raíces de p.

Ejercicio 19 (Convergencia de métodos iterativos estacionarios) *Un método iterativo estacionario para resolver $Ax = b$ tiene la forma $x^{(k+1)} = Gx^{(k)} + c$, donde G es la matriz de iteración.*

(a) *Demuestre que para cualquier matriz $G \in \mathbb{R}^{n\times n}$:*

$$G^k \to 0 \quad \text{si y solo si} \quad \rho(G) < 1,$$

donde $\rho(G) = \max_i |\lambda_i(G)|$ es el radio espectral. ***Sugerencia****: Use la forma de Jordan de G y que todas las normas matriciales son equivalentes.*

(b) *Demuestre que para cualquier norma matricial:*

$$\rho(G) \leq \|G\|.$$

(c) *Concluya que si $\|G\| < 1$ para alguna norma, entonces el método converge.*

Ejercicio 20 (Método de Jacobi) *El método de Jacobi para $Ax = b$ es $x^{(k+1)} = D^{-1}(b - (L+U)x^{(k)})$, donde $A = D+L+U$ (diagonal, triangular inferior estricta, triangular superior estricta).*

(a) *Suponga que A es* ***estrictamente diagonal dominante por filas****:*

$$|a_{ii}| > \sum_{j\neq i} |a_{ij}|, \quad i = 1, \ldots, n.$$

Demuestre que el método de Jacobi converge analizando los autovalores de la matriz de iteración G_J. ***Sugerencia****: Utilice el Teorema de los Círculos de Gershgorin aplicado a la matriz $G_J = -D^{-1}(L+U)$. Observe que los elementos diagonales de G_J son nulos y relacione los radios de los discos con la condición de diagonal dominancia.*

(b) *Exhiba un ejemplo de matriz simétrica definida positiva para la cual Jacobi diverge.*

Ejercicio 21 (Método de Gauss-Seidel) *El método de Gauss-Seidel para $Ax = b$ es $(D+L)x^{(k+1)} = b - Ux^{(k)}$, con matriz de iteración $G_{GS} = -(D+L)^{-1}U$.*

(a) *Suponga que A es estrictamente diagonal dominante por filas. Demuestre que el método de Gauss-Seidel converge analizando los autovalores de G_{GS}.* ***Sugerencia****: Use un argumento similar al de la demostración del Teorema de los Círculos de Gershgorin aplicado a G_{GS}.*