

---

# ELEMENTOS DE CÁLCULO NUMÉRICO

Primer Cuatrimestre 2026

---

## Práctica N° 2: Álgebra Lineal Numérica

### Descomposiciones matriciales

**Ejercicio 1 (Propiedades de matrices triangulares superiores)** Sea  $\mathcal{T}_n$  el conjunto de matrices triangulares superiores de tamaño  $n \times n$ .

- (a) Demuestre que si  $A, B \in \mathcal{T}_n$ , entonces  $AB \in \mathcal{T}_n$ .
- (b) Demuestre que si  $A \in \mathcal{T}_n$  tiene todos sus elementos diagonales no nulos, entonces  $A$  es inversible.
- (c) Demuestre que si  $A \in \mathcal{T}_n$  es inversible, entonces  $A^{-1} \in \mathcal{T}_n$ .

**Sugerencia para (c):** Considere la ecuación  $AA^{-1} = I$  y determine las entradas de  $A^{-1}$  por sustitución hacia atrás.

**Ejercicio 2 (Descomposición  $LDL^T$  para matrices simétricas)** Sea  $A \in \mathbb{R}^{n \times n}$  una matriz simétrica que admite una descomposición  $LU$  sin pivoteo, donde  $L$  es triangular inferior con diagonal unitaria y  $U$  es triangular superior.

- (a) Demuestre que  $U = DL^T$ , donde  $D$  es una matriz diagonal.
- (b) Concluya que  $A$  admite la descomposición  $A = LDL^T$ .
- (c) Verifique explícitamente esta descomposición para la matriz:

$$A = \begin{pmatrix} 4 & 2 & 2 \\ 2 & 3 & 1 \\ 2 & 1 & 3 \end{pmatrix}.$$

- (d) Compare el costo de almacenamiento de  $LDL^T$  vs  $LU$  para matrices simétricas.

**Sugerencia:** Use que  $A = A^T$  y  $(LU)^T = U^T L^T = A$ .

**Ejercicio 3 (Eficiencia de LU para matrices tridiagonales)** Una matriz tridiagonal  $A \in \mathbb{R}^{n \times n}$  tiene la forma:

$$A = \begin{pmatrix} b_1 & c_1 & 0 & \cdots & 0 \\ a_2 & b_2 & c_2 & \cdots & 0 \\ 0 & a_3 & b_3 & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & c_{n-1} \\ 0 & \cdots & 0 & a_n & b_n \end{pmatrix}.$$

- (a) Demuestre que si  $A$  admite descomposición  $LU$  sin pivoteo, entonces  $L$  y  $U$  son bidiagonales:

$$L = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ \ell_2 & 1 & \ddots & \vdots \\ 0 & \cdots & \ddots & 0 \\ \vdots & & \ell_n & 1 \end{pmatrix}, \quad U = \begin{pmatrix} u_1 & c_1 & 0 & \cdots \\ 0 & u_2 & c_2 & \ddots \\ \vdots & \ddots & \ddots & \ddots \\ 0 & \cdots & 0 & u_n \end{pmatrix}.$$

- (b) Derive fórmulas explícitas para  $\ell_i$  y  $u_i$  en términos de  $a_i, b_i, c_i$ .
- (c) Demuestre que el costo de factorizar  $A$  es  $O(n)$  operaciones (en lugar de  $O(n^3)$  para matrices densas).
- (d) Demuestre que el costo de resolver  $Ax = b$  dado  $A = LU$  es  $O(n)$  operaciones.
- (e) Aplique el algoritmo a la matriz tridiagonal  $5 \times 5$  con  $a_i = -1$ ,  $b_i = 2$ ,  $c_i = -1$ .

**Ejercicio 4 (Proyección ortogonal mediante factorización QR)** Sea  $A \in \mathbb{R}^{m \times n}$  con  $m \geq n$  y rango columna completo, y sea  $A = QR$  su descomposición QR.

- (a) Demuestre que  $P = QQ^T$  es una matriz de proyección, es decir, que  $P^2 = P$  y  $P^T = P$ .
- (b) Demuestre que  $P$  proyecta sobre el espacio columna de  $A$ : para todo  $y \in \mathbb{R}^m$ , se tiene  $Py \in \text{Col}(A)$ .
- (c) Demuestre que  $P$  es la proyección ortogonal:  $(I - P)y \perp \text{Col}(A)$  para todo  $y \in \mathbb{R}^m$ .
- (d) Calcule explícitamente la matriz de proyección  $P$  para:

$$A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{pmatrix}.$$

**Ejercicio 5 (Espacios fundamentales y factorización QR)** Sea  $A \in \mathbb{R}^{m \times n}$  con  $m \geq n$  y sea  $A = QR$  su descomposición QR, donde  $Q \in \mathbb{R}^{m \times n}$  tiene columnas ortonormales y  $R \in \mathbb{R}^{n \times n}$  es triangular superior.

- (a) **Espacio columna:** Demuestre que  $\text{Col}(A) = \text{Col}(Q)$ .
- (b) **Espacio nulo:** Demuestre que  $\text{Nul}(A) = \text{Nul}(R)$ .
- (c) Use (a) y (b) para explicar por qué  $A$  y  $Q$  tienen el mismo rango.
- (d) Si  $r = \text{rank}(A) < n$ , explique cómo la estructura de  $R$  revela esta deficiencia de rango.

**Ejercicio 6 (Mínimos cuadrados vía QR vs ecuaciones normales)** Sea  $A \in \mathbb{R}^{m \times n}$  con  $m \geq n$  y rango columna completo, y sea  $b \in \mathbb{R}^m$ . El problema de mínimos cuadrados es:

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2.$$

- (a) **Solución vía ecuaciones normales:** Demuestre que la solución satisface  $A^T Ax = A^T b$ .

- (b) **Solución vía QR:** Si  $A = QR$ , demuestre que la solución es  $x = R^{-1}Q^T b$ .
- (c) Demuestre que ambos métodos producen la misma solución en aritmética exacta.
- (d) **Análisis de condicionamiento:** Usando la SVD de  $A$ , demuestre que:

$$\kappa(A^T A) = \kappa(A)^2 = \kappa(R)^2,$$

donde  $\kappa(\cdot)$  denota el número de condición en norma 2. Concluya que QR es numéricamente más estable que las ecuaciones normales cuando  $A$  está mal condicionada.

**Ejercicio 7 (Factorización de Cholesky para matrices definidas positivas)** Sea  $B \in \mathbb{R}^{n \times n}$  una matriz simétrica definida positiva.

- (a) Demuestre que existe una matriz  $A \in \mathbb{R}^{n \times n}$  tal que  $B = AA^T$ . **Sugerencia:** Use que toda matriz definida positiva tiene raíz cuadrada:  $B = B^{1/2} B^{1/2}$ .
- (b) Aplique la descomposición QR a  $A^T$ :  $A^T = QR$ . Demuestre que:

$$B = AA^T = (A^T)^T A^T = R^T Q^T QR = R^T R.$$

- (c) Concluya que  $B$  admite la descomposición de Cholesky  $B = LL^T$  donde  $L = R^T$  es triangular inferior.
- (d) Verifique la factorización para:

$$B = \begin{pmatrix} 4 & 2 \\ 2 & 5 \end{pmatrix}.$$

- (e) Compare el costo de Cholesky ( $\sim \frac{n^3}{6}$  operaciones) con LU ( $\sim \frac{n^3}{3}$  operaciones).

**Ejercicio 8 (Norma 2 de matrices normales)** Una matriz  $A \in \mathbb{C}^{n \times n}$  es **normal** si  $A^* A = AA^*$ , donde  $A^*$  denota la conjugada transpuesta.

- (a) Demuestre que:

$$\|A\|_2 = \max_{1 \leq i \leq n} |\lambda_i|,$$

donde  $\lambda_i$  son los autovalores de  $A$ . (Sugerencia: Use la descomposición espectral para matrices normales:  $A = U\Lambda U^*$ , donde  $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$  y  $U$  es unitaria.)

- (b) Verifique que matrices hermitianas, unitarias y normales satisfacen  $\|A\|_2 = \rho(A)$  (radio espectral).
- (c) Muestre con un ejemplo que esto no es cierto para matrices no normales.

**Ejercicio 9** Sea  $A \in \mathbb{C}^{n \times n}$  una matriz no singular. Demuestre que la distancia de  $A$  al conjunto de matrices singulares (en norma 2) es exactamente su menor valor singular  $\sigma_n$ . Es decir:

$$\min_{B \text{ singular}} \|A - B\|_2 = \sigma_n.$$

**Ejercicio 10 (Descomposición polar desde SVD)** Toda matriz  $A \in \mathbb{R}^{m \times n}$  admite una *descomposición polar*  $A = Q_{\text{polar}} S$ , donde:

- $Q_{\text{polar}} \in \mathbb{R}^{m \times n}$  tiene columnas ortonormales ( $Q_{\text{polar}}^T Q_{\text{polar}} = I_n$ ).
- $S \in \mathbb{R}^{n \times n}$  es simétrica semidefinida positiva.

Sea  $A = U \Sigma V^T$  la descomposición SVD de  $A$ . Demuestre que:

$$Q_{\text{polar}} = UV^T, \quad S = V \Sigma V^T.$$

**Ejercicio 11 (Problema de Procrustes ortogonal)** Dadas dos matrices  $A, B \in \mathbb{R}^{m \times n}$  representando conjuntos de datos (nubes de puntos), queremos encontrar la matriz ortogonal  $Q \in \mathbb{R}^{n \times n}$  óptima (geoméricamente, la rotación óptima) que transforma  $A$  en  $B$  minimizando:

$$\min_{Q^T Q = I} \|AQ - B\|_F,$$

donde  $\|\cdot\|_F$  es la norma de Frobenius.

- (a) Demuestre que minimizar  $\|AQ - B\|_F^2$  es equivalente a maximizar  $\text{tr}(Q^T A^T B)$ .
- (b) Sea  $A^T B = U \Sigma V^T$  la descomposición SVD de  $A^T B$ . Demuestre que la solución óptima es:

$$Q = UV^T.$$

**Ejercicio 12 (Pseudoinversa y solución de norma mínima)** Sea  $A \in \mathbb{R}^{m \times n}$  con SVD  $A = U \Sigma V^T = \sum_{i=1}^r \sigma_i u_i v_i^T$ . Se define la *pseudoinversa de Moore-Penrose* como:

$$A^+ = V \Sigma^+ U^T = \sum_{i=1}^r \frac{1}{\sigma_i} v_i u_i^T,$$

donde  $\Sigma^+$  es diagonal con entradas  $1/\sigma_i$  en las primeras  $r$  posiciones.

- (a) Demuestre que  $x = A^+ b$  resuelve el problema de cuadrados mínimos  $\min_x \|Ax - b\|_2$ .
- (b) Demuestre que entre todas las soluciones de cuadrados mínimos,  $x = A^+ b$  tiene norma mínima:

$$\|A^+ b\|_2 = \min\{\|x\|_2 : \|Ax - b\|_2 = \min\}.$$

**Ejercicio 13 (Condicionamiento y propagación del error vía SVD)** Sea  $A \in \mathbb{R}^{n \times n}$  una matriz inversible y considere el sistema lineal  $Ax = b$ . Suponga que el lado derecho  $b$  está contaminado por un error  $\Delta b$ , de modo que la solución calculada  $x + \Delta x$  satisface  $A(x + \Delta x) = b + \Delta b$ .

- (a) Usando la descomposición SVD de  $A = U \Sigma V^T$ , demuestre que:

$$\|\Delta x\|_2 \leq \frac{1}{\sigma_n} \|\Delta b\|_2 \quad y \quad \|b\|_2 \leq \sigma_1 \|x\|_2.$$

(b) Deduzca que el error relativo satisface la cota:

$$\frac{\|\Delta x\|_2}{\|x\|_2} \leq \kappa_2(A) \frac{\|\Delta b\|_2}{\|b\|_2},$$

donde  $\kappa_2(A) = \sigma_1/\sigma_n$  es el número de condición.

- (c) Construya un ejemplo de  $2 \times 2$  donde la igualdad se alcance. **Sugerencia:** Elija  $b$  alineado con el primer vector singular izquierdo  $u_1$  (máxima amplificación) y  $\Delta b$  alineado con el último  $u_n$  (mínima atenuación en la inversa), o viceversa según convenga.
- (d) Concluya que si  $\kappa_2(A)$  es grande, pequeños errores en  $b$  pueden resultar en errores catastróficos en la solución  $x$ , independientemente del método de resolución del sistema lineal.

**Ejercicio 14 (Matrices de Householder)** Una matriz de Householder tiene la forma  $H = I - 2vv^T$  donde  $v \in \mathbb{R}^n$  con  $\|v\|_2 = 1$ .

- (a) Demuestre que  $H$  es ortogonal:  $H^T H = I$ .
- (b) Demuestre que  $H$  es autoinversa:  $H^2 = I$  (es decir,  $H = H^{-1}$ ).
- (c) Demuestre que  $H$  es simétrica:  $H^T = H$ .
- (d) Interprete geométricamente  $H$  como una reflexión respecto al hiperplano ortogonal a  $v$ .
- (e) Para un vector  $x \in \mathbb{R}^n$  dado, construya  $v$  tal que  $Hx = \alpha e_1$  donde  $e_1 = (1, 0, \dots, 0)^T$  y  $\alpha = \pm \|x\|_2$ .

**Sugerencia para (e):** Tome  $v = \frac{x - \alpha e_1}{\|x - \alpha e_1\|}$  con  $\alpha = -\text{sign}(x_1)\|x\|_2$  para evitar cancelación.

**Ejercicio 15 (Factorización QR mediante reflexiones de Householder)** El algoritmo de Householder construye la factorización QR aplicando reflexiones sucesivas.

- (a) Sea  $A \in \mathbb{R}^{m \times n}$  con  $m \geq n$ . En el paso  $k$ , queremos anular las entradas debajo de la diagonal en la columna  $k$ .
- (b) Construya la matriz de Householder  $H_k$  que anula las componentes  $k+1, \dots, m$  del vector formado por la columna  $k$  de la submatriz restante.
- (c) Demuestre que después de  $n$  pasos:

$$H_n \cdots H_2 H_1 A = R,$$

donde  $R$  es triangular superior.

- (d) Concluya que  $A = QR$  con  $Q = H_1 H_2 \cdots H_n$ .
- (e) Demuestre que el costo total es  $O(2mn^2 - \frac{2n^3}{3})$  operaciones.

**Ejercicio 16 (Reducción bidiagonal para SVD)** El cálculo de la SVD de  $A \in \mathbb{R}^{m \times n}$  se facilita si primero reducimos  $A$  a forma bidiagonal.

- (a) Demuestre que mediante reflexiones de Householder aplicadas alternadamente por izquierda y derecha, se puede reducir  $A$  a la forma:

$$A = UBV^T,$$

donde  $U \in \mathbb{R}^{m \times m}$  y  $V \in \mathbb{R}^{n \times n}$  son ortogonales, y  $B \in \mathbb{R}^{m \times n}$  es bidiagonal superior:

$$B = \begin{pmatrix} d_1 & f_1 & 0 & \cdots & 0 \\ 0 & d_2 & f_2 & \cdots & 0 \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & d_{n-1} & f_{n-1} \\ 0 & \cdots & 0 & 0 & d_n \\ 0 & \cdots & 0 & 0 & 0 \\ \vdots & & \vdots & \vdots & \vdots \end{pmatrix}.$$

- (b) Explique cómo la SVD de  $A$  se obtiene de la SVD de  $B$ : si  $B = \tilde{U}\Sigma\tilde{V}^T$ , entonces  $A = (U\tilde{U})\Sigma(\tilde{V}^TV^T)$ .
- (c) Demuestre que el costo de bidiagonalización es  $O(2mn^2 - \frac{2n^3}{3})$  operaciones.

**Ejercicio 17 (Forma de de Hessenberg)** Una matriz  $H \in \mathbb{R}^{n \times n}$  está en **forma de Hessenberg superior** si  $h_{ij} = 0$  para  $i > j + 1$ .

- (a) Demuestre que el costo de calcular la descomposición QR de una matriz  $H \in \mathbb{R}^{n \times n}$  en forma de Hessenberg es  $O(n^2)$  operaciones. ¿Cuál es el costo para matrices densas generales? **Sugerencia:** Observe que en cada columna  $k$  solo es necesario anular una entrada (la subdiagonal). Una reflexión de Householder diseñada para esto modificará únicamente dos filas de la matriz, costando  $O(n)$  operaciones.
- (b) Demuestre que si  $A$  es simétrica y se reduce a forma de Hessenberg mediante transformaciones de semejanza ortogonal  $H = Q^T A Q$ , entonces  $H$  es tridiagonal. **Sugerencia:** Use que  $H$  es simétrica ( $H = H^T$ ) y que la forma de Hessenberg superior implica  $h_{ij} = 0$  para  $i > j + 1$ .

## Métodos iterativos

**Ejercicio 18 (Método de la potencia: análisis de convergencia)** Sea  $A \in \mathbb{R}^{n \times n}$  una matriz diagonalizable con autovalores  $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$  y autovectores linealmente independientes  $\{v_1, \dots, v_n\}$ . El método de la potencia construye la sucesión  $x^{(k+1)} = \frac{Ax^{(k)}}{\|Ax^{(k)}\|}$ .

- (a) Si escribimos el vector inicial como  $x^{(0)} = c_1 v_1 + \cdots + c_n v_n$  con  $c_1 \neq 0$ , demuestre que:

$$A^k x^{(0)} = \lambda_1^k \left( c_1 v_1 + \sum_{j=2}^n c_j \left( \frac{\lambda_j}{\lambda_1} \right)^k v_j \right).$$

- (b) Deduzca que la dirección de  $x^{(k)}$  converge a la dirección de  $v_1$  (autovector dominante) cuando  $k \rightarrow \infty$ .

- (c) Identifique el término que controla la velocidad de convergencia y exprese la tasa de convergencia en función de los autovalores.
- (d) Demuestre que el cociente de Rayleigh  $\rho(x^{(k)}) = \frac{(x^{(k)})^T A x^{(k)}}{\|x^{(k)}\|_2^2}$  converge a  $\lambda_1$  (asuma convergencia de  $x^{(k)}$  a  $v_1$  normalizado).

**Ejercicio 19 (Método de la potencia inversa)** El método de la potencia inversa con shift  $\sigma$  aplica el método de la potencia a la matriz  $M = (A - \sigma I)^{-1}$ .

- (a) Demuestre que si  $(\lambda, v)$  es un par autovalor-autovector de  $A$ , con  $\lambda \neq \sigma$ , entonces  $(\mu, v)$  con  $\mu = (\lambda - \sigma)^{-1}$  es par autovalor-autovector de  $M$ .
- (b) Suponga que  $\lambda_k$  es el autovalor de  $A$  más cercano a  $\sigma$ , tal que  $|\lambda_k - \sigma| < |\lambda_j - \sigma|$  para todo  $j \neq k$ . Demuestre que el método converge al autovector  $v_k$ .
- (c) Demuestre que la tasa de convergencia asintótica es lineal e igual a  $|\lambda_k - \sigma|/|\lambda_j - \sigma|$ , donde  $\lambda_j$  es el segundo autovalor más cercano a  $\sigma$ .
- (d) Analice cómo elegir  $\sigma$  para maximizar la velocidad de convergencia y discuta las implicaciones numéricas de elegir  $\sigma$  muy cercano a  $\lambda_k$  (condicionamiento del sistema lineal vs velocidad de convergencia).

**Ejercicio 20 (Iteración de cociente de Rayleigh)** Este algoritmo es una variante de la potencia inversa donde el shift se actualiza en cada paso usando el cociente de Rayleigh:  $\sigma_k = \frac{(x^{(k)})^T A x^{(k)}}{\|x^{(k)}\|_2^2}$ .

- (a) Escriba los 3 pasos de una iteración genérica  $k \rightarrow k+1$ :

- i. Cálculo del shift:  $\sigma_k = \rho(x^{(k)})$ .
- ii. Resolución del sistema lineal:  $(A - \sigma_k I)y^{(k+1)} = x^{(k)}$ .
- iii. Normalización:  $x^{(k+1)} = y^{(k+1)} / \|y^{(k+1)}\|$ .

- (b) Explique intuitivamente por qué la convergencia es superlineal.

**Ejercicio 21 (Método QR e Iteración Ortogonal)** El método QR utiliza la descomposición QR para calcular autovalores. Consiste en, dada una matriz  $A_1 = A \in \mathbb{R}^{n \times n}$ , generar una sucesión de matrices  $A_k$  definida por:

$$A_k = Q_k R_k \quad (QR), \quad A_{k+1} = R_k Q_k.$$

- (a) Probar que todas las matrices  $A_k$  tienen los mismos autovalores. **Sugerencia:** Demuestre que  $A_{k+1}$  es semejante a  $A_k$ .
- (b) Considere las matrices acumuladas  $\bar{Q}_k = Q_1 Q_2 \cdots Q_k$  y  $\bar{R}_k = R_k R_{k-1} \cdots R_1$ . Demuestre por inducción que  $A^k = \bar{Q}_k \bar{R}_k$ . Es decir,  $\bar{Q}_k$  proviene de la factorización QR de la potencia  $A^k$ . **Sugerencia:** Observe que  $A_{k+1} = Q_k^T A_k Q_k$  y use la hipótesis inductiva.
- (c) Demuestre que  $A^k e_1$  es proporcional a la primera columna de  $\bar{Q}_k$  (use que  $\bar{R}_k$  es triangular superior). Concluya que la primera columna de la matriz ortogonal acumulada converge al autovector dominante de  $A$  (simulando el **método de la potencia** sobre  $e_1$ ).

**Ejercicio 22 (Iteración QR y forma de Hessenberg)** Sea  $H \in \mathbb{R}^{n \times n}$  una matriz en forma de Hessenberg superior, y sea  $H = QR$  su descomposición QR.

- (a) Demuestre que  $Q$  es una matriz de Hessenberg superior. **Sugerencia:** Escriba  $Q = HR^{-1}$  y utilice que el producto de una matriz de Hessenberg superior por una triangular superior es de Hessenberg superior.
- (b) Demuestre que  $H' = RQ$  también está en forma de Hessenberg superior.
- (c) Concluya que si comenzamos con  $A$  en forma de Hessenberg, todas las iteraciones del algoritmo QR permanecen en forma de Hessenberg.

**Ejercicio 23 (Algoritmo QR para raíces de polinomios)** Dado un polinomio mónico  $p(\lambda) = \lambda^n + a_{n-1}\lambda^{n-1} + \cdots + a_1\lambda + a_0$ , su **matriz compañera** es:

$$C = \begin{pmatrix} 0 & 0 & \cdots & 0 & -a_0 \\ 1 & 0 & \cdots & 0 & -a_1 \\ 0 & 1 & \cdots & 0 & -a_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & -a_{n-1} \end{pmatrix}.$$

- (a) Demuestre que el polinomio característico de  $C$  es:

$$\det(C - \lambda I) = (-1)^n p(\lambda).$$

Por lo tanto, los autovalores de  $C$  son precisamente las raíces de  $p$ .

- (b) Demuestre que  $C$  está en forma de Hessenberg superior.
- (c) Concluya que el algoritmo QR aplicado a  $C$  tiene costo  $O(kn^2)$  donde  $k$  es el número de iteraciones requerido.

**Ejercicio 24 (Convergencia de métodos iterativos estacionarios)** Un método iterativo estacionario para resolver  $Ax = b$  tiene la forma  $x^{(k+1)} = Gx^{(k)} + c$ , donde  $G$  es la matriz de iteración.

- (a) Demuestre que para cualquier matriz  $G \in \mathbb{R}^{n \times n}$ :

$$G^k \rightarrow 0 \quad \text{si y solo si} \quad \rho(G) < 1,$$

donde  $\rho(G) = \max_i |\lambda_i(G)|$  es el radio espectral. **Sugerencia:** Use la forma de Jordan de  $G$  y que todas las normas matriciales son equivalentes.

- (b) Demuestre que para cualquier norma matricial:

$$\rho(G) \leq \|G\|.$$

- (c) Concluya que si  $\|G\| < 1$  para alguna norma, entonces el método converge.



**Ejercicio 25 (Método de Jacobi)** El método de Jacobi para  $Ax = b$  es  $x^{(k+1)} = D^{-1}(b - (L+U)x^{(k)})$ , donde  $A = D + L + U$  (diagonal, triangular inferior estricta, triangular superior estricta).

(a) Suponga que  $A$  es *estrictamente diagonal dominante por filas*:

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}|, \quad i = 1, \dots, n.$$

Demuestre que el método de Jacobi converge analizando los autovalores de la matriz de iteración  $G_J$ . **Sugerencia:** Utilice el Teorema de los Círculos de Gershgorin aplicado a la matriz  $G_J = -D^{-1}(L + U)$ . Observe que los elementos diagonales de  $G_J$  son nulos y relacione los radios de los discos con la condición de diagonal dominancia.

(b) Exhiba un ejemplo de matriz simétrica definida positiva para la cual Jacobi diverge.

**Ejercicio 26 (Método de Gauss-Seidel)** El método de Gauss-Seidel para  $Ax = b$  es  $(D + L)x^{(k+1)} = b - Ux^{(k)}$ , con matriz de iteración  $G_{GS} = -(D + L)^{-1}U$ .

(a) Suponga que  $A$  es *estrictamente diagonal dominante por filas*. Demuestre que el método de Gauss-Seidel converge analizando los autovalores de  $G_{GS}$ . **Sugerencia:** Use un argumento similar al de la demostración del Teorema de los Círculos de Gershgorin aplicado a  $G_{GS}$ .