
ELEMENTOS DE CÁLCULO NUMÉRICO

Primer Cuatrimestre 2026

Práctica N° 2: Álgebra Lineal Numérica

Descomposiciones matriciales

Ejercicio 1 (Propiedades de matrices triangulares superiores) Sea $\mathcal{T}_n$ el conjunto de matrices triangulares superiores de tamaño $n \times n$.

- (a) Demuestre que si $A, B \in \mathcal{T}_n$, entonces $AB \in \mathcal{T}_n$.
- (b) Demuestre que si $A \in \mathcal{T}_n$ tiene todos sus elementos diagonales no nulos, entonces A es inversible.
- (c) Demuestre que si $A \in \mathcal{T}_n$ es inversible, entonces $A^{-1} \in \mathcal{T}_n$.

Sugerencia para (c): Considere la ecuación $AA^{-1} = I$ y determine las entradas de A^{-1} por sustitución hacia atrás.

Ejercicio 2 (Descomposición LDL^T para matrices simétricas) Sea $A \in \mathbb{R}^{n \times n}$ una matriz simétrica que admite una descomposición LU sin pivoteo, donde L es triangular inferior con diagonal unitaria y U es triangular superior.

- (a) Demuestre que $U = DL^T$, donde D es una matriz diagonal.
- (b) Concluya que A admite la descomposición $A = LDL^T$.
- (c) Compare el costo de almacenamiento de LDL^T vs LU para matrices simétricas.

Ejercicio 3 (Eficiencia de LU para matrices tridiagonales) Una matriz tridiagonal $A \in \mathbb{R}^{n \times n}$ tiene la forma:

$$A = \begin{pmatrix} b_1 & c_1 & 0 & \cdots & 0 \\ a_2 & b_2 & c_2 & \cdots & 0 \\ 0 & a_3 & b_3 & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & c_{n-1} \\ 0 & \cdots & 0 & a_n & b_n \end{pmatrix}.$$

- (a) Demuestre que si A admite descomposición LU sin pivoteo, entonces L y U son bidiagonales:

$$L = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ \ell_2 & 1 & \ddots & \vdots \\ 0 & \ddots & \ddots & 0 \\ \vdots & & \ell_n & 1 \end{pmatrix}, \quad U = \begin{pmatrix} u_1 & c_1 & 0 & \cdots \\ 0 & u_2 & c_2 & \ddots \\ \vdots & \ddots & \ddots & \ddots \\ 0 & \cdots & 0 & u_n \end{pmatrix}.$$

- (b) Derive fórmulas explícitas para ℓ_i y u_i en términos de a_i, b_i, c_i .
- (c) Demuestre que el costo de factorizar A es $O(n)$ operaciones (en lugar de $O(n^3)$ para matrices densas).
- (d) Demuestre que el costo de resolver $Ax = b$ dado $A = LU$ es $O(n)$ operaciones. ¿Cuántas eran para matrices densas?

Ejercicio 4 (Proyección ortogonal mediante factorización QR) Sea $A \in \mathbb{R}^{m \times n}$ con $m \geq n$ y rango columna completo, y sea $A = QR$ su descomposición QR.

- (a) Demuestre que $P = QQ^T$ es una matriz de proyección, es decir, que $P^2 = P$ y $P^T = P$.
- (b) Demuestre que P proyecta sobre el espacio columna de A : para todo $y \in \mathbb{R}^m$, se tiene $Py \in \text{Col}(A)$.
- (c) Demuestre que P es la proyección ortogonal: $(I - P)y \perp \text{Col}(A)$ para todo $y \in \mathbb{R}^m$.
- (d) Calcule explícitamente la matriz de proyección P para:

$$A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{pmatrix}.$$

Ejercicio 5 (Espacios fundamentales y factorización QR) Sea $A \in \mathbb{R}^{m \times n}$ con $m \geq n$ y sea $A = QR$ su descomposición QR, donde $Q \in \mathbb{R}^{m \times n}$ tiene columnas ortonormales y $R \in \mathbb{R}^{n \times n}$ es triangular superior.

- (a) **Espacio columna:** Suponiendo además que A tiene rango columna completo, demuestre que $\text{Col}(A) = \text{Col}(Q)$.
- (b) **Espacio nulo:** Demuestre que $\text{Nul}(A) = \text{Nul}(R)$.
- (c) Use (a) y (b) para explicar por qué A y Q tienen el mismo rango.
- (d) Si $r = \text{rank}(A) < n$, explique cómo la estructura de R revela esta deficiencia de rango.

Ejercicio 6 (Factorización de Cholesky para matrices definidas positivas) Sea $B \in \mathbb{R}^{n \times n}$ una matriz simétrica definida positiva.

- (a) **Existencia:** Demuestre que B admite una descomposición $B = LL^T$, donde L es triangular inferior.

Comentario: este inciso también puede deducirse usando la descomposición LDL^T para matrices simétricas (Ejercicio 2), junto con la positividad de los pivotes diagonales.

Sugerencia: Escriba $B = B^{1/2}B^{1/2}$ usando la raíz cuadrada matricial y aplique la descomposición QR a $B^{1/2}$.

- (b) **Algoritmo:** Suponiendo que la descomposición $B = LL^T$ existe, derive fórmulas explícitas para las entradas de L y estime el costo del algoritmo.

Sugerencia: Iguale entradas en $B = LL^T$ columna por columna. La entrada (i, j) da $b_{ij} = \sum_{k=1}^{\min(i,j)} \ell_{ik}\ell_{jk}$. Para determinar la columna j de L (es decir, $\ell_{jj}, \ell_{j+1,j}, \dots, \ell_{nj}$), suponiendo conocidas las columnas $1, \dots, j-1$: primero despeje ℓ_{jj} de la entrada diagonal (j, j) , y luego ℓ_{ij} para $i > j$.

Ejercicio 7 (Ajuste polinomial por cuadrados mínimos) Se mide la deformación y (en mm) de una viga en función de la carga aplicada t (en kN), obteniendo los datos:

t_k	1	2	3	4	5
y_k	0.5	2.5	5.8	11.2	18.1

Se propone ajustar un polinomio de grado 2: $p(t) = c_0 + c_1t + c_2t^2$.

- (a) Escriba el sistema sobredeterminado $Ac = y$.
- (b) Plantee las ecuaciones normales $A^T Ac = A^T y$ y calcule $A^T A$ y $A^T y$.
- (c) ¿Qué cambiaría en la matriz A si en lugar de la base $\{1, t, t^2\}$ se usara la base $\{1, t, \frac{1}{2}(3t^2 - 1)\}$?

Ejercicio 8 (Linealización de modelos no lineales) En muchas aplicaciones, los datos siguen un modelo que no es lineal en los parámetros, pero puede **linealizarse** mediante un cambio de variable.

- (a) **Modelo exponencial:** La concentración de un fármaco en sangre sigue $y = \alpha e^{\beta t}$, donde $\alpha > 0$ y $\beta < 0$ son desconocidos. Se tienen los datos:

t_k (horas)	0	1	2	3	4
y_k (mg/L)	10.2	6.9	4.3	3.2	1.9

Aplique logaritmo natural a ambos lados del modelo y plantee el problema de cuadrados mínimos resultante. Identifique la matriz A y el vector b .

- (b) **Modelo potencial:** La velocidad del viento y a altura t sigue una ley de potencia $y = \alpha t^\beta$. Se tienen las mediciones:

t_k (metros)	10	20	40	80	100
y_k (m/s)	5.1	5.9	6.8	7.8	8.2

Linealice el modelo y plantee el problema de cuadrados mínimos correspondiente.

- (c) **Discusión:** La linealización transforma el problema de minimizar $\sum_k (y_k - \alpha e^{\beta t_k})^2$ en minimizar $\sum_k (\ln y_k - \ln \alpha - \beta t_k)^2$. ¿Son equivalentes estos dos problemas de optimización? ¿En qué sentido la linealización altera el peso relativo de las observaciones?

Ejercicio 9 (Cuadrados mínimos en el caso complejo: ajuste de sinusoides) Un *sis-
mógrafo* registra una señal $y(t)$ que se modela como superposición de ondas sinusoidales de
frecuencias conocidas $\omega_1, \omega_2, \dots, \omega_n$:

$$y(t) = \sum_{j=1}^n c_j e^{i\omega_j t}, \quad c_j \in \mathbb{C}.$$

Las amplitudes complejas c_j (que codifican amplitud y fase de cada onda) son desconocidas.
Se dispone de $m > n$ mediciones $y_k = y(t_k)$ en tiempos $t_1, \dots, t_m$, contaminadas por ruido,
por lo que el sistema es incompatible y se busca la solución de cuadrados mínimos:

$$\min_{c \in \mathbb{C}^n} \|Ac - y\|_2, \quad \text{donde } A_{kj} = e^{i\omega_j t_k}, \quad y = (y_1, \dots, y_m)^T.$$

- (a) Escriba las ecuaciones normales para este problema. Verifique que la matriz A^*A es
hermítica y definida positiva.
- (b) Suponga $n = 2$ frecuencias $\omega_1 = 1$, $\omega_2 = 3$, con $m = 4$ mediciones equiespaciadas
 $t_k = \frac{\pi}{4}(k-1)$, $k = 1, \dots, 4$. Escriba explícitamente la matriz $A \in \mathbb{C}^{4 \times 2}$.

Ejercicio 10 (Análisis del timbre de un instrumento musical) Cuando un instrumento
musical produce una nota con frecuencia fundamental ω_0 , la señal resultante es una superposi-
ción de la fundamental y sus **armónicos superiores** $2\omega_0, 3\omega_0, \dots$:

$$y(t) = \sum_{j=1}^n c_j e^{ij\omega_0 t}, \quad c_j \in \mathbb{C}.$$

La frecuencia fundamental ω_0 determina la nota (por ejemplo, un La central corresponde a
440 Hz). El **timbre**, que es lo que permite distinguir la misma nota tocada por un piano,
un violín o una flauta, está determinado por las amplitudes relativas $|c_1|, |c_2|, \dots, |c_n|$ de cada
armónico. Por ejemplo, una flauta tiene casi toda la energía en la fundamental ($|c_1| \gg |c_j|$
para $j \geq 2$), mientras que un oboe tiene armónicos superiores muy pronunciados.

El objetivo es, dada una grabación de una nota conocida, estimar los coeficientes c_j para
caracterizar el timbre del instrumento. Se toman $m > n$ muestras $y_k = y(t_k)$ (contaminadas
por ruido) y se plantea el problema de cuadrados mínimos:

$$\min_{c \in \mathbb{C}^n} \|Ac - y\|_2, \quad \text{donde } A_{kj} = e^{ij\omega_0 t_k}, \quad y = (y_1, \dots, y_m)^T.$$

Considere un La central ($\omega_0 = 440 \cdot 2\pi$ rad/s) con $n = 3$ armónicos y $m = 6$ muestras
equiespaciadas en $t_k = \frac{k-1}{6 \cdot 440}$ para $k = 1, \dots, 6$.

- (a) Escriba la matriz $A \in \mathbb{C}^{6 \times 3}$ y verifique que las columnas de A son ortogonales, es decir,
que $A^*A = 6I_3$.
- (b) Use el teorema de la proyección ortogonal para escribir directamente la solución de cuadra-
dos mínimos. ¿Cuál es la complejidad del algoritmo obtenido, en comparación con resolver
las ecuaciones normales o realizar la descomposición QR?

Ejercicio 11 Sea $A \in \mathbb{C}^{n \times n}$ una matriz no singular. Demuestre que la distancia de A al conjunto de matrices singulares (en norma 2) es exactamente su menor valor singular σ_n . Es decir:

$$\min_{B \text{ singular}} \|A - B\|_2 = \sigma_n.$$

Ejercicio 12 (Descomposición polar desde SVD) Toda matriz $A \in \mathbb{R}^{m \times n}$ admite una **descomposición polar** $A = Q_{\text{polar}} S$, donde:

- $Q_{\text{polar}} \in \mathbb{R}^{m \times n}$ tiene columnas ortonormales ($Q_{\text{polar}}^T Q_{\text{polar}} = I_n$).
- $S \in \mathbb{R}^{n \times n}$ es simétrica semidefinida positiva.

Sea $A = U \Sigma V^T$ la descomposición SVD de A . Demuestre que:

$$Q_{\text{polar}} = UV^T, \quad S = V \Sigma V^T.$$

Ejercicio 13 (Problema de Procrustes ortogonal) Dadas dos matrices $A, B \in \mathbb{R}^{m \times n}$ representando conjuntos de datos (nubes de puntos), queremos encontrar la matriz ortogonal $Q \in \mathbb{R}^{n \times n}$ óptima (geoméricamente, la rotación óptima) que transforma A en B minimizando:

$$\min_{Q^T Q = I} \|AQ - B\|_F,$$

donde $\|\cdot\|_F$ es la norma de Frobenius.

- (a) Demuestre que minimizar $\|AQ - B\|_F^2$ es equivalente a maximizar $\text{tr}(Q^T A^T B)$.
- (b) Sea $A^T B = U \Sigma V^T$ la descomposición SVD de $A^T B$. Demuestre que la solución óptima es:

$$Q = UV^T.$$

Ejercicio 14 (Pseudoinversa y solución de norma mínima) Sea $A \in \mathbb{R}^{m \times n}$ con $m \geq n$ y $r = \text{rank}(A) \leq n$. Sea $A = U \Sigma V^T$ su SVD, donde $U = (u_1 \mid \cdots \mid u_m) \in \mathbb{R}^{m \times m}$ y $V = (v_1 \mid \cdots \mid v_n) \in \mathbb{R}^{n \times n}$ son ortogonales, y $\Sigma \in \mathbb{R}^{m \times n}$ tiene entradas diagonales $\sigma_1 \geq \cdots \geq \sigma_r > 0 = \sigma_{r+1} = \cdots = \sigma_n$. Se define la **pseudoinversa de Moore-Penrose** como:

$$A^+ = V \Sigma^+ U^T = \sum_{i=1}^r \frac{1}{\sigma_i} v_i u_i^T \in \mathbb{R}^{n \times m},$$

donde $\Sigma^+ \in \mathbb{R}^{n \times m}$ tiene entradas diagonales $1/\sigma_1, \dots, 1/\sigma_r, 0, \dots, 0$.

Consideramos el problema de cuadrados mínimos $\min_x \|Ax - b\|_2$

- (a) Demuestre que si $r < n$, el problema de cuadrados mínimos admite infinitas soluciones.
Sugerencia: Si $\hat{x}$ es una solución, considere $\hat{x} + z$ con $z \in \text{Ker}(A)$.
- (b) Demuestre que $x = A^+ b$ es una solución del problema de cuadrados mínimos.
- (c) Demuestre que entre todas las soluciones de cuadrados mínimos, $x = A^+ b$ tiene norma mínima. Es decir, si definimos el conjunto de soluciones de cuadrados mínimos como

$$\mathcal{S} = \text{argmin}_{x \in \mathbb{R}^n} \|Ax - b\|_2,$$

entonces $\|A^+ b\|_2 = \min_{x \in \mathcal{S}} \|x\|_2$.

Ejercicio 15 (Condicionamiento de mínimos cuadrados vía SVD) Sea $A \in \mathbb{R}^{m \times n}$ con $m \geq n$ y rango columna completo, con descomposición QR $A = QR$ y SVD $A = U\Sigma V^T$. Usando la SVD de A , demuestre que:

$$\kappa(A^T A) = \left(\frac{\sigma_{\max}(A)}{\sigma_{\min}(A)} \right)^2 = \kappa(R)^2,$$

donde $\kappa(\cdot)$ denota el número de condición en norma 2 para matrices inversibles. Concluya que resolver el problema de mínimos cuadrados vía QR es numéricamente más estable que vía las ecuaciones normales cuando A está mal condicionada.

Métodos iterativo para autovalores y sistemas lineales

Ejercicio 16 (Método de la potencia: análisis de convergencia) Sea $A \in \mathbb{R}^{n \times n}$ una matriz diagonalizable con autovalores $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$ y autovectores linealmente independientes $\{v_1, \dots, v_n\}$. El método de la potencia construye la sucesión $x^{(k+1)} = \frac{Ax^{(k)}}{\|Ax^{(k)}\|}$.

(a) Si escribimos el vector inicial como $x^{(0)} = c_1 v_1 + \dots + c_n v_n$ con $c_1 \neq 0$, demuestre que:

$$A^k x^{(0)} = \lambda_1^k \left(c_1 v_1 + \sum_{j=2}^n c_j \left(\frac{\lambda_j}{\lambda_1} \right)^k v_j \right).$$

(b) Deduzca que la dirección de $x^{(k)}$ converge a la dirección de v_1 (autovector dominante) cuando $k \rightarrow \infty$.

(c) Identifique el término que controla la velocidad de convergencia y exprese la tasa de convergencia en función de los autovalores.

(d) Demuestre que el cociente de Rayleigh $\rho(x^{(k)}) = \frac{(x^{(k)})^T A x^{(k)}}{\|x^{(k)}\|_2^2}$ converge a λ_1 (asuma convergencia de $x^{(k)}$ a v_1 normalizado).

Ejercicio 17 (Método QR e Iteración Ortogonal) El **método QR** utiliza la descomposición QR para calcular autovalores. Consiste en, dada una matriz $A_1 = A \in \mathbb{R}^{n \times n}$, generar una sucesión de matrices A_k definida por:

$$A_k = Q_k R_k \quad (QR), \quad A_{k+1} = R_k Q_k.$$

(a) Probar que todas las matrices A_k tienen los mismos autovalores. **Sugerencia:** Demuestre que A_{k+1} es semejante a A_k .

(b) Considere las matrices acumuladas $\bar{Q}_k = Q_1 Q_2 \dots Q_k$ y $\bar{R}_k = R_k R_{k-1} \dots R_1$. Demuestre por inducción que $A^k = \bar{Q}_k \bar{R}_k$. Es decir, $\bar{Q}_k$ proviene de la factorización QR de la potencia A^k . **Sugerencia:** Observe que $A_{k+1} = Q_k^T A_k Q_k$ y use la hipótesis inductiva.

(c) Demuestre que $A^k e_1$ es proporcional a la primera columna de $\bar{Q}_k$ (use que $\bar{R}_k$ es triangular superior). Concluya que la primera columna de la matriz ortogonal acumulada converge al autovector dominante de A (simulando el **método de la potencia** sobre e_1).

Ejercicio 18 (Algoritmo QR para raíces de polinomios) Dado un polinomio mónico $p(\lambda) = \lambda^n + a_{n-1}\lambda^{n-1} + \cdots + a_1\lambda + a_0$, su **matriz compañera** es:

$$C = \begin{pmatrix} 0 & 0 & \cdots & 0 & -a_0 \\ 1 & 0 & \cdots & 0 & -a_1 \\ 0 & 1 & \cdots & 0 & -a_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & -a_{n-1} \end{pmatrix}.$$

(a) Demuestre que el polinomio característico de C es:

$$\det(C - \lambda I) = (-1)^n p(\lambda).$$

Por lo tanto, los autovalores de C son precisamente las raíces de p .

Ejercicio 19 (Convergencia de métodos iterativos estacionarios) Un método iterativo estacionario para resolver $Ax = b$ tiene la forma $x^{(k+1)} = Gx^{(k)} + c$, donde G es la matriz de iteración.

(a) Demuestre que para cualquier matriz $G \in \mathbb{R}^{n \times n}$:

$$G^k \rightarrow 0 \quad \text{si y solo si} \quad \rho(G) < 1,$$

donde $\rho(G) = \max_i |\lambda_i(G)|$ es el radio espectral. **Sugerencia:** Use la forma de Jordan de G y que todas las normas matriciales son equivalentes.

(b) Demuestre que para cualquier norma matricial:

$$\rho(G) \leq \|G\|.$$

(c) Concluya que si $\|G\| < 1$ para alguna norma, entonces el método converge.

Ejercicio 20 (Método de Jacobi) El método de Jacobi para $Ax = b$ es $x^{(k+1)} = D^{-1}(b - (L+U)x^{(k)})$, donde $A = D + L + U$ (diagonal, triangular inferior estricta, triangular superior estricta).

(a) Suponga que A es **estrictamente diagonal dominante por filas**:

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}|, \quad i = 1, \dots, n.$$

Demuestre que el método de Jacobi converge analizando los autovalores de la matriz de iteración G_J . **Sugerencia:** Utilice el Teorema de los Círculos de Gershgorin aplicado a la matriz $G_J = -D^{-1}(L + U)$. Observe que los elementos diagonales de G_J son nulos y relacione los radios de los discos con la condición de diagonal dominancia.

(b) Exhiba un ejemplo de matriz simétrica definida positiva para la cual Jacobi diverge.

Ejercicio 21 (Método de Gauss-Seidel) El método de Gauss-Seidel para $Ax = b$ es $(D + L)x^{(k+1)} = b - Ux^{(k)}$, con matriz de iteración $G_{GS} = -(D + L)^{-1}U$.

(a) Suponga que A es estrictamente diagonal dominante por filas. Demuestre que el método de Gauss-Seidel converge analizando los autovalores de G_{GS} . **Sugerencia:** Use un argumento similar al de la demostración del Teorema de los Círculos de Gershgorin aplicado a G_{GS} .