
ELEMENTOS DE CÁLCULO NUMÉRICO

Primer Cuatrimestre 2026

Laboratorio N° 6: Método de Newton en varias variables y Descenso por Gradiente

Ejercicio 1 (Intersección de curvas planas: método de Newton en $\mathbb{R}^2$.)

Considere el sistema de ecuaciones

$$F(x, y) = \begin{pmatrix} f_1(x, y) \\ f_2(x, y) \end{pmatrix} = \begin{pmatrix} x^2 + y^2 + xy - 7 \\ x^3 - y + 1 \end{pmatrix} = \mathbf{0}. \quad (1)$$

Geométricamente, $f_1 = 0$ es una elipse (rotada) y $f_2 = 0$ es la curva cúbica $y = x^3 + 1$.

- (a) Verifique algebraicamente que $(x_*, y_*) = (1, 2)$ es solución exacta de (1).
- (b) Calcule analíticamente la matriz jacobiana

$$J(x, y) = \frac{\partial F}{\partial (x, y)} = \begin{pmatrix} \partial_x f_1 & \partial_y f_1 \\ \partial_x f_2 & \partial_y f_2 \end{pmatrix}.$$

Evalúe $J(1, 2)$ y verifique que es invertible.

- (c) El método de Newton para $F(x, y) = \mathbf{0}$ es la iteración

$$\mathbf{p}^{(k+1)} = \mathbf{p}^{(k)} - J(\mathbf{p}^{(k)})^{-1} F(\mathbf{p}^{(k)}).$$

Implemente esta iteración. En la práctica, en lugar de invertir J , resuelva el sistema lineal $J\delta = -F$ y actualice $\mathbf{p} \leftarrow \mathbf{p} + \delta$ (use `numpy.linalg.solve`). Itere hasta que $\|F(\mathbf{p}^{(k)})\| < 10^{-10}$.

- (d) Ejecute Newton a partir de $\mathbf{p}^{(0)} = (0, 0)$. Registre $\|F(\mathbf{p}^{(k)})\|$ en cada iteración y gráfiquelo en escala semilogarítmica. ¿En cuántas iteraciones converge? ¿Observa convergencia cuadrática?
- (e) La curva cúbica y la elipse se intersectan en más de un punto. Grafique ambas curvas en la región $[-3, 3] \times [-3, 6]$ e identifique visualmente una segunda solución. Ejecute Newton desde un punto inicial próximo a ella y repórtela.

Ejercicio 2 (Descenso por gradiente para regresión logística: dataset *Titanic*.)

Se desea predecir la supervivencia de un pasajero del Titanic a partir de tres atributos: género (**sex**), clase del pasaje (**pclass**) y edad (**age**). El modelo es una *regresión logística*: dado el vector de atributos extendido $\mathbf{x} \in \mathbb{R}^4$ (los tres atributos más un 1 para el sesgo), la probabilidad predicha de supervivencia es

$$\hat{p}(\mathbf{x}; \mathbf{w}) = \sigma(\mathbf{w}^\top \mathbf{x}), \quad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

El parámetro $\mathbf{w} \in \mathbb{R}^4$ se ajusta minimizando la *pérdida cuadrática*

$$L(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n (\hat{p}(\mathbf{x}_i; \mathbf{w}) - y_i)^2,$$

donde $y_i \in \{0, 1\}$ es la etiqueta de supervivencia del pasajero i .

(a) **Preparación de datos.** Cargue el dataset con

```
import seaborn as sns; df = sns.load_dataset('titanic')
```

Construya la matriz $X \in \mathbb{R}^{n \times 4}$ y el vector $\mathbf{y} \in \{0, 1\}^n$ de la siguiente forma:

- Elimine las filas con valores faltantes en `age`, `sex` o `pclass`.
- Codifique `sex`: `male` $\mapsto 0$, `female` $\mapsto 1$.
- Normalice `age` y `pclass` restando la media y dividiendo por el desvío estándar.
- Añada una columna de unos (sesgo) como última columna de X .
- Tome $\mathbf{y}$ de la columna `survived`.

Reporte n , la fracción de supervivientes y las dimensiones de X .

(b) **Gradiente de la pérdida.** Muestre que

$$\nabla_{\mathbf{w}} L(\mathbf{w}) = \frac{2}{n} \sum_{i=1}^n (\hat{p}_i - y_i) \hat{p}_i (1 - \hat{p}_i) \mathbf{x}_i,$$

donde $\hat{p}_i = \sigma(\mathbf{w}^\top \mathbf{x}_i)$. En forma matricial, si $\hat{\mathbf{p}} = \sigma(X\mathbf{w})$ (componente a componente):

$$\nabla_{\mathbf{w}} L(\mathbf{w}) = \frac{2}{n} X^\top [(\hat{\mathbf{p}} - \mathbf{y}) \odot \hat{\mathbf{p}} \odot (1 - \hat{\mathbf{p}})],$$

donde $\odot$ denota el producto de Hadamard (componente a componente). Verifique numéricamente esta fórmula comparándola con diferencias finitas centradas para un $\mathbf{w}$ de prueba.

(c) **Implementación.** Programe la función `descenso_gradiente(X, y, alpha, n_iter)` que, partiendo de $\mathbf{w}^{(0)} = \mathbf{0}$, ejecute n_{iter} pasos de descenso con paso constante α :

$$\mathbf{w}^{(k+1)} = \mathbf{w}^{(k)} - \alpha \nabla L(\mathbf{w}^{(k)}).$$

La función debe devolver el historial de pérdidas $\{L(\mathbf{w}^{(k)})\}_{k=0}^{n_{\text{iter}}}$.

- (d) **Efecto del paso α .** Ejecute el método para $\alpha \in \{0.01, 0.1, 1.0, 5.0\}$ con $n_{\text{iter}} = 500$. Grafique en una misma figura las curvas de pérdida vs. iteración. ¿Qué ocurre con α demasiado grande? ¿Converge para todos los valores?
- (e) **Evaluación.** Con el α que produjo mejor convergencia, calcule la *accuracy* (fracción de predicciones correctas) usando el criterio $\hat{y}_i = \mathbf{1}[\hat{p}_i \geq 0.5]$. Compare este resultado con el clasificador trivial que siempre predice la clase mayoritaria.

Ejercicio 3 (* Búsqueda de sección áurea para minimización unidimensional.)

Sea $f : [a_0, b_0] \rightarrow \mathbb{R}$ continua y unimodal en $[a_0, b_0]$ (es decir, existe un único minimizador $x_* \in [a_0, b_0]$ y f decrece a la izquierda de x_* y crece a su derecha). El método de sección áurea mantiene dos puntos interiores

$$x_1 = b_k - \tau(b_k - a_k), \quad x_2 = a_k + \tau(b_k - a_k), \quad 0 < \tau < 1,$$

y, según la comparación entre $f(x_1)$ y $f(x_2)$, descarta uno de los extremos para construir $[a_{k+1}, b_{k+1}] \subset [a_k, b_k]$.

- (a) Imponga la condición de *reutilización*: al pasar de $[a_k, b_k]$ a $[a_{k+1}, b_{k+1}]$, uno de los dos puntos interiores del paso k debe coincidir con un punto interior del paso $k+1$. Deduzca que τ debe satisfacer

$$\tau^2 = 1 - \tau,$$

y concluya que

$$\tau = \frac{\sqrt{5} - 1}{2}.$$

- (b) Demuestre que, con esta elección de τ , en cada iteración se realiza **una sola** evaluación nueva de la función (la otra se reutiliza de la iteración anterior).
- (c) Pruebe que la longitud del intervalo verifica

$$b_{k+1} - a_{k+1} = \tau(b_k - a_k),$$

y por inducción

$$b_k - a_k = \tau^k(b_0 - a_0).$$

A partir de esto, obtenga una cota del número de iteraciones necesario para garantizar $b_k - a_k \leq \varepsilon$.

- (d) Demuestre que el minimizador x_* pertenece a todos los intervalos generados:

$$x_* \in [a_k, b_k] \quad \text{para todo } k.$$

Luego, usando que los intervalos son encajados y que su longitud tiende a 0, concluya que

$$\bigcap_{k \geq 0} [a_k, b_k] = \{x_*\},$$

y por lo tanto el método converge al minimizador. Si define la aproximación $m_k = (a_k + b_k)/2$, pruebe además que $m_k \rightarrow x_*$.

- (e) (Opcional) Implemente el método y verifique numéricamente la ley de contracción en una función de prueba, por ejemplo $f(x) = (x-1.7)^2 + e^{0.2x}$ en un intervalo inicial que contenga al minimizador.